

动态规划 确定性和 随机模型

[美] D.P. 柏塞克斯 著
李人厚 韩崇昭 译

西安交通大学出版社


外国教材精选

动态规划 确定性和随机模型

[美] D. P. 柏塞克斯 著

李人厚 韩崇昭 译

JY1-15/28



西安交通大学出版社

内 容 简 介

本书介绍了动态规划的概念、算法及其应用。对不完全状态信息情况下的动态规划问题，书中作了详尽的叙述，尤其对无限时域动态规划及其应用的阐述较为精辟，不多见于其它文献。作者对问题的表述尽可能深入浅出，而对动态规划在不同领域中的应用，以统一的数学方法予以处理，很有特色。

本书适合作为自动控制、系统工程、计算机科学与工程以及应用数学等专业大学本科生、研究生的教材或参考书，也可供工程技术人员参考。

Dynamic Programming: Deterministic and Stochastic Models

D. P. Bertsekas

Prentice-Hall, 1987

动态规划 确定性和随机模型

[美] D. P. 柏塞克斯 著

李人厚 韩崇昭 译

*

西安交通大学出版社出版

(西安市咸宁路28号)

西安电子科技大学出版社印刷厂印装

陕西省新华书店发行 各地新华书店经售

*

开本 787×1092 1/16 印张 18.5 字数 448 千字

1990年1月第1版 1990年1月第1次印刷

印数: 1—1 000

ISBN 7-5605-0308-x/O·57 定价: 4.10 元

《外国教材精选》总序

近十年来,我国高等学校教材建设在经历了从无到有、巩固提高的过程之后,目前正进入向高质量、高层次、多品种发展的欣欣向荣,百花争艳时期。现在,教材建设仍是高等学校教学改革的重要方面,这里也存在一个改革开放的问题。在这种形势下,精选国外一些有影响、有特色、特别是世界上著名大学现用的优秀教材翻译出版,无疑将对我国当前教材建设起到借鉴、促进和填补某些学科空白的积极作用。为此,西安交通大学出版社决定组织翻译出版一套《外国教材精选》系列书。

外国教材专业面广、类型繁多、层次各异,我们这套系列书在选题时以专业面较广,内容新颖或具有明显特色的教材为目标,具体原则如下:

1. 列选的教材不限国别及语种,以便博采众长。
2. 国外著名经典性教材,多次修订重版经久不衰者。
3. 最新出版,为国外著名大学所采用,有独特风格、体系,能反映国外教育动向,可供借鉴者。
4. 反映最新科技成果,能填补国内某学科教材空缺者。

根据我校具体情况,《外国教材精选》系列书将以电类教材(含电力、电子、计算机与信息科学)为主。今后随着形势的发展和需要,再进一步组织其他学科的国外先进教材翻译出版。

我们期望这套系列书,不仅是高等学校的学生和教师的良师益友;而且对已在生产科研第一线的广大科技工作者的知识更新,吸取国外科技新成果方面也大有裨益。

这套《外国教材精选》虽然从搜求原著、遴选、翻译、审校等方面都做了较细致的工作,但从浩如烟海的外国教材中精选少数形成一套系列书,对我们毕竟还是一种尝试。书源还不够充分,经验也感不足,缺点在所难免,诚挚地希望读者予以指正。

西安交通大学《外国教材精选》编委会

1988年6月

译者序

动态规划自贝尔曼(Bellman)开创以来,在理论研究和实际应用两个方面都有着重大的进展,它已成为动态系统优化的重要手段之一。

呈现在读者面前的这套教材是柏塞克斯(D.P.Bertsekas)教授十多年来在美国斯坦福大学、伊里诺斯大学、麻省理工学院等著名大学中讲课内容的结晶,是一本很具特色的优秀著作。作者以完整的理论体系阐述了确定性和随机性动态规划的基本理论,并把它在自动控制、人工智能、系统工程等学科中的应用融会贯通。书中不仅对有限时域、完全状态信息的动态规划作了系统的论述,而且对无限时域、不完全状态信息的动态规划问题也作了较严格的探讨,这是一般参考书中所很少涉及的。

本书在论述中,尽量避免采用繁琐的数学推导,作者往往从实际工程应用例子入手,其中包括数学发展史上许多著名的例题,引人入胜地介绍了动态规划的基本概念和方法,深入浅出,脍炙人口,书中各章带有启发性的习题,更会引起读者对动态规划的广泛兴趣。所以,本书很适合作教材,适用于工科大学自动控制、计算机科学、系统工程、应用数学等专业的本科生和研究生。对这些领域中的工程技术人员,也无疑是一本很好的参考书。

书中最后部分引入了无限时域问题的一些主要算法,如逐次逼近法,策略迭代法,和自适应集结法。这些都是作者最近几年来对动态规划理论和方法的新贡献,也是研究动态规划的热门课题。

愿本书的翻译出版对推动动态规划的学术研究和工程应用有所裨益。

在翻译过程中,对原著的个别印刷错误和笔误作了修正。限于译者的水平,译文中的错误和不妥之处在所难免,敬希广大读者不吝赐教。

游兆永教授对本书的译稿进行了认真的审阅,并提出许多宝贵意见,谨表感谢。

李人厚 韩崇昭

一九八八年九月

于西安交通大学

原 著 序

本书是根据14年来在斯坦福大学、伊里诺斯大学和麻省理工学院讲授动态规划和随机控制的课程发展而来的。本书的目的是从工程、运筹学、以至经济学和应用数学的某些方面，提供适合于广大读者的关于这个专题的统一处理方法。例如，我们同时处理现代控制理论中众所周知的随机控制问题；运筹学中普遍涉及的马尔科夫决策问题；以及在计算机科学中经常强调的组合问题。书中用大量不同类型的例题来阐明理论，其中许多例题本身还包含重要的应用。这些例题可以按类概括而彼此独立，所以教师可有所侧重地应用其中一类，使课程适合于自己的对象。

很好掌握概率导论和本科生数学是本书在教学基础方面的要求。这包括一学期的概率论与普通微积分、实分析、向量矩阵代数、以及几乎所有本科生在第四学年都要学习的基础优化理论。在本书附录中提供了这些材料的综述。关于动态系统理论、优化或控制的先修课程或背景材料无疑对读者会有帮助，我们认为本材料的内容是合理地自成体系的。

动态规划是能用基本分析充分阐明和解释的一种概念上简单的技术。然而在数学上如要严格地全面处理，则随机动态规划需要测度概率论方面的复杂知识。我决定绕开这些复杂的数学，用一般的假定来进行分析。它仅当所探讨的概率空间为可数时才认为是严格的。对此问题的数学上的严格处理，在我和 Steven Shreve 合著的专著《随机最优控制：离散时间情况》(Stochastic Optimal Control: The Discrete Time Case, Academic Press, 1978)中予以完成。这本专著是对本教材的补充，并为本书中某些未十分成熟的专题提供了坚实的基础。

我衷心感谢对本书作出贡献的许多个人和院校。在与 Steven Shreve 一起完成1973年的专著时，使我加深了对专题的理解。在此期间完善了处理无限时域问题的几个证明和结果，现已成为本教材内容的一部分。Michael Caramanis, Lennart Ljung 和 John Tsitsiklis 讲授了本书的修订本，而且提供了一些实质性评论和习题。这些年来，在与几位有才干的助教交往中得益匪浅。这些交往中，特别要提到 Paris Canellakis, Panos Constantopoulos 和 John Tsitsiklis。很多同事提供了有价值的见解和信息，特别是 David Castanon 和 Krishna Pattipati。(美国)国家科学基金会(NSF)支持了第五章所述关于无限时域问题的研究，麻省理工学院以其令人鼓舞的教学和研究环境，成为实现该项工作的理想场所。

D.P. 柏塞克斯

(Dimitri P. Bertsekas)

目 录

译者序

原著序

第一章 动态规划算法

- § 1.1 基本问题 (1)
- § 1.2 动态规划算法 (8)
- § 1.3 确定性系统和最短路径问题 (16)
- § 1.4 最短路径在统筹分析、编码理论和正向搜索中的应用 (19)
- § 1.5 时间滞后、相关扰动及预报 (29)
- § 1.6 注记 (33)

第二章 特殊领域中的应用

- § 2.1 线性系统和二次代价函数：确定性等价原理 (41)
- § 2.2 库存控制 (48)
- § 2.3 动态证券分析 (53)
- § 2.4 最优停止问题 (57)
- § 2.5 调度和次序互换理论 (63)
- § 2.6 注记 (66)

第三章 不完全状态信息问题

- § 3.1 简化成完全状态信息情况 (72)
- § 3.2 线性系统和二次代价：估计和控制的分离 (74)
- § 3.3 线性系统的最小方差控制 (78)
- § 3.4 充分统计和有限状态马尔科夫链：一个示教问题 (90)
- § 3.5 假设检验：序列概率比检验 (97)
- § 3.6 注记 (100)

第四章 次优与自适应控制

- § 4.1 确定性等价控制 (106)
- § 4.2 开环反馈控制器 (108)
- § 4.3 有限前瞻策略：在柔性制造和计算机下棋中的应用 (110)
- § 4.4 自适应控制：自校正调节器 (119)
- § 4.5 注记 (126)

第五章 无限时域问题：理论部分

- § 5.1 基本结果 (132)
- § 5.2 计算方法：逐次逼近，策略迭代，自适应集结，线性规划 (138)
- § 5.3 收缩映射的作用 (152)
- § 5.4 每阶段无界代价和无折扣问题 (153)
- § 5.5 非平稳与周期性问题 (165)

§ 5.6 注记	(169)
第六章 无限时域问题: 应用部分	
§ 6.1 线性系统与二次代价	(180)
§ 6.2 库存控制	(181)
§ 6.3 最优停止	(183)
§ 6.4 首次通过问题 ^[原注]	(188)
§ 6.5 随机调度和多臂投赌机问题	(194)
§ 6.6 最优博弈策略	(201)
§ 6.7 连续时间马尔科夫链及其一致化: 在排队系统中的应用 ^[原注]	(207)
§ 6.8 注记	(218)
第七章 每阶段平均代价的极小化	
§ 7.1 最优性条件	(232)
§ 7.2 逐次逼近、误差界限和线性规划解	(238)
§ 7.3 策略迭代	(246)
§ 7.4 无限状态空间: 具有二次代价泛函的线性系统	(249)
§ 7.5 注记	(251)
附录: 存在性结果和证明	
附录 A: 数学综述	(259)
A.1 集合	(259)
A.2 欧氏空间	(260)
A.3 矩阵	(260)
A.4 R^n 中的拓扑概念	(261)
A.5 凸集和函数	(262)
附录 B: 关于优化理论	(264)
附录 C: 关于概率论	(266)
附录 D: 关于有限状态马尔科夫链	(269)
参考文献	(272)

第一章 动态规划算法

§ 1.1 基本问题

本书研究分阶段进行决策的情况。虽然每次决策所产生的结果无法充分预见，但在下次决策之前可以进行观测。其目标是对某个代价函数——被认为是希望结果的一个数学表达式求极小。

这种问题的关键是不能用孤立的观点看待决策。决策者必须在希望当前代价低与未来难以避免的高代价可能性之间进行平衡。动态规划把握了这一思想，它在每个阶段选择一个使当前阶段代价之和最小，而且对未来阶段也可期望是最好的决策。

范围很广的一类问题可以按这种方式来处理，而本书尽力保持这一主导思想，不因与问题结构不相干的假设而造成混乱。因此，本节对有限阶段(有限时域)动态系统的最优控制问题，建立了一种应用范围很广的模型。前四章我们遇到的都是这种模型。其无限时域形式将是后三章研究的主题。

基本问题的两个主要特征决定了其结构：(1)一个作为基础的离散时间动态系统；(2)对整个时间相加的一个代价泛函。动态系统具有如下形式

$$x_{k+1} = f_k(x_k, u_k, w_k), \quad k=0, 1, \dots, N-1,$$

其中

k : 离散时间标号；

x_k : 系统状态，总合了与未来优化有关的过去的信息；

u_k : 在已知状态 x_k 的情况下，在时刻 k 所选择的控制或决策变量；

w_k : 随机参数(也称为扰动或噪声)；

N : 时域或施加控制的次数。

代价泛函在下述意义上具有相加性，即在每个时刻 k ，引起代价 $g_k(x_k, u_k, w_k)$ ，而沿任意系统样本轨线的总代价为

$$g_N(x_N) + \sum_{k=0}^{N-1} g_k(x_k, u_k, w_k),$$

其中 $g_N(x_N)$ 是在过程结束时所产生的终端代价。然而，因为 w_k 的存在，代价函数一般是一个随机变量，优化无意义。所以我们把问题按如下方式来表述，即要选择控制 $u_0, u_1, \dots, u_{N-1}$ ，使得期望代价

$$E\left\{g_N(x_N) + \sum_{k=0}^{N-1} g_k(x_k, u_k, w_k)\right\}$$

为极小，式中是相对于所涉及随机变量的联合分布求期望。

稍后我们会对上面所用术语给出更精确的定义。首先我们通过几个例题提供某些带方向性的问题。

库存控制例题

考虑在 N 个时间周期的每一个开始时刻订购一定数量货物以满足随机需求的问题。我们记

x_k : 表示在第 k 个周期开始时刻具有的存货量;

u_k : 表示在第 k 个周期开始时刻的订货量(且立即发货);

w_k : 表示第 k 个周期的需求量, 具有给定的概率分布。假定 $w_0, \dots, w_{N-1}$ 为独立的随机变量, 且假定超额的订货被拖欠, 一旦另有库存立即予以满足。这样, 存货量按离散时间(或差分)方程演变:

$$x_{k+1} = x_k + u_k - w_k,$$

其中负的存货量相应于拖欠的需求(见图 1.1)。




图 1.1 库存控制例题。在周期 k 的存货量(状态) x_k , 在周期 k 的订货量(控制) u_k , 以及在周期 k 的需求量(随机扰动) w_k , 利用差分方程 $x_{k+1} = x_k + u_k - w_k$, 决定了下一周期 $k+1$ 的存货量, 以及第 k 个周期的代价。

每个周期 k 所造成的代价由两部分组成: (1) 采购价格 cu_k , 其中 c 是订购单位货物的价格; (2) 代价 $H(x_{k+1})$, 它表示在周期结束时刻正的存货量 $x_{k+1} > 0$ (对超库存的保管费用), 或负的存货量 $x_{k+1} < 0$ (不满足需求的缺货代价) 所引起的惩罚。利用方程 $x_{k+1} = x_k + u_k - w_k$, 可以写出周期 k 的代价函数为

$$cu_k + H(x_k + u_k - w_k),$$

而且 N 个周期的总期望代价为

$$E\left\{\sum_{k=0}^{N-1} cu_k + H(x_k + u_k - w_k)\right\}.$$

我们的目标是选择合适的订货量 $u_0, \dots, u_{N-1}$, 在自然约束 $u_k \geq 0, k=0, \dots, N-1$ 条件下, 使上述代价函数为极小。一种可能性是在时刻 0 选择所有的订货量 $u_0, \dots, u_{N-1}$, 而不必等到知道后来的需求水平。然而比较好的选择是将订货 u_k 推迟到时刻 k , 此时可以知道当时的存货水平。这种运行模式涉及信息的收集, 以及基于有用信息而作出的序贯决策, 这在动态规划中是至关重要的。这就意味着, 我们对选择库存订货的最优数值并不真正感兴趣, 感兴趣的是寻求一个最优规则, 以便在每个周期 k , 对每个可能发生的存货量 x_k , 选择

订货量 u_k 。这就是一个“行动对策略”的特性。数学上，这个问题就是寻求一个函数序列 μ_k , $k=0, \dots, N-1$, 把存货量 x_k 映射到订货量 u_k , 使得总的期望代价为极小。 μ_k 的意义是, 对每个 k 和 x_k 的可能值,

$\mu_k(x_k)$ = 在时刻 k , 当存货量为 x_k 时, 应该订货的总量。

序列 $\pi = \{\mu_0, \mu_1, \dots, \mu_{N-1}\}$ 也称为一个控制律或一个策略。对每个这样的 π , 在固定的初始存货量 x_0 情况下相应的代价函数为

$$J_\pi(x_0) = E\left\{\sum_{k=0}^{N-1} c\mu_k(x_k) + H[x_k + \mu_k(x_k) - w_k]\right\},$$

我们的目标是对固定的 x_0 , 对所有容许的 π 使 $J_\pi(x_0)$ 为极小。在 § 2.2 节将会证明, 合理选择代价函数 H , 最优订货规则具有如下形式

$$\mu_k(x_k) = \begin{cases} S_k - x_k, & \text{若 } x_k < S_k, \\ 0, & \text{若 } x_k \geq S_k, \end{cases}$$

其中 S_k 是由问题的数据确定的适当的阈值。换句话说, 当存货量低于阈值 S_k 时, 订货只要使存货量达到 S_k 就行了。

上面的例题说明建立基本问题的主要组成部分:

1. 具有如下形式的离散时间系统

$$x_{k+1} = f_k(x_k, u_k, w_k),$$

其中 f_k 是某个函数; 此例中 $f_k(x_k, u_k, w_k) = x_k + u_k - w_k$ 。

2. 独立的随机参数 w_k 。容许 w_k 的概率分布依赖于 x_k 和 u_k 。这将具有普遍性; 在这个例子中, 我们可以认为需求量 w_k 受当前存货水平影响。

3. 控制约束。在此例中 $u_k \geq 0$ 。在一般情况下, 约束集合将依赖于 x_k 和时标 k , 即 $u_k \in U_k(x_k)$ 。为了理解约束如何依赖于 x_k , 可在库存的例题中想象一种情况, 即存在一个能调节存货量的上界 B , 使 $u_k \leq B - x_k$ 。

4. 具有如下形式的相加性代价函数

$$E\left\{g_N(x_N) + \sum_{k=0}^{N-1} g_k(x_k, u_k, w_k)\right\},$$

其中 g_k , $k=0, \dots, N$ 是某些函数; 在前面的例题中,

$$g_N(x_N) = 0, \text{ 而 } g_k(x_k, u_k, w_k) = cu_k + H(x_k + u_k - w_k)。$$

5. 对控制律的优化。即对每个 k 和 x_k 的可能值, 选择 u_k 的规则。

在前面的例题中, 状态 x_k 是实数。在另外的情况下, 状态是一个 n 维向量。然而, 也有可能状态取值于一个离散集合, 如整数集合, 或者甚至是一个有限集合。

当存货量以整单位来计量时(如汽车), 其中每一个量就是 x_k , u_k 或 w_k 的一个有效分数, 此时库存问题以离散形式描述更自然。于是, 把所有整数集而不是实数集取为状态空间更合适。当然, 系统方程和每个周期代价函数的形式保持不变。

在另一些系统中, 状态本质上是离散的, 不存在问题的连续对应部分。这样的系统往往根据状态间的转移概率可方便地加以确定。我们需要知道的是 $p_{ij}(u, k)$, 它定义为在 k 时刻, 给定当前的状态 x_k 为 i , 控制 u_k 选为 u 情况下, 下一个状态 x_{k+1} 为 j 的概率, 即

$$p_{ij}(u, k) = P\{x_{k+1} = j | x_k = i, u_k = u\}。$$

[如果系统是平稳的, 即以前的概率与 k 无关, 可去掉自变量 k , 用 $p_{ij}(u)$ 代替 $p_{ij}(u, k)$ 。] 这种系统可以换一种形式, 按如下离散时间系统方程来描述。

$$x_{k+1} = w_k,$$

式中随机参数 w_k 的概率分布为

$$P\{w_k = j | x_k = i, u_k = u\} = p_{ij}(u, k).$$

根据所碰到的情况, 可以按爱好用差分方程或用转移概率来描述系统。我们将用例题来阐明这些思想。

排队例题

考虑可容纳 n 个顾客的房间, 且在 N 个时间周期内运行的一个排队系统(见图 1.2)。假定对顾客的服务只能在一个周期的开始(或终止)时刻开始(或终止)。在一个时间周期内, m 个顾客到达的概率 p_m 给定, 而且在两个不同周期的到达数是相互独立的。顾客一经发现系统客满就离去, 而且以后不再进来。系统提供两种服务: 快服务和慢服务, 而且分别具有每周




图 1.2 能容纳 n 个顾客房间的排队系统。在任一时间周期, 服务可在快慢之间转换, 使得顾客等待和服务代价之和为极小: (a) 具有能容纳 n 个顾客房间及两种服务的排队系统; (b) 快和慢服务的转移概率图。假设的数据为 $n = 3, p_0 = 0.2, p_1 = 0.5, p_2 = 0.3$, 对 $m > 0, p_m = 0$, 且 $q_f = 0.8, q_s = 0.3$ 。

期价格 c_f 和 c_s 。服务可在每个周期的开始时刻在快和慢之间转换。如果在某一周期提供快(慢)服务, 在该周期开始时刻接受服务的顾客, 将以概率 q_f (相应地, q_s) 在这个周期末终止服务, 而与顾客已被服务的周期数以及系统中的顾客数无关($q_f > q_s$)。对每一个周期, 系

统中有 i 个顾客，就有代价 $c(i)$ 。同样在最后一个周期末，有 i 个顾客留在系统时，有终端代价 $c(i)$ 。问题是选择每个周期所提供的服务类型，它作为周期开始时系统中顾客数目的函数，使得 N 个周期的总期望代价为极小。

这里把周期开始时系统中的顾客数作为状态，而把所提供的服务种类作为决策变量（控制）是合适的。那么，每个周期的代价是 $c(i)$ 加上 c_f 或 c_s （取决于提供快服务或慢服务）。我们来推导系统的转移概率。当在一个周期开始时系统为空，下一个状态是 j 的概率与提供的服务种类无关。当 $j < n$ 时，它等于 j 个顾客到达的给定概率

$$p_{0j}(u_f) = p_{0j}(u_s) = p_j, \quad j = 0, 1, \dots, n-1,$$

当 $j = n$ 时，它等于 n 个或更多顾客到达的概率：

$$p_{0n}(u_f) = p_{0n}(u_s) = \sum_{m=n}^{\infty} p_m.$$

当系统中至少有一个顾客 ($i > 0$) 时，则有

$$p_{ij}(u_f) = 0, \quad \text{如果 } j < i-1,$$

$$p_{i(i-1)}(u_f) = q_f p_0,$$

$$p_{ij}(u_f) = P\{j-i+1 \text{ 到达, 服务完毕}\}$$

$$+ P\{j-i \text{ 到达, 服务未完毕}\}$$

$$= q_f p_{j-i+1} + (1-q_f) p_{j-i}, \quad \text{如果 } i-1 < j < n-1,$$

$$p_{i(n-1)}(u_f) = q_f \sum_{m=n-i}^{\infty} p_m + (1-q_f) p_{n-1-i},$$

$$p_{in}(u_f) = (1-q_f) \sum_{m=n-i}^{\infty} p_m.$$

当提供慢服务时，转移概率也用这些公式表示，只是分别用 u_s 和 q_s 代替 u_f 和 q_f 。

有时转移概率表示在一张图上，图中的连线代表各种状态间的转移，这就是所谓转移概率图，或简称转移图。图 1.2 表示了一个特殊情况，其中 $n=3$ ， $p_0=0.2$ ， $p_1=0.5$ ， $p_2=0.3$ ；对 $m>2$ ， $p_m=0$ ，且 $q_f=0.8$ ， $q_s=0.3$ 。

在下面建立方程的过程中，假定状态 x_k 取值于称为状态空间的某集合 S_k 。我们将不要求 S_k 是一个有限集，或一个 n 维向量空间。动态规划令人鼓舞的方面是它的可用性与状态空间的性质关系甚少（虽然其有效性肯定依赖于 S_k ）。为此，对 S_k 不作任何假定，这样处理起来方便些。以后，这些假设确会变成严重的障碍。我们同样允许 u_k 和 w_k 分别从某些非特定的空间 C_k 和 D_k 中取值。

基本问题

给定离散时间动态系统

$$x_{k+1} = f_k(x_k, u_k, w_k), \quad k=0, 1, \dots, N-1, \quad (1.1)$$

式中状态 x_k 是空间 S_k 的元，控制 u_k 是空间 C_k 的元，而随机“扰动” w_k 就是空间 D_k 的元。控制 u_k 被限定在给定的 C_k 的非空子集 $U_k(x_k)$ 中取值，该子集依赖于当前的状态 x_k [对所有 $x_k \in S_k$ 和 k ， $u_k \in U_k(x_k)$]。随机扰动 w_k 由概率测度 $P_k(\cdot | x_k, u_k)$ 来表征，它明显依赖于 x_k 和 u_k ，但与先前的扰动 $w_{k-1}, \dots, w_0$ 的值无关。我们考虑控制律类（也称为策略），

它由函数序列 $\pi = \{\mu_0, \mu_1, \dots, \mu_{N-1}\}$ 构成, 其中 u_k 把状态 x_k 映射到控制 $u_k = \mu_k(x_k)$, 并且对所有 $x_k \in S_k$, 使得 $\mu_k(x_k) \in U_k(x_k)$ 。这样的控制律称为容许控制律。

给定一个初态 x_0 , 问题是寻求一个容许控制律 $\pi = \{\mu_0, \mu_1, \dots, \mu_{N-1}\}$, 使代价泛函

$$J_\pi(x_0) = E_{w_k} \left\{ g_N(x_N) + \sum_{k=0}^{N-1} g_k[x_k, \mu_k(x_k), w_k] \right\} \quad (1.2)$$

$k=0, \dots, N-1$

为极小, 并受如下系统方程约束

$$x_{k+1} = f_k[x_k, \mu_k(x_k), w_k], \quad k=0, 1, \dots, N-1. \quad (1.3)$$

代价函数 $g_k, k=0, 1, \dots, N$ 是给定的。

对给定的初态 x_0 , 最优控制律 π^* 就是使相应代价为极小

$$J_{\pi^*}(x_0) = \min_{\pi \in \Pi} J_\pi(x_0),$$

式中 Π 是所有容许控制律的集合。相应于 x_0 的最优代价记为 $J^*(x_0)$, 即

$$J^*(x_0) = \min_{\pi \in \Pi} J_\pi(x_0).$$

我们把 J^* 看作为把每个初态 x_0 赋给为最优代价 $J^*(x_0)$ 的一个函数, 称之为最优代价函数, 或最优值函数。

[为了方便从事数学方面的读者, 我们指出, 上述方程中 $\min$ 表示数集 $\{J_\pi(x_0) | \pi \in \Pi\}$ 的最大下界(或下确界)。把上式写成 $J^*(x_0) = \inf_{\pi \in \Pi} J_\pi(x_0)$, 更符合通常数学上所使用的表示方法。然而, (如在附录 B 中讨论的那样), 即使下确界不能达到, 我们发现用 $\min$ 代替 $\inf$ 还是更方便些, 这样少一些麻烦, 也不会引起任何混淆。]

信息在基本问题中的作用

我们在前面已指出, 策略 $\{\mu_0, \mu_1, \dots, \mu_{N-1}\}$ 可以看成是一个计划, 在每个时刻, 对每个在该时刻可能出现的状态, 它规定了所应施加的控制。这种运行模式隐含着信息的收集, 认清这一点十分重要。由控制器接收到的信息, 是每个时刻当前的状态值, 而且在控制过程中直接利用这信息。因为 k 时刻的控制通过函数 μ_k 依赖于当前的状态 x_k (参见图 1.3)。这个信息的可用性确实具有重要意义。如果这一信息不利用, 控制器就不能适应不期望的状态值, 其结果使代价受到不利的影响。例如, 在前面考虑过的库存控制问题中, 在每个周期 k 开始时可用的信息是仓库的存货量 x_k 。显然, 对于库房经理来说, 这个信息十分重要, 他要根据当前存货量 x_k 的多少来调节订购量 u_k 。

然而应该注意, 状态信息的可用性不会带来坏处, 但也可能不会带来好处。譬如, 在确定性控制问题中, 不存在随机扰动, 给定初态和控制序列, 就可预报未来的状态。所以对所有控制序列 $\{u_0, u_1, \dots, u_{N-1}\}$ 的优化, 犹如对所有容许策略的优化一样, 获得相同的最优代价。甚至在某些随机控制问题中也有相同的结论(见习题13)。这就引出一个有关的专题, 假




图 1.3 基本问题中的信息收集。在每个时刻 k , 控制器观测到当前的状态 x_k , 并且施加依赖于该状态的控制 $u_k = \mu_k(x_k)$ 。

定没有忘记任何信息, 控制器实际上知道以前的状态和控制 $x_0, u_0, \dots, x_{k-1}, u_{k-1}$, 以及当前的状态 x_k 。于是提出一个问题: 利用整个系统历史的策略是否 优于只利用当前状态的策略? 答案是否定的(见[B23])。其直觉上的理由是: 对一给定的问题, 和给定的时刻 k 和状态 x_k , 所有未来的期望代价明显地只依赖于 x_k , 而与以前的历史无关。

建立基本问题的理论限制

对动态规划算法进行开发之前, 我们试图澄清不是建立在坚实数学基础上的某些方面的问题。这是数学上严密性的问题之一, 本质上是高技术。非数学专业的读者不必关心这些问题, 可以跳过本节其余部分而不会失去内容的连贯性。

首先, 一旦采用容许控制律 $\{\mu_0, \mu_1, \dots, \mu_{N-1}\}$, 对于每个阶段 $k=0, 1, \dots, N-1$, 就会有如下事件序列:

1. 控制器观测到 x_k , 并施加 $u_k = \mu_k(x_k)$ 。
2. 按照给定的概率测度 $P_k(\cdot | x_k, \mu_k(x_k))$, 产生扰动 w_k 。
3. 引起代价 $g_k[x_k, \mu_k(x_k), w_k]$, 并加到以前的代价中去。
4. 按照系统方程

$$x_{k+1} = f_k[x_k, \mu_k(x_k), w_k].$$

产生下一个状态 x_{k+1} 。如果这是最后一个阶段 ($k=N-1$), 将终点代价 $g_N(x_N)$ 加到前面的代价中去。否则, 增加 k , 下一阶段重复相同的事件序列。

这个过程是已经定义的, 并且以精确的概率项来表达。然而, 需要把代价函数

$$g_N(x_N) + \sum_{k=0}^{N-1} g_k[x_k, \mu_k(x_k), w_k]$$

看作为具有完全确定期望值的有定义的随机变量时, 事情就复杂了。概率论的框架要求对每个 $\{\mu_0, \mu_1, \dots, \mu_{N-1}\}$, 定义一个作为基础的概率空间, 即一个集合 Ω , Ω 中事件的集类, 以及这些事件上的概率测度。而且, 按附录C, 代价函数必须是这一空间上合适定义的随机变量(用测度概率论的术语说, 即由概率空间到实轴的一个可测函数)。为满足这一要求, 对函数 f_k, g_k 和 μ_k 就要有附加的(可测性)假定, 并且有必要对空间 S_k, C_k 和 D_k 引入附加的结构。而这些假说可能限制容许控制律类, 因为函数 μ_k 要受限制以满足附加的(可测性)要求。

因此, 除非规定了这些附加的假设和结构, 问题就不能合适地建立。另一方面, 对一般的状态、控制和扰动空间, 严格建立基本问题已经超出了导论性教科书的数学框架, 这里不予考虑(见[B23])。不过, 这些困难主要是技术上的, 不会严重影响所得的基本结果。因此, 如同所有导论性书本和大多数有关这一专题的杂志文献一样, 我们认为用非正式的推导和论证方法来处理这些问题是比较合适和方便的。

然而, 我们还要强调, 在扰动空间 $D_k, k=0, 1, \dots, N-1$ 为可数集的假设条件下, 所有上述数学上的困难都不存在了。因为在这种情况下, 只要附加假设: 代价函数(1.2)中所有项的期望值存在, 且对任一策略 π 是有限的, 就能对此问题提供一个合理的框架。

当 D_k 可数时, 一种简便的做法是把代价函数中的所有期望值, 按照 D_k 元素的概率重写成无限和的形式。另一个办法是把代价 $J_\pi(x_0)$ 写成

$$J_{\pi}(x_0) = E_{x_1, \dots, x_N} \left\{ g_N(x_N) + \sum_{k=0}^{N-1} \tilde{g}_k[x_k, \mu_k(x_k)] \right\}, \quad (1.4)$$

式中

$$\tilde{g}_k[x_k, \mu_k(x_k)] = E_{w_k} \{ g_k[x_k, \mu_k(x_k), w_k] | x_k, \mu_k(x_k) \},$$

它相对于定义在可数集 D_k 上的概率分布 $P_k(\cdot | x_k, \mu_k(x_k))$ 取期望值。那么, 可以把基本概率空间取作 $\tilde{S}_1, \tilde{S}_2, \dots, \tilde{S}_N$ 的笛卡尔积, 其中

$$\begin{aligned} \tilde{S}_1 &= \{x_1 \in S_1 | x_1 = f_0[x_0, \mu_0(x_0), w_0], w_0 \in D_0\}, \\ \tilde{S}_{k+1} &= \{x_{k+1} \in S_{k+1} | x_{k+1} = f_k[x_k, \mu_k(x_k), w_k], \\ &\quad x_k \in \tilde{S}_k, w_k \in D_k\}, k=1, 2, \dots, N-1. \end{aligned}$$

集合 $\tilde{S}_k$ 是加上控制律 $\{\mu_0, \mu_1, \dots, \mu_{N-1}\}$ 时, 在时刻 k 所有能达到的状态所构成的 S_k 的子集。 $D_0, D_1, \dots, D_{N-1}$ 均为可数集的事实, 保证了集合 $\tilde{S}_1, \dots, \tilde{S}_N$ 也均为可数的(因为可数集合的任意可数集类的并是可数集)。现在, 系统方程(1.3), 概率分布 $P_k(\cdot | x_k, \mu_k(x_k))$, 初态 x_0 , 和控制律 $\{\mu_0, \mu_1, \dots, \mu_{N-1}\}$, 定义了可数集 $\tilde{S}_1 \times \tilde{S}_2 \times \dots \times \tilde{S}_N$ 上的一个概率分布, 而式(1.4)是对于这一分布定义的数学期望。

总之, 只有当扰动空间 $D_0, \dots, D_{N-1}$ 是可数集时, 才能严格建立基本问题。没有 D_k 的可数性, 读者应理解以后所得结果和结论基本上是正确的, 但数学上陈述不严密。事实上, 当讨论无限时域问题时(需要更高的严密性), 我们将使可数性假设明朗化。我们注意到, 水平较高的读者, 严格地导出第二章和第三章中特殊应用问题的大多数结果, 不会有多大困难。如在本章注记和习题12中所阐述的那样, 是能够做到这一点的。

§ 1.2 动态规划算法

动态规划(DP)技术建立在非常简单的概念上, 即最优性原理。这个名称起源于贝尔曼, 他为 DP 的普及作出了一系列贡献, 并且使其转换成系统性的工具。概略地说, 最优性原理表述了如下不言而喻的事实。

令 $\pi^* = \{\mu_0^*, \mu_1^*, \dots, \mu_{N-1}^*\}$ 是基本问题的最优控制律, 考虑在时刻 i 处于状态 x_i , 并希望从时刻 i 到时刻 N 的“余留代价”(Cost-to-go)

$$E \left\{ g_N(x_N) + \sum_{k=i}^{N-1} g_k[x_k, \mu_k(x_k), w_k] \right\}.$$

为极小的子问题。且假定利用 π^* 时, 状态 x_i 以正概率出现。那么, 对此子问题, 截控制律 $\{\mu_i^*, \mu_{i+1}^*, \dots, \mu_{N-1}^*\}$ 是最优的。

最优性原理的直觉判断是非常简单的。如果截控制律按所说的那样不是最优, 那么一旦到达 x_i , 我们就可对此子问题切换到一个最优策略, 从而可进一步减小代价。用汽车旅行作比喻, 假定我们已经找到了从洛杉矶到波士顿的最快路径, 而且这一路径通过芝加哥。最优性原理道出了显而易见的真理: 这个路径中从芝加哥到波士顿的一段, 也一定是从芝加哥开始到波士顿结束旅行的最快路径。

最好用一个例题来介绍 DP 算法。

库存控制例题(续)

考虑上一节的库存控制例题。以下是从最后一个时间周期开始, 时间上反向倒推, 确定最优库存订货量策略的过程。

周期 $N-1$ 假定在周期 $N-1$ 开始时, 存货量为 x_{N-1} 。显然, 不管过去情况如何, 仓库经理应订购存货 $u_{N-1}^* = \mu_{N-1}^*(x_{N-1})$, 它对 u_{N-1} 使得最后一个时间周期的订购、存货和缺货代价之和为极小。而代价等于

$$E_{w_{N-1}} \{cu_{N-1} + H(x_{N-1} + u_{N-1} - w_{N-1})\}.$$

我们用 $J_{N-1}(x_{N-1})$ 表示最后一个周期的最优代价, 则

$$J_{N-1}(x_{N-1}) = \min_{u_{N-1} \geq 0} E \{cu_{N-1} + H(x_{N-1} + u_{N-1} - w_{N-1})\}.$$

从本质上说, J_{N-1} 是存货量 x_{N-1} 的函数。对于每个 x_N , J_N 可用解析方法或数值方法(在这种情况下, 可用一个表格在计算机中存储函数 J_N) 计算。在计算 J_{N-1} 的过程中, 我们得到最后一个周期的最优库存订货量策略 $\mu_{N-1}^*(x_{N-1})$ 。这里 $\mu_{N-1}^*(x_{N-1}) \geq 0$, 它对于每个 x_{N-1} 的值使上述方程的右边达到极小。

周期 $N-2$ 假定在周期 $N-2$ 的开始, 存货量为 x_{N-2} 。现在, 仓库经理显然应订购 $u_{N-2} = \mu_{N-2}^*(x_{N-2})$, 它并非只使周期 $N-2$ 的期望代价为极小, 而是使

(周期 $N-2$ 的期望代价) + (在周期 $N-1$ 采用最优策略时, 周期 $N-1$ 的期望代价) 为极小。这就等于

$$E_{w_{N-2}} \{cu_{N-2} + H(x_{N-2} + u_{N-2} - w_{N-2})\} + E_{w_{N-2}} \{J_{N-1}(x_{N-1})\}.$$

利用系统方程 $x_{N-1} = x_{N-2} + u_{N-2} - w_{N-2}$, 上式后一项可以写成

$$E_{w_{N-2}} \{J_{N-1}(x_{N-2} + u_{N-2} - w_{N-2})\}.$$

这样, 给定状态 x_{N-2} , 最后两个周期的最优代价 $J_{N-2}(x_{N-2})$ 由下式给出

$$J_{N-2}(x_{N-2}) = \min_{u_{N-2} \geq 0} E \{cu_{N-2} + H(x_{N-2} + u_{N-2} - w_{N-2}) + J_{N-1}(x_{N-2} + u_{N-2} - w_{N-2})\}.$$

对每个 x_{N-2} 再来计算 $J_{N-2}(x_{N-2})$ 。同样也计算最优订货策略 $\mu_{N-2}^*(x_{N-2})$ 。

周期 k 类似地, 在周期 k 对初始库存 x_k , 仓库经理应订购 u_k , 使得

(周期 k 的期望代价) + (在周期 $k+1, \dots, N-1$ 采用最优策略时, 这些周期的期望代价) 为极小。用 $J_k(x_k)$ 表示最优代价, 则有

$$J_k(x_k) = \min_{u_k \geq 0} E \{cu_k + H(x_k + u_k - w_k) + J_{k+1}(x_k + u_k - w_k)\}, \quad (1.5)$$

实际上这就是该问题的动态规划方程。

函数 $J_k(x_k)$ 表示由周期 k 开始, 初始库存为 x_k 时, 对于余留周期的最优期望代价。这些函数是从周期 $N-1$ 开始, 到周期 0 结束, 按时间反向递推计算得到的。 $J_0(x_0)$ 的值是 0 时刻, 初始库存为 x_0 时, 过程的最优期望代价。在计算时, 最优库存策略 $\{\mu_0^*(x_0), \mu_1^*(x_1),$

$\dots, \mu_{N-1}^*(x_{N-1})\}$ 是对每个 x_k 和 k , 同时地由式(1.5)右边求极小而计算得到的。

这个例题说明了 DP 所具有的主要优点。原始库存问题要求对策略集合, 即当前存贮量(更一般是当前状态)的函数序列集合进行优化。式(1.5)的 DP 算法把这一问题分解成一系列对订货量集合(更一般的是控制空间)求极小的问题。这些问题的每一个都远比原始问题简单。

现在我们来阐述基本问题的 DP 算法, 并证明它的最优性。

命题 令 $J^*(x_0)$ 是最优代价, 则

$$J^*(x_0) = J_0(x_0),$$

式中函数 J_0 由如下算法的最后一步给定, 该算法按时间由周期 $N-1$ 到周期 0 反向进行:

$$J_N(x_N) = g_N(x_N) \quad (1.6)$$

$$J_k(x_k) = \min_{u_k \in U_k(x_k, w_k)} E\{g_k(x_k, u_k, w_k) + J_{k+1}[f_k(x_k, u_k, w_k)]\}, \quad (1.7) \text{ (原注)}$$

$$k=0, 1, \dots, N-1.$$

而且, 对每个 x_k 和 k , 若 $u_k^* = \mu_k^*(x_k)$ 使式(1.7)右边极小, 则控制律 $\pi^* = \{\mu_0^*, \dots, \mu_{N-1}^*\}$ 是最优的。

证明: 由于表征 w_k 的概率测度仅依赖于 x_k 和 u_k , 而与 w_k 以前的扰动值 $w_0, \dots, w_{k-1}$ 无关, 于是我们可把 $J^*(x_0)$ 写成如下形式

$$J^*(x_0) = \min_{\mu_0, \mu_{N-1}} [E\{g_0[x_0, \mu_0(x_0), w_0] + E\{g_1[x_1, \mu_1(x_1), w_1] + \dots + E\{g_{N-1}[x_{N-1}, \mu_{N-1}(x_{N-1}), w_{N-1}] + g_N(x_N)\} \dots\}],$$

式中对 w_k 取期望, $k=0, 1, \dots, N-1$ 是以 x_k 和 $\mu_k(x_k)$ 为条件的。这个表达式也可写成

$$J^*(x_0) = \min_{\mu_0} [E\{g_0[x_0, \mu_0(x_0), w_0] + \min_{\mu_1} [E\{g_1[x_1, \mu_1(x_1), w_1] + \dots + \min_{\mu_{N-1}} [E\{g_{N-1}[x_{N-1}, \mu_{N-1}(x_{N-1}), w_{N-1}] + g_N(x_N)\} \dots\}]]].$$

在此方程中, 对所有函数 μ_k 极小化, 使得对所有 x_k 和 k , $\mu_k(x_k) \in U_k(x_k)$ 。另外, 这个极小化受系统方程约束

$$x_{k+1} = f_k[x_k, \mu_k(x_k), w_k].$$

现在, 我们利用如下结果: 对 x, u 的任意函数 F , 有

$$\min_{\mu \in M} F[x, \mu(x)] = \min_{u \in U(x)} F(x, u),$$

式中 M 是对所有 x , 使得 $\mu(x) \in U(x)$ 的所有函数 $\mu(x)$ 的集合。

把此结果用于 $J^*(x_0)$ 的方程式, 把 $x_{k+1} = f_k(x_k, u_k, w_k)$ 代入并引入式(1.7)的函数 J_k , 则得所需结果:

$$J^*(x_0) = J_0(x_0).$$

如果对每个 x_k 和 k , $\mu_k^*(x_k)$ 使式(1.7)右边达到极小, 则 $\{\mu_0^*, \dots, \mu_{N-1}^*\}$ 为最优控制律是显而

原注: 当然, 仅当基本问题是严格建立, DP 算法及其证明才是严格的。如在上节所说明的, 当扰动空间 D_k , $k=0, 1, \dots, N-1$ 是可数集合, 而且对每个容许策略 π , 代价泛函表达式(1.2)所有项的期望值都适当定义且有界时, 就是这种情况。另外, 已假定式(1.7)中的期望值, 对所有 $u_k \in U_k(x_k)$ 和所有 $x_k \in S_k$ 存在且有限。我们进一步注意到, 虽然没有明显指出, 式(1.7)中的数学期望是相对于表征 w_k (它与 x_k 和 u_k 相关) 的概率测度来取值。

易见的。因为这一控制律获得最优代价。

证毕

以上证明的论证过程也可以用来解释 $J_k(x_k)$ 。对由 k 时刻和状态 x_k 开始, 到 N 时刻结束的 $(N-k)$ 阶段问题, 它就是最优代价。以后我们称 $J_k(x_k)$ 为状态 x_k 和时刻 k 的余留代价, 而把 J_k 作为 k 时刻的余留代价函数。在理想上, 我们希望利用 DP 算法来决定 J_k 的闭型表达式, 要不然也希望获取 J_k 或 μ_k^* 的有用特征。在许多情况下, 人们不得不采取 DP 方程的数值解。因为式(1.7)中的极小化必须对每个 x_k 的值进行计算, 而数值求解是十分费时的。典型地, 把状态空间离散化, 极小化是对有限个状态 x_k 进行的, 所需要的计算量与离散点的数目成正比。因此, 对复杂的多维问题, 计算负担已到不可忍受的程度。然而, DP 在不确定情况下是唯一的序列优化的一般方法。

现在我们用例题来说明 DP 算法分析和计算方面的问题。

例题 1

某种材料通过串接的两个炉子(见图 1.4), 记

x_0 : 材料的初始温度,

$x_k, k=1, 2$: 材料在炉子 k 的出口温度,

$u_{k-1}, k=1, 2$: 炉子 k 的内部温度。

假定模型具有如下形式

$$x_{k+1} = (1-a)x_k + au_k, \quad k=0, 1,$$

式中 a 是 $(0, 1)$ 区间中的某个标量。目的是得到接近给定目标温度 T 的最终温度 x_2 , 同时消耗较少的能量。这可用如下形式的代价函数来表示

$$r(x_2 - T)^2 + u_0^2 + u_1^2,$$

式中 $r > 0$ 是一个给定的标量。假定 u_k 无约束。(实际上存在约束, 但如果我们能够求解无约束问题, 而且验证这个解满足约束, 则一切都顺利了。)

我们可以看出, 这是一个符合基本框架的确定性问题。 $N=2$, 终端消耗 $g_2(x_2) = r(x_2 - T)^2$, 于是 DP 算法的初始条件是[见式(1.6)]:




图 1.4 例题 1 的问题。材料温度按 $x_{k+1} = (1-a)x_k + au_k$ 演变, 其中 a 是某个标量, 且 $0 < a < 1$ 。

$$J_2(x_2) = r(x_2 - T)^2.$$

对倒数第二阶段有[见式(1.7)]

$$\begin{aligned} J_1(x_1) &= \min_{u_1} [u_1^2 + J_2(x_2)] \\ &= \min_{u_1} [u_1^2 + J_2[(1-a)x_1 + au_1]]. \end{aligned}$$

把上述形式的 J_2 代入得

$$J_1(x_1) = \min_{u_1} [u_1^2 + r[(1-a)x_1 + au_1 - T]^2]. \quad (1.8)$$

对 u_1 求导并使之等于零, 就实现极小化。由此得

$$0 = 2u_1 + 2ra[(1-a)x_1 + au_1 - T],$$

把各项归并得后一个炉子的最优温度

$$u_1 = \mu_1^*(x_1) = \frac{ra[T - (1-a)x_1]}{1 + ra^2}$$

注意, 这不是一个单个控制, 而是一个控制函数, 是一个规则, 它告诉我们对每个可能状态 x_1 的最优炉温 u_1 。

把最优的 u_1 代入 J_1 的表达式(1.8)得:

$$\begin{aligned} J_1(x_1) &= \frac{r^2 a^2 [(1-a)x_1 - T]^2}{(1 + ra^2)^2} + r \left[(1-a)x_1 + \frac{ra^2 [T - (1-a)x_1]}{1 + ra^2} - T \right]^2 \\ &= \frac{r^2 a^2 [(1-a)x_1 - T]^2}{(1 + ra^2)^2} + r \left(\frac{ra^2}{1 + ra^2} - 1 \right)^2 [(1-a)x_1 - T]^2, \end{aligned}$$

最后,

$$J_1(x_1) = \frac{r[(1-a)x_1 - T]^2}{1 + ra^2}.$$

现在我们返回一步到 0 阶段, 有[参见式(1.7)]

$$\begin{aligned} J_0(x_0) &= \min_{u_0} [u_0^2 + J_1(x_1)] \\ &= \min_{u_0} [u_0^2 + J_1[(1-a)x_0 + au_0]], \end{aligned}$$

把已得到的 J_1 的表达式代入, 得

$$J_0(x_0) = \min_{u_0} \left[u_0^2 + \frac{r[(1-a)^2 x_0 + (1-a)au_0 - T]^2}{1 + ra^2} \right].$$

对 u_0 求极小, 令相应的导数为零得

$$0 = 2u_0 + \frac{2r(1-a)a[(1-a)^2 x_0 + (1-a)au_0 - T]}{1 + ra^2}.$$

经过某些计算, 得第一个炉子的最优温度

$$u_0 = \mu_0^*(x_0) = \frac{r(1-a)a[T - (1-a)^2 x_0]}{1 + ra^2[1 + (1-a)^2]}.$$

把此表达式代入 J_0 的公式即得最优消耗。这导致一个直接但冗长的计算, 最后得较简单的公式

$$J_0(x_0) = \frac{r[(1-a)^2 x_0 - T]^2}{1 + ra^2[1 + (1-a)^2]}.$$

这就完成了问题的求解。

以后我们会看到, 本例题中有些有价值的特点可普遍推广。第一个特点是简易性, 从而得到了一个解析解。按算法步骤稍加思考, 读者就会相信其所以使问题求解简单的原因, 是因为代价函数的二次特性和系统方程的线性。事实上, 我们在 §2.1 将会看到, 一般情况下当系统为线性, 代价函数为二次型时, 不管阶段数 N 多大, 最优策略都具有一个解析表达式。

该例题中另一个有价值的特点是, 当一个零均值的随机扰动加到这个系统方程时, 最优策略不受影响。为了解这一点, 假定材料温度演变按

$$x_{k+1} = (1-a)x_k + au_k + w_k, \quad k=0, 1,$$

式中 w_0, w_1 是相互独立的随机变量, 具有给定的分布, 零均值

$$E\{w_0\} = E\{w_1\} = 0,$$

和有限方差。那么, J_1 的方程[参见式(1.7)]变为

$$\begin{aligned} J_1(x_1) &= \min_{u_1} E_{w_1} \{u_1^2 + r[(1-a)x_1 + au_1 + w_1 - T]^2\} \\ &= \min_{u_1} [u_1^2 + r[(1-a)x_1 + au_1 - T]^2 \\ &\quad + 2rE\{w_1\}[(1-a)x_1 + au_1 - T] + rE\{w_1^2\}]. \end{aligned}$$

所以, 利用 $E\{w_1\} = 0$ 的事实得

$$J_1(x_1) = \min_{u_1} [u_1^2 + r[(1-a)x_1 + au_1 - T]^2] + rE\{w_1^2\}.$$

把此方程与式(1.8)比较, 我们看到, w_1 的存在造成一个无关紧要的附加项 $rE\{w_1^2\}$ 。因此, 最后一个阶段的最优策略不受 w_1 存在的影响, 只是 $J_1(x_1)$ 增加了一个常数项 $rE\{w_1^2\}$ 。容易看出, 类似的情况对第一阶段也成立。尤其是, 最优代价除了附加项 $r(E\{w_1^2\} + E\{w_2^2\})$ 之外, 与前面的表达式相同。

最优策略不受零均值扰动存在影响的特性, 就是确定性等价原理的表现形式, 它对线性系统和二次代价函数的几类问题均成立(见 § 2.1, § 3.2, § 3.3 和 § 6.1 节)。

例题 2

考虑与 § 2.1 节类似的一个库存控制问题, 区别在于存货量和需求都是非负整数变量。而且, 假定可存放的存货量 $(x_k + u_k)$ 有一上界; 还假定超出需求的部分 $(w_k - x_k - u_k)$ 即为损失。由此, 存货量方程取如下形式

$$x_{k+1} = \max(0, x_k + u_k - w_k).$$

假定最大库存容量 $(x_k + u_k)$ 是 2 单位, 计划期 N 是 3 个周期, 订货费用 c 是 1 单位。每阶段保存或短缺货物的代价给定为

$$H(x_k + u_k - w_k) = \max(0, x_k + u_k - w_k) + 3 \max(0, w_k - x_k - u_k).$$

终态代价为零。初始存货量 x_0 是给定的, 对所有周期, 需求量 w_k 具有相同的概率分布, 给定为

$$p(w_k = 0) = 0.1, \quad p(w_k = 1) = 0.7, \quad p(w_k = 2) = 0.2.$$

对于不同的控制值, 系统可以根据三个可能状态 0, 1, 2 之间的转移概率来表示(见图 1.5a)。

DP 算法的起始方程为

$$J_3(x_3) = 0,$$


因为终态代价是零[参见式(1.6)]。算法采取如下形式[参见式(1.7)]

$$\begin{aligned} J_k(x_k) &= \min_{\substack{0 \leq u_k \leq 2 - x_k \\ u_k = 0, 1, 2}} E \{u_k + \max(0, x_k + u_k - w_k) + 3 \max(0, w_k - x_k - u_k) \\ &\quad + J_{k+1}[\max(0, x_k + u_k - w_k)]\}, \quad k=0, 1, 2, \end{aligned}$$

式中 x_k, u_k, w_k 可取值 0, 1, 2。

阶段 2 对三个可能状态的每一个计算 $J_2(x_2)$:

$$J_2(0) = \min_{u_2 = 0, 1, 2} E \{u_2 + \max(0, u_2 - w_2) + 3 \max(0, w_2 - u_2)\}$$



	阶段 0		阶段 1		阶段 2	
存货量	余留代价	最优购货量	余留代价	最优购货量	余留代价	最优购货量
0	4.9	1	3.3	1	1.7	1
1	3.9	0	2.3	0	0.7	0
2	3.35	0	1.82	0	0.9	0

(b)

图 1.5 例题 2 的系统和 DP 结果: (a) 对不同购货量(控制)的转移概率图。连线旁边的数字是转移概率, 由于 $x_h + u_h \leq 2$ 的限制, 在状态 2 时, 控制 $u = 1$ 不存在。类似地, 只有在状态 0 时, 限制 $u = 2$ 才是可能的。(b) 例题 2 DP 算法的结果。

$$\begin{aligned}
 = & \min_{u_2=0,1,2} \{u_2 + 0.1[\max(0, u_2) + 3\max(0, -u_2)] \\
 & + 0.7[\max(0, u_2 - 1) + 3\max(0, 1 - u_2)] + 0.2[\max(0, u_2 - 2) \\
 & + 3\max(0, 2 - u_2)]\}.
 \end{aligned}$$

对于 u_2 的三种可能值的每一个, 计算右边的期望值:

$$u_2 = 0: E\{\cdot\} = 0.7 \times 3 \times 1 + 0.2 \times 3 \times 2 = 3.3,$$

$$u_2 = 1: E\{\cdot\} = 1 + 0.1 \times 1 + 0.2 \times 3 \times 1 = 1.7,$$

$$u_2 = 2: E\{\cdot\} = 2 + 0.1 \times 2 + 0.7 \times 1 = 2.9.$$

因此, 选择能使期望值最小的 u_2 , 有

$$\triangleright J_2(0) = 1.7, \quad \mu_2^*(0) = 1. \quad \triangleleft$$

对 $x_2 = 1$ 有

$$J_2(1) = \min_{u_2=0,1} E\{u_2 + \max(0, 1 + u_2 - w_2) + 3\max(0, w_2 - 1 - u_2)\}$$

$$\begin{aligned}
&= \min_{u_2=0,1} \{u_2 + 0.1[\max(0, 1+u_2) + 3\max(0, -1-u_2)] \\
&\quad + 0.7[\max(0, u_2) + 3\max(0, -u_2)] \\
&\quad + 0.2[\max(0, u_2-1) + 3\max(0, 1-u_2)]\}, \\
u_2=0: E\{\cdot\} &= 0.1 \times 1 + 0.2 \times 3 \times 1 = 0.7, \\
u_2=1: E\{\cdot\} &= 1 + 0.1 \times 2 + 0.7 \times 1 = 1.9.
\end{aligned}$$

因此

$$\triangleright \quad J_2(1) = 0.7, \quad \mu_2^*(1) = 0. \quad \triangleleft$$

对 $x_2 = 2$, 唯一容许的控制是 $u_2 = 0$, 于是有

$$\begin{aligned}
J_2(2) &= E_{w_2} \{ \max(0, 2-w_2) + 3\max(0, w_2-2) \} \\
&= 0.1 \times 2 + 0.7 \times 1 = 0.9,
\end{aligned}$$

$$\triangleright \quad J_2(2) = 0.9, \quad \mu_2^*(2) = 0. \quad \triangleleft$$

阶段 1 利用前一阶段得到的 $J_2(0)$, $J_2(1)$, $J_2(2)$ 的值, 对三个可能状态 $x_1 = 0, 1, 2$ 的每一个再计算 $J_1(x_1)$:

$$\begin{aligned}
J_1(0) &= \min_{u_1=0,1,2} E \{ u_1 + \max(0, u_1-w_1) + 3\max(0, w_1-u_1) \\
&\quad + J_2[\max(0, u_1-w_1)] \}, \\
u_1=0: E\{\cdot\} &= 0.1 \times J_2(0) + 0.7[3 \times 1 + J_2(0)] \\
&\quad + 0.2[3 \times 2 + J_2(0)] = 5.0, \\
u_1=1: E\{\cdot\} &= 1 + 0.1[1 + J_2(1)] + 0.7 \times J_2(0) \\
&\quad + 0.2[3 \times 1 + J_2(0)] = 3.3, \\
u_1=2: E\{\cdot\} &= 2 + 0.1[2 + J_2(2)] + 0.7[1 + J_2(1)] \\
&\quad + 0.2 \times J_2(0) = 3.82,
\end{aligned}$$

$$\triangleright \quad J_1(0) = 3.3, \quad \mu_1^*(0) = 1. \quad \triangleleft$$

$$\begin{aligned}
J_1(1) &= \min_{u_1=0,1} E \{ u_1 + \max(0, 1+u_1-w_1) + 3\max(0, w_1-1-u_1) \\
&\quad + J_2[\max(0, 1+u_1-w_1)] \} \\
u_1=0: E\{\cdot\} &= 0.1[1 + J_2(1)] + 0.7 \times J_2(0) \\
&\quad + 0.2[3 \times 1 + J_2(0)] = 2.3, \\
u_1=1: E\{\cdot\} &= 1 + 0.1[2 + J_2(2)] + 0.7[1 + J_2(1)] \\
&\quad + 0.2 \times J_2(0) = 2.82,
\end{aligned}$$

$$\triangleright \quad J_1(1) = 2.3, \quad \mu_1^*(1) = 0. \quad \triangleleft$$

$$\begin{aligned}
J_1(2) &= E \{ \max(0, 2-w_1) + 3\max(0, w_1-2) + J_2[\max(0, 2-w_1)] \} \\
&= 0.1[2 + J_2(2)] + 0.7[1 + J_2(1)] + 0.2 \times J_2(0) = 1.82,
\end{aligned}$$

$$\triangleright \quad J_1(2) = 1.82, \quad \mu_1^*(2) = 0. \quad \triangleleft$$

阶段 0 因为初始状态已知是零, 我们只需计算 $J_0(0)$ 。有

$$\begin{aligned}
J_0(0) &= \min_{u_0=0,1,2} E \{ u_0 + \max(0, u_0-w_0) + 3\max(0, w_0-u_0) \\
&\quad + J_1[\max(0, u_0-w_0)] \}, \\
u_0=0: E\{\cdot\} &= 0.1 \times J_1(0) + 0.7[3 \times 1 + J_1(0)]
\end{aligned}$$

$$\begin{aligned}
& + 0.2[3 \times 2 + J_1(0)] = 6.6, \\
u_0 = 1: & E\{\cdot\} = 1 + 0.1[1 + J_1(1)] + 0.7 \times J_1(0) \\
& + 0.2[3 \times 1 + J_1(0)] = 4.9, \\
u_0 = 2: & E\{\cdot\} = 2 + 0.1[2 + J_1(2)] + 0.7[1 + J_1(1)] \\
& + 0.2 \times J_1(0) = 5.352,
\end{aligned}$$

$$\triangleright \quad J_0(0) = 4.9, \quad \mu_0^*(0) = 1. \quad \triangleleft$$

如果预先并不知道初始状态, 我们必须以类似方式去计算 $J_0(1)$ 和 $J_0(2)$, 以及使它们最小的 u_0 。这些计算得到

$$\triangleright \quad J_0(1) = 3.9, \quad \mu_0^*(1) = 0, \quad \triangleleft$$

$$\triangleright \quad J_0(2) = 3.352, \quad \mu_0^*(2) = 0. \quad \triangleleft$$

因此, 每个周期的最优订货策略是: 如果当前存货为零, 订购 1 单位; 其它情况则不订货。DP 算法的结果以表格形式在图 1.5(b) 中给出。

例题 3

有限状态系统。我们早已提到(参看上一节排队的例题), 具有有限状态的系统, 可以用离散时间系统方程表示, 也可以用状态间的转移概率来描述(参看图 1.2 和图 1.5)。我们来推导相应的 DP 算法。为下面讨论方便, 假定问题是平稳的(即转移概率、每阶段代价以及控制约束集合, 不随阶段的变化而变化)。那么, 如果

$$p_{ij}(u) = P\{x_{k+1} = j | x_k = i, u_k = u\}$$

是转移概率, 我们可以换一种方法来表示系统, 即用系统方程

$$x_{k+1} = w_k,$$

来描述(参见上一节的讨论), 其中扰动 w_k 的概率分布是

$$p\{w_k = j | x_k = i, u_k = u\} = p_{ij}(u).$$

利用这个系统方程, 并用 $g(i, u)$ 表示在状态 i 加入控制 u 时的每个阶段期望代价, 则 DP 算法可重写成

$$J_k(i) = \min_{u \in U(i)} [g(i, u) + E\{J_{k+1}(w_k)\}]$$

或者等效地(按照前面给定的 w_k 的分布)

$$J_k(i) = \min_{u \in U(i)} [g(i, u) + \sum_j p_{ij}(u) J_{k+1}(j)], \quad k = 0, 1, \dots, N-1.$$

作为一个说明, 在上一节的排队问题中, 这一算法取如下形式

$$J_N(i) = C(i), \quad i = 0, 1, \dots, n,$$

$$\begin{aligned}
J_k(i) = \min & [c(i) + c_f + \sum_{j=1}^n p_{ij}(u_f) J_{k+1}(j), \quad c(i) + c_s + \sum_{j=0}^n p_{ij}(u_s) J_{k+1}(j)], \\
& k = 0, 1, \dots, N-1.
\end{aligned}$$

在极小化过程中这两个表达式相应于两个可利用的决策(快服务和慢服务)。

§ 1.3 确定性系统和最短路径问题

本教材的主要目的是分析随机优化问题, 以及出现不确定性时的后果。然而, 在许多重要的场合还会碰到确定性问题, 本节和下一节都用来阐明确定性问题的某些特征。

首先我们注意到, 只要简单地把扰动空间 D_k 考虑成只有单一元, 则确定性问题必定可纳入基本问题的框架。然而, 与随机问题相反, 在确定性问题中利用反馈, 对减小代价不会带来任何好处。换句话说, 对容许控制律类 $\{\mu_0, \dots, \mu_{N-1}\}$ 使代价泛函为极小; 与对控制向量序列类 $\{u_0, \dots, u_{N-1}\}$, 且对所有 $k, u_k \in U_k(x_k)$, 使代价泛函为极小, 导致相同的最优代价。原因十分简单, 因为对于一个确定性问题, 一个最优控制律 $\{\mu_0^*, \dots, \mu_{N-1}^*\}$ 所达到的代价同样也可由控制序列

$$u_k^* = \mu_k^*(x_k^*), \quad k = 0, \dots, N-1,$$

来达到, 式中 $x_0^*, \dots, x_{N-1}^*$ 定义为

$$x_{k+1}^* = f_k(x_k^*, u_k^*), \quad x_0^* = x_0, \quad k = 0, 1, \dots, N-1.$$

为此, 我们可以对控制序列求代价泛函为极小, 这一任务可以用各种各样确定性控制算法来完成, 如最陡下降法、共轭梯度法和牛顿法。当这些算法可利用时, 它们通常比 DP 更有效。另一方面, DP 具有更广泛的应用范围, 因为它能够处理诸如整数集或离散集这样困难的约束集合。而且, DP 可得出一个全局最优解。这与前面提到的各种方法相反, 一般情况下上述方法不能保证全局最优。

现在考虑一个确定性问题。其中状态空间 S_k 对每个 k 是有限集。那么, 在任意状态 x_k , 控制 u_k 可与由状态 x_k 到状态 $f_k(x_k, u_k)$ 的转移发生联系。于是, 一个有限状态的确定性问题, 可以用诸如图 1.6 的图形等价地表示。其中, 弧线相应于相继阶段状态间的转移, 每一条弧线都有一个与之相联系的代价。我们还加了一个人为的终端结点 t 。每条连接阶段 N 状态 x_N 和终端结点的弧线代价为 $g_N(x_N)$ 。控制序列相应于各条由初始状态 (在阶段 0 的结点 s) 开始, 到相应于最后阶段 N 的结点之一终止的一条路径。如果我们把代价看作为弧的长度, 可以看出, 一个确定性问题, 等价于寻求由图形的初始结点 s 到终端结点 t 的一条最短路径。[一条路径就是形如 $(j_1, j_2), (j_2, j_3), \dots, (j_{k-1}, j_k)$ 的弧的序列, 其长度就是弧长之和。]




图 1.6 一个确定性有限状态系统的转移图。结点相应于状态。弧分别由结点 x_k 开始, 结点 x_{k+1} 结束, 相应于形式为 $x_{k+1} = f_k(x_k, u_k)$ 的一次转移。弧长等于相应转移的代价 $g_k(x_k, u_k)$ 。问题等价于寻求由初始结点 s 到终端结点 t 的一条最短路径。

如果我们记

$$c_{ji}^k = \text{由状态 } i \in S_k \text{ 到状态 } j \in S_{k+1} \text{ 的转移代价,}$$

$$k = 0, 1, \dots, N-1,$$

c_{it}^N = 状态 $i \in S_N$ 的终端代价,

DP 算法则取如下形式

$$J_N(i) = c_{it}^N, \quad i \in S_N, \quad (1.9)$$

$$J_k(i) = \min_{j \in S_{k+1}} \{c_{ij}^k + J_{k+1}(j)\}, \quad i \in S_k, \quad k = 0, 1, \dots, N-1. \quad (1.10)$$

最优代价是 $J_0(s)$, 等于由 s 到 t 最短路径的长度。

上述算法按时间反向处理。按照如下简单分析, 可以推导出一个等价的按时间正向算法。从 s 到 t 的最优路径, 也就是一个“逆”最短路径问题中由 t 到 s 的最优路径。而在“逆”最短路径问题中, 每条弧的方向改变, 长度保持不变。相应于这一“逆”问题的 DP 算法是

$$\tilde{J}_N(j) = c_{jt}^0, \quad j \in S_1, \quad (1.11)$$

$$\tilde{J}_k(j) = \min_{i \in S_{N-k}} \{c_{ji}^{N-k} + \tilde{J}_{k+1}(i)\}, \quad j \in S_{N-k+1}, \quad k = 1, 2, \dots, N-1, \quad (1.12)$$

而最优代价是

$$\tilde{J}_0(t) = \min_{i \in S_N} \{c_{it}^N + \tilde{J}_1(i)\}. \quad (1.13)$$

反向 DP 算法式(1.9), (1.10)和正向 DP 算法式(1.11)到(1.13), 在 $J_0(s) = \tilde{J}_0(t)$ 意义下是等价的, 而且由这两种算法中的任一种得到的最优控制序列(或最短路径), 对于原问题都是最优的。我们能够把式(1.12)中的 $\tilde{J}_k(j)$ 看作为由初始状态 s 到状态 j 的最优完成代价(cost-to-arrive)。这与式(1.10)中的 $J_k(i)$ 形成对照, 后者表示由状态 i 到终态 t 的最优余留代价。

总之, 一个确定性有限状态问题, 等价于一个特殊类型的最短路径问题, 而且能够用正常的(反向)DP 算法, 或者一个正向 DP 算法来求解。还令人感兴趣的是, 如我们现在知道的, 任何一个最短路径问题, 都能够成为一个确定性有限状态 DP 问题。

令 $\{1, 2, \dots, N, t\}$ 是一个图形中的结点集合, 又令 c_{ij} 是由结点 i 移到结点 j 的代价(或者连接 i 和 j 弧的长度)。结点 t 是一个特殊的结点, 称为目的地结点。对于结点 i 和 j 之间没有弧的情况, 允许出现 $c_{ij} = \infty$ 。我们希望找到由每个结点 i 到结点 t 的一条最短路径, 即一个移动序列, 使由每个结点 $1, 2, \dots, N$ 到 t 的总代价为极小。为使这一问题有解, 必须排除在同一结点开始和终止的移动序列(循环)具有负的总长度的可能性。否则, 只要简单地增加越来越多的负长度循环, 就有可能使某些路径的长度减小到任意小的值。

因为负长度循环已被假设排除在外, 显然一条最优路径不需要大于 N 次移动。所以我们可以把移动次数限制到 N 。我们把这一问题建立在如下情况: 准确要求 N 次移动, 但允许有由结点 i 到其本身, 而代价 $c_{ii} = 0$ 的蜕化移动。对于 $i = 1, \dots, N, k = 0, 1, \dots, N-1$, 我们记

$J_{N-1}(i)$ = 在一次移动中由 i 到 t 所得最优代价。

$J_k(i)$ = 在 $(N-k)$ 次移动中由 i 到 t 所得最优代价。

那么, 由 i 到 t 最优路径的代价是 $J_0(i)$ 。这就有可能把这一问题纳入基本问题的框架之内, 并应用 DP 算法。然而, 为简单起见, 我们直接写出 DP 方程, 采取直观上清晰的形式

由 i 到 t , $(N-k)$ 次移动中的最优代价

$$= \min_{j=1, \dots, N} \{c_{ij} + \text{由 } j \text{ 到 } t, (N-k-1) \text{ 次移动中的最优代价}\}$$

或

$$J_k(i) = \min_{j=1, \dots, N} \{c_{ij} + J_{k+1}(j)\}, \quad k=0, 1, \dots, N-2,$$

且

$$J_{N-1}(i) = c_{it}, \quad i=1, 2, \dots, N.$$




图 1.7 (a) 最短路径问题的数据。目的地结点是 5，两个方向的弧长相等，它表示在连接结点的线段旁边。(b) 由 DP 算法产生的余留代价。沿阶段 k 和状态 i 的数字是 $J_k(i)$ 。箭头表示在每个阶段和结点的最优移动。

k 次移动之后，处在结点 i 的最优策略是移向结点 j^* ，其中 j^* 对所有 $j=1, \dots, N$ ，使括号内的表达式极小化。应该注意，此处不排除由 i 到 i 的蜕化移动。如果由此算法得到的最优路径包括这样的蜕化移动，此即简单地意味着其持续时间少于 N 次移动。

为了演示这一算法，考虑图 1.7(a) 所示的问题，其中代价 c_{ij} , $i \neq j$ (我们假定 $c_{ij} = c_{ji}$) 表示在弧线旁。图 1.7(b) 表示了每个结点 i 的余留代价 $J_k(i)$ 和标号 k ，以及最优路径。最优路径是

$$1 \rightarrow 5, 2 \rightarrow 3 \rightarrow 4 \rightarrow 5, 3 \rightarrow 4 \rightarrow 5, 4 \rightarrow 5.$$

§ 1.4 最短路径在统筹分析、编码理论和正向搜索中的应用

最短路径问题出现在许多不同的场合，现在举几个例子。

统筹分析

考虑包括几种活动的一个项目计划，其中某些活动必须在其它活动可开始之前完成。每个活动的持续时间预先已知，我们要寻求完成该项目所需的时间，以及关键活动。这些关键活动即使稍微延误，则会导致整个项目完成的相应延误。

这个问题可以用具有结点 $1, 2, \dots, N$ 的有向图来表示，如图 1.8 所示(也称为活动网

络)。此处结点表示项目某个阶段的完成。弧 (i, j) 表示一旦阶段 i 完成即开始的一个活动，且有已知的持续时间为 t_{ij} 。只有当所有的活动或所有进入到 j 的弧 (i, j) 均已完成时，一个阶段(结点) j 就完成。特殊结点1和 N 分别表示项目的开始和结束。当然，结点1(或 N)没有进入(或没有出去)的弧。

一个活动网络的重要特征是非循环性，即它没有有向循环[形如 $(i, j_1), (j_1, j_2), \dots, (j_k, i)$ 的有向弧序列]。这是问题建立中所固有的，结点可解释为阶段完成。

现在考虑完成项目所有阶段，进而完成项目本身所需的时间 T 。对任意由结点1到结点 j_k 的有向路径 $p = \{(1, j_1), (j_1, j_2), \dots, (j_{k-1}, j_k)\}$ ，令 D_p 是这个路径的持续时间，定义为其所有活动持续时间之和，即

$$D_p = t_{1j_1} + t_{j_1j_2} + \dots + t_{j_{k-1}j_k}.$$

如果每个活动在其前一个活动结束后立即开始，则 D_p 就是这个活动序列 $(1, j_1), \dots, (j_{k-1}, j_k)$ 的总持续时间。显然， D_p 不可能超过项目总的持续时间，即

$$D_p \leq T, \quad \text{所有路径 } p.$$

我们断言

$$T = \max_p D_p,$$

于是，寻求 T 的问题，就是当每条弧 (i, j) 的长度为 t_{ij} 时，寻求由结点1到结点 N 的最长路径的问题。因为这种图是非循环的，该问题也可以看作为每条弧 (i, j) 的长度为 $-t_{ij}$ 的最短路径问题。

证明这一结论的最容易的方法是推导相应的DP算法。令 $N_k, k=1, 2, \dots$ 是阶段集合

$$N_k = \{i \mid \text{由1到} i \text{的路径中所含的弧最大数目恰好为 } k\},$$

且 $N_0 = \{1\}$ 。对每个阶段 i ，令

T_i : 完成 i 所需时间，

则有

$$T_i = \max_{(j, i)} \{t_{ji} + T_j \mid j \in N_0 \cup \dots \cup N_{k-1}\}, \quad i \in N_k,$$

稍加思考即明白， T_i 等于由1到 i 所有路径 p 的最大 D_p 。对 $i=N$ ，得 $T = \max_p D_p$ 。

对于图1.8的活动网络，有

$$N_0 = \{1\}, N_1 = \{2, 4\}, N_2 = \{3, 5\}, N_3 = \{6\}, N_4 = \{7\}.$$

利用前面的公式计算得

$$T_1 = 0, T_2 = 3, T_4 = 1, T_3 = 4, T_5 = 4, T_6 = 9, T_7 = 11,$$

而且关键(即最长)路径是 $1 \rightarrow 2 \rightarrow 3 \rightarrow 6 \rightarrow 7$ 。在完成关键活动 $(1, 2), (2, 3), (3, 6), (6, 7)$ 中的任意延误，将成比例地延误整个项目的完成。




图 1.8 活动网络图。结点表示项目某个阶段的完成。弧线表示活动，并用持续时间标记。若在相应的结点，与进入弧相关的活动全部完成，则一个阶段就完成。当所有阶段完成时，该项目即完成。项目的持续时间是 由 结点 1 到 结点 7 的最长路径的长度。

卷积编码与 Viterbi 解码器

当二进制数据在有噪声信道中传输时，作为加强通信可靠性的一种手段，通常要采用编

码。一种非常通用的编码方法称为卷积编码，它把源生二进制数据序列

$$\{w_1, w_2, \dots\}, \quad w_k \in \{0, 1\}, \quad k=1, 2, \dots,$$

转换成码序列

$$\{y_1, y_2, \dots\},$$

式中每个 y_k , $k=1, 2, \dots$ 是一个具有二进制坐标的 n 维向量(称为码字)

$$y_k = \begin{bmatrix} y_k^1 \\ \vdots \\ y_k^n \end{bmatrix}, \quad y_k^i \in \{0, 1\}, \quad i=1, \dots, n.$$

向量 y_k 通过如下形式的方程与 w_k 发生联系

$$y_k = Cx_{k-1} + dw_k, \quad k=1, 2, \dots, \quad (1.14)$$

$$x_k = Ax_{k-1} + bw_k, \quad k=1, 2, \dots, \quad (1.15)$$

x_0 : 给定,

式中 x_k 是一个具有二进制坐标的 m 维向量(称为状态), 而 C, d, A, b 分别是 $n \times m, n \times 1, m \times m, m \times 1$ 矩阵, 其元为二进制数。包含在表达式 $Cx_{k-1} + dw_k$ 和 $Ax_{k-1} + bw_k$ 中的乘积与求和用模 2 算术进行运算。

作为一个例子, 令 $m=2, n=3$, 且

$$C = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 1 \end{bmatrix}, \quad A = \begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix},$$

$$d = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \quad b = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

则系统(1.14)到(1.15)的演变, 可以用图 1.9 所示转移图(称为格架)来表示。由此图和初始状态 x_0 , 可以生成相应于数据序列 $\{w_1, w_2, \dots\}$ 的码字序列 $\{y_1, y_2, \dots\}$ 。例如, 当初始状态 $x_0 = 00$, 数据序列为

$$\{w_1, w_2, w_3, w_4\} = \{1, 0, 0, 1\}$$

时, 生成的状态序列是

$$\{x_0, x_1, x_2, x_3, x_4\} = \{00, 01, 11, 10, 00\},$$

而字码序列是

$$\{y_1, y_2, y_3, y_4\} = \{111, 011, 111, 011\}.$$

现在假定有噪声, 传输信道的特征为: 一个码字 y 以已知概率 $p(z|y)$ 被接收成 z , 其中 z 是任意 n 个字节的二进制数。我们把

$$Z_N = \{z_1, z_2, \dots, z_N\}$$

记为发送序列

$$Y_N = \{y_1, y_2, \dots, y_N\}$$

时所收到的序列。我们假定误码是相互独立的, 使得

$$p(Z_N|Y_N) = \prod_{k=1}^N p(z_k|y_k). \quad (1.16)$$




图 1.9 由 x_{k-1} 到 x_k 的状态转移图。每条弧上的二进制数字对, 就是相应转移的数据/码字对 w_k/y_k 。例如, 当 $x_{k-1} = 01$, 零数位 ($w_k = 0$) 作用到 $x_k = 11$ 的一个转移, 且生成码字 011。

一个最大似然解码器将接收到的序列 Z_N 转换成一个序列

$$\hat{Y}_N = \{\hat{y}_1, \hat{y}_2, \dots, \hat{y}_N\}$$

使得

$$p(Z_N | \hat{Y}_N) = \max_{Y_N} p(Z_N | Y_N).$$

对 Y_N 的约束是：它必须是一个可行码字序列（即它必须相应于某个初始状态和数据序列）。给定 $\hat{Y}_N$ ，就可以构造出一个相应的数据序列 $\{\hat{w}_1, \dots, \hat{w}_N\}$ ，它作为一个解码数据被接受。

Viterti 开发了一种最短路径方法，实现了最大似然解码器。利用式(1.16)，我们知道使 $p(Z_N | Y_N)$ 为极大的问题，等价于如下问题：对一个已知的接收序列 $\{z_1, z_2, \dots, z_N\}$ ，

$$\min \sum_{k=1}^N -\ln[p(z_k | y_k)],$$

$$\text{对所有二进制序列 } \{y_1, y_2, \dots, y_N\}. \quad (1.17)$$

为弄明白这是一个最短路径问题，注意到给定 z_k ，我们就能在状态转移图中对每条弧赋以长度 $-\ln[p(z_k | y_k)]$ ，其中 y_k 就是与弧相应的码字。其次，我们通过连接 N 个状态转移图来构造一个图形，并且在图的左边和右边分别加上虚拟点 s 和 t ，且以零长度弧分别连接到 x_0 和 x_{N-1} （见图 1.10）。问题式(1.17)的解，可从构造一条由 s 到 t 的最短路径，且寻求与之相关的序列 $\{\hat{y}_1, \dots, \hat{y}_N\}$ 而得到。由最短路径和格架图，我们则能得到解码后的数据序列 $\{\hat{w}_1, \hat{w}_2, \dots, \hat{w}_N\}$ 。

实际上，一旦接收到相应的码字，就立即在线计算由 s 到每个结点的最短距离，是构造最短路径较方便的方法。在接收到全部码字序列 Z_N 之前存在许多对部分数据序列解码的实施方法。（当 Z_N 是一个长序列时，这一方法很有用。）譬如，对某个 k 人们能够容易地检查，




图 1.10 把最大似然解码看作为寻求由 s 到 t 一条最短路径的问题。由 s 到状态 x_0 和由状态 x_{N-1} 到 t 的弧长为零。由状态 x_{k-1} 到状态 x_k 的一条弧的长为 $-\ln p(z_k | y_k)$ ，其中 z_k 是接收到的码字，而 y_k 是与该弧有关的码字。

是否所有由 s 到 x_k 的最短路径，都穿过由状态 $x_0, \dots, x_{k-1}$ 组成的子图中的一个单结点。若是，则能看出由 s 到那个结点的最短路径，将不受接收其它码字的影响（最优性原理）。因此，相应的数据子列就能有可靠地解码，并传送到它的目的地。

正向搜索

在某些最短路径问题中，结点数目非常之多，以至于在计算机存储器中贮存这些结点非常困难。事实上，由于某些最短路径问题的性质，只要穷举所研究图中的所有结点，求解就变得非常简单。而实际课题是如何避免完全穷举所有结点来求解问题。在这种情况下，常常可由原结点向目的结点正向搜索最短路径，以节省内存和计算时间。这种技术部分地起源于人工智能，并典型地应用于求解智力测验和下棋游戏等的计算机程序中(见 § 4.3)。现在给出一些例子。

例题1

四皇后问题。四皇后必须放在 4×4 格的一个棋盘上，使其不能相互攻击。换句话说，位置的安排使得 4×4 棋盘上每行、每列和每个对角线都至多有一个皇后。等价地，我们能够把此问题看作为一个问题的序列。首先，把一个皇后放在顶上一行头两个方格中的某一个；然后把另一个皇后放在第二行，使其不受第一个的攻击；然后类似地放第三个和第四个皇后。(只考虑顶上一行头两个方格就足够了，因为其它两个方格导致对称的棋局。)我们可以把棋





图 1.11 四皇后问题的最短路径的建立。在顶上一行右边两个方格之一放置一个皇后造成的对称棋局被略去。放皇后的方格涂黑。除了连接死局和人为终端结点的弧之外，其它所有弧的长度为零。

局与一个非循环图的结点联系起来，其中根结点 s 相应于无皇后的棋局，而终端结点相应于死局。在这种情况下不可能再放入另外的皇后而不受其他皇后攻击。让我们用一条弧把每一死局与人为结点 t 联接起来，这些弧都赋予长度 $+\infty$ (见图 1.11)，以表示它们相应于死局而不能得出解。那么，四皇后问题就简化为寻求由结点 s 到结点 t 最短路径的问题。注意，一旦穷举图中的结点，问题就根本解决了。这里的结点数少。然而，我们能够想象具有很大存贮需求的类似问题。比如，有一个八皇后问题，棋盘为 8×8 ，而不是 4×4 。

例题 2

推销员旅行问题。运行序列调度的一个重要模型，就是古典的推销员旅行问题。这里我们给定 N 个城市 和每两个城市之间的里程。我们希望寻求访问各城市正好 为一次的最小旅行里程。为使这个问题转化为一个最短路径问题，我们把一个结点与每个由 n 个不同城市构成的序列联系起来， $n = 1, 2, \dots, N$ 。相应图形的结构和弧的长度，在图 1.12 中用 例子加以说明。源结点 s 由城市 A 组成，它作为起点。每增加一个新的城市， n 个城市 ($n < N$) 的序列就产生了 $(n+1)$ 个城市的序列。每个这样的序列用一条弧联接起来，其长度等于 $n+1$ 个城市中最后两个之间的里程。每个由 N 个城市构成的序列都联接到一个人为终端结点 t 上，其长



	A	B	C	D
A		5	1	15
B	5		20	4
C	1	20		3
D	15	4	3	

城市间的公里数表

图 1.12 推销员旅行问题建立最短路径的例题。四个城市 A, B, C, D 之间的距离示于表中。弧线长度示于线旁。

度等于由该序列最末一个城市到起点城市 A 的距离。注意, 结点数目随城市数目以指数形式增加, 因而我们希望有一种算法, 它不需要穷举和/或存贮这些结点。

在最短路径问题中, 我们将考虑有一个单独结点 s , 它没有进入弧, 称之为原点; 而另一个单独结点 t , 它没有输出弧, 称之为目的结点。我们假定每条弧 (i, j) 有一个长度 a_{ij} , 其值为非负或为 $+\infty$ 。我们希望找到一条由原结点到目的结点的最短路径。注意, 上面给出的两个例题均满足这些条件 (见图 1.11 和图 1.12)。下面的算法是求解这一问题的一般方法。在此算法中, 我们使用了两种称为 “OPEN” 和 “CLOSED” 的结点表。OPEN 表包含正在活动的结点, 即它们要由算法进一步检查的候选结点。CLOSED 表包含那些以前活动, 而现在已由算法检查过, 并且不再进一步考虑作为当前候选的结点。开始时, OPEN 表只包含源结点 s , CLOSED 表是空的。算法保持有一个由原点到目的地最短距离的上界值, 称之为 UPPER, 而且初值等于 $+\infty$ 。算法对每一个结点 i 也保持有一个由原点到该结点最短距离的上界 d_i 。初始情况下 $d_s = 0$, 而所有其它的结点 i 有 $d_i = +\infty$ 。如果有一条弧 (i, j) 联接 i 和 j , 则称结点 j 为结点 i 的子结点。算法的步骤如下:

步骤 1 由 OPEN 表的最前面移去一个结点 i , 把它放到 CLOSED 表中。对于 i 的每一个子结点 j , 如果 $j \neq t$, 转到步骤 1a; 如果 $j = t$, 转到步骤 1b。

步骤 1a ($j \neq t$), 如果 $d_i + a_{ij} < \min\{d_j, \text{UPPER}\}$, 置 $d_j = d_i + a_{ij}$, 给 j 以标号 i , 把 j 放到 OPEN 表的最前面; 如果 j 属于 CLOSED 表, 把 j 从 CLOSED 表中去掉。(注意, 为了在算法终止后追踪到原点的最短路径, 这种标记是必需的。)

步骤 1b ($j = t$) 如果 $d_i + a_{it} < \text{UPPER}$, 置 $\text{UPPER} = d_i + a_{it}$, 把结点 i 标记成处在迄今找到的由 s 到 t 的最好路径上。


步骤 2 如果 OPEN 表为空表, 算法结束; 否则转到步骤 1。

可以看出, 通过这个算法, d_j 或者为 $+\infty$ (如果结点 j 还未进入 OPEN 表); 或者是由 s 到 j 的路径长度, 而 j 是由进入 OPEN 表至少一次的结点构成。而且, UPPER 或者是 $+\infty$; 或者是由 s 到 t 的路径长度。所以这是由 s 到 t 最短距离的一个过估计。这个算法的思想是: 当发现一条由 s 到 j 的路径短于以前所考虑的路径时 (步骤 1a 中 $d_i + a_{ij} < d_j$), d_j 相应地减小, 结点 j 进入 OPEN 表, 从而可以把通过 j 到达 j 的子结点的路径考虑进去。然而, 只有当所考虑的路径有机会引出一条由 s 到 t 的路径, 且其长度小于由 s 到 t 最短距离的过估计 UPPER 时, 这样做才有意义。根据弧长的非负性, 路径长度 $d_i + a_{ij}$ 不小于 UPPER, 是不可能的。这就提供了只有当 $d_i + a_{ij}$ 小于 UPPER 时, 在步骤 1a 中 j 进入 OPEN 表的合理性。

循此算法可以看出, 它首先检查结点 s (开始时在 OPEN 表中的唯一结点), 把 s (永久地) 放入 CLOSED 表中; 而且假定 t 不是 s 的一个子结点。在设置 $d_s = 0$ 之后, 将 s 的所有子结点 j 放入 OPEN 表中。如果 t 是 s 的一个子结点, 则在步骤 1b 中置 UPPER 为 a_{st} , 而且只有当 $a_{sj} < a_{st}$ 时, 在 t 之后检验过的 s 的子结点才能放到 OPEN 表中。实际上应该如此, 因为若 $a_{sj} \geq a_{st}$, 结点 j 不可能处在比由弧 (s, t) 构成的直接路径更短的从 s 到 t 的路径上。随后, 算法由 OPEN 表的最前面取出 s 的最后一个结点 $j \neq t$, 并把它放到 CLOSED 表中, 而把满足步骤 1a 判据的子结点 $j \neq t$ 放入 OPEN 表中, 如此等等。当算法终止时, 利用在步骤 1b 中最后标记的、处在最好路径上的结点, 肯定可以得到最短路径。从那个结点开始, 循着标记, 反向推进可构造出到原点的最短路径。图 1.13 说明用此算法去求解图 1.12

的推销员旅行问题。

为验证刚才描述的算法所得路径是最短的，我们做如下推理。首先，我们利用反证法认为算法将终止。事实上，如果算法不能终止，某个结点 j 将无限地不断进入 OPEN 表，此即意味着 d_j 将无限地减小，每次都得到由 s 到 j 一条相应的更短路径。这是不可能的。因为根据弧长的非负假设，由 s 到 j 不同长度的路径的数目是有限的。因此，算法将终止。其次，我们证明到终止时 UPPER 的值，必定等于由 s 到 t 的最短距离 d^* 。事实上，令 $(s, j_1, j_2, \dots, j_k, t)$ 是由 s 到 t 的一条最短路径，则每个路径 $(s, j_1, \dots, j_m)$, $m = 1, \dots, k$ 分别是由 s 到 j_m 的一个最短路径。如果终止时，UPPER 的值大于 d^* ，则在整个算法中也必定如此，所以在整个算法中 UPPER 也大于所有路径 $(s, j_1, \dots, j_m)$, $m = 1, \dots, k$ 的长度。从而结点 j_k 将永远不会以由 s 到 j_k 的最短距离 d_{j_k} 进入 OPEN 表。因为在这种情况下，UPPER 将



迭代次数	OPEN 表	进入 CLOSED 表的结点	UPPER
0	1	-	$+\infty$
1	2, 7, 10	1	$+\infty$
2	3, 5, 7, 10	2	$+\infty$
3	4, 5, 7, 10	3	$+\infty$
4	5, 7, 10	4	43
5	6, 7, 10	5	43
6	7, 10	6	13
7	8, 10	7	13
8	9, 10	8	13
9	10	9	13
10	Empty	10	13

(b)

图 1.13 用于图 1.12 推销员旅行问题的算法。按次序检验了结点 1 到 10 之后，找到最优解 $ABCD$ 。表中给出了 OPEN 表逐次的内容。

按算法在步骤 1 第二次检查结点 j_k 之后, 立即在步骤 1b 设置成 d^* 。类似地, 这将意味着结点 j_{k-1} 将永远不会以由 s 到 j_{k-1} 的最短距离 $d_{j_{k-1}}$ 进入 OPEN 表。反向进行处理, 我们会断言 j_1 将永远不会以由 s 到 j_1 的最短距离 d_{j_1} [它等于弧 (s, j_1) 的长度] 进入 OPEN 表。然而, 如前面讨论, 这发生在算法的第一次迭代中, 于是就造成矛盾。从而知道, UPPER 等于终止时由 s 到 t 的最短距离。还可以看到, 由 t 向 s 反向循标记构成的路径, 其长度等于 UPPER, 所以它就是由 s 到 t 的最短路径。

这个算法有两个吸引人的方面。第一是有可能节省计算时间。因为在步骤 1a 中对于 $d_i + a_{ij} \geq \text{UPPER}$ 的结点 j , 不需要进入 OPEN 表, 且以后不必检验。而且, 如果我们知道最短距离的一个下界, 一旦 UPPER 精确达到这个下界, 或者在一个可接受的容许误差 $\epsilon > 0$ 之内, 就可结束计算。(例如, 在四皇后问题中这个特点是有用的, 其中最短距离已知为零或无限大。那么, 一旦找到一个解, 算法就终止。)

该算法第二个吸引人的方面是可能节省内存需求。这在诸如图 1.11 和图 1.12 中最为明显, 图中由原结点到其它结点有唯一的一条有向路径。因此, 根据我们在 OPEN 表中放入和移出结点的规则, 如图 1.14 所示, 若按深度优先的方式进行搜索, 结果 CLOSED 表中的大部分可以从存储器中删除, 如图 1.15 所示。其出发点是: 一旦一个结点的所有子结点进入 CLOSED 表, 则通过该结点的所有路径已生成并被估算过。因而只存贮迄今已找到的最好路径就够了, 有关该结点的其它所有信息均可删掉。




图 1.14 按深度优化方式搜索一个树, 打勾表示其中结点进入 CLOSED 表的次序。




图 1.15 对图 1.14 按深度优先搜索的存贮需求图。在打勾的结点进入 CLOSED 表的时刻, 只有树的实线部分需要存贮。根据规则, 所有后续结点在 CLOSED 表中的结点不必存贮。点线部分已经生成并从存储器中删去, 而树的虚线部分并未生成。

刚才给出的算法有许多不同的类别。前面对算法有效性的证明, 并不依赖于步骤 1 中从 OPEN 表最前面移去一个结点, 也不依赖于步骤 1a 中在 OPEN 表的最前面放入一个结点。这就给算法如何运算以很大的自由度。一个重要的情况是: 当在步骤 1 中选择的结点 i 不是恰好处在 OPEN 表最前面的结点, 而是 OPEN 表中 d_i 为极小的结点。这就是大家知道的最

佳优先搜索,而且对所考虑的问题等价于 Dijkstra 算法(见[P2]及习题 27)。另一种可能性是:如果 j 当前属于 CLOSED 表,则在步骤 1a 把结点 j 放在 OPEN 表的最前面;如果 j 不属于 OPEN 表或 CLOSED 表,则放在 OPEN 表的最后面;如果 j 属于 OPEN 表,则把 j 留在 OPEN 表当前的位置上。这个算法由 Pape 提出[P4],对非常重要的一类问题变得非常有效[D6]。

前已提及,算法的关键思想是放弃检验那些不可能处在最短路径上的结点而节省计算时间。这是基于步骤 1a 中结点 j 被放入 OPEN 表之前,必须通过 $d_i + a_{ij} \leq \text{UPPER}$ 的检验。如果我们能找到由结点 j 到目的地最短距离的一个正的欠估计 h_j ,我们就可以强化这种检验。这种估计能从掌握的有关问题的专门知识中得到。在步骤 1a 中,当 $d_i + a_{ij} + h_j < \text{UPPER}$ (而不是 $d_i + a_{ij} < \text{UPPER}$)时,把结点 j 放入 OPEN 表,从而可以大大加速计算。按此方式,在算法结束前,只有很少几个结点会放在 OPEN 表中。利用 h_j 是从 j 到目的结点最短距离的一个欠估计的事实,前面给出的论证将证明该算法以获得正确的最短路径而结束。

刚才描述的思想是强化 $d_i + a_{ij} < \text{UPPER}$ 检验,以容许结点 j 进入 OPEN 表的一种方式。另一种思想是:在步骤 1a 中,对结点 j 得到由 j 到目的结点最短距离的一个过估计 h_j ,以图减小 UPPER 值。因此,在步骤 1a 之后,如果 $d_i + h_j < \text{UPPER}$,我们就可以把 UPPER 减小为 $d_i + h_j$,从而使将来进入 OPEN 表的容许性检验变得更严格。这一思想用在某些类型的分枝定界算法中。现在我们简要地描述其中一种类型的算法(进一步的讨论见[P2]和[P9])。

例题 3

分枝定界法。考虑在一个有限可行解集 X 上使一个代价函数 $f(x)$ 为极小的问题。分枝定界法使用一个具有结点的非循环图。结点按一对一关系与 X 的子集类 $\mathcal{N}$ 相对应。我们要求如下:

1. $X \in \mathcal{N}$ (即由所有解构成的集合是一个结点)。
2. 如果 x 是一个解,则 $\{x\} \in \mathcal{N}$ (即看作单点集的所有解都是结点)。
3. 如果 $Y \in \mathcal{N}$ 包含一个以上解 $x \in X$,则存在 $Y_1, \dots, Y_n \in \mathcal{N}$,使得对所有 i , $Y_i \subsetneq Y$, 且

$$\bigcup_{i=1}^n Y_i = Y.$$

Y 称为 $Y_1, \dots, Y_n$ 的父结点;而 $Y_1, \dots, Y_n$ 称为 Y 的子结点。

4. 除 X 之外,每个结点至少有一个父结点。

显然, $\mathcal{N}$ 定义了一个根结点为 X 、终端结点为 $\{x\}$, $x \in X$ 的非循环图(见图 1.16)。如果 Y_i 是 Y 的一个子结点,假定存在联接 Y 和 Y_i 的一条弧。假定对每个非终端结点 Y ,存在一种算法来计算 Y 上最小代价的上界 $\bar{f}_Y$ 和下界 f_Y :

$$f_Y \leq \min_{x \in Y} f(x) \leq \bar{f}_Y.$$

进一步假定对一个单点解结点,上界和下界严格相等,

$$f_{\{x\}} = f(x) = \bar{f}_{\{x\}}, \quad \text{对所有 } x \in X.$$

现在把联接一个父结点 Y 和一个子结点 Y_i 的弧长定义为下界之差




图 1.16 相应于分枝定界法的算法树。每个结点（子集）
除了由单个解组成之外，都分成几个其它的结点（子集）。

$$f_{Y_i} = f_{Y_i}$$

显然，对每个结点 Y ，上界 f_Y 就是由原结点 X 到 Y 的任意路径的长度。因为我们假定对所有可行解 $x \in X$ ，有 $f_{(x)} = f(x)$ 。显而易见，寻找由原结点到某个单点结点的最短路径，等价于对 $x \in X$ ，使 $f(x)$ 极小。

现在考虑前面讨论的最短路径算法的一种变形，其中还利用我们关于上界 f_Y 的知识来减小 UPPER 的值。一开始，OPEN 表只含 X ，CLOSED 表是空的，而 UPPER 等于 f_X 。

步骤 1 从 OPEN 表中移出一个结点 Y ，并放入 CLOSED 表。对 Y 的每个子结点 Y_i ，转到步骤 2。

步骤 2 如果 $f_{Y_i} < \text{UPPER}$ ，则把 Y_i 放入 OPEN 表。另外，如果 $f_{Y_i} < \text{UPPER}$ ，则置 $\text{UPPER} = f_{Y_i}$ ；如果 Y_i 由单点解组成，把此解标记为迄今找到的最好解。

步骤 3 如果 OPEN 表非空，转到步骤 1。否则结束，而迄今所找到的最好解就是最优解。

上述算法另一种在步骤 3 结束的方法是：设定一个容差 $\epsilon > 0$ ，检查 UPPER 和 OPEN 表中所有集合 Y 的最小下界 f_Y 之差是否小于 ϵ 。若是，算法结束，而且 OPEN 表中的某个集合必包含一个误差在 ϵ 范围内为最优的解。这一算法还有其它许多类型。例如，如果一个结点的上界 f_Y 实际上是某个元 $x \in Y$ 的代价 $f(x)$ ，则每当步骤 2 中 $f_Y < \text{UPPER}$ ，此元就能取作迄今找到的最好解。其它类型与步骤 1 中从 OPEN 表中选择一个结点的方法有关。例如，最佳优先型的两种策略，就是依据最小下界或上界来选择结点。最后我们注意到，有效地应用分枝定界法要求我们创造性地利用掌握的特定问题的知识。尤其重要的是使算法在每个结点产生实际上尽可能陡的上界和下界，因为这样才使较少的结点容许进入 OPEN 表，随之节省计算。

§ 1.5 时间滞后、相关扰动及预报

本节讨论在建立基本问题时某些假设不能满足的情况。我们将考虑系统方程中存在时间

滞后, 扰动 w_k 是相关的, 以及在时刻 k 能够预报未来的不确定性 $w_k, w_{k+1}, \dots$, 从而更新相应的概率分布等情况。问题还包括这样的情况: 系统演变由于一个随机事件, 或者由于决策者的行动先于最终时间而结束。一般来说, 在所有这些情况中, 利用状态增广的办法, 可将问题变换成基本问题的框架。然而, (不可避免地) 付出的代价就是增加了所变换问题的复杂性。

时间滞后

为简单起见, 假定在状态和控制中至多有一个周期的时间滞后, 即假定系统方程形如

$$\begin{aligned} x_{k+1} &= f_k(x_k, x_{k-1}, u_k, u_{k-1}, w_k), \quad k=1, 2, \dots, N-1, \\ x_1 &= f_0(x_0, u_0, w_0). \end{aligned} \quad (1.18)$$

多于一个周期的时间滞后问题, 可以通过对此情况的直接推广来处理。

现在, 我们如果引入附加的状态变量 y_k 和 s_k , 并使之恒等: $y_k = x_{k-1}$, $s_k = u_{k-1}$, 对于 $k=1, 2, \dots, N-1$, 系统方程(1.18)变为

$$\begin{pmatrix} x_{k+1} \\ y_{k+1} \\ s_{k+1} \end{pmatrix} = \begin{pmatrix} f_k(x_k, y_k, u_k, s_k, w_k) \\ x_k \\ u_k \end{pmatrix}. \quad (1.19)$$

定义 $\tilde{x}_k = (x_k, y_k, s_k)$ 为新的状态, 则有

$$\tilde{x}_{k+1} = \tilde{f}_k(\tilde{x}_k, u_k, w_k), \quad (1.20)$$

式中系统函数 $\tilde{f}_k$ 由式(1.19)按显式定义。用式(1.20)作为系统方程, 把代价泛函作适当变换, 这个问题就简化为没有时间滞后的基本问题。自然, 要找寻的控制律 $\{\mu_0, \dots, \mu_{N-1}\}$ 将由新的状态 $\tilde{x}_k$ 的函数 μ_k 构成; 或等价地说, μ_k 将是当前状态 x_k , 以及过去状态 x_{k-1} 和控制 u_{k-1} 的函数。DP 算法(按照原问题的变量)为

$$\begin{aligned} J_N(x_N) &= g_N(x_N), \\ J_{N-1}(x_{N-1}, x_{N-2}, u_{N-2}) &= \min_{u_{N-1} \in U_{N-1}(x_{N-1})} E \{ g_{N-1}(x_{N-1}, u_{N-1}, w_{N-1}) \\ &\quad + J_N[f_{N-1}(x_{N-1}, x_{N-2}, u_{N-1}, u_{N-2}, w_{N-1})] \}, \\ J_k(x_k, x_{k-1}, u_{k-1}) &= \min_{u_k \in U_k(x_k)} E \{ g_k(x_k, u_k, w_k) \\ &\quad + J_{k+1}[f_k(x_k, x_{k-1}, u_k, u_{k-1}, w_k), x_k, u_k] \}, \\ &\quad k=1, \dots, N-2, \\ J_0(x_0) &= \min_{u_0 \in U_0(x_0)} E \{ g_0(x_0, u_0, w_0) \\ &\quad + J_1[f_0(x_0, u_0, w_0), x_0, u_0] \}. \end{aligned}$$

我们注意到, 在代价泛函中出现时间滞后时, 例如, 被极小化的表达式具有如下形式

$$E \left\{ g_N(x_N, x_{N-1}) + \sum_{k=0}^{N-1} g_k(x_k, x_{k-1}, u_k, w_k) \right\}.$$

在这种情况下, 类似的变换是可能的, 在极端情况下, 时间滞后使代价泛函具有非相加形式:

$$E \{ g_N(x_N, x_{N-1}, \dots, x_0, u_{N-1}, \dots, u_0, w_{N-1}, \dots, w_0) \}.$$

那么, 为把这个问题简化为基本问题的形式, k 时刻的增广状态 $\tilde{x}_k$ 必须包括

$$(x_k, x_{k-1}, \dots, x_0, u_{k-1}, \dots, u_0, w_{k-1}, \dots, w_0)$$

且变换后的代价泛函取如下形式

$$E\{g_N(\tilde{x}_N)\}, \text{ 其中 } \tilde{x}_N = (x_0, \dots, x_N, u_0, \dots, u_{N-1}, w_0, \dots, w_{N-1}).$$

寻求的控制律由函数 μ_k 构成, 而 μ_k 是现在与过去的状态 $x_k, \dots, x_0$, 过去的控制 $u_{k-1}, \dots, u_0$, 以及过去的扰动 $w_{k-1}, \dots, w_0$ 的函数。当然, 我们必须假定, 对控制器而言, 过去的扰动是已知的; 否则我们就面临一个不完全状态信息的问题。DP 算法取如下形式

$$\begin{aligned} J_{N-1}(x_0, \dots, x_{N-1}, u_0, \dots, u_{N-2}, w_0, \dots, w_{N-2}) \\ = \min_{u_{N-1} \in U_{N-1}(x_{N-1})} E \{g_N(x_0, \dots, x_{N-1}, f_{N-1}(x_{N-1}, u_{N-1}, w_{N-1}), \\ u_0, \dots, u_{N-1}, w_0, \dots, w_{N-1})\}. \\ J_k(x_0, \dots, x_k, u_0, \dots, u_{k-1}, w_0, \dots, w_{k-1}) \\ = \min_{u_k \in U_k(x_k)} E\{J_{k+1}(x_0, \dots, x_k, f_k(x_k, u_k, w_k), u_0, \dots, u_k, w_0, \dots, w_k)\}, \\ k=0, \dots, N-2. \end{aligned}$$

对控制约束集依赖于过去状态或控制等情况, 也可以写出类似的算法。

相关扰动

现在我们转到扰动 w_k 为相关的情况。这里我们假定 w_k 是欧氏空间的元, 而且 w_k 的概率分布并不明显地依赖于当前的状态 x_k 和 u_k , 但显然依赖于以前的扰动 $w_0, \dots, w_{k-1}$ 的值。利用统计方法(譬如见[A1]), 常常通过一个线性系统表示这个过程 $w_0, w_1, \dots, w_{N-1}$

$$\begin{aligned} y_{k+1} &= A_k y_k + \xi_k, \quad k=0, 1, \dots, N-1, y_0 = 0, \\ w_k &= C_k y_{k+1}, \end{aligned}$$

式中 A_k, C_k 是适当维数的矩阵, ξ_k 是具有给定分布的独立随机变量。换句话说, 相关过程 $w_0, \dots, w_{N-1}$ 表现为一个受白噪声过程扰动的线性系统的输出。如图 1.17 所示, 也即由独立随机向量构成的一个过程。

现在考虑 y_k 为附加的状态变量, 则有新的系统方程:

$$\begin{bmatrix} x_{k+1} \\ y_{k+1} \end{bmatrix} = \begin{bmatrix} f_k[x_k, u_k, C_k(A_k y_k + \xi_k)] \\ A_k y_k + \xi_k \end{bmatrix}. \quad (1.21)$$

把 $\tilde{x}_k = (x_k, y_k)$ 取为新的状态, 取 ξ_k 为新的扰动, 式(1.21)可以写成

$$\tilde{x}_{k+1} = \tilde{f}_k(\tilde{x}_k, u_k, \xi_k).$$

对代价泛函作适当变换, 该问题就简化为基本问题的形式。注意, 为使问题具有完全状态信息, 控制器必须能观测到 $y_k, k=1, \dots, N-1$ 。当矩阵 C_{k-1} 为单位阵、 w_{k-1} 可观测时,




图 1.17 相关过程 $\{w_k\}$ 表示成由白噪声序列 $\{\xi_k\}$ 驱动的一个线性系统的输出。

即具有完全状态信息。DP 算法取如下形式

$$J_N(x_N, y_N) = g_N(x_N),$$

$$J_k(x_k, y_k) = \min_{u_k \in U_k(x_k)} E\{g_k[x_k, u_k, C_k(A_k y_k + \xi_k)] + J_{k+1}[f_k[x_k, u_k, C_k(A_k y_k + \xi_k)], A_k y_k + \xi_k]\}.$$

当 C_k 为单位阵时, 最优控制器具有如下形式

$$\{\mu_0^*(x_0), \mu_1^*(x_1, w_0), \dots, \mu_{N-1}^*(x_{N-1}, w_{N-2})\}.$$

预报

最后, 考虑这样一种情况: 在时刻 k , 决策者得到一个预报 y_k , 它导致对 w_k 的概率分布并可能对未来扰动要重新判断。例如, y_k 可能是 w_k 的一个准确的预报值, 或者 w_k 是有限分布类中的一个特定的分布的准确预报。在实际中令人感兴趣的预报是, 比方说气候状况、货币利率和库存需求的概率分布。

一般情况下, 预报可以用状态增广的方法来处理, 虽然变换成基本问题的形式相当复杂。这里我们只处理一个简单的情况。

考虑 w_k 的概率分布不依赖于 $x_k, u_k, w_{k-1}, \dots, w_0$ 的情况。假定在每个周期 k 的开始, 决策者收到一个准确预报: 下一个扰动 w_k 将根据有限的给定分布类 $\{P_{k+1|1}, \dots, P_{k+1|n}\}$ 中一个特殊的概率分布来选择; 即如果预报是 i , 则 w_k 根据 $P_{k+1|i}$ 来选择。在时刻 k 预报为 i 的先验概率 p_i^k 是给定的。于是, 预报过程可以用方程

$$y_{k+1} = \xi_k \quad (1.22)$$

来表示, 其中 y_{k+1} 可以取值 $1, 2, \dots, n$, 而 ξ_k 是以概率 $p_1^{k+1}, \dots, p_n^{k+1}$ 取值 $1, 2, \dots, n$ 的一个随机变量。这里的解释是: 当 ξ_k 取值为 i 时, 则 w_{k+1} 将按照概率分布 $P_{k+1|i}$ 出现。

把系统方程和式(1.22)结合起来, 我们得到一个增广系统为

$$\begin{bmatrix} x_{k+1} \\ y_{k+1} \end{bmatrix} = \begin{bmatrix} f_k(x_k, u_k, w_k) \\ \xi_k \end{bmatrix} = \tilde{f}_k(\tilde{x}_k, u_k, \tilde{w}_k).$$

新的状态是 $\tilde{x}_k = (x_k, y_k)$, 新的扰动是 $\tilde{w}_k = (w_k, \xi_k)$ 。 $\tilde{w}_k$ 的概率分布是根据分布 $P_{k+1|i}$ 和概率 p_i^k 给定, 且明显依赖于 $\tilde{x}_k$ (通过 y_k), 但不依赖于先前的扰动 $\tilde{w}_{k-1}, \dots, \tilde{w}_0$ 。于是, 通过对代价泛函的适当变换, 该问题就能纳入基本问题的框架。要注意的是, 在每个时刻施加的控制是当前状态和当前预报二者的函数。DP 算法取如下形式

$$J_N(x_N, y_N) = g_N(x_N),$$

$$J_k(x_k, y_k) = \min_{u_k \in U_k(x_k)} E \left\{ g_k(x_k, u_k, w_k) + \sum_{i=1}^n p_i^{k+1} J_{k+1}[f_k(x_k, u_k, w_k), i] | y_k \right\},$$

$$k = 0, 1, \dots, N-1,$$

式中对 w_k 取期望是对概率分布 $P_{k+1|y_k}$ 来进行的, 其中 y_k 可能取值 $1, 2, \dots, n$ 。预报扩大到覆盖几个周期也可按类似方法处理, 尽管要以增加复杂性为代价。受控制作用影响的预报问题也允许按类似方式处理。

从以上讨论应该清楚, 状态增广是把不确定条件下的决策问题转换为基本问题形式的非常通用和强有力的手段。还应该认识到, 按不同方法使状态增广, 则存在问题变换的许多途径。基本的指导原则是: 当进行第 k 次决策时, 只选择其知识有利于决策者的那些变量作为 k 时刻的增广状态。例如, 在单周期时间滞后的情况下, 直觉上一目了然的是, 知道 k 时刻 x_k, x_{k-1}, u_{k-1} 的值有利于控制器, 因为这些变量通过系统方程影响下一个状态 x_{k+1} 。然而,

知道 k 时刻 $x_{k-2}, x_{k-3}, \dots, u_{k-2}, \dots$ 的值, 则对控制器不能带来任何好处。因此, 这些过去的状态和控制不必包括在增广状态中, 虽然从技术上说把这些变量包括进去是可能的。在问题变换中, 只把那些其知识有利于决策过程的变量考虑作为增广状态的专题, 在讨论具有不完全状态信息的问题(第三章)时, 将占有重要的支配地位。

最后我们指出, 虽然状态增广是一个方便的方法, 但势必引入分析和计算上的复杂性, 这在许多情况下是个难以逾越的障碍。

§ 1.6 注 记

动态规则是一个简单的数学方法, 在各种不同的场合, 工程师、数学家和社会科学家已应用了许多年。正是贝尔曼在五十年代早就认识到, DP 将被发展(与数字计算机的出现相结合)成为一个优化的系统性工具。贝尔曼展示了 DP 的广阔范围, 并促使其理论形成一个统一的整体。他的早期著作[B5, B6], 至今仍是流行的读物。其它有关 DP 的著作有[H8], [H16], [K5], [K14], [N2], [R2], [W7]和[W11]。关于在一般空间中严格处理 DP, 解决与之有关的可测性问题, 并作为本书的补充材料, 请参阅[B23]。对连续时间问题的建立, 参阅[B7]和[F3]。

Viterbi 算法与最短路径问题的联系, 已在[O2]和[F4]中阐述清楚。关于搜索法的深入材料及其在博弈中的应用, 请参阅[P9]。关于最短路径、分枝定界和组合优化方面的背景材料, 参阅[P2]。

正如在 § 1.1 所讨论的那样, 只有在扰动空间是可数集的情况下, 基本问题建立才是严格的。然而, 当可数性假设不能满足, 而对容许控制律类有进一步的限制(如可测性)时, DP 算法往往能够按一种简单的方式加以利用。程度高的读者通过求解习题 12 会明白如何做到这一点。这个习题表明, 如果人们能在一个控制律子集(如这个子集满足某个可测性约束)内, 找到一个达到 DP 算法极小值的控制律, 则此控制律就是最优的。这个事实可以用来严格建立第二章和第三章中有关特殊应用所引出的许多结果。例如, 在线性二次型问题中(§ 2.1), 由 DP 方程确定一个控制律, 它是当前状态的一个线性函数。当 w_k 可以取不可数的多个值时, 容许控制律仅由波雷尔可测的函数 μ_k 所组成。因为线性控制律属于这一类, 习题 12 的结果保证这一控制律是最优的。

习 题

1. 用 DP 算法求解以下两个问题:

- (a) $\min \sum_{i=0}^3 x_i^2 + u_i^2$
s. t $x_0 = 0, x_4 = 8, u_i = \text{非负整数}$
 $x_{i+1} = x_i + u_i, i = 0, 1, 2, 3;$
- (b) $\min \sum_{i=0}^3 x_i^2 + 2u_i^2$
s. t $x_0 = 5, u_i \in \{0, 1, 2\},$
 $x_{i+1} = x_i - u_i, i = 0, 1, 2, 3.$

2. 在 n 个城市之间有航线。在一些情况下可直达, 而在另一些情况下通过中转换乘飞

机。城市 i 和 j 之间的航班票价记为 C_{ij} ($C_{ij} = C_{ji}$)。而为了标记方便, 当 i 和 j 之间没有直达航班时, 记 $C_{ij} = \infty$ 。问题是寻求由任一城市 i , 也许通过中转达到任意其它城市 j 可能最便宜的航费。建立一个 DP 算法来求解这一问题。当 $n=6$, 且 $C_{12}=30, C_{13}=60, C_{14}=25, C_{15}=C_{16}=\infty, C_{23}=C_{24}=C_{25}=\infty, C_{26}=50, C_{34}=35, C_{35}=C_{36}=\infty, C_{45}=15, C_{46}=\infty, C_{56}=15$ 时, 求解这一问题的答案。

3. 假定有一台机器, 它处于运行或损坏状态之一。如果运行一周, 产生总利润 100 美元。如果一周中发生故障, 总利润为零。如果在一周开始处于运行状态, 并采取预防性维护措施, 则一周内出现故障的概率是 0.4; 如不进行维护, 故障的概率是 0.7。然而, 维护要花去 20 美元。当在一周开始时机器损坏, 或以 40 美元的费用去修理, 在此情况下出现故障的概率是 0.4; 或用新机器取代, 费用为 150 美元, 它保证机器在第一周正常运行。假定第一周开始时为新机器, 寻求一个最优的修理、取代和维护策略, 使四周的总利润为最大。

4. 两个对手共玩一种掷骰子之类的赌博游戏如下: 二人共掷一颗骰子。第一人知道其对手点数后可以停投, 也可以再掷一次骰子, 而把所掷点数加到他以前掷的点数上。然后他可以停止, 或者再掷, 并把新掷的点数加到他以前掷的点数总和之上。他愿意重复这一过程多少次就重复多少次。如果他的总点数超过 7 点(即失败), 他就输了。如果他在超过 7 点之前就停掷, 第二人接过去连续掷骰子, 直到他的总点数是 4 或高于 4。如果第二人的总点数超过 7 点, 他就输了。否则, 具有较大总点数的人赢; 在持平的情况下算第二人赢。问题是确定第一人的停止策略, 使其对第二人每个可能的初始投掷点数, 赢得这次赌博的概率为最大。试根据 DP 建立这一问题, 并在第二人初始投掷点数是 3 的情况下, 求一个最优停止策略。提示: 取 $N=6$, 状态空间由如下 15 个状态组成:

x^1 : 失败;

x^{1+i} : 在点数总和为 i ($1 \leq i \leq 7$) 时已停掷;

x^{8+i} : 当前的点数总和是 i , 但投掷者还未停止 ($1 \leq i \leq 7$)。

最优策略是不断投掷, 直到点数总和是 4 或高于 4。

5. 极小极大问题。在基本问题的框架中, 考虑扰动 $w_0, w_1, \dots, w_{N-1}$ 不具有概率描述, 但知道其属于相应的给定的集合 $W_k(x_k, u_k) \subset D_k, k=0, 1, \dots, N-1$, 而这些集合依赖于当前状态 x_k 和控制 u_k 。在这种情况下, 寻求一个控制律 $\pi = \{u_0, \dots, u_{N-1}\}$, 且对所有 x_k 和 k , 有 $\mu_k(x_k) \in U_k(x_k)$, 使得代价泛函

$$J_\pi(x_0) = \max_{\substack{w_k \in W_k[x_k, \mu_k(x_k)] \\ k=0, 1, \dots, N-1}} \left\{ g_N(x_N) + \sum_{k=0}^{N-1} g_k[x_k, \mu_k(x_k), w_k] \right\}.$$

为极小。这个问题的 DP 算法取如下形式

$$J_N(x_N) = g_N(x_N),$$

$$J_k(x_k) = \min_{u_k \in U(x_k)} \max_{w_k \in W_k(x_k, u_k)} \{g_k(x_k, u_k, w_k) + J_{k+1}[f_k(x_k, u_k, w_k)]\}.$$

假定对所有 x_k 和 k , $J_k(x_k) > -\infty$, 证明最优代价等于 $J_0(x_0)$ 。提示: 模仿在随机情况下的证明; 证明并利用如下事实: 如果 U, W, X 是三个集合, $f: W \rightarrow X$ 是一个函数, 而 M 是所有函数 $\mu: X \rightarrow U$ 的集合; 那么, 对于任意函数 $G_0: W \rightarrow (-\infty, \infty]$, $G_1: X \times U \rightarrow (-\infty, \infty]$, 使得

$$\min_{u \in U} G_1[f(w), u] > -\infty, \quad \text{对所有 } w \in W,$$

则有

$$\min_{u \in U} \max_{w \in W} \{G_0(w) + G_1[f(w), u]\} = \max_{w \in W} \{G_0(w) + \min_{u \in U} G_1[f(w), u]\}.$$

6. 每阶段折扣代价问题。在基本问题的框架中, 考虑代价泛函取如下形式的情况

$$E\left\{\alpha^N g_N(x_N) + \sum_{k=0}^{N-1} \alpha^k g_k(x_k, u_k, w_k)\right\},$$

式中 α 是折扣因子, 且 $0 < \alpha < 1$ 。证明 DP 算法的另一种形式由下式给定

$$\begin{aligned} V_N(x_N) &= g_N(x_N), \\ V_k(x_k) &= \min_{u_k \in U_k(x_k)} E\{g_k(x_k, u_k, w_k) + \alpha V_{k+1}[f_k(x_k, u_k, w_k)]\}. \end{aligned}$$

7. 指数代价泛函问题。在基本问题的框架中, 考虑代价泛函具有如下形式的情况

$$E_{w_k} \left\{ \exp \left[g_N(x_N) + \sum_{k=0}^{N-1} g_k(x_k, u_k, w_k) \right] \right\}, \quad k=0, 1, \dots, N-1$$

(a) 证明最优代价和最优策略可以由 DP 算法

$$\begin{aligned} J_N(x_N) &= \exp[g_N(x_N)], \\ J_k(x_k) &= \min_{u_k \in U_k(x_k)} E\{J_{k+1}[f_k(x_k, u_k, w_k)] \exp[g_k(x_k, u_k, w_k)]\}. \end{aligned}$$

的最后一步得到。如果其最优控制律存在, 证明这一算法产生一个最优控制律。

(b) 定义函数 $V_k(x_k) = \ln J_k(x_k)$, 再假定 g_k 仅为 x_k 和 u_k (而不是 w_k) 的函数。证明上述 DP 算法可以重新写成

$$\begin{aligned} V_N(x_N) &= g_N(x_N), \\ V_k(x_k) &= \min_{u_k \in U_k(x_k)} [g_k(x_k, u_k) + \ln E\{\exp V_{k+1}[f_k(x_k, u_k, w_k)]\}]. \end{aligned}$$

8. 终止过程。在基本问题中, 考虑这样一种情况: 在时刻 i 发生一个给定的扰动值 $\bar{w}_i$, 或在此时刻控制器给出终止决策 u_i , 则系统演化在时刻 i 终止。如果在时刻 i 发生终止, 最终的代价是

$$T + \sum_{k=0}^i g_k(x_k, u_k, w_k),$$

式中 T 是一个终止代价。如果过程直到最后时刻 N 还未终止, 最终的代价是 $g_N(x_N) + \sum_{k=0}^{N-1} g_k(x_k, u_k, w_k)$ 。把问题变换成基本问题的框架。提示: 用一个特殊的终止态把状态空间扩增。

9. 相乘代价。在基本问题的框架中, 考虑代价泛函具有相乘形式

$$E_{w_k} \{g_N(x_N) \cdot g_{N-1}(x_{N-1}, u_{N-1}, w_{N-1}) \cdots g_0(x_0, u_0, w_0)\}, \quad k=0, \dots, N-1$$

的情况。假定对所有 x_k, u_k, w_k 和 k , $g_k(x_k, u_k, w_k) \geq 0$, 对此问题设计一个 DP 型的算法。

10. 假定有一艘货船, 其最大载重量为 z , 它的装货包含有 N 种不同数量的不同货物。令 v_i 是第 i 种货物的价值, w_i 是第 i 种货物的重量, 而 x_i 是装在这艘货船中第 i 种货物数目, 问题是确定最大价值的装货, 即使 $\sum_{i=1}^N x_i v_i$ 为最大, 同时受 $\sum_{i=1}^N x_i w_i \leq z$, 及 $x_i = 0, 1, 2, \dots$ 的约束。按 DP 建立这一问题。

11. 考虑一个由 N 级串联组成的装置, 其中每一级都由一个特殊元件构成。元件可能受到损坏。为了提高装置的可靠性, 提供备用元件。对于 $j = 1, 2, \dots, N$, 令 $(1 + m_j)$ 是第 j 级的元件数; 又令 $p_j(m_j)$ 是使用 $(1 + m_j)$ 个元件时, 第 j 级成功运行的概率; 令 c_j 是第 j 级单个元件的价值。考虑寻求每级元件数目, 使由下式

$$p_1(m_1) \cdot p_2(m_2) \cdots p_N(m_N)$$

表示的装置可靠性为最大, 且受到价值约束 $\sum_{j=1}^N c_j m_j \leq A$, 其中 $A > 0$ 是给定的。按 DP 建立此问题。

12. 在一个策略子集上求极小。这个问题主要有理论上的意义(见本章注记的末尾部分)。考虑基本问题的一种变形, 对其寻求

$$\min_{x \in \tilde{\Pi}} J_{\pi}(x_0),$$

其中 $\tilde{\Pi}$ 是函数 μ_k 序列 $\{\mu_0, \mu_1, \dots, \mu_{N-1}\}$ 的集合的某个给定的子集, 而函数 $\mu_k: S_k \rightarrow C_k$, 且对所有 $x_k \in S_k$, 有 $\mu_k(x_k) \in U_k(x_k)$ 。假定

$$\pi^* = \{\mu_0^*, \mu_1^*, \dots, \mu_{N-1}^*\}$$

属于 $\tilde{\Pi}$, 且按 DP 算法达到极小, 即对所有 $k = 0, 1, \dots, N-1$, 和 $x_k \in S_k$,

$$\begin{aligned} J_k(x_k) &= E \{g_k[x_k, \mu_k^*(x_k), w_k] + J_{k+1}[f_k(x_k, \mu_k^*(x_k), w_k)]\} \\ &= \min_{u_k \in U_k(x_k)} E \{g_k(x_k, u_k, w_k) + J_{k+1}[f_k(x_k, u_k, w_k)]\}, \end{aligned}$$

且 $J_N(x_N) = g_N(x_N)$ 。进一步假定函数 J_k 是实值, 上面的数学期望适当定义且有限。证明 π^* 在 $\tilde{\Pi}$ 内是最优的, 且

$$J_0(x_0) = \min_{x \in \tilde{\Pi}} J_{\pi}(x_0) = J_{\pi^*}(x_0).$$

13. 半线性系统。考虑一个包含如下系统

$$x_{k+1} = A_k x_k + f_k(u_k) + w_k,$$

的问题, 其中 $x_k \in R^n$, f_k 是给定的函数; 而 A_k 和 w_k 分别是 $n \times n$ 随机矩阵和 n 维随机向量, 具有不依赖于 x_k 和 u_k , 或 A_k 和 w_k 以前值的给定的概率分布。假定代价泛函具有如下形式

$$E_{A_k, w_k} \left\{ c_N' x_N + \sum_{k=0}^{N-1} [c_k' x_k + g_k[\mu_k(x_k)]] \right\},$$

其中 c_k 是给定的向量, 而 g_k 是给定的函数。证明如果该问题的最优代价是有限的, 控制约束集 $U_k(x_k)$ 与 x_k 无关, 则 DP 算法的余留代价函数是仿射的(线性加常数)。假定至少存在一个最优策略, 证明存在一个最优策略由常值函数 μ_k^* 构成; 即对所有 $x_k \in R^n$, $\mu_k^*(x_k) = \text{常数}$ 。

14. 一个农民, 每年生产 x_k 个单位的某种谷物, 把 $(1-u_k)x_k$ 单位的产品贮存起来, 其中 $0 \leq u_k \leq 1$; 而把其余 $u_k x_k$ 单位用于投资; 于是下一年的产量增加到 x_{k+1} , 并由下式给出

$$x_{k+1} = x_k + w_k u_k x_k, \quad k=0, 1, \dots, N-1.$$

标量 w_k 是独立随机变量, 具有不依赖于 x_k 和 u_k 的恒定分布。而且, $E\{w_k\} = \bar{w} > 0$ 。问题是寻求一个最优投资策略, 使 N 年的贮存产品总期望

$$E_{w_k, k=0, 1, \dots, N-1} \left\{ x_N + \sum_{k=0}^{N-1} (1-u_k)x_k \right\}.$$

为极大。证明一个最优控制律由以下给定:

(a) 如果 $\bar{w} > 1$, $\mu_0^*(x_0) = \dots = \mu_{N-1}^*(x_{N-1}) = 1$ 。

(b) 如果 $0 < \bar{w} < 1/N$, $\mu_0^*(x_0) = \dots = \mu_{N-1}^*(x_{N-1}) = 0$ 。

(c) 如果 $1/N \leq \bar{w} \leq 1$,

$$\mu_0^*(x_0) = \dots = \mu_{N-\bar{k}-1}^*(x_{N-\bar{k}-1}) = 1,$$

$$\mu_{N-\bar{k}}^*(x_{N-\bar{k}}) = \dots = \mu_{N-1}^*(x_{N-1}) = 0,$$

式中 $\bar{k}$ 使得 $1/(\bar{k}+1) < \bar{w} \leq 1/\bar{k}$ 。(注意, 这个控制律由常值函数构成。)

15. 设 x_k 表示某个国家在周期 k 的教育工作者数目, 又令 y_k 表示在周期 k 的研究人员数目。在第 k 个周期内, 新的科学家(潜在的教育工作者和研究人員)由教育工作者按每人 γ_k 的速率产生; 同时教育工作者和研究人員因死亡、退休和调动以速率 δ_k 离开岗位。标量 γ_k , $k=0, 1, \dots, N-1$, 是取值于正实数的一个有界闭区间、独立恒定分布的随机变量。类似地, δ_k , $k=0, 1, \dots, N-1$ 是取值于区间 $[\delta, \delta']$, 且 $0 < \delta \leq \delta' < 1$, 独立恒定分布。根据鼓励的原则, 科学政策制定者可决定在 k 周期所产生新科学家变成教育工作者的部分 u_k 。于是, 教育工作者和研究人員的数目按如下方程演变

$$x_{k+1} = (1-\delta_k)x_k + u_k \gamma_k x_k,$$

$$y_{k+1} = (1-\delta_k)y_k + (1-u_k)\gamma_k x_k.$$

初始数目 x_0, y_0 是已知的, 要求找到一个策略 $\{\mu_0^*(x_0, y_0), \dots, \mu_{N-1}^*(x_{N-1}, y_{N-1})\}$, 且对所有 x_k, y_k 和 k ,

$$0 < \alpha \leq \mu_k^*(x_k, y_k) \leq \beta < 1,$$

它使 $E_{\gamma_k, \delta_k}\{y_N\}$ (即在 N 个周期后, 最后研究人員的期望数) 为最大。标量 α 和 β 是给定的。

(a) 证明余留代价函数 $J_k(x_k, y_k)$ 是线性的, 即对某标量 λ_k, μ_k

$$J_k(x_k, y_k) = \lambda_k x_k + \mu_k y_k.$$

(b) 在 $E\{\gamma_k\} > E\{\delta_k\}$ 的假设条件下, 推导最优策略 $\{\mu_0^*, \dots, \mu_{N-1}^*\}$, 而且证明这个最优策略可以由常值函数构成。

(c) 假定 k 周期新科学家成为教育工作者的部分是 $u_k + \varepsilon_k$ (而不是 u_k), 其中 ε_k 是独立恒定分布的随机变量, 它还独立于 γ_k 和 δ_k , 且取值于区间 $[-\alpha, 1-\beta]$ 。导出余留代价函数和最优策略的形式。

16. 在两个并行处理器执行 DP[L1]。在一台由两个处理器组成的并行计算机上建立 DP 算法, 求解 § 1.3 的确定性问题。一个处理器执行正向算法, 另一个执行反向算法。

17. 分段(落)问题是把具有长度 $L_1, \dots, L_N$ 的 N 个词 $w_1, \dots, w_N$ 所组成的一个序列分

割成长度为 A 的行。在该问题的一种简单形式中，词由理想宽度为 b 的空档隔开，但空档可根据需要拉长或缩短。于是，一行 $w_i, w_{i+1}, \dots, w_{i+k}$ 的长度准确地为 A 。与此行相关的代价是 $(k+1)|b' - b|$ ，其中 $b' = (A - L_i - \dots - L_{i+k}) / (k+1)$ 是空档的实际平均宽度；如有最末的一行 ($N = i+k$)，则在此情况下当 $b' \geq b$ 时，代价为零。建立求解问题的一个 DP 算法，使分隔代价为极小。提示：对于 $i = 1, \dots, N$ ，考虑最优分隔 $w_i, \dots, w_N$ 的子问题。

18. 计算机分配。在古老的扑克牌游戏中，玩牌者只有知道发牌者发的一张牌后才出牌。当牌的点数总和超过 21 时，玩牌者就输了。如果玩牌者在超过 21 点之前停止出牌，则发牌者出牌，直到达到 17 点或超过 17 点。如他的总点数超过 21 点，或者低于玩牌者的点数，发牌者就输了。如果玩牌者和出牌者结束时有相等的总点数，二人均无输赢；在所有其它情况下都是发牌者赢。玩牌者按其选择可以 1 或 11 来计 A 的点数；发牌者在其总点数为 17 到 21 之间时，按 11 计 A 的点数；其它情况下计为 1 点。J、Q、K 双方都计为 10 点。我们假定牌的副数为无限多，这样特定牌出现的概率与以前出的牌无关。

(a) 对发牌者每一个可能的头张牌，计算发牌者总点数达到 17、18、19、20、21 或超过 21 的概率。

(b) 对双方总点数之和为 12 到 20 的每一个可能值计算玩牌者的最优选择(出牌或停止出牌)。假定玩牌者的牌并不包括 A 。

(c) 在玩牌者的牌包括 A 时，重复(b)。

19. 考虑一个流行的小型智力游戏。三个标有数字 1、2、3 的方形彩块放在一个 2×2 的格子中，留下一个空格。与空格相邻的两个彩块可以移到空格中去，由此建立一个新的布局。利用 DP 的一种论证方法回答如下问题：由任意其它布局开始，是否有可能产生一个给定的布局？

20. 在一堆 11 根火柴棒中，两个人轮流取走 1 根或 4 根火柴棒，取走最后一根火柴的，人获胜。试利用一种 DP 的论证，证明存在一个先取火柴者获胜的策略。

21. 伪币问题。有六枚硬币，其中一枚是伪币，而且知道它比其它硬币重或轻。试构造一个策略，用双盘天平，以最少平均试验次数找出伪币。提示：有两个初始决策有意义：(1) 两对两试验；(2) 一对一试验。

22. 给定一系列矩阵相乘式

$$M_1 M_2 \cdots M_k M_{k+1} \cdots M_N,$$

式中 $M_k, k = 1, \dots, N$ 维数为 $n_k \times n_{k+1}$ 。其中相乘的次序会产生不同的结果。例如，若 $n_1 = 1, n_2 = 10, n_3 = 1, n_4 = 10$ ，^[注] 计算 $((M_1 M_2) M_3)$ 需要 20 次乘法运算；但计算 $(M_1 (M_2 M_3))$ 需要 200 次相乘运算。推导一个 DP 算法，以寻求最优相乘次序。对 $n_1 = 2, n_2 = 10, n_3 = 5, n_4 = 1$ 解此问题。

23. 加倍算法。考虑一个确定性时不变有限状态问题，即状态和控制空间、每阶段代价和系统方程对每个时间周期都是相同的。设 $J_k(x, y)$ 是由时刻 0 的状态 x 到达 k 时刻的状态 y 的最优代价，证明对所有 k ，

$$J_{2k}(x, y) = \min_z \{J_k(x, z) + J_k(z, y)\}.$$

讨论此方程如何被用来求解具有很阶段数的问题，而且具有优越性。

译者注：原文有漏，译者补入。

24. 最短路径问题 DP 的复杂性。考虑 § 1.3 最短路径算法

$$J_k(i) = \min_{j=1, \dots, N} \{c_{ij} + J_{k+1}(j)\}$$

假设 m 是一条最短路径中, 由任一结点 $1, \dots, N$ 到目的结点最多弧的数目。证明算法在 m 步之后结束, 而且需要的算术运算次数是由 γmL 定界, 其中 L 是弧数目, 而 γ 是不依赖于 m , L 和 N 的一个数。

25. DP 的单调性。DP 算法一个明显而又非常重要的特性是: 如果终端代价 g_N 变成一致较大的代价 $\tilde{g}_N$ [即对所有 x_N , $g_N(x_N) \leq \tilde{g}_N(x_N)$], 则相应的代价 $J_k(x_k)$ 将是一致增加的。更一般地, 给定两个函数 J_{k+1} 和 $\tilde{J}_{k+1}$, 且对所有 x_{k+1} , $J_{k+1}(x_{k+1}) \leq \tilde{J}_{k+1}(x_{k+1})$, 则对所有 x_k 和 $u_k \in U_k(x_k)$, 有

$$\begin{aligned} & E_{w_k} \{g_k(x_k, u_k, w_k) + J_{k+1}[f_k(x_k, u_k, w_k)]\} \\ & \leq E_{w_k} \{g_k(x_k, u_k, w_k) + \tilde{J}_{k+1}[f_k(x_k, u_k, w_k)]\}. \end{aligned}$$

现在假定, 在基本问题中系统和代价是时不变的; 即 $S_k \equiv S$, $C_k \equiv C$, $D_k \equiv D$, $f_k \equiv f$, $U_k(x_k) \equiv U(x_k)$, 及 $g_k \equiv g$ 。证明在 DP 算法中, 如果对所有 $x \in S$ 有 $J_{N-1}(x) \leq J_N(x)$, 则

$$J_k(x) \leq J_{k+1}(x), \quad \text{对所有 } x \in S \text{ 和 } k.$$

类似地, 如果对所有 $x \in S$ 有 $J_{N-1}(x) \geq J_N(x)$, 则

$$J_k(x) \geq J_{k+1}(x), \quad \text{对所有 } x \in S \text{ 和 } k.$$

26. 修改 § 1.4 的正向搜索算法, 使它同时找出从原点 s 到几个目的地结点的最短路径。提示: 把目的地结点与一个新的人为结点用具有足够大长度的弧联接起来。

27. 最短路径问题的 *Dijkstra* 算法。考虑 § 1.4 正向搜索算法中的最佳优先型式。在每次迭代中, 我们从 OPEN 表中选择一个结点 j , 使其对 OPEN 表中的所有结点具有最小的估计 d_j 。

(a) 证明每个结点 j 进入 OPEN 表至多一次; 再证明在其进入 CLOSED 表的时刻, 其估计 d_j 等于由 s 到 j 的最短距离。

(b) 证明终止所需要的算术运算次数由 cN^2 定界, 其中 N 是结点数, c 是某个常数。

28. 分布式异步最短路径计算[B19]。考虑寻找由结点 $1, 2, \dots, N$ 到结点 t 的最短路径的问题, 假定所有弧 c_{ij} 为正。考虑迭代

$$\begin{aligned} d_i^{k+1} &= \min_j \{c_{ij} + d_j^k\}, \quad i = 1, 2, \dots, N, \\ d_t^{k+1} &= 0. \end{aligned} \quad (1.23)$$

(a) 在 § 1.3 已证明, 如果对 $i = 1, \dots, N$, 初始条件是 $d_i^0 = \infty$ 和 $d_t^0 = 0$, 则式(1.23)在 N 步内产生一个最短距离 d_i^* 。证明对于所有 $i = 1, \dots, N, t$, 如果初始条件是 $d_i^0 = 0$, 则式(1.23)在有限步产生最短距离。根据问题的数据对迭代次数提出一个上界。

(b) 假定迭代

$$d_i := \min_j \{c_{ij} + d_j\} \quad (1.24)$$

在结点 i 执行, 并与每个其它结点 j 对 d_j 的相应迭代并行处理。然而, 在各不同结点执行这一迭代的时间并不同步。而且, 每个结点 i 把其最后的计算结果 d_i , 在任意时刻进行通信, 具有潜在的大的通信时延。所以, 从每个其它相邻结点接收到一个通信之前, 存在一个结点

执行迭代式(1.24)几次的可能性。假定每个结点从不停止执行迭代式(1.24)，且把结果发送到其它结点。证明时刻 T 相应结点 i 可得估计 d_i^T ，对于在一个有限时间 $\overline{T}$ 之后的所有 T ，等于最短距离 d_i^* 。提示：设 $\bar{d}_i^*$ 和 $\underline{d}_i^*$ 分别为从(a)中的第一个和第二个初始条件起始，式(1.23)所产生的估计。证明对每个 k ，存在一个时刻 T_k ，使得对所有 $T \geq T_k$ ，有 $\underline{d}_i^* \leq d_i^T \leq \bar{d}_i^*$ 。

第二章 特殊领域中的应用

§ 2.1 线性系统和二次代价函数：确定性等价原理

本节我们考虑线性系统情况

$$x_{k+1} = A_k x_k + B_k u_k + w_k, \quad k=0, 1, \dots, N-1,$$

这里，目的是寻找一个控制律，使二次代价泛函

$$E_{w_k} \left\{ x_N' Q_N x_N + \sum_{k=0}^{N-1} (x_k' Q_k x_k + u_k' R_k u_k) \right\},$$

$k=0, \dots, N-1$

为极小。在这个表达式中， x_k 和 u_k 分别为 n 和 m 维向量；矩阵 A_k , B_k , Q_k , R_k 给定，并且有适当的维数。假定 Q_k 为对称半正定矩阵， R_k 是对称正定阵；扰动 w_k 是独立随机向量，具有给定的概率分布，与 x_k 和 u_k 无关。而且，向量 w_k 有零均值和有限二阶矩，控制 u_k 无约束。

这是调节器问题的一个通用描述方程。我们要保持系统状态接近原点，这类问题在运动或过程的自动控制中是很一般的。二次代价泛函通常是合理的，因为它对状态偏离原点大的进行重罚；而对小偏离进行轻罚。然而，即使在并不完全有道理的情况，也常用二次代价。因为它可导出易于实现的绝妙的解析解。许多不同的变化形式和推广形式也具有类似的解。例如，扰动 w_k 可以有非零均值，二次代价可有如下形式

$$E \left\{ (x_N - \bar{x}_N)' Q_N (x_N - \bar{x}_N) + \sum_{k=0}^{N-1} [(x_k - \bar{x}_k)' Q_k (x_k - \bar{x}_k) + u_k' R_k u_k] \right\},$$

此式表达了一个愿望，使系统状态接近于某给定轨迹 $(\bar{x}_0, \bar{x}_1, \dots, \bar{x}_N)$ 而不是接近于原点。另一种推广形式是当 A_k , B_k 为独立随机矩阵，而不是已知阵。这一情况在本节末进行考虑。

现在应用 DP 算法，我们有

$$J_N(x_N) = x_N' Q_N x_N, \quad (2.1)$$

$$J_k(x_k) = \min_{u_k} E \{ x_k' Q_k x_k + u_k' R_k u_k + J_{k+1}(A_k x_k + B_k u_k + w_k) \}. \quad (2.2)$$

这就使得余留代价函数 J_k 为二次型。由此，最优控制律是状态的线性函数，这可由直接计算来证明。对 $k=N-1$ ，将式(2.2)中二次形式(2.1)展开，利用 $E\{w_{N-1}\}=0$ ，消去 $E\{w_{N-1}' Q_N (A_{N-1} x_{N-1} + B_{N-1} u_{N-1})\}$ ，我们有

$$\begin{aligned} J_{N-1}(x_{N-1}) = & x_{N-1}' Q_{N-1} x_{N-1} + \min_{u_{N-1}} [u_{N-1}' R_{N-1} u_{N-1} \\ & + u_{N-1}' B_{N-1}' Q_N B_{N-1} u_{N-1} + x_{N-1}' A_{N-1}' Q_N A_{N-1} x_{N-1} \\ & + 2x_{N-1}' A_{N-1}' Q_N B_{N-1} u_{N-1}] + E\{w_{N-1}' Q_N w_{N-1}\}. \end{aligned}$$

对 u_{N-1} 求导，并使导数为零，得

$$(R_{N-1} + B_{N-1}' Q_N B_{N-1}) u_{N-1} = -B_{N-1}' Q_N A_{N-1} x_{N-1}.$$

因为 R_{N-1} 正定， $B_{N-1}' Q_N B_{N-1}$ 半正定，故乘在 u_{N-1} 左边的矩阵正定，从而可逆。由此，极

小的控制向量由下式给定

$$u_{N-1}^* = -(R_{N-1} + B_{N-1}' Q_N B_{N-1})^{-1} B_{N-1}' Q_N A_{N-1} x_{N-1}.$$

代入 J_{N-1} 的表达式, 我们有

$$J_{N-1}(x_{N-1}) = x_{N-1}' K_{N-1} x_{N-1} + E\{w_{N-1}' Q_N w_{N-1}\},$$

式中矩阵 K_{N-1} 由直接计算而得, 并由下式给定

$$K_{N-1} = A_{N-1}' [Q_N - Q_N B_{N-1} (B_{N-1}' Q_N B_{N-1} + R_{N-1})^{-1} B_{N-1}' Q_N] A_{N-1} + Q_{N-1}.$$

显然, 矩阵 K_{N-1} 是对称的, 也是半正定的。为了看清这一点, 注意由前面的计算, 对 $x \in R^n$, 我们有

$$x' K_{N-1} x = \min_u [x' Q_{N-1} x + u' R_{N-1} u + (A_{N-1} x + B_{N-1} u)' Q_N (A_{N-1} x + B_{N-1} u)].$$

因为 Q_{N-1} , R_{N-1} 和 Q_N 是半正定的, 括号内的表达式非负, 对 u 求极小仍保持非负性, 所以对 $x \in R^n$, $x' K_{N-1} x \geq 0$ 。因此, K_{N-1} 是半正定的。

根据 J_{N-1} 是一个半正定二次函数(加上一个无关紧要的常数项), 我们可以按类似处理从 DP 方程式(2.2)获得 $N-2$ 阶段最优控制律。如前, 我们证明 J_{N-2} 是一个半正定二次函数。依次进行, 对每一个 k 得到最优控制律, 具有形式

$$\mu_k^*(x_k) = L_k x_k, \quad (2.3)$$

式中增益矩阵 L_k 由如下方程给出

$$L_k = -(B_k' K_{k+1} B_k + R_k)^{-1} B_k' K_{k+1} A_k, \quad (2.4)$$

式中对称半正定矩阵 K_k 递推地由如下算法给出

$$K_N = Q_N, \quad (2.5)$$

$$K_k = A_k' [K_{k+1} - K_{k+1} B_k (B_k' K_{k+1} B_k + R_k)^{-1} B_k' K_{k+1}] A_k + Q_k. \quad (2.6)$$

最优代价由下式给出:

$$J_0(x_0) = x_0' K_0 x_0 + \sum_{k=0}^{N-1} E\{w_k' K_{k+1} w_k\}.$$

这个解具有吸引力的方面是比较简单。用它来计算控制律式(2.3), 并在工程应用中实现。当前状态通过线性反馈增益阵 L_k 被反馈作为输入, 如图 2.1 所示。这说明了




图 2.1 线性二次问题最优控制器的线性反馈结构
线性二次描述最为普遍的原因。在第三章我们将会看到, 即使系统状态 x_k 不是完全能观(不完全状态信息), 控制律仍保持为线性。

黎卡提方程和它的渐近行为

方程(2.6)叫做离散时间黎卡提方程。它在现代控制理论中起重要作用, 其性质已被广泛而尽详地进行研究。黎卡提方程一个有趣的性质是: 只要矩阵 A_k , B_k , Q_k , R_k 为常阵, 并分别等于 A , B , Q , R ; 那么当 $k \rightarrow -\infty$ 时, 其解 K_k 收敛(在适当的假定条件下)到稳态解 K , 满足代数黎卡提方程

$$K = A' [K - K B (B' K B + R)^{-1} B' K] A + Q. \quad (2.7)$$

马上要证明的这个性质说明, 当系统为

$$x_{k+1} = Ax_k + Bu_k + w_k, \quad k=0,1,\dots,N-1, \quad (2.8)$$

且阶段数 N 很大时, 控制式(2.3)可合理地由线性平稳控制律 $\{\mu^*, \mu^*, \dots, \mu^*\}$ 来近似, 这里

$$\mu^*(x) = Lx, \quad (2.9)$$

$$L = -(B'KB + R)^{-1}B'KA, \quad (2.10)$$

K 是黎卡提方程式(2.6)的稳态解, 满足式(2.7)。这个控制律就实现而言更有吸引力。

现在我们转而证明由黎卡提方程产生的矩阵序列 $\{K_k\}$ 的收敛性。首先引入能控性和能观性概念, 这在现代控制论中是十分重要的。

定义 如果 $n \times nm$ 矩阵

$$[B, AB, A^2B, \dots, A^{n-1}B]$$

满秩(即具有线性独立行), 那么, (A, B) 对就称为能控的, 其中 A 为 $n \times n$ 矩阵, B 为 $n \times m$ 矩阵。如果 (A', C') 对为能控的, 其中 A' 和 C' 分别表示 A 和 C 的转置, 那么 (A, C) 对称为是能观的。其中 A 为 $n \times n$ 的矩阵, C 为 $m \times n$ 矩阵。

可以证明, 如果 (A, B) 对是能控的, 那么对任意的初始状态 x_0 , 存在一个控制向量序列 $u_0, u_1, \dots, u_{n-1}$, 迫使系统

$$x_{k+1} = Ax_k + Bu_k \quad (2.11)$$

在时刻 n 等于零。为了理解这一点, 注意由系统方程得

$$x_n = A^n x_0 + Bu_{n-1} + ABu_{n-2} + \dots + A^{n-1}Bu_0,$$

或者等价地

$$x_n - A^n x_0 = [B, AB, \dots, A^{n-1}B] \begin{bmatrix} u_{n-1} \\ \vdots \\ u_0 \end{bmatrix}. \quad (2.12)$$

如果 (A, B) 是能控的, 矩阵 $[B, AB, \dots, A^{n-1}B]$ 满秩; 由此, 可以适当地选择 $(u_0, u_1, \dots, u_{n-1})$ 使式(2.12)的右边等于 R^n 中任意向量。特别地, 可以选择 $(u_0, u_1, \dots, u_{n-1})$ 使式(2.12)的右边等于 $-A^n x_0$, 这意味 $x_n = 0$ 。这个性质阐明了“能控对”这个名称, 并用此来定义能控性。能观性的概念在估值问题中有类似的解释。即给定 $z_k = Cx_k$, 公式中的测量 $z_0, z_1, \dots, z_{N-1}$, 有可能推断系统 $x_{k+1} = Ax_k$ 的初始状态。

定义 若 $\lim_{k \rightarrow \infty} D^k = 0$ (即 D^k 元的序列收敛于零), 则 $n \times n$ 的矩阵 D 是稳定的。

注意, 若 D 是稳定矩阵, 那么系统 $x_{k+1} = Dx_k$ 的状态 x_k , 对任意状态 x_0 , 当 $k \rightarrow \infty$ 时, 趋于零。稳态性概念在控制理论中至关重要。在我们的问题中, 其重要性在于平稳控制律式(2.9)产生一个稳定的系统。也就是说矩阵 $(A + BL)$ 是一个稳定矩阵; 因而在无输入扰动情况下, 相应的闭环系统

$$x_k = (A + BL)x_{k-1} = (A + BL)^k x_0, \quad k=0,1,\dots,$$

的状态 x_k 当 $k \rightarrow \infty$ 时趋于零。

我们给出以下的命题。它证明对一个平稳系统和常矩阵 Q_k, R_k , 在能控性和能观性的条件下, 对任意半正定初始矩阵, 黎卡提方程式(2.5)和式(2.6)的解, 收敛于正定矩阵 K 。此外, 该命题证明了相应的控制律式(2.9)和式(2.10)导致一个稳定系统。为了简化标记, 在如下命题中, 我们已把黎卡提方程的时间标号反过来。这样, 方程式(2.13)中 P_k 相应于方程式(2.6)中 K_{N-k} 。

命题 令 A 为 $n \times n$ 阵, B 为 $n \times m$ 阵, Q 为 $n \times n$ 对称半正定律, R 为 $m \times m$ 对称正定

阵。考虑离散时间黎卡提方程

$$P_{k+1} = A' [P_k - P_k B (B' P_k B + R)^{-1} B' P_k] A + Q, \quad k = 0, 1, \dots, \quad (2.13)$$

式中初始矩阵 P_0 是任意的半正定对称阵。假定 (A, B) 对是能控的, 还假定 Q 可以写成 $C' C$, 这里 (A, C) 对是能观的^[注], 那么

(a) 存在一个正定对称阵 P , 使得每一个半正定对称初始阵 P_0 , 有

$$\lim_{k \rightarrow \infty} P_k = P.$$

而且, P 是半正定对称阵类中如下代数黎卡提方程的唯一解

$$P = A' [P - P B (B' P B + R)^{-1} B' P] A + Q. \quad (2.14)$$

(b) 矩阵

$$D = A + B L, \quad (2.15)$$

式中

$$L = -(B' P B + R)^{-1} B' P A, \quad (2.16)$$

是稳定矩阵。

证明 分几步进行。首先证明当初始矩阵 P_0 等于零时, 由式(2.13)所产生的序列的收敛性。其次证明式(2.15)矩阵 D 是稳定的。接着证明当 P_0 为任意半正定对称阵时, 由式(2.13)所产生序列的收敛性。最后我们证明式(2.14)解的唯一性。

初始矩阵 $P_0 = 0$ 考虑寻找一个序列 $u_0, u_1, \dots, u_{k-1}$, 使

$$\sum_{i=0}^{k-1} (x_i' Q x_i + u_i' R u_i) \quad (2.17)$$

为极小, 并受

$$x_{i+1} = A x_i + B u_i, \quad i = 0, 1, \dots, k-1, \quad (2.18)$$

约束的最优控制问题, 式中 x_0 给定。根据本节的理论, 这个问题的最优值是

$$x_0' P_k(0) x_0,$$

式中 $P_k(0)$ 由黎卡提方程式(2.13)给定, $P_0 = 0$ 。我们有

$$x_0' P_k(0) x_0 \leq x_0' P_{k+1}(0) x_0, \quad \text{对所有 } x_0 \in R^n, \quad k = 0, 1, \dots,$$

因为对任何控制序列 $(u_0, u_1, \dots, u_k)$ 我们有

$$\sum_{i=0}^{k-1} (x_i' Q x_i + u_i' R u_i) \leq \sum_{i=0}^k (x_i' Q x_i + u_i' R u_i).$$

因此

$$\begin{aligned} x_0' P_k(0) x_0 &= \min_{u_i, i=0, \dots, k-1} \sum_{i=0}^{k-1} (x_i' Q x_i + u_i' R u_i) \\ &\leq \min_{u_i, i=0, \dots, k} \sum_{i=0}^k (x_i' Q x_i + u_i' R u_i) = x_0' P_{k+1}(0) x_0, \end{aligned}$$

这里两个极小化都受系统方程 $x_{i+1} = A x_i + B u_i$ 约束; 而且对固定的 x_0 和每一个 $k, x_0' P_k(0) x_0$ 受一个代价制约而上有界。这个代价相应于迫使 x_0 在 n 步内回到原点, 而此后是控制为零的某个控制序列。按能控性的假定, 这样的一个序列是存在的。因而序列 $\{x_0' P_k(0) x_0\}$

原注: 注意, 若 r 是 Q 的秩, 就存在一个 $r \times n$, 秩为 r 的矩阵 C , 使 $Q = C' C$ (见附录 A)。

递增且有界。所以对每个 $x_0 \in R^n$ 收敛到某个实数。由此得出, 序列 $\{P_k(0)\}$ 收敛于某矩阵 P , 即 $P_k(0)$ 的元素序列收敛到相应的 P 元素。为了清楚起见, 取 $x_0 = (1, 0, \dots, 0)$ 。由此得出, $P_k(0)$ 第一个对角元素的序列收敛到 P 的第一个对角元素。相似地, 取 $x_0 = (0, \dots, 0, 1, 0, \dots, 0)$, 其中第 i 个元素为 1, $i = 2, \dots, n$ 。由此得出所有 $P_k(0)$ 的对角元素收敛至相应的 P 的对角元素。接下来取 $x_0 = (1, 1, 0, \dots, 0)$, 证明第一行的第二元素收敛。如此继续, 得到

$$\lim_{k \rightarrow \infty} P_k(0) = P,$$

式中 $P_k(0)$ 由式(2.13)产生, 且 $P_0 = 0$ 。而且极限矩阵 P 是半正定和对称的。现在, 在式(2.13)中取极限, 由此得, P 满足

$$P = A' [P - PB(B'PB + R)^{-1}B'P]A + Q. \quad (2.19)$$

而且, 若定义

$$L = -(B'PB + R)^{-1}B'PA, \quad D = A + BL \quad (2.20)$$

通过直接计算, 可以验证以下的等式。该式在后面的证明中将很有用:

$$P = D'PD + Q + L'RL. \quad (2.21)$$

$D = A + BL$. 稳定性 对一个任意初态 x_0 , 考虑系统

$$x_{k+1} = (A + BL)x_k = Dx_k \quad (2.22)$$

因为

$$x_k = D^k x_0,$$

所以只要证明当 $k \rightarrow \infty$ 时, $x_k \rightarrow 0$ 就行了。利用式(2.21), 对所有 k , 我们有

$$x'_{k+1}Px_{k+1} - x'_kPx_k = x'_k(D'PD - P)x_k = -x'_k(Q + L'RL)x_k.$$

因此

$$x'_{k+1}Px_{k+1} = x'_0Px_0 - \sum_{i=0}^k x'_i(Q + L'RL)x_i. \quad (2.23)$$

因为方程的左边有下界零, 得

$$x'_k(Q + L'RL)x_k \rightarrow 0.$$

利用 R 正定, Q 可以写成 CC' 的事实, 则得:

$$\lim_{k \rightarrow \infty} Cx_k = 0, \quad \lim_{k \rightarrow \infty} Lx_k = 0. \quad (2.24)$$

由式(2.22), 有

$$\begin{bmatrix} C(x_{k+n-1} - \sum_{i=1}^{n-1} A^{i-1}BLx_{k+n-i-1}) \\ C(x_{k+n-2} - \sum_{i=1}^{n-2} A^{i-1}BLx_{k+n-i-2}) \\ \vdots \\ C(x_{k+1} - BLx_k) \\ Cx_k \end{bmatrix} = \begin{bmatrix} CA^{n-1} \\ CA^{n-2} \\ \vdots \\ CA \\ C \end{bmatrix} x_k. \quad (2.25)$$

由于式(2.24), 左边趋于零, 故右边也趋于零。根据能观性假定, 式(2.25)右边乘 x_k 的矩阵满秩。由此, $x_k \rightarrow 0$, 式(2.21)的矩阵 D 是稳定的。

P 的正定性 假定相反, 即存在某个 $x_0 \neq 0$, 使得 $x'_0Px_0 = 0$ 。那么, 由式(2.23), 我

们得

$$x_k'(Q + L'RL)x_k = 0, \quad k = 0, 1, \dots,$$

式中 $x_k = D^k x_0$ 。这反过来说明[参阅方程(2.24)]

$$Cx_k = 0, \quad Lx_k = 0, \quad k = 0, 1, \dots$$

现在对 $k=0$, 考虑式(2.25), 按前面的等式, 左边为零, 因此

$$0 = \begin{bmatrix} CA^{n-1} \\ \vdots \\ CA \\ C \end{bmatrix} x_0.$$

因为乘 x_0 的矩阵按能观性假定满秩, 得 $x_0 = 0$, 这与 $x_0 \neq 0$ 的假设矛盾。因此 P 是正定的。

任意初始阵 P_0 。 接下来我们证明, 当初始矩阵是任意半正定矩阵 P_0 , 由式(2.13)所定义的矩阵序列 $\{P_k(x_0)\}$ 收敛到 $P = \lim_{k \rightarrow \infty} P_k(0)$ 。确实, 使

$$x_k' P_0 x_k + \sum_{i=0}^{k-1} (x_i' Q x_i + u_i' R u_i) \quad (2.26)$$

为极小, 受式(2.18)约束的最优代价等于 $x_0' P_k(0) x_0$ 。因此, 对每个 $x_0 \in R^n$, 我们有

$$x_0' P_k(0) x_0 \leq x_0' P_k(P_0) x_0.$$

现在考虑相应于控制器 $\mu(x_k) = u_k = Lx_k$ 的代价式(2.26), 这里 L 由式(2.20)定义。代价由下式给出:

$$x_0' \left[D'^k P_0 D^k + \sum_{i=0}^{k-1} [D'^i (Q + L'RL) D^i] \right] x_0.$$

且大于 $x_0' P_k(P_0) x_0$, 后者当然是式(2.26)的最优值。因此, 对所有 k 和 $x \in R^n$, 有

$$x' P_k(0) x \leq x' P_k(P_0) x \leq x' \left[D'^k P_0 D^k + \sum_{i=0}^{k-1} [D'^i (Q + L'RL) D^i] \right] x. \quad (2.27)$$

现在, 我们已证明

$$\lim_{k \rightarrow \infty} P_k(0) = P, \quad (2.28)$$

而且还有 (利用 $\lim_{k \rightarrow \infty} D'^k P_0 D^k = 0$)

$$\begin{aligned} \lim_{k \rightarrow \infty} \left\{ D'^k P_0 D^k + \sum_{i=0}^{k-1} [D'^i (Q + L'RL) D^i] \right\} \\ = \lim_{k \rightarrow \infty} \left\{ \sum_{i=0}^{k-1} [D'^i (Q + L'RL) D^i] \right\} = P, \end{aligned} \quad (2.29)$$

其中最后的等式利用式(2.21)可容易验证。将式(2.27)合并到式(2.29), 我们得到对任意半正定对称阵

$$\lim_{k \rightarrow \infty} P_k(P_0) = P.$$

解的唯一性 若 $\tilde{P}$ 是式(2.14)的另一个半正定解, 那么对所有 $k=0, 1, \dots$, 我们有 $P_k(\tilde{P}) = \tilde{P}$ 。由刚才证明的收敛性结果, 还有

$$\lim_{k \rightarrow \infty} P_k(\tilde{P}) = P,$$

从而有

$$\tilde{P} = P.$$

证毕。

前面命题的假设可以在一定程度上放松。假定 (A, B) 对不必能控, 而假定系统是可镇定的。其含义是存在一个 $m \times n$ 的反馈增益阵 G , 使矩阵 $(A + BG)$ 稳定。那么以前给出的 $P_k(0)$ 收敛到某个半正定阵 P 的证明仍成立。[我们利用平稳控制律 $\mu(x) = Gx$, 对于这个控制律, $(A + BG)$ 是稳定的, 以保证 $x_0' P_k(0) x_0$ 有界。]假定 (A, C) 对不必能观, 而假定系统是能检测的, 即当 $u_k \rightarrow 0$, 且 $Cx_k \rightarrow 0$ 时, A 使得 $x_k \rightarrow 0$ 。(这实质上意味着通过观察量测序列 $\{z_k\}$, 且 $z_k = Cx_k$, 系统的不稳定性可以检测出来。)这样, 方程式(2.24)说明 $x_k \rightarrow 0$, 且矩阵 $D = A + BL$ 是稳定的。除了 P 的正定性不能保证之外, 命题证明的其它部分是一样的。(作为例子, 取 $A = 0, B = 0, C = 0, R > 0$, 那么可镇定性及能检测性假定条件满足, 但 $P = 0$ 。)总之, 若命题的能控性和能观性假设由前述可镇定性及能检测性来代替, 除了极限矩阵 P 的正定性之外, 命题的结论仍有效, 现在只能保证 P 为半正定。

随机系统矩阵

现在我们考虑更一般的情况, $\{A_0, B_0\}, \{A_1, B_1\}, \dots, \{A_{N-1}, B_{N-1}\}$ 未知, 而只知它们是独立随机矩阵, 且与 $w_0, w_1, \dots, w_{N-1}$ 无关。它们的概率分布给定, 并假定有有限的二次矩。把三元组 (A_k, B_k, w_k) 考虑为各时刻 k 的扰动, 这个问题也属于基本问题的范畴, DP算法写成

$$J_N(x_N) = x_N' Q_N x_N,$$

$$J_k(x_k) = \min_{u_k, w_k, A_k, B_k} E \{ x_k' Q_k x_k + u_k' R_k u_k + J_{k+1}(A_k x_k + B_k u_k + w_k) \}.$$

计算非常类似于 A_k, B_k 为非随机矩阵的情况, 它表明最优控制律具有如下形式

$$\mu_k^*(x_k) = L_k x_k, \quad (2.30)$$

式中增益矩阵 L_k 给定为

$$L_k = -[R_k + E\{B_k' K_{k+1} B_k\}]^{-1} E\{B_k' K_{k+1} A_k\}, \quad (2.31)$$

其中矩阵 K_k 由如下递推方程给出:

$$K_N = R_N, \quad (2.32)$$

$$K_k = E\{A_k' K_{k+1} A_k\} - E\{A_k' K_{k+1} B_k\} [R_k + E\{B_k' K_{k+1} B_k\}]^{-1} \times E\{B_k' K_{k+1} A_k\} + Q_k. \quad (2.33)$$

让我们观察一下有关二次代价的本质来结束这一节。考虑对 u 使如下二次形式的代价为极小

$$E\{(ax + bu + w)^2\},$$

式中 a, b 为给定标量, w 是随机变量。达到最优值是

$$u^* = -\left(\frac{a}{b}\right)x - \left(\frac{1}{b}\right)E\{w\}.$$

于是, u^* 仅通过均值 $E\{w\}$ 而依赖于 w 的概率分布。特别是, 优化结果与 $E\{w\}$ 代替 w 相应的确定性问题相同。这个性质称之为确定性等价原理, 并以不同的形式出现在许多(但不是全部)涉及线性系统和二次代价的随机控制问题中。对本节的第一个问题(A_k, B_k 为已知), 确定性等价原理表现为如下事实: 控制律式(2.3)与相应确定性问题得出的控制律相同, 在该确定性问题中, w_k 不是一个随机变量, 而是已知的, 且等于零(其期望值)。然而, 对 A_k

和 B_k 为随机的问題，确定性等价原理不再成立，因为在方程(2.33)中用其期望值代替 A_k , B_k , 所得控制律未必是最优的。

§ 2.2 库存控制

现在我们考虑 § 1.1 和 § 1.2 的库存控制问题。假定在每个周期，超额的需求被拖欠，当另有存货时则予以满足要求。这可在系统方程

$$x_{k+1} = x_k + u_k - w_k, \quad k=0, 1, \dots, N-1.$$

中用负存货量来表示。我们还假定逐次需求 w_k 有界且独立；在第 N 个周期末拖欠需求(未供货)就是损失；而且在第 N 个周期末库存积余价值为零。在这些条件下，求极小的总期望代价由如下表达式给出

$$E_{w_k} \left\{ \sum_{k=0}^{N-1} [cu_k + p \max(0, -x_{k+1}) + h \max(0, x_{k+1})] \right\},$$

$k=0, \dots, N-1$

或者利用系统方程

$$E_{w_k} \left\{ \sum_{k=0}^{N-1} [cu_k + p \max(0, w_k - x_k - u_k) + h \max(0, x_k + u_k - w_k)] \right\}.$$

$k=0, \dots, N-1$

(如 § 1.1 讨论的那样，也可以用更一般的代价函数。)。我们假定 $c > 0$, $h \geq 0$, $p > c$ 。为了使问题适定，这个假定是必须的，下面将会看清这一点。

应用 DP 算法，我们有

$$J_N(x_N) = 0 \quad (2.34)$$

$$J_k(x_k) = \min_{u_k \geq 0} [cu_k + L(x_k + u_k) + E\{J_{k+1}(x_k + u_k - w_k)\}], \quad (2.35)$$

式中函数 L 定义为

$$L(y) = pE\{\max(0, w_k - y)\} + hE\{\max(0, y - w_k)\}.$$

实际上，只要 w_k 的概率分布依赖于 k , L 就依赖于 k 。为简化标记，我们不去证明这个依赖关系，而假定所有需求均为恒定分布。

引入变量 $y_k = x_k + u_k$, 可以把式(2.35)的右边写成

$$\min_{y_k \geq x_k} [cy_k + L(y_k) + E\{J_{k+1}(y_k - w_k)\}] - cx_k.$$

函数 L 可以看成是凸的。我们将马上证明 J_{k+1} 也是凸的，但现在我们认定它成立。这样，括号内的函数是凸的。假设这个函数有一极小值 S_k , 可以看出(根据约束 $y_k \geq x_k$)：若 $x_k \geq S_k$, y_k 的极小等于 x_k ；否则等于 S_k 。利用方程 $u_k = y_k - x_k$, 我们看到，在这些条件下，最优策略由一标量序列 $\{S_0, S_1, \dots, S_{N-1}\}$ 确定，并具有如下形式

$$\mu_k^*(x_k) = \begin{cases} S_k - x_k, & \text{若 } x_k < S_k, \\ 0, & \text{若 } x_k \geq S_k. \end{cases} \quad (2.36)$$

对每个 k , 标量 S_k 使以下函数极小

$$G_k(y) = cy + L(y) + E\{J_{k+1}(y - w)\}. \quad (2.37)$$

通过证明余留代价函数 J_k [因此还有式(2.37)的函数 G_k] 是凸函数，而且 $\lim_{|y| \rightarrow \infty} G_k(y) = \infty$ 。可以证明式(2.36)策略的最优性，以及极小的标量 S_k 存在。现在我们归纳证明这些




图 2.2 当固定代价为零时, 余留代价函数的结构

性质。

已知 J_N 是凸函数[参阅方程(2.34)]。因为 $L(y)$ 的导数当 $y \rightarrow -\infty$ 时趋于 $-p$, 且 $c < p$ 。我们看到当 $y \rightarrow -\infty$ 和 $y \rightarrow \infty$ 时, $G_{N-1}(y) (= cy + L(y))$ 的导数分别为负和正(见图 2.2)。所以 $\lim_{|y| \rightarrow \infty} G_{N-1}(y) = \infty$ 。在时刻 $N-1$, 最优策略由下式给出

$$\mu_{N-1}^*(x_{N-1}) = \begin{cases} S_{N-1} - x_{N-1}, & \text{若 } x_{N-1} < S_{N-1}, \\ 0, & \text{若 } x_{N-1} \geq S_{N-1}. \end{cases}$$

进而, 由 DP 方程(2.35), 有

$$J_{N-1}(x_{N-1}) = \begin{cases} c(S_{N-1} - x_{N-1}) + L(S_{N-1}), & \text{若 } x_{N-1} < S_{N-1}, \\ L(x_{N-1}), & \text{若 } x_{N-1} \geq S_{N-1}. \end{cases}$$

根据 L 的凸性, 以及 S_{N-1} 使 $cy + L(y)$ 极小(见图 2.2)的事实, J_{N-1} 是一个凸函数。因此, 给定 J_N 的凸性, 就能证明 J_{N-1} 的凸性。而且 $\lim_{|y| \rightarrow \infty} J_{N-1}(y) = \infty$

类似地, 对 $k = N-2, \dots, 0$, 可以看出 $\lim_{|y| \rightarrow \infty} G(y) = \infty$ 。因为 $c < p$, 且 $\lim_{|y| \rightarrow \infty} J_{k+1}(y) = \infty$ 。我们有

$$J_k(x_k) = \begin{cases} c(S_k - x_k) + L(S_k) + E\{J_{k+1}(S_k - w_k)\}, & \text{若 } x_k < S_k, \\ L(x_k) + E\{J_{k+1}(x_k - w_k)\}, & \text{若 } x_k \geq S_k, \end{cases}$$

式中 S_k 使 $cy + L(y) + E\{J_{k+1}(y - w)\}$ 为极小。我们再一次有 $\lim_{|y| \rightarrow \infty} J_k(y) = \infty$, 而且 J_{k+1} 的凸性(这隐含 $E\{J_{k+1}(x - w)\}$ 的凸性)表明 J_k 的凸性。策略式(2.36)的最优性证明完成。

正的固定代价

现在我们转到更复杂的情况,即存在一个与正的库存订购量有关的非零固定代价 $K > 0$ 。这里,订购存货 $u \geq 0$ 的费用为

$$C(u) = \begin{cases} K + cu, & u > 0, \\ 0, & u = 0. \end{cases}$$

DP 算法取如下形式

$$\begin{aligned} J_N(x_N) &= 0, \\ J_k(x_k) &= \min_{u_k \geq 0} [C(u_k) + L(x_k + u_k) + E\{J_{k+1}(x_k + u_k - w_k)\}], \end{aligned}$$

式中 L 定义如前为

$$L(y) = pE\{\max(0, w - y)\} + hE\{\max(0, y - w)\}.$$

再考虑函数 G_k :

$$G_k(y) = cy + L(y) + E\{J_{k+1}(y - w)\}. \quad (2.38)$$

如果我们能证明函数 G_k 是凸的,那么就很容易验证 (s, S) 类型的策略

$$\mu_k^*(x_k) = \begin{cases} S_k - x_k, & \text{若 } x_k < s_k, \\ 0, & \text{若 } x_k \geq \tilde{s}_k, \end{cases} \quad (2.39)$$

为最优,式中 S_k 是 y 的一个值,它使 $G_k(y)$ 极小。 s_k 是 y 的最小值。对此 y , $G_k(y) = K + G_k(S_k)$ 。遗憾的是,当 $K > 0$ 时, J_k 或 G_k 是凸函数的假设并不一定成立。函数 $G_k(y)$ 有可能具有如图 2.3 所示的形式。对于这种情况,最优策略是在区间 I 订购 $(S - x)$, 在区间 II 和 IV 订货为零,在区间 III 为 $(\tilde{S} - x)$ 。然而,我们将证明,即使函数 G_k 非凸,它们具有以下性质

$$\begin{aligned} K + G_k(z + y) &\geq G_k(y) + z \left[\frac{G_k(y) - G_k(y - b)}{b} \right], \\ &\text{对所有 } z \geq 0, b > 0, y. \end{aligned} \quad (2.40)$$

这个性质称为 K -凸性, Scarf 首先利用它来证明多周期 (s, S) 策略的最优性[S5]。现在,如




图 2.3 当固定代价非零时, 函数 G_k 的潜在形式

果式(2.40)成立,则图 2.3 所示情况是不可能的,因为如果 y_0 是区间 III 中局部极大值,那么,对足够小的 $b > 0$, 必有

$$\frac{G_k(y_0) - G_k(y_0 - b)}{b} \geq 0,$$

且由式(2.40)得出

$$K + G_k(\tilde{S}) \geq G_k(y_0),$$

它与图 2.3 所示结构相矛盾。更一般地, 利用下述引理的 d 部分容易证明: 若式(2.40)成立, 则最优策略具有式(2.39)的形式。

定义 如果

$$K + g(z + y) \geq g(y) + z \left[\frac{g(y) - g(y - b)}{b} \right], \quad \text{对所有 } z \geq 0, b > 0, y.$$

我们就说函数 $g: R \rightarrow R$ 是 K -凸的, 其中 $K \geq 0$ 。

在如下引理中提供了 K -凸函数的某些性质。引理的最后部分主要是证明当 G_k 满足式(2.40)时, (s, S) 策略式(2.39)的最优性。

引理

(a) 一个凸函数 $g: R \rightarrow R$ 也是 0-凸, 因此对所有 $K \geq 0$ 也是 K -凸的。

(b) 若 $g_1(y)$ 和 $g_2(y)$ 分别为 K -凸和 L -凸的 ($K \geq 0, L \geq 0$), 那么, 对所有正 α 和 β , $\alpha g_1(y) + \beta g_2(y)$ 为 $(\alpha K + \beta L)$ -凸的。

(c) 若 $g(y)$ 是 K -凸的, 那么对所有 y , 只要 $E_w\{|g(y - w)|\} < \infty$, 则 $E_w\{|g(y - w)|\}$ 也是 K -凸的。

(d) 若 $g: R \rightarrow R$ 是一个连续 K -凸函数, 且当 $|y| \rightarrow \infty$ 时 $g(y) \rightarrow \infty$, 则存在标量 s 和 S , 且 $s \leq S$, 使得

- i) 对所有 $y \in R$, $g(S) \leq g(y)$;
- ii) $g(S) + K = g(s) < g(y)$, 对所有 $y < s$;
- iii) $g(y)$ 是 $(-\infty, s)$ 区间上的递减函数;
- iv) $g(y) \leq g(z) + K$, 对所有 $y, z, s \leq y \leq z$ 。

证明: (a) 部分是由凸函数的基本性质得出, (b) 和 (c) 直接由 K -凸函数的定义得出。我们集中证明 (d) 部分。

因为 g 是连续的, 且当 $|y| \rightarrow \infty$ 时 $g(y) \rightarrow \infty$, 所以存在一个 g 的极小点。令 S 为这样一个点。再令 s 为满足 $z \leq S$, $g(S) + K = g(z)$ 的最小标量 z 。对所有 y , 且 $y < s$, 我们由 K -凸性的定义, 有

$$K + g(S) \geq g(s) + \frac{S - s}{s - y} [g(s) - g(y)].$$

因为 $K + g(S) - g(s) = 0$, 得 $g(s) - g(y) \leq 0$ 。因为 $y < s$, 且 s 是满足 $g(S) + K = g(s)$ 的最小标量, 必有 $g(s) < g(y)$, 这就证明了 (ii)。现在对 $y_1 < y_2 < s$, 我们有

$$K + g(S) \geq g(y_2) + \frac{S - y_2}{y_2 - y_1} [g(y_2) - g(y_1)].$$

又由 (ii),

$$g(y_2) > g(S) + K = g(s),$$

将这两个不等式加起来得

$$0 > \frac{S - y_2}{y_2 - y_1} [g(y_2) - g(y_1)],$$

由此得 $g(y_1) > g(y_2)$ 。于是证明了(iii)。为了证明(iv)，我们注意到，对 $y = z$ 以及对 $y = S$ ，或 $y = s$ ，(iv)成立。留下两种可能性： $S < y < z$ 和 $s < y < S$ 。如果 $S < y < z$ ，那么由 K -凸性

$$K + g(z) \geq g(y) + \frac{z-y}{y-S} [g(y) - g(S)] \geq g(y),$$

于是(iv)得证。如果 $s < y < S$ ，则由 K -凸性

$$g(s) = K + g(S) \geq g(y) + \frac{S-y}{y-s} [g(y) - g(s)],$$

由此得

$$\left[1 + \frac{S-y}{y-s}\right] g(s) \geq \left[1 + \frac{S-y}{y-s}\right] g(y),$$

和 $g(s) \geq g(y)$ 。注意

$$g(z) + K \geq g(S) + K = g(s),$$

从而得 $g(z) + K \geq g(y)$ 。这样，对此情况也证明了(iv)。证毕。

现在考虑式(2.38)函数 G_{N-1} ：

$$G_{N-1}(y) = cy + L(y).$$

显然， G_{N-1} 是凸的。因此由上述引理的(a)部分，它也是 K -凸的。从 $K=0$ 情况分析，有

$$J_{N-1}(x) = \begin{cases} K + G_{N-1}(S_{N-1}) - cx, & \text{对 } x < S_{N-1}, \\ G_{N-1}(x) - cx, & \text{对 } x \geq S_{N-1}, \end{cases} \quad (2.41)$$

式中 S_{N-1} 使 $G_{N-1}(y)$ 极小，而 s_{N-1} 是使 $G_{N-1}(y) = K + G_{N-1}(S_{N-1})$ 成立 y 的最小值。注意，因为 $K > 0$ ，我们有 $s_{N-1} \neq S_{N-1}$ ，而且在 s_{N-1} 点上 G_{N-1} 的斜率为负。结果，在 s_{N-1} 上 J_{N-1} 的左边斜率大于右边斜率(如图 2.4 所示)，且 J_{N-1} 非凸。然而我们将根据 G_{N-1} 是 K -凸的，证明 J_{N-1} 也是 K -凸的。为此，必须验证

$$K + J_{N-1}(y+z) \geq J_{N-1}(y) + z \left[\frac{J_{N-1}(y) - J_{N-1}(y-b)}{b} \right],$$

对所有 $z \geq 0, b > 0, y$ 。 (2.42)

我们区别三种情况：

情况 1 $y \geq s_{N-1}$ 若 $y-b \geq s_{N-1}$ ，那么在 z, b, y 值的区域内，根据式(2.41)，函数 J_{N-1} 是 K -凸函数之和，并是一个线性函数。因此，由引理中(b)，它是 K -凸的，且式(2.42)成立。若 $y-b < s_{N-1}$ ，那么根据式(2.41)，我们可把式(2.42)写成

$$\begin{aligned} & K + G_{N-1}(y+z) - c(y+z) \\ & \geq G_{N-1}(y) - cy + z \left[\frac{G_{N-1}(y) - cy - G_{N-1}(s_{N-1}) + c(y-b)}{b} \right], \end{aligned}$$

或等效地




图 2.4 当固定代价非零时，余留代价函数的结构

$$K + G_{N-1}(y+z) \geq G_{N-1}(y) + z \left[\frac{G_{N-1}(y) - G_{N-1}(s_{N-1})}{b} \right]. \quad (2.43)$$

现在, 如果 y 使得 $G_{N-1}(y) \geq G_{N-1}(s_{N-1})$, 则按 G_{N-1} 的 K -凸性, 有

$$\begin{aligned} K + G_{N-1}(y+z) &\geq G_{N-1}(y) + z \left[\frac{G_{N-1}(y) - G_{N-1}(s_{N-1})}{y - s_{N-1}} \right] \\ &\geq G_{N-1}(y) + z \left[\frac{G_{N-1}(y) - G_{N-1}(s_{N-1})}{b} \right]. \end{aligned}$$

这样, 式(2.43)成立, 因此式(2.42)也成立。如果 y 使得 $G_{N-1}(y) < G_{N-1}(s_{N-1})$, 那么有

$$\begin{aligned} K + G_{N-1}(y+z) &\geq K + G_{N-1}(s_{N-1}) = G_{N-1}(s_{N-1}) > G_{N-1}(y) \\ &\geq G_{N-1}(y) + z \left[\frac{G_{N-1}(y) - G_{N-1}(s_{N-1})}{b} \right]. \end{aligned}$$

所以对这种情况式(2.43)成立, 由此式(2.42)也成立。

情况 2 $y \leq y+z \leq s_{N-1}$ 。在这个区域, 由式(2.41), 函数 J_{N-1} 是线性的, 因而式(2.42)成立。

情况 3 $y < s_{N-1} < y+z$ 。对这种情况, 根据式(2.41), 可以把式(2.42)写成

$$\begin{aligned} K + G_{N-1}(y+z) - c(y+z) \\ \geq G_{N-1}(s_{N-1}) - cy + z \left[\frac{G_{N-1}(s_{N-1}) - cy - G_{N-1}(s_{N-1}) + c(y-b)}{b} \right], \end{aligned}$$

或等效地

$$K + G_{N-1}(y+z) \geq G_{N-1}(s_{N-1}),$$

由 s_{N-1} 的定义, 此式成立。

这样, 我们已证明 G_{N-1} 的 K -凸性和连续性, 连同 $|y| \rightarrow \infty$ 时 $G_{N-1}(y) \rightarrow \infty$ 这个事实, 说明了 J_{N-1} 的 K -凸性。此外, J_{N-1} 可以看成是连续的。现在利用引理, 由式(2.38)得出 G_{N-2} 是一个 K -凸函数。进而利用 w_{N-2} 的有界性, 得出 G_{N-2} 是连续的, 而且当 $|y| \rightarrow \infty$ 时, $G_{N-2}(y) \rightarrow \infty$ 。重复前面的论证, 得到 J_{N-2} 是 K -凸的。类似地进行, 我们证明了对所有 k , 函数 G_k 为 K -凸和连续的, 并且当 $|y| \rightarrow \infty$ 时, $G_k(y) \rightarrow \infty$ 。同时[利用引理的(d)], 我们证明了式(2.39)多周期策略 (s, S) 的最优性。

对其它几个库存问题(见习题 3 到 6 和 14 到 17), 可以证明 (s, S) 类型策略的最优性。

§ 2.3 动态证券分析

证券交易理论处理如何在资产的集合中将一定数量的财产进行投资的问题。通常这个问题由均方差公式来处理[M4, S18]。据此, 假定投资者使一个效用函数的期望值极大, 该效用函数取决于投资回收率的均值和方差。另一种方法是本节要讨论的, 假设投资者在几个时间周期决策, 其目标使最后财产最大。我们以分析单周期模型开始, 然后把结果推广到多周期情况。

令 x_0 表示投资者的初始财产(以货币单位计量), 并假定有 n 种风险资产, 它与随机回收率 $e_1, e_2, \dots, e_n$ 相对应。投资者在这几种风险资产中可以分配其财产。投资者也可以投资于提供确定回收率 s 的无风险资产。若用 $u_1, \dots, u_n$ 表示投资于 n 种风险资产的相应

数额, 用 $(x_0 - u_1 - \cdots - u_n)$ 表示投资在无风险资产的数额, 最后财产由下式表示

$$x_1 = s(x_0 - u_1 - \cdots - u_n) + \sum_{i=1}^n e_i u_i,$$

或等价地

$$x_1 = sx_0 + \sum_{i=1}^n (e_i - s)u_i. \quad (2.44)$$

目标是对 $u_1, \cdots, u_n$, 使

$$E\{U(x_1)\},$$

极大。式中 U 是投资者的效用函数。我们假定对所有 x_0, u_i , 期望值适当定义且有限。 U 是凹的且二次连续可微。对 $u_1, \cdots, u_n$ 并不加约束。为了得到简单形式的结果, 这些假定是必须的。以后再加上少数几个附加假定。

让我们对每一个初始财产值来考虑上述问题, 用 $u_i^* = \mu^{i*}(x_0)$, $i = 1, \cdots, n$ 表示在初始财产为 x_0 时, 投资在 n 种风险资产的最优数额。

如果

$$\mu^{i*}(x_0) = \alpha^i h(x_0), \quad i = 1, \cdots, n, \quad (2.45)$$

式中 α^i , $i = 1, \cdots, n$ 是固定常数, $h(x_0)$ 是 x_0 的函数(对所有 i 是相同的), 那么我们说有价证券 $\{\mu^{1*}(x_0), \cdots, \mu^{n*}(x_0)\}$ 是部分地分离的。

当部份分离成立, 投资在 n 种风险资产的数额比率固定, 并与初始财产无关; 即

$$\frac{\mu^{i*}(x_0)}{\mu^{j*}(x_0)} = \frac{\alpha^i}{\alpha^j}, \quad \text{对 } 1 \leq i, j \leq n, \alpha^i \neq 0.$$

实际上, 在这种情况下, 当部份分离成立时, 我们将证明有价证券 $\{\mu^{1*}(x_0), \cdots, \mu^{n*}(x_0)\}$ 是由 x_0 的仿射函数(线性加常数)组成, 具有如下形式

$$\mu^{i*}(x_0) = \alpha^i [a + bsx_0], \quad i = 1, \cdots, n. \quad (2.46)$$

式中 a 和 b 是表征效用函数 U 的常数。在式(2.46)中 $a = 0$ 的特殊情况下, 我们说最优有价证券是完全分离的, 即意味着投资在风险资产和无风险资产的数额比是固定的, 并与初始财产无关。

现在我们说明, 当效用函数满足

$$-\frac{U'(x_1)}{U''(x_1)} = a + bx_1, \quad \text{对所有 } x_1. \quad (2.47)$$

时, 式中 U' 和 U'' 分别表示 U 的一阶和二阶导数, a 和 b 为某些标量, 那么最优有价证券由式(2.46)给出。而且, 若 $J(x_0)$ 是问题的最优值

$$J(x_0) = \max_{u_i} E\{U(x_1)\}, \quad (2.48)$$

则有

$$-\frac{J'(x_0)}{J''(x_0)} = \frac{a}{s} + bx_0, \quad \text{对所有 } x_0. \quad (2.49)$$

我们假定, 最优有价证券存在, 并有如下形式

$$\mu^{i*}(x_0) = \alpha^i(x_0)[a + bsx_0],$$

式中 $\alpha^i(x_0)$, $i=1, \dots, n$ 是某些可微函数。我们将证明, 对所有 x_0 , $d\alpha^i(x_0)/dx_0=0$, 而函数 α^i 必为常数。

由 $\mu^*(x_0)$ 的最优性, $i=1, \dots, n$, 对每一个 x_0 , 我们有

$$\frac{dE\{U(x_1)\}}{du_i} = E\left\{U' \left[sx_0 + \sum_{i=1}^n (e_i - s)\alpha^i(x_0)(a + bsx_0) \right] (e_i - s) \right\} = 0. \quad (2.50)$$

将式(2.50)的 n 个方程对 x_0 求导, 得

$$E \left\{ \begin{pmatrix} (e_1 - s)^2 \cdots (e_1 - s)(e_n - s) \\ \vdots \\ (e_n - s)(e_1 - s) \cdots (e_n - s)^2 \end{pmatrix} U''(x_1)(a + bsx_0) \right\} \begin{pmatrix} \frac{d\alpha^1(x_0)}{dx_0} \\ \vdots \\ \frac{d\alpha^n(x_0)}{dx_0} \end{pmatrix} \quad (2.51)$$

$$= - \begin{pmatrix} E\left\{ U''(x_1)(e_1 - s)s \left[1 + \sum_{i=1}^n (e_i - s)\alpha^i(x_0)b \right] \right\} \\ \vdots \\ E\left\{ U''(x_1)(e_n - s)s \left[1 + \sum_{i=1}^n (e_i - s)\alpha^i(x_0)b \right] \right\} \end{pmatrix}.$$

利用关系式(2.47), 我们有

$$U''(x_1) = - \frac{U'(x_1)}{a + b \left[sx_0 + \sum_{i=1}^n (e_i - s)\alpha^i(x_0)(a + bsx_0) \right]} \quad (2.52)$$

$$= - \frac{U'(x_1)}{(a + bsx_0) \left[1 + \sum_{i=1}^n (e_i - s)\alpha^i(x_0)b \right]}.$$

代入式(2.50)并利用式(2.51), 我们得到式(2.51)的右边是零向量。式(2.51)左边的矩阵, 除了蜕化情况外, 可以被证明为非奇异。假定它确是非奇异的, 我们得到

$$\frac{d\alpha^i(x_0)}{dx_0} = 0, \quad i=1, \dots, n,$$

及 $\alpha^i(x_0) = \alpha^i$, 其中 α^i 是某一常数。这样就证明了式(2.46)。

现在我们把注意力放到证明关系式(2.49)。我们有

$$J(x_0) = E\{U(x_1)\} = E\left\{ U \left[s \left[1 + \sum_{i=1}^n (e_i - s)\alpha^i b \right] x_0 + \sum_{i=1}^n (e_i - s)\alpha^i a \right] \right\},$$

由此

$$J'(x_0) = E\left\{ U'(x_1) s \left[1 + \sum_{i=1}^n (e_i - s)\alpha^i b \right] \right\}, \quad (2.53)$$

$$J''(x_0) = E\left\{ U''(x_1) s^2 \left[1 + \sum_{i=1}^n (e_i - s)\alpha^i b \right]^2 \right\}.$$

作某些计算之后, 并利用式(2.52), 最后关系得

$$J''(x_0) = - \frac{E\left\{U'(x_1)s\left[1 + \sum_{i=1}^n (e_i - s)\alpha^i b\right]\right\}s}{a + bsx_0}. \quad (2.54)$$

将式(2.53)和式(2.54)结合, 就得到所需结果:

$$-\frac{J'(x_0)}{J''(x_0)} = \frac{a}{s} + bx_0.$$

可以证明, 下面的效用函数满足这个条件

$$\begin{aligned} \text{指数函数: } & -e^{-x/a}, & \text{对 } b=0, \\ \text{对数函数: } & \ln(x+a), & \text{对 } b=1, \\ \text{幂函数: } & [1/(b-1)](a+bx)^{1-(1/b)}, & \text{其它情况.} \end{aligned} \quad (2.55)$$

自然, 在我们的问题中, 只允许有这类凹的效用函数, 而且, 如果采用一个不是定义在整个实线上的效用函数, 则问题必须按某一种方法来建立, 以保证最终财产的所有可能值均处在效用函数的定义域之内。

现在容易将上面分析的单周期结果推广到多周期情况。我们假定, 在 N 个相继时间周期的每个周期开始时刻, 当前的财产均可再投资。我们记

- x_k 第 k 周期开始时, 投资者的财产,
 - u_i^k 第 k 周期开始时, 投资在第 i 个风险资产的数额,
 - e_i^k 第 k 周期之间, 无风险投资的回收率。
- (按单周期模型)我们有系统方程

$$x_{k+1} = s_k x_k + \sum_{i=1}^n (e_i^k - s_k) u_i^k, \quad k=0, 1, \dots, N-1. \quad (2.56)$$

假定向量 $e^k = (e_1^k, \dots, e_n^k)$, $k=0, \dots, N-1$, 均是独立的, 具有给定的概率分布, 通过以下分析, 得到有限的期望值。

目标是使终点财产 x_N 的期望效用值 $E\{U(x_N)\}$ 极大。这里我们假定对所有 x , U 满足

$$-\frac{U'(x)}{U''(x)} = a + bx.$$

用 DP 算法应用于这个问题, 有

$$J_N(x_N) = U(x_N), \quad (2.57)$$

$$J_k(x_k) = \max_{u_1^k, \dots, u_n^k} E\left\{J_{k+1}\left[s_k x_k + \sum_{i=1}^n (e_i^k - s_k) u_i^k\right]\right\}. \quad (2.58)$$

由单周期问题的解, 我们有周期 $N-1$ 开始时的最优策略, 其形式为

$$\mu_{N-1}^*(x_{N-1}) = \alpha_{N-1} [a + bs_{N-1} x_{N-1}],$$

式中 α_{N-1} 是一个适当的 n 维向量; 且有

$$-\frac{J'_{N-1}(x)}{J''_{N-1}(x)} = \frac{a}{s_{N-1}} + bx. \quad (2.59)$$

因此把式(2.58)中本节的结果用于倒数的第二个周期, 得到最优策略

$$\mu_{N-2}^*(x_{N-2}) = \alpha_{N-2} \left(\frac{a}{s_{N-1}} + bs_{N-2} x_{N-2} \right),$$

式中 α_{N-2} 也是一个适当的 n 维向量。

同样地运行下去, 对第 k 周期, 有

$$\mu_k^*(x_k) = \alpha_k \left(\frac{a}{s_{N-1} \cdots s_{k+1}} + b s_k x_k \right), \quad (2.60)$$

式中 α_k , $k=0, 1, \dots, N-1$ 都是 n 维向量, 依赖于风险资产回收率 e_i^k 的概率分布, 并由最优余留代价函数 J_k 期望值的最优化所决定。这些函数满足

$$-\frac{J'_k(x)}{J''_k(x)} = \frac{a}{s_{N-1} \cdots s_k} + b x, \quad k=0, 1, \dots, N-1. \quad (2.61)$$

这样, 可以看到当投资者面临其财产有机会不断地再投资时, 他采取与单周期情况类似的一个策略。把分析再推进一步, 可以看到, 若效用函数中 $a=0$, 即 U 具有如下形式之一

$$\ln x, \text{ 对 } b=1,$$

$$\left(\frac{1}{b-1} \right) (bx)^{1-(1/b)}, \text{ 对 } b \neq 0, b \neq 1,$$

则由式(2.60)得出, 在每一阶段, 投资者的行动好象他面临一个单周期的投资, 后者是由回收率 s_k , e_i^k , $i=1, \dots, n$ 和目标函数 $E\{U(x_{k+1})\}$ 来表征。这种投资者可忽视其财产有再投资机会的策略, 它称之为无远见策略(myopic policy)[M10]。

注意, 当对所有 k , $s_k=1$ 时, 无远见策略也是一个最优策略, 它意味财产按无风险资产的回收率而折价。而且可以证明, 当 $a=0$ 时, 甚至在回收率 s_k 为独立随机变量的更一般的情况下[M10], 和在投资过程中对风险资产回收率的概率分布可以预测的情况下, 一个无远见策略也是最优的。(见习题 7)。

现在转到更一般的情况, 其中 $a \neq 0$ 。对决策者那方面只要求有少许的预见。可以看出(把式(2.58)与式(2.61)比较), 在周期 k , 最优策略式(2.60)如同投资者面临单周期问题所采用的策略一样, 他将对 u_i^k , $i=1, \dots, n$, 使

$$E\{U(s_{N-1} \cdots s_{k+1} x_{k+1})\}$$

极大, 并受 $x_{k+1} = s_k x_k + \sum_{i=1}^n (e_i^k - s_k) u_i^k$ 的约束。换句话说, 投资者使财产的期望效用为极大。如果第 k 个周期 u_i^k 投资于风险资产, 且所产生的财产 x_{k+1} 在其余周期 $k+1, \dots, N-1$, 无例外地相继投资于无风险资产就造成此结果。这就是所谓部分无远见策略[M10]。在投资过程中, 当风险资产的回收率的概率分布可以预测时, 这种策略也可以证明是最优的(见习题 7)。

在 $a \neq 0$ 情况下另一个令人感兴趣的方面是: 对所有 k , 当 $s_k > 1$ 时, 则当时域增长时 ($N \rightarrow \infty$), 初始阶段的策略趋于一个无远见策略[比较式(2.60)和式(2.61)]。这样, 我们可以得出结论: 对 $s_k > 1$, 当时域趋于无限时, 部分无远见策略渐近于一个无远见策略。

§ 2.4 最优停止问题

本节和下面几节所要考虑的一类最优停止问题是由每个状态, 使系统演变停止的控制可用性来表征。因此, 每阶段控制器观察系统的当前状态, 决定是否继续过程(或许以一定的代价)或停止过程, 并由此造成某些损失。

资产出售问题

作为第一个例子,考虑一个拥有一宗资产(譬如一片土地)的人。为此,有人周期性地向他出价一定数额的货币。我们假定这些随机性的出价 $w_0, w_1, \dots, w_{N-1}$ 是独立恒定分布的,并取值于某个有界区间。我们考虑一个 N 阶段时域问题。假定此人接受这个出价,他可以按固定的利率 $r > 0$ 将此货币投资;如果他拒受这个出价,他就要等到下一周期考虑下一个出价。所拒受的出价不能重提。我们假定如果以前每一出价已经拒绝接受,最后一次出价 w_{N-1} 必须接受。目标是寻求一个接受和拒绝出价的策略,使得在第 N 周期此人的收益最大。

用基本推理的方法可以为此问题导出 DP 算法。作为一个建模的练习,我们将试图通过定义状态空间、控制空间、扰动空间、系统方程和代价泛函,把此问题纳入基本问题的框架。我们把在时刻 k 的随机出价 w_k 看作扰动,而相应的扰动空间是实线。控制空间由两个元 u^1, u^2 组成,它们相应于决策“出售”和“不出售”。我们把状态空间定义为实线,用一个附加的终止状态(称其为 T)来增广。一旦资产出售,系统的运动进入终态。在时刻 k ,系统状态写成 $x_k \neq T$,这意味资产还未出售,且当前所考虑的出价等于 x_k 。在时刻 k ,系统写成处于状态 $x_k = T$,意味资产已经出售。按这些约定,可将系统方程写成如下形式

$$\begin{aligned} x_{k+1} &= f_k(x_k, u_k, w_k), \quad k=0, \dots, N-1, \\ x_0 &= 0, \end{aligned}$$

式中 $x_k \in R \cup \{T\}$, 函数 f_k 由以下关系来定义

$$x_{k+1} = \begin{cases} T, & \text{若 } u_k = u^1(\text{出售}) \text{ 或 } x_k = T, \\ w_k, & \text{其它情况。} \end{cases}$$

其相应的报酬函数可以写成

$$E_{w_k} \left\{ g_N(x_N) + \sum_{k=0}^{N-1} g_k(x_k, u_k, w_k) \right\}$$

$k=0, \dots, N-1$

式中

$$\begin{aligned} g_N(x_N) &= \begin{cases} x_N, & \text{若 } x_N \neq T, \\ 0, & \text{其它情况。} \end{cases} \\ g_k(x_k, u_k, w_k) &= \begin{cases} (1+r)^{N-k} x_k, & \text{若 } x_k \neq T \text{ 且 } u_k = u^1, \\ 0, & \text{其它情况。} \end{cases} \end{aligned}$$

根据这个式子,可以写出对状态 x_k 的相应 DP 算法:

$$J_N(x_N) = \begin{cases} x_N, & \text{若 } x_N \neq T, \\ 0, & \text{若 } x_N = T, \end{cases} \quad (2.62)$$

$$J_k(x_k) = \begin{cases} \max[(1+r)^{N-k} x_k, E\{J_{k+1}(w_k)\}]; & \text{若 } x_k \neq T, \\ 0, & \text{若 } x_k = T. \end{cases} \quad (2.63)$$

在方程(2.63)中, $(1+r)^{N-k} x_k$ ($x_k \neq T$) 是当所考虑的出价为 x_k , 由决策 u^1 (出售) 所得的收益; $E\{J_{k+1}(w_k)\}$ 代表相应于决策 u^2 (不出售) 所期望的收益。

现在由 DP 算法式(2.62)和式(2.63), 我们得到 $x_k \neq T$ 情况下以下形式的最优策略:

如果 $(1+r)^{N-k} x_k > E\{J_{k+1}(w_k)\}$, 接受出价 $w_{k-1} = x_k$;

如果 $(1+r)^{N-k} x_k < E\{J_{k+1}(w_k)\}$, 拒绝接受出价 $w_{k-1} = x_k$ 。

当 $(1+r)^{N-k} x_k = E\{J_{k+1}(w_k)\}$ 时, 接受和拒绝都是最优。

作进一步分析后, 该结果可以写成更简便的形式。让我们引入函数

$$V_k(x_k) = \frac{1}{(1+r)^{N-k}} J_k(x_k), \quad x_k \neq T,$$

它表示了对最后 $N-k$ 个阶段的折扣余留代价。由式(2.62)和式(2.63)可以看到

$$V_N(x_N) = x_N, \quad (2.64)$$

$$V_k(x_k) = \max[x_k, (1+r)^{-1} E\{V_{k+1}(w_k)\}], \quad k=0, 1, \dots, N-1. \quad (2.65)$$

利用记法

$$\alpha_k = \frac{1}{1+r} E\{V_{k+1}(w_k)\},$$

最优策略由下式给出

接受出价 $w_{k-1} = x_k$, 若 $x_k > \alpha_k$,

拒绝出价 $w_{k-1} = x_k$, 若 $x_k < \alpha_k$ 。

对 $x_k = \alpha_k$, 接受和拒绝均为最优(图2.5)。

因此, 最优策略由序列 $\alpha_1, \dots, \alpha_{N-1}$ 所决定。

由算法式(2.64)和式(2.65), 我们有

$$V_k(x_k) = \begin{cases} x_k, & \text{若 } x_k > \alpha_k, \\ \alpha_k, & \text{若 } x_k < \alpha_k. \end{cases}$$

由此我们得

$$\alpha_k = \frac{1}{1+r} E\{V_{k+1}(w_k)\} = \frac{1}{1+r} \int_0^{\alpha_{k+1}} \alpha_{k+1} dP(w_k) + \frac{1}{1+r} \int_{\alpha_{k+1}}^{\infty} w_k dP(w_k).$$

式中对所有标量 λ , 函数 P 定义为:

$$P(\lambda) = \text{Prob}\{w < \lambda\}.$$

α_k 的差分方程也可以写成:

$$\alpha_k = \frac{P(\alpha_{k+1})}{1+r} \alpha_{k+1} + \frac{1}{1+r} \int_{\alpha_{k+1}}^{\infty} w_k dP(w_k), \quad k=1, \dots, N-1, \quad (2.66)$$

且 $\alpha_N = 0$ 。我们首先说明这方程的解是单调下降的(如人们所期望的那样), 即

$$\alpha_k \geq \alpha_{k+1}, \quad \text{对所有 } k. \quad (2.67)$$

确实, 由式(2.64)和式(2.65), 我们看到

$$V_{N-1}(x) \geq V_N(x), \quad \text{对所有 } x \geq 0.$$

对 $k=N-2$ 和 $k=N-1$, 应用式(2.65), 并利用上述不等式, 对所有 $x \geq 0$, 我们得到

$$\begin{aligned} V_{N-2}(x) &= \max[x, (1+r)^{-1} E_w\{V_{N-1}(w)\}] \\ &\geq \max[x, (1+r)^{-1} E_w\{V_N(w)\}] = V_{N-1}(x). \end{aligned}$$

以同样方式继续, 我们看到

$$V_k(x) \geq V_{k+1}(x), \quad \text{对所有 } x \geq 0 \text{ 和 } k.$$

因为 $\alpha_k = E\{V_{k+1}(w_k)\}/(1+r)$, 我们得式(2.67)。

现在因为

$$0 \leq \frac{P(a)}{1+r} \leq \frac{1}{1+r} < 1, \quad \text{对所有 } a \geq 0,$$




图 2.5 作为时间函数接受出价的阈值

$$0 \leq \frac{1}{1+r} \int_{x_{k+1}}^{\infty} w dP(w_k) \leq \frac{E\{w_k\}}{1+r}, \text{ 对所有 } k,$$

利用式(2.67)的单调性, 可以看出由差分方程(2.66), (向后)产生的序列 $\{\alpha_k\}$ 收敛(当 $k \rightarrow -\infty$)于一个常数 $\bar{\alpha}$, 满足

$$\bar{\alpha}(1+r) = P(\bar{\alpha})\bar{\alpha} + \int_{\bar{\alpha}}^{\infty} w dP(w).$$

当 $k \rightarrow -\infty$ 时取极限, 并利用 P 左连续这个事实, 这个方程可由式(2.66)获得。

这样, 当时域变得越来越长时(即 $N \rightarrow \infty$), 对每个固定的 $k \geq 1$, 最优策略近似于平稳策略:

$$\begin{aligned} &\text{接受出价 } w_{k-1} = x_k, && \text{若 } x_k > \bar{\alpha}, \\ &\text{拒绝接受出价 } w_{k-1} = x_k, && \text{若 } x_k < \bar{\alpha}. \end{aligned}$$

对相应的无限时域问题, 这种策略的最优性将在 § 6.1 证明。

限期采购

让我们考虑相同性质的另一个问题。假定某一时间需要一定数量的原料。如果该原料的价格是波动的, 因此就遇到要决定是否按现价采购或者再等待一个周期的问题。在这期间价格也许上升或降低。我们假定逐次的价格 w_k 是独立的, 并按 $P(w_k)$ 恒定分布。采购必须在 N 个时间周期内完成。

这个问题和前述的问题有明显的相似性。让我们用

$$x_{k+1} = w_k$$

表示在周期 $k+1$ 开始所通行的价格。与前面类似, 有 DP 算法

$$\begin{aligned} J_N(x_N) &= x_N, \\ J_k(x_k) &= \min[x_k, E\{J_{k+1}(w_k)\}], \end{aligned}$$

最优采购策略给定为

$$\begin{aligned} &\text{采购, 若 } x_k < E\{J_{k+1}(w_k)\} = \alpha_k, \\ &\text{不采购, 若 } x_k > E\{J_{k+1}(w_k)\} = \alpha_k. \end{aligned}$$

类似地, 阈值 $\alpha_1, \alpha_2, \dots, \alpha_{N-1}$, 可以由离散方程得到

$$\begin{aligned} \alpha_k &= \alpha_{k+1}[1 - P(\alpha_{k+1})] + \int_0^{\alpha_{k+1}} w dP(w), \\ \alpha_{N-1} &= \int_0^{\infty} w P(w) = E\{w\}. \end{aligned}$$

现在考虑这一问题的另一种型式。这里假定逐次价格 $w_0, \dots, w_{N-1}$ 不是独立, 而是相关的, 并可以表示为

$$w_k = x_{k+1}, \quad k = 0, 1, \dots, N-1,$$

且

$$x_{k+1} = \lambda x_k + \xi_k, \quad x_0 = 0,$$

式中 λ 是一个标量, 且 $0 \leq \lambda < 1$, 而 $\xi_0, \xi_1, \dots, \xi_{N-1}$ 是独立恒定分布的随机变量, 取给定概率分布的正值。如在 § 1.5 所讨论的, 在这些条件下, DP 算法取如下形式

$$\begin{aligned} J_N(x_N) &= x_N, \\ J_k(x_k) &= \min[x_k, E\{J_{k+1}(\lambda x_k + \xi_k)\}], \end{aligned}$$

式中与采购决策有关的代价是 x_k , 与等待决策有关的代价为 $E\{J_{k+1}(\lambda x_k + \xi_k)\}$ 。

我们将证明在这种情况下, 最优策略也具有与独立价格问题相同的形式。确实, 我们有

$$J_{N-1}(x_{N-1}) = \min[x_{N-1}, \lambda x_{N-1} + \bar{\xi}],$$

式中 $\bar{\xi} = E\{\xi_{N-1}\}$ 。如图 2.6 所示, 在时刻 $N-1$, 最优策略由下式给出


采购, 若 $x_{N-1} < a_{N-1}$,
不采购, 若 $x_{N-1} > a_{N-1}$ 。

式中 a_{N-1} 是由方程 $a_{N-1} = \lambda a_{N-1} + \bar{\xi}$ 定义, 即

$$a_{N-1} = \frac{1}{1-\lambda} \bar{\xi}.$$

注意到

$J_{N-1}(x) \leq J_N(x)$, 对所有 x ,
以及 J_{N-1} 是凹的, 且它随 x 递增。利用 DP 算法中的这个事实, 可以证明(第一章中习题 24)



$J_k(x) \leq J_{k+1}(x)$, 对所有 x 和 k , 图 2.6 当价格相关时余留代价函数 $J_{N-1}(x_{N-1})$ 的结构
 J_k 是凹的, 并对所有 k 随 x 递增。且根据对所有 k , $\bar{\xi} = E\{\xi_k\} > 0$ 的事实, 可以证明

$$E\{J_{k+1}(\xi_k)\} > 0, \quad \text{对所有 } k.$$

这些事实说明(如图 2.7 所示), 对每一个周期 k , 最优策略具有形式

采购, 若 $x_k < a_k$;
不采购, 若 $x_k > a_k$ 。




图 2.7 当价格相关时, 确定最优策略

式中获得标量 a_k , 成为方程

$$x = E\{J_{k+1}(\lambda x + \xi_k)\}.$$

唯一的正解。

注意, $J_k(x) \leq J_{k+1}(x)$, 说明

$$a_{k-1} \leq a_k \leq a_{k+1}, \quad \text{对所有 } k.$$

因此(如人们所期待的那样)阈值价格(低于此值应采购)在过程的早期阶段较低,随着限期接近而增加。

一般停止问题和一步前瞻规则

现在我们来建立在阶段 N 或 N 之前强制停止的一般类型的 N 阶段问题。考虑 § 1.1 基本问题的平稳形式(状态控制和扰动空间、扰动分布、控制约束集合,和每阶段代价对所有时间都一样)。假定在每个状态 x_k 和时间 k ,除了控制 $u_k \in U(x_k)$ 之外,有一个停止动作,迫使系统以代价 $t(x_k)$ 进入终止状态,并且接着无代价地保持在这一状态。如最后阶段还不发生停止,终止代价为 $t(x_N)$ 。因此实际上,我们假定在最后阶段或者早些时候总会引起终止代价。

DP 算法由下式给出

$$J_N(x_N) = t(x_N) \quad (2.68)$$

$$J_k(x_k) = \min[t(x_k), \min_{u \in U(x)} E\{g(x_k, u, w_k) + J_{k+1}[f(x_k, u, w_k)]\}], \quad k = 0, 1, \dots, N-1, \quad (2.69)$$

而且对于在集合

$$T_k = \{x | t(x) \leq \min_{u \in U(x)} E\{g(x, u, w) + J_{k+1}[f(x, u, w)]\}\}.$$

中的状态 x , 在时刻 k 停止是最优的。

由式(2.68)和式(2.69)有

$$J_{N-1}(x) \leq J_N(x), \quad \text{对所有 } x \in S.$$

且利用式(2.69)中这一事实。归纳得到

$$J_k(x) \leq J_{k+1}(x), \quad \text{对所有 } x \in S \text{ 和 } k.$$

[这里我们利用问题的平稳性和 DP 的单调性(第一章习题 24)]利用这一结果和 T_k 的定义,我们看到

$$T_0 \subset \dots \subset T_k \subset T_{k+1} \subset \dots \subset T_{N-1}. \quad (2.70)$$

现在考虑集合 T_{N-1} 为吸收的情况,意即若一个状态属于 T_{N-1} , 且不选择终止,下一个状态仍将在 T_{N-1} , 即

$$f(x, u, w) \in T_{N-1}, \quad \text{对 } x \in T_{N-1}, u \in U(x), w \in D. \quad (2.71)$$

我们将证明式(2.70)等式成立,并对所有 k , 我们有

$$T_k = T_{N-1} = \{x \in S | t(x) \leq \min_{u \in U(x)} E\{g(x, u, w) + t[f(x, u, w)]\}\}.$$

为理解这一点,注意由 T_{N-1} 的定义,我们有

$$J_{N-1}(x) = t(x), \quad x \in T_{N-1},$$

且利用式(2.71),我们对 $x \in T_{N-1}$ 得到

$$\begin{aligned} \min_{u \in U(x)} E\{g(x, u, w) + J_{N-1}[f(x, u, w)]\} \\ = \min_{u \in U(x)} E\{g(x, u, w) + t[f(x, u, w)]\} \geq t(x). \end{aligned}$$

所以对所有 $x_{N-2} \in T_{N-1}$, 或等价地 $T_{N-1} \subset T_{N-2}$, 停止是最优的。它与式(2.70)一起,意味着 $T_{N-2} = T_{N-1}$, 而且按类似的处理,对所有 k 得 $T_k = T_{N-1}$ 。

总之,如果条件式(2.71)成立(一步停止集合 T_{N-1} 是吸收的),则停止集合 T_k 都等于状态集合;对于该状态集合,最好是停止而不是多延续一个阶段后再停止。这种形式的策略

就是所谓一步前瞻策略。在许多类型的应用中,它是最优的策略。下面我们给出几个例子。另外一些例子在习题中和 § 6.3、§ 6.4 中给出。在 § 6.3 和 § 6.4, 停止问题将以无限时域方式重新研究。

例题 1 保留过去出价的资产出售问题。考虑本节前面已考虑过的资产出售问题, 区别在于被拒绝接受的出价在以后的时间可以被接受。那么如果资产在时间 k 未被出售, 状态按下式

$$x_{k+1} = \max[x_k, w_k]$$

变化而不是按 $x_{k+1} = w_k$ 演变。因而 DP 方程式(2.64)和式(2.65)变为

$$V_N(x_N) = x_N,$$

$$V_k(x_k) = \max[x_k, (1+r)^{-1}E\{V_{k+1}(\max[x_k, w_k])\}].$$

向前一步停止集合为

$$T_{N-1} = \{x | x \geq (1+r)^{-1}E\{\max[x, w]\}\}.$$

可以看出(与式(2.66)相比较)另一种特征是

$$T_{N-1} = \{x | x \geq \bar{\alpha}\}, \quad (2.72)$$

式中 $\bar{\alpha}$ 由下式获得:

$$\bar{\alpha}(1+r) = P(\bar{\alpha})\bar{\alpha} + \int_{\bar{\alpha}}^{\infty} w dp(w).$$

因为过去的出价可在后来的日子被接受, 已有的有效出价不能随时间下降, 由此得到一步停止集合式(2.72)按式(2.71)的意义是吸收的。所以接受等于或高于 $\bar{\alpha}$ 的第一次出价的一步前瞻停止规则是最优的。注意这个策略与时域长度 N 无关。

例题 2 推理的盗贼问题[W11]。一个盗贼可在任一晚间 k , 以自己的累计收益 x_k 而罢休不干, 或撬门入室把一笔 w_k 的钱偷出。然而在后一种情况下, 他会以概率 p 被抓获, 且被迫停止盗窃活动, 同时罚交他迄今所得收益。钱数 w_k 具有均值 $\bar{w}$, 独立恒定分布。问题是寻求一种策略, 使盗贼在 N 个夜间的期望收益最大。

我们可以将此问题建立成一个停止问题。它具有两个动作(罢休不干或继续盗窃)。由实践, 罢休状态和相应于盗贼被抓的特殊状态组成状态空间。DP 算法给出如下

$$J_N(x_N) = x_N$$

$$J_k(x_k) = \max[x_k, (1-p)E\{J_{k+1}(x_k + w_k)\}].$$

向前一步停止集合为

$$T_{N-1} = \{x | x \geq (1-p)(x + \bar{w})\} = \left\{x | x \geq \frac{(1-p)\bar{w}}{p}\right\},$$

(更确切地, 这个集合要与相应于盗贼被抓的特殊状态相加。)因为这个集合在式(2.71)意义下是吸收的。我们得出结论: 当盗贼的收益达到或超过 $(1-p)\bar{w}/p$ 时, 罢休不干的一步前瞻策略是一种最优策略。相应于无限时域问题, 这种策略的最优性将在 § 6.3 中演示。

§ 2.5 调度和次序互换理论

假定有一个要执行的任务集合, 但任务的次序受最优选择的约束。例如, 在一个建筑项目中安排操作次序使建筑时间最短; 车间的作业调度使机床空闲时间最少。在这类问题中,

一个有用的技术常常以某个调度计划开始,然后将相邻的两个任务互换,看看发生什么情况。

作为一个例子,考虑一个知识竞赛,参赛者必须从 N 个给定的条目中以他所选择的任意次序回答所提问题。以概率 P_i 正确回答问题 i , 参赛者将获得奖赏 r_i 。第一次回答不正确,提问就终止,允许参赛者持有他原有的奖赏。问题是选择回答的次序,使期望奖赏极大。

令 i 和 j 为最优次序排列表 $L = (i_0, \dots, i_{k-1}, i, j, i_{k+2}, \dots, i_{N-1})$ 中两个相邻的问题。交换第 k 个和第 $k+1$ 个问题 i 和 j , 考虑由 L 得到的表 $L' = (i_0, \dots, i_{k-1}, j, i, i_{k+2}, \dots, i_{N-1})$ 。比较 L 和 L' 的期望奖赏, 有

$$\begin{aligned} E\{L \text{ 的奖赏}\} &= E\{\{i_0, \dots, i_{k-1}\} \text{ 的奖赏}\} \\ &\quad + p_{i_0} \cdots p_{i_{k-1}} (p_i r_i + p_i p_j r_j) \\ &\quad + p_{i_0} \cdots p_{i_{k-1}} p_i p_j E\{\{i_{k+2}, \dots, i_{N-1}\} \text{ 的奖赏}\}. \end{aligned}$$

$$\begin{aligned} E\{L' \text{ 的奖赏}\} &= E\{\{i_0, \dots, i_{k-1}\} \text{ 的奖赏}\} \\ &\quad + p_{i_0} \cdots p_{i_{k-1}} (p_j r_j + p_j p_i r_i) \\ &\quad + p_{i_0} \cdots p_{i_{k-1}} p_j p_i E\{\{i_{k+2}, \dots, i_{N-1}\} \text{ 的奖赏}\}. \end{aligned}$$

因为 L 是最优地排列着, 从这些方程得出

$$p_j r_j + p_j p_i r_i \leq p_i r_i + p_i p_j r_j,$$

或等价地

$$\frac{p_j r_j}{1-p_j} \leq \frac{p_i r_i}{1-p_i}.$$

所以, 为使期望奖赏极大, 问题应该以 $p_i r_i / (1-p_i)$ 递减的次序来回答。

互换理论

考虑第一章的基本问题, 并试图将前面给出的互换理论推广。基本要求是使问题存在一个开环的最优策略, 即执行的控制序列以及控制函数任意序列。在第一章讨论过, 对确定性问题, 这肯定是成立的。但在某些随机问题中, 包括前面的例子也是成立的。

为了应用互换理论, 我们从最优序列 $\{u_0, \dots, u_{k-1}, u^*, \tilde{u}, u_{k+2}, \dots, u_{N-1}\}$ 开始, 把注意力放在时刻 k 和 $k+1$ 分别所施加的控制 u^* 和 $\tilde{u}$ 上 ($k=0, 1, \dots, N-1$)。然后我们论证: 若交换 u^* 和 $\tilde{u}$ 的次序, 期望代价不可能增大。特别地, 如果 X_k 是一个状态集合, 该状态可从给定的初态 x_0 开始, 利用控制序列 $\{u_0, \dots, u_{k-1}\}$, 以正概率出现。对所有 $x_k \in X_k$, 必有

$$\begin{aligned} &E\{g_k(x_k, u^*, w_k) + g_{k+1}(x_{k+1}^*, \tilde{u}, w_{k+1}) + J_{k+2}^*(x_{k+2}^*)\} \\ &\leq E\{g_k(x_k, \tilde{u}, w_k) + g_{k+1}(\tilde{x}_{k+1}, u^*, w_{k+1}) + J_{k+2}^*(\tilde{x}_{k+2})\}, \end{aligned} \quad (2.73)$$

式中 x_{k+1}^* 和 x_{k+2}^* (或 $\tilde{x}_{k+1}$ 和 $\tilde{x}_{k+2}$) 是当加上 $u_k = u^*$ 和 $u_{k+1} = \tilde{u}$ (或 $u_k = \tilde{u}$ 和 $u_{k+1} = u^*$) 时, x_k 以后的状态, $J_{k+2}^*(\cdot)$ 是时间 $k+2$ 的最优余留代价函数。

关系式(2.73)是优化的必要条件。对每一个 k 和每一个最优开环策略, 此式成立。在任意给定的调度问题中, 并不保证此条件强得足以导出一个最优解, 但这是值得考虑的。现在我们给出两个例子。

单处理器上的作业调度

我们假定有 N 个作业按先后次序处理, 第 i 个作业需要一个随机时间 T_i 来执行。时间 $T_1, \dots, T_N$ 是独立的。如果作业 i 在时间 t 完成, 报酬为 $a^t R_i$, 其中 a 是一个折扣因子, 且 $0 < a < 1$ 。问题是寻找调度方案, 使总的期望报酬最大。

显然, 这问题可在基本问题框架内来建立(当一个作业完成时, 使离散时间增值。在阶段 k 的状态是迄今已完成作业的集合。在时间 k 的容许控制是将来要处理的作业。因为时间 T_i 是独立的, 第 k 个作业完成的时间不必包括在状态中)。显然它也存在一个是最优的开环策略。

考虑一个最优的作业调度 $L = (i_0, \dots, i_{k-1}, i, j, i_{k+2}, \dots, i_{N-1})$, 和调度 $L' = (i_0, \dots, i_{k-1}, j, i, i_{k+2}, \dots, i_{N-1})$, 后者由交换 i 和 j 得到。令 t_k 是作业 i_{k-1} 完成的时间。因为完成其余作业 $i_{k+2}, \dots, i_{N-1}$ 的报酬与 i 和 j 所执行的次序无关, 由必要条件式(2.73)得

$$E\{a^{t_k+T_i} R_i + a^{t_k+T_i+T_j} R_j\} \geq E\{a^{t_k+T_j} R_j + a^{t_k+T_j+T_i} R_i\}.$$

因为 t_k , T_i 和 T_j 独立, 这一关系式可写成

$$E\{a^{t_k}\} (E\{a^{T_i}\} R_i + E\{a^{T_j}\} E\{a^{T_i}\} R_j) \geq E\{a^{t_k}\} (E\{a^{T_j}\} R_j + E\{a^{T_i}\} E\{a^{T_j}\} R_i), \quad [\text{注}]$$

因此, 最后得

$$\frac{R_i E\{a^{T_i}\}}{1 - E\{a^{T_i}\}} \geq \frac{R_j E\{a^{T_j}\}}{1 - E\{a^{T_j}\}}.$$

于是得到结论: 以 $R_i E\{a^{T_i}\} / (1 - E\{a^{T_i}\})$ 的递减次序调度作业, 使期望报酬最大。

两台串联处理器上的作业调度

考虑在两台处理器 A 和 B 中 N 个作业的调度问题, B 接受 A 的输出作为其输入。作业 i 在 A 和 B 中处理分别需要已知的时间 a_i 和 b_i 。问题是寻找一个调度计划使总的处理时间最小。

为使这个问题建成基本问题的形式, 在机器 A 完成一个作业, 而下个作业开始的时刻, 将离散时间增值。我们把 k 时刻留在 A 中待处理的作业集合 X_k , 加上机器 B 中的工作积压 τ_k 取为状态。如已没有遗留作业, 该 τ_k 即为清理 B 所需的时间总量。这样, 如果 (X_k, τ_k) 是阶段 k 的状态, 而作业 i 在机器 A 完成, 则状态变化到 (X_{k+1}, τ_{k+1}) 由下式给出

$$X_{k+1} = X_k - \{i\}, \quad \tau_{k+1} = b_i + \min[0, \tau_k - a_i].$$

相应的 DP 算法是

$$J_k(X_k, \tau_k) = \min_{i \in X_k} [a_i + J_{k+1}(X_k - \{i\}, b_i + \min[0, \tau_k - a_i])],$$

终端条件为

$$J_N(\emptyset, \tau_N) = \tau_N.$$

式中 $\emptyset$ 为空集。

译者注: 此式原文有误。

因为问题是确定性的, 所以存在一个最优开环调度计划 $\{i_0, \dots, i_{k-1}, i, j, i_{k+2}, \dots, i_{N-1}\}$, 应用必要条件式(2.73)我们得

$$J_{k+2}(X_k - \{i\} - \{j\}, \tau_{ij}) \leq J_{k+2}(X_k - \{i\} - \{j\}, \tau_{ji}), \quad (2.74)$$

式中 $\tau_{ij}(\tau_{ji})$ 是时刻 $k+2$ 在机器 B 的积压, 此时 i 先于 j (j 先于 i) 处理, 且在时间 k 的积压为 τ_k 。直接计算表明

$$\tau_{ij} = b_i + b_j - a_i - a_j + \max[\tau_k, a_i, a_i + a_j - b_i], \quad (2.75a)$$

$$\tau_{ji} = b_i + b_j - a_j - a_i + \max[\tau_k, a_j, a_j + a_i - b_j]. \quad (2.75b)$$

显然, J_{k+2} 按 τ 单调递增。所以由式(2.74)我们得

$$\tau_{ij} \leq \tau_{ji}.$$

根据式(2.75), 这个关系隐含了两种可能性。第一是:

$$\tau_k \geq \max[a_i, a_i + a_j - b_i],$$

$$\tau_k \geq \max[a_j, a_j + a_i - b_j],$$

在 $\tau_{ij} = \tau_{ji}$ 这种情况下, i 和 j 的次序不会造成差异。(当时刻 k 的积压是如此之多, 以至作业 i 和 j 二者都发现 B 正在对以前的作业进行工作, 即是这种情况。)第二种可能性是:

$$\max[a_i, a_i + a_j - b_i] \geq \max[a_j, a_j + a_i - b_j],$$

可以看出, 它等价于

$$\min[a_i, b_j] \leq \min[a_j, b_i].$$

满足这些优化必要条件的调度计划可按以下步骤构造:

1. 寻求 $\min_i \min[a_i, b_i]$.
2. 如果极小值为 a , 先取相应的作业; 如果是 b , 后取相应的作业。
3. 其余作业重复这过程, 直到作出完整的调度计划。

为了证明这个调度计划确是最优的, 我们从一个最优调度开始。考虑使 $\min[a_i, b_i]$ 为最小的作业 i_0 , 通过逐次交换将其变动到与以前所建立的作业调度方案的相同位置上, 由以上分析看出, 所得调度方案仍然是最优的。类似地, 继续通过逐次交换, 且一直保持最优, 我们可把这一最优调度方案转换成原来构造的方案。我们把具体细节留给读者。

§ 2.6 注 记

动态线性二次问题的确定性等价原理首先由 Simon 给予讨论 [S 19]。他的工作先于考虑了一种单周期情况的 Theil, 和考虑了一种确定性情况的 Holt 等人。类似的问题后来(显然是独立地)由 Kalman 和 Koepcke [K2], Gunckel 和 Franklin [G5], 以及 Joseph 和 Tou [J5] 等人研究过。由于他们的工作, 有关线性二次问题的文献急遽增加。IEEE 自动控制文集有关线性二次问题的专集包含了大多数有关理论及随后的变化, 还有数百篇参考文献。关于习题 2 的多维形式, 见 [J1]。

由 Arrow 等人的开创性论文所推动的库存控制的文献也是大量的。1966 年, 由 Veinott [V5] 所作的综述文章包含 118 篇参考文献。综合了 1958 以前绝大部分研究成果的重要著作是 Arrow 等的专著 [A8]。在非零固定代价情况下关于 (s, S) 最优性证明的创造性论证由 Scarf [S5] 建立。习题 17 的结果归属于 Veinott [V7], 也可参阅 Tsitsiklis [T7]。

§ 2.3 节中大多数材料取自 Mossin 的论文 [M10]。

习 题

1. 带预报的线性二次问题。对如下情况考虑最初在 § 2.1 考察过的线性二次问题：在周期 k 开始时，存在一个由准确预测构成的有用预报 $y_k \in \{1, 2, \dots, n\}$ 。 w_k 将按照一个特定的概率分布 $P_{k|y_k}$ 进行选择(参看 § 1.4)。在分布 $P_{k|y_k}$ 条件下， w_k 不必具有零均值。证明最优控制律具有如下形式

$$\mu_k(x_k, y_k) = -(B_k' K_{k+1} B_k + R_k)^{-1} B_k' K_{k+1} [A_k x_k + E\{w_k | y_k\}] + \alpha_k,$$

式中矩阵 K 由黎卡提方程式(2.5)和式(2.6)给出， α_k 是适当的向量。

2. 考虑一个标量线性系统

$$x_{k+1} = a_k x_k + b_k u_k + w_k, \quad k = 0, 1, \dots, N-1,$$

式中 $a_k, b_k \in R$ ，每个 w_k 是一高斯随机变量，具有零均值和方差 σ^2 ，证明使代价泛函

$$E\left\{\exp\left[x_N^2 + \sum_{k=0}^{N-1} (x_k^2 + r u_k^2)\right]\right\}, \quad r > 0,$$

极小的控制律 $\{\mu_0^*, \mu_1^*, \dots, \mu_{N-1}^*\}$ 是状态变量的线性函数。假定无控制约束，独立扰动，且对每一个 x_0 最优代价是有限的。举例说明为了使结果成立，高斯假设是基本的。

3. 考虑一个与 § 3.2 多阶段库存问题相似的一个库存控制问题。唯一的差别是在每个周期 k 开始，决策者除了知道当前存货量 x_k 之外，还收到一个准确的预报，即需求 w_k 将按两种可能的概率分布 P_l, P_s (大需求，小需求)之一来选择，大需求预报的先验概率已知(参阅 § 1.4)。

(a) 对单周期问题求最优存货订购策略。

(b) 把这一结果推广到 N 周期情况。

(c) 把这一结果推广到任意有限数目可能分布的情况。

4. 考虑库存控制问题。在过程开始时购买价格 $c_k, k = 1, \dots, N-1$ ，不知道，但知道它们是具有已知先验概率分布的独立随机变量。然而在第 k 周期开始，决策者已经知道价格 c_k 的准确值。所以在时刻 k 以准确知道的价格 c_k ，作出购货决策。试将最优订货策略表示出来。

5. 对如下情况考虑 § 2.2 多周期库存问题：它在订货与付货之间有一个周期的时间滞后，即系统方程的形式为

$$x_{k+1} = x_k + u_{k-1} - w_k, \quad k = 1, \dots, N-1,$$

$$x_1 = x_0 - w_0.$$

证明 (s, S) 策略是最优的。

6. 在如下假设条件下考虑库存问题：在每个阶段超额的需求及时供货，但被丢失；即系统方程为 $x_{k+1} = \max[0, x_k + u_k - w_k]$ ，而不是 $x_{k+1} = x_k + u_k - w_k$ 。证明多周期 (s, S) 策略是最优的。

简略证明(S. Shreve)：令 $J_N(x_N) = 0$ ，且对所有 k

$$G_k(y) = cy + E\{h \max[0, y - w_k] + p \max[0, w_k - y] + J_{k+1}(\max[0, y - w_k])\},$$

$$J_k(x) = -cx + \min_{u \geq 0} [K\delta(u) + G_k(x+u)],$$

式中 $\delta(0)=0$, 对 $u>0$, $\delta(u)=1$ 。如果我们能证明 G_k 是 K -凸连续的, 且当 $|y|\rightarrow\infty$ 时, $G_k(y)\rightarrow\infty$, 则结果就出来了。困难部分是证明 K -凸性, 因为 G_{k+1} 是 K -凸的, 并不意味着 $E\{J_{k+1}(\max[0, y-w])\}$ 是 K -凸的。这只要证明 G_{k+1} 的 K -凸性意味着

$$H(y) = p \max[0, -y] + J_{k+1}(\max[0, y]) \quad (2.76)$$

的 K -凸性; 或等价地意味

$$K + H(y+z) \geq H(y) + z \frac{H(y) - H(y-b)}{b}, \quad z \geq 0, b > 0, y. \quad (2.77)$$

就足够了。根据 G_{k+1} 的 K -凸性, 对适当的标量 s_{k+1} 和 S_{k+1} , 使得

$$G_{k+1}(S_{k+1}) = \min_y G_{k+1}(y), \text{ 且 } K + G_{k+1}(S_{k+1}) = G_{k+1}(s_{k+1}), \text{ 有:}$$

$$J_{k+1}(x) = -cx + \begin{cases} G_{k+1}(x), & \text{若 } s_{k+1} \leq x, \\ K + G_{k+1}(S_{k+1}), & \text{若 } x < s_{k+1}, \end{cases} \quad (2.78)$$

根据 § 2.2 的理论, J_{k+1} 是 K -凸的。

情况 1 $0 \leq y-b < y \leq y+z$ 对于这个区域, 由 J_{k+1} 的 K -凸性可得出式(2.77)。

情况 2 $y-b < y \leq y+z \leq 0$ 在此区域内, H 是线性的, 因而是 K -凸的。

情况 3 $y-b < y \leq 0 \leq y+z$ 在此区域内, 式(2.77)可以(根据式(2.76))写成
 $K + J_{k+1}(y+z) \geq J_{k+1}(0) - p(y+z)$ 。我们将证明

$$K + J_{k+1}(z) \geq J_{k+1}(0) - pz, \quad z \geq 0. \quad (2.79)$$

如果 $0 < s_{k+1} \leq z$, 则应用式(2.78)和 $p > c$,

$$K + J_{k+1}(z) = K - cz + G_{k+1}(z) \geq K - pz + G_{k+1}(S_{k+1}) = J_{k+1}(0) - pz.$$

如果 $0 \leq z \leq s_{k+1}$, 则应用式(2.78)和 $p > c$,

$$\begin{aligned} K + J_{k+1}(z) &= 2K - cz + G_{k+1}(S_{k+1}) \geq K - pz + G_{k+1}(S_{k+1}) \\ &= J_{k+1}(0) - pz. \end{aligned}$$

如果 $s_{k+1} \leq 0 \leq z$, 则利用式(2.78)和 $p > c$, 以及 § 2.2 中引理部分(iv),

$$K + J_{k+1}(z) = K - cz + G_{k+1}(z) \geq G_{k+1}(0) - pz = J_{k+1}(0) - pz.$$

因此式(2.79)得证; 且对所考虑的情况, 得出式(2.77)。

情况 4 $y-b < 0 < y \leq y+z$ 则 $0 < y < b$ 。如果

$$\frac{H(y) - H(0)}{y} \geq \frac{H(y) - H(y-b)}{b}, \quad (2.80)$$

则因为在 $[0, \infty)$ 上 H 与 J_{k+1} 一致, 因而 J_{k+1} 是 K -凸的,

$$K + H(y+z) \geq H(y) + z \frac{H(y) - H(0)}{y} \geq H(y) + z \frac{H(y) - H(y-b)}{b},$$

式中最后一步是根据式(2.80)而得的。如果

$$\frac{H(y) - H(0)}{y} < \frac{H(y) - H(y-b)}{b},$$

则我们有

$$H(y) - H(0) < \frac{y}{b} [H(y) - H(y-b)] = \frac{y}{b} [H(y) - H(0) + p(y-b)].$$

从而有

$$\left(1 - \frac{y}{b}\right) [H(y) - H(0)] < \left(\frac{y}{b}\right) p(y-b) = -py \left(1 - \frac{y}{b}\right),$$

且因为 $b > y$,

$$H(y) - H(0) < -py. \quad (2.81)$$

利用 H 的定义和式(2.79)和式(2.81), 现在我们有

$$\begin{aligned} H(y) + z \frac{H(y) - H(y-b)}{b} &= H(y) + z \frac{H(0) - py - H(0) + p(y-b)}{b} \\ &= H(y) - pz < H(0) - p(y+z) \\ &\leq K + H(y+z). \end{aligned}$$

因此对这个情况式(2.77)得证。

证毕。

7. 对如下情况考虑 § 2.3 的动态有价值证券问题: 在每一个周期 k , 有一个预报。即对该周期风险资产的回收率, 是按 § 1.5 特定概率分布来选择。证明部分无远见策略是最优的。

8. 考虑涉及如下线性系统的一个问题:

$$x_{k+1} = A_k x_k + B_k u_k, \quad k = 0, 1, \dots, N-1,$$

式中 $n \times n$ 阵 A_k 给定, $n \times m$ 阵 B_k 是独立随机矩阵, 并具有与 x_k, u_k 无关的给定概率分布。问题是寻求最优的控制律 $\{\mu_0^*, \dots, \mu_{N-1}^*\}$, 使代价泛函 $E\{U(c'x_N)\}$ 极大。式中 c 是给定的 n 维向量。我们假定 U 是一个凹的效用函数, 对所有 y 满足

$$-\frac{U'(y)}{U''(y)} = a + by,$$

且控制无约束。证明最优控制律是由当前状态的仿射函数组成。提示: 把问题简化成一维问题并利用 § 2.3 结果。

9. 一个雇主与 N 个谋职的候选人谈话, 每次谈话后必须立即决定是否要聘任相应的候选人。谈话之后, 给每一候选人记分, 记分是独立恒定分布的, 确定使被聘任的候选人期望记分为最高的策略。

10. 假设有人要出售房屋, 并且每天早晨有一出价, 我们假定相继的出价是独立的。出价 x_j 具有概率 p_j , $j = 1, \dots, n$, 其中 x_j 是给定的非负标量。任何未被即刻接受的出价并不失效, 可在以后任何日期被接受。还有, 每天房子卖不出去要付维护费 c 。目标是使房屋出售价减去维护费用为最大。考虑要在 N 天期限内出售房子的问题, 并表征其最优策略。

11. 扩大生产能力问题。考虑扩大一个设备能力的问题。它在 N 个时间周期内生产单一类型的非存放物品或服务项目。用 x_k 表示到 k 个周期开始时的生产能力, 而 $u_k \geq 0$ 是在第 k 个周期内增加的生产能力。于是, 生产能力按下式演变

$$x_{k+1} = x_k + u_k, \quad k = 0, 1, \dots, N-1.$$

第 k 个周期的需求用 w_k 表示, 具有一个与 x_k 或 u_k 无关的已知概率。而且, 假定逐次的需求是独立和有界的。记

$C_k(u_k)$ 与增加生产能力 u_k 有关的扩大代价,

$P_k(x_k + u_k - w_k)$ 与生产能力 $x_k + u_k$ 和需求 w_k 有关的惩罚代价,

$S(x_N)$ 最终生产能力 x_N 的补助值。

因此, 代价泛函取如下形式

$$E_{w_k} \left\{ -S(x_N) + \sum_{k=0}^{N-1} [C_k(u_k) + P_k(x_k + u_k - w_k)] \right\},$$

$k = 0, 1, \dots, N-1$

(a) 推导解此问题的 DP 算法。

(b) 假定 S 是一个凹函数, 且 $\lim_{x \rightarrow \infty} dS(x)/dx = 0$, P_k 是凸函数, 扩大代价 C_k 的形式为

$$C_k(u) = \begin{cases} K + c_k u, & \text{若 } u > 0, \\ 0, & \text{若 } u = 0. \end{cases}$$

式中对所有 k , $K \geq 0$, $c_k > 0$. 假定当 $|y| \rightarrow \infty$ 时, $c_k y + E\{P_k(y - w_k)\} \rightarrow \infty$, 证明最优策略是 (s, S) 型的。

12. 赌博问题。一个赌徒进入赌博, 他可在任意时刻 k 下任何不超过他现有赌本 x_k (定义为他的初始本钱加赢得或减去输掉的赌注 $u_k \geq 0$)。赢回赌注和更多的钱的概率为 p , $1/2 < p < 1$; 输掉他的赌注的概率为 $(1-p)$ 。证明使 $E\{\ln x_N\}$ 最大的赌博策略 (式中 x_N 表示赌 N 次后他的赌本) 为: 在每个时刻 k , 赌注为 $u_k = (2p-1)x_k$ 。提示: 该问题与 § 2.3 有价证券问题有关。

13. 最优采样终止问题。随机地逐次地和一次一个地观测一群 $N \geq 2$ 的物体。观测者或者选择当前已观测到的物体, 在这种情况下, 选择过程停止; 或者拒绝该物体, 对下一个进行观测。观测者可以相对于已观测到的物体, 将每一个物体排序, 其目的是按照某个准则使选择“最好”物体的概率为最大。假定没有两个物体可被判为相等, 令 r^* 为最小正整数 r , 使

$$\frac{1}{N-1} + \frac{1}{N-2} + \cdots + \frac{1}{r} \leq 1.$$

证明一个最优策略需要观测到头 r^* 个物体。假定第 r^* 物体相对于已观测到的其它物体级别为头等, 它就必须被选中; 否则观测过程必须继续, 直到找到相对于其它已观测过的物体级别为头等的物体。提示: 我们假定, 如果第 r 个物体相对前面 $(r-1)$ 物体级别为头等, 则它为最好的概率为 r/N 。对 $k \geq r^*$, 假定已选择了 k 个物体, 且相对于前面 $(k-1)$ 物体, 第 k 个物体不是最好。令 $J_k(0)$ 为找到最好物体的最大概率。证明

$$J_k(0) = \frac{k}{N} \left(\frac{1}{N-1} + \cdots + \frac{1}{k} \right).$$

14. 考虑 § 2.2 的库存控制问题, 其区别在于逐次需求相关, 并满足以下形式的关系式

$$w_k = e_k - c e_{k-1}, \quad k = 0, 1, \cdots,$$

式中 c 是给定的标量, e_k 是独立随机变量, $e_{-1} = 0$ 。

(a) 证明这个问题可以变换成具有独立需求的库存问题。提示: 给定 $w_0, w_1, \cdots, w_{k-1}$, 我们可以根据关系

$$e_{k-1} - c^k e_{-1} = \sum_{i=0}^{k-1} c^i w_{k-1-i}.$$

来确定 e_{k-1} 。

定义 $z_k = x_k + c e_{k-1}$ 为一个新的状态变量。

(b) 当存货交付有一个周期时延时, 证明上述结论同样正确 (参见习题 5)。

15. 考虑 § 2.2 具有零固定代价的库存控制问题, 唯一的区别在于对存货量的容许值 x_k 有一个上界 $\bar{b}$ 和一个下界 $\underline{b}$ 。这样对 u_k 加上了附加的约束

$$\underline{b} + d \leq u_k + x_k \leq \bar{b},$$

式中 $d > 0$ 是需求 w_k 可以取的最大值 (假定 $\underline{b} + d < \bar{b}$)。证明存在标量 $S_0, S_1, \cdots, S_{N-1}$ 和一个如下形式的最优策略 $\{\mu_0^*, \cdots, \mu_{N-1}^*\}$:

$$\mu_k^*(x_k) = \begin{cases} S_k - x_k, & \text{若 } x_k < S_k, \\ 0, & \text{若 } x_k \geq S_k. \end{cases}$$

16. 考虑 § 2.2 库存控制问题(非零固定代价), 区别在于需求是确定性的, 且在每一时间周期必须被满足(即每单位缺货代价为 ∞)。证明当且仅当存货量 x_k 不足以满足需求 w_k 时, 在周期 k 订购一个正的数量才是最优的。而且, 当订购一个正的数量时, 它必须将存货量提高到满足整数个周期需求的水平。

17. 考虑 § 2.2 零固定代价的库存控制问题, 其区别仅在于订货量 u_k 限定为非负整数。令 J_k 为最优余留代价函数, 证明:

(a) J_k 是连续的。

(b) $J_k(x+1) - J_k(x)$ 是 x 的非递减函数。

(c) 存在一个数的序列 $\{S_k\}$, 使如下给定的策略是最优的,

$$\mu_k(x_k) = \begin{cases} n, & \text{若 } x_k \in [S_k - n, S_k - n + 1), n = 1, 2, \dots, \\ 0, & \text{若 } x_k \geq S_k. \end{cases}$$

18. 希腊探险家 Theseus 落入国王 Minos 迷宫而受困。他每天可以试探 N 个通道之一, 如果他进入通道 i , 就可以以概率 p_i 逃出; 以概率 q_i 被杀; 且他以概率 $(1 - p_i - q_i)$ 确定通路是死胡同。在后一种情况下, 他就回到出发点。证明按 p_i/q_i 递减的次序试探通道, 使他在 N 天内逃脱的概率为最大。

提示: 利用互换理论。

19. 一个司机在去目的地的路上要寻找一个停车场。每一停车场免费的概率为 p , 它与别的停车场是否免费无关。在到达停车场之前, 司机不知道它是否免费。如果从终点算起, 他在 k 个地方停车, 要付出代价 k ; 如果他到目的地而不停车, 代价为 C 。

(a) 如果他从目的地算起, 停车在 k 个停车场, 令 F_k 为最小期望代价, 证明

$$F_0 = C$$

$$F_k = p \min[k, F_{k-1}] + q F_{k-1}, \quad k = 1, 2, \dots,$$

式中 $q = 1 - p$ 。

(b) 证明最优策略具有如下形式: 如果 $k \geq k^*$, 决不停车; 但如果 $k < k^*$, 停车在第一个免费的地方, 其中 k 是从目的地算起停车场数目, k^* 是满足 $q^{i-1} < (pc + q)^{-1}$ 的最小整数 i 。

20. Hardy 定理。令 $\{a_1, \dots, a_n\}$ 和 $\{b_1, \dots, b_n\}$ 是单调非递减的数列。我们把每一个 $i = 1, \dots, n$ 与一个不相同的标号 j_i 连系起来。考虑表达式 $\sum_{i=1}^n a_i b_{j_i}$ 。证明对所有 i , 当 $j_i = i$ 时, 此表达式为最大; 对所有 i , 当 $j_i = n - i + 1$ 时, 为最小。

提示: 利用互换理论。

21. 有人在给定的一天出来猎捕某种动物或呆在家里。当动物头数为 x 时, 捕获一头动物的概率为 $p(x)$, 它是一个已知的递增函数; 而捕获一头以上动物的概率为零。被捕获动物价值一个单位, 打猎一天耗费 c 个单位。证明只有当 $p(x) \geq c$ 时, 打猎是最优的。

22. 考虑标量线性系统

$$x_{k+1} = ax_k + bu_k,$$

式中 a 和 b 已知。在每个周期我们任选: 或利用控制 u_k , 引起代价 $qx_k^2 + ru_k^2$; 或停止, 引起停止代价 tx_k^2 。如果在周期 N 还未停止, 终端代价为停止代价 tx_N^2 。我们假定, $q \geq 0$, $r > 0$, $t > 0$ 。证明, 对 t 存在一个阈值, 在每个初态低于此值时立即停止是最优的; 在每个状态 x_k 和周期 k , 高于此值继续下去是最优的。

第三章 不完全状态信息问题

§ 3.1 简化成完全状态信息情况

迄今为止, 我们已假定控制器获取了当前状态的精确值, 但这种假定往往是不现实的。例如某些状态变量可能是取不到的, 用于测量的传感器可能不精确, 或者获取状态精确值的代价是不容许的。对于这类情况的建模, 我们假定在每一阶段控制器接收有关当前状态的某些观测, 该观测可能受随机不确定性污染。数学上, 在阶段 k 所得观察 z_k 具有如下形式

$$z_k = h_k(x_k, u_{k-1}, v_k),$$

式中 h_k 是某个函数, v_k 是随机扰动。我们首先来看一个例子, 然后提出一个精确的问题描述

多路存取通信例子

考虑一个共享公共通道的发送站集合, 例如一组地面站与卫星以公用频率进行通信, 地面站同步发送整倍数的数据包。每个包发送需要一个时间单位(也称之为槽)。在槽 k 期间信包到达的总数 a_k 与以前到达的无关, 具有一个给定的概率分布。在第 k 槽开始的时刻, 发送站不知道积压的 x_k (等待发送的包数)。因此在包发送的调度中存在一定的困难。这样, 采用了一种(称为槽式 Aloha)策略。根据这个策略, 在 k 槽开始时刻, 系统中的每一个包在该槽期间以概率 u_k (所有包都一样)被发送。如果两个或两个以上的包被同时发送, 它们互相冲突, 必须重新加入积压行列, 在后来的槽中再重发。然而各站可以观察通道, 并确定在任何一个时间槽是否有冲突(两个以上的包)、成功(一个包)或空闲(无包)。这些观测提供了有关系统状态的信息(积压 x_k), 并可以用来适当地选择控制(发送概率 u_k)。目标是使积压少到使每一阶段代价 $z_k(x_k)$ (它是 x_k 单调增函数)适当。

在这里, 系统的状态是积压 x_k , 并按方程

$$x_{k+1} = x_k + a_k - t_k$$

演变。式中 a_k 是新到达的数目, t_k 是槽 k 期间成功发送的包数。 a_k 和 t_k 都可以看成是随机扰动, t_k 的分布由状态 x_k 和控制 u_k 所决定。可以看出, t_k 为 1 (成功)的概率是 $x_k u_k (1 - u_k)^{x_k - 1}$; 否则为 0 (空闲或冲突)。如果我们拥有完全的状态信息(即在槽 k 开始时刻的积压 x_k 为已知), 最优策略为选择 u_k 使成功概率 $x_k u_k (1 - u_k)^{x_k - 1}$ 极大。将此概率的导数置零, 我们找到最优(完全状态信息)的策略为

$$\mu_k(x_k) = \frac{1}{x_k}, \quad \text{对所有 } x_k \geq 1.$$

然而, x_k 为未知(不完全状态信息)时, 最优控制必须在现有的观测基础上来选择(即整个通道成功、空闲和冲突的历史)。这些观察相与积压的历史(过去的状态)和过去发送的概率(过去的控制)有关, 而被随机不确定性污染。数学上我们可以写出方程 $z_{k+1} = v_{k+1}$, 式中 z_{k+1} 是在第 k 槽结束时所得的观测。随机变量 v_{k+1} 以概率 $(1 - u_k)^{x_k}$ 产生一个空闲, 以概率 $x_k u_k (1 - u_k)^{x_k - 1}$ 成功, 其他情况为冲突。

现在我们确切地叙述本章的问题。

具有不完全状态信息的基本问题

考虑 1.1 节的基本问题，其中控制器不拥有状态的完全知识，而是获得如下形式的观测

$$\begin{aligned} z_0 &= h_0(x_0, v_0), \\ z_k &= h_k(x_k, u_{k-1}, v_k), \quad k=1, 2, \dots, N-1. \end{aligned} \quad (3.1)$$

观测 z_k 属于一给定的观测空间。随机观测扰动属于一个给定的空间 V_k ，并以一个给定的概率测度来表征

$$P_{v_k}(\cdot | x_k, \dots, x_0, u_{k-1}, \dots, u_0, w_{k-1}, \dots, w_0, v_{k-1}, \dots, v_0),$$

此式明显依赖于当前状态，过去状态，控制和扰动。

初始状态 x_0 也是随机的，并由一个给定的概率测度 P_{x_0} 来表征。 w_k 的概率测度 $P_{w_k}(\cdot | x_k, u_k)$ 是给定的，可能明显依赖于 x_k 和 u_k ，但不依赖于扰动 $w_0, \dots, w_{k-1}, v_0, \dots, v_{k-1}$ 。控制 u_k 受约束，从一个控制空间 C_k 的一个给定非空子集 U_k 取值，假定这个子集与 x_k 无关。

令 I_k 表示在时刻 k 控制器可利用的信息，并称其为信息向量。我们有

$$\begin{aligned} I_k &= (z_0, z_1, \dots, z_k, u_0, u_1, \dots, u_{k-1}), \quad k=1, 2, \dots, N-1, \\ I_0 &= z_0. \end{aligned} \quad (3.2)$$

我们考虑控制律类(或策略)，它由函数序列 $\pi = \{\mu_0, \mu_1, \dots, \mu_{N-1}\}$ 组成，每个函数 μ_k 将信息向量 I_k 映射到控制空间 C_k ，且

$$\mu_k(I_k) \in U_k, \text{ 对所有的 } I_k, k=0, \dots, N-1.$$

这种控制律称为容许的。问题是寻求一个容许控制律 $\pi = \{\mu_0, \mu_1, \dots, \mu_{N-1}\}$ ，使如下代价泛函极小

$$J_\pi = E_{\substack{x_0, w_k, v_k \\ k=0, \dots, N-1}} \left\{ g_N(x_N) + \sum_{k=0}^{N-1} g_k[x_k, \mu_k(I_k), w_k] \right\} \quad (3.3)$$

并受系统方程

$$x_{k+1} = f_k[x_k, \mu_k(I_k), w_k], \quad k=0, 1, \dots, N-1,$$

的约束。量测方程为

$$\begin{aligned} z_0 &= h_0(x_0, v_0), \\ z_k &= h_k[x_k, \mu_{k-1}(I_{k-1}), v_k], \\ &\quad k=1, 2, \dots, N-1. \end{aligned}$$

代价函数 $g_k, k=0, 1, \dots, N$ 为给定。

注意它与完全状态信息情况的区别。在我们试图对每个状态 x_k 和时间 k 寻求一个规则以确定所施加的控制 u_k 之前，现在我们先对每个可能的信息向量 I_k (或信息状态)，即对每个已接收的观测序列和到 k 时刻为止采用的控制，寻求一个规则以给出所施加的控制。

现在我们证明本问题如何可以变换成具有完全状态信息基本问题的框架。相似地，如在 § 1.5 讨论状态增广法一样，直观上我们显然应定义一个新系统， k 时刻系统的状态由所有其知识有利于控制器进行第 k 次决策的变量组成。这样，作为新系统状态的第一个候选对象是信息向量 I_k ，确实，我们将证明这种选择是适宜的。

由定义[参阅方程(3.2)], 我们有

$$I_{k+1} = (I_k, z_{k+1}, u_k), \quad k=0, 1, \dots, N-2, \quad I_0 = z_0. \quad (3.4)$$

这些方程可以看作对系统演变的描述, 它与 § 1.1 所讨论的基本问题中的演变具有相同的本质。系统的状态是 I_k 。控制 u_k 和 z_{k+1} 可以看作作为随机扰动。而且对任意事件 $\bar{Z}_{k+1}$ (Z_{k+1} 的一个子集), 有

$$P(z_{k+1} \in \bar{Z}_{k+1} | I_k, u_k) = P(z_{k+1} \in \bar{Z}_{k+1} | I_k, u_k, z_0, z_1, \dots, z_k), \quad (3.5)$$

因为 $z_0, z_1, \dots, z_k$ 是信息向量 I_k 的一部分。因此, z_{k+1} 的概率测度只明显依赖于新系统式 (3.4) 的状态 I_k 和控制 u_k , 而与以前的扰动 $z_k, \dots, z_1$ 无关。

通过写出

$$E\{g_k(x_k, u_k, w_k)\} = E\left\{E\{g_k(x_k, u_k, w_k) | I_k, u_k\}\right\},$$

我们可类似地按新系统的变量来变换代价泛函。作为新状态 I_k 和控制 u_k 函数的每阶段代价为

$$\bar{g}_k(I_k, u_k) = E_{x_k, w_k}\{g_k(x_k, u_k, w_k) | I_k, u_k\}. \quad (3.6)$$

这样, 具有不完全状态信息的基本问题已变换成具有完全状态信息问题。它包括系统式 (3.4) 和每阶段代价式 (3.6)。写出后一个问题的 DP 算法, 并代入表达式 (3.4) 和 (3.6), 我们得到

$$J_{N-1}(I_{N-1}) = \min_{u_{N-1} \in U_{N-1}} \left[E_{x_{N-1}, w_{N-1}}\{g_N[f_{N-1}(x_{N-1}, u_{N-1}, w_{N-1})] + g_{N-1}(x_{N-1}, u_{N-1}, w_{N-1}) | I_{N-1}, u_{N-1}\} \right], \quad (3.7)$$

$$J_k(I_k) = \min_{u_k \in U_k} \left[E_{x_k, w_k, z_{k+1}}\{g_k(x_k, u_k, w_k) + J_{k+1}(I_k, z_{k+1}, u_k) | I_k, u_k\} \right]. \quad (3.8)$$

方程 (3.7) 和 (3.8) 构成了本节的基本 DP 算法。最优控制律 $\{\mu_0^*, \mu_1^*, \dots, \mu_{N-1}^*\}$ 的求得, 首先是对信息向量 I_{N-1} 的每个可能值, 求解式 (3.7) 的极小化问题, 得到 $\mu_{N-1}^*(I_{N-1})$; 同时, 计算 $J_{N-1}(I_{N-1})$, 并通过式 (3.8) 中的求极小用于 $J_{N-2}(I_{N-2})$ 的计算中。极小化是对 I_{N-2} 的每个可能值来进行的, 类似地处理, 就求得 $J_{N-3}(I_{N-3})$ 和 μ_{N-3}^* , 如此继续就计算得到 $J_0(I_0) = J_0(z_0)$ 。然后得到具有如下形式的最优代价 J^*

$$J^* = E_{z_0}\{J_0(z_0)\}. \quad (3.9)$$

§ 3.2 线性系统和二次代价: 估计和控制的分离

现在我们考虑与 § 2.1 线性系统/二次代价问题相类似的不完全状态信息问题。我们有相同的线性系统

$$x_{k+1} = A_k x_k + B_k u_k + w_k, \quad k=0, 1, \dots, N-1, \quad (3.10)$$

和二次代价

$$E\left\{x_N' Q_N x_N + \sum_{k=0}^{N-1} (x_k' Q_k x_k + u_k' R_k u_k)\right\}, \quad (3.11)$$

但现在控制器不拥有当前系统的状态，而是在每一周期开始时接收如下形式的观测

$$z_k = C_k x_k + v_k, \quad k=0, 1, \dots, N-1, \quad (3.12)$$

式中 $z_k \in R^s$, C_k 是给定的 $s \times m$ 矩阵, $k=0, 1, \dots, N-1$; $v_k \in R^s$ 是观测噪声向量, 具有给定的概率分布; 而且向量 v_k 是独立的, 与 x_0 和 w_k 无关。关于输入扰动 w_k , 我们的假设与 § 2.1 相同; 并假定系统矩阵 A_k , B_k 为已知。

由方程(3.7), 有

$$J_{N-1}(I_{N-1}) = \min_{u_{N-1}} \left[E_{x_{N-1}, w_{N-1}} \{ (A_{N-1}x_{N-1} + B_{N-1}u_{N-1} + w_{N-1})' Q_N \right. \\ \times (A_{N-1}x_{N-1} + B_{N-1}u_{N-1} + w_{N-1}) + x_{N-1}' Q_{N-1} x_{N-1} \\ \left. + u_{N-1}' R_{N-1} u_{N-1} | I_{N-1} \} \right].$$

利用关系 $E\{w_{N-1} | I_{N-1}\} = E\{w_{N-1}\} = 0$, 上面的表达式可写成

$$J_{N-1}(I_{N-1}) = E_{x_{N-1}} \{ x_{N-1}' (A_{N-1}' Q_N A_{N-1} + Q_{N-1}) x_{N-1} | I_{N-1} \} \\ + E_{w_{N-1}} \{ w_{N-1}' Q_N w_{N-1} \} \\ + \min_{u_{N-1}} [u_{N-1}' (B_{N-1}' Q_N B_{N-1} + R_{N-1}) u_{N-1} \\ + 2 E\{x_{N-1} | I_{N-1}\}' A_{N-1} Q_N B_{N-1} u_{N-1}]. \quad (3.13)$$

求极小得到最后阶段的最优控制律为

$$u_{N-1}^* = \mu_{N-1}^*(I_{N-1}) \\ = - (B_{N-1}' Q_N B_{N-1} + R_{N-1})^{-1} B_{N-1}' Q_N A_{N-1} E\{x_{N-1} | I_{N-1}\}, \quad (3.14)$$

代入式(3.13), 得

$$J_{N-1}(I_{N-1}) = E_{x_{N-1}} \{ x_{N-1}' K_{N-1} x_{N-1} | I_{N-1} \} \\ + E_{x_{N-1}} \{ [x_{N-1}' - E\{x_{N-1} | I_{N-1}\}]' P_{N-1} [x_{N-1} - E\{x_{N-1} | I_{N-1}\}] | I_{N-1} \} \\ + E_{w_{N-1}} \{ w_{N-1}' Q_N w_{N-1} \}, \quad (3.15)$$

式中矩阵 K_{N-1} 和 P_{N-1} 由下式给出

$$P_{N-1} = A_{N-1}' Q_N B_{N-1} (R_{N-1} + B_{N-1}' Q_N B_{N-1})^{-1} B_{N-1}' Q_N A_{N-1}, \\ K_{N-1} = A_{N-1}' Q_N A_{N-1} - P_{N-1} + Q_{N-1}.$$

除了 x_{N-1} 由条件期望 $E\{x_{N-1} | I_{N-1}\}$ 代替之外, 控制律式(3.4)与 § 2.1 中问题的相应最优控制律相同。也应注意到, 除了 $J_{N-1}(I_{N-1})$ 包含一个附加中间项之外, 余留代价 $J_{N-1}(I_{N-1})$ 与完全信息问题的余留代价存在着相应的类似性, 而中间项实际上是对估计误差的惩罚。

现在, 对周期 $N-2$ 的 DP 方程为

$$J_{N-2}(I_{N-2}) = \min_{u_{N-2}} \left[E_{x_{N-2}, w_{N-2}} \{ x_{N-2}' Q_{N-2} x_{N-2} + u_{N-2}' R_{N-2} u_{N-2} \right. \\ \left. + J_{N-1}(I_{N-1}) | I_{N-2}, u_{N-2} \} \right] \\ = \min_{u_{N-2}} \left[E_{x_{N-2}, w_{N-2}} \{ x_{N-2}' Q_{N-2} x_{N-2} + u_{N-2}' R_{N-2} u_{N-2} \right.$$

$$\begin{aligned}
& + (A_{N-2}x_{N-2} + B_{N-2}u_{N-2} + w_{N-2})' K_{N-1} (A_{N-2}x_{N-2} \\
& + B_{N-2}u_{N-2} + w_{N-2}) | I_{N-2} \}] \\
& + E \{ [x_{N-1} - E\{x_{N-1} | I_{N-1}\}]' P_{N-1} [x_{N-1} \\
& - E\{x_{N-1} | I_{N-1}\}] | I_{N-2}, u_{N-2} \} \\
& + E \{ w_{N-1}' Q_N w_{N-1} \}.
\end{aligned} \tag{3.16}$$

应注意，我们已经把倒数第二项排除在关于 u_{N-2} 求极小之外。之所以这样做，是因为这一项将被证明与 u_{N-2} 无关，这容易由下面的引理得出

引理 对每一个 k ，存在一个函数 F_k ，使得对所有策略，有

$$x_k - E\{x_k | I_k\} = F_k(x_0, w_0, \dots, w_{k-1}, v_0, \dots, v_k).$$

证明：固定一个策略，考虑下面具有相同初始条件 $x_0 = \bar{x}_0$ 的两个系统，在第一个系统中，控制由如下策略决定

$$x_{k+1} = A_k x_k + B_k u_k + w_k, \quad z_k = C_k x_k + v_k,$$

而在第二个系统中，没有控制

$$\bar{x}_{k+1} = A_k \bar{x}_k + w_k, \quad \bar{z}_k = C_k \bar{x}_k + v_k.$$

记

$$\begin{aligned}
z^k &= (z_0, \dots, z_k)', & \bar{z}^k &= (\bar{z}_0, \dots, \bar{z}_k)', \\
w^k &= (w_0, \dots, w_k)', & v^k &= (v_0, \dots, v_k)', \\
u^k &= (u_0, \dots, u_k)'.
\end{aligned}$$

线性性质说明存在矩阵 F_k , G_k 和 H_k ，使得

$$\begin{aligned}
x_k &= F_k x_0 + G_k u^{k-1} + H_k w^{k-1}, \\
\bar{x}_k &= F_k x_0 + H_k w^{k-1}.
\end{aligned}$$

因为 $u^{k-1} = E\{u^{k-1} | I_k\}$ ，这些方程产生

$$x_k - E\{x_k | I_k\} = \bar{x}_k - E\{\bar{x}_k | I_k\}. \text{ 证毕}$$

该引理主要是说，由误差 $x_k - E\{x_k | I_k\}$ 的统计所表示的估计质量不受控制选择的影响。这是因为系统和测量方程都是线性的。

现在转到我们的问题，利用最后阶段类似的论证，对方程(3.16)求极小得

$$\begin{aligned}
u_{N-2}^* &= \mu_{N-2}^*(I_{N-2}) = -(R_{N-2} + B_{N-2}' K_{N-1} B_{N-2})^{-1} \\
&\quad \times B_{N-2}' K_{N-1} A_{N-2} E\{x_{N-2} | I_{N-2}\}.
\end{aligned}$$

作类似处理，得到每一阶段的最优控制律：

$$\mu_k^*(I_k) = L_k E\{x_k | I_k\}. \tag{3.17}$$

式中

$$L_k = -(R_k + B_k' K_{k+1} B_k)^{-1} B_k' K_{k+1} A_k. \tag{3.18}$$

且矩阵 K_k 由黎卡提方程递推给出

$$K_N = Q_N. \tag{3.19}$$

$$K_k = A_k' [K_{k+1} - K_{k+1} B_k (R_k + B_k' K_{k+1} B_k)^{-1} B_k' K_{k+1}] A_k + Q_k. \tag{3.20}$$

将前面的观察一般化，我们注意到，除了状态 x_k 由它的条件期望取代之外，最优控制律式(3.17)与相应的 § 2.1 中完全状态信息问题的最优控制律相同。

有趣的是，最优控制器可以象图 3.1 所示分成两个部分：一个是估计器，它利用数据产




图 3.1 线性二次问题最优控制器的结构

生条件期望 $E\{x_k | I_k\}$ ；和一个执行器，它将 $E\{x_k | I_k\}$ 乘上增益矩阵 L_k ，施加于控制输入 $u_k = L_k E\{x_k | I_k\}$ 。而且增益矩阵 L_k 与问题的统计特性无关，和用在确定性问题的增益一样。在后一种情况下， w_k 和 x_0 固定并等于它们的期望值。另一方面，可以证明，在给定某个信息(随机向量) I 的条件下，随机向量 x 的估计 $\hat{x}$ ，它使均方误差 $E\{\|x - \hat{x}\|^2 | I\}$ 极小，且精确地等于条件期望 $E\{x | I\}$ (将二次式展开，并对 $\hat{x}$ 的导数置零)。这样，最优控制器的估计器部分，是无控制情况下估计状态 x_k 问题的最优解；而执行器部分是完全状态信息情况下控制问题的最优解。这个性质，说明最优控制器的两个部分，可以独立地设计成一个估计和一个控制问题的最优解，称作线性系统和二次代价的分离定理，它在现代自动控制理论中占有中心地位。

另一个有趣的结果是：在每时刻 k ，最优控制器要加的控制，就是当输入扰动 $w_k, w_{k+1}, \dots, w_{N-1}$ 和当前状态 x_k 已知，且它们的条件期望值分别固定为零和 $E\{x_k | I_k\}$ 时，所面临的使如下余留代价

$$x_N' Q_N x_N + \sum_{i=k}^{N-1} (x_i' Q_i x_i + u_i' R_i u_i),$$

为极小，确定性问题所要施加的控制。这是确定性等价原理的另一种形式。这在 § 2.1 中已提到。将此结论推广到相关扰动的情况，见习题 1。

实现方面：稳态控制器

如在完全信息情况下所阐述的，最优控制律的执行器部分的线性形式对于实现特别具有吸引力。然而在不完全信息情况下，我们面临构造出产生条件期望 $E\{x_k | I_k\}$ 的一个估计器的额外问题。一般来说，这种估计器的实现并不容易。然而在重要的特殊场合，当扰动 w_k, v_k 和初始条件 x_0 为高斯随机向量时，用卡尔曼滤波算法[K1]有可能方便地实现估计器。该算法给出了条件期望 $E\{x_k | I_k\}$ 。由于不确定性的高斯性质，它成为信息向量 I_k (注：即测量 $z_0, z_1, \dots, z_k$ 和控制 $u_0, u_1, \dots, u_{k-1}$) 的线性函数。然而，计算是按递推方式进行；为了产生 $E\{x_k | I_k\}$ ，只需要 k 时刻的最新量测 z_k 和控制 u_{k-1} ，以及 $E\{x_{k-1} | I_{k-1}\}$ 。算法的形式是

原注：实际上，对于 x_0, w_k, u_k 的更一般类型的概率分布，包括 Gauss 分布，作为特殊情况，包括及球面不变分布类[V9, B31]，可以证明条件期望 $E\{x_k | I_k\}$ 是 I_k 的线性函数。

[见[A1], [M6]]:

$$\begin{aligned} E\{x_{k+1} | I_{k+1}\} &= A_k E\{x_k | I_k\} + B_k u_k \\ &\quad + \Sigma_{k+1|k+1} C'_{k+1} N_{k+1}^{-1} [z_{k+1} - C_{k+1} (A_k E\{x_k | I_k\} + B_k u_k)], \\ k &= 0, 1, \dots, N-1, \end{aligned} \quad (3.21)$$

$$E\{x_0 | I_0\} = E\{x_0\} + \Sigma_{0|0} C'_0 N_0^{-1} [z_0 - C_0 E\{x_0\}], \quad (3.22)$$

式中, 矩阵 $\Sigma_{k|k}$ 是可以预先计算的, 并由递推方式给出

$$\Sigma_{k+1|k+1} = \Sigma_{k+1|k} - \Sigma_{k+1|k} C'_{k+1} (C_{k+1} \Sigma_{k+1|k} C'_{k+1} + N_{k+1})^{-1} C_{k+1} \Sigma_{k+1|k} \quad (3.23)$$

$$\Sigma_{k+1|k} = A_k \Sigma_{k|k} A'_k + M_k, \quad k = 0, 1, \dots, N-1, \quad (3.24)$$

且

$$\Sigma_{0|0} = S - SC'_0 (C_0 SC'_0 + N_0)^{-1} C_0 S.$$

在此方程中, M_k, N_k 和 S 分别为 w_k, v_k 和 x_0 的协方差阵, 而且我们假定 w_k 和 v_k 具有零均值; 即

$$\begin{aligned} E\{v_k\} &= E\{v_k\} = 0, \\ M_k &= E\{w_k w'_k\}, \quad N_k = E\{v_k v'_k\}, \\ S &= E\{[x_0 - E\{x_0\}][x_0 - E\{x_0\}]'\} \end{aligned}$$

另外, 矩阵 N_k 假定是正定的。

现在, 考虑系统和测量方程以及扰动的统计为平稳的情况。我们可以去掉系统矩阵的下标。假定 (A, B) 是能控的, (A, F) 是能观的, 其中 F 是一个矩阵, 满足 $Q = F'F$ 。由 § 2.1 的定理, 如果时域趋于无限, 最优控制器趋于稳态控制律

$$\mu^*(I_k) = L \hat{x}_k, \quad (3.25)$$

式中, 我们用记法

$$E\{x_k | I_k\} = \hat{x}_k, \quad L = -(R + B'KB)^{-1} B'KA, \quad (3.26)$$

而 K 是如下代数黎卡提方程

$$K = A'[K - KB(R + B'KB)^{-1} B'K]A + Q \quad (3.27)$$

的唯一半正定对称解。用相似论证, 当 $k \rightarrow \infty$ 取极限, $\hat{x}_k$ 可以由一个稳态卡尔曼滤波算法产生

$$\hat{x}_{k+1} = (A + BL) \hat{x}_k + \bar{\Sigma} C' N^{-1} [z_{k+1} - C(A + BL) \hat{x}_k], \quad (3.28)$$

式中, $\bar{\Sigma}$ 由下式给出

$$\bar{\Sigma} = \Sigma - \Sigma C' (C \Sigma C' + N)^{-1} C \Sigma, \quad (3.29)$$

而 Σ 是如下黎卡提方程

$$\Sigma = A[\Sigma - \Sigma C' (C \Sigma C' + N)^{-1} C \Sigma]A' + M \quad (3.30)$$

的唯一半正定解。假定 (A, C) 能观, (A, D) 能控, D 是一个矩阵, 使得 $M = DD'$, 则上式可用 § 2.1 的定理来证明。由于它的简单性, 方程(3.25)、(3.26)和(3.28)的稳态控制器对于实际实现特别具有吸引力。

§ 3.3 线性系统的最小方差控制

至此, 我们已经考虑了象在上节那样以状态变量形式表示的线性系统的控制。然而线性

系统常常用输入—输出方程来建模。根据描述系统动态行为所需参数的数目,后者更为经济。本节我们将考虑单输入、单输出、线性、有限维、因果性和时不变的系统,以及一个特殊类型的二次代价泛函。所得最优控制律特别简单,并且有广泛的用途。我们首先介绍关于输入—输出形式线性系统的基本结论。详细的讨论可在[A11]、[A12]、[G3]和[W12]找到。

一个单输入、单输出、线性、有限维、因果性和时不变的系统由如下形式的方程确定

$$y_k + a_1 y_{k-1} + \cdots + a_m y_{k-m} = b_0 u_k + b_1 u_{k-1} + \cdots + b_m u_{k-m}, \quad (3.31)$$

式中 a_i 和 b_i 是给定的标量。标量序列 $\{u_k | k=0, \pm 1, \pm 2, \dots\}$ 和 $\{y_k | k=0, \pm 1, \pm 2, \dots\}$ 分别为系统的输入和输出。

采用后向移位算子(记为 s)来描述这种类型的系统颇为方便。 s 对序列 $\{x_k | k=0, \pm 1, \pm 2, \dots\}$ 进行运算时, 它的下标移一单位; 即

$$s(x_k) = x_{k-1}, \quad k=0, \pm 1, \pm 2, \dots$$

我们用 s^r 表示 r 次连续使用 s 所产生的算子

$$s^r(x_k) = x_{k-r}, \quad k=0, \pm 1, \pm 2, \dots \quad (3.32)$$

为了简单起见, 写成 $s^r x_k = x_{k-r}$, 前向移位算子用 s^{-1} 表示, 它是 s 的逆算子, 定义为

$$s^{-1}(x_k) = x_{k+1}, \quad k=0, \pm 1, \pm 2, \dots$$

这样, 记法式(3.32)对所有整数 r 成立。我们可以把 s^r 形式的算子进行线性组合。例如, 算子 $(s + 2s^2)$ 定义为

$$(s + 2s^2)(x_k) = x_{k-1} + 2x_{k-2}, \quad k=0, \pm 1, \pm 2, \dots$$

用这个记法, 式(3.31)可写成

$$A(s)y_k = B(s)u_k, \quad (3.33)$$

式中 $A(s)$ 和 $B(s)$ 是算子

$$A(s) = 1 + a_1 s + \cdots + a_m s^m, \quad (3.34)$$

$$B(s) = b_0 + b_1 s + \cdots + b_m s^m. \quad (3.35)$$

有时把式(3.33)写成下式更为方便

$$y_k = \frac{B(s)}{A(s)} u_k$$

或

$$\frac{A(s)}{B(s)} y_k = u_k.$$

两个方程的意义是, 序列 $\{y_k\}$ 和 $\{u_k\}$ 通过式(3.33)建立联系。这有一定的随意性, 即对一个固定的 $\{u_k\}$, 方程(3.33)有无限多个以 $\{y_k\}$ 表示的解。例如, 对 $u_k \equiv 0$, 方程

$$y_k + a y_{k-1} = u_k$$

具有所有序列形式为 $y_k = \beta(-a)^k$ 的解, 式中 β 是任意标量。如即将要讨论的那样, 对稳定系统和对一个有界的序列 $\{u_k\}$ 存在一个有界的唯一解。这个解下面记为 $(B(s)/A(s))u_k$ 。注意, $B(s)/A(s)$ 在通常涉及的 z 变换线性系统, 可以看作为传递函数。

现在引入某些术语:

(a) 当 $\{y_k\}$, $\{u_k\}$ 满足 $A(s)y_k = B(s)u_k$ 时, 我们说 y_k 是通过滤波器 $B(s)/A(s)$ 传送 u_k 而得到的。这来自工程术语。在工程中, 线性时不变系统常常被称为滤波器。我们把方程 $A(s)y_k = B(s)u_k$ 也称为滤波器 $B(s)/A(s)$ 。

(b) 如果多项式 $A(s)$ 的所有(复)根严格在复平面的单位圆外, 即对所有满足 $A(\rho) = 0$

的复数 ρ , $|\rho| > 1$, 我们就说滤波器 $B(s)/A(s)$ 是稳定的。一个稳定的滤波器具有如下两个性质:

$$1. A(s)y_k = 0$$

的每一个解, 满足 $\lim_{k \rightarrow \infty} y_k = 0$; 即如果输入序列 $\{u_k\}$ 恒定为零, 输出 y_k 趋于零。

2. 对每一个有界序列 $\{\bar{u}_k\}$, 方程

$$A(s)y_k = B(s)\bar{u}_k$$

在有界序列类内有一个唯一解。而且方程的每一个解 $\{y_k\}$ (可能无界) 满足

$$\lim_{k \rightarrow \infty} (y_k - \bar{y}_k) = 0. \quad (3.36)$$

例如, 考虑系统

$$y_k - 0.5 y_{k-1} = u_k$$

给定有界的输入序列 $\bar{u}_k = \{\dots, 1, 1, 1, \dots\}$, 所有解的集合由

$$y_k = 2 + \frac{1}{2^k}$$

给出。但这些解中, 唯一的有界解是 $\bar{y}_k = \{\dots, 2, 2, 2, \dots\}$ 。

(c) 当多项式 $B(s)$ 的所有根严格在单位圆外时, 滤波器 $B(s)/A(s)$ 称为最小相位的。例如, 在 [P5] 中, 阐明了术语“最小相位”, 其原因我们在此并不关心。如果 $b_0 \neq 0$, 而滤波器 $B(s)/A(s)$ 是最小相位和稳定的, 则逆滤波器 $A(s)/B(s)$ 也是最小相位和稳定的。在这些条件下, 对每一个有界输出序列 $\{\bar{y}_k\}$ 存在唯一有界输入序列 $\{\bar{u}_k\}$ 满足

$$A(s)\bar{y}_k = B(s)\bar{u}_k.$$

具有随机输入线性时不变系统的建模

现在考虑一个具有输出 $\{y_k\}$, 控制输入 $\{u_k\}$ 和 零均随机输入 $\{w_k\}$ 的 随机、线性、时不变、有限维系统。假定 $\{w_k\}$ 是一个平稳的 (直至二阶) 随机过程, 即 $\{w_k\}$ 是一个定义在同一概率空间的随机变量序列, 对所有 $i, k = 0, \pm 1, \pm 2, \dots$, 满足

$$E\{w_k\} = 0, \quad E\{w_0 w_i\} = E\{w_k w_{k+i}\} < \infty.$$

(本节所有关于平稳过程都理解为刚才所述的有限意义。) 由线性性质知, y_k 是 $\{u_k\}$ 产生的序列和 $\{w_k\}$ 产生的序列之和。换句话说, 我们有

$$y_k = y_k^1 + y_k^2, \quad (3.37)$$

式中 y_k^1, y_k^2 对某些滤波器 $B_1(s)/A_1(s), B_2(s)/A_2(s)$ 满足

$$A_1(s)y_k^1 = B_1(s)u_k, \quad (3.38a)$$

$$A_2(s)y_k^2 = B_2(s)w_k. \quad (3.38b)$$

分别对式 (3.38a) 和式 (3.38b) 乘 $A_2(s)$ 和 $A_1(s)$, 然后相加并利用式 (3.37), 我们得到

$$\bar{A}(s)y_k = \bar{B}(s)u_k + v_k, \quad (3.39)$$

式中 $\bar{A}(s)$ 和 $\bar{B}(s)$ 是多项式。

$$\bar{A}(s) = A_1(s)A_2(s),$$

$$\bar{B}(s) = A_2(s)B_1(s),$$

$\{v_k\}$ 给定为

$$v_k = A_1(s)B_2(s)w_k. \quad (3.40)$$

它是零均值, 广义相关, 平稳的随机过程。

我们想象在 $y_k, y_{k-1}, \dots$ 已经产生和被观测之后施加控制输入 u_k 的情况。因此, 对式 (3.38) 中 $B_1(0)=0$ 的情况感兴趣。

所以, 对某些标量 $\bar{a}_i$ 和 $\bar{b}_i$, 以及某个正整数 m_0 多项式 $\bar{A}(s)$ 和 $\bar{B}(s)$ 具有如下形式

$$\bar{A}(s) = 1 + \bar{a}_1 s + \dots + \bar{a}_{m_0} s^{m_0},$$

$$\bar{B}(s) = \bar{b}_1 s + \dots + \bar{b}_{m_0} s^{m_0}.$$

总之, 我们已建立了具有如下形式的模型

$$\bar{A}(s)y_k = \bar{B}(s)u_k + v_k,$$

式中 $\bar{A}(s)$ 和 $\bar{B}(s)$ 是上面形式的多项式, $\{v_k\}$ 是某个零均值、相关、平稳的随机过程。

具有有理谱的随机过程

让我们稍微离开一下主题, 先来讨论式 (3.40) 随机过程 $\{v_k\}$ 的本质。给定一个零均值的平稳标量过程 $\{v_k\}$, 用 $C(k)$ 表示自相关函数

$$C(k) = E\{v_i v_{i+k}\}, \quad k = 0, \pm 1, \pm 2, \dots$$

我们说 $\{v_k\}$ 具有有理谱, 如果对 $\lambda \in [-\pi, \pi]$, 存在由下式

$$S_v(\lambda) = \sum_{k=-\infty}^{\infty} C(k) e^{-j k \lambda} = C(0) + 2 \sum_{k=1}^{\infty} C(k) \cos(k\lambda)$$

定义的 $\{C(k)\}$ 变换且可表示成

$$S_v(\lambda) = \sigma^2 \frac{|B(e^{j\lambda})|^2}{|A(e^{j\lambda})|^2}, \quad \lambda \in [-\pi, \pi]. \quad (3.41)$$

式中 σ 是一个标量, $A(z)$ 和 $B(z)$ 是具有实系数的某些多项式

$$A(z) = 1 + a_1 z + \dots + a_m z^m, \quad (3.42a)$$

$$B(z) = 1 + b_1 z + \dots + b_m z^m, \quad (3.42b)$$

且 $A(z)$ 在单位圆 $\{z \mid |z| = 1\}$ 上无根。

我们有如下事实:

(a) 如果 $\{v_k\}$ 是一个白噪声过程, 且对 $k \neq 0$, 有 $C(0) = \sigma^2$, $C(k) = 0$, 则

$$S_v(\lambda) = \sigma^2, \quad \lambda \in [-\pi, \pi],$$

显然, $\{v_k\}$ 有有理谱。

(b) 如果 $\{v_k\}$ 有式 (3.41) 所给定的有理谱, 则 S_v 可以写成

$$S_v(\lambda) = \bar{\sigma}^2 \frac{|\tilde{B}(e^{j\lambda})|^2}{|\tilde{A}(e^{j\lambda})|^2}, \quad \lambda \in [-\pi, \pi],$$

式中 $\bar{\sigma}$ 是一个标量, 而 $\tilde{A}(z)$, $\tilde{B}(z)$ 均为具有如下形式的唯一实多项式

$$\tilde{A}(z) = 1 + \tilde{a}_1 z + \dots + \tilde{a}_m z^m,$$

$$\tilde{B}(z) = 1 + \tilde{b}_1 z + \dots + \tilde{b}_m z^m$$

满足:

1. $\tilde{A}(z)$ 所有的根严格在单位圆外;
 2. $\tilde{B}(z)$ 所有的根严格在单位圆外或圆上; 如果 $B(z)$ 无根在单位圆上, 则 $\tilde{B}(z)$ 亦然。
- 注意, 若 $\rho \neq 0$ 是 $A(z)$ 的一个根, 则 $|A(e^{j\lambda})|^2 = A(e^{j\lambda})A(e^{-j\lambda})$, 含一个因子

$(1 - \rho^{-1}e^{j\lambda})(1 - \rho^{-1}e^{-j\lambda}) = \rho^{-2}(1 - \rho e^{j\lambda})(1 - \rho e^{-j\lambda})$, 就可以得出以上结果。稍加思考即表明, 根据 ρ 在单位圆外或圆内就决定了 $\tilde{A}(z)$ 的根应是 ρ 或 ρ^{-1} , 同样, $\tilde{B}(z)$ 的根由 $B(z)$ 的根求得。这样, 多项式 $\tilde{A}(z)$ 和 $\tilde{B}(z)$ 以及 σ^2 可唯一确定。不失一般性, 我们可假定式(3.41)中 $A(z)$ 和 $B(z)$ 在单位圆内无根。

(c) 如果 $\{v_k\}$ 是平稳的, 具有有理谱 $S_v(\lambda)$; 而 $\{w_k\}$ 是另一个平稳过程, 它通过一个稳定线性滤波器 $B_1(s)/A_1(s)$ 传送 v_k 而得到, 即

$$A_1(s)w_k = B_1(s)v_k,$$

则 $\{w_k\}$ 具有有理谱 S_w 给定为

$$S_w(\lambda) = \frac{|B_1(e^{j\lambda})|^2}{|A_1(e^{j\lambda})|^2} S_v(\lambda), \quad \lambda \in [-\pi, \pi].$$

特别地, 若 $\{v_k\}$ 是白噪声, $E\{v_k^2\} = \sigma^2$ 则

$$S_w(\lambda) = \sigma^2 \frac{|B_1(e^{j\lambda})|^2}{|A_1(e^{j\lambda})|^2}, \quad \lambda \in [-\pi, \pi].$$

利用定义, 其证明是直接的。例如在[P5], 这是一个给定的标准事实。

(d) 下面一个论断很难严格证明, 我们以命题形式来阐述, 证明见[A10, PP75-76]。

命题 如果 $\{v_k\}$ 是一个零均值的平稳随机过程, 具有有理谱

$$S_v(\lambda) = \sigma^2 \frac{|B(e^{j\lambda})|^2}{|A(e^{j\lambda})|^2}, \quad \lambda \in [-\pi, \pi],$$

式中 A, B 由式(3.42)给出。假定(不失一般性)在单位圆内无根, 则存在一个零均值的平稳白噪声过程 $\{\epsilon_k\}$ (定义在与 $\{v_k\}$ 相同的概率空间上), 且有 $E\{\epsilon_k^2\} = \sigma^2$ 、使得对所有 k

$$v_k + a_1 v_{k-1} + \cdots + a_m v_{k-m} = \epsilon_k + b_1 \epsilon_{k-1} + \cdots + b_m \epsilon_{k-m}.$$

(从数学的高度看, 我们注意到这个关系式是 P 几乎处处成立的, 而 P 是空间的概率测度。)

ARMAX 模型

现在我们回到具有随机输入线性系统的表示问题。我们已有了模型式(3.39)

$$\bar{A}(s)y_k = \bar{B}(s)u_k + v_k.$$

如果零均值平稳过程 $\{v_k\}$ 具有有理谱, 则前面的分析和命题说明存在一个零均值的平稳白噪声过程 $\{\epsilon_k\}$, 满足

$$D(s)v_k = C(s)\epsilon_k, \quad (3.43)$$

式中多项式 $C(s)$ 和 $D(s)$ 有如下形式

$$C(s) = 1 + c_1 s + \cdots + c_{m-1} s^{m-1},$$

$$D(s) = 1 + d_1 s + \cdots + d_{m-1} s^{m-1},$$

$C(s)$ 无根在单位圆内。将式(3.39)两边乘 $D(s)$, 利用式(3.43)得

$$A(s)y_k = B(s)u_k + C(s)\epsilon_k, \quad (3.44)$$

式中

$$A(s) = D(s)\bar{A}(s),$$

$$B(s) = D(s)\bar{B}(s).$$

根据 $A(0) = 1, B(0) = 0$ 的事实, 对某个整数 m 和标量 $a_1, \cdots, a_m, b_1, \cdots, b_m, c_1, \cdots, c_m$ 可以写出

$$A(s) = 1 + a_1 s + \cdots + a_m s^m,$$

$$B(s) = b_1 s + \cdots + b_m s^m,$$

$$C(s) = 1 + c_1 s + \cdots + c_m s^m,$$

并将式(3.44)写成:

$$y_k + a_1 y_{k-1} + \cdots + a_m y_{k-m} = b_1 u_{k-1} + \cdots + b_m u_{k-m} + \epsilon_k + c_1 \epsilon_{k-1} + \cdots + c_m \epsilon_{k-m}. \quad (3.45)$$

式(3.45)是我们要采用的一个模型。不失一般性,我们假定 $C(s)$ 严格地在单位圆内无根。方程(3.45)称之为 ARMAX(Auto Regressive Moving Average, with eXogenous input, 带外生输入的自回归滑动平均)模型。在后面各节的许多分析中,必须排除 $C(s)$ 在单位圆上有根的临界情况,并假定滤波器 $C(s)/A(s)$ 为最小相位。在绝大多数实际情况下,这个假设是满足的。

如果 $C(s) = 1$, 噪声项序列 $C(s)\epsilon_k = \epsilon_k$ 为白噪声,则在几种情况下,有关 ARMAX 模型

$$A(s)y_k = B(s)u_k + C(s)\epsilon_k$$

的分析和算法可以大大简化。然而,以前的分析说明,这是一个典型的不现实的假设。为了强调这一点,并理解噪声如何易于相互关联,假定有一个一阶系统

$$x_{k+1} = ax_k + w_k,$$

我们观测

$$y_k = x_k + v_k$$

则

$$\begin{aligned} y_{k+1} &= x_{k+1} + v_{k+1} \\ &= ax_k + w_k + v_{k+1} \\ &= a(y_k - v_k) + w_k + v_{k+1}, \end{aligned}$$

所以最后

$$y_{k+1} = ay_k + v_{k+1} - av_k + w_k.$$

然而噪声序列 $\{v_{k+1} - av_k + w_k\}$ 是相关的,即使 $\{v_k\}$ 和 $\{w_k\}$ 是相互独立的白噪声过程。

ARMAX 模型式(3.45)可以写成状态空间形式。其过程基于状态增广,用例子说明也许能最好地理解。考虑系统

$$y_k + a_1 y_{k-1} = b_1 u_{k-1} + b_2 u_{k-2} + \epsilon_k + c_1 \epsilon_{k-1} \quad (3.46)$$

我们有

$$\begin{bmatrix} y_{k+1} \\ u_k \\ \epsilon_{k+1} \end{bmatrix} = \begin{bmatrix} -a_1 & b_2 & c_1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} y_k \\ u_{k-1} \\ \epsilon_k \end{bmatrix} + \begin{bmatrix} b_1 \\ 1 \\ 0 \end{bmatrix} u_k + \begin{bmatrix} \epsilon_{k+1} \\ 0 \\ \epsilon_{k+1} \end{bmatrix}, \quad (3.47)$$

令

$$\begin{aligned} x_k &= \begin{bmatrix} y_k \\ u_{k-1} \\ \epsilon_k \end{bmatrix}, & w_k &= \begin{bmatrix} \epsilon_{k+1} \\ 0 \\ \epsilon_{k+1} \end{bmatrix}, \\ A &= \begin{bmatrix} -a_1 & b_2 & c_1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}, & B &= \begin{bmatrix} b_1 \\ 1 \\ 0 \end{bmatrix}, \end{aligned}$$

我们可以把式(3.47)写成

$$x_{k+1} = Ax_k + Bu_k + w_k, \quad (3.48)$$

式中 $\{w_k\}$ 是一个平稳的白噪声过程。通过状态增广，我们得到了状态空间模型。注意：状态 x_k 包括 ϵ_k 。这样，如果假定控制器在时刻 k 只知道现在和过去的输出 $y_k, y_{k-1}, \dots$ ，以及过去的控制 $u_{k-1}, u_{k-2}, \dots$ ，（但不知道 $\epsilon_{k-1}, \epsilon_{k-2}, \dots$ ），我们就面临一个不完全状态信息模型。如果式(3.46) $c_1 = 0$ ，则状态空间模型可以简化，使得

$$x_k = \begin{bmatrix} y_k \\ u_{k-1} \end{bmatrix}.$$

在这种情况下，我们有完全状态信息。更一般地说，当且仅当 $b_1 \neq 0, c_1 = c_2 = \dots = c_m = 0$ ，ARMAX模型式(3.45)有完全状态信息。

最小方差控制：完全状态信息情况

考虑 ARMAX 模型式(3.45)的完全状态信息情况：

$$y_k + a_1 y_{k-1} + \dots + a_m y_{k-m} = b_1 u_{k-1} + \dots + b_m u_{k-m} + \epsilon_k, \quad (3.49)$$

式中 $b_1 \neq 0$ ，我们希望使代价

$$E \left\{ \sum_{k=1}^N |y_k|^2 \right\} \quad (3.50)$$

极小。知道现在和过去的输出 $y_k, y_{k-1}, \dots$ ，以及过去的控制 $u_{k-1}, u_{k-2}, \dots$ ，在时刻 k ，控制器施加 u_k, u_k 无约束。将系统变换成状态空间形式之后，我们看到这个问题可以简化成完全状态信息线性二次问题。它包含一个具有如下形式的系统：

$$x_{k+1} = Ax_k + Bu_k + w_k,$$

式中 x_k 是向量

$$[y_k, y_{k-1}, \dots, y_{k-m+1}, u_{k-1}, \dots, u_{k-m+1}]'$$

除了二次代价泛函中相应的矩阵 R_k 为零以外，这个问题和§2.1的问题具有相同的本质。不过，在§2.1，我们利用了 R_k 的可逆性，只是为了保证最优控制律和黎卡提方程的各种矩阵可逆。如果这些矩阵的可逆性能够通过其它方程得以保证，即使 R_k 非正定，仍然可用相同分析。包含系统式(3.49)和代价泛函式(3.50)的问题正是这种情况。与§2.1类似的分析表明，时刻 k 的最优控制 u_k^* （给定 $y_k, y_{k-1}, \dots, y_{k-m+1}, u_{k-1}, \dots, u_{k-m+1}$ ），等于所有未来扰动 $\epsilon_{k+1}, \dots, \epsilon_N$ 置为零（它们的期望值）时所施加的控制（确定性等价）。从而得出

$$\begin{aligned} \mu_k^*(y_k, \dots, y_{k-m+1}, u_{k-1}, \dots, u_{k-m+1}) \\ = \frac{1}{b_1} (a_1 y_k + \dots + a_m y_{k-m+1} - b_2 u_{k-1} - \dots - b_m u_{k-m+1}), \end{aligned}$$

$\{u_k^*\}$ 通过方程

$$\begin{aligned} b_1 u_k^* + b_2 u_{k-1}^* + \dots + b_m u_{k-m+1}^* \\ = a_1 y_k + a_2 y_{k-1} + \dots + a_m y_{k-m+1} \end{aligned} \quad (3.51)$$

产生。换句话说， $\{u_k^*\}$ 是 $\{y_k\}$ 通过线性滤波器 $\bar{A}(s)/\bar{B}(s)$ 而产生的。其中

$$\bar{A}(s) = a_1 + a_2 s + \dots + a_m s^{m-1}, \quad (3.52)$$

$$\bar{B}(s) = b_1 + b_2 s + \dots + b_m s^{m-1}, \quad (5.53)$$

如图 3.2 所示，所得闭环系统为

$$y_k = \bar{e}_k \quad (3.54)$$

相应的代价为

$$NE\{\epsilon_k^2\}$$

注意,称为最小方差控制律的最优控制律是时不变的,并与时域 N 无关。

由于式(3.54)所给定的最优闭环系统显然是稳定的,可以预料,如果在反馈回路中滤波器 $\bar{A}(s)/\bar{B}(s)$ 不稳定,就会有严重困难。如果 $\bar{B}(s)$ 有某些根在单位圆内,则序列 $\{u_k\}$ 将趋于无界,这可由下例说明。

例题

考虑系统

$$y_k + y_{k-1} = u_{k-1} - 2u_{k-2} + \epsilon_k.$$

最优控制律为

$$u_k = y_k + 2u_{k-1},$$

最优闭环系统为

$$y_k = \epsilon_k,$$

这是一个稳定系统。另一方面,由这两个方程得

$$u_k = \epsilon_k + 2u_{k-1}$$

从而, u_k 由不稳定系统产生,且事实上由

$$u_k = \sum_{n=0}^k 2^n \epsilon_{k-n}.$$

给出。所以,即使输出 y_k 保持有界,控制 u_k 却以概率 1 变为无界。

用另一种观点来看一下这同一个困难。假定 $\bar{B}(s)$ 的系数 $b_1, b_2, \dots, b_m$ 与真实系统的系数稍有差别。我们将证明,如果反馈滤波器 $\bar{A}(s)/\bar{B}(s)$ 不稳定,则闭环系统在 u_k 和 y_k 二者以概率 1 变成无界的意义上也不稳定。

假定系统受下式支配

$$A^0(s)y_k = B^0(s)u_k + \epsilon_k, \quad (3.55)$$

在假设系统模型为

$$A(s)y_k = B(s)u_k + \epsilon_k,$$

时,计算得控制律。式中 $A(s)$ 和 $B(s)$ 与 $A^0(s)$ 和 $B^0(s)$ 稍有差别, $\bar{A}_0(s)$, $\bar{B}_0(s)$ 由下式定义

$$1 + s\bar{A}^0(s) = A^0(s), \quad (3.56a)$$

$$s\bar{B}^0(s) = B^0(s). \quad (3.56b)$$

如果 $A^0(s) = A(s)$, $B^0(s) = B(s)$, 则 $\bar{A}^0(s) = \bar{A}(s)$, $\bar{B}^0(s) = \bar{B}(s)$ 。式(3.55)乘上 $\bar{B}(s)$, 并利用控制律关系式

$$\bar{B}(s)u_k = \bar{A}(s)y_k,$$

我们得到

$$\bar{B}(s)A^0(s)y_k = B^0(s)\bar{A}(s)y_k + \bar{B}(s)\epsilon_k.$$

利用式(3.56), 消去 $A^0(s)$ 和 $B^0(s)$, 得闭环系统




图 3.2 具有完全状态信息的最小方差控制。最优闭环系统结构, 其中 $A(s) = 1 + a_1s + \dots + a_ms^m$, $B(s) = b_1s + \dots + b_ms^m$, $\bar{A}(s) = s^{-1}(A(s) - 1)$, $\bar{B}(s) = s^{-1}B(s)$ 。

$$\{\bar{B}(s) + s[\bar{B}(s)\bar{A}^0(s) - \bar{B}^0(s)\bar{A}(s)]\}y_k = \bar{B}(s)\epsilon_k$$

如果 $\bar{A}^0(s)$ 和 $\bar{B}^0(s)$ 的系数与 $\bar{A}(s)$, $\bar{B}(s)$ 接近, 则多项式

$$\bar{B}(s) + s[\bar{B}(s)\bar{A}^0(s) - \bar{B}^0(s)\bar{A}(s)]$$

的根接近 $\bar{B}(s)$ 的根。仅当 $\bar{B}(s)$ 的根在单位圆外, 闭环系统是稳定的, 即滤波器 $\bar{A}(s)/\bar{B}(s)$ 是稳定的。如果模型精确, 闭环系统将会由于通常所说的零极点相消而稳定。然而最微小的建模误差就会引起不稳定。

由以上分析可以得出结论: 仅当最小方差控制律可以通过一个稳定滤波器 $[\bar{B}(s)$ 的根在单位圆外]来实现时, 才是可取的。即使 $\bar{B}(s)$ 的根在单位圆外, 但其中某些根接近单位圆, 则最小方差控制律的特性会对多项式 $A(s)$ 和 $B(s)$ 的参数非常敏感。克服这种敏感性的一种方法, 是将代价变成

$$E \left\{ \sum_{k=1}^N (|y_k|^2 + R|u_{k-m}|^2) \right\},$$

式中 R 是某个正参数, 这和 § 2.1 一样, 要通过黎卡提方程求解。详细推导见 [A12]

在某些问题中, 系统方程包括一个附加的外部输入序列 $\{v_k\}$, 当它们发生时, 其值可以由控制器测得。考虑标量系统

$$\begin{aligned} y_k + a_1 y_{k-1} + \cdots + a_m y_{k-m} \\ = b_1 u_{k-1} + \cdots + b_m u_{k-m} + d_1 v_{k-1} + \cdots + d_m v_{k-m} + \epsilon_k, \end{aligned}$$

式中 $\{v_k\}$ 是一个任意序列, v_k 的值可以在时刻 k 由控制器无误差地测得。因此, 最小方差控制器有如下形式

$$\begin{aligned} \mu_k^*(y_k, \dots, y_{k-n+1}, u_{k-1}, \dots, u_{k-m+1}, v_k, \dots, v_{k-m+1}) \\ = \frac{1}{b_1} (a_1 y_k + \cdots + a_m y_{k-m+1} \\ - d_1 v_k - \cdots - d_m v_{k-m+1} - b_2 u_{k-1} \cdots - b_m u_{k-m+1}). \end{aligned}$$

且 $\{u_k^*\}$ 由下式产生

$$\bar{B}(s)u_k^* = \bar{A}(s)y_k - \bar{D}(s)v_k,$$

式中

$$\begin{aligned} \bar{A}(s) &= a_1 + a_2 s + \cdots + a_m s^{m-1}, \\ \bar{B}(s) &= b_1 + b_2 s + \cdots + b_m s^{m-1}, \\ \bar{D}(s) &= d_1 + d_2 s + \cdots + d_m s^{m-1}. \end{aligned}$$

闭环系统仍是 $y_k = \epsilon_k$ 。但为了实际的目的, 仅当 $\bar{B}(s)$ 的根在单位圆外时, 系统才稳定。靠测量外部输入且用作控制的过程, 通常称为前馈控制。

不完全状态信息情况

现在考虑一般的 ARMAX 模型

$$\begin{aligned} y_k + a_1 y_{k-1} + \cdots + a_m y_{k-m} \\ = b_M u_{k-M} + \cdots + b_m u_{k-m} + \epsilon_k + c_1 \epsilon_{k-1} + \cdots + c_n \epsilon_{k-n}. \end{aligned}$$

或等价地

$$A(s)y_k = B(s)u_k + C(s)\epsilon_k,$$

其中

$$A(s) = 1 + a_1 s + \cdots + a_m s^m,$$

$$B(s) = b_M s^M + \cdots + b_m s^m,$$

$$C(s) = 1 + c_1 s + \cdots + c_m s^m.$$

我们作以下假定:

1. $b_M \neq 0$, 且 $1 \leq M \leq m$.
2. $\{\epsilon_k\}$ 为零均值的平稳白噪声过程。
3. 多项式 $C(s)$ 所有根在单位圆外(如前所述, 这个假定并不过于受限制)。

在每个时刻 k , 控制器知道现在和过去的输出 $y_k, y_{k-1}, \dots, y_{-m+1}, u_{k-1}, u_{k-2}, \dots, u_{-m+M}$ 。这样, 在时刻 k 的信息向量为

$$I_k = (y_k, y_{k-1}, \dots, y_{-m+1}, u_{k-1}, u_{k-2}, \dots, u_{-m+M}), \quad (3.57)$$

u_k 无约束, 问题是寻找一个控制律 $\{\mu_0(I_0), \dots, \mu_{N-1}(I_{N-1})\}$ 使

$$E \left\{ \sum_{k=1}^N |y| k^2 \right\}.$$

极小。利用状态增广方法, 这个问题可以纳入 § 3.2 线性二次问题的框架。以状态空间格式表示的相应线性系统包含一个状态 x_k , 它由下式给定

$$x_k = (y_{k+M-1}, \dots, y_{k+N-m}, u_{k-1}, \dots, u_{k+M-m}, \epsilon_{k+M-1}, \dots, \epsilon_{k+M-m}).$$

因为控制器不知道 $y_{k+M-1}, \dots, y_{k+1}$ 和 $\epsilon_{k+M-1}, \dots, \epsilon_{k+M-m}$, 所以我们面临一个不完全状态信息问题。用与 § 3.2 相似的分析表明, 在时刻 k (给定 I_k) 的最优控制 u_k^* , 如同在确定性问题中, 将当前状态

$$x_k = (y_{k+M-1}, \dots, y_{k+M-m}, u_{k-1}, \dots, u_{k+M-m}, \epsilon_{k+M-1}, \dots, \epsilon_{k+M-m}),$$

设置成给定 I_k 时的条件期望值, 将未来扰动 $\epsilon_{k+M}, \dots, \epsilon_N$ 设置成零(它们的期望值)时所要施加的控制一样。

因此, 最优控制 $u_k^* = \mu_k^*(I_k)$ 是使 $E\{y_{k+N} | u_k, I_k\} = 0$ 的控制, 并由如下方程求解 u_k 而得:

$$E\{y_{k+N} | y_k, \dots, y_{-m+1}, u_k, u_{k-1}, \dots, u_{-m+M}\} = 0. \quad (3.58)$$

这就导致计算这个条件期望值, 即预报或预测的问题, 它具有应有的重要性。

ARMAX 模型的预报

给定 $A(s)$ 和 $C(s)$, 我们可以得到以下形式的 $F(s)$ 和 $G(s)$

$$F(s) = 1 + f_1 s + \cdots + f_{M-1} s^{M-1}, \quad (3.59)$$

$$G(s) = g_0 + g_1 s + \cdots + g_{m-1} s^{m-1}. \quad (3.60)$$

满足

$$C(s) = A(s)F(s) + s^M G(s). \quad (3.61)$$

$F(s)$ 和 $G(s)$ 的系数唯一由 $C(s)$ 和 $A(s)$ 确定, 只要使如下关系式两边相等

$$1 + c_1 s + \cdots + c_m s^m = (1 + a_1 s + \cdots + a_m s^m)(1 + f_1 s + \cdots + f_{M-1} s^{M-1}) + s^M(g_0 + g_1 s + \cdots + g_{m-1} s^{m-1})$$

例题:

令 $m=3$, $M=2$, 则上述方程取如下形式:

$$1 + c_1 s + c_2 s^2 + c_3 s^3 = (1 + a_1 s + a_2 s^2 + a_3 s^3)(1 + f_1 s) + s_2(g_0 + g_1 s + g_2 s^2),$$

使系数相等, 我们有

$$\begin{aligned} c_1 &= a_1 + f_1, \quad c_2 = a_2 + a_1 f_1 + g_0, \\ c_3 &= a_3 + a_2 f_1 + g_1, \quad a_3 f_1 + g_2 = 0. \end{aligned}$$

由此, f_1, g_0, g_1 , 和 g_2 就唯一确定。

ARMAX 模型可写成为

$$A(s)y_{k+M} = \bar{B}(s)u_k + C(s)\epsilon_{k+M}, \quad (3.62)$$

式中

$$\bar{B}(s) = s^{-M}B(s) = b_M + b_{M+1}s + \cdots + b_ms^{m-M}$$

式(3.62)两边乘上 $F(s)$, 我们有

$$F(s)A(s)y_{k+M} = F(s)\bar{B}(s)u_k + F(s)C(s)\epsilon_{k+M},$$

利用式(3.61), 得

$$C(s)[y_{k+M} - F(s)\epsilon_{k+M}] = F(s)\bar{B}(s)u_k + G(s)y_k. \quad (3.63)$$

令

$$\begin{aligned} z_{k+M} &= y_{k+M} - F(s)\epsilon_{k+M} \\ &= y_{k+M} - \epsilon_{k+M} - f_1\epsilon_{k+M-1} - \cdots - f_{M-1}\epsilon_{k+1}, \end{aligned} \quad (3.64)$$

$$w_k = F(s)\bar{B}(s)u_k + G(s)y_k. \quad (3.65)$$

则式(3.63)写成

$$C(s)z_{k+M} = w_k$$

或

$$z_{k+M} + c_1 z_{k+M-1} + \cdots + c_m z_{k+M-m} = w_k. \quad (3.66)$$

现在对 z_{k+M} 进行两种基本观察:

(a) 由式(3.64)以及 $\{\epsilon_k\}$ 是独立零均值序列的事实, 有

$$E\{z_{k+M} | I_k, u_k\} = E\{y_{k+M} | I_k, u_k\},$$

所以, 我们只需预报 z_{k+M} , 就可得到所需的 y_{k+M} 的预报值。

(b) 在时刻 k , 式(3.65)的标量 w_k 是可利用的(即由 I_k 和 u_k 确定)。所以, 式(3.66)可以作为利用 w_k 预报 z_{k+M} 的一个基础。特别地, 预报值 $E\{z_{k+M} | I_k\}$ 可以由 $\hat{y}_{k+M}$ 来近似, 而 $\hat{y}_{k+M}$ 由下式产生

$$\hat{y}_{k+m} + c_1 \hat{y}_{k+m-1} + \cdots + c_m \hat{y}_{k+M-m} = w_k. \quad (3.67)$$

其初始条件为

$$\hat{y}_{M-1} = \hat{y}_{M-2} = \cdots = \hat{y}_{M-m} = 0. \quad (3.68)$$

为了看清这一点, 注意到由式(3.66)到式(3.68), 有

$$z_{k+L} = \hat{y}_{k+M} + [\gamma_1(k)z_{M-1} + \cdots + \gamma_m(k)z_{M-m}], \quad (3.69)$$

和

$$E\{z_{k+M} | I_k, u_k\} = \hat{y}_{k+M} + \sum_{i=1}^m \gamma_i(k)E\{z_{M-i} | I_k, u_k\},$$

式中 $\gamma_1(k), \cdots, \gamma_m(k)$ 是依赖于 k 的适当标量。因为 $C(s)$ 所有的根在单位圆内, 我们有(与本节关于稳定性的讨论进行比较)

$$\lim_{k \rightarrow \infty} \gamma_1(k) = \lim_{k \rightarrow \infty} \gamma_2(k) = \cdots = \lim_{k \rightarrow \infty} \gamma_m(k) = 0, \quad (3.70)$$

由此, 对大的 k 值

$$\hat{y}_{k+M} \simeq E\{z_{k+M} | I_k, u_k\} = E\{y_{k+M} | I_k, u_k\}.$$

(更确切地说, 当 $k \rightarrow \infty$, 有 $|\hat{y}_{k+M} - E\{y_{k+M} | I_k, u_k\}| \rightarrow 0$, 它是在均方意义上收敛。)

总之, 对最优预报 $E\{y_{k+M} | I_k, u_k\}$ 的一个近似式, 是由如下方程产生的 $\hat{y}_{k+M}$ 给出:

$$\hat{y}_{k+M} + c_1 \hat{y}_{k+M-1} + \cdots + c_m \hat{y}_{k+M-m} = F(s) \bar{B}(s) u_k + G(s) y_k \quad (3.71)$$

其初始条件为

$$\hat{y}_{M-1} = \hat{y}_{M-2} = \cdots = \hat{y}_{M-m} = 0. \quad (3.72)$$

最小方差控制: 不完全状态信息情况

从以前讨论知, 最小方差控制律是由对 u_k 求解方程式(3.58)而得到。这里重复:

$$E\{y_{k+M} | I_k, u_k\} = 0.$$

于是, 通过设置 u_k 的值使 $\hat{y}_{k+M} = 0$, 即对 u_k 求解方程[参阅式(3.71)和式(3.72)]:

$$F(s) \bar{B}(s) u_k + G(s) y_k = c_1 \hat{y}_{k+M-1} + \cdots + c_m \hat{y}_{k+M-m}.$$

可以得到一个合理的近似值。然而, 如果遵循这一策略, 以前的预报 $\hat{y}_{k+M-1}, \cdots, \hat{y}_{k+M-m}$ 将等于零。这样, (近似)的最小方差控制律由下式给出

$$F(s) \bar{B}(s) u_k + G(s) y_k = 0. \quad (3.73)$$

即如图 3.3 所示, u_k^* 是使 y_k 通过线性滤波器 $-G(s)/F(s) \bar{B}(s)$ 而产生的。

由式(3.63)和式(3.73), 我们得到闭环系统方程:

$$C(s)[y_{k+M} - F(s) \epsilon_{k+M}] = 0.$$

因为 $C(s)$ 的根在单位圆外, 我们得

$$y_{k+M} = F(s) \epsilon_{k+M} + \gamma(k),$$

式中, 当 $k \rightarrow \infty$ 时, $\gamma(k) \rightarrow 0$, 所以, 闭环系统渐近地取如下形式

$$y_k = \epsilon_k + f_1 \epsilon_{k-1} + \cdots + f_{M-1} \epsilon_{k-M+1}$$

现在, 我们考虑当真实系统参数与所假定的模型参数略有差别时, 闭环系统的稳定性特性。

设真实系统由下式描述:

$$A^0(s) y_k = s^M \bar{B}^0(s) u_k + C^0(s) \epsilon_k, \quad (3.74)$$

而 u_k 由如下最小方差控制律给定

$$F(s) \bar{B}(s) u_k + G(s) y_k = 0, \quad (3.75)$$

式中

$$C(s) = A(s) F(s) + s^M G(s).$$

对式(3.74)乘以 $F(s) \bar{B}(s)$, 并利用式(3.75), 得

$$F(s) \bar{B}(s) A^0(s) y_k = -s^M \bar{B}^0(s) G(s) y_k + F(s) \bar{B}(s) C^0(s) \epsilon_k.$$

把最后两个方程联合并项, 我们有

$$\{F(s) \bar{B}(s) A^0(s) + [C(s) - A(s) F(s)] \bar{B}^0(s)\} y_k = F(s) \bar{B}(s) C^0(s) \epsilon_k$$

或

$$\{\bar{B}^0(s) C(s) + F(s) [\bar{B}(s) A^0(s) - A(s) \bar{B}_0(s)]\} y_k = F(s) \bar{B}(s) C^0(s) \epsilon_k.$$




图 3.3 具有不完全状态信息的最小方差控制, 最优闭环系统的结构

如果 $A^0(s)$, $\bar{B}^0(s)$ 和 $C^0(s)$ 的系数与 $A(s)$, $\bar{B}(s)$ 和 $C(s)$ 的系数接近, 则闭环系统的极点将与 $\bar{B}(s)C(s)$ 的根相近。这样, 仅当 $\bar{B}(s)$ 的根严格在单位圆之外, 闭环系统实际上才是稳定的。这与前面已讨论过的完全状态信息情况类似。

例题:

考虑无时延情况 ($M=1$)。由式(3.61), 我们有

$$G(s) = S^{-1}[C(s) - A(s)], \quad F(s) = 1,$$

再由式(3.73), 利用 $\bar{B}(s) = S^{-1}B(s)$, 得

$$B(s)u_k = [A(s) - C(s)]y_k.$$

等价地, u_k 通过如下方程产生

$$u_k = -\frac{1}{b_1} [(a_1 - c_1)y_k + \cdots + (a_m - c_m)y_{k-m+1} - b_2 u_{k-1} - \cdots - b_m u_{k-m+1}]$$

闭环系统给定为

$$y_k - \epsilon_k + c_1(y_{k-1} - \epsilon_{k-1}) + \cdots + c_m(y_{k-m} - \epsilon_{k-m}) = 0,$$

或等价地, $C(s)(y_k - \epsilon_k) = 0$ 。因为 $C(s)$ 的根在单位圆外, 这是一个稳定系统, 而且有

$$y_k = \epsilon_k + \gamma(k),$$

式中, 当 $k \rightarrow \infty$ 时, $\gamma(k) \rightarrow 0$ 。

§ 3.4 充分统计和有限状态马尔科夫链: 一个示教问题

DP 算法式(3.7)和式(3.8)的主要困难是在维数扩展的状态空间中进行。在每个阶段, 当加一个新的测量时, 状态(信息向量 I_k)的维数也相应地增大。这促使人们尽力缩减控制真正所需的数据。换句话说, 我们对寻求称之为充分统计的量感兴趣, 理想上充分统计量的维数小于 I_k 。但就控制而言, 它综合了 I_k 所有的本质内容。

为了方便起见, 将算法式(3.7)和式(3.8)重述于此

$$J_{N-1}(I_{N-1}) = \min_{u_{N-1} \in U_{N-1}} \left[E \{ g_N [f_{N-1}(x_{N-1}, u_{N-1}, w_{N-1})] + g_{N-1}(x_{N-1}, u_{N-1}, w_{N-1}) | I_{N-1}, u_{N-1} \} \right], \quad (3.76)$$

$$J_k(I_k) = \min_{u_k \in U_k} \left[E \{ g_k(x_k, u_k, w_k) + J_{k+1}(I_k, z_{k+1}, u_k) | I_k, u_k \} \right]. \quad (3.77)$$

假设我们能找到一个信息向量 I_k 的函数 $S_k(\cdot)$, 使得式(3.76)和式(3.77)中极小化的控制通过 $S_k(I_k)$ 依赖于 I_k 。这意味着 DP 算法式(3.76)和式(3.77)右边的极小化, 可根据某个函数 H_k 写成

$$\min_{u_k \in U_k} H_k[S_k(I_k), u_k].$$

这样一个函数 $S_k(\cdot)$ 将称为一个充分统计量。其显著的特点是, 由前述极小化所得的一个最优控制律可以写成

$$\mu_k(I_k) = \bar{\mu}_k[S_k(I_k)],$$

式中 $\bar{\mu}_k$ 是一个适当的函数。于是, 如果充分统计量由一个比信息向量 I_k 元素少的集合来表

征, 则可较方便地以形式 $u_k = \bar{u}_k[S_k(I_k)]$ 来实现控制律, 并使用有成效的数据压缩。

有许多不同的函数可以当作充分统计量。单位函数 $S_k(I_k) = I_k$ 肯定是其中之一。如果我们假定观测扰动 v_{k+1} 的概率分布只明显依赖于当前的状态、控制和系统扰动 x_k, u_k, w_k , 而不依赖于 $x_{k-1}, \dots, x_0, u_{k-1}, \dots, u_0, w_{k-1}, \dots, w_0, v_{k-1}, \dots, v_0$, 就得到另一个重要的充分统计量。在这个假设条件下可以证明, 当给定信息向量 I_k 时, 充分统计由状态 x_k 的条件概率测度 $P_{x_k|I_k}$ 给出。

证明 $P_{x_k|I_k}$ 是一个充分统计, 需要一个独立的有趣的推导。一个关键的事实是 $P_{x_k|I_k}$ 按时间递推产生, 而且可以看作一个受控离散时间动态系统的状态。应用贝叶斯规则, 对所有 k , 可以写成

$$P_{x_{k+1}|I_{k+1}} = \Phi_k(P_{x_k|I_k}, u_k, z_{k+1}), \quad (3.78)$$

式中 Φ_k 是可以由问题的数据决定的某个函数, u_k 是系统的控制, z_{k+1} 起随机扰动的作用, 它的统计是已知的, 且明显依赖于 $P_{x_k|I_k}$ 和 u_k , 而与 $z_k, \dots, z_0$ 无关。这个事实最好用例子来说明。

例题:

在一个典型搜索问题中, 每一周期必须决定是否搜索可能藏有财宝的地方。如果有财宝存在, 搜索以概率 β 将其发掘出来。在这种情况下, 财宝从藏处取走。

记 p_k 为在周期 k 开始时存在财宝的概率。这一概率按如下方程演变:

$$p_{k+1} = \begin{cases} p_k, & \text{若在时刻 } k \text{ 未搜索藏宝地方,} \\ 0, & \text{若搜索藏宝地方, 并在周期 } k \text{ 找到财宝,} \\ \frac{p_k(1-\beta)}{p_k(1-\beta) + 1 - p_k}, & \text{若搜索藏宝地方, 但在周期 } k \text{ 未找到财宝.} \end{cases}$$

第二个关系式成立, 因为在一次成功的搜索之后财宝被取走。第三个关系式是通过应用贝叶斯规则得到 (p_{k+1} 是第 k 周期有财宝搜索不成功的概率, 然后除以不成功搜索的概率)。上面的方程定义了式 (3.78) 形式的一个动态系统。这里控制 u_k 取两个值: 搜索或不搜索。如果搜索藏宝地方, 观测 z_{k+1} 取两个值: 找到财宝或找不到。在未搜索藏宝地方时, z_{k+1} 的值是无关紧要的。

关于方程 (3.78) 的一般形式, 在习题 7 中对状态、控制、观测和扰动空间均为有限集的情况进行了推导。在空间为实线且所涉及的随机变量具有概率密度函数的情况下, 条件密度 $p(x_{k+1}|I_{k+1})$ 可由 $p(x_k|I_k), u_k$ 和 z_{k+1} 按如下方程产生:

$$\begin{aligned} p(x_{k+1}|I_{k+1}) &= p(x_{k+1}|I_k, u_k, z_{k+1}) \\ &= \frac{p(x_{k+1}, z_{k+1}|I_k, u_k)}{p(z_{k+1}|I_k, u_k)} \\ &= \frac{p(p_{k+1}|I_k, u_k)p(z_{k+1}|I_k, u_k, x_{k+1})}{\int_{-\infty}^{\infty} p(x_{k+1}|I_k, u_k)p(z_{k+1}|I_k, u_k, x_{k+1})dx_{k+1}}. \end{aligned}$$

在这个方程中, 出现在右边的概率密度可以仅由 $p(x_k|I_k), u_k$ 和 z_{k+1} 来表示。特别地, 利用给定的密度 $p(w_k|x_k, u_k)$ 和关系式:

$$p(w_k|I_k, u_k) = \int_{-\infty}^{\infty} p(x_k|I_k)p(w_k|x_k, u_k)dx_k.$$

密度 $p(x_{k+1} | I_k, u_k)$ 可以通过 $p(x_k | I_k), u_k$, 和系统方程 $x_{k+1} = f_k(x_k, u_k, w_k)$ 来表示。

类似地, 利用 $p(x_k | I_k), p(w_k | x_k, u_k)$ 和给定的概率密度 $p(v_{k+1} | x_k, u_k, w_k)$, 密度 $p(z_{k+1} | I_k, u_k, x_{k+1})$ 可以通过测量方程 $z_{k+1} = h_{k+1}(x_{k+1}, u_k, v_{k+1})$ 来表示。把这些表达式代入 $p(x_{k+1} | I_{k+1})$ 的方程, 我们得到式 (3.78) 形式的一个方程式。在以后各节中, 将给出方程具有式 (3.78) 形式的其他明显的例子。关于式 (3.78) 数学上严格的陈述和相应的 DP 算法可在 [B23] 中找到。在任何情况下, 可以看到, 由式 (3.78) 描述的系统适合基本问题的框架。而且, 在时刻 k , 控制器可以计算出 (至少在原则上) 条件概率测度: $P_{x_k | I_k}$ 。所以, 在系统式 (3.78), 控制器具有完全状态信息。现在利用新的系统方程 (3.78), 根据充分统计 $P_{x_k | I_k}$, DP 算法式 (3.76) 和式 (3.77) 可以写成如下形式:

$$\bar{J}_{N-1}(P_{x_{N-1} | I_{N-1}}) = \min_{u_{N-1} \in U_{N-1}} \left[E_{x_{N-1}, w_{N-1}} \{ g_N[f_{N-1}(x_{N-1}, u_{N-1}, w_{N-1})] \right. \\ \left. + g_{N-1}(x_{N-1}, u_{N-1}, w_{N-1}) | I_{N-1}, u_{N-1} \} \right], \quad (3.79)$$

$$\bar{J}_k(P_{x_k | I_k}) = \min_{u_k \in U_k} \left[E_{x_k, w_k, z_{k+1}} \{ g_k(x_k, u_k, w_k) \right. \\ \left. + \bar{J}_{k+1}[\Phi_k(P_{x_k | I_k}, u_k, z_{k+1})] | I_k, u_k \} \right]. \quad (3.80)$$

而且, 这个 DP 算法获得一个形式为

$$u_k^* = \bar{u}_k^*(P_{x_k | I_k}), \quad k=0, 1, \dots, N-1.$$

的控制律。另外, 最优代价由下式给出

$$J^* = E_{z_0} \{ \bar{J}_0(P_{x_0 | z_0}) \},$$

式中 $\bar{J}_0$ 由算法式 (3.79) 和式 (3.80) 的最后一步求得。 z_0 的概率测度是由 x_0 和 v_0 的统计特性和测量方程 $z_0 = h_0(x_0, v_0)$ 求得。

实际上, 前面的分析是一个具有不完全状态信息的问题, 替换和简化成一个含有系统式 (3.78), 其状态为 $P_{x_k | I_k}$, 和一个适当地变换过的代价泛函的完全状态信息问题。可以得出一个结论: 条件概率 $P_{x_k | I_k}$ 综合了在周期 k 控制所需的全部信息。在不存在状态的完全知识时, 控制器可看成控制“概率的状态” $P_{x_k | I_k}$, 以便在信息 I_k 可用的条件下, 使期望代价极小。

不管它的计算值如何, 最优控制律表示为一个条件概率分布 $P_{x_k | I_k}$ 的函数序列

$$\mu_k(I_k) = \bar{u}_k(P_{x_k | I_k}), \quad k=0, 1, \dots, N-1,$$

在概念上是有帮助的。它将最优控制器分解成两部分: (1) 估计器。它在时刻 k , 利用测量 z_k 和控制 u_{k-1} 产生概率分布 $P_{x_k | I_k}$; (2) 执行器。它产生作为概率分布 $P_{x_k | I_k}$ 函数的一个系统的控制输入 (图 3.4)。除了概念上和分析上的重要性之外, 这种解释已经形成不同次优控制方案的基础。它预先将控制器分割成一个估计器和一个执行器, 并力图把每一部分按似乎是“合理的”方式进行设计。在第四章将提出这种类型的设计方案。

当系统是一个有限状态马尔科夫链时, 条件概率分布 $P_{x_k | I_k}$ 是由数的有限集合来表征。这特别方便, 而且, 当控制和观测空间也是有限集合时, 情况将进一步简化。这使得




图 3.4 最优控制器概念上分离成一个估计器和一个执行器

DP 算法式(3.79)和式(3.80)中余留代价函数 $\bar{J}_k$ 是分段线性且凹的。这一事实的演示是直接的,但也是冗长的,并在习题 7 中列出了概要。 $\bar{J}_k$ 的分段线性是一个重要性质,因为它说明 $\bar{J}_k$ 可以由一个标量的有限集合来表征。然而对固定的 k , 这些标量的数目仍旧会随 N 迅速增加,且还没有计算上的有效方法来解决这一问题([见 P3])。这里我们不讨论计算 $\bar{J}_k$ 的特殊程序([见 S21], [S23]), 而是举例演示 DP 算法。第一个例子,即示教例子在本节讨论。下一节处理第二个例子,即假设检验问题。

一个示教问题

考虑一个示教问题,其目的是教会学生一个简单的课目。在每一周期开始时,学生可以处在两种可能状态之一:

- x^1 学会了课目,
- x^2 未学会课目。

在每个周期开始,教师必须作出两个决定之一:

- u^1 结束教课,
- u^2 继续教一个周期,然后进行测验看学生是否学会这课目。

测验有两种可能的结果:

- z^1 学生给出正确答案,
- z^2 学生给出错误答案。

示教进行时,从一个状态到另一个状态的转移概率,由下式给出:

$$\begin{aligned} P(x_{k+1} = x^1 | x_k = x^1) &= 1, & P(x_{k+1} = x^2 | x_k = x^1) &= 0, \\ P(x_{k+1} = x^1 | x_k = x^2) &= t, & P(x_{k+1} = x^2 | x_k = x^2) &= 1-t, & 0 < t < 1. \end{aligned}$$

测验的结果在概率上依赖于学生如下的知识状态:

$$\begin{aligned} P(z_k = z^1 | x_k = x^1) &= 1, & P(z_k = z^2 | x_k = x^1) &= 0, \\ P(z_k = z^1 | x_k = x^2) &= r, & P(z_k = z^2 | x_k = x^2) &= 1-r, & 0 < r < 1. \end{aligned}$$

每周期教学和测验代价为 I 。如果学生已学会或还未学会,结束教学的代价分别为零和 $C > 0$ 。目的是寻找每一周期 k 的“教学—结束”策略,它是自然增长到该周期的测验信息的函数,使总的期望代价极小。这里假定存在最大为 N 周期的教学过程。

容易把这个问题变换并纳入具有不完全状态信息基本问题的框架。而且得出结论:在周

期 k 是否继续或结束教学的决策, 依赖于给定迄今为止测验结果情况下, 学生已学会课目的条件概率。这概率表示为

$$p_k = P(x_k = x^1 | z_0, z_1, \dots, z_k).$$

此外, 我们可以利用定义在充分统计 p_k 空间上的 DP 算法式(3.79)和式(3.80), 得到最优策略。然而, 我们不希望用这种复杂的过程, 希望直接论证并得到该 DP 算法。

关于条件概率 p_k (假定教学进行) 的演变, 按贝叶斯规则有

$$\begin{aligned} p_{k+1} &= P(x_{k+1} = x^1 | z_0, \dots, z_{k+1}) \\ &= \frac{P(x_{k+1} = x^1, z_{k+1} | z_0, \dots, z_k)}{P(z_{k+1} | z_0, \dots, z_k)} \\ &= \frac{P(x_{k+1} = x^1 | z_0, \dots, z_k) P(z_{k+1} | z_0, \dots, z_k, x_{k+1} = x^1)}{\sum_{i=1}^2 P(x_{k+1} = x^i | z_0, \dots, z_k) P(z_{k+1} | z_0, \dots, z_k, x_{k+1} = x^i)} \end{aligned}$$

由给定的概率描述, 我们有

$$\begin{aligned} P(z_{k+1} | z_0, \dots, z_k, x_{k+1} = x^1) &= P(z_{k+1} | x_{k+1} = x^1) \\ &= \begin{cases} 1, & \text{若 } z_{k+1} = z^1, \\ 0, & \text{若 } z_{k+1} = z^2, \end{cases} \\ P(z_{k+1} | z_0, \dots, z_k, x_{k+1} = x^2) &= P(z_{k+1} | x_{k+1} = x^2) \\ &= \begin{cases} r, & \text{若 } z_{k+1} = z^1, \\ 1-r, & \text{若 } z_{k+1} = z^2, \end{cases} \\ P(x_{k+1} = x^1 | z_0, \dots, z_k) &= p_k + (1-p_k)t, \\ P(x_{k+1} = x^2 | z_0, \dots, z_k) &= (1-p_k)(1-t). \end{aligned}$$

把这些方程合并, 得到

$$p_{k+1} = \Phi(p_k, z_{k+1}),$$

式中函数 Φ 定义为

$$\Phi(p_k, z_{k+1}) = \begin{cases} \frac{p_k + (1-p_k)t}{p_k + (1-p_k)t + (1-p_k)(1-t)r}, & \text{若 } z_{k+1} = z^1, \\ 0, & \text{若 } z_{k+1} = z^2. \end{cases}$$

或等价地

$$\Phi(p_k, z_{k+1}) = \begin{cases} \frac{1 - (1-t)(1-p_k)}{1 - (1-t)(1-r)(1-p_k)}, & \text{若 } z_{k+1} = z^1, \\ 0, & \text{若 } z_{k+1} = z^2. \end{cases} \quad (3.81)$$

仔细检验这些方程表明, 如所期望的那样, 学生已学到的课目的条件概率随每一正确回答而增加; 随错误的回答而降低到零。我们还要指出, 方程(3.81)是方程(3.78)的一个特殊情况。因为除了终止只有一个可能的行动, 函数 Φ 时 u_k 的依赖不明显地表示出来。

现在, 我们转到关于该问题 DP 算法的推导上。在第 N 周期末, 假定教学已继续到该周期, 期望代价为

$$\bar{J}_N(P_N) = (1 - p_N)C \quad (3.82)$$

在第 $N-1$ 周期, 教师已计算出学生学到课目的条件概率 p_{N-1} , 希望决定是否停止教学并达到期望代价 $(1 - p_{N-1})C$ 或继续教学并达到期望代价 $I + E_{z_N}\{\bar{J}_N(p_N)\}$ 。这就导出以下最优期

望余留代价的方程:

$$\bar{J}_{N-1}(p_{N-1}) = \min[(1-p_{N-1})C, I + E_{z_N} \{\bar{J}_N[\Phi(p_{N-1}, z_N)]\}].$$

同样, 用 $k+1$ 代替 N , 对每一阶段 k , 算法写成:

$$\bar{J}_k(p_k) = \min[(1-p_k)C, I + E_{z_{k+1}} \{\bar{J}_{k+1}[\Phi(p_k, z_{k+1})]\}].$$

现在利用函数 Φ 的表达式(3.81)和概率

$$P(z_{k+1} = z^2 | p_k) = (1-t)(1-r)(1-p_k),$$

$$P(z_{k+1} = z^1 | p_k) = 1 - (1-t)(1-r)(1-p_k),$$

有

$$\bar{J}_k(p_k) = \min[(1-p_k)C, I + A_k(p_k)], \quad (3.83)$$

式中

$$\begin{aligned} A_k(p_k) = & [1 - (1-t)(1-r)(1-p_k)] \bar{J}_{k+1} \left[\frac{1 - (1-t)(1-p_k)}{1 - (1-t)(1-r)(1-p_k)} \right] \\ & + (1-t)(1-r)(1-p_k) \bar{J}_{k+1}(0) \end{aligned} \quad (3.84)$$

特别地, 利用式(3.82)到式(3.4), 直接计算得

$$\begin{aligned} \bar{J}_{N-1}(p_{N-1}) &= \min[(1-p_{N-1})C, I + A_{N-1}(p_{N-1})] \\ &= \min[(1-p_{N-1})C, I + (1-t)(1-p_{N-1})C]. \end{aligned}$$

这样, 如图 3.5 所示, 如果

$$I + (1-t)C < C, \quad (3.85)$$




图 3.5 在最后周期, 确定最优教学策略

则存在一个标量 α_{N-1} , 且 $0 < \alpha_{N-1} < 1$, 它决定最后周期的最优策略:

继续教学, 若 $p_{N-1} \leq \alpha_{N-1}$,

停止教学, 若 $p_{N-1} > \alpha_{N-1}$

利用式(3.84)可以证明(习题 8), 在式(3.85)条件下, 对每一 k , 函数 $A_k(p)$ 为凹和分段线性的, 并对所有 k 满足

$$A_k(1) = 0. \quad (3.86)$$

而且, 对所有 k , 它们满足

$$A_k(p) \geq A_k(p'), \quad \text{对 } 0 \leq p < p' \leq 1, \quad (3.87)$$

$$A_{k-1}(p) \leq A_k(p) \leq A_{k+1}(p), \quad \text{对所有 } p \in [0, 1]. \quad (3.88)$$

这样, 由 DP 算法式(3.83)和方程(3.86)~(3.88)得出: 对每一周期的最优策略是由唯一的标量 α_k 所决定。此 α_k 使

$$(1 - \alpha_k)C = I + A_k(\alpha_k), \quad k = 0, 1, \dots, N-1.$$

对周期 k , 最优策略由下式给出

继续教学, 若 $p_k \leq \alpha_k$,

停止教学, 若 $p_k > \alpha_k$ 。

因为对于 k , 函数 $A_k(p)$ 为单调非降的, 由图 3.6 得出:

$$\alpha_{N-1} \leq \alpha_{N-2} \leq \dots \leq \alpha_k \leq \alpha_{k-1} \leq \dots \leq 1 - \frac{I}{C},$$

所以当 $k \rightarrow -\infty$ 时, 序列 $\{\alpha_k\}$ 收敛到某个标量 $\bar{\alpha}$ 。因此, 当时域增长时, 最优策略(至少对最初的某些阶段可以由平稳策略来近似)是

$$\text{若 } p_k \leq \bar{\alpha}, \text{ 继续教学,} \quad (3.89)$$

$$\text{若 } p_k > \bar{\alpha} \text{ 停止教学。}$$




图 3.6 教学阈值随时间而减少的图示

这个平稳策略实现方便, 它不需要每一阶段计算条件概率。由方程(3.81), 我们知道, 如果给出正确回答 z^1 , p_{k+1} 超过 p_k ; 如果给出错误回答 z^2 , p_{k+1} 降为零。

递推地定义概率

$$\pi_1 = \Phi(0, z^1), \pi_2 = \Phi(\pi_1, z^1), \dots, \pi_{k+1} = \Phi(\pi_k, z^1), \dots,$$

令 n 为 $\pi_n > \bar{\alpha}$ 的最小整数, 显然, 可以实现平稳策略如下:

如果收到 n 个相继的正确回答, 停止教学;

否则, 继续进行教学。

§ 3.5 假设检验：序列概率比检验

本节中，我们考虑一个典型的统计序列分析的假设检验问题。一个决策者相对于两种假设，可以各以代价 C 进行观测。给定一个新的观测，他或者接受两种假设之一；或者推迟一个周期以上的再决策，且付代价为 C ，得到一个新的观测。问题是在观测代价和以较高概率接受错误假设之间进行折衷。

令 $z_0, z_1, \dots, z_{N-1}$ 为观测序列。我们假定它们是独立恒定分布的随机变量，在有限集合中取值。假定我们知道 z_k 的概率分布是 f_0 或 f_1 ，我们试图决定其中之一正确。这里，对任意元 $z \in Z$ ， $f_0(z)[f_1(z)]$ 表示当 f_0 或 (f_1) 是真实分布时 z 的概率。在时刻 k ，观测 $z_0, \dots, z_k$ ，之后，我们或停止观测，且接受 f_0 或 f_1 ，或者以代价 $C > 0$ ，进行一个新的观测。如果我们停止观测且做出选择，若选择正确，就不造成损失；如果不正确地选择 f_0 或 f_1 ，代价分别为 L_0 和 L_1 。真实分布为 f_0 的先验概率 p 是给定的，且假定至多能进行 N 次观测。

容易理解，我们面临一个具有不完全状态信息的问题，它包括两个状态：

x^0 ：真实分布为 f_0 ，

x^1 ：真实分布为 f_1 。

充分统计的 DP 算法式(3.79)和式(3.80)定义在如下条件概率的可能值的 $[0, 1]$ 区间上：

$$p_k = P(x_k = x^0 | z_0, \dots, z_k).$$

类似地，如在上节一样，我们将直接地推得算法。

按照如下方程，条件概率 p_k 递推地产生，[假定对所有 $z \in Z$ ， $f_0(z) > 0$ ， $f_1(z) > 0$]：

$$p_{k+1} = \frac{p_k f_0(z_{k+1})}{p_k f_0(z_{k+1}) + (1-p_k) f_1(z_{k+1})}, \quad k=0, 1, \dots, N-2, \quad (3.90)$$

$$p_0 = \frac{p f_0(z_0)}{p f_0(z_0) + (1-p) f_1(z_0)}, \quad (3.91)$$

这里 p 是真实分布为 f_0 的先验概率。对于最后周期，最优期望代价为

$$\bar{J}_{N-1}(p_{N-1}) = \min[(1-p_{N-1})L_0, p_{N-1}L_1], \quad (3.92)$$

式中 $(1-p_{N-1})L_0$ 是接受 f_0 的期望代价， $p_{N-1}L_1$ 是接受 f_1 的期望代价。把式(3.90)和式(3.91)考虑进去，我们由如下方程得到第 k 周期最优期望余留代价

$$\bar{J}_k(p_k) = \min \left[(1-p_k)L_0, p_k L_1, \right. \\ \left. C + E_{z_{k+1}} \left\{ \bar{J}_{k+1} \left[\frac{p_k f_0(z_{k+1})}{p_k f_0(z_{k+1}) + (1-p_k) f_1(z_{k+1})} \right] \right\} \right],$$

式中对 z_{k+1} 的期望是相对于概率分布

$$p(z_{k+1}) = p_k f_0(z_{k+1}) + (1-p_k) f_1(z_{k+1}), \quad z_{k+1} \in Z,$$

进行。等价地，对 $k=0, 1, \dots, N-1$ ，

$$\bar{J}_k(p_k) = \min[(1-p_k)L_0, p_k L_1, C + A_k(p_k)], \quad (3.93)$$

式中

$$A_k(p_k) = E_{z_{k+1}} \left\{ \bar{J}_{k+1} \left[\frac{p_k f_0(z_{k+1})}{p_k f_0(z_{k+1}) + (1-p_k) f_1(z_{k+1})} \right] \right\}. \quad (3.94)$$

最后周期的最优策略(见图 3.7)是由式(3.92)给出的求极小获得:

若 $p_{N-1} \geq \mu$, 接受 f_0 ,

若 $p_{N-1} < \mu$, 接受 f_1 .

式中 μ 由关系式 $(1-\mu)L_0 = \mu L_1$ 决定, 或等价地

$$\mu = \frac{L_0}{L_0 + L_1}.$$

现在, 我们证明如下引理.




图 3.7 在最后周期决定最优策略

引理: 式(3.94)的函数 $A_k: [0, 1] \rightarrow R$ 是凹的, 且对所有 k 和 $p \in [0, 1]$, 满足

$$A_k(0) = A_k(1) = 0,$$

$$A_{k-1}(p) \leq A_k(p).$$

证明: 对所有 $p \in [0, 1]$, 我们有

$$\bar{J}_{N-2}(p) \leq \min[(1-p)L_0, pL_0] = \bar{J}_{N-1}(p).$$

利用系统的平稳性以及 DP 的单调性(第一章习题 24), 对所有 k 和 $p \in [0, 1]$ 我们得,

$$\bar{J}_k(p) \leq \bar{J}_{k+1}(p).$$

利用式(3.94), 对所有 k 和 $p \in [0, 1]$, 我们有 $A_{k-1}(p) \leq A_k(p)$.

为了根据式(3.92)和式(3.93)证明 A_k 的凹性, 只要证明 $\bar{J}_{k+1}$ 为凹性, 通过关系式(3.94)意味着 A_k 为凹性就行了. 事实上, 假定 $\bar{J}_{k+1}$ 在 $[0, 1]$ 区间是凹的, 令 $z^1, z^2, \dots, z^n$ 表示观测空间 Z 的元, 由式(3.94)我们有

$$A_k(p) = \sum_{i=1}^n [pf_0(z^i) + (1-p)f_1(z^i)] \bar{J}_{k+1} \left[\frac{pf_0(z^i)}{pf_0(z^i) + (1-p)f_1(z^i)} \right].$$

因此, 只要证明 $\bar{J}_{k+1}$ 的凹性意味着如下各函数为凹性就行了

$$h_i(p) = [pf_0(z^i) + (1-p)f_1(z^i)] \bar{J}_{k+1} \left[\frac{pf_0(z^i)}{pf_0(z^i) + (1-p)f_1(z^i)} \right].$$

为了证明 h_i 的凹性, 我们必须证明, 对每一个 $\lambda \in [0, 1]$, $p_1, p_2 \in [0, 1]$, 我们有

$$\lambda h_i(p_1) + (1-\lambda)h_i(p_2) \leq h_i[\lambda p_1 + (1-\lambda)p_2].$$

利用记法

$$\xi_1 = p_1 f_0(z^i) + (1-p_1)f_1(z^i), \quad \xi_2 = p_2 f_0(z^i) + (1-p_2)f_1(z^i),$$

上述不等式等价于

$$\begin{aligned} & \frac{\lambda \xi_1}{\lambda \xi_1 + (1-\lambda) \xi_2} \bar{J}_{k+1} \left[\frac{p_1 f_0(z')}{\xi_1} \right] + \frac{(1-\lambda) \xi_2}{\lambda \xi_1 + (1-\lambda) \xi_2} \bar{J}_{k+1} \left[\frac{p_2 f_0(z')}{\xi_2} \right] \\ & \leq \bar{J}_{k+1} \left[\frac{(\lambda p_1 + (1-\lambda) p_2) f_0(z')}{\lambda \xi_1 + (1-\lambda) \xi_2} \right]. \end{aligned}$$

这个关系已由 $\bar{J}_{k+1}$ 的凹性证明。证毕。

利用这个引理，我们得(见图 3.8)：如果

$$C + A_{N-2}[L_0/(L_0 + L_1)] < L_0 L_1 / (L_0 + L_1),$$

则对各周期 k 的最优策略形式为

若 $p_k \geq \alpha_k$ ，接受 f_0 ，

若 $p_k \leq \beta_k$ ，接受 f_1 ，

若 $\beta_k < p_k < \alpha_k$ ，继续观测。

这里标量 α_k, β_k 由以下关系式确定：

$$\beta_k L_1 = C + A_k(\beta_k),$$

$$(1 - \alpha_k) L_0 = C + A_k(\alpha_k).$$




图 3.8 确定最优假设检验策略

而且我们有

$$\dots \leq \alpha_{k+1} \leq \alpha_k \leq \alpha_{k-1} \leq \dots \leq 1 - \frac{C}{L_0},$$

$$\dots \geq \beta_{k+1} \geq \beta_k \geq \beta_{k-1} \geq \dots \geq \frac{C}{L_1}$$

因此，当 $N \rightarrow \infty$ 时，序列 $\{\alpha_{N-i}\}, \{\beta_{N-i}\}$ 分别收敛到 $\bar{\alpha}, \bar{\beta}$ ，且最优策由如下平稳策略近似：

若 $p_k \geq \bar{\alpha}$ ，接受 f_0 ，

若 $p_k \leq \bar{\beta}$ ，接受 f_1 。

(3.95)

若 $\bar{\beta} < p_k < \bar{\alpha}$, 继续观测。

现在条件概率 p_k 由下式给出

$$p_k = \frac{p f_0(z_0) f_0(z_1) \cdots f_0(z_k)}{p f_0(z_0) \cdots f_0(z_k) + (1-p) f_1(z_0) \cdots f_1(z_k)}. \quad (3.96)$$

式中 p 是 f_0 为真实假设的先验概率。利用式(3.96)平稳策略(3.95)可以写成如下形式:

$$\begin{aligned} \text{若 } R_k \geq A = \frac{(1-p)\bar{\alpha}}{p(1-\alpha)}, & \quad \text{接受 } f_0, \\ \text{若 } R_k \leq B = \frac{(1-p)\bar{\beta}}{p(1-\beta)}, & \quad \text{接受 } f_1. \end{aligned} \quad (3.97)$$

若 $B < R_k < A$, 继续观测。

式中序列概率比 R_k 由下式给出

$$R_k = \frac{f_0(z_0) \cdots f_0(z_k)}{f_1(z_0) \cdots f_1(z_k)}.$$

利用递推方程

$$R_{k+1} = \frac{f_0(z_{k+1})}{f_1(z_{k+1})} R_k.$$

可容易产生 R_k 。过程(3.97)称为序列概率比检验。这种过程属于统计序列分析的第一种形式化方法[W1]。对于该问题无限时域形式, 策略(3.95)的最优性将在 § 6.3 节证明。

§ 3.6 注 记

关于具有不完全状态信息线性二次问题方面的文献, 请参阅 § 2.1 所列文献, 以及威辛豪森的综述文章[W16]。卡尔曼滤波算法[K1]是众所周知的广泛应用的工具, 具体讨论可在许多教课书中找到[A1, J3, L8, M6, M7, N1]。关于具有高斯不确定性的线性二次问题, 及习题 6 中心内容的观测代价, 请参阅[A4]和[C3]。当随机扰动相关时, 说明确定性等价原理的习题, 是基于作者未发表的报告[B8]。最小方差方法在[A11], [A13]和[W12]中也有描述。

通过一个充分统计量进行数据压缩的概念, 随着 1965 年 Stribel 的论文[S26]得到广泛注意(亦可参阅[S27, S31])。关于在序列极小极大问题中充分统计概念的类比, 请参阅[B22]。

通过充分统计, 对具有不完全状态信息马尔科夫链的控制问题的分析可能性, 已研究了很长时间, 在[E2]、[S21]和[S23]已有所发现。余留代价函数分段线性的证明及计算方法在[S21]和[S23]中给出。在 § 3.4 描述的示教模型已经有许多作者研究过, 具有几种变型[A14, G4, K3, S20]。

关于序列概率比检验及有关课题, 参阅[C1], [D1], [W11]以及其中所引参考文献。本节所给的处理方法来源于[A6]。

习 题

1. 考虑 § 3.2 的线性系统和测量方程, 并考虑寻求一个控制律 $\{\mu_0^*(I_0), \dots, \mu_{N-1}^*(I_{N-1})\}$ 使二次代价

$$E\left\{x_N' Q x_N + \sum_{k=0}^{N-1} u_k' R_k u_k\right\}.$$

极小的问题。假定随机向量 $x_0, w_0, \dots, w_{N-1}, v_0, \dots, v_{N-1}$ 相关, 并有给定的联合概率分布和有限的一阶及二阶矩。证明最优控制律由下式给出

$$\mu_k^*(I_k) = L_k E\{y_k | I_k\},$$

式中增益矩阵由如下递推算法求得:

$$L_k = -(B_k' K_{k+1} B_k + R_k)^{-1} B_k' K_{k+1} A_k,$$

$$K_N = Q,$$

$$K_k = A_k' [K_{k+1} - K_{k+1} B_k (B_k' K_{k+1} B_k + R_k)^{-1} B_k' K_{k+1}] A_k,$$

且向量 y_k 由下式给出

$$y_k = x_k + A_k^{-1} w_k + A_k^{-1} A_{k+1}^{-1} w_{k+1} + \dots + A_k^{-1} \dots A_{N-1}^{-1} w_{N-1}.$$

(假定矩阵 $A_0, A_1, \dots, A_{N-1}$ 为可逆)。提示: 证明代价可写成为如下形式:

$$E\left\{y_0' K_0 y_0 + \sum_{k=0}^{N-1} (u_k - L_k y_k)' p_k (u_k - L_k y_k)\right\},$$

式中

$$p_k = B_k' K_{k+1} B_k + R_k.$$

2. 考虑标量系统

$$x_{k+1} = x_k + u_k + w_k,$$

$$z_k = x_k + v_k,$$

式中 § 3.2 的假设有效。令代价为

$$E\left\{x_N^2 + \sum_{k=0}^{N-1} (x_k^2 + u_k^2)\right\},$$

并令给定的概率分布是

$$p(x_0 = 2) = \frac{1}{2}, \quad p(w_k = 1) = \frac{1}{2}, \quad p\left(u_k = \frac{1}{4}\right) = \frac{1}{2},$$

$$p(x_0 = -2) = \frac{1}{2}, \quad p(w_k = -1) = \frac{1}{2}, \quad p\left(v_k = -\frac{1}{4}\right) = \frac{1}{2}.$$

(a) 确定最优控制律。提示: 对这个特殊问题, $E\{x_k | I_k\}$ 可由 $E\{x_{k-1} | I_{k-1}\}$, u_{k-1} , 和 z_k 确定。

(b) 在成为测量的线性函数的所有控制律类中, 确定最优控制律。

(c) 当 $N \rightarrow \infty$ 时, 确定 (a) 和 (b) 中控制律的渐近形式。寻求相应的长期平均代价比率:

$$\lim_{N \rightarrow \infty} \frac{1}{N} E\left\{\sum_{k=0}^{N-1} (x_k^2 + u_k^2)\right\}.$$

3. 一个具有高斯分布的线性系统

$$x_{k+1} = Ax_k + Bu_k + w_k, \quad k=0, 1, \dots, N-1,$$

按类似 § 3.2 的方法控制得使二次代价极小。其区别是控制器在每个时刻，可为下一阶段 \$(k+1)\$，任意选择两类测量类型之一：

$$\text{第一种类型} \quad z_{k+1} = C^1 x_{k+1} + v_{k+1}^1$$

$$\text{第二种类型} \quad z_{k+1} = C^2 x_{k+1} + v_{k+1}^2$$

这里 \$C^1\$ 和 \$C^2\$ 是给定的有适当维数的矩阵，\$\{v_k^1\}\$ 和 \$\{v_k^2\}\$ 是零均值白噪声随机序列，具有给定的与 \$x_0\$ 和 \$\{w_k\}\$ 无关的有限协方差。每进行一次类型 1 (或类型 2) 的量测，有一个代价 \$g_1\$ (或 \$g_2\$)。问题是寻求最优控制和量测选择策略，使二次代价

$$x_N' Q x_N + \sum_{k=0}^{N-1} (x_k' Q x_k + u_k' R u_k)$$

和总的量测代价之和的期望值极小。为了方便，假定 \$N=2\$，且第一次量测 \$z_0\$ 是类型 1。证明 \$k=0\$ 和 \$k=1\$ 的最优量测的选择依赖于信息向量 \$I_0\$ 和 \$I_1\$ 的值，并可以预先确定。描述最优策略的本质。

4. 考虑由下式给定的标量单输入、单输出系统

$$y_k + a_1 y_{k-1} + \dots + a_m y_{k-m} = b_M u_{k-M} + \dots + b_n u_{k-n} + \epsilon_k + c_1 \epsilon_{k-1} + \dots, \dots, \epsilon_{k-m} + v_{k-n}$$

式中 \$1 \leq M \leq m\$，\$0 \leq n \leq m\$，和 \$v_k\$ 由如下形式的方程产生

$$v_k + d_1 v_{k-1} + \dots + d_m v_{k-m} = \zeta_k + e_1 \zeta_{k-1} + \dots + e_m \zeta_{k-m},$$

且多项式 \$(1 + c_1 s + \dots + c_m s^m)\$，\$(1 + d_1 s + \dots + d_m s^m)\$ 和 \$(1 + e_1 s + \dots + e_m s^m)\$ 的根严格在单位圆外，标量 \$v_k\$ 在时刻 \$k\$ 连同 \$y_k\$ 由控制器观测。序列 \$\{\epsilon_k\}\$ 和 \$\{\zeta_k\}\$ 是零均值独立恒定分布的，具有有限方差。寻求易于实现的近似最小方差控制器，使 \$E\{\sum_{k=0}^N y_k^2\}\$ 极小。讨论闭环系统的稳定性。

5. (a) 在具有不完全状态信息的基本问题框架内，考虑系统和观测为线性的情况：

$$x_{k+1} = A_k x_k + B_k u_k + w_k, \quad k=0, 1, \dots,$$

$$z_k = C_k x_k + v_k, \quad k=0, 1, \dots.$$

初始状态 \$x_0\$，扰动 \$w_k\$ 和 \$v_k\$ 假定为高斯的且相互独立。它们的协方差给定，\$w_k\$ 和 \$v_k\$ 具有零均值，证明 \$E\{x_0 | I_0\}, \dots, E\{x_{N-1} | I_{N-1}\}\$ 对这一问题构造了一个充分统计。

(b) 利用部分 (a) 的结果，就单阶段问题的特殊情况，求一个最优控制律。该问题包括标量系统和观测

$$x_1 = x_0 + u_0,$$

$$z_0 = x_0 + v_0,$$

和求代价泛函 \$E\{|x_1|\}\$。

(c) 将 (b) 推广到如下标量系统的情况

$$x_{k+1} = ax_k + u_k, \quad k=0, 1, \dots, N-1,$$

$$z_k = cx_k + v_k, \quad k=0, 1, \dots, N-1.$$

和代价泛函 \$E\{\sum_{k=1}^N |x_k|\}\$。标量 \$a\$ 和 \$c\$ 给定。注意：如下“积分的微分”公式对您也许有用。

$$\frac{d}{dy} \int_{a(y)}^{\beta(y)} f(y, \xi) d\xi = \int_{a(y)}^{\beta(y)} \frac{df(y, \xi)}{dy} d\xi + f[y, \beta(y)] \frac{d\beta(y)}{dy} - f[y, a(y)] \frac{da(y)}{dy}$$

$$-f[y, \alpha(y)] \frac{d\alpha(y)}{dy}.$$

6. 考虑一台机器可能处在两种状态之一：好或坏。假设机器在每一周期末生产一种产品，但生产的产品好或坏分别取决于机器处于好或坏的状态。假设一旦机器处于坏状态，那么它就一直处于该状态直到被替换为止。如果在某一周期开始时，机器处于良好状态，则以概率 t 在周期末处于坏状态。一旦生产出产品，以代价 I 进行产品检验或不进行检验。如果发现所检验的产品是坏的，将机器用处于良好状态的机器代替，代价为 R 。生产一个坏产品的代价为 $C > 0$ 。假定初始时刻机器处于良好状态，且阶段为 N 个周期，写出获取最优检验策略的 DP 算法。设 $t = 0.2$, $I = 1$, $R = 3$, $C = 2$, $N = 8$, 解此问题。(最优策略是：在第三周期末进行检验。在其他任何周期不进行检验)。提示：寻找一个合适的充分统计。

7. 对具有不完全状态信息的有限状态系统的控制。考虑一个系统，它在任何时刻可处在有限个状态 $1, 2, \dots, n$ 中任何一个。当采用控制 u 时，系统以概率 $p_{ij}(u)$ 由状态 i 移到状态 j 。控制选自一个有限集合 $u^1, u^2, \dots, u^m$ 。随着每个状态的转移，控制器进行观测。存在有限个可能的观测结果： $z^1, z^2, \dots, z^q$ 。给定当前状态为 j 和前一个控制为 u ，出现 z^q 的概率表示为 $r_j(u, \theta)$, $\theta = 1, \dots, q$ 。

(a) 考虑条件概率的列向量

$$P_k = [p_k^1, \dots, p_k^n]'$$

式中

$$p_k^j = P(x_k = j | z_0, \dots, z_k, u_0, \dots, u_{k-1}), \\ j = 1, \dots, n,$$

证明它按

$$p_{k+1}^j = \frac{\sum_{i=1}^n p_k^i p_{ij}(u_k) r_i(u_k, z_{k+1})}{\sum_{j=1}^n \sum_{i=1}^n p_k^i p_{ij}(u_k) r_i(u_k, z_{k+1})}, \quad j = 1, \dots, n.$$

可以进行更新。将此方程写成紧凑形式

$$P_{k+1} = \frac{[r(u_k^k, z^{k+1})] * [P(u_k^k)' P_k]}{r(u_k^k, z^{k+1})' P(u_k^k)' P_k}, \quad j = 1, \dots, n,$$

式中 $P(u_k)$ 是 $n \times n$ 转移概率矩阵，第 ij 元素为 $p_{ij}(u_k)$ ， $r(u_k, z_{k+1})$ 是列向量。第 j 个分量为 $r_j(u_k, z_{k+1})$ 。 $[P(u_k)' P_k]_i$ 是向量 $P(u_k)' P_k$ 的第 j 个分量。 $[r(u_k, z_{k+1})] * [P(u_k)' P_k]$ 表示向量，第 j 个分量为 $r_j(u_k, z_{k+1}) [P(u_k)' P_k]_j$ ，撇号表示转置。

(b) 假定在每个阶段 k ，存在一个与控制 u 和 i 到 j 的转移相应的代价，记为 $g_k(i, u, j)$ 。无终端代价。考虑寻找一个最优策略，使 N 周期中每一阶段的代价之和极小的问题。证明相应的 DP 算法为

$$\bar{J}_{N-1}(P_{N-1}) = \min_{u \in \{u^1, \dots, u^m\}} P_{N-1}' G_{N-1}(u)$$

$$\bar{J}_k(P_k) = \min_{u \in \{u^1, \dots, u^m\}} [P_k' G_k(u)]$$

$$+ \sum_{\theta=1}^q r(u, \theta)' P(u)' P_k \bar{J}_{k+1} \left[\frac{[r(u, \theta)] * [P(u)' P_k]}{r(u, \theta)' P(u)' P_k} \right],$$

$$k=0, 1, \dots, N-2,$$

式中 $G_k(u)$ 由下式给出

$$G_k(u) = \begin{pmatrix} \sum_{j=1}^n p_{1j}(u) g_k(1, u, j) \\ \dots \\ \sum_{j=1}^n p_{nj}(u) g_k(n, u, j) \end{pmatrix}, k=0, 1, \dots, N-1.$$

(c) 按归纳法证明: 对所有 k , 当把 $\bar{J}_k$ 看作具有非负分量的向量集合上的一个函数时, $\bar{J}_k$ 是正齐次的, 即

$$\bar{J}_k(\lambda P_k) = \lambda \bar{J}_k(P_k), \lambda > 0.$$

利用这个结果, 将 $\bar{J}_k, k=0, 1, \dots, N-2$, 写成另一种形式

$$\bar{J}_k(P_k) = \min_{u \in \{u^1, \dots, u^m\}} [P_k' G_k(u) + \sum_{\theta=1}^q \bar{J}_{k+1} [[r(u, \theta)] * [P(u)' P_k]]].$$

(d) 归纳证明: 对所有 k , $\bar{J}_k$ 具有如下形式

$$\bar{J}_k(P_k) = \min [P_k' \alpha_k^1, \dots, P_k' \alpha_k^m],$$

式中 $\alpha_k^1, \dots, \alpha_k^m$ 为 R^n 中某些向量。

8. 考虑在示教问题中的函数 $\bar{J}_k(p_k)$ 。归纳证明: 这些函数的每一个为分段线性且凹的, 形式为

$$\bar{J}_k(p_k) = \min [\alpha_k^1 + \beta_k^1 p_k, \alpha_k^2 + \beta_k^2 p_k, \dots, \alpha_k^m + \beta_k^m p_k],$$

式中 $\alpha_k^1, \dots, \alpha_k^m, \beta_k^1, \dots, \beta_k^m$ 是合适的标量。

9. 双臂投赌机问题。向一个人提供 N 次免费游戏, 按其喜欢, 游戏在两台投币机器 A 和 B 之间分配进行。机器 A 以已知概率 s 付 α 美元; 以概率 $(1-s)$ 不付钱; 机器 B 以概率 p 付 β 美元, 以概率 $(1-p)$ 不付钱。这人并不知道 p , 但对 p 有一个先验概率分布 $F(p)$ 。问题是寻求玩的策略, 使得期望利益最大。令 $(m+n)$ 表示在 k 次免费游戏之后 ($m+n \leq k$) 玩机器 B 的次数。令 m 表示成功的次数, n 为失败的次数。证明此问题的 DP 算法为

$$\bar{J}_{N-1}(m, n) = \max \{s\alpha, p(m, n)\beta\}, m+n \leq N-1,$$

$$\bar{J}_k(m, n) = \max \{s[\alpha + \bar{J}_{k+1}(m, n)] + (1-s)\bar{J}_{k+1}(m, n),$$

$$p(m, n)[\beta + \bar{J}_{k+1}(m+1, n)] + [1-p(m, n)]\bar{J}_{k+1}(m, n+1)\},$$

$$m+n \leq k,$$

式中

$$p(m, n) = \frac{\int_0^1 p^{m+1}(1-p)^n dF(p)}{\int_0^1 p^m(1-p)^n dF(p)}.$$

设 $N=6$, $\alpha=\beta=1$, $s=0.6$, $dF(p)/dp=1$, 对 $0 \leq p \leq 1$ 求解此问题。[答案是在下列的 (m, u) 对情况下玩机器 B : $(0,0)$, $(1,0)$, $(2,0)$, $(3,0)$, $(4,0)$, $(5,0)$, $(2,1)$, $(3,1)$, $(4,1)$; 其他情况下应该玩机器 A]。

10. 在投掷硬币的游戏中, 向某人提供 2 对 1 的赌注打赌, 当出现背面时算他赢。然而, 他怀疑硬币一边轻一边重, 而具有概率 p 的一个先验分布 $F(p)$, 其中 p 是在每次投掷中出现正面的概率。问题是寻求一个最优策略, 在给定迄今为止的赌博结果情况下, 决定是否继续或停止参与赌博, 最多容许投掷 N 次。指出如何利用 DP 可以求得这个策略。

第四章 次优与自适应控制

我们已经看到,有时有可能得到 DP 算法的一种闭式解,或者至少利用算法以表征一个最优策略。然而,这几乎是例外。在绝大多数情况下,必须数值求解 DP 方程以获得最优策略。这样做,其计算量常常是令人望而却步的。而且对许多问题,由 DP 求完全解是不可能的。其原因是贝尔曼所说的“维数灾难”。譬如,考虑状态空间是 R^n 的一个问题,为了获得余留代价函数 $J_k(x_k)$,首先要把状态空间离散化。例如每轴取 100 个离散点,形成具有 100^n 个点的网格。DP 方程右边的极小化必须对这些点中的每一个进行数值计算。当每次计算极小化,需要进行数值积分(求期望运算)时,事情就变得更加复杂了。计算机存贮同样也存在尖锐的问题。因此,对于具有有限维状态和控制空间的问题,DP 只能应用于那些空间维数较小的场合。当控制空间为一维时,应用一维极小化技术[L9],问题有时就得以简化。在另外一些场合,可揭示问题的特殊结构,以减少计算的需求。

当各种努力失败时,就必须提出一个控制方案,它能够在实际中被实现,而且性能上也适当(有希望接近最优)。本章我们讨论几个次优控制的思想。

§ 4.1 确定性等价控制

确定性等价控制器(CEC)是一个次优控制方案。它是受线性二次控制理论的推动而发展起来的。在每一阶段它施加一个控制,如果所有不确定量固定在它们的期望值上,则此控制将是最优的。即表现出存在一定形式的等价原理。

我们将 § 3.1 中具有不完全状态信息的基本问题作为模型,并进一步假定输入扰动 w_k 的概率测度与 x_k 和 u_k 无关。假定状态空间和扰动空间为相应欧氏空间的凸子集,所以期望值

$$\bar{x}_k = E\{x_k | I_k\}, \quad \bar{w}_k = E\{w_k\}$$

属于相应的状态空间和扰动空间。如果不是这样,则下面方案可以用 $\bar{x}_k$ 和 $\bar{u}_k$ 来实现,而 $\bar{x}_k$ 和 $\bar{u}_k$ 是相应空间的某些“典型的”元。

在每一时刻 k , 由 CEC 所施加的控制输入 $\tilde{\mu}_k(I_k)$ 由以下规则确定:

1. 给定一个信息向量 I_k , 计算

$$\bar{x}_k = E\{x_k | I_k\}.$$

2. 解确定性问题, 寻找一个控制序列 $\{\tilde{u}_k, \tilde{u}_{k+1}, \dots, \tilde{u}_{N-1}\}$, 使得

$$g_N(x_N) + \sum_{i=k}^{N-1} g_i(x_i, u_i, \bar{w}_i)$$

在如下约束下为极小:

$$u_i \in U_i, \quad x_{i+1} = f_i(x_i, u_i, \bar{w}_i), \quad i = k, k+1, \dots, N-1, \quad x_k = \bar{x}_k.$$

3. 施加控制输入

$$\tilde{\mu}_k(I_k) = \tilde{u}_k,$$

注意, 如果精确地测得当前状态 x_k (完全状态信息), 则第一步就不必要。一旦初态 $\bar{x}_k = E\{x_k | I_k\}$ 用估计程序 (或完全观测) 为已知时, 必须在每一时刻 k , 解第二步的确定性最优优化问题。(实际上, 常用一个次优估计方案, 产生 $\bar{x}_k$ 的近似值。) 在任意一次实际的 CEC 运算中, 必须求解总数为 N 个这样的问题。然而, 这些问题中的每一个都是确定性最优控制问题, 而且往往是一类诸如最速下降法、共轭梯度法和牛顿法 [L10] 等功能强大的数值方法行之有效的问题。因此, CEC 需求解 N 个这样的问题, 以取代求解获得最优控制器所需的 DP 算法。而且, 实现 CEC 不需要最优反馈控制器所要求的那种类型的存贮器, 这是一个主要的优点。

另一种以“在线”方式求解 N 个最优控制问题的方法是先求解这些问题。它是通过计算确定性最优控制问题的一个最优反馈控制器来完成的, 而确定性问题是由原问题将所有不确定性量用它们的期望值代替而得到的。容易验证 (其于确定性问题最优控制器开环与反馈实现的等价性), 前面给出的 CEC 的实现等价于如下问题:

令 $\{\mu_0^d(x_0), \dots, \mu_{N-1}^d(x_{N-1})\}$ 是对如下确定性问题由 DP 算法所得的一个最优控制器:

$$\min g_N(x_N) + \sum_{k=0}^{N-1} g_k[x_k, \mu_k(x_k), \bar{w}_k], \text{ 对所有 } \{\mu_0, \dots, \mu_{N-1}\}$$

约束: $\mu_k(x_k) \in U_k$, 对所有 $x_k \in S_k$,

$$x_{k+1} = f_k[x_k, \mu_k(x_k), \bar{w}_k], k = 0, 1, \dots, N-1.$$

则在时刻 k , 由 CEC 所施加的控制输入 $\tilde{\mu}_k(I_k)$ 为

$$\tilde{\mu}_k(I_k) = \mu_k^d[E\{x_k | I_k\}] = \mu_k^d(\bar{x}_k),$$

如图 4.1 所示。




图 4.1 确定性等价控制器的结构

换句话说, CEC 的另一种实现方法包括寻找一个对相应确定性问题为最优的反馈控制器 $\{\mu_0^d, \mu_1^d, \dots, \mu_{N-1}^d\}$, 然后用这个控制器对不确定系统进行控制 (用期望值代替状态)。对不论哪一种所给的定义, CEC 都可以作为其实现的基础。根据问题的性质, 某种方法可能比

另一种方法更好些。

CEC 在实践中通常运行良好, 接近于最优时就要付出代价。事实上, 对 § 2.1 和 § 3.2 的线性二次问题, 它等于最优控制器(确定性等价原理)。然而, 也有可能它运行得要比最优开环控制器坏得多(见习题 4)。

多路存取通信例子

考虑在 § 3.1 开始时所描述的槽式 Aloha 系统。对此问题得到一个最优策略是很困难的, 主要是因为积压(状态)的条件分布在给定的通道发送历史的情况下没有一个简单的表征式。因此, 我们改用一种次优策略。如在 § 3.1 所讨论的那样, 完全状态信息类型的问题有一简单的最优策略:

$$\mu_k(x_k) = \frac{1}{x_k}, \text{ 对所有 } x_k \geq 1.$$

结果, 有一个自然的 CEC,

$$\tilde{\mu}_k(I_k) = \min\left[1, \frac{1}{\bar{x}_k}\right],$$

式中 $\bar{x}_k$ 是基于以往成功、空闲和冲突的整个通道历史对当前信包积压的一个估计。产生 $\bar{x}_k$ 的递推估计器在[H2]和[R1]给出。如果在第 k 槽发生冲突, $\bar{x}_k$ 增加一定数量; 如果是其它情况 $\bar{x}_k$ 减 1, 估计器就得到 $\bar{x}_{k+1}$ 。然后加上在第 k 槽期间到达信包的期望数, 将它估计为观测到的成功率(到槽 k 为止的成功数除以 k)。详细细节参阅[H2]和[R1]。整个控制方案的稳定性在[T8]中已作了研究。

§ 4.2 开环反馈控制器

开环反馈控制器(OLFC)与 CEC 是类似的, 不同的是在 k 时刻计算要施加的控制 $\bar{\mu}_k(I_k)$ 时, 它明确地考虑了关于 $x_k, w_k, \dots, w_{N-1}$ 的不确定性。这个控制是由以下程序确定:

1. 给定信息向量 I_k , 计算条件概率测度 $P_{x_k | I_k}$ 。
2. 寻求一个控制序列 $\{\bar{u}_k, \bar{u}_{k+1}, \dots, \bar{u}_{N-1}\}$, 使

$$E_{x_k, w_k, \dots, w_{N-1}} \left\{ g_N(x_N) + \sum_{i=k}^{N-1} g_i(x_i, u_i, w_i) \mid I_k \right\}$$

在如下约束下达到极小

$$u_i \in U_i, \quad x_{i+1} = f_i(x_i, u_i, w_i), \quad i = k, \dots, N-1. \quad [\text{注}]$$

3. 施加控制输入

$$\bar{\mu}_k(I_k) = \bar{u}_k.$$

对 OLFC 的运算可以解释如下: 在每个时刻 k , 控制器利用所得到的新量测来计算条件概率分布 $P_{x_k | I_k}$ 。然而, 选择控制输入, 却好象是将来不会再收到进一步的量测。

原注: 如对 CEC 一样, 假定这个问题的最优解存在, 且根据某些规则, 解决了多重解所造成的不明确性。

同 CEC 类似, OLFC 要求在系统任意的实际运用中求解 N 个最优控制问题; 每一个问题可再由确定性最优控制或数学规划技术来求解。计算比 CEC 略复杂些, 因为现在代价包括了非确定性量的期望运算。实现 OLFC 的主要困难在于计算 $P_{x_k|I_k}$ 。在许多情况下, 不能精确算出 $P_{x_k|I_k}$, 因而必须采用某些“合理的”近似方法。当然, 如果我们完全状态信息, 困难就不会出现。

在任意的次优控制策略中, 应确保优先使用量测。这就意味着这一方法的性能至少和任意开环策略一样好, 而开环策略是施加一个独立于所收到的量测值的控制序列。一个最优开环策略的求得, 是寻求一个序列 $\{u_0^*, u_1^*, \dots, u_{N-1}^*\}$, 使

$$\bar{J}(u_0, u_1, \dots, u_{N-1}) = E_{\substack{x_0, w_k \\ k=0, 1, \dots, N-1}} \left\{ g_N(x_N) + \sum_{k=0}^{N-1} g_k(x_k, u_k, w_k) \right\}$$

极小, 并服从约束: $x_{k+1} = f_k(x_k, u_k, w_k)$ 和 $u_k \in U_k$, $k=0, 1, \dots, N-1$ 。与 CEC 比较, OLFC 的一个很好的性质是(参阅习题 4): 其性能至少与最优开环策略一样好。

命题 相应于一个 OLFC $\pi = \{\bar{\mu}_0, \bar{\mu}_1, \dots, \bar{\mu}_{N-1}\}$ 的代价 J_π 满足

$$J^* \leq J_\pi \leq J_0^*, \quad (4.1)$$

证明: [注] 我们有

$$\bar{J}_\pi = E_{z_0} \{ \bar{J}_0(I_0) \} = E_{z_0} \{ \bar{J}_0(z_0) \}, \quad (4.2)$$

式中, 函数 $\bar{J}_0$ 由如下递推算法获得

$$\begin{aligned} \bar{J}_{N-1}(I_{N-1}) = & E_{x_{N-1}, w_{N-1}} \{ g_N[f_{N-1}(x_{N-1}, \bar{\mu}_{N-1}(I_{N-1}), w_{N-1})] \\ & + g_{N-1}[x_{N-1}, \bar{\mu}_{N-1}(I_{N-1}), w_{N-1}] | I_{N-1} \}, \end{aligned} \quad (4.3)$$

$$\begin{aligned} \bar{J}_k(I_k) = & E_{x_k, w_k, v_{k+1}} \{ g_k[x_k, \bar{\mu}_k(I_k), w_k] \\ & + \bar{J}_{k+1}[I_k, h_{k+1}[f_k(x_k, \bar{\mu}_k(I_k), w_k), \bar{\mu}_k(I_k), v_{k+1}], \bar{\mu}_k(I_k)] | I_k \}, \\ & k=0, 1, \dots, N-1. \end{aligned} \quad (4.4)$$

再考虑函数 $J_k^c(I_k)$, $k=0, 1, \dots, N-1$, 定义为

$$J_k^c(I_k) = \min_{\substack{u_i \in U_i \\ i=k, \dots, N-1}} E_{\substack{x_k, w_i \\ x_{i+1} = f_i(x_i, u_i, w_i) \\ i=k, \dots, N-1}} \left\{ g_N(x_N) + \sum_{i=k}^{N-1} g_i(x_i, u_i, w_i) | I_k \right\}. \quad (4.5)$$

这个方程中的极小化问题, 正是在时刻 k 为计算 OLFC 的控制输入 $\bar{\mu}_k(I_k)$ 所必须解决的问题。显然, $J_k^c(I_k)$ 可以解释为在当前信息向量为 I_k 时, 从时刻 k 到时刻 N 所计算的开环最优代价。可以看出,

$$E_{z_0} \{ J_0^c(z_0) \} \leq J_0^*. \quad (4.6)$$

我们要证明,

$$\bar{J}_k(I_k) \leq J_k^c(I_k), \text{ 对所有 } I_k \text{ 和 } k. \quad (4.7)$$

原注: 在整个证明中, 假定所有出现的期望值均已有定义, 且有限, 对每一个 I_k , 式(4.5)达到极小。

然后由式(4.2), 式(4.6)和式(4.7)得出:

$$J_{\pi} \leq J_0^*,$$

这就是要证明的关系式。我们用归纳法来证明式(4.7)。

由 OLFC 的定义和式(4.5), 我们有

$$\bar{J}_{N-1}(I_{N-1}) = J_{N-1}^c(I_{N-1}), \text{ 对所有 } I_{N-1},$$

因此对 $k = N - 1$, 式(4.7)成立。假定

$$\bar{J}_{k+1}(I_{k+1}) \leq J_{k+1}^c(I_{k+1}), \text{ 对所有 } I_{k+1}. \quad (4.8)$$

那末, 由式(4.4), 式(4.8)和式(4.5), 有

$$\begin{aligned} \bar{J}_k(I_k) &= E_{x_k, w_k, v_{k+1}} \{g_k[x_k, \bar{\mu}_k(I_k), w_k] \\ &\quad + \bar{J}_{k+1}[I_k, h_{k+1}[f_k(x_k, \bar{\mu}_k(I_k), w_k), \bar{\mu}_k(I_k), v_{k+1}], \bar{\mu}_k(I_k) | I_k] \} \\ &\leq E_{x_k, w_k, v_{k+1}} \{g_k[x_k, \bar{\mu}_k(I_k), w_k] \\ &\quad + J_{k+1}^c[I_k, h_{k+1}[f_k(x_k, \bar{\mu}_k(I_k), w_k), \bar{\mu}_k(I_k), v_{k+1}], \bar{\mu}_k(I_k) | I_k] \} \\ &= E_{x_k, w_k, v_{k+1}} \left\{ \min_{\substack{u_i \in U_i \\ i=k+1, \dots, N-1}} E_{\substack{x_{k+1}, w_i \\ x_{i+1} = f_i(x_i, u_i, w_i) \\ i=k+1, \dots, N-1}} \{g_k[x_k, \bar{\mu}_k(I_k), w_k] \right. \\ &\quad \left. + \sum_{i=k+1}^{N-1} g_i(x_i, u_i, w_i) + g_N(x_N) | I_{k+1}\} | I_k \right\} \\ &\leq \min_{\substack{u_i \in U_i \\ i=k+1, \dots, N-1}} E_{\substack{x_k, w_k, w_i \\ x_{i+1} = f_i(x_i, u_i, w_i) \\ i=k+1, \dots, N-1 \\ x_{k+1} = f_k[x_k, \bar{\mu}_k(I_k), w_k]}} \{g_N(x_N) + g_k[x_k, \bar{\mu}_k(I_k), w_k] \\ &\quad + \sum_{i=k+1}^{N-1} g_i(x_i, u_i, w_i) | I_k\} = J_k^c(I_k). \end{aligned}$$

第二个不等式由求期望和求极小的次序交换(注意, 我们总有 $E\{\min[\cdot]\} \leq \min[E\{\cdot\}]$), 以及“积分掉” v_{k+1} 而得到。最后的等式由 OLFC 的定义得到。这样, 对所有 k 证明了式(4.7), 并证明了所需结果。证毕

值得注意的是, 由式(4.7)从时刻 k 到时刻 N 所计算的开环最优代价 $J_k^c(I_k)$ 提供了一个易于获得 OLFC 的性能界限。

上述命题表明, OLFC 优先利用了量测。然而在每个周期, 它选择当前的控制输入, 犹如未来不再取量测。当然, 关于所得的代价如何逼近最优, 并没有提供任何信息。但是, 对于许多问题来说, OLFC 似乎是一个最令人满意的控制模式。

§ 4.3 有限前瞻策略: 在柔性制造和计算机下棋中的应用

减少 DP 算法所检验的状态数目的一个实际方法, 就是截短时域长度, 而且在每个阶段, 使用基于前瞻少数几个阶段的决策。最简单的可能性就是采用一步前瞻策略。据此, 在阶段 k 和状态 x_k 利用控制 $\bar{u}_k(x_k)$, 使如下表达式达到极小

$$\min_{u_k \in U_k(x_k)} E\{g_k(x_k, u_k, w_k) + \tilde{J}_{k+1}[f_k(x_k, u_k, w_k)]\},$$

式中 $\tilde{J}_{k+1}$ 是真实余留代价函数 J_{k+1} 的某种近似。类似地, 两步前瞻策略在时刻 k 和状态 x_k , 施加控制 $u_k(x_k)$, 使前面的方程达到极小, 但现在 $\tilde{J}_{k+1}$ 本身是在一步前瞻近似的基础上得到的。换句话说, 对所有可能的状态

$$x_{k+1} = f_k(x_k, u_k, w_k),$$

我们有

$$\begin{aligned} \tilde{J}_{k+1}(x_{k+1}) = & \min_{u_{k+1} \in U_{k+1}(x_{k+1})} E\{g_{k+1}(x_{k+1}, u_{k+1}, w_{k+1}) \\ & + \tilde{J}_{k+2}[f_{k+1}(x_{k+1}, u_{k+1}, w_{k+1})]\}, \end{aligned}$$

式中 $\tilde{J}_{k+2}$ 是余留代价函数 J_{k+2} 的某种近似。

这种方法计算上的节约是明显的。对一步前瞻策略, 每个阶段只需解一个单独的极小化问题; 而在两步前瞻策略中, 在阶段 k , DP 方程必须求解的状态数等于 1 加所有可能由当前状态 x_k 所产生的下一状态 x_{k+1} 的个数。实际上整个两步前瞻计算可以建成为一个单独的通常易于处理的数学规划问题(见习题 1 和 2)。还要注意, 固定的前瞻方法, 可以和 § 4.1 和 § 4.2 确定性等价和开环反馈控制方法结合起来, 进一步简化计算。

实现有限步前瞻策略的关键问题是在最后一步选择余留代价的近似。乍看起来, 在有关状态的范围内充分逼近真实的余留代价函数似乎很重要。其实不然, 重要的是充分逼近余留代价的微分(或相对值); 即对一个 n 步前瞻策略, 对可由当前状态提前 n 步产生的任意两个状态 x 和 x' , 重要的是使之有:

$$\tilde{J}_{k+n}(x) - \tilde{J}_{k+n}(x') \approx J_{k+n}(x) - J_{k+n}(x').$$

例如, 若对所有 x, x' , 等式成立, 则对每个有关的 x , $\tilde{J}_{k+n}(x)$ 和 $J_{k+n}(x)$ 相差一个常数, 从而 n 步前瞻策略应是最优的。

选择余留代价近似的方式与所解问题有很大的关系。例如, 在下棋之类的游戏中, 某个棋局(状态)的近似余留代价, 包含了把棋局的某些特征和性能指标启发式的结合。在其它问题中, 一个余留代价的近似可能基于一个比较简单问题的解, 该问题在计算或分析方面均易于处理。下面的例题说明这些方法。

柔性制造系统中的生产控制

柔性制造系统(FMS)为有关零部件的中小批量制造提高生产率, 提供了一种通用的方法。在 FMS 中, 有几个工作站, 其中每一个都有进行多种加工操作的能力。它容许同时制造多种类型的零件, 减少空闲时间; 并且当一个工作站因为失效或维修而退出服务时, 容许生产继续进行。

考虑一个生产 n 种零件的加工中心, 记

u_k^i : 周期 k 中生产零件 i 的数量。

d_k^i : 周期 k 中已知的零件 i 需求量。

x_k^i : 到周期 k 为止, 所生产的零件 i 和需求量的累计差额。

再令 x_k, u_k, d_k 表示分别具有分量 x_k^i, u_k^i, d_k^i 的 n 维向量。那么, 我们有

$$x_{k+1} = x_k + u_k - d_k \quad (4.9)$$

加工中心由 n 个工作站组成, 各工作站以随机方式发生故障和修理, 因而影响系统的生产能力(即对 u_k 的约束)。粗略地说, 我们的问题是制定零件生产计划, 使 x_k 尽最大可能保持在零附近。

工作站的状态由如下 m 维向量来描述

$$\alpha_k = (\alpha_k^1, \dots, \alpha_k^m),$$

式中

$$\alpha_k^i = \begin{cases} 1, & \text{若工作站 } i \text{ 在周期 } k \text{ 运行;} \\ 0, & \text{其它。} \end{cases}$$

我们用一个具有已知转移概率的马尔科夫链来建立 α_k 的演变模型

$$p_{rs}^i = P(\alpha_{k+1}^i = s | \alpha_k^i = r), \quad r, s = 0, 1, \text{ 且 } i = 1, 2, \dots, m.$$

在实际场合, 这些概率必须由各个站的故障和修理率来估计, 但我们并不打算进一步深入讨论此事。还要注意, 在实际上这些概率可能依赖于 u_k 。为了推导余留代价的近似关系式, 这种依赖关系不予考虑[参见式(4.15)], 而当计算实际的次优控制时, 有可能要考虑[参见式(4.16)的极小化]。

根据定义, 系统的生产能力就是生产向量 u_k 的约束集合, 并依赖于工作站的状态 α_k , 用 $U(\alpha_k)$ 来表示。

我们选择 (x_k, α_k) 作为系统状态, 其中 x_k 按式(4.9)演变。 α_k 如前按马尔科夫链来描述。问题是对每一个状态 (x_k, α_k) , 寻求一个生产向量 $u_k \in U(\alpha_k)$, 使形式为

$$J_\pi(x_0) = E \left\{ \sum_{k=0}^{N-1} \sum_{i=1}^n g_i(x_k^i) \right\}$$

的代价函数极小。每阶段代价 g_i 表示了保持零件 i 的当前累积或多余接近于零的愿望。举两个例子: $g_i(x^i) = \beta_i |x^i|$ 或 $g_i(x^i) = \beta_i |x^i|^2$, $\beta_i > 0$ 。

对此问题, DP 算法为

$$J_k(x_k, \alpha_k) = \sum_{i=1}^n g_i(x_k^i) + \min_{u_k \in U(\alpha_k)} E \{ J_{k+1}(x_k + u_k - d_k, \alpha_{k+1}) | \alpha_k \}, \quad (4.10)$$

但遗憾的是, 对一个实际规模的 FMS(譬如零件种类 $n > 10$) 常常要求巨大的计算量。所以我们来考虑以适当的近似取代余留代价 J_{k+1} 的一步前瞻策略的可能性。

现在我们观察到, 在很大程度上, 问题可以对各个零件类别进行分解。的确, 系统方程(4.9)和每阶段代价具有一个可分的结构。零件间的唯一耦合来自约束 $u_k \in U(\alpha_k)$ 。这个约束典型地有一个类似单纯形的结构

$$U(\alpha_k) = \{u_k | \gamma(\alpha_k)' u_k \leq \delta(\alpha_k), u_k^i \geq 0, i = 1, \dots, n\}, \quad (4.11)$$

式中 $\gamma(\alpha_k)$ 是一已知的 n 维向量, $\delta(\alpha_k)$ 是一个取决于 α_k 的标量。假设用如下形式的超立方体 $\underline{U}(\alpha_k)$ 和 $\bar{U}(\alpha_k)$ 来近似

$$\begin{aligned} \underline{U}(\alpha_k) &= \{u_k^i | 0 \leq u_k^i \leq \underline{B}_i(\alpha_k)\}, \\ \bar{U}(\alpha_k) &= \{u_k^i | 0 \leq u_k^i \leq \bar{B}_i(\alpha_k)\}, \\ \underline{U}(\alpha_k) &\subset U(\alpha_k) \subset \bar{U}(\alpha_k), \end{aligned} \quad (4.12)$$




图 4.2 由超正方体对生产能力约束集合的内外逼近

如图 4.2 所示。如果对各工作站的状态 $\alpha_k, U(\alpha_k)$ 用 $\bar{U}(\alpha_k)$ 或 $\underline{U}(\alpha_k)$ 来代替, 则问题相对于零件类别完全分解。对每一零件 i , 外逼近的 DP 算法给定为

$$\bar{J}_h^i(x_h^i, \alpha_k) = g_i(x_h^i) + \min_{0 < u_h^i < \bar{B}_i(\alpha_k)} E \{ \bar{J}_{h+1}^i(x_h^i + u_h^i - d_h^i, \alpha_{k+1}) | \alpha_k \}, \quad (4.13)$$

而内逼近给定为

$$\underline{J}_h^i(x_h^i, \alpha_k) = g_i(x_h^i) + \min_{0 < u_h^i < \underline{B}_i(\alpha_k)} E \{ \underline{J}_{h+1}^i(x_h^i + u_h^i - d_h^i, \alpha_{k+1}) | \alpha_k \}. \quad (4.14)$$

而且, 根据式(4.12), 余留代价函数 $\bar{J}_h^i$ 和 $\underline{J}_h^i$ 提供了真正余留代价函数 J_h 的上界和下界,

$$\sum_{i=1}^n \bar{J}_h^i(x_h^i, \alpha_k) \leq J_h(x_h, \alpha_k) \leq \sum_{i=1}^n \underline{J}_h^i(x_h^i, \alpha_k), \quad (4.15)$$

并可用来构成适用于一步前瞻策略的 J_h 近似值。最简单的可能性是采用平均近似

$$\tilde{J}_h(x_h, \alpha_k) = \frac{1}{2} \sum_{i=1}^n [\bar{J}_h^i(x_h^i, \alpha_k) + \underline{J}_h^i(x_h^i, \alpha_k)],$$

在状态 (x_h, α_k) , 利用次优控制 $\tilde{u}_h$, 它对所有 $u_h \in U(\alpha_k)$, 使

$$E \left\{ \sum_{i=1}^n [\bar{J}_{h+1}^i(x_h^i + u_h^i - d_h^i, \alpha_{k+1}) + \underline{J}_{h+1}^i(x_h^i + u_h^i - d_h^i, \alpha_{k+1})] | \alpha_k \right\} \quad (4.16)$$

极小[参阅式(4.10)]。

为了实现这个方案, 必须完成 DP 算法式(4.13)和式(4.14), 并以表格形式存贮相应函数 $\bar{J}_h^i$ 和 $\underline{J}_h^i$, 使其可以通过表达式(4.16)求极小, 用在次优控制的实时计算中。包含在 DP 算法式(4.13)和式(4.14)中的计算量相当大, 但可离线完成; 无论如何, 总比计算最优控制所要求的工作量少。整个方法的可行性及其优点, 已在[K8]中对现实规模 FMS 的仿真而显示出来。还可参阅[T6]和[K7]。

计算机下棋

下棋的计算机程序是人工智能比较突出的成就之一。它们的基本方法论在应用次优控制方面提供了一个有趣的案例研究。这包括有限步前瞻的思想, 而且也阐明了某些我们还没有更多的机会去仔细研究的 DP 思想。其中有正向搜索的思想, 这是一个重要的节省内存的技

术，它在人工智能中应用十分普遍，并且在 § 1.4 中已经讨论过，还有 $\alpha-\beta$ 修剪的思想，它是减少寻找最优博弈策略所需计算量的有效方法。

所有计算机下棋程序所根据的奠基性论文是由最著名的现代应用数学家之一 C. 香农撰写的 [S16]。香农认为，开始的棋局是否为赢、输或平是一个原则上可以回答的问题，但答案也许永远不知道。他估计，根据下棋要求一个卒子前进，或每 50 步吃一子（否则宣布为平局）的规则，在一盘棋的走法中有 10^{120} 数量级不同的可能走步序列。他得出结论，为了研究这些走步序列，且为白方选择一个最好的初始走步，一个“快”计算机大约需要 10^9 年的时间。作为一种替代方法，香农提出了一个对很少几步的有限前瞻，而且按照记分函数评价终局，该记分函数适当地考虑了实力平衡、机动性、卒子的组织状态，以及其它的棋局因素。此处约定棋局中白方占高分棋局，黑方占低分棋局。

首先考虑在一个给定的棋局 P 中选择第一步的一步前瞻战略。令 $M_1, \dots, M_r$ 为走棋这一方在棋局 P 中可以进行的所有合法的棋步。用 $M_1P, M_2P, \dots, M_rP$ 表示所产生的棋局，且令 $S(M_1P), \dots, S(M_rP)$ 为相应的记分。那么，由白方（或黑方）在棋局 P 选择的棋步是具有最高（或最低）分数的棋步。这就是所谓 P 的倒推分，由下式给出

$$BS(P) = \begin{cases} \max\{S(M_1P), \dots, S(M_rP)\}, & \text{若在棋局 } P \text{ 白方走,} \\ \min\{S(M_1P), \dots, S(M_rP)\}, & \text{若在棋局 } P \text{ 黑方走.} \end{cases}$$

此过程如图 4.3 所说明。

其次考虑给定棋局 P 的一个两步前瞻战略。为了具体起见，假定白方走，合法的棋步为 $M_1, \dots, M_r$ ，相应的棋局为 $M_1P, \dots, M_rP$ 。那么，在每个棋局 M_iP 中， $i=1, \dots, r$ ，黑方应用一步前瞻战略走棋。于是给出了最好的棋步，并对各棋局 $M_iP, i=1, \dots, r$ ，给出了黑方的倒推记分 $BS(M_iP)$ 。最后，根据倒推记分 $BS(M_1P), \dots, BS(M_rP)$ ，白方应用一步前瞻战略，据此，得到棋局 P 最好的棋步和棋局 P 的倒推记分：




图 4.3 一步前瞻树，如果白方在棋局 P 走棋，最好棋步为 M_1 ，倒推记分为 $+5$ 。如果黑方在棋局 P 走棋，最好棋步为 M_3 ，且倒推记分为 -3 。




图 4.4 白方走棋的二步前瞻树。倒推记分表示在括号内。最好初始棋步是 M_3 ，主连续为 $(M_3, M_{3,1})$ 。

$$BS(P) = \max\{BS(M_1P), \dots, BS(M_nP)\}.$$

最好棋步的序列称之为主连续。该过程在图 4.4 中说明。

显然，刚才描述的香农方法(称为 A 类极大极小算法)，可以推广到前瞻任意数目的步数(参看图 4.5)。解决具有未来代价和总的终端代价(或倒推记分)的一步前瞻问题无疑是 DP 算法的中心内容。确实可以看出，所述的极大极小算法不是别的，就是极大极小问题的 DP 算法(第一章习题 5)。此处，的棋局和走棋可以分别看作状态与控制，其中仅有的终端代价(终局的记分)和一个棋局的倒推记分不是别的，就是相应状态的最优余留代价。




图 4.5 白方走棋的四步前瞻树。倒推记分表示在括号中。最好的初始棋步为 M_1 ，主连续用粗线表示。

香农认识到，用一个 A 类策略仍旧不能期望计算机向中等水平的棋手挑战。在一个典型的棋局中大约有 30~35 个合法棋步。从而对 n 步前瞻就有 $30^n \sim 35^n$ 个终局要记分。对 $n=6$ ，就给出大约 10^8 个棋局，在假定 10 微秒记录一局时，就可算出一个六步前瞻策略。仅对终局计分计算机就需要大约 2 小时 45 分钟。另一个缺点是，某些棋局比其它棋局要求更多的分析。例如，如果在一个搜索序列的最后一步吃掉一子，则主要考虑对方是否会反吃以及如何反吃。

这些考虑促使香农提出了一个 B 类策略。根据这种策略，搜索树的深度是可变的。他建议在每个棋局，计算机对所有合法的棋步进行初步研究，并把“明显坏”的棋步抛弃掉。为此目的，要把记分函数和某个启发式策略结合起来加以利用。类似地，他建议某些棋局，包括如吃子或将死威胁，要在正常的搜索深度之外，作进一步考察。

几乎所有的下棋计算机程序都利用香农 B 类策略的某种形式，它们的不同在于记分函数的选择，即在一个给定的棋局中舍弃棋步的判据和宣布一个给定棋局为终局的判据。一个称为换完(*swappoff*)的特别有效的算法用来快速分析吃子和反吃子的长序列。这样就有可能对真正复杂的动态棋局进行记分[L2]。

香农指出，随着前瞻深度的增加，每步计算量按指数增长，而所需的存贮量只是线性增

长。所以允许下棋程序在有限存贮的微处理器系统中运行。这在图 4.6 和 4.7 中作了说明，它仅按需要产生新的棋步，且仅存贮当前受检验的一步序列和搜索树各级上的合法走步表。计算和棋步生成按纵向优先方式进行。精确的算法可以按如下所谓自递推的程序进行描述。




图 4.6 以深度优先方式穿越一个树。勾号表示要计算终局记分和中局倒推记分的点




图 4.7 关于图 4.6 的树用极大极小算法深度优先方式的存贮需求。在用勾号标注终局记分时，只有实线棋步寄存在存贮器中。点线棋步已生成，并从存贮器中删除；虚线棋步尚未生成。存贮要求随前瞻的深度线性增长。

极大极小算法

为了确定棋局 n 的倒推记分 $BS(n)$ ，按如下步骤进行：

1. 若 n 是一个终局，返回它的记分。

否则:

2. 产生棋局 n 的合法棋步表, 并令相位棋局为 $n_1, \dots, n_r$ 。如果在 n 轮到白方走, 将棋局 n 的试探性倒推记分 $TBS(n)$ 置成 $+\infty$; 如果在 n 轮到黑方走, 置成 $-\infty$ 。

3. 对 $i = 1, \dots, r$, 进行:

a. 确定棋局 n_i 的倒推记分 $BS(n_i)$ 。

b. 若在棋局 n 轮到白方走, 置 $TBS(n) := \max\{TBS(n), BS(n_i)\}$ 。

若在棋局 n 轮到黑方走, 置 $TBS(n) := \min\{TBS(n), BS(n_i)\}$ 。

4. 返回 $BS(n) = TBS(n)$ 。

注意, 一旦一个棋局的倒推分计算出来, 它在搜索树上的所有后续棋局可从存储器中清除, 说明如图 4.7。由这个正向计算方法所提供的大量的内存节约, 在具有大量数目终端状态的搜索问题中非常有用, 在 § 1.4 中也讨论过这问题。

极大极小算法的有效性用 $\alpha-\beta$ 修剪过程(简称 $\alpha-\beta$)可大大改善。此程序 可用来摒弃某些计算, 包括对最好棋步的选择不会影响棋局的。为了了解 $\alpha-\beta$ 过程, 考虑一个棋手在棋局 P 思索下一步走法的情景。假定该棋手已经竭尽全力分析一个较好的棋步 M_1 , 相应记分为 $BS(M_1P)$, 并接着检验下一步 M_2 。假设在考察对手回棋时, 发现了一个特强的反应, 它确保 M_2 的记分比 M_1 差。这种反应称为棋步 M_2 的反着, 使得进一步考虑 M_2 已无必(即从棋步 M_2 以下搜索树部分可以摒弃)。图 4.8 表示了一个实例。





图 4.8 $\alpha-\beta$ 过程。白方已计算棋步 M_1 , 具有倒推分 $(+1)$, 并开始计算棋步 M_2 。黑方第一个回棋是 M_2 的一个反着, 因为它导致一个暂时得分 -5 , 少于 M_1 的倒推分。因为 M_2 的倒推分将是 -5 或更少, 则 M_2 比 M_1 差。所以不必再去计算 M_2 。

$\alpha-\beta$ 过程可以推广到任意的或不规则的深度的博弈树, 且可以很简单地结合到极大极小算法中去。一般来说, 如果在对给定棋局更新倒推记分过程中(步骤 3b), 这个记分跨出了某一界限, 就不必再对此棋局进行进一步的计算。动态地调整修剪界并从上到下传递如下:

1. 在棋局 n , 黑方的修剪界表示为 α , 并等于白方走棋的棋局 n 其所有的先前棋局的最当前记分。一旦它的暂时倒推记分等于或低于 α , 就可以停止对棋局 n 的搜索。

2. 在棋局 n , 白方的修剪界表示为 β , 它等于黑方走棋的棋局 n 其所有的先前棋局的最低当前记分。一旦它的暂时倒推记分高于 β , 就可以停止对棋局 n 的搜索。

图 4.9 说明这个过程。可以证明, 在开局时倒推记分和最优棋步不会因 $\alpha-\beta$ 过程结合到极大极小过程中去而受影响。我们将此证明留给读者(习题 8)。可以看出, 如果在每一棋局首先探索最好棋步, $\alpha-\beta$ 过程将更有效。倾向于使 α 保持高界, 使 β 保持低界, 这样就节



迭代深化按其纯粹形式包括：首先在一歩前瞻的基础上进行一次搜索；然后在二歩前瞻的基础上(从头)进行一次搜索；再然后是在三歩前瞻的基础上进行一次搜索，如此等等。这个过程一直进行下去，或者到达固定的前瞻程度，或者计算时间超过某一限制而结束。在与某个前瞻程度相应的每次迭代中，人们在起始局得到一个最好的棋歩。这歩在后来迭代中首先进行考察，包括一个額外前瞻歩。这样增强了 $\alpha-\beta$ 过程的功能，并超过了对額外计算的补偿，该迭代包括在长前瞻之前进行一次短前瞻的搜索(实际上，给定终局的数目，每附加一级前瞻，大约增加 30 倍以上计算，额外的计算相对较少)。这个方法的一个优点是，在整个搜索过程中能保持最好的棋歩，而且可以在任何所需的时刻产生。商用程序迟早会吸收这个特点。依靠这个特点，迫使计算机根据耗尽所分配的给定时间或对方棋手的命令来走歩。方法的改进就是通过一歩前瞻在起始棋局获得棋歩彻底分类表，然后在以后迭代中利用改进排序以增强 $\alpha-\beta$ 过程的性能。

• 118 •

个前瞻级上都有保留一个以上杀步的表格。)

在搜索一个博弈树中,有和没有 $\alpha-\beta$ 过程会产生同样的结果, $\alpha-\beta$ 过程是安全的。某些计算机下棋程序使用更极端的树修剪过程,通常这种过程对给定前瞻级,要求较少的计算。但有时会漏掉最强有力的棋步。关于这种过程的优点现在还有争议。参考文献[L2]和(N4)研究了这个问题,而且对计算机下棋程序提出了广泛的讨论。

§ 4.4 自适应控制: 自校正调节器

至今我们一直在处理具有已知状态方程的系统。然而在实际上,经常碰到的情况是系统方程含有不准确知道的参数。当然,一种可能的方法是进行实验并从系统输入-输出记录估计未知参数。但这种过程颇为费时。而且,如果系统的参数随时间而变(在许多工业过程中常常如此),就需要重复这个过程。

另一种选择是:按直接处理未知参数的方法来建立随机控制问题。容易证明,含有未知系统参数的问题可以用状态增广方法纳入具有不完全状态信息基本问题的框架。事实上,设系统方程具有如下形式

$$x_{k+1} = f_k(x_k, \theta, u_k, w_k),$$

式中 θ 是未知参数向量,具有一个给定的先验概率分布。我们引入一个附加的状态变量 $y_k = \theta$, 得到系统方程具有如下形式

$$\begin{bmatrix} x_{k+1} \\ y_{k+1} \end{bmatrix} = \begin{bmatrix} f_k(x_k, y_k, u_k, w_k) \\ y_k \end{bmatrix}. \quad (4.17)$$

把 $\tilde{x}_k = (x_k, y_k)$ 定义为新的状态,我们得

$$\tilde{x}_{k+1} = \tilde{f}_k(\tilde{x}_k, u_k, w_k),$$

式中 $\tilde{f}_k$ 由式(4.17)按明显的方式进行定义。初始状态是

$$\tilde{x}_0 = (x_0, \theta).$$

将代价泛函作适当的变换,所得问题成为适合通常框架的问题。

必须注意,因为 $y_k = \theta$ 是不能观测的,即使控制器收到状态 x_k 精确的量测值,我们仍面临一个具有不完全状态信息的问题。而且,参数向量通常使增广系统式(4.17)成为非线性,并以这种方式进入状态方程。结果,在绝大多数情况下,用 DP 算法实际上不可能得到一个最优控制器。因此,需要次优控制器,本节我们将讨论在设计中所涉及到的某些问题。然后为 ARMAX 模型考虑一种确定性等价控制器,称之为自校正调节器,它成功地应用在实际中。

谨慎, 探测和双重控制

次优控制常常受最优控制定性结果的引导,所以力图弄清后者的某些特征是重要的。其中之一是“谨慎”和“探测”之间需要平衡。这两个概念最好用一个例子来说明。

考虑线性标量系统

$$x_{k+1} = x_k + bu_k + w_k, \quad k = 0, 1, \dots, N-1,$$

和二次终端代价 $E\{x_N^2\}$ 。这里除了控制系数 b 未知之外,每一个量都与 § 2.1 一样(完全状态

信息)。进而, 已知 b 的先验概率分布是高斯的, 且具有如下均值和方差

$$\bar{b} = E\{b\} > 0, \quad \sigma_b^2 = E\{(b - \bar{b})^2\}.$$

而且, w_k 是零均值高斯的; 对每个 k , 方差为 σ_w^2 。

首先考虑 $N=1$ 的情况, 其代价为

$$E\{x_1^2\} = E\{(x_0 + bu_0 + w_0)^2\}.$$

简单的计算给出 u_0 的最小值:

$$u_0 = -\frac{\bar{b}}{\bar{b}^2 + \sigma_b^2} x_0,$$

且最优代价为

$$\frac{\sigma_b^2}{\bar{b}^2 + \sigma_b^2} x_0^2 + \sigma_w^2.$$

所以这里的最优控制是谨慎的, 即随着 b 的不确定性 (即 σ_b^2) 的增加, $|u_0|$ 减小。

其次考虑 $N=2$ 的情况, 在阶段 1 的最优余留代价由前面给定的计算获得:

$$J_1(I_1) = \frac{\sigma_b^2(1)}{[\bar{b}(1)]^2 + \sigma_b^2(1)} x_1^2 + \sigma_w^2, \quad (4.18)$$

式中 $I_1 = (x_0, u_0, x_1)$ 是信息向量, 且

$$\bar{b}(1) = E\{b | I_1\}, \quad \sigma_b^2(1) = E\{[b - \bar{b}(1)]^2 | I_1\}.$$

$\sigma_b^2(1)$ 的值可以由方程 $x_1 = x_0 + bu_0 + w_0$ 和标准的最小二乘估计理论的结果获得 (见 [A1] 和 [L7])。最终结果对我们没有进一步的用处, 所以我们只加以叙述而不加计算:

$$\sigma_b^2(1) = \frac{\sigma_b^2 \sigma_w^2}{u_0^2 \sigma_b^2 + \sigma_w^2}. \quad (4.19)$$

从式 (4.18) 我们看到, 在阶段 1 我们希望 $\sigma_b^2(1)$ 小; 而从式 (4.19) 得出, 为达到这一点, 我们必须施加一个绝对值大的控制 u_0 。选择大的控制以增强参数辨识叫做探测。另一方面, 若 $|u_0|$ 大, $|x_1|$ 也大, 根据式 (4.18) 这是不希望的。所以在选择 u_0 时, 必须在谨慎 (u_0 小, 使 x_1 保持合理地小) 和探测 (值大, 改善信噪比和加强 b 的辨识) 之间进行平衡。这种在控制目标和参数辨识目标之间的折衷被称为双重控制。这常常在系统参数未知, 但在大多数情况下又遗憾地不能精确定量时显示出来。

二阶段控制和可辨识性

在出现未知参数时, 次优控制一个明显的合理形式是把控制过程分离为两个阶段: 参数辨识阶段和控制阶段。在第一阶段辨识未知参数, 而控制不考虑辨识的中间结果。第二阶段利用由第一阶段得到的最后参数估计, 以实现一个最优控制律。为了考虑参数的不断变化, 在任何系统运行期间, 这种辨识和控制阶段的交替可能要重复好多次。

这个方法的一个缺点是在辨识阶段期间所收集的信息, 在第二阶段开始之前, 不能用来调节控制律。而且, 决定何时终止一个阶段和开始另一阶段常常并不容易。

第二个困难更具有根本性的实质, 即控制过程可能使得某些未知参数对辨识过程是不显现的。这就是参数可辨识性问题 [L7], 对此最好用例子来说明。

例题 1

考虑标量系统

$$x_{k+1} = ax_k + bu_k + w_k, \quad k=0, 1, \dots, N-1,$$

具有二次代价

$$E\left\{\sum_{k=1}^N x_k^2\right\}.$$

我们假定是完全状态信息,好象参数 a 和 b 均为已知,这是一个最小方差控制问题(见 § 3.3)。最优控制律为

$$\mu_k^*(x_k) = -\frac{a}{b}x_k.$$

现在假定参数 a 和 b 为未知,并考虑二阶段方法。在第一阶段采用控制律

$$\tilde{\mu}_k(x_k) = \gamma x_k, \quad (4.20)$$

(γ 是某个标量,例如 $\gamma = -\bar{a}/\bar{b}$, 式中 $\bar{a}$ 和 $\bar{b}$ 为 a 和 b 的先验估计)。在第一阶段末了,控制律变成

$$\tilde{\mu}_k(x_k) = -\frac{\hat{a}}{\hat{b}}x_k,$$

式中 $\hat{a}$ 和 $\hat{b}$ 是从辨识过程得到的估计值。然而,用控制律式(4.20),闭环系统为

$$x_{k+1} = (a + b\gamma)x_k + w_k,$$

所以辨识过程最多只能辨识 $(a + b\gamma)$ 的值,而不是 a 和 b 两个值。换句话说,辨识过程不能区分满足 $a_1 + b_1\gamma = a_2 + b_2\gamma$ 的 (a_1, b_1) 值和 (a_2, b_2) 值。所以当加上形式为式(4.20)的反馈控制时, a 和 b 是不可辨识的。

克服这个困难的一种方法是在控制律式(4.20)中加上一个附加的已知输入 δ_k , 即用

$$\tilde{\mu}_k(x_k) = \gamma x_k + \delta_k.$$

于是闭环系统变成

$$x_{k+1} = (a + b\gamma)x_k + b\delta_k + w_k,$$

从 $\{x_k\}$ 和 $\{\delta_k\}$ 的知识,有可能辨识 $(a + b\gamma)$ 和 b 。给定 γ , 就可以得到 a 和 b 的估计值。实际上,为了在系统具有较高维数的更一般情况下保证这一点,序列 $\{\delta_k\}$ 必须满足某些条件:它必须是“持续激励的”(见[L8])。

解决可辨识性问题的第二种可能性是人为地在控制反馈中引入一个单位时延,以改变系统的结构。因此不考虑具有形式 $\tilde{\mu}_k(x_k) = \gamma x_k$ 的控制律,而是考虑具有以下形式的控制

$$u_k = \tilde{\mu}_k(x_{k-1}) = \gamma x_{k-1}.$$

因此闭环系统变成

$$x_{k+1} = ax_k + b\gamma x_{k-1} + w_k,$$

给定 γ , 可以辨识参数 a 和 b 。这个技术可以推广到任意阶次的系统。但人为地引入一个控制时延,对可辨识性问题似乎不是一个理想的解答。

确定性等价控制和可辨识性

在某种意义上与两阶段方法正好相对的一个方案是当产生参数估计值时,把它们结合到控制律中去,当作是真实的参数值。这个方法本质上是 § 4.2 考虑过的确定性等价控制器。根据以前研究过的系统

$$x_{k+1} = f_k(x_k, \theta, u_k, w_k).$$

假设对 θ 的各可能值, 控制律 $\pi^*(\theta) = \{\mu_0^*(\cdot, \theta), \dots, \mu_{N-1}^*(\cdot, \theta)\}$ 对某代价 $J_\pi(x_0, \theta)$ 是最优的。那么在时刻 k 所采用的(次优)控制为

$$\hat{\mu}_k(I_k) = \mu_k^*(x_k, \hat{\theta}_k),$$

式中 $\hat{\theta}_k$ 是根据时刻 k 可利用的信息

$$I_k = \{x_0, x_1, \dots, x_k, u_0, \dots, u_{k-1}\}$$

对 θ 的估计值。例如

$$\hat{\theta}_k = E\{\theta | I_k\},$$

或者更恰当地, 它是通过在线系统辨识方法所得的估计值。

遗憾的是可辨识性的困难也与此方法联系在一起。为了简单, 假设系统是平稳的, 具有先验已知转移概率 $P\{x_{k+1} | x_k, u_k, \theta\}$ 。所加的控制律也是平稳的:

$$\hat{\mu}_k(I_k) = \mu^*(x_k, \hat{\theta}_k), \quad k = 0, 1, \dots.$$

则在时刻 k , 给定估计 $\hat{\theta}_k$, 控制器“认为”系统的概率演变受下式支配

$$P\{x_{k+1} | x_k, \mu^*(x_k, \hat{\theta}_k), \hat{\theta}_k\}.$$

然而, 真正的概率演变受下式支配

$$P\{x_{k+1} | x_k, \mu^*(x_k, \hat{\theta}_k), \theta^*\},$$

这里 θ^* 是真实的参数值。现在假设, 对某些 $\hat{\theta} \neq \theta^*$ 和所有 x_{k+1}, x_k , 我们有

$$P\{x_{k+1} | x_k, \mu^*(x_k, \hat{\theta}), \hat{\theta}\} = P\{x_{k+1} | x_k, \mu^*(x_k, \hat{\theta}), \theta^*\}. \quad (4.21)$$

即: 存在一个虚假的参数值, 在闭环控制下的系统看起来此虚假值似乎是真的一样。因此, 在某时刻如果控制器估计参数为 $\hat{\theta}$, 以后的数据将倾向于支持这个有误差的估计。结果情况会发展到辨识过程固定在一个错误的参数值, 而且所加的控制不管如何搜索充足的信息, 都将永远地偏离最优。

关系式(4.21)说明了在闭环控制下不可辨识问题的实质。真实参数值不能唯一地由闭环系统的概率演变来确定。

下面的例子说明这个困难。

例题 2[B33]

考虑一个两状态且具有控制 u^1 和 u^2 的系统。转移概率取决于所加控制以及参数 θ , 该 θ 已知取 θ^* 和 $\hat{\theta}$ 二值之一。如图 4.10 所示。对于由状态 1 到它本身的转移, 代价为零; 对所有其它转移, 代价为 1。所以, 在状态 1 的最优控制, 是使状态保持为 1 的概率为最大的控制。假定真实参数为 θ^* , 则最优控制为 u^2 。但如果控制器“认为”真实参数是 $\hat{\theta}$, 就会施加控制 u^1 。因为在 u^1 下, 对不论哪一个参数值, 看起来都是一样的, 以后的数据会倾向于支持控制器的想法, 以为真实参数确为 $\hat{\theta}$ 。

更确切地说, 假设在每个时刻 k , 参数估计方法选择 θ 值, 使

$$P\{\theta | I_k\} = \frac{P\{I_k | \theta\}P(\theta)}{P(\theta)}$$

极大, 式中 $P(\theta)$ 是真实参数为 θ 的先验概率(这个方法几乎与最大似然方法一样)。则如果 $P(\hat{\theta}) > P(\theta^*)$, 可以看出控制器将在每一时刻 k , 将 θ 错误地估计为 $\hat{\theta}$, 并应用不正确的控

制 u^1 。

例题 3[K11]

考虑线性标量系统

$$x_{k+1} = ax_k + bu_k + w_k,$$

这里我们知道参数或为 $(a, b) = (1, 1)$, 或为 $(a, b) = (0, -1)$ 。序列是独立、平稳、零均值和高斯的。代价为二次形式

$$\sum_{k=0}^{N-1} (x_k^2 + 2u_k^2),$$

式中 N 非常大, 所以采用最优控制律的平稳形式 (见 § 2.1 和 § 7.4)。通过黎卡提方程, 这个控制律可计算为

$$\mu^*(x_k) = \begin{cases} -\frac{x_k}{2}, & \text{若 } (a, b) = (1, 1), \\ 0, & \text{若 } (a, b) = (0, -1). \end{cases}$$

为了估计 (a, b) , 我们用最小二乘辨识方法。在时刻 k , 最小二乘判据的值给出为

$$V_k(1, 1) = \sum_{i=0}^{k-1} (x_{i+1} - x_i - u_i)^2, \text{ 对 } (a, b) = (1, 1), \quad (4.22a)$$

$$V_k(0, -1) = \sum_{i=0}^{k-1} (x_{i+1} + u_i)^2, \text{ 对 } (a, b) = (0, -1). \quad (4.22b)$$

在时刻 k , 施加的控制为

$$u_k = \tilde{\mu}_k(I_k) = \begin{cases} -\frac{x_k}{2}, & \text{若 } V_k(1, 1) < V_k(0, -1), \\ 0, & \text{若 } V_k(1, 1) > V_k(0, -1). \end{cases}$$

假设真实参数为 $\theta^* = (0, -1)$, 则真实系统按

$$x_{k+1} = -u_k + w_k \quad (4.23)$$

演变。如果在时刻 k , 由于 $V_k(\hat{\theta}) < V_k(\theta^*)$, 控制器错误地将参数估计为 $\hat{\theta} = (1, 1)$, 所加控制将是 $u_k = -\frac{x_k}{2}$, 而真实的闭环系统将按

$$x_{k+1} = \frac{x_k}{2} + w_k \quad (4.24)$$

演变。另一方面, 控制器认为 (给定估计值 $\hat{\theta}$) 闭环系统按

$$x_{k+1} = x_k + u_k + w_k = x_k - \frac{x_k}{2} + w_k = \frac{x_k}{2} + w_k \quad (4.25)$$

演变; 所以从式(4.24)和式(4.25)我们看到, 在控制律 $u_k = -x_k/2$ 情况下, 参数值不论是真还是假, 闭环系统演变是一样的 [参见式(4.21)]。

为了明白怎样会造成错误, 注意对某个 k , 若 $V_k(\hat{\theta}) < V_k(\theta^*)$, 由式(4.23)至式(4.25), 我们将有




图 4.10 对于例题 2, 两状态系统的转移概率。在非最优控制 u^1 的情况下, 系统看起来对参数 θ 的真值和假值是一样的。

$$x_{k+1} + u_k = x_{k+1} - x_k - u_k,$$

所以由式(4.22a)和式(4.22b), 我们得到

$$V_{k+1}(\hat{\theta}) < V_{k+1}(\theta^*).$$

所以, 如果 $V_1(\hat{\theta}) < V_1(\theta^*)$, 对每个 k , 最小二乘辨识方法会得到错误估计值 $\hat{\theta}$ 。为了明白这可能以正概率发生, 注意, 由于真实系统为 $x_{k+1} = -u_k + w_k$, 我们有

$$V_1(\hat{\theta}) = (x_1 - x_0 - u_0)^2 = (w_0 - x_0 - 2u_0)^2,$$

$$V_1(\theta^*) = (x_1 - u_0)^2 = w_0^2.$$

故不等式 $V_1(\hat{\theta}) < V_1(\theta^*)$ 等价于

$$(x_0 + 2u_0)^2 < 2w_0(x_0 + 2u_0),$$

因为 w_0 是高斯的, 它会以正概率发生。

最后我们指出: 从直觉上想象, 如果参数估计值收敛于某个 $\hat{\theta} \neq \theta^*$, 则对于这个 $\hat{\theta}$, 在式(4.21)意义上失去可辨识性是非常可能的。因为一般来说, 在辨识方法中, 参数估计的收敛蕴含着所得数据与基于当前估计所拥有的系统观察渐近一致。这将在后来的 ARMAX 模型、最小二乘辨识以及最小方差控制的文章中得以证明。在其它方面也可以证明(比如有有限状态系统和最大似然辨识, 见[B32]和[B33], 这些论文首先明确了刚才所述的论题)。结论是失去可辨识性是一个严重问题; 典型地, 在确定性等价控制中要碰到这种问题。

自校正调节器

前面我们描述了在确定性等价控制中不可辨识性论题的本质。即在闭环控制下, 不正确的估计会使系统的行为好象这些参数是正确的一样[参阅式(4.21)]。结果辨识会固定在虚假的参数值上。然而, 这并不一定不好, 因为也许在虚假参数值基础上所实现的控制律会接近最优。事实上, 通过一个偶然的巧合可以得出: 在实际方面重要的最小方差控制描述中 (§3.3), 当参数估计收敛时, 它们典型地收敛于虚假值, 但是产生的控制律却典型地收敛于最优。通过一个例子, 我们可以得到有关这一现象的一个概念。

例题 4

考虑最简单的 ARMAX 模型:

$$y_{k+1} + ay_k = bu_k + \epsilon_{k+1},$$

当 a 和 b 为已知时, 最小方差控制律为

$$u_k = \mu_k(I_k) = -\frac{a}{b} y_k.$$

现在假设 a 和 b 不知道, 但用某种方法可在线辨识。施加的控制为

$$u_k = -\frac{\hat{a}_k}{\hat{b}_k} y_k, \quad (4.26)$$

式中 $\hat{a}_k$ 和 $\hat{b}_k$ 是在时刻 k 得到的估计。设真实参数值为 a^* 和 b^* , 则当

$$\hat{a}_k \rightarrow \hat{a}, \quad \hat{b}_k \rightarrow \hat{b}$$

时, 出现可辨识性困难, 式中 $\hat{a}$ 、 $\hat{b}$ 使得如下真实闭环系统

$$y_{k+1} + a^* y_k = \frac{b^* \hat{a}}{\hat{b}} y_k + \epsilon_{k+1}$$

与基于估计 $\hat{a}$ 和 $\hat{b}$ 而控制器认为是真实的闭环系统一致。后一个系统为

$$y_{k+1} = \epsilon_{k+1}.$$

因为这两个系统是一样的, 我们必须有

$$\frac{a^*}{b^*} = \frac{\hat{a}}{\hat{b}},$$

这意味着仅管渐近估计 $\hat{a}$ 和 $\hat{b}$ 可能不正确, 控制律式(4.26)渐近地成为最优。

例题 4 可以推广到 § 3.3 无滞后的一般 ARMAX 模型:

$$y_k + \sum_{i=1}^m a_i y_{k-i} = \sum_{i=1}^m b_i u_{k-i} + \epsilon_k + \sum_{i=1}^m c_i \epsilon_{k-i}. \quad (4.27)$$

如果参数估计收敛(不管采用的辨识方法), 则最小方差控制器认为闭环系统渐近地为

$$y_k = \epsilon_k \quad (4.28)$$

(参阅 § 3.3)。所以, 若发生可辨识性困难, 真实的闭环系统也必渐近地由式(4.28)给出, 且显然是最优闭环系统。

总之, 我们已经证明, 若参数估计收敛于某个值, 对于这个估计值, 在式(4.21)意义上失去了可辨识性, 那么, 对于 ARMAX 模型所产生的最小方差控制律 不管采用什么辨识方法是渐近最优的。现在我们通过证明强调这一结论: 如果采用最小二乘类型的辨识方法, 参数估计收敛只出现在失去可辨识性的值上(而因此使得相应的最小方差控制律渐近最优)。事实上, 即使辨识所采用的模型在某种程度上是不正确的, 这种情况也会出现。

假定真实系统给定为

$$y_k + \sum_{i=1}^m a_i^* y_{k-i} = \sum_{i=1}^m b_i^* u_{k-i} + \epsilon_k + \sum_{i=1}^m c_i^* \epsilon_{k-i} \quad (4.29)$$

为了简单, 我们要求 $b_i^* \neq 0$ (这个假定可以放松, 主要利用不久即要给出的同样证明)。假定控制器为如下形式的模型

$$y_k + \sum_{i=1}^m a_i y_{k-i} = \sum_{i=1}^m b_i u_{k-i} + \epsilon_k,$$

且应用最小方差控制

$$u_k = \hat{\rho}_k(I_k) = \frac{1}{\hat{b}_1^k} \left(\sum_{i=1}^m \hat{a}_i^k y_{k-i+1} - \sum_{i=2}^m \hat{b}_i^k u_{k-i+1} \right), \quad (4.30)$$

式中估计 $\hat{a}_i^k, \hat{b}_i^k$ 是对 a_i 和 b_i 使下式极小:

$$\sum_{n=1}^k \left(y_n + \sum_{i=1}^m a_i y_{n-i} - \sum_{i=1}^m \hat{b}_i^k u_{n-i} \right)^2.$$

把此表达式对 a_i 的导数置零, 对所有 $i=1, \dots, m$, 我们得

$$\sum_{n=1}^k y_{n-i} \left(y_n + \sum_{i=1}^m \hat{a}_i^k y_{n-i} - \sum_{i=1}^m \hat{b}_i^k u_{n-i} \right) = 0 \quad (4.31)$$

现在假定当 $k \rightarrow \infty$ 时, 估计 $\hat{a}_i^k$ 和 $\hat{b}_i^k$ 收敛于某个 $\hat{a}_i$ 和 $\hat{b}_i$:

$$\hat{a}_i^k \rightarrow \hat{a}_i, \quad \hat{b}_i^k \rightarrow \hat{b}_i, \quad i=1, \dots, m.$$

则由于利用最小方差控制式(4.30), 我们有

$$\sum_{i=1}^n \hat{a}_i y_{n-i} - \sum_{i=1}^n \hat{b}_i u_{n-i} \rightarrow 0, \quad \text{当 } n \rightarrow \infty,$$

所以由式(4.31), 对闭环系统得到

$$\lim_{k \rightarrow \infty} \frac{1}{k} \sum_{i=1}^k y_{k-i} y_k = 0, \quad i = 1, \dots, m.$$

在适当(遍历性)假设下, 上述方程中时间平均可代之以总体平均, 它意味着当 $k \rightarrow \infty$ 时, 渐近地有

$$E\{y_{k-i} y_k\} = 0, \quad i = 1, \dots, m.$$

所以, 当 $k \rightarrow \infty$ 时, 输出 y_k 与过去输出 y_{k-i} , $i = 1, 2, \dots$, 渐近不相关。由此得出, 真实的闭环系统渐近地变成

$$y_k = \epsilon_k. \quad (4.32)$$

这是最优的, 甚至当所有系统参数为已知时也可以由最小方差控制达到。

注意, 如果 $c_i^* \neq 0$, 渐近估计 $\hat{a}_i$ 和 $\hat{b}_i$ 将不会收敛到真实值 a_i^* 和 b_i^* 。甚至在最简单的 $m=1$ 和 $c_1^* = 0$ 的情况, 由式(4.32)所蕴含的唯一关系是 $a_1^*/b_1^* = \hat{a}_1/\hat{b}_1$ 。

前面的论证也可用来对稍微不同的最小二乘辨识方法证明一个类似的结果; 也可以对它其它辨识方法证得类似的结果, 但证明有些不一样[K10]。再重复一下, 如果最小二乘参数估计收敛, 则得到一个渐近最优的最小方差控制律。

接着要遇到的问题是小二乘估计是否确实收敛。广泛的仿真已经表明, 对许多系统这些估计收敛, 而且已经建立了整个控制方案的实用性。然而, 关于收敛性课题的完整分析已激起许多研究者的努力, 目前已有的部分成果[K6]还没有结合起来形成一个综合性理论。关于这个专题研究状况的说明请参看综述论文[K10]。然而, 作为一个通用的过程控制算法, 目前自校正调节器已被证明在实践中正方兴未艾, 且有广泛的应用前景。

§ 4.5 注 记

由高维数所引起的问题长期以来一直被认为是 DP 的主要缺点。由贝尔曼和他的助手以及其它学者作了很大努力寻找部分的补救办法(例如见[B5], [B6]和[N2])。一类两阶段问题——称为随机规划——可以用数学规划技术来求解(见习题 1, 2; 参考文献[V1], [B10], [B13], [R3]和[W2]及其所引的文献)。

习题 4 的例子表明 CEC 的性能可能比最优开环控制器还差的结论, 属于威辛豪森(见[T1])。关于 CEC 有趣的敏感性问题, 见[M1]。开环反馈控制的思想出于 Dreyfus[D8], 它对于开环控制的优越性建立在[B17]中极大极小控制关系上。这个结果的推广在[W4]中给出。除这里所给出的之外, 次优控制器曾由许多作者提出[B1, B21, T3, T4, T5, D5, S1, S2, S24 和 S32]。随着 Åström 和 Wittenmark[A14]的论文发表, 自校正调节器受到广泛的注意。Kumar 已研究了具有未知参数一般线性二次问题[K11], 而且对自适应控制提出很精彩的综述[K10], 也见[A12], [G3], [L6]和[L8]。具有未知参数的马尔科夫链控制在[B32], [B33], [D7], [K12]和[M12]已作了研究。

实际上一旦用了次优控制器, 希望知道所得的代价如何近似最优。关于次优控制器性能的紧边界是有用的, 但通常很难得到。在这方面有关的重要结果见[W14]和[W15]。

习 题

1. 两阶段问题和确定性优化。本问题的作用是证明某些随机控制问题如何能由(确定性)数学规划方法求解。考虑第一章基本问题的下述情况: 只有两个阶段($N=2$), 且对初始阶段, 扰动空间为一个有限集合 $D_0 = \{w_0^1, \dots, w_0^r\}$ 。 w_0^i , $i=1, \dots, r$ 的概率用 p_i 表示, 且与 x_0 和 u_0 无关。

证明由下式给出的最优代价函数 $J_0(x_0)$

$$J_0(x_0) = \min_{u_0 \in U_0(x_0)} \sum_{i=1}^r p_i [g_0(x_0, u_0, w_0^i) + \min_{u_1 \in U_1[f_0(x_0, u_0, w_0^i)]} E \{g_1[f_0(x_0, u_0, w_0^i), u_1, w_1] + g_2[f_1[f_0(x_0, u_0, w_0^i), u_1, w_1]]\},$$

等于以下问题的最优代价

$$\begin{aligned} \min_{\substack{u_0, z_i, u_1 \\ i=1, \dots, r}} \sum_{i=1}^r p_i [g_0(x_0, u_0, w_0^i) + z_i] \\ \text{s. t. } z_i \geq E_{w_1} \{g_1[f_0(x_0, u_0, w_0^i), u_1^i, w_1] + g_2[f_1[f_0(x_0, u_0, w_0^i), u_1^i, w_1]]\}, \\ u_0 \in U_0(x_0), \quad u_1^i \in U_1[f_0(x_0, u_0, w_0^i)]. \end{aligned}$$

再证明这个数学规划问题的解如何可以用来获取一个最优控制律。

2. 随机规划。考虑关于 x 求极小的问题:

$$g(x) + E \left\{ \min_{y \geq 0} q' y \right. \\ \left. f(x) + A y = r \right\}$$

$$\text{s. t. } h_i(x) = 0, \quad i=1, \dots, s, \quad l_j(x) \leq 0, \quad j=1, \dots, p,$$

式中 $x \in R^n$, $y \in R^m$, q 是 R^m 中给定的一个向量, $r \in R^k$ 是一个随机向量, 以给定的概率 $p_1, \dots, p_t$ 取值于有限个值 $r_1, \dots, r_t$ 。 g, h_i, l_j 是给定的连续可微实值函数; $f: R^n \rightarrow R^k$ 是一个连续可微映射, A 是给定的 $k \times m$ 矩阵。证明这个问题可以看成是一个适合第一章中基本问题框架的两个阶段问题。再证明这问题如何可转换成一个确定性问题, 它可以由标准的数学规划方法求解。

3. 考虑一个具有完全状态信息, 包括 § 2.1 的 n 维线性系统

$$x_{k+1} = A_k x_k + B_k u_k + w_k, \quad k=0, 1, \dots, N-1,$$

和一个形式为

$$E_{w_k} \left\{ g_N(c' x_N) + \sum_{k=0}^{N-1} g_k(u_k) \right\}$$

$k=0, \dots, N-1$

的代价泛函的问题。式中 $c \in R^n$ 是一给定向量。证明该问题的 DP 算法可以在一维状态空间得出。

4. 考虑如下二维、两阶段具有标量控制和扰动的线性系统

$$x_{k+1} = x_k + b u_k + d w_k, \quad k = 0, 1,$$

式中 $b = [1, 0]'$, $d = [1/2, \sqrt{2}/2]'$, 初始状态 $x_0 = 0$, 控制 u_0 和 u_1 是无约束的, 扰动 w_0 和 w_1 是独立恒定分布的随机变量。它们各以概率 $1/2$ 取值 $+1$ 和 -1 。呈现完全状态信息。代价为

$$E \{ \|x_2\| \},$$

w_0, w_1

式中 $\|\cdot\|$ 表示通常的欧式范数。证明最优开环代价和最优闭环代价均为 $\sqrt{3}/2$, 但相应于 CEC 的代价为 1。

5. 考虑包括如下标量系统具有完全状态信息的一个两阶段问题

$$x_0 = 1, \quad x_1 = x_0 + u_0 + w_0, \quad x_2 = f(x_1, u_1).$$

控制约束为 $u_0, u_1 \in \{0, -1\}$, 随机变量 w_0 以相同的概率 $1/2$ 取值 $+1$ 和 -1 。函数 f 定义为

$$f(1, 0) = f(1, -1) = f(-1, 0) = f(-1, -1) = 0.5,$$

$$f(2, 0) = 0, \quad f(2, 1) = 2, \quad f(0, -1) = 0.6, \quad f(0, 0) = 2.$$

代价函数为

$$E \{ x_2 \}.$$

w_0

(a) 证明对此问题, 一个可能的 OLFC 为

$$\bar{\mu}_0(x_0) = -1; \quad \bar{\mu}_1(x_1) = \begin{cases} 0, & \text{如 } x_1 = \pm 1, 2, \\ -1, & \text{如 } x_1 = 0. \end{cases} \quad (4.33)$$

且最终代价为 0.5。

(b) 证明对此问题的一个可能的 CEC 为

$$\tilde{\mu}_0(x_0) = 0, \quad \tilde{\mu}_1(x_1) = \begin{cases} 0, & \text{若 } x_1 = \pm 1, 2, \\ -1, & \text{若 } x_1 = 0, \end{cases} \quad (4.34)$$

且产生的代价为 0.3。再证明这个 CEC 是一个最优反馈控制器。

6. 考虑习题 5 的系统和代价泛函, 但区别为

$$f(0, -1) = 0.$$

(a) 证明习题 5 的控制器式 (4.33), 既是一个 OLFC, 又是一个 CEC, 并且相应的代价为 0.5。

(b) 假定第一阶段控制约束集为 $\{0\}$, 不是 $\{0, -1\}$ 。证明习题 5 的控制器式 (4.34) 既是一个 OLFC, 又是一个 CEC。其相应的代价为 0。

注意, 这个问题说明了在次优控制中普遍出现的一种病态。为理解这一点, 考虑一个问题, 和一个对该问题不是最优的次优策略。令 $\pi^* = \{\mu_0^*, \dots, \mu_{N-1}^*\}$ 为最优策略, 将控制约束集加以限定, 使得在状态 x_k 只许有最优控制 $\mu^*(x_k)$ 。则由次优控制策略所达到的代价将会改善。

7. 证明关于自校正调节器收敛性质的 Åström-Wittenmark 的结果在以下不论哪种情况也成立。

(a) 不估计参数 b_1 的值, 而是当所有其它参数用最小二乘估计时, 它在某一非零固定值保持不变。

(b) 控制时延大于 1。

8. 提出一种详细的论证, 证明有和无 $\alpha-\beta$ 修剪搜索棋局将获得相同的结果。

9. 在一种 Nim 赌博中, 两个赌徒以 5 便士赌注开始, 轮流从赌注中取走 1, 2, 或 3 便士, 拿走最后一个便士的人为输。构造对策树并证明第二个取钱的人可用最优的手法取胜。

第五章 无限时域问题：理论部分

本书其余各章将讨论迄今已考虑过，但在两方面不同于以前的这样一些问题。首先，阶段数是无限的；其次，系统是平稳的，即每阶段的系统方程和代价函数，以及随机扰动的统计特性并不随阶段的变化而变化。当然，无限阶段的假设只是一种数学上的表述，因为实际上从来都不满足，它包含了对有限但阶段数很大问题的合理近似。平稳性假设在实际中经常是满足的，有些情况下，是对系统参数随时间非常缓慢变化情况的合理近似。

按一般规律，无限时域问题较之有限时域问题要求有更加复杂的分析方法。困难具有两重性，其一，是无限时域问题要求分析极限行为，如 DP 算法及其相应最优策略的收敛性；这种分析往往是非常困难的，但有时出现惊人的可能性。其二，是对包含不可数扰动空间问题的严格概率分析，需要有关测度概率论方面的复杂工具。这些困难要比在有限时域问题分析中所遇到的困难严重得多，远远超出了本书所介绍的范围。由于这一原因，以及在无限时域问题分析中需要比有限时域问题更加高的严密性，所以我们将只限于扰动空间是可数集的情况。文献[B23]详细论述了有关不可数扰动空间的数学基础，而且对这一高级课题给出了比较完整的处理。

从积极方面来看，无限时域问题的分析往往是完美的，而且最优策略的实现又往往是简单的。例如：最优策略典型地是平稳的，即施加控制的最优规则并不随阶段的变化而变化。

传统上，主要感兴趣的无限时域问题有如下三类：

(a) 在每阶段代价有界的折扣情况下，代价函数取如下形式

$$J_{\pi}(x_0) = \lim_{N \rightarrow \infty} E_{w_h} \left\{ \sum_{h=0}^{N-1} \alpha^h g[x_h, \mu_h(x_h), w_h] \right\},$$

$h=0, 1, \dots$

其中 $J_{\pi}(x_0)$ 表示与初态 x_0 和策略 $\pi = \{\mu_0, \mu_1, \dots\}$ 相应的代价； α 是一个标量，且 $0 < \alpha < 1$ ，称为折扣因子。每阶段代价 $g(x, u, w)$ 是上一致有界和下一致有界的。这种情况将在 § 5.1 到 § 5.3 进行讨论，而且是最简单的无限时域问题。这主要是因为 DP 迭代中出现了一个收缩映射 (§ 5.3)。此处没有病态，有效的计算方法可用于问题求解。

(b) 在每阶段代价无界的情况，代价函数与 (a) 有相同的形式，只是标量 α 是正实数，但不必小于单位 1；进而，每阶段代价容许是上无界或下无界的。这个问题在 § 5.4 讨论。

(c) 仅当 $J_{\pi}(x_0)$ 至少对某个容许的策略 π 和某个初态 x_0 为有限时，(a) 中 $J_{\pi}(x_0)$ 求极小才有意义，在许多感兴趣的问题中，将会得出 $J_{\pi}(x_0) = +\infty$ ，但极限

$$\lim_{N \rightarrow \infty} \frac{1}{N} E_{w_h} \left\{ \sum_{h=0}^{N-1} g[x_h, \mu_h(x_h), w_h] \right\}$$

$h=0, 1, \dots$

对于每个策略 $\pi = \{\mu_0, \mu_1, \dots\}$ 和初态 x_0 都是有限的。在此情况下，试图使上式达到极小是合理的，它可以视为策略 π 相应的每阶段平均代价。这是第七章要讨论的主题，在那里，我们把注意力主要放在有限状态马尔科夫链问题上。

在本书以后全部的章节中，我们将集中考虑完全信息情况。不完全信息问题按第三章处理方法使其转变为包含充分统计的完全信息问题。本章将集中讨论第一章基本问题如下无限

时域的平稳形式。

问题 I：总期望代价的无限时域问题。考虑一个平稳的离散时间动态系统

$$x_{k+1} = f(x_k, u_k, w_k), \quad k=0, 1, 2, \dots, \quad (5.1)$$

其中状态 x_k , $k=0, 1, \dots$, 是空间 S 的一个元, 控制 u_k , $k=0, 1, \dots$, 是空间 C 的一个元, 而随机扰动 w_k , $k=0, 1, \dots$, 是空间 D 的一个元。假定 D 是一个可数集, 控制 u_k 被约束在 C 的一个给定的非空子集 $U(x_k)$ 中取值, 而 $U(x_k)$ 依赖于当前的状态 x_k [$u_k \in U(x_k)$, 对所有的 $x \in S$, $k=0, 1, \dots$]。随机扰动 w_k , $k=0, 1, \dots$, 具有恒等的统计特性, 而且由定义在 D 上的概率 $P(\cdot | x_k, u_k)$ 来表征, 其中 $P(w_k | x_k, u_k)$ 是当前状态和控制分别为 x_k 和 u_k 时, w_k 发生的概率。 w_k 的概率可能显依赖于 x_k 和 u_k , 但不依赖于以前的扰动值 $w_{k-1}, \dots, w_0$ 。

给定初状 x_0 , 问题为寻找一个策略 $\pi = \{\mu_0, \mu_1, \dots\}$, 其中 $\mu_k: S \rightarrow C, \mu_k(x_k) \in U(x_k)$, 对所有 $x_k \in S$, $k=0, 1, \dots$, 使得如下代价泛函数为极小[原注]

$$J_\pi(x_0) = \lim_{N \rightarrow \infty} E_{w_k} \left\{ \sum_{k=0}^{N-1} \alpha^k g[x_k, \mu_k(x_k), w_k] \right\}, \quad (5.2)$$

并受系统方程(5.1)约束。实值函数 $g: S \times C \times D \rightarrow R$ 是给定的, 标量 α 是正实数。

注意, 在我们容许任意的状态和控制空间的同时, 要求扰动空间是一个可数集。为了避免在 § 1.1 讨论过的数学复杂性, 这一要求是必须的。然而, 在许多感兴趣的问题中, 特别是确定性最优控制问题, 以及有限和可数状态马尔科夫链控制问题, 我们的假设是满足的。对于其他一些问题, 我们的主要结果按照这里给出的相同论证方法[B23], 仍能得到证明(在附加的技术条件下)。

由式(5.2)给出的代价 $J_\pi(x_0)$ 表示有限时域代价的极限。正如 § 1.1 讨论的, 这一代价函数是适当定义的。另一种可能性是通过 π 对期望无限时域代价

$$E_{w_k} \left\{ \sum_{k=0}^{\infty} \alpha^k g[x_k, \mu_k(x_k), w_k] \right\}.$$

求极小。这样的代价泛函将要求更加复杂的数学描述(所有扰动序列空间上的一个概率测度, 参见[B23])。然而, 在我们将使用的假设条件下, 上式等于由式(5.2)给出的代价。这可以用单调收敛定理(见 § 5.4)加以证明, 即在我们已满足的条件下, 求极限和数学期望是可以互换的。

在本章的前三节, 我们将在下述假设下讨论问题:

假设 D (折扣代价)。每阶段代价 g 满足。

$$0 \leq g(x, u, w) \leq M, \text{ 对所有 } (x, u, w) \in S \times C \times D, \quad (5.3)$$

其中 M 是某个标量, 且 $0 < \alpha < 1$ 。

注意, 式(5.3)能够被如下形式的不等式替代

$$M_2 \leq g(x, u, w) \leq M_1,$$

其中 M_1 和 M_2 是任意的标量, 这是因为对 g 加上常量 r 只需对代价加上 $(1-\alpha)^{-1}r$ 。假设

原注: 以后总假定 $g(x, u, w)$ 对所有 x, u, w 要么非负, 要么非正。所以式(5.2)的极限适当定义为一个实数或 $\pm \infty$ 。

D 并非限制到不能出现。对空间 S 、 C 和 D 均为有限集这类问题,它是成立的。即使这些空间不是有限集,在问题求解期间,它们将常用有限集近似。在另外一些情况下,可以将此问题变换,使它定义在使式(5.3)成立的状态与控制空间的一个有界区域。

用 Π 表示所有容许策略 π 的集合,即所有函数序列 $\pi = \{\mu_0, \mu_1, \dots\}$ 的集合,且 $\mu_k: S \rightarrow C$, 对所有 $x \in S$, $k = 0, 1, \dots, \mu_k(x) \in U(x)$ 。最优代价函数 J^* 由下式给出

$$J^*(x) = \min_{\pi \in \Pi} J_\pi(x), \quad x \in S,$$

在假设 D 下,它作为一个实值函数是适当定义的。事实上,利用式(5.2)和式(5.3),容易看出对所有 $x \in S$ 有 $0 \leq J^*(x) \leq M \sum_{k=0}^{\infty} \alpha^k = M/(1-\alpha)$ 。

使我们特别感兴趣的一类容许策略是平稳策略类,具有 $\pi = \{\mu, \mu, \dots\}$ 的形式;对这类策略,每阶段控制选择规则是相同的。本章通篇隐含地假定平稳策略是容许的。与一个平稳策略 $\{\mu, \mu, \dots\}$ 以及初态 $x \in S$ 相应的代价可记为 $J_\mu(x)$, 即对 $\pi = \{\mu, \mu, \dots\}$, 我们写成

$$J_\mu(x_0) = J_\pi(x_0) = \lim_{N \rightarrow \infty} E_{w_k} \left\{ \sum_{k=0}^{N-1} \alpha^k g[x_k, \mu(x_k), w_k] \right\}. \quad (5.4)$$

$k = 0, 1, \dots$

类似地对 J^* , 在假设 D 下, J_μ 也适当地定义为一个实值函数。平稳策略 $\{\mu^*, \mu^*, \dots\}$ 为最优的论述,本章通篇是指,对所有 $x \in S$, $J^*(x) = J_{\mu^*}(x)$ 。

下一节将给出最优代价函数 J^* 的一个特点,并在假设 D 下提出一些基本结果。§ 5.2 在假定状态、控制和扰动均为有限集的情况下,描述计算方法。在 § 5.1 和 § 5.2 得到的结果将通过在 § 5.3 给出的收缩映射概念加以解释。在 § 5.4 中,我们将放松假设 D, 而且考虑每阶段代价是上无界或下无界的情况。最后,我们将在 § 5.5 考虑系统及每阶段代价非平稳或周期性问题。我们将证明,这些问题能够变换成包含平稳系统及每阶段代价的问题。这样,我们有可能得到类似于平稳问题的非平稳问题的简单结果。

§ 5.1 基本结果

考虑利用截项由无限时域问题得到的一个 N 阶段问题。这个问题就是寻找策略 $\pi_N = \{\mu_0, \mu_1, \dots, \mu_{N-1}\}$, 且对所有 $x_k \in S$, $\mu_k(x_k) \in U(x_k)$, 使得

$$J_{\pi_N}(x_0) = E_{w_k} \left\{ \sum_{k=0}^{N-1} \alpha^k g[x_k, \mu_k(x_k), w_k] \right\} \quad (5.5)$$

$k = 0, 1, \dots, N-1$

在系统方程约束下达到极小。对每个初态 x_0 , 该问题的最优代价是 $V_0(x_0)$, 其中 V_0 是由 DP 算法的最后一步给出。

$$V_N(x) = 0, \quad x \in S,$$

$$V_k(x) = \min_{u \in U(x)} E_w \{ \alpha^k g(x, u, w) + V_{k+1}[f(x, u, w)] \},$$

$$x \in S, \quad k = 0, 1, \dots, N-1$$

用 α^k 除两边, 且记

$$J_{N-k}(x) = \alpha^{-k} V_k(x), \quad x \in S, \quad k = 0, 1, \dots, N,$$

这些方程就能写成

$$J_0(x) = 0, \quad x \in S \quad (5.6)$$

$$J_{k+1}(x) = \min_{u \in U(x)} \min_w E\{g(x, u, w) + \alpha J_k[f(x, u, w)]\},$$

$$x \in S, \quad k = 0, 1, \dots, N-1 \quad (5.7)$$

最优代价是 $J_N(x_0)$ 。

算法式(5.6)、式(5.7)等价于原始的 DP 算法。主要区别是余留代价函数的标号倒过来,使得现在的算法是由标号 k 从小到大地进行。 $J_k(x)$ 能够被解释为从状态 x 开始前进 k 步(而不是 $N-k$)所得到的最小代价(即 k 阶段最优代价)。因为在无限时域问题中阶段的数目是不定的,利用 J_k 比利用 V_k 更方便。正因为如此,在本书以后的章节中将用式(5.6)、式(5.7)形式的 DP 算法。

我们希望推导具有式(5.5)代价的 N 阶段问题与相应无限时域问题之间的关系,但在此之前需要引入某些记法和预备知识。

对于任意函数 $J: S \rightarrow R$, $\mu: S \rightarrow C$, 且对所有的 $x \in S$, 我们记:

$$T(J)(x) = \min_{u \in U(x)} \min_w E\{g(x, u, w) + \alpha J[f(x, u, w)]\}, \quad (5.8)$$

$$T_\mu(J)(x) = \min_w E\{g[x, \mu(x), w] + \alpha J[f(x, \mu(x), w)]\}. \quad (5.9)$$

(当我们写 $T(J)(x)$ 或 $T_\mu(J)(x)$ 时,总隐含假定这个期望值是适当定义的)。注意 $T(J)(\cdot)$ 和 $T_\mu(J)(\cdot)$ 都是定义在状态空间 S 上的函数,而 T, T_μ 也可以视为一种映射,它把 S 上的一个函数 J 变换为 S 上的另一个函数 $[T(J)$ 或 $T_\mu(J)]$ 。

映射 T 和 T_μ 起着重要的理论作用。在表达式中,它提供了用其它方法难以表述的简便记法。因此,读者应该牢固掌握它们的含义。由定义式(5.8)和式(5.9)可以看出, $T(J)(x)$ 就是具有初始状态 x 、阶段代价 g , 以及终端代价函数 αJ 时的单阶段问题的最优代价。类似地, $T_\mu(J)(x)$ 是对同一问题相应于策略 $\{\mu, \mu, \dots\}$ 的代价。

我们用 T^k 表示映射 J 本身 k 次复合算子,即对所有 x 和 k

$$T^k(J)(x) = T[T^{k-1}(J)](x), \quad T^0(J)(x) = J(x).$$

类似地, T_μ^k 的定义为

$$T_\mu^k(J)(x) = T_\mu[T_\mu^{k-1}(J)](x), \quad T_\mu^0(J)(x) = J(x).$$

可以看出, $T^k(J)(x)$ 就是具有初始状态 x , 每阶段代价 g , 和终端代价函数 $\alpha^k J$ 的 k 阶段、 α 折扣问题的最优代价。类似地, $T_\mu^k(x)$ 就是对同一问题策略 $\{\mu, \mu, \dots\}$ 的代价。注意,按照这一记法,相应于零终端代价函数的有限时域问题,式(5.6),式(5.7)的 DP 算法可写成:

$$J_0(x) = 0, \quad (5.10)$$

$$J_k(x) = T^k(J_0)(x). \quad (5.11)$$

最后,考虑一个 k 阶段问题的一个 k 阶段策略 $\{\mu_0, \mu_1, \dots, \mu_{k-1}\}$, 然后对于 $i = 0, \dots, k-2$ 递推地定义 $(T_{\mu_0} T_{\mu_1} \dots T_{\mu_{k-1}})(J)(x)$ 为

$$(T_{\mu_1} T_{\mu_{i+1}} \dots T_{\mu_{k-1}})(J)(x) = T_{\mu_i}[(T_{\mu_{i+1}} \dots T_{\mu_{k-1}})(J)](x)$$

它表示了具有初态 x , 每阶段代价 g , 以及终端代价 $\alpha^k J$ 时的 k 阶段、 α 折扣问题的策略代价。

下面的单调性特性在本章推导过程中具有重要的作用。

引理 1 对于任意函数 $J: S \rightarrow R$, $J': S \rightarrow R$, 使得

$$J(x) \leq J'(x), \quad \text{对所有 } x \in S,$$

和对任意函数 $\mu: S \rightarrow C$, 且对所有 $x \in S$, $\mu(x) \in U(x)$, 我们有

$$\begin{aligned} T^k(J)(x) &\leq T^k(J')(x), & x \in S, & k=1,2,\dots, \\ T_\mu^k(J)(x) &\leq T_\mu^k(J')(x), & x \in S, & k=1,2,\dots. \end{aligned}$$

证明: 这个证明由以前给出的将 $T^k(J)(x)$ 和 $T_\mu^k(J)(x)$ 解释为 k 阶段问题代价而得到。
(当终端代价函数一致增大时, k 段代价亦一致增大。) 证毕

对于任意两个函数 $J: S \rightarrow R$, $J': S \rightarrow R$, 如果对所有 $x \in S$, $J(x) \leq J'(x)$, 我们说

$$J \leq J',$$

利用这种记法, 引理 1 可以表述为

$$\begin{aligned} J \leq J' &\Rightarrow T^k(J) \leq T^k(J'), & k=1,2,\dots, \\ J \leq J' &\Rightarrow T_\mu^k(J) \leq T_\mu^k(J'), & k=1,2,\dots. \end{aligned}$$

记 $e: S \rightarrow R$ 为单位函数, 它对 S 上的元恒取值 1:

$$e(x) = 1, \quad \text{对所有 } x \in S. \quad (5.12)$$

由式(5.8)、式(5.9), 对任意函数 $J: S \rightarrow R$, 任意标量 r , 以及所有 $x \in S$, 我们有

$$\begin{aligned} T(J+re)(x) &= T(J)(x) + ar, \\ T_\mu(J+re)(x) &= T_\mu(J)(x) + ar. \end{aligned}$$

更一般地说, 由归纳法我们可以证明如下引理。

引理 2 对于每个 k , 函数 $J: S \rightarrow R$, 平稳策略 $\{\mu, \mu, \dots\}$, 以及标量 r , 我们有

$$T^k(J+re)(x) = T^k(J)(x) + \alpha^k r, \quad \text{对所有 } x \in S, \quad (5.13)$$

$$T_\mu^k(J+re)(x) = T_\mu^k(J)(x) + \alpha^k r, \quad \text{对所有 } x \in S. \quad (5.14)$$

下面的命题证明, 对于任意有界起始函数 J , 式(5.6)和式(5.7)[或式(5.10)和式(5.11)]的 DP 算法, 收敛到一个最优代价函数 J^* 。这也可以视为假设 D 的直接结果, 后者意味着代价 $E\{\sum_{h=N}^\infty \alpha^h g(x_h, u_h, w_h)\}$ 的“尾项”, 当 $N \rightarrow \infty$ 时减小为零。而且, 即使一个终端代价 $\alpha^N J(x_N)$ 加在 N 阶段代价上, 当 J 有界时, 随 $N \rightarrow \infty$, 其作用减小为零。

命题 1 (DP 算法的收敛性) 对于任何有界函数 $J: S \rightarrow R$, 下式成立:

$$J^*(x) = \lim_{k \rightarrow \infty} T^k(J)(x), \quad \text{对所有 } x \in S. \quad (5.15)$$

证明: 由式(5.3)知, 对任何初始状态 $x \in S$, 以及每个策略 $\{\mu_0, \mu_1, \dots\}$,

$$\lim_{N \rightarrow \infty} E\left\{\sum_{h=0}^{N-1} \alpha^h g[x_h, \mu_h(x_h), w_h]\right\} \leq E\left\{\sum_{h=0}^{N-1} \alpha^h g[x_h, \mu_h(x_h), w_h]\right\} + M \sum_{h=N}^\infty \alpha^h$$

通过 $\{\mu_0, \mu_1, \dots\}$ 将上式两边求极小, 则

$$J^*(x) \leq J_N(x) + \left(\frac{\alpha^N}{1-\alpha}\right)M, \quad \text{对所有的 } x \in S, N=0,1,\dots \quad (5.16)$$

其中 J_N 是对所有 N , 由式(5.6)和式(5.7)[或式(5.10)和式(5.11)]定义。又因为每阶段代价非负, 则

$$J_N(x) \leq J^*(x), \quad \text{对所有 } x \in S. \quad (5.17)$$

结合两个不等式得:

$$J^*(x) = \lim_{N \rightarrow \infty} J_N(x), \quad \text{对所有 } x \in S. \quad (5.18)$$

现在, 对任意有界函数 $J: S \rightarrow R$, 设 r 是一个标量, 使得

$$J_0 - re \leq J \leq J_0 + re, \quad (5.19)$$

式中 J_0 是零函数。把 T^k 应用到这一关系, 再利用引理 2 得:

$$T^k(J_0) - \alpha^k r e \leq T^k(J) \leq T^k(J_0) + \alpha^k r e. \quad (5.20)$$

因为 $T^k(J_0)$ 收敛到 J^* [方程(5.18)], 而 $\alpha^k r$ 收敛于零。所以结果成立。

证毕

给定任何平稳策略 $\{\mu, \mu, \dots\}$, 我们可以认为, 除了对每个状态 x , 控制约束集仅含一个元(控制 $\mu(x)$), 即约束集的形式为 $\tilde{U}(x) = \{\mu(x)\}$, $x \in S$ 之外, 这与命题 1 讨论的问题是相同的。显然, 此时假设 D 仍是满足的, 因为只有一个容许策略 $(\{\mu, \mu, \dots\})$, 应用命题 1 产生如下推论。

推论 1.1 设 $J_\mu(x)$ 是当初始状态为 x 时, 相应于平稳策略 $\{\mu, \mu, \dots\}$ 的代价泛函式(5.2) 的值, 则对任何有界函数 $J: S \rightarrow R$, 下式成立

$$J_\mu(x) = \lim_{k \rightarrow \infty} T_\mu^k(J)(x), \quad x \in S. \quad (5.21)$$

下一个命题将证明 J^* 是泛函方程的唯一解。这个方程就是所谓贝尔曼方程, 它为获得一个平稳最优策略提供了方法。

命题 2 (贝尔曼方程, 最优性的充分与必要条件)

(a) 最优代价函数 J^* 满足

$$J^*(x) = \min_{u \in U(x)} E\{g(x, u, w) + \alpha J^*[f(x, u, w)]\}, \quad x \in S. \quad (5.22)$$

或等价地写成

$$J^*(x) = T(J^*)(x), \quad x \in S$$

同时, J^* 是这个方程的唯一有界解。

(b) 一个平稳策略 $\{\mu^*, \mu^*, \dots\}$ 是最优的, 当且仅当 $\mu^*(x)$ 对所有 $x \in S$ 在式 (5.22) 中达到极小; 也就是说,

$$T(J^*)(x) = T_{\mu^*}(J^*)(x), \quad x \in S.$$

证明 (a) 由式(5.16)有

$$J_k \leq J^* \leq J_k + \left(\frac{M\alpha^k}{1-\alpha}\right)e.$$

把映射 T 应用于这一关系, 且利用引理 2 可得

$$J_{k+1} \leq T(J^*) \leq J_{k+1} + \left(\frac{M\alpha^{k+1}}{1-\alpha}\right)e.$$

又因为 J_{k+1} 收敛于 J^* (命题 1), 根据上面的关系, 当 $k \rightarrow \infty$ 时取极限得 $J^* = T(J^*)$ 。

为了证明唯一性, 简单地观察如果 J 是有界的, 且满足 $J = T(J)$, 那么 $J = \lim_{k \rightarrow \infty} T^k(J)$, 由命题 1 得 $J = J^*$ 。

(b) 为证明这一部分, 让我们叙述下面的推论, 这一推论从命题 2 部分得到, 证明与由命题 1 得到推论 1.1 的推理相同。

推论 2.1 设 $\{\mu, \mu, \dots\}$ 是一个平稳策略,

$$J_\mu(x) = E_{\tilde{w}}\{g[x, \mu(x), w] + \alpha J_\mu[f(x, \mu(x), w)]\}, \quad x \in S, \quad (5.23)$$

或等价地写成

$$J_\mu(x) = T_\mu(J_\mu)(x), \quad x \in S,$$

而且, J_μ 是这个方程的唯一有界解。

现在, 如果对每个 $x \in S$, $\mu^*(x)$ 使式(5.22)右边极小, 则对所有 $x \in S$, 我们有

$$J^*(x) = E_w \{g[x, \mu^*(x), w] + \alpha J^*[f(x, \mu^*(x), w)]\}.$$

因此, 由推论的唯一性部分, 对所有 $x \in S$, 必有 $J^*(x) = J_{\mu^*}(x)$, 从而知 $\{\mu^*, \mu^*, \dots\}$ 是最优的。同样, 如果 $\{\mu^*, \mu^*, \dots\}$ 是最优的, 则有 $J^* = J_{\mu^*}$ 。同时, 由推论得 $J_{\mu^*} = T_{\mu^*}(J_{\mu^*})$ 。

因此, $J^* = T_{\mu^*}(J^*)$, 此即意味着对所有 $x \in S$, $\mu^*(x)$ 在式(5.22)中达到极小。证毕

注意, 命题 2 意味着, 当对所有 $x \in S$, 式(5.22)右边达到极小值时, 存在最优平稳策略。

最后, 我们证明如下收敛速率估计, 它对任意有界函数 J 成立:

$$\max_{x \in S} |T^k(J)(x) - J^*(x)| \leq \alpha^k \max_{x \in S} |J(x) - J^*(x)|, \quad k = 0, 1, \dots$$

这一关系是下述结果的一个特殊情况。

命题 3 对于任意两个有界函数 $J: S \rightarrow R, J': S \rightarrow R$, 以及对所有 $k = 0, 1, \dots$, 下式成立。

$$\max_{x \in S} |T^k(J)(x) - T^k(J')(x)| \leq \alpha^k \max_{x \in S} |J(x) - J'(x)|. \quad (5.24)$$

证明: 记

$$c = \max_{x \in S} |J(x) - J'(x)|$$

则有

$$J - ce \leq J' \leq J + ce$$

把 T^k 用于这一关系, 而且利用引理 2 得

$$T^k(J) - \alpha^k ce \leq T^k(J') \leq T^k(J) + \alpha^k ce.$$

于是有

$$|T(J)(x) - T(J')(x)| \leq \alpha^k c, \quad x \in S,$$

此即证明了结论。

证毕

正如前面一样, 我们有:

推论 3.1 对于任意两个有界函数 $J: S \rightarrow R, J': S \rightarrow R$, 以及任意平稳策略 $\{\mu, \mu, \dots\}$, 则有

$$\max_{x \in S} |T_\mu^k(J)(x) - T_\mu^k(J')(x)| \leq \alpha^k \max_{x \in S} |J(x) - J'(x)|, \quad k = 0, 1, \dots$$

由迄今所建立的命题得出的主要结论是: 最优代价函数 J^* 是式(5.22)贝尔曼方程的唯一有界解。只要该式右边达到极小值, 则方程产生一个最优平稳解。进而, 由任意有界函数 J 开始, DP 算法以极限形式产生了函数 J^* , 其收敛速率至少比一个几何级数的收敛速率快 (命题 3)。于是, DP 算法至少能够用来实际计算 J^* 的近似值。这种计算方法以及另外一些方法将在下一节讨论。本节其余部分用来研究两个例题。

资产出售例题

考虑 § 2.4 的资产出售问题。当这个问题视为一个无限时域问题时, 则其本质上是一个具有折扣因子 $\alpha = 1/(1+r)$ 的折扣代价问题 [参见方程(2.65)]。如果我们假定报价 x 是有界的, 则本节分析结果是可用的, 而且最优价值函数就是贝尔曼方程的唯一解

$$J^*(x) = \max [x, (1+r)^{-1} E(J^*(w))].$$

由此方程得到的最优策略具有如下形式：如果当前的报价 $\geq (1+r)^{-1}E\{J^*(w)\} = \bar{\alpha}$ ，则出售；反之则不出售。临界数 $\bar{\alpha} = (1+r)^{-1}E\{J^*(w)\}$ 与 § 2.4 所得相同。

部件更换问题

设一个机床的某个部件处在用 $[0, 1]$ 区间表示的连续状态中的某个状态。在每个周期的开始时刻，该部件经受检测，确定其当前的状态 $x \in [0, 1]$ ，并作出决策，是否在状态 $x = 0$ ，以代价 $R > 0$ 用新部件来替换。对于单个周期，给定部件处于状态 x 时，期望代价为 $C(x)$ ，其中 $C(\cdot)$ 是一个非负有界的、 $[0, 1]$ 区间上 x 的增函数。给定该部件在周期开始的状态 x ，在周期终止处在小于或等于 z 状态的条件概率分布 $F(z|x)$ 是已知的；而且，对每个非减函数 $J: [0, 1] \rightarrow R$ ，则有

$$\int_y^1 J(z) dF(z|x_1) \leq \int_y^1 J(z) dF(z|x_2), \quad \text{对 } 0 \leq x_1 \leq x_2 \leq 1.$$

这个假设意味着该部件使用时逐渐趋于损坏；也就是说，对于每个 $y \in [0, 1]$ ，当处于一个较坏的初始状态时，该部件的最终状态处于 $[y, 1]$ 区间的机会较大。假定一个折扣因子 $\alpha \in (0, 1)$ 而且是一个无限时域，该问题就是确定最优更换策略。

该问题显然属于本节所研究问题的框架之内，而且最优代价函数 J^* 就是贝尔曼方程的唯一有界解。

$$J^*(x) = \min \left[R + C(0) + \alpha \int_0^1 J^*(z) dF(z|0), C(x) + \alpha \int_0^1 J^*(z) dF(z|x) \right].$$

一个最优更换策略由下式给出

$$\begin{cases} \text{更换, 如果 } R + C(0) + \alpha \int_0^1 J^*(z) dF(z|0) \leq C(x) + \alpha \int_0^1 J^*(z) dF(z|x); \\ \text{否则不更换.} \end{cases}$$

现在，考虑 DP 算法

$$\begin{aligned} J_0(x) &= 0, \\ T(J_0)(x) &= \min[R + C(0), C(x)], \\ T^k(J_0)(x) &= \min \left[R + C(0) + \alpha \int_0^1 T^{k-1}(J_0)(z) dF(z|0), \right. \\ &\quad \left. C(x) + \alpha \int_0^1 T^{k-1}(J_0)(z) dF(z|x) \right], \quad k = 1, 2, \dots \end{aligned}$$

因为 $C(x)$ 是 x 的递增函数，则 $T(J_0)(x)$ 是 x 的非减函数；而且根据我们对 $F(z|x)$ 的假设， $T^2(J_0)(x)$ 也是 x 的非减函数。类似地，对所有 k ， $T^k(J_0)(x)$ 也是 x 的非减函数，而且，如下极限函数也是 x 的非减函数

$$J^*(x) = \lim_{k \rightarrow \infty} T^k(J_0)(x).$$

在我们的假设下可以得出：函数 $C(x) + \alpha \int_0^1 J^*(z) dF(z|x)$ 是 x 的增函数。这简单地反映了一个直观的明显事实：当初始状态增大时，（即从一个较坏的初始状态开始），最优代价不可能减小，于是，最优代价取如下形式

如果 $x \geq x^*$ ，更换；

如果 $x < x^*$ ，不更换。

其中 x^* 是一个标量，它满足




图 5.1 在更换例题中确定最优策略

$$R + C(0) + \alpha \int_0^1 J^*(z) dF(z|0) = C(x^*) + \alpha \int_0^1 J^*(z) dF(z|x^*),$$

如图 5.1 所示。

§ 5.2 计算方法：逐次逼近，策略迭代，自适应集结，线性规划

本节将提出在假设 D 条件下求解无限时域问题的各种不同的方法。第一种方法即逐次逼近法，本质上就是 DP 算法；而且正如上一节所讨论的那样以最优代价函数和最优策略的极限产生。我们将描述旨在加速收敛的某些形式。其它两种方法：策略迭代和线性规划方法，都是以有限步迭代而终止（假定所涉及的空间是有限集）。然而，当状态的数目较大时，因为每次迭代计算量过份大，这些方法变得不切实际。自适应集结是一种新的方法，它在逐次逼近和策略迭代之间填补了间隙，而且在某种意义上说是结合了这两种方法的优点。

在这一节，我们通篇假定假设 D 成立，而且问题所涉及的空间 S 、 C 和 D 均为有限集。于是，实际上我们是在处理有限状态马尔科夫链控制问题。

设 S 由 n 个状态构成，分别记为 $1, 2, \dots, n$ ，即

$$S = \{1, 2, \dots, n\}$$

设 $p_{ij}(u)$ 表示转移概率

$$p_{ij}(u) = P(x_{k+1} = j | x_k = i, u_k = u), \quad i, j \in S, u \in U(i).$$

于是 $p_{ij}(u)$ 就是给定当前状态 i ，并把控制 $u \in U(i)$ 加于系统之后，下一个状态是 j 的概率。转移概率既可以是先验给定的，也可以由系统方程

$$x_{k+1} = f(x_k, u_k, w_k)$$

以及输入扰动 w_k 的已知概率分布 $P(\cdot | x, u)$ 计算得到。事实上，我们有

$$p_{ij}(u) = P[W_{ij}(u) | i, u],$$

其中 $w_{ij}(u)$ 就是如下（有限）集合

$$W_{ij}(u) = \{W \in D | f(i, u, w) = j\}.$$

在处理马尔科夫链时，为简化标记，我们假定每阶段代价并不依赖于 w 。这相当于在处理所有计算中利用每阶段的期望代价，无论在映射 T 和 T_μ 的定义或者在以后的分析中，都不会产生本质上的差异。基本表达式

$$g(i, u) + \alpha E\{J[f(i, u, w)]\}$$

可以按 $p_{ij}(u)$ 的形式写成

$$g(i, u) + \alpha \sum_{j=1}^n p_{ij}(u) J(j), \quad i \in S.$$

结果, 式(5.8)和(5.9)的映射 T 与 T_μ 可以写成

$$T(J)(i) = \min_{u \in U(i)} \left[g(i, u) + \alpha \sum_{j=1}^n p_{ij}(u) J(j) \right], \quad i = 1, 2, \dots, n,$$

$$T_\mu(J)(i) = g[i, \mu(i)] + \alpha \sum_{j=1}^n p_{ij}[\mu(i)] J(j), \quad i = 1, 2, \dots, n.$$

函数 $J, T_\mu(J)$ 可以由 n 维向量表示

$$J = \begin{pmatrix} J(1) \\ \vdots \\ J(n) \end{pmatrix}, \quad T_\mu(J) = \begin{pmatrix} T_\mu(J)(1) \\ \vdots \\ T_\mu(J)(n) \end{pmatrix}.$$

如果我们组成转移概率矩阵

$$P_\mu = \begin{pmatrix} p_{11}[\mu(1)] & \cdots & p_{1n}[\mu(1)] \\ \vdots & & \vdots \\ p_{n1}[\mu(n)] & \cdots & p_{nn}[\mu(n)] \end{pmatrix},$$

并且考虑 n 维向量 g_μ 定义为

$$g_\mu = \begin{pmatrix} g[1, \mu(1)] \\ \vdots \\ g[n, \mu(n)] \end{pmatrix},$$

则我们可以按向量形式写成

$$T_\mu(J) = g_\mu + \alpha P_\mu J.$$

相应于平稳策略 $\{\mu, \mu, \dots\}$ 的代价函数 J_μ , 由推论 2.1 知, 它是如下方程的唯一解

$$J_\mu = T_\mu(J_\mu) = g_\mu + \alpha P_\mu J_\mu. \quad (5.25)$$

这个方程也可以写成

$$(I - \alpha P_\mu) J_\mu = g_\mu,$$

或等价地写成

$$J_\mu = (I - \alpha P_\mu)^{-1} g_\mu,$$

其中 I 表示 $n \times n$ 单位阵。矩阵 $I - \alpha P_\mu$ 的可逆性是保证的, 因为我们已经证明: 代表方程 $J_\mu = T_\mu(J_\mu)$ 的方程组对于任意向量 g_μ 有唯一解(参看推论 2.1)。

逐次逼近与误差界限

我们由一个 n 维向量 J 开始, 逐次计算 $T(J), T^2(J), \dots$, 其中 T 由式(5.8)定义。根据命题 1 有

$$\lim_{k \rightarrow \infty} T^k(J)(i) = J^*(i), \quad i \in S.$$

而且, 由命题 3 知, 对于所有 $i \in S$, $|J^*(i) - T^k(J)(i)|$ 是由一个几何级数的倍乘来定界。令人感兴趣的是, 逐次逼近法在有限步迭代之后将产生一个最优策略(见习题 14)。由于某

些误差界限的可用性，这个方法可从实质上获得改进，现在我们予以解释。

为理解这些界限的实质，注意一个平稳策略 $\{\mu, \mu, \dots\}$ 的代价可以表示为

$$J_\mu(i) = g[i, \mu(i)] + \sum_{k=1}^{\infty} \alpha^k E\{g[x_k, \mu(x_k)] | x_0 = i\}.$$

从而得

$$g_\mu + \left(\frac{\alpha\beta}{1-\alpha}\right)e \leq J_\mu \leq g_\mu + \left(\frac{\alpha\bar{\beta}}{1-\alpha}\right)e, \quad (5.26)$$

其中 e 是单位向量， $e = [1, 1, \dots, 1,]'$ ，而 β 与 $\bar{\beta}$ 是每阶段的最小和最大代价：

$$\beta = \min_i g_\mu[i, \mu(i)], \quad \bar{\beta} = \max_i g_\mu[i, \mu(i)].$$

利用 β 和 $\bar{\beta}$ 的定义，我们可把式(5.26)进一步表示为

$$\left(\frac{\beta}{1-\alpha}\right)e \leq g_\mu + \left(\frac{\alpha\beta}{1-\alpha}\right)e \leq J_\mu \quad (5.27)$$

$$\leq g_\mu + \left(\frac{\alpha\bar{\beta}}{1-\alpha}\right)e \leq \left(\frac{\bar{\beta}}{1-\alpha}\right)e.$$

现在，把这些界限应用到逐次逼近法的推导过程中。假定有向量 J ，计算

$$T_\mu(J) = g_\mu + \alpha P_\mu J.$$

利用这一方程消去如下方程中的 g_μ

$$J_\mu = g_\mu + \alpha P_\mu J_\mu,$$

从而得

$$J_\mu - J = T_\mu(J) - J + \alpha P_\mu (J_\mu - J),$$

这就是方程 $J_\mu = T_\mu(J_\mu)$ 的一种变分形式。由此方程得出： $J_\mu - J$ 是与策略 $\{\mu, \mu, \dots\}$ ，以及等于 $(T_\mu(J) - J)$ 的每阶段代价相应的代价向量。因此，在式(5.27)中用 $J_\mu - J$ 代替 J_μ ，用 $T_\mu(J) - J$ 代替 g_μ ，从而得

$$\begin{aligned} \left(\frac{\gamma}{1-\alpha}\right)e &\leq T_\mu(J) - J + \left(\frac{\alpha\gamma}{1-\alpha}\right)e \leq J_\mu - J \\ &\leq T_\mu(J) - J + \left(\frac{\alpha\bar{\gamma}}{1-\alpha}\right)e \leq \left(\frac{\bar{\gamma}}{1-\alpha}\right)e, \end{aligned}$$

式中

$$\gamma = \min_i [T_\mu(J)(i) - J(i)], \quad \bar{\gamma} = \max_i [T_\mu(J)(i) - J(i)].$$

等效地，对于每个向量 J 有

$$\begin{aligned} J + \left(\frac{\gamma}{1-\alpha}\right)e &\leq T_\mu(J) + \left(\frac{\alpha\gamma}{1-\alpha}\right)e \leq J_\mu \\ &\leq T_\mu(J) + \left(\frac{\alpha\bar{\gamma}}{1-\alpha}\right)e \leq J + \left(\frac{\bar{\gamma}}{1-\alpha}\right)e. \end{aligned}$$

下面的命题是更巧妙地应用前述论断而得出的。

命题 4 对于每个向量 J ，状态 i 、以及 k ，有

$$\begin{aligned} T^k(J)(i) + c_k &\leq T^{k+1}(J)(i) + c_{k+1} \\ &\leq J^*(i) \leq T^{k+1}(J)(i) + \bar{c}_{k+1} \leq T^k(J)(i) + \bar{c}_k, \end{aligned} \quad (5.28)$$

其中

$$c_k = \frac{\alpha}{1-\alpha} \min_{i \in S} [T^k(J)(i) - T^{k-1}(J)(i)], \quad (5.29)$$

$$\bar{c}_k = \frac{\alpha}{1-\alpha} \max_{i \in S} [T^k(J)(i) - T^{k-1}(J)(i)]. \quad (5.30)$$

证明, 记

$$\gamma = \min_{i \in S} [T(J)(i) - J(i)].$$

则有

$$J + \gamma e \leq T(J). \quad (5.31)$$

把 T 作用于两边, 再利用 T 的单调性及式(5.13)得

$$T(J) + \alpha \gamma e \leq T^2(J), \quad (5.32)$$

并且由于式(5.31), 则

$$J + (1+\alpha)\gamma e \leq T(J) + \alpha \gamma e \leq T^2(J) \quad (5.33)$$

重复这个过程, 先用 T 作用得

$$T(J) + (\alpha + \alpha^2)\gamma e \leq T^2(J) + \alpha^2 \gamma e \leq T^3(J), \quad (5.34)$$

然后利用式(5.31)写成

$$J + (1 + \alpha + \alpha^2)\gamma e \leq T(J) + (\alpha + \alpha^2)\gamma e \leq T^2(J) + \alpha^2 \gamma e \leq T^3(J). \quad (5.35)$$

k 步之后, 将导致一个不等式

$$\begin{aligned} J + \left(\sum_{i=0}^k \alpha^i\right) \gamma e &\leq T(J) + \left(\sum_{i=1}^k \alpha^i\right) \gamma e \\ &\leq T^2(J) + \left(\sum_{i=2}^k \alpha^i\right) \gamma e \leq \dots \leq T^{k+1}(J). \end{aligned}$$

当 $k \rightarrow \infty$ 时, 取极限得

$$J + \left(\frac{c_1}{\alpha}\right) e \leq T(J) + c_1 e \leq T^2(J) + \alpha c_1 e \leq J^*, \quad (5.36)$$

其中 c_1 是由式(5.29)定义。用 $T^k(J)$ 代替这个不等式中的 J , 则有

$$T^{k+1}(J) + c_{k+1} e \leq J^*,$$

这就是式(5.28)中的第二个不等式。

由式(5.33)有

$$\alpha \gamma \leq \min_{i \in S} [T^2(J)(i) - T(J)(i)],$$

从而有

$$\alpha c_1 \leq c_2.$$

把这一结果用于式(5.36)得

$$T(J) + c_1 e \leq T^2(J) + c_2 e,$$

用 $T^{k-1}(J)$ 代替 J , 则有式(5.28)中的第一个不等式。类似的方法可以证明式(5.28)中最后

两个不等式。

证毕

注意, 式(5.28)的误差界限能够在逐次逼近法的计算中作为一个附带结果, 很容易地计算出来。下面的例题将表明这种情况。

例题:


考虑一个问题, 其中有两个状态和两个控制

$$S = \{1, 2\}, \quad C = \{u^1, u^2\}.$$


相应于控制 u^1 和 u^2 转移概率示于图 5.2, 即有转移概率矩阵

$$P(u^1) = \begin{bmatrix} p_{11}(u^1) & p_{12}(u^1) \\ p_{21}(u^1) & p_{22}(u^1) \end{bmatrix} = \begin{bmatrix} \frac{3}{4} & \frac{1}{4} \\ \frac{3}{4} & \frac{1}{4} \end{bmatrix},$$

$$P(u^2) = \begin{bmatrix} p_{11}(u^2) & p_{12}(u^2) \\ p_{21}(u^2) & p_{22}(u^2) \end{bmatrix} = \begin{bmatrix} \frac{1}{4} & \frac{3}{4} \\ \frac{1}{4} & \frac{3}{4} \end{bmatrix}.$$



(a)



(b)

图 5.2 例中的状态转移图: (a) $u = u^1$, (b) $u = u^2$

转移代价如下:

$$g(1, u^1) = 2, \quad g(1, u^2) = 0.5, \quad g(2, u^1) = 1, \quad g(2, u^2) = 3,$$

折扣因子 $\alpha = 0.9$ 。映射 T 由下式给出

$$T(J)(i) = \min \left\{ g(i, u^1) + \alpha \sum_{j=1}^2 p_{ij}(u^1) J(j), \right.$$

$$\left. g(i, u^2) + \alpha \sum_{j=1}^2 p_{ij}(u^2) J(j) \right\}, \quad i = 1, 2.$$

式(5.29)和(5.30)中的 c_k 和 $\bar{c}_k$ 为

$$c_k = \frac{\alpha}{1-\alpha} \min \{ T^k(J)(1) - T^{k-1}(J)(1), T^k(J)(2) - T^{k-1}(J)(2) \},$$

$$\bar{c}_k = \frac{\alpha}{1-\alpha} \max \{ T^k(J)(1) - T^{k-1}(J)(1), T^k(J)(2) - T^{k-1}(J)(2) \}.$$

由零函数 J_0 [$J_0(1) = J_0(2) = 0$] 开始, 逐次逼近法的结果示于表 5.1, 而且用于说明误差界限的功能和实用性。

实际中, 当误差界限的差值 $(\bar{c}_k - c_k)$ 变得充分小时, 就终止逐次逼近迭代, 而 J^* 的最终估计为如下的“中值”

$$\tilde{J}_k = T^k(J) + \left(\frac{\bar{c}_k - c_k}{2} \right) e$$

或者“平均值”

$$\hat{J}_k = T^k(J) + \frac{\alpha}{n(1-\alpha)} \sum_{i=1}^n [T^k(J)(i) - T^{k-1}(J)(i)] e.$$

这两个向量都处在由误差界限限定的区域之内。如果存在唯一的平稳策略 $\{\mu^*, \mu^*, \dots\}$, 能够证明[B20]: $\hat{J}_k$ 和 $\tilde{J}_k$ 趋于最优代价向量 J^* 的速率, 受转移概率矩阵 P_{μ^*} 的次主特征值

表 5.1 带有或不带有命题 4 误差界限的逐次逼近法的性能指标

k	$T^k(J_0)(1)$	$T^k(J_0)(2)$	$T^k(J_0)(1) + c_k$	$T^k(J_0)(1) + \bar{c}_k$	$T^k(J_0)(2) + c_k$	$T^k(J_0)(2) + \bar{c}_k$
0	0.00000	0.00000				
1	0.50000	1.00000	5.00000	9.50000	5.50000	10.00000
2	1.28750	1.56250	6.35000	8.37500	6.62500	8.65000
3	1.84438	2.22063	6.85625	7.76750	7.23250	8.14375
4	2.41391	2.74459	7.12962	7.53969	7.46031	7.87038
5	2.89573	3.24692	7.23214	7.41665	7.58333	7.76786
6	3.34321	3.68517	7.28750	7.37054	7.62946	7.71250
7	3.73972	4.08583	7.30826	7.34563	7.65437	7.69174
8	4.09937	4.44362	7.31947	7.33628	7.66372	7.68053
9	4.42180	4.76689	7.32367	7.33124	7.66876	7.67633
10	4.71256	5.05727	7.32594	7.32935	7.67065	7.67406
11	4.97398	5.31886	7.32679	7.32833	7.67167	7.67321
12	5.20938	5.55418	7.32725	7.32794	7.67206	7.67275
13	5.42118	5.76602	7.32743	7.32774	7.67226	7.67257
14	5.61183	5.95665	7.32752	7.32766	7.67234	7.67248
15	5.78340	6.12823	7.32755	7.32762	7.67238	7.67245
16	5.93782	6.28265	7.32757	7.32760	7.67240	7.67243
17	6.07680	6.42163	7.32758	7.32759	7.67241	7.67242
18	6.20188	6.54670	7.32758	7.32759	7.67241	7.67242

(Subdominant eigenvalue)所支配。更精确地说, 令 $\lambda_1, \dots, \lambda_n$, 为按模递减排序的 P_{μ^*} 的特征值。即

$$|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_n|,$$

而 λ_1 等于 1。那么 λ_2 就是次主特征值。 $\hat{J}_k - J^*$ 的收敛速度依赖于 $|\lambda_2|$ 如何接近于单位 1。如果 $|\lambda_2| \approx 1$, 且 $\alpha \approx 1$, 则收敛率就慢; 本质上来说, $\hat{J}_k - J^*$ 和 α^k 一样, 收敛于零。如果 $|\lambda_2| \approx 0$, 则收敛率就快。水平高的读者对所有的 J 和 μ^* 先验证如下方程。

$$T_{\mu^*}(J) - J_{\mu^*} = \alpha P_{\mu^*}(J - J_{\mu^*}),$$

就会理解这个原因。然后假定, 相应于 $\lambda_1, \lambda_2, \dots, \lambda_n$ 存在一组线性独立的特征向量 $e_1, e_2, \dots, e_n$, 且 $e_1 = e = [1, 1, \dots, 1]'$ 。于是有

$$J - J_{\mu^*} = \xi_1 e + \sum_{i=2}^n \xi_i e_i,$$

其中 $\xi_1, \xi_2, \dots, \xi_n$ 是某些标量, 而逐次逼近法的误差可写成

$$T_{\mu^*}^k(J) - J_{\mu^*} = \alpha^k \xi_1 e + \alpha^k \sum_{i=2}^n \lambda_i^k \xi_i e_i.$$

利用命题 4 中误差界限, 相当于沿向量 e , 对 $T_{\mu^*}^k(J)$ 进行移动。这可消去误差分量 $\alpha^k \xi_1 e$, 但不影响其它项 $\alpha^k \sum_{i=2}^n \lambda_i^k \xi_i e_i$, 后者的减小与 $\alpha^k |\lambda_2|^k$ 相同, λ_2 是次主特征值。(参阅文献 [B20, M8], [M9], 以及习题 26)。

在前面的例子中, 能够证明 $\mu^*(1) = u^2$, $\mu^*(2) = u^1$, 且

$$P_{\mu^*} = \begin{bmatrix} \frac{1}{4} & \frac{3}{4} \\ \frac{3}{4} & \frac{1}{4} \end{bmatrix}.$$

P_{μ^*} 的特征值是 $\lambda_1 = 1$, 和 $\lambda_2 = -\frac{1}{2}$, 且收敛是相当快的。另一方面, 有很多情况, 即使利用误差界限, 方法的收敛也是很慢的。例如, 假定 P_{μ^*} 为具有两个或两个以上分块的块对角阵, 或者更一般地, 它对应于具有一个以上遍历类(见附录 D)的一个系统, 那末可以证明, 次主持特征值 λ_2 为 1, 而且当 α 接近 1 时, 典型地说来, 收敛是慢的。

作为一个例子, 考虑具有单一策略和一个以上遍历类的三个简单确定性问题。

问题 1 $n = 3$, P_{μ} = 三维单位阵, $g_{\mu}[i, \mu(i)] = i$;

问题 2 $n = 5$, P_{μ} = 五维单位阵, $g_{\mu}[i, \mu(i)] = i$;

问题 3 $n = 6$, $g_{\mu}[i, \mu(i)] = i$, 且

$$P_{\mu} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{bmatrix}.$$

表 5.2 给出带或不带命题 4 的误差界限, 在最大座标误差 $\max_i |J_{\mu}(i)|$ 为 10^{-8} 范围内, 利用逐次逼近法寻求 J_{μ} 所需的迭代次数。在所有情况下, 起始函数均是零。性能指标不怎么令人满意, 然而这却是一种典型情况, 即最优转移概率矩阵的次主特征值的模接近于 1。

表 5.2 带或不带误差界限的逐次逼近法的迭代次数, 问题是确定性的, 由于转移矩阵的次主特征值是单位 1, 误差界限失效。

	问 题		问 题		问 题	
	$\alpha = 0.9$	$\alpha = 0.99$	$\alpha = 0.9$	$\alpha = 0.99$	$\alpha = 0.9$	$\alpha = 0.99$
不带误差界限	131	1374	131	1374	132	1392
带误差界限	127	1333	129	1352	131	1374

逐次逼近的高斯-赛德尔方法

在前面叙述的逐次逼近法中, 近似代价函数对所有的状态同时进行迭代。另一种方法就是一次只对一个状态进行迭代, 同时把中间结果插入计算中, 这与利用高斯-赛德尔方法求解非线性方程组 $J = T(J)$ 相对应。(参见[O4])。

对于 n 维向量 J , 定义映射 F

$$F(J)(i) = \min_{u \in U(i)} [g(i, u) + \alpha \sum_{j=1}^n p_{ij}(u) J(j)] \quad (5.37)$$

且对 $i = 2, \dots, n$, 有

$$F(J)(i) = \min_{u \in U(i)} \left[g(i, u) + \alpha \sum_{j=1}^{i-1} p_{ij}(u) F(J)(j) + \alpha \sum_{j=i}^n p_{ij}(u) J(j) \right]. \quad (5.38)$$

总之,除了用以前的计算值 $F(J)(1), \dots, F(J)(i-1)$ 代替 $J(1), \dots, J(i-1)$ 之外, $F(J)(i)$ 是由与 $T(J)(i)$ 相同的方程计算。显然,除非使用并行计算机, $F(J)$ 的计算与 $T(J)$ 的计算同样容易。

现在,我们考虑用来计算 $J, F(J), F^2(J), \dots$ 的逐次逼近法。下面的命题将证明这一方法是有效的,而且相对于以前的逐次逼近法有更好的性能指标。

命题 5 设 J, J' 是两个 n 维向量,则对任何 $k=0, 1, \dots$, 有

$$\max_{i \in S} |F^k(J)(i) - F^k(J')(i)| \leq \alpha^k \max_{i \in S} |J(i) - J'(i)|. \quad (5.39)$$

进而还有

$$F(J^*)(i) = J^*(i), \quad i \in S, \quad (5.40)$$

$$\lim_{k \rightarrow \infty} F^k(J)(i) = J^*(i), \quad i \in S. \quad (5.41)$$

证明:对 $k=1$ 证明式(5.39)即已充分。由 F 的定义和命题 3 有

$$|F(J)(1) - F(J')(1)| \leq \alpha \max_{i \in S} |J(i) - J'(i)|.$$

同样利用这一不等式有

$$\begin{aligned} |F(J)(2) - F(J')(2)| &\leq \alpha \max_{i \in S} \{ |F(J)(1) - F(J')(1)|, \\ &\quad |J(2) - J'(2)|, \dots, |J(n) - J'(n)| \} \\ &\leq \alpha \max_{i \in S} |J(i) - J'(i)|. \end{aligned}$$

按同样方法,对任意 i 和 $j < i$ 有

$$|F(J)(j) - F(J')(j)| \leq \alpha \max_{i \in S} |J(i) - J'(i)|,$$

从而对 $k=1$ 证得式(5.39)。式(5.40)是根据定义式(5.37)到(5.38),以及 $J^* = T(J^*)$ 的事实。式(5.41)是根据式(5.39)和式(5.40)获得。证毕

命题 6 如果向量 J 满足

$$J(i) \leq T(J)(i) \leq J^*(i), \quad i \in S,$$

则

$$T^k(J)(i) \leq F^k(J)(i) \leq J^*(i), \quad i \in S, \quad k=1, 2, \dots. \quad (5.42)$$

证明:利用定义式(5.37)到(5.38)以及 T 的单调特性,这个证明立即可得出。证毕

此命题提出了在逐次逼近法中用映射 F 代替 T 的主要动机。对于满足 $J^* \leq T(J) \leq J$ 的 n 维向量 J ,可以证明类似的结果。相对于原始的逐次逼近法,高斯-赛德尔方法具有更快的收敛速度这一事实,已经过广泛的试验为实际所验证。然而,这种比较有时会导致误解,因为原始方法通常都是与命题 4 的误差界限一起应用。人们也可以在高斯-赛德尔方法中应用误差界限(见习题 3)。然而,当界限引入之后,并不存在一种方法对另一种方法的明显优越性。然而,原始方法较之高斯-赛德尔方法更适合于并行计算。

在逐次逼近中非最优作用的消除

由命题 2 我们知:如果 $\tilde{u} \in U(i)$ 使得

$$g(i, \tilde{u}) + \alpha \sum_{j=1}^n p_{ij}(\tilde{u}) J^*(j) > J^*(i), \quad (5.43)$$

则 $\tilde{u}$ 在状态 i 不是最优的, 即对每个最优平稳策略 $\{\mu^*, \mu^*, \dots\}$, 则有 $\mu^*(i) \neq \tilde{u}$ 。因此, 如果我们能肯定式(5.43)成立, 则我们能够安全地由容许集合 $U(i)$ 中消去 $\tilde{u}$ 。由于我们不知道最优代价函数 J^* , 不能直接检查式(5.43); 但我们能保证其成立, 如果

$$g(i, \tilde{u}) + \alpha \sum_{j=1}^n p_{ij}(\tilde{u}) \underline{J}(j) > \bar{J}(i), \quad (5.44)$$

其中 $\bar{J}$ 和 $\underline{J}$ 是上界和下界, 满足

$$\underline{J}(i) \leq J^*(i) \leq \bar{J}(i), \quad i \in S.$$

上述关系是有效地应用本节前面所给误差界限的基础。当这些界限在逐次逼近法过程中计算时, 不等式(5.44)能够同时被检查, 且非最优作用能够从容许集合中消除, 节省以后的计算。因为上限函数 $\bar{J}$ 和下限函数 $\underline{J}$ 均收敛于 J^* , 容易看出[考虑到约束集 $U(i)$ 是有限集合], 最终所有非最优 $\tilde{u} \in U(i)$ 均被消除, 从而在有限步迭代之后把集合 $U(i)$ 简化成在 i 最优的控制集。按此方式, 逐次逼近法的计算量将有明显减少。然而, 为了在每个 $i \in S$ 保存还未消除的控制集, 计算机所需存贮量会有所增加。

策略迭代

策略迭代算法进行过程如下: 选用一个初始平稳策略 $\pi^0 = \{\mu^0, \mu^0, \dots\}$, 计算相应的代价函数 $J_{\mu^0} = J_{\pi^0}$ 。然后通过相应于 J_{μ^0} 的 DP 方程的极小化, 计算改进的策略 $\pi^1 = \{\mu^1, \mu^1, \dots\}$, 并重复过程。

这一算法是基于如下命题。

命题 7 设 $\pi = \{\mu, \mu, \dots\}$ 和 $\bar{\pi} = \{\bar{\mu}, \bar{\mu}, \dots\}$ 均为平稳策略, 使得

$$\begin{aligned} & g[i, \bar{\mu}(i)] + \alpha \sum_{j=1}^n p_{ij}[\bar{\mu}(i)] J_{\mu}(j) \\ &= \min_{u \in U(i)} \left[g(i, u) + \alpha \sum_{j=1}^n p_{ij}(u) J_{\mu}(j) \right], \end{aligned} \quad (5.45)$$

或等价地写成

$$T_{\bar{\pi}}(J_{\mu}) = \bar{T}(J_{\mu}).$$

则有

$$J_{\bar{\pi}}(i) \leq J_{\mu}(i), \quad i \in S. \quad (5.46)$$

而且, 如果 π 不是最优的, 则至少对一个状态 $i \in S$, 式(5.46)以严格不等成立。

证明: 由推论 2.1 和式(5.45), 对每个 $i \in S$ 有

$$\begin{aligned} J_{\mu}(i) &= g[i, \mu(i)] + \alpha \sum_{j=1}^n p_{ij}[\mu(i)] J_{\mu}(j) \\ &\geq g[i, \bar{\mu}(i)] + \alpha \sum_{j=1}^n p_{ij}[\bar{\mu}(i)] J_{\mu}(j) \\ &= T_{\bar{\pi}}(J_{\mu})(i), \end{aligned}$$

不等式两边重复用 T_{μ}^- ，再利用 T_{μ}^- 的单调性和推论 1.1 得

$$J_{\mu} \geq T_{\mu}^-(J_{\mu}) \geq \dots \geq T_{\mu}^{-k}(J_{\mu}) \geq \dots \geq \lim_{k \rightarrow \infty} T_{\mu}^{-k}(J_{\mu}) = J_{\mu}^*,$$

此即证明式(5.46)。如果 $J_{\mu} = J_{\mu}^*$ ，则由前面的关系式 $J_{\mu} = T_{\mu}^-(J_{\mu})$ ，和式(5.45)得 $T_{\mu}^-(J_{\mu}) = T(J_{\mu})$ ，及 $J_{\mu} = T(J_{\mu})$ ，从而由命题 2，得 $J_{\mu} = J^*$ 。于是， $\pi = \{\mu, \mu, \dots\}$ 必是最优的。由此知，如果 π 不是最优的，则对某个 $i \in S$ ，式(5.46)以严格不等式成立。证毕

策略迭代算法

步骤1(初始化) 猜想一个初始平稳策略

$$\pi^0 = \{\mu^0, \mu^0, \dots\}.$$

步骤2(策略评价) 给定一个平稳策略

$$\pi^k = \{\mu^k, \mu^k, \dots\},$$

由如下线性方程组计算相应的代价函数 J_{μ^k}

$$(I - \alpha P_{\mu^k}) J_{\mu^k} = g_{\mu^k}.$$

步骤3(策略改进)得到一个平稳策略 $\pi^{k+1} = \{\mu^{k+1}, \mu^{k+1}, \dots\}$ ，对所有 $i \in S$ 满足

$$\begin{aligned} & g[i, \mu^{k+1}(i)] + \alpha \sum_{j=1}^n p_{ij}[\mu^{k+1}(i)] J_{\mu^k}(j) \\ &= \min_{u \in U(i)} [g(i, u) + \alpha \sum_{j=1}^n p_{ij}(u) J_{\mu^k}(j)] \end{aligned}$$

或等价地写成

$$T_{\mu^k+1}(J_{\mu^k}) = T(J_{\mu^k}).$$

如果 $J_{\mu^k} = T(J_{\mu^k})$ ，停止；否则转到步骤 2 重复这一过程。

因为所有平稳策略的集合是有限的(由 S 和 C 的有限性)，且在每一步迭代产生一个改进的策略，因而此算法将在有限次迭代后得到一个最优平稳策略，随即迭代结束。策略迭代算法的这一特性是相对于逐次逼近法的主要优点，后者一般是在无限次迭代后才收敛。另外，在算法的第二步为求解 T_{μ^k} 的准确值，要求解线性方程组 $J_{\mu^k} = T_{\mu^k}(J_{\mu^k})$ 。该方程组的维数等于状态的个数；而当状态个数很大时，这一算法并不具有吸引力。

我们将利用本节前面研究过的例题演示这一算法。

例题(续)：

步骤1 选择一个初始策 $\pi^0 = \{\mu^0, \mu^0, \dots\}$ ，其中

$$\mu^0(1) = u^1, \mu^0(2) = u^2.$$

步骤2 通过方程 $J_{\mu^0} = T_{\mu^0}(J_{\mu^0})$ 得到 J_{μ^0} ，或等效地写成

$$\begin{aligned} J_{\mu^0}(1) &= g(1, u^1) + \alpha p_{11}(u^1) J_{\mu^0}(1) + \alpha p_{12}(u^1) J_{\mu^0}(2), \\ J_{\mu^0}(2) &= g(2, u^2) + \alpha p_{21}(u^2) J_{\mu^0}(1) + \alpha p_{22}(u^2) J_{\mu^0}(2). \end{aligned}$$

把具体数据代入则有

$$\begin{aligned} J_{\mu^0}(1) &= 2 + 0.9 \times \frac{3}{4} \times J_{\mu^0}(1) + 0.9 \times \frac{1}{4} \times J_{\mu^0}(2), \\ J_{\mu^0}(2) &= 3 + 0.9 \times \frac{1}{4} \times J_{\mu^0}(1) + 0.9 \times \frac{3}{4} \times J_{\mu^0}(2). \end{aligned}$$

对 $J_{\mu^0}(1)$ 和 $J_{\mu^0}(2)$ 解这个线性方程组得

$$J_{\mu^0}(1) \approx 24.12, J_{\mu^0}(2) \approx 25.96.$$

步骤3 现在求满足 $T_{\mu^1}(J_{\mu^0}) = T(J_{\mu^0})$ 的 $\mu^1(1), \mu^1(2)$, 则有

$$\begin{aligned} T(J_{\mu^0})(1) &= \min \left\{ 2 + 0.9 \left(\frac{3}{4} \times 24.12 + \frac{1}{4} \times 25.96 \right), \right. \\ &\quad \left. 0.5 + 0.9 \left(\frac{1}{4} \times 24.12 + \frac{3}{4} \times 25.96 \right) \right\} \\ &= \min \{ 24.12, 23.45 \} = 23.45, \\ T(J_{\mu^0})(2) &= \min \left\{ 1 + 0.9 \left(\frac{3}{4} \times 24.12 + \frac{1}{4} \times 25.96 \right), \right. \\ &\quad \left. 3 + 0.9 \left(\frac{1}{4} \times 24.12 + \frac{3}{4} \times 25.96 \right) \right\} \\ &= \min \{ 23.12, 25.95 \} = 23.12. \end{aligned}$$

最小控制是

$$\mu^1(1) = u^2, \mu^1(2) = u^1.$$

步骤2 通过方程 $J_{\mu^1} = T_{\mu^1}(J_{\mu^1})$ 得到 J_{μ^1} , 即

$$\begin{aligned} J_{\mu^1}(1) &= g(1, u^2) + \alpha p_{11}(u^2) J_{\mu^1}(1) + \alpha p_{12}(u^2) J_{\mu^1}(2), \\ J_{\mu^1}(2) &= g(2, u^1) + \alpha p_{21}(u^1) J_{\mu^1}(1) + \alpha p_{22}(u^1) J_{\mu^1}(2). \end{aligned}$$

把具体数据代入并解这个线性方程组得

$$J_{\mu^1}(1) \approx 7.33, J_{\mu^1}(2) \approx 7.67.$$

步骤3 为求 $T(J_{\mu^1})$ 完成如下极小化

$$\begin{aligned} T(J_{\mu^1})(1) &= \min \left\{ 2 + 0.9 \left(\frac{3}{4} \times 7.33 + \frac{1}{4} \times 7.67 \right), \right. \\ &\quad \left. 0.5 + 0.9 \left(\frac{1}{4} \times 7.33 + \frac{3}{4} \times 7.67 \right) \right\} \\ &= \min \{ 8.67, 7.33 \} = 7.33, \\ T(J_{\mu^1})(2) &= \min \left\{ 1 + 0.9 \left(\frac{3}{4} \times 7.33 + \frac{1}{4} \times 7.67 \right), \right. \\ &\quad \left. 3 + 0.9 \left(\frac{1}{4} \times 7.33 + \frac{3}{4} \times 7.67 \right) \right\} \\ &= \min \{ 7.67, 9.83 \} = 7.67. \end{aligned}$$

因此有 $J_{\mu^1} = T(J_{\mu^1})$, 此即意味着 $\{\mu^1, \mu^1, \dots\}$ 是最优的, 且 $J_{\mu^1} = J_{\mu^*}$:

$$\mu^*(1) = u^2, \mu^*(2) = u^1, J^*(1) \approx 7.33, J^*(2) \approx 7.67.$$

近似策略迭代与自适应状态集结

前面我们曾说过, 当状态个数较大时, 策略迭代算法的策略评价步骤是非常费时间的, 因而使得这一方法的实用性受到挑战. 克服这一困难的一种途径就是对每一步 k 近似地求出策略评价, 并对如下方程求近似解 $\tilde{J}_{\mu^k}$

$$J_{\mu^k} = g_{\mu^k} + \alpha P_{\mu^k} J_{\mu^k}.$$

做到这一点的一种自然的方式是完成旨在求解上述方程组的几个逐次逼近步骤, 这里我们以策略改进步骤的结果 $T_{\mu^k}(\tilde{J}_{\mu^{k-1}}) = T(\tilde{J}_{\mu^{k-1}})$ 进入 k 步策略评价, 而近似的 J_{μ^k} 是由下式得

$$\tilde{J}_{\mu^k} = T_{\mu^k}^m(\tilde{J}_{\mu^{k-1}}),$$

到其中 m 是某个正整数。诸如命题 4 中的一个误差界限可用来精简这一过程。取 $m=1$ 相应于跳过策略评价步骤的逐次逼近法, 而取 $m=\infty$ 相应于一种策略迭代, 依靠这种迭代通过逐次逼近法迭代地完成策略评价步骤。分析和计算经验([P18], [P19])告诉我们, 通常取 m 为大于 1 的整数, 并由试探法来决定。此处一个关键的思想是: 当对每个状态可利用的控制数目较多时, 涉及单个策略(对某个 μ 和 J 评价 $T_{\mu}(J)$)的逐次迭代步骤, 比涉及所有策略(对某个 J 评价 $T(J)$)的步骤便宜得多。注意: 高斯-赛德尔步骤可以用来代替通常的逐次逼近步骤, 产生更有效的计算。

利用逐次逼近法近似地求解如下方程是不重要的

$$J_{\mu} = T_{\mu}(J_{\mu}).$$

另一种可能性就是通过把原始系统的状态归并为较小的集结状态集合, 去求解由此得到的较小维数的方程组。更明确地说, 就是对一个固定的平稳策略 $\{\mu, \mu, \dots\}$, 我们把状态空间 S 划分为 m 个相交的子集 $S_1, S_2, \dots, S_m$,

$$S = S_1 \cup S_2 \cup \dots \cup S_m,$$

称之为集结状态。假定我们有 J_{μ} 的一个估计 J , 并假定对每个集结状态 S_i 的状态 S , 变差 $J_{\mu}(s) - J(s)$ 是常量。这等于假定, 对某个 m 维向量 y 有

$$J_{\mu} - J = Wy,$$

式中 $n \times m$ 阵 W 的第 i 列在相应于 S_i 中状态的座标上元素为 1, 其余元素为零。由方程 $T_{\mu}(J) = g_{\mu} + \alpha P_{\mu} J$ 以及 $J_{\mu} = g_{\mu} + \alpha P_{\mu} J_{\mu}$, 有

$$(I - \alpha P_{\mu})(J_{\mu} - J) = T_{\mu}(J) - J.$$

这就是前面讨论的方程 $J_{\mu} = T_{\mu}(J_{\mu})$ 的变化形式, 而且同样好地用来评价 J_{μ} 。用转置阵 W' 乘方程两边, 并利用方程 $J_{\mu} - J = Wy$ 得

$$W'(I - \alpha P_{\mu})Wy = W'(T_{\mu}(J) - J),$$

此方程对 y 求解得

$$y = [W'(I - \alpha P_{\mu})W]^{-1}W'(T_{\mu}(J) - J).$$

所以, 代入方程 $J_{\mu} - J = Wy$ 得:

$$J_{\mu} = J + W[W'(I - \alpha P_{\mu})W]^{-1}W'(T_{\mu}(J) - J),$$

再把 T_{μ} 作用两边,

$$J_{\mu} = T_{\mu}(J_{\mu}) = T_{\mu}(J) + \alpha P_{\mu} W[W'(I - \alpha P_{\mu})W]^{-1}W'(T_{\mu}(J) - J).$$

因此, 我们能得出结论: 如果差 $J_{\mu}(s) - J(s)$ 对于某个集结状态, 粗略地认为一个常量, 则对 J_{μ} 的一个较好的近似由下式给出

$$J_{\mu} \approx T_{\mu}(J) + \alpha P_{\mu} W[W'(I - \alpha P_{\mu})W]^{-1}W'(T_{\mu}(J) - J).$$

给定 J , 要得到这个近似结果, 需要做:

1. 计算 $T_{\mu}(J)$ 。
2. 描述集结状态(即定义 W)。

3. 求解如下方程组中的 y

$$W'(I - \alpha P_\mu)W y = W'(T_\mu(J) - J) \quad (5.47)$$

且用下式近似 J_μ

$$J_\mu \approx T_\mu(J) + \alpha P_\mu W y.$$

关键在于式(5.47)的维数为 m (集结状态的个数), 它可以比 n (在策略迭代的评价阶段产生的方程组 $J_\mu = T_\mu(J_\mu)$ 的维数) 小得多。事实上, m 值小, 比方说 3 到 6, 往往是非常有效的 (参看[B20])。

注意, 有可能利用不只一个逐次集结步骤去逼近策略迭代算法中的策略评价步骤。而且, 实验和分析[B20]表明, 利用这一方法的最有效途径就是用几个逐次逼近步骤加在每个集结步骤的前后; 即将映射 T_μ 应用到当前的迭代。跟在一个集结步骤后面的逐次逼近步骤数目要么是固定的, 要么是基于一算法的进展; 即当逐次逼近步骤进展变得相对小时, 完成一个集结步。

对于上述方法的收敛性至今没有证明。在计算经验的基础上, 这种方法在实际中似乎是可靠的。无论如何, 其收敛性可通过引入一种特征而得到保证。依靠这个特征, 在逐次逼近步骤 (步骤1), 计算命题 4 的误差界限; 且加上一个要求: 如果这些误差界限是前一次集结步所计算的界限乘某个因子改进不多, 则跳过紧接着的集结步。

方程组(5.47)具有一个有趣的解释。假定我们用如下对角阵乘以两边

$$N = \begin{bmatrix} n_1^{-1} & & & 0 \\ & n_2^{-1} & & \\ & & \ddots & \\ 0 & & & n_m^{-1} \end{bmatrix},$$

其中 n_i 是集结状态 S_i 中状态的个数。那么, 简捷的计算表明, 式(5.47)取如下形式

$$(I - \alpha \bar{P})y = r,$$

其中 $\bar{P}$ 是 $m \times m$ 集结马尔科夫链的转移概率矩阵, 其元素为

$$\bar{p}_{ij} = \frac{1}{n_i} \sum_{s \in S_i} \sum_{t \in S_j} p_{st}(\mu), \quad i, j = 1, \dots, m,$$

r 是一个向量, 其第 i 个元素是第 i 个集结状态上 $T_\mu(J) - J$ 的平均值。

$$r_i = \frac{1}{n_i} \sum_{j \in S_i} [T_\mu(J)(j) - J(j)],$$

(见图5.3)。于是, 我们能够把方程组(5.47)看作为集结马尔科夫链的一个策略评价步骤, 而且对每个集结状态 i , 每阶段代价等于 r_i ——即 $T_\mu(J) - J$ 对该状态的平均值。

关键的问题在于如何划分集结状态 $S_1, S_2, \dots, S_m$, 使得差值 $J_\mu - J$ 在每个集结状态上都很小。解决这个问题的途径就是根据差值 $T_\mu(J)(i) - J(i)$ 的大小对状态分组。按此方式即意味着对每个状态 i , 若 $T_\mu(J)(i) - J(i) = c$, 置 $i \in S_1$, 且

如果 $T_\mu(J)(i) - J(i) - c - (k-1)\Delta \in (0, \Delta]$, 置 $i \in S_k$ 。

其中

$$c = \min_i [T_\mu(J)(i) - J(i)], \quad \bar{c} = \max_i [T_\mu(J)(i) - J(i)], \quad \Delta = \frac{\bar{c} - c}{m}.$$

这种选择是基于这样的猜想: 至少在接近收敛时, 对于那些状态 i , $T_\mu(J)(i) - J(i)$ 大小差




图 5.3 自适应集结法的解释。在此例子中，集结状态是 $S_1 = \{1, 2, 3\}$ ， $S_2 = \{4, 5\}$ ，和 $S_3 = \{6\}$ 。

集结马尔科夫链具有转移概率 $\bar{p}_{11} = \frac{1}{3} (p_{21} + p_{31})$ ， $\bar{p}_{12} = \frac{1}{3} (p_{41} + p_{51})$ ， $\bar{p}_{13} = 0$ ，

$\bar{p}_{21} = \frac{1}{2} (p_{42} + p_{52})$ ， $\bar{p}_{22} = \frac{1}{2} p_{45}$ ， $\bar{p}_{23} = \frac{1}{2} p_{56}$ ， $\bar{p}_{31} = 0$ ， $\bar{p}_{32} = p_{56}$ ，和 $\bar{p}_{33}$

$= 0$ 。一个集结步可解释为对集结马尔科夫链的策略评价步。

不多， $J_\mu(i) - J(i)$ 也大小差不多。如果 P 是单位阵，这当然是对的；但在另外一些情况下也是对的，比如马尔科夫链具有一个以上遍历类的情况，这正是逐次逼近法收敛很慢的一类问题。关于详细的分析与计算方面的结果请参阅[B20]。特别地，对于涉及几个遍历类的问题，在进行一个集结步骤之前，进行几个（纯的）逐次逼近步骤是很重要的。在集结步骤之前，使每个遍历类中 $J_\mu(i) - J(i)$ 和 $T_\mu(J)(i) - J(i)$ 二者变得大小差不多是有效的。

值得注意的是，集结状态会随着迭代步骤的改变而变化，这就是我们将集结方法表征为自适应集结的理由。而且，用于划分集结状态的判据不利用任何特殊的问题结构。在有些情况下，可利用已有的特殊结构，以此修正用于形成集结状态的方法。

为说明这种自适应集结方法的有效性，考虑前面叙述的三个确定性问题（参看表5.2），以及由零函数开始的具有两个、三个和四个集结状态时方法的性能。表5.3给出的结果应该与表5.2的结果是可比的。

直观上显然集结法的性能随着集结状态数目的增大应有所改进。实际上，计算结果已证明了这一点。两种极端的情况即 $m = n$ 和 $m = 1$ 是非常有趣的。当 $m = n$ 时，各集结状态具有单个状态，因而我们得到了策略迭代算法。当 $m = 1$ 时，只有一个集结状态；我们有

$$W = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix},$$

由简捷的计算证明方程(5.47)产生

$$y = \frac{1}{n(1-a)} \sum_{i=1}^n [T_\mu(J)(i) - J(i)].$$

由此方程得到近似式

$$J_\mu \approx T_\mu(J) + W \frac{a}{n(1-a)} \sum_{i=1}^n [T_\mu(J)(i) - J(i)],$$

这等于说把逐次逼近的结果 $T_\mu(J)$ 移到一个向量, 该向量处在由命题 4 给出的误差界范围的中间某位置。于是, 我们可把集结方法看作为具有策略迭代和逐次逼近(与命题 4 误差界限结合), 包括两种极端特殊情况的算法连续统一体。

表 5.3 具有两个、三个和四个集结状态解表 5.2 问题时自适应集结方法的迭代步数

集结状态数	问题 1		问题 2		问题 3	
	$\alpha = 0.9$	$\alpha = 0.99$	$\alpha = 0.9$	$\alpha = 0.99$	$\alpha = 0.9$	$\alpha = 0.99$
2	14	13	9	9	83	505
3	1	1	3	3	64	367
4	—	—	3	3	26	354

线性规划

如前面讨论的, 我们有

$$J \leq T(J) \Rightarrow J \leq J^* = T(J^*).$$

于是, $J^*(1), \dots, J^*(n)$ 是如下求极大问题的解(对 $\lambda_1, \dots, \lambda_n$):

$$\max \sum_{i=1}^n \lambda_i$$

$$\text{s.t.} \quad \lambda_i \leq T(J_\lambda)(i), \quad i = 1, \dots, n,$$

其中函数 $J_\lambda: S \rightarrow R$ 定义为

$$J_\lambda(i) = \lambda_i, \quad i = 1, \dots, n.$$

这个问题还可以写成

$$\max \sum_{i=1}^n \lambda_i$$

$$\text{s.t.} \quad \lambda_i \leq g(i, u) + \alpha \sum_{j=1}^n p_{ij}(u) \lambda_j, \quad i = 1, \dots, n, u \in U(i).$$

这是一个具有 n 个变量和多至 $n \times m$ 个约束的线性规划问题, 其中 m 是集合 $U(i)$ 元素的最大个数。当 n 增加时, 这个线性规划问题变得越来越复杂。而当 n 和 m 都非常大时(在几百的数量级), 线性规划方法已失去实用性。

对于本节所考虑的例子, 线性规划问题取如下形式

$$\max \lambda_1 + \lambda_2$$

$$\text{s.t.} \quad \lambda_1 \leq 2 + 0.9 \left(\frac{3}{4} \lambda_1 + \frac{1}{4} \lambda_2 \right), \quad \lambda_1 \leq 0.5 + 0.9 \left(-\frac{1}{4} \lambda_1 + \frac{3}{4} \lambda_2 \right),$$

$$\lambda_2 \leq 1 + 0.9 \left(-\frac{3}{4} \lambda_1 + \frac{1}{4} \lambda_2 \right), \quad \lambda_2 \leq 3 + 0.9 \left(\frac{1}{4} \lambda_1 + \frac{3}{4} \lambda_2 \right).$$

§ 5.3 收缩映射的作用

在 DP 模型中两个关键的结构性质对于绝大多数可以证明的有关数学结果至关重要。第一是映射 T 和 T_μ 的单调特性(见 § 5.1 引理 1), 这一特性对于本章的模型是基本的。例如,

它形成了下一节所要证明的结果的基础。

然而,当每阶段代价有界且存在折扣时,我们有加强单调性效能的另一性质,即映射 T 和 T_μ 是收缩映射。本节我们将解释这一特性的意思和含义。本节的内容在概念上是非常重要的,因为收缩映射也存在于另外几种 DP 模型中。抽象 DP 模型以及单调性与收缩的含义在文献[D2]、[B16]和[B23]中有详细叙述。

设 $B(S)$ 表示 S 上所有有界实值函数集合,我们将标量

$$\|J\| = \max_{x \in S} |J(x)|$$

与属于 $B(S)$ 的每个函数 $J: S \rightarrow R$, 联系起来。

为照顾水平高的读者,我们指出函数 $\|\cdot\|$ 能被证明是线性空间 $B(S)$ 的一个范数,且用此范数 $B(S)$ 成为一个完备的赋范线性空间,即巴拿赫空间[L9]。下面的定义和定理是专门对更一般概念和结果的 $B(S)$ 而言的(如见参考文献[L5]和[L9])。

定义 映射 $H: B(S) \rightarrow B(S)$ 称为是一个收敛映射,如果存在一个标量 $\rho < 1$, 使得

$$\|H(J) - H(J')\| \leq \rho \|J - J'\|, \text{ 对所有 } J, J' \in B(S),$$

其中 $\|\cdot\|$ 如前述范数定义。称映射 H 为一个 m 阶段收缩映射,如果存在正整数 m 和某个 $\rho < 1$, 使得

$$\|H^m(J) - H^m(J')\| \leq \rho \|J - J'\|, \text{ 对所有 } J, J' \in B(S),$$

其中 H^m 表示 H 本身 m 次复合映射 $H \cdots H$ 。

收缩映射不动点定理 如果 $H: B(S) \rightarrow B(S)$ 是一个收缩映射,或 m 阶段收缩映射,则存在 H 的唯一不动点,即存在唯一函数 $J^* \in B(S)$, 使得

$$H(J^*) = J^*.$$

而且,如果 J 是 $B(S)$ 中的任一函数, H^k 是 H 本身 k 次复合映射, 则

$$\lim_{k \rightarrow \infty} \|H^k(J) - J^*\| = 0.$$

证明: 见文献[L5]或[L9]。

现在考虑,由式(5.8)和(5.9)定义的映射 T 和 T_μ 。命题 3 和推论 3.1 表明 T 和 T_μ 均为收缩映射($\rho = \alpha$)。这样,直接由收缩映射定理得知,逐次逼近法收敛到 T 的一个唯一不动点。还要注意,由式(5.37)和式(5.38)定义的映射 F , 根据命题 5 也是一个收缩映射,且 $\rho = \alpha$; 命题 5 的收敛结果同样是不动点定理的一个特殊情况。

§5.4 每阶段无界代价和无折扣问题

本节我们仍考虑问题 I, 但对假设 D 放松,即容许 $\alpha \geq 1$ 和每阶段代价上无界或下无界。由此引起的复杂性是带有实质性的,比假设 D 条件下问题的分析要繁得多。主要困难在于:即使 $\alpha < 1$, 命题 1 以及与之有关的结果都不再成立。我们将假定下面两个假设之一是有效的,以取代假设 D。

假设 P (正性) ^[原注1] 代价函数式(5.2)中的函数 g 满足

$$0 \leq g(x, u, w), \text{ 对所有 } (x, u, w) \in S \times C \times D. \quad (5.48)$$

原注: 相应于假设 P 的问题在一些研究文献中有时称为负 DP 问题[S28]。在这些问题中,目标函数求极大,而每阶段的报酬是负的。类似地,相应于假设 N 的问题称为正 DP 问题[B28, S28]。

假设N (负性) 代价函数式(5.2)中的函数 g 满足

$$g(x, u, w) \leq 0, \text{ 对所有 } (x, u, w) \in S \times C \times D \quad (5.49)$$

在每阶段报酬或效用非负, 且总的折扣期望报酬求极大的问题中, 我们可以考虑对负报酬求极小, 这样就归入假设N的框架之中。

注意, 当 $\alpha < 1$ 时, g 要么上有界, 要么下有界。我们可以把一个标量加到 g , 使式(5.48)或式(5.49)满足。最优策略将不受这种变化的影响, 因为鉴于折扣因子的存在, g 加一个常数 r , 仅是对与每个策略相应的代价加 $(1-\alpha)^{-1}r$ 。

由每阶段无界代价函数引起的一种复杂性是: 对某个初始状态 x_0 和某个容许策略 $\pi = \{\mu_0, \mu_1, \dots\}$, 代价 $J_\pi(x_0)$ 可以是 $+\infty$ (在假设P的情况下), 或 $-\infty$ (在假设N的情况下)。考虑下面的例子。

例题1

设系统方程为

$$x_{k+1} = \beta x_k + u_k, \quad k = 0, 1, 2, \dots,$$

其中 $x_k, u_k \in R, k = 0, 1, \dots, \beta$ 是正标量。控制约束是 $|u_k| \leq 1$, 而代价是

$$J_\pi(x_0) = \lim_{N \rightarrow \infty} \sum_{k=0}^{N-1} \alpha^k |x_k|.$$

考虑策略 $\tilde{\pi} = \{\tilde{\mu}, \tilde{\mu}, \dots\}$, 对所有 $\alpha \in R$, 式中 $\tilde{\mu}(x) = 0$, 则

$$J_{\tilde{\pi}}(x_0) = \lim_{N \rightarrow \infty} \sum_{k=0}^{N-1} \alpha^k \beta^k |x_0|,$$

因而

$$J_{\tilde{\pi}}(x_0) = \infty, \text{ 如果 } x_0 \neq 0, \alpha\beta \geq 1, \quad (\text{注})$$

否则, $J_{\tilde{\pi}}(x_0)$ 为有限。也可以验证, 当 $\beta > 1$ 且 $\alpha\beta \geq 1$ 时, 对于 $|x_0| > 1/(\beta-1)$, 最优代价 $J^*(x_0)$ 等于 $+\infty$; 而对 $|x_0| \leq 1/(\beta-1)$, $J^*(x_0)$ 有限。问题是 $\beta > 1$ 时系统是不稳定的, 且根据对控制的约束, 一旦状态已达到充分大时, 迫使其接近于零也是不可能的。

对某些策略代价函数成为无限大的可能性, 没有多少办法, 折扣因子 $\alpha < 1$ 的存在并没有多大的帮助, 因为对某个状态或控制策略, 当 $k \rightarrow \infty$ 时, 乘积 $\alpha^k g(x_k, u_k, w_k)$ 仍然可能远离零点。为适应这种情况, 我们在进行分析时要从概念上理解, 对于某初始状态 x_0 和策略 $\pi \in \Pi$, 在假设P(或N)情况下, 代价 $J_\pi(x_0)$ 和 $J^*(x_0)$ 可以是 $+\infty$ (或 $-\infty$)。换句话说, 我们把 $J_\pi(\cdot)$ 和 $J^*(\cdot)$ 考虑成广义的实值函数。事实上, 即使对某个 (x, u, w) , 代价 $g(x, u, w)$ 是 $+\infty$ (或 $-\infty$)。以后整个的分析仍是有效的。

所提出的结果提供了最优代价函数 J^* , 和最优平稳策略的特征。同时也提供了一些条件, 在这些条件下, 逐次逼近法以极限形式产生最优代价 J^* 。在证明中, 我们往往需要在各种关系式中互换期望和极限。在下面定理的假设条件下, 这种互换是正确的。

单调收敛定理 令 $P = (p_1, p_2, \dots)$ 是可数集合 $S, S = \{1, 2, \dots\}$ 上的概率分布, 设 $\{h_N\}$ 是 S 上的广义实值函数序列, 使得

译者注: 原文为 $\alpha\beta \leq 1$ 。

$$0 \leq h_N(i) \leq h_{N+1}(i), \quad i, N = 1, 2, \dots$$

令 $h: S \rightarrow [0, +\infty]$ 是极限函数

$$h(i) = \lim_{N \rightarrow \infty} h_N(i),$$

则

$$\lim_{N \rightarrow \infty} \sum_{i=1}^{\infty} p_i h_N(i) = \sum_{i=1}^{\infty} p_i \lim_{N \rightarrow \infty} h_N(i) = \sum_{i=1}^{\infty} p_i h(i).$$

证明: 我们有

$$\sum_{i=1}^{\infty} p_i h_N(i) \leq \sum_{i=1}^{\infty} p_i h(i).$$

取极限得

$$\lim_{N \rightarrow \infty} \sum_{i=1}^{\infty} p_i h_N(i) \leq \sum_{i=1}^{\infty} p_i h(i),$$

剩下的是证明相反的不等式。对每个整数 $M \geq 1$, 我们有

$$\lim_{N \rightarrow \infty} \sum_{i=1}^{\infty} p_i h_N(i) \geq \lim_{N \rightarrow \infty} \sum_{i=1}^M p_i h_N(i) = \sum_{i=1}^M p_i h(i),$$

当 $M \rightarrow \infty$ 取极限, 则相反的不等式得证。

证毕

贝尔曼方程: 最优性条件

命题8 在假设 P 或 N 条件下, 最优代价函数 J^* 满足

$$J^*(x) = \min_{u \in U(x)} E\{g(x, u, w) + \alpha J^*[f(x, u, w)]\}, \quad x \in S \quad (5.50a)$$

或按式(5.8)的映射 T ,

$$J^* = T(J^*). \quad (5.50b)$$

证明: 设 $\pi = \{\mu_0, \mu_1, \dots\}$ 是一个容许策略, 当初态为 x 时, 考虑相应于 π 的 $J_\pi(x)$, 有

$$J_\pi(x) = E\{g[x, \mu_0(x), w] + V_\pi[f(x, \mu_0(x), w)]\}, \quad (5.51)$$

其中, 对所有 $x_1 \in S$,

$$V_\pi(x_1) = \lim_{N \rightarrow \infty} E_{w_k} \left\{ \sum_{k=1}^{N-1} \alpha^k g[x_k, \mu_k(x_k), w_k] \right\}.$$

在此方程中, x_{k+1} 是由 $x_k, \mu_k(x_k), w_k$ 按系统方程(5.1)产生的。换句话说, $V_\pi(x_1)$ 是当初态为 x_1 , 利用 π 由第一阶段直至无限的代价。显然有

$$V_\pi(x_1) \geq \alpha J^*(x_1), \quad \text{对所有 } x_1 \in S.$$

因此由式(5.51)得

$$\begin{aligned} J_\pi(x) &\geq E\{g[x, \mu_0(x), w] + \alpha J^*[f(x, \mu_0(x), w)]\} \\ &\geq \min_{u \in U(x)} E\{g(x, u, w) + \alpha J^*[f(x, u, w)]\}. \end{aligned}$$

对所有容许策略求极小, 得

$$\min_{\pi} J_\pi(x) = J^*(x) \geq \min_{u \in U(x)} E\{g(x, u, w) + \alpha J^*[f(x, u, w)]\} = T(J^*)(x).$$

于是, 余下的是证明相反的不等式也成立。

假设条件 P 情况下, 令 $\{\epsilon_i\}$ 为正序列, 且考虑容许策略 $\bar{\pi} = \{\bar{\mu}_0, \bar{\mu}_1, \dots\}$, 使得

$$T_{\bar{\mu}_k}^-(J^*)(x) \leq T(J^*)(x) + \epsilon_k, \quad x \in S, \quad k=0, 1, \dots.$$

前面已证, $T(J^*) \leq J^*$, 所以由上面的不等式得

$$T_{\bar{\mu}_k}^-(J^*)(x) \leq J^*(x) + \epsilon_k, \quad x \in S, \quad k=0, 1, \dots.$$

把 $T_{\bar{\mu}_{k-1}}^-$ 作用于上式两边, 有

$$\begin{aligned} (T_{\bar{\mu}_{k-1}}^- T_{\bar{\mu}_k}^-)(J^*)(x) &\leq T_{\bar{\mu}_{k-1}}^-(J^*)(x) + \alpha \epsilon_k \\ &\leq T(J^*)(x) + \epsilon_{k-1} + \alpha \epsilon_k \\ &\leq J^*(x) + \epsilon_{k-1} + \alpha \epsilon_k. \end{aligned}$$

继续这一过程得

$$(T_{\bar{\mu}_0}^- T_{\bar{\mu}_1}^- \dots T_{\bar{\mu}_k}^-)(J^*)(x) \leq T(J^*)(x) + \sum_{i=0}^k \alpha^i \epsilon_i.$$

当 $k \rightarrow \infty$ 时取极限, 则有

$$J^*(x) \leq J_\pi(x) \leq T(J^*)(x) + \sum_{i=0}^{\infty} \alpha^i \epsilon_i, \quad x \in S.$$

因为序列 $\{\epsilon_i\}$ 是任意的, 我们可取 $\sum_{i=0}^{\infty} \alpha^i \epsilon_i$ 小到任意所需程度, 从而对所有 $x \in S$ 得 $J^*(x) \leq T(J^*)(x)$ 。与前面证明的不等式 $J^*(x) \geq T(J^*)(x)$ 结合起来, 则得到所要的结论(在假设条件 P 下)。

在假设 N 情况下, 设 J_N 是相应于 N 阶段问题的代价函数

$$J_N(x_0) = \min_{\pi} E\left\{\sum_{k=0}^{N-1} \alpha^k g[x_k, \mu_k(x_k), w_k]\right\}. \quad (5.52)$$

首先我们证明

$$J^*(x) = \lim_{N \rightarrow \infty} J_N(x), \quad x \in S. \quad (5.53)$$

事实上, 根据假设 N, 对所有 N 有 $J^* \leq J_N$, 所以

$$J^*(x) \leq \lim_{N \rightarrow \infty} J_N(x), \quad x \in S. \quad (5.54)$$

同时, 对所有的 $\pi = \{\mu_0, \mu_1, \dots\}$ 有

$$E\left\{\sum_{k=0}^{N-1} \alpha^k g[x_k, \mu_k(x_k), w_k]\right\} \geq J_N(x_0),$$

当 $N \rightarrow \infty$ 时取极限

$$J_\pi(x) \geq \lim_{N \rightarrow \infty} J_N(x), \quad x \in S.$$

对 $\pi \in \Pi$ 求极小, 得到 $J^*(x) \geq \lim_{N \rightarrow \infty} J_N(x)$ 。把这个关系式与式(5.54)结合, 得式(5.53)。

对于每个容许的 μ , 我们有

$$T_\mu(J_N) \geq J_{N+1},$$

当 $N \rightarrow \infty$ 时取极限, 并利用单调收敛定理和式(5.53)得

$$T_{\mu}(J^*) \geq J^*.$$

对 μ 求极小, 则得 $T(J^*) \geq J^*$. 把此式与前面证得的不等式 $J^* \geq T(J^*)$ 结合起来, 即证得假设 N 下的结论. 证毕

类似于推论 1.1、2.1 和 3.1, 我们有:

推论 8.1 设 $\pi = \{\mu, \mu, \dots\}$ 是一个平稳策略, 则在假设条件 P 或 N 下, 我们有

$$J_{\mu}(x) = E_w \{g[x, \mu(x), w] + \alpha J_{\mu}[f(x, \mu(x), w)]\},$$

或按式(5.9)的映射 T_{μ} 有

$$J_{\mu} = T_{\mu}(J_{\mu}). \quad (5.55)$$

与假设 D 的情况相反, 在假设 P 或 N 条件下, 最优代价函数 J^* 未必是如下贝尔曼方程的唯一解

$$J(x) = T(J)(x) = \min_{u \in U(x)} E_w \{g(x, u, w) + \alpha J[f(x, u, w)]\}. \quad (5.56)$$

考察下面的例子.

例题 2

令 $S = [0, +\infty)$ (或 $S = (-\infty, 0]$), 以及

$$g(x, u, w) = 0, \quad f(x, u, w) = \frac{x}{\alpha}.$$

那么, 对每个 β , 由下式给出的函数

$$J(x) = \beta x, \quad x \in S$$

是式(5.56)的解. 因而在这种情况下 T 有无限多个不动点. 然而注意, 在有界函数类中, 只有唯一的不动点, 即零函数 $J_0(x) \equiv 0$, 这就是该问题的最优代价函数. 在更一般的情况下, 利用下面的命题 9 可以证明, 如果 $\alpha < 1$, 存在一个有界函数是 T 的一个不动点, 则此函数必等于最优代价函数 J^* (见习题 15). 当 $\alpha = 1$, 方程(5.56)即使在有界函数类中也可能有无限多个解. 这是显然的, 因为若 $\alpha = 1$, 且 $J(\cdot)$ 是式(5.56)的任意一个解, 则 $J(\cdot) + r$, r 为任意标量, 也是一个解.

然而, 最优代价函数 J^* 具有如下性质: 它是下面命题所描述的 T 的最小(在假设 P 条件下)或最大(在假设 N 条件下)不动点.

命题 9 (a) 在假设 P 条件下, 如果 $\tilde{J}: S \rightarrow (-\infty, +\infty]$ 满足 $\tilde{J} \geq T(\tilde{J})$, $\tilde{J}$ 为下有界, 且 $\alpha < 1$, 或 $\tilde{J} \geq 0$, 则有 $\tilde{J} \geq J^*$.

(b) 在假设 N 条件下, 如果 $\tilde{J}: S \rightarrow [-\infty, \infty)$ 满足 $\tilde{J} \leq T(\tilde{J})$, $\tilde{J}$ 为上有界, 且 $\alpha < 1$, 或 $\tilde{J} \leq 0$, 则有 $\tilde{J} \leq J^*$.

证明 (a) 在假设 P 条件下, 令 r 是一个标量, 使得对所有 $x \in S$, $\tilde{J}(x) + r \geq 0$; 如果 $\alpha \geq 1$, 令 $r = 0$, 对于任意序列 $\{\epsilon_k\}$, 且 $\epsilon_k > 0$, 设 $\tilde{\pi} = \{\tilde{\mu}_0, \tilde{\mu}_1, \dots\}$ 为一个容许策略, 按这种策略, 对每个 $x \in S$ 和 k 有

$$E_w \{g[x, \tilde{\mu}_k(x), w] + \alpha \tilde{J}[f(x, \tilde{\mu}_k(x), w)]\} \leq T(\tilde{J})(x) + \epsilon_k. \quad (5.57)$$

因为对所有 $x \in S$, $T(\tilde{J})(x) > -\infty$, 这样的策略是存在的. 对于任意初始状态 x_0 , 我们有

$$\begin{aligned}
J^*(x_0) &= \min_x \lim_{N \rightarrow \infty} E \left\{ \sum_{h=0}^{N-1} \alpha^h g[x_h, \mu_h(x_h), w_h] \right\} \\
&\leq \min_x \lim_{N \rightarrow \infty} \inf_{w_h} E \left\{ \alpha^N [\tilde{J}(x_N) + r] + \sum_{h=0}^{N-1} \alpha^h g[x_h, \mu_h(x_h), w_h] \right\} \\
&\leq \lim_{N \rightarrow \infty} \inf_{w_h} E \left\{ \alpha^N [\tilde{J}(x_N) + r] + \sum_{h=0}^{N-1} \alpha^h g[x_h, \tilde{\mu}_h(x_h), w_h] \right\}.
\end{aligned}$$

利用式(5.57)以及假设 $\tilde{J} \geq T(\tilde{J})$ 得

$$\begin{aligned}
&E \left\{ \alpha^N \tilde{J}(x_N) + \sum_{h=0}^{N-1} \alpha^h g[x_h, \tilde{\mu}_h(x_h), w_h] \right\} \\
&= E_{w_h} \left\{ \alpha^N \tilde{J}[f(x_{N-1}, \tilde{\mu}_{N-1}(x_{N-1}), w_{N-1})] + \sum_{h=0}^{N-1} \alpha^h g[x_h, \tilde{\mu}_h(x_h), w_h] \right\} \\
&\leq E_{w_h} \left\{ \alpha^{N-1} T(\tilde{J})(x_{N-1}) + \sum_{h=0}^{N-2} \alpha^h g[x_h, \tilde{\mu}_h(x_h), w_h] \right\} + \alpha^{N-1} \epsilon_{N-1} \\
&\leq E_{w_h} \left\{ \alpha^{N-1} \tilde{J}(x_{N-1}) + \sum_{h=0}^{N-2} \alpha^h g[x_h, \tilde{\mu}_h(x_h), w_h] \right\} + \alpha^{N-1} \epsilon_{N-1} \\
&\leq E_{w_h} \left\{ \alpha^{N-2} \tilde{J}(x_{N-2}) + \sum_{h=0}^{N-3} \alpha^h g[x_h, \tilde{\mu}_h(x_h), w_h] \right\} + \alpha^{N-2} \epsilon_{N-2} + \alpha^{N-1} \epsilon_{N-1} \\
&\vdots \\
&\leq \tilde{J}(x_0) + \sum_{h=0}^{N-1} \alpha^h \epsilon_h.
\end{aligned}$$

结合这些不等式得

$$J^*(x_0) \leq \tilde{J}(x_0) + \lim_{N \rightarrow \infty} \left(\alpha^N r + \sum_{h=0}^{N-1} \alpha^h \epsilon_h \right).$$

因为序列 $\{\epsilon_k\}$ 是任意的(除了要求 $\epsilon_k > 0$ 外), 我们可以选择 $\{\epsilon_k\}$, 使得 $\lim_{N \rightarrow \infty} \sum_{h=0}^{N-1} \alpha^h \epsilon_h$ 任意接近于零, 结果得证。

(b) 在假设 N 条件下, 令 r 是一个标量, 使得对所有 $x \in S, \tilde{J}(x) + r = 0$; 如果 $\alpha \geq 1$, 令 $r = 0$ 。对任意初始状态 $x_0 \in S$, 我们有

$$\begin{aligned}
J^*(x_0) &= \min_x \lim_{N \rightarrow \infty} E \left\{ \sum_{h=0}^{N-1} \alpha^h g[x_h, \mu_h(x_h), w_h] \right\} \\
&\geq \min_x \lim_{N \rightarrow \infty} \sup_{w_h} E \left\{ \alpha^N [\tilde{J}(x_N) + r] + \sum_{h=0}^{N-1} \alpha^h g[x_h, \mu_h(x_h), w_h] \right\} \\
&\geq \lim_{N \rightarrow \infty} \sup_x \min_{w_h} E \left\{ \alpha^N [\tilde{J}(x_N) + r] + \sum_{h=0}^{N-1} \alpha^h g[x_h, \mu_h(x_h), w_h] \right\}, \quad (5.58)
\end{aligned}$$

其中最后一个不等式根据如下事实求得: 对任何以 λ 为参数的函数序列 $\{h_N(\lambda)\}$ 有

$$\min_1 \lim_{N \rightarrow \infty} \sup h_N(\lambda) \geq \lim_{N \rightarrow \infty} \sup \min_1 h_N(\lambda).$$

这个不等式是由

$$h_N(\lambda) \geq \min_1 h_N(\lambda)$$

不断地取两边的上确界, 且左边对 λ 求极小得到。

利用假设 $\tilde{J} \leq T(\tilde{J})$, 现在我们有

$$\begin{aligned} & \min_{x, w_h} E \left\{ \alpha^N \tilde{J}(x_N) + \sum_{h=0}^{N-1} \alpha^h g[x_h, \mu_h(x_h), w_h] \right\} \\ &= \min_{x, w_h} E \left\{ \sum_{h=0}^{N-2} \alpha^h g[x_h, \mu_h(x_h), w_h] \right. \\ & \quad \left. + \alpha^{N-1} \min_{u_{N-1} \in U(x_{N-1})} E \{ g(x_{N-1}, u_{N-1}, w_{N-1}) \right. \\ & \quad \left. + \alpha \tilde{J}[f(x_{N-1}, u_{N-1}, w_{N-1})] \right\} \\ & \geq \min_{x, w_h} E \left\{ \alpha^{N-1} \tilde{J}(x_{N-1}) + \sum_{h=0}^{N-2} \alpha^h g[x_h, \mu_h(x_h), w_h] \right\} \\ & \quad \vdots \\ & \geq \tilde{J}(x_0). \end{aligned}$$

利用式(5.58)的关系得

$$J^*(x_0) \geq \tilde{J}(x_0) + \lim_{N \rightarrow \infty} \alpha^N r = \tilde{J}(x_0).$$

证毕

与前面类似, 有如下推论:

推论 9.1 令 $\pi = \{\mu, \mu, \dots\}$ 为一个容许的平稳策略,

(a) 在假设 P 条件下, 如果 $\tilde{J}: S \rightarrow (-\infty, +\infty]$ 满足 $\tilde{J} \geq T_*(\tilde{J})$, $\tilde{J}$ 为下有界且 $\alpha < 1$ 或 $\tilde{J} \geq 0$, 则 $\tilde{J} \geq J_*$.

(b) 在假设 N 条件下, 如果 $\tilde{J}: S \rightarrow [-\infty, +\infty)$ 满足 $\tilde{J} \leq T_*(\tilde{J})$, $\tilde{J}$ 为上有界, 且 $\alpha < 1$, 或 $\tilde{J} \leq 0$, 则 $\tilde{J} \leq J_*$.

在假设 N 条件下, 命题 9 也产生了如下最优平稳策略的特征。

命题 10 在假设 N 条件下最优性的充分与必要条件 在假设 N 条件下, 一个平稳策略 $\pi^* = \{\mu^*, \mu^*, \dots\}$ 是最优的充分与必要条件是

$$J_{*,*} = T_{*,*}(J_{*,*}) = T(J_{*,*}),$$

或等价地写成

$$\begin{aligned} J_{*,*}(x) &= E \{ g[x, \mu^*(x), w] + \alpha J_{*,*}[f(x, \mu^*(x), w)] \} \\ &= \min_{u \in U(x)} E \{ g(x, u, w) + \alpha J_{*,*}[f(x, u, w)] \}, \quad x \in S. \end{aligned}$$

证明: 假定上述条件成立, 则因为 $J_{*,*}$ 是 T 的一个不动点, 由命题 9 有 $J_{*,*} \leq J^*$, 即意味着 π^* 最优。反过来, 若 π^* 是最优的, 则有 $J^* = J_{*,*}$, 且由此得 $T_{*,*}(J_{*,*}) = J_{*,*} = J^* = T(J^*) = T(J_{*,*})$, 这就证明了所要结果。

证毕

上述最优性条件的解释是：持续利用 μ^* 是最优的，当且仅当其性能至少与第一阶段利用任意 μ ，其后利用 μ^* 一样好。下面的例子表明，在假设 P 条件下，这一条件是必要的，但非充分的。

例题 3

令 $S = (-\infty, +\infty)$ ，对所有 $x \in S$ ， $U(x) = (0, 1]$ ；对所有 $(x, u, w) \in S \times C \times D$ ，

$$g(x, u, w) = |x|, \quad f(x, u, w) = \alpha^{-1}ux.$$

对所有 $x \in S$ ，令 $\mu^*(x) = 1$ ，则当 $x \neq 0$ 时， $J_{\mu^*}(x) = +\infty$ ，和 $J_{\mu^*}(0) = 0$ 。而且读者容易验证，我们有 $J_{\mu^*} = T_{\mu^*}(J_{\mu^*}) = T(J_{\mu^*})$ ；也容易验证 $J^*(x) = |x|$ 。因此，策略 $\{\mu^*, \mu^*, \dots\}$ 不是最优的。

另一方面，在假设 P 条件下，我们有不同的最优性条件。

命题 11 在假设 P 条件下最优性的充分与必要条件 在假设 P 条件下，一个平稳策略 $\Pi^* = \{\mu^*, \mu^*, \dots\}$ 为最优的充分与必要条件是

$$J^* = T_{\mu^*}(J^*) = T(J^*),$$

或等价地写成

$$\begin{aligned} J^*(x) &= E_w \{g[x, \mu^*(x), w] + \alpha J^*[f(x, \mu^*(x), w)]\} \\ &= \min_{u \in U(x)} E \{g(x, u, w) + \alpha J^*[f(x, u, w)]\}, \quad x \in S. \end{aligned}$$

证明：由推论 8.1，有 $J_{\mu^*} = T_{\mu^*}(J_{\mu^*})$ 。如果上述条件成立[即 $J^* = T_{\mu^*}(J^*)$]，则由推论 9.1 得 $J_{\mu^*} \leq J^*$ ，此即意味着 π^* 的最优性。反过来，如果 π^* 是最优的，则有 $J^* = J_{\mu^*}$ ，由此得 $T_{\mu^*}(J^*) = T_{\mu^*}(J_{\mu^*}) = J_{\mu^*} = J^* = T(J^*)$ ，这就证明了所需结果。证毕

在假设 N 条件下，命题的充分部分还是不成立，下面的例子表明了这一点。

例题 4

令 $S = C = (-\infty, 0]$ ，对所有 $x \in S$ ， $U(x) = C$ ；且对所有 $(x, u, w) \in S \times C \times D$ ，有

$$g(x, u, w) = f(x, u, w) = u;$$

那么，对所有 $x \in S$ ， $J^*(x) = -\infty$ ；而且每个平稳策略 $\pi^* = \{\mu^*, \mu^*, \dots\}$ 满足上述命题的条件。另一方面，对 $\mu^*(x) \equiv 0$ ，则对所有 $x \in S$ 有 $J_{\mu^*}(x) = 0$ 。因此， $\{\mu^*, \mu^*, \dots\}$ 不是最优的。

值得注意的是，命题 11 意味着在假定 P 条件下，当 $U(x)$ 对每个 $x \in S$ 是有限集时，存在一个最优平稳策略。但在假设 N 条件下，却不一定成立(见第六章习题 7)。

逐次逼近法

现在我们转到 DP 算法是否收敛到最优代价函数 J^* 的问题。令 J_0 是 S 上的零函数，即对所有 $x \in S$ ，

$$J_0(x) = 0.$$

在假设 P 条件下，我们有

$$J_0 \leq T(J_0) \leq T^2(J_0) \leq \dots \leq T^k(J_0) \leq \dots,$$

而在假设 N 条件下，有

$$J_0 \geq T(J_0) \geq T^2(J_0) \geq \dots \geq T^k(J_0) \geq \dots.$$

无论在哪种情况下，极限函数

$$J_{\infty}(x) = \lim_{k \rightarrow \infty} T^k(J_0)(x), \quad x \in S \quad (5.59)$$

都是有定义的。如果我们容许 J_∞ 取值 $+\infty$ (在假设 P 条件下), 或 $-\infty$ (在假设 N 条件下)。这里产生了一个问题: 逐次逼近法是否在如下意义仍然有效

$$J_\infty = J^*. \quad (5.60)$$

当然, 此问题具有计算方面的兴趣; 但也具有分析方面的意义。因为若知道 $J^* = \lim_{k \rightarrow \infty} T^k(J_0)$, 则人们就可以由 $T^k(J_0)$ 的性质推断未知函数 J^* 的性质, 而前者是以具体算法方式所定义的函数。

在假设 D 条件下, 已证明 $J_\infty = J^*$ 总成立。我们将证明, 在假设 N 条件下, 这一结论也是对的。然而, 在假设 D 条件下, 结果会有 $J_\infty \neq J^*$ (见习题 9)。下面我们将给出一些容易验证的条件, 它保证在假设 P 条件下 $J_\infty = J^*$ 。我们有如下命题。

命题 12 令假设 P 成立, 且假定

$$J_\infty(x) = T(J_\infty)(x), \quad x \in S.$$

那么, 如果 $J: S \rightarrow R$ 是任意有界函数, 且 $\alpha < 1$, 或在其它情况下 $J_0 \leq J \leq J^*$, 则有

$$\lim_{k \rightarrow \infty} T^k(J)(x) = J^*(x), \quad x \in S. \quad (5.61)$$

(b) 令假设 N 成立, 那么, 如果 $J: S \rightarrow R$ 是任意有界函数, 且 $\alpha < 1$; 或在其它情况下 $J^* \leq J \leq J_0$, 则有

$$\lim_{k \rightarrow \infty} T^k(J)(x) = J^*(x), \quad x \in S. \quad (5.62)$$

证明: (a) 因为在假设 P 条件下有

$$J_0 \leq T(J_0) \leq \dots \leq T^k(J_0) \leq \dots \leq J^*,$$

从而有 $\lim_{k \rightarrow \infty} T^k(J_0) = J_\infty \leq J^*$ 。根据假设, J_∞ 也是 T 的一个不动点, 由命题 9 得 $J^* \leq J_\infty$ 。从而有

$$J_\infty = J^*, \quad (5.63)$$

因而对 $J = J_0$ 的情况, 证明了式(5.61)。

对于 $\alpha < 1$, 且 J 是有界的情况, 令 r 为一个标量, 使得

$$J_0 - re \leq J \leq J_0 + re. \quad (5.64)$$

把 T^k 应用于这个关系式, 并利用引理 1 和 2 得

$$T^k(J_0) - \alpha^k re \leq T^k(J) \leq T^k(J_0) + \alpha^k re. \quad (5.65)$$

因为 $T^k(J_0)$ 收敛于 J^* (已证), 上述关系表明 $T^k(J)$ 也收敛于 J^* 。

在 $J_0 \leq J \leq J^*$ 的情况下, 应用 T^k 则有

$$T^k(J_0) \leq T^k(J) \leq J^*, \quad k = 0, 1, \dots. \quad (5.66)$$

因为 $T^k(J_0)$ 收敛于 J^* , 则 $T^k(J)$ 也收敛于 J^* 。

(b) 前面已证(见式(5.53)), 在假设 N 条件下有

$$J_\infty(x) = \lim_{k \rightarrow \infty} T^k(J_0)(x) = J^*(x). \quad (5.67)$$

由此知, 这个证明是与(a)部分的证明相同。

证毕

现在, 我们着手获得一些条件, 它保证在假设 P 条件下, $J_\infty = T(J_\infty)$ (从而由命题 12 使得 $J_\infty = J^*$) 成立。我们将证明两个命题。第一个命题容易证明, 但要求较严的假设条件。第二个命题证明有点困难, 但要求的假设条件弱得多。

命题 13 令假设 P 成立, 且假定对每个 $\alpha \in S$, 控制约束集是一个有限集, 则

$$J_\infty = T(J_\infty) = J^*. \quad (5.68)$$

证明: 如命题 12(a)部分的证明, 对所有 k 有 $T^k(J_0) \leq J_\infty \leq J^*$. 应用 T 于这个关系得

$$\begin{aligned} T^{k+1}(J_0)(x) &= \min_{u \in U(x)} E\{g(x, u, w) + \alpha T^k(J_0)[f(x, u, w)]\} \\ &\leq T(J_\infty)(x), \end{aligned} \quad (5.69)$$

在式(5.69)中取极限, 得 $J_\infty \leq T(J_\infty)$. 假定存在一个 $\tilde{x} \in S$, 使得

$$J_\infty(\tilde{x}) < T(J_\infty)(\tilde{x}) \quad (5.70)$$

当 $x = \tilde{x}$ 时, u_k 使得式(5.69)达到最小. 因 $U(\tilde{x})$ 为有限, 则必存在某 $\tilde{u} \in U(\tilde{x})$, 使得对正整数集合的某个无限子集 $\mathcal{K}$ 中的所有 k , 有 $u_k = \tilde{u}$. 由式(5.69), 对所有 $k \in \mathcal{K}$ 有

$$T^{k+1}(J_0)(\tilde{x}) = E\{g(\tilde{x}, \tilde{u}, w) + \alpha T^k(J_0)[f(\tilde{x}, \tilde{u}, w)]\} \leq T(J_\infty)(\tilde{x}).$$

当 $k \in \mathcal{K}$, $k \rightarrow \infty$ 时, 取极限得

$$\begin{aligned} J_\infty(\tilde{x}) &= E\{g(\tilde{x}, \tilde{u}, w) + \alpha J_\infty[f(\tilde{x}, \tilde{u}, w)]\} \\ &\leq T(J_\infty)(\tilde{x}) = \min_{u \in U(\tilde{x})} E\{g(\tilde{x}, u, w) + \alpha J_\infty[f(\tilde{x}, u, w)]\}. \end{aligned}$$

从而得 $J_\infty(\tilde{x}) = T(J_\infty)(\tilde{x})$, 与式(5.70)相矛盾. 证毕

下面的命题要求一个紧集而非有限集合. 在这方面, 它加强了命题 13. 我们回想一下(见附录 A), 一个 n 维欧氏空间 R^n 中的子集 X 称为是紧的, 如果每个序列 $\{x_k\}$, $x_k \in X$ 包含一个子序列 $\{x_{k_j}\}_{j \in \mathcal{K}}$, 它收敛于一个点 $x \in X$. 等效地说, 当且仅当 X 是有界闭集, 它才是紧的; 空集被平凡地认为是紧集. 给定任意一族紧集, 它们的交集是一个紧集(可能是空集). 给定一个非空紧集序列 $X_1, X_2, \dots, X_k, \dots$ 使得

$$X_1 \supset X_2 \supset \dots \supset X_k \supset X_{k+1} \supset \dots, \quad (5.71)$$

它们的交集 $\bigcap_{k=1}^{\infty} X_k$ 是非空紧集. 根据这一事实, 从而知, 若 $f: R^n \rightarrow [-\infty, +\infty]$ 是一个函数, 使得集合

$$F_\lambda = \{x \in R^n \mid f(x) \leq \lambda\} \quad (5.72)$$

对每个 $\lambda \in R$ 是紧集, 则存在一个点 x^* 使 f 极小化, 即存在 $x^* \in R^n$, 使得

$$f(x^*) = \min_{x \in R^n} f(x). \quad (5.73)$$

为了看清楚这一点, 取序列 $\{\lambda_k\}$ 使得 $\lambda_k \rightarrow \min_{x \in R^n} f(x)$; 且对所有 k , $\lambda_k \geq \lambda_{k+1}$. 如果 $\min_{x \in R^n} f(x) < +\infty$, 这样的序列存在, 且集合

$$F_{\lambda_k} = \{x \in R^n \mid f(x) \leq \lambda_k\} \quad (5.74)$$

是非空紧集. 且对所有 k , $F_{\lambda_k} \supset F_{\lambda_{k+1}}$. 因此, 交集 $\bigcap_{k=1}^{\infty} F_{\lambda_k}$ 也是非空紧集. 设 x^* 是 $\bigcap_{k=1}^{\infty} F_{\lambda_k}$ 中的任意点, 则

$$f(x^*) \leq \lambda_k, \quad k=1, 2, \dots, \quad (5.75)$$

当 $k \rightarrow \infty$ 取极限, 得 $f(x^*) \leq \min_{x \in R^n} f(x)$, 此即证明了 x^* 使 $f(x)$ 极小化. 我们能保证式(5.72)的集合 F_λ 对所有 λ 是紧集的最一般的情况是, f 连续且当 $\|x\| \rightarrow \infty$ 时 $f(x) \rightarrow \infty$.

命题 14 令假设 P 成立, 且假定集合

$$U_k(x, \lambda) = \left\{ u \in U(x) \mid E\{g(x, u, w) + \alpha T^k(J_0)[f(x, u, w)]\} \leq \lambda \right\} \quad (5.76)$$

对每个 $x \in S$, $\lambda \in R$, 以及对大于某个整数 $\bar{k}$ 的所有整数 k , 是一个欧氏空间的紧子集, 则

$$J_{\infty} = T(J_{\infty}) = J^*, \quad (5.77)$$

且存在一个最优平稳策略。

证明: 如在命题 13 中一样, 有 $J_{\infty} \leq T(J_{\infty})$ 。假定存在一个状态 $\tilde{x} \in S$, 使得

$$J_{\infty}(\tilde{x}) < T(J_{\infty})(\tilde{x}), \quad (5.78)$$

显然必有 $J_{\infty}(\tilde{x}) < +\infty$ 。对于每个 k , 考虑集合

$$U_k[\tilde{x}, J_{\infty}(\tilde{x})] = \{u \in U(\tilde{x}) \mid E\{g(\tilde{x}, u, w) + \alpha T^k(J_0)[f(\tilde{x}, u, w)]\} \leq J_{\infty}(\tilde{x})\}.$$

令 u_k 也是使下式达到极小的点

$$T^{k+1}(J_0)(\tilde{x}) = \min_{u \in U(\tilde{x})} E\{g(\tilde{x}, u, w) + \alpha T^k(J_0)[f(\tilde{x}, u, w)]\}.$$

即 u_k 使得

$$T^{k+1}(J_0)(\tilde{x}) = E\{g(\tilde{x}, u_k, w) + \alpha T^k(J_0)[f(\tilde{x}, u_k, w)]\}.$$

根据我们的紧性假设, 这样的极小点 u_k 存在。对每个 $k \geq \bar{k}$, 考虑序列 $\{u_i\}_{i=k}^{\infty}$, 因为 $T^k(J_0) \leq T^{k+1}(J_0) \leq \dots \leq J_{\infty}$, 则有

$$\begin{aligned} E\{g(\tilde{x}, u_i, w) + \alpha T^k(J_0)[f(\tilde{x}, u_i, w)]\} \\ \leq E\{g(\tilde{x}, u_i, w) + \alpha T^i(J_0)[f(\tilde{x}, u_i, w)]\} \\ \leq J_{\infty}(\tilde{x}), \quad i \geq k. \end{aligned}$$

因此 $\{u_i\}_{i=k}^{\infty} \subset U_k[\tilde{x}, J_{\infty}(\tilde{x})]$ 。因为 $U_k[\tilde{x}, J_{\infty}(\tilde{x})]$ 是紧集, $\{u_i\}_{i=k}^{\infty}$ 的所有极限点均属于 $U_k[\tilde{x}, J_{\infty}(\tilde{x})]$, 并且至少有一个这样的极限点存在。因此, 整个序列 $\{u_i\}_{i=k}^{\infty}$ 的极限点也是存在的。从而得到: 若 $\tilde{u}$ 是 $\{u_i\}_{i=k}^{\infty}$ 的一个极限点, 则

$$\tilde{u} \in \bigcap_{k=\bar{k}}^{\infty} U_k[\tilde{x}, J_{\infty}(\tilde{x})].$$

由式(5.76), 此即意味着对所有 $k \geq \bar{k}$,

$$J_{\infty}(\tilde{x}) \geq E\{g(\tilde{x}, \tilde{u}, w) + \alpha T^k(J_0)[f(\tilde{x}, \tilde{u}, w)]\} \geq T^{k+1}(J_0)(\tilde{x}).$$

当 $k \rightarrow \infty$ 时, 取极限得

$$J_{\infty}(\tilde{x}) = E\{g(\tilde{x}, \tilde{u}, w) + \alpha J_{\infty}[f(\tilde{x}, \tilde{u}, w)]\}.$$

因为上式右边大于或等于 $T(J_{\infty})(\tilde{x})$, 则与式(5.78)矛盾, 因此, $J_{\infty} = T(J_{\infty})$ 。根据命题 12 (a), 式(5.77)得证。

为证明存在一个最优平稳策略, 观察式(5.77), 而最后一个关系式意味着对一个状态 $\tilde{x} \in S$, 且 $J^*(\tilde{x}) < +\infty$, $\tilde{u}$ 在下式达到极小

$$J^*(\tilde{x}) = \min_{u \in U(\tilde{x})} E\{g(\tilde{x}, u, w) + \alpha J^*[f(\tilde{x}, u, w)]\}$$

对于状态 $\tilde{x} \in S$, 使得 $J^*(\tilde{x}) = +\infty$, 每个 $\tilde{u} \in U(\tilde{x})$ 达到前述的极小值。因此, 由命题 11, 最优平稳策略存在。 证毕

读者通过对这一证明的详细考察, 可以验证: 如果 $\mu_k(\tilde{x})$, $k=0, 1, \dots$ 在如下关系式

达到最小

$$T^{k+1}(J_0)(\tilde{x}) = \min_{u \in U(\tilde{x}), w} E\{g(\tilde{x}, u, w) + \alpha T^k(J_0)[f(\tilde{x}, u, w)]\},$$

则若对每个 $\tilde{x} \in S$, $\mu^*(\tilde{x})$ 是 $\{\mu_k(\tilde{x})\}$ 的极限点, 策略 $\pi^* = \{\mu^*, \mu^*, \dots\}$ 为最优, 而且, 对每个 $\tilde{x} \in S$, 且 $J^*(\tilde{x}) < +\infty$, $\{\mu_k(\tilde{x})\}$ 至少有一个极限点。于是, 在命题 13 或命题 14 的假设条件下, 逐次逼近法不仅以极限形式产生了最优代价函数 J^* , 而且也产生了一个最优平稳策略。

其他计算方法

在假设 D 条件下, 我们讨论了三种计算求解方法: 逐次逼近法、策略迭代和线性规则。我们已经看出, 在假设 P 和 N 条件下完成逐次逼近法的有效性(实际上, 在假设 P 条件下, 需要附加条件, 如控制空间的有限性等, 但求计算解时, 这条件典型地满足)。

遗憾的是, 在假设 P 或假设 N 条件下, 如果没有进一步的条件, 策略迭代不是一种有效的过程。如果 $\{\mu, \mu, \dots\}$ 和 $\{\bar{\mu}, \bar{\mu}, \dots\}$ 均为容许策略, 且 $T_{\bar{\mu}}(J_{\mu}) = T(J_{\mu})$, 则在假设 P 条件下, 可证明

$$J_{\bar{\mu}}(x) \leq J_{\mu}(x), \quad x \in S. \quad (5.79)$$

为弄清这一点, 注意 $T_{\bar{\mu}}(J_{\mu}) = T(J_{\mu}) \leq T_{\mu}(J_{\mu}) = J_{\mu}$, 由此得 $\lim_{N \rightarrow \infty} T_{\bar{\mu}}^N(J_{\mu}) \leq J_{\mu}$ 。因为 $J_{\bar{\mu}} = \lim_{N \rightarrow \infty} T_{\bar{\mu}}^N(J_0)$, 和 $J_0 \leq J_{\mu}$, 我们得式(5.79)。然而, 式(5.79)本身不能充分保证策略迭代的有效性。例如, 当 μ 非最优时, 并不清楚式(5.79)严格不等式是否至少对一个状态 $x \in S$ 成立。此处的困难是, 等式 $J_{\mu} = T(J_{\mu})$ 并不意味着 $\{\mu, \mu, \dots\}$ 如在假设 D 条件下那样是最优的, 需要其它条件以保证策略迭代的有效性。然而, 对几种类型的问题, 可以证实这种条件(见习题 6.1 和 6.4)。

当 S 、 C 和 D 均为有限集时, 利用命题 9 可以导出一种基于数学规划的计算方法。在假设 N 条件下, 且 $\alpha = 1$, 相应的(线性)规划是(与 § 6.2 末比较)

$$\max \sum_{i=1}^n \lambda_i$$

$$\text{约束:} \quad \lambda_i \leq g(i, u) + \sum_{j=1}^n p_{ij}(u) \lambda_j, \quad i = 1, 2, \dots, n, \quad u \in U(i).$$

在假设 P 条件下, 且 $\alpha = 1$, 相应的规划取如下形式

$$\min \sum_{i=1}^n \lambda_i$$

$$\text{约束:} \quad \lambda_i \geq \min_{u \in U(i)} [g(i, u) + \sum_{j=1}^n p_{ij}(u) \lambda_j], \quad i = 1, \dots, n.$$

但遗憾的是, 这一规划问题不仅不是线性的, 甚至不是凸的。

然而, 读者应读记住, 包含有限状态的马尔科夫链(S , C 和 D 有限)问题, 和无折扣($\alpha \geq 1$)问题是两种基本类型。一种可能性是, 对某些初始状态, 最优总期望代价无限。在此情况下, 本章的公式很可能变得没有意义, 且此类问题应该纳入第七章每阶段平均费用的框架; 另一种可能性是对所有初始状态, 最优总期望代价有限。在这种情况下, 假设 P 或 N

即意味着, 以概率 1 最终进入某个无代价状态(或无代价状态集), 并且以后不再离开。对这类问题, 有一种专门的理论(见 § 6.4), 在通常满足的假设条件下, 它保证策略迭代有效。

§ 5.5 非平稳与周期性问题的

迄今为止, 本章一直假定问题仅涉及平稳系统, 和平稳的每阶段代价(除非有折扣因子存在)。系统或每阶段代价为非平稳的问题, 在实际中或理论研究中偶尔会碰到, 而且有一定的意义。这类问题可利用简单的变换归入问题 I 的框架中。而对于问题 I, 平稳性是主要的。一旦考虑这种变换, 我们就可得到类似于 § 5.1 和 § 5.4 的结果。

考虑如下形式的非平稳系统

$$x_{k+1} = f_k(x_k, u_k, w_k), \quad k=0, 1, \dots,$$

且代价函数有如下形式

$$J_\pi(x_0) = \lim_{N \rightarrow \infty} E_{w_k} \left\{ \sum_{k=0}^{N-1} \alpha^k g_k[x_k, \mu_k(x_k), w_k] \right\}. \quad (5.80)$$

$k=0, 1, \dots, N-1$

在这些方程中, 对每个 k , x_k 属于空间 S_k ; u_k 属于空间 C_k 。而且对所有 $x_k \in S_k$, 满足 $u_k \in U_k(x_k)$ 。 w_k 属于可数空间 D_k , 集合 S_k 、 C_k 、 $U_k(x_k)$ 、 D_k 可能按阶段而变。随机扰动 w_k 由概率 $P_k(\cdot | x_k, u_k)$ 来表征, 它依赖于 x_k 和 u_k , 以及时间标号 k 。容许策略集 Π 是所有序列 $\pi = \{\mu_0, \mu_1, \dots\}$ 的集合, 且 $\mu_k: S_k \rightarrow C_k$; 对所有 $x_k \in S_k$ 和 $k=0, 1, \dots$, $\mu_k(x_k) \in U_k(x_k)$ 。函数 $g_k: S_k \times C_k \times D_k \rightarrow R$ 是给定的, 并假定满足下述三个假设条件之一, 即本章前面讨论过的假设 D、假设 P 和假设 N。

假设 D' 对所有 $k=0, 1, \dots$, 函数 g_k 满足

$$0 \leq g_k(x_k, u_k, w_k) \leq M, \quad \text{对所有 } (x_k, u_k, w_k) \in S_k \times C_k \times D_k.$$

式中 M 是某个标量, 且 $\alpha < 1$ 。

假设 P' 对所有 $k=0, 1, \dots$, 函数 g_k 满足

$$0 \leq g_k(x_k, u_k, w_k), \quad \text{对所有 } (x_k, u_k, w_k) \in S_k \times C_k \times D_k.$$

假设 N' 对所有 $k=0, 1, \dots$, 函数 g_k 满足

$$g_k(x_k, u_k, w_k) \leq 0, \quad \text{对所有 } (x_k, u_k, w_k) \in S_k \times C_k \times D_k.$$

我们将所建立的问题称为非平稳问题(NSP)。通过对特殊情况即每阶段状态空间相同(对所有 k , $S_k = S$)问题的研究, 我们可得到关于如何把 NSP 转化为一个平稳问题的概念。考虑一个增广状态,

$$\tilde{x} = (x, k),$$

其中 $x \in S$, k 是时间标号。新的状态空间是 $\tilde{S} = S \times K$, 其中 K 表示非负整数集。增广系统是按如下关系演变

$$(x, k) \rightarrow [f_k(x, u_k, w_k), k+1], \quad (x, k) \in \tilde{S}.$$

类似地, 我们可定义每阶段代价如下:

$$\tilde{g}[(x, k), u_k, w_k] = g_k(x, u_k, w_k), \quad (x, k) \in \tilde{S}.$$

显然, 相应于增广系统的问题是平稳的。如果我们限于注意初始状态 $\tilde{x}_0 \in S \times \{0\}$, 则可看出这个平稳问题与 NSP 等价。

现在考虑更一般的情况。为了简化记法,我们假定状态空间 $S_i, i=0,1,\dots$, 控制空间 $C_i, i=0,1,\dots$, 以及扰动空间 $D_i, i=0,1,\dots$, 均互相不相交。这个假定并不失一般性, 如果必要, 我们可以重新标记 S_i, C_i 和 D_i 的元, 而不影响问题的结构。现在定义新的状态空间 S , 控制空间 C , 和新的(可数)扰动空间 D 如下

$$S = \bigcup_{i=0}^{\infty} S_i, \quad C = \bigcup_{i=0}^{\infty} C_i, \quad D = \bigcup_{i=0}^{\infty} D_i.$$

引入一个新的(平稳)系统

$$\tilde{x}_{k+1} = f(\tilde{x}_k, \tilde{u}_k, \tilde{w}_k), \quad k=0,1,\dots, \quad (5.81)$$

其中 $\tilde{x}_k \in S, \tilde{u}_k \in C, \tilde{w}_k \in D$, 而系统函数 $f: S \times C \times D \rightarrow S$ 定义为:

$$f(\tilde{x}, \tilde{u}, \tilde{w}) = f_i(\tilde{x}, \tilde{u}, \tilde{w}), \quad \text{若 } \tilde{x} \in S_i, \tilde{u} \in C_i, \tilde{w} \in D_i, i=0,1,\dots.$$

对于这个三元组 $(\tilde{x}, \tilde{u}, \tilde{w})$, 式中对于某个 $i=0,1,\dots$, 我们有 $\tilde{x} \in S_i$, 但 $\tilde{u} \notin C_i$, 或 $\tilde{w} \notin D_i$, f 的定义是不重要的; 根据将要引入的控制约束, 任何定义都合适我们的目的。控制约束取为 $\tilde{u} \in U(\tilde{x})$, 对所有 $\tilde{x} \in S$, 其中 $U(\cdot)$ 定义为

$$U(\tilde{x}) = U_i(\tilde{x}), \quad \text{若 } \tilde{x} \in S_i, i=0,1,\dots.$$

扰动 $\tilde{w}$ 由概率 $P\{\tilde{w}|\tilde{x}, \tilde{u}\}$ 表征, 使得

$$P(\tilde{w} \in D_i | \tilde{x} \in S_i, \tilde{u} \in C_i) = 1, \quad i=0,1,\dots,$$

$$P(\tilde{w} \notin D_i | \tilde{x} \in S_i, \tilde{u} \in C_i) = 0, \quad i=0,1,\dots.$$

而且, 对任意 $w_i \in D_i, x_i \in S_i, u_i \in C_i, i=0,1,\dots$, 有

$$P(w_i | x_i, u_i) = P_i(w_i | x_i, u_i).$$

我们也可以引入一个新的代价函数

$$\tilde{J}_{\pi}(\tilde{x}_0) = \lim_{N \rightarrow \infty} E_{\tilde{w}_k} \left\{ \sum_{k=0}^{N-1} \alpha^k g[\tilde{x}_k, \tilde{\mu}_k(\tilde{x}_k), \tilde{w}_k] \right\}, \quad (5.82)$$

其中, 每阶段(平稳)代价 $g: S \times C \times D \rightarrow R$ 定义为

$$g(\tilde{x}, \tilde{u}, \tilde{w}) = g_i(\tilde{x}, \tilde{u}, \tilde{w}), \quad \text{若 } \tilde{x} \in S_i, \tilde{u} \in C_i, \tilde{w} \in D_i, i=0,1,\dots.$$

对于三元组 $(\tilde{x}, \tilde{u}, \tilde{w})$, 式中对于某个 $i=0,1,\dots$, 我们有 $\tilde{x} \in S_i$, 但 $\tilde{u} \notin C_i$, 或 $\tilde{w} \notin D_i$ 。假设 D' 成立时, 对所有 $(\tilde{x}, \tilde{u}, \tilde{w}), 0 \leq g(\tilde{x}, \tilde{u}, \tilde{w}) \leq M$; 当假设 P' 成立时, $0 \leq g(\tilde{x}, \tilde{u}, \tilde{w})$; 假设 N' 成立时, $g(\tilde{x}, \tilde{u}, \tilde{w}) \leq 0$; 那末, 对 g 的任何定义都是合适的。对于新的问题, 容许策略集 $\tilde{\Pi}$ 由所有序列 $\tilde{\pi} = \{\tilde{\mu}_0, \tilde{\mu}_1, \dots\}$ 组成, 其中 $\tilde{\mu}_k: S \rightarrow C$, 且对所有 $\tilde{x} \in S, k=0,1,\dots, \tilde{\mu}_k(\tilde{x}) \in U(\tilde{x})$ 。

给定的结构, 定义了一类显然适合于问题 I 框架的问题。我们把这类问题称为平稳问题 (SP)。

重要的是, 要理解 NSP 与此处建立的 SP 之间的密切联系。设 $\pi = \{\mu_0, \mu_1, \dots\}$ 是对 NSP 一个容许的策略, 同时设 $\tilde{\pi} = \{\tilde{\mu}_0, \tilde{\mu}_1, \dots\}$ 是对 SP 一个容许策略, 使得

$$\tilde{\mu}_i(\tilde{x}) = \mu_i(\tilde{x}), \quad \text{如果 } \tilde{x} \in S_i, i=0,1,\dots. \quad (5.83)$$

令 $x_0 \in S_0$ 是 NSP 的初始状态, 且考虑 SP 相同的初始状态(即 $\tilde{x}_0 = x_0 \in S_0$)。那么, 在 SP 中产生的状态序列 $\{\tilde{x}_i\}$ 以概率 1 满足 $\tilde{x}_i \in S_i, i=0,1,\dots$ (即系统由 S_0 移到 S_1 , 然后到 S_2 , 等等, 正好与 NSP 中一样)。而且, NSP 和 SP 中状态和代价生成的概率规律也是相同的。

结果容易看出, 对任意满足式(5.83)的容许策略 π 和 $\tilde{\pi}$, 和满足 $x_i = \tilde{x}_i \in S_0$ 的初始状态 $x_0, \tilde{x}_0$, 在 NSP 和 SP 中产生的状态序列是相同的(对所有 $i, x_i = \tilde{x}_i$), 假定对所有 i , 产生的扰动 w_i 和 $\tilde{w}_i$ 也是相同的话(对所有 $i, w_i = \tilde{w}_i$). 而且, 如果 π 和 $\tilde{\pi}$ 满足式(5.83), 若 $x_0 = \tilde{x}_0 \in S$, 则有 $J_\pi(x_0) = \tilde{J}_\pi(\tilde{x}_0)$. 让我们再考虑 NSP 和 SP 的最优代价函数:

$$J^*(x_0) = \min_{\pi \in \Pi} J_\pi(x_0), \quad x_0 \in S_0,$$

$$\tilde{J}^*(\tilde{x}_0) = \min_{\tilde{\pi} \in \tilde{\Pi}} \tilde{J}_{\tilde{\pi}}(\tilde{x}_0), \quad \tilde{x}_0 \in S.$$

则由 SP 的结构得

$$\tilde{J}^*(\tilde{x}_0) = \tilde{J}^*(\tilde{x}_0, i), \quad \text{若 } \tilde{x}_0 \in S_i, \quad i = 0, 1, \dots. \quad (5.84)$$

式中

$$\tilde{J}^*(\tilde{x}_0, i) = \min_{\pi \in \Pi} \lim_{N \rightarrow \infty} E_{w_k} \left\{ \sum_{k=i}^{N-1} \alpha^{k-i} g_k[x_k, \mu_k(x_k), w_k] \right\},$$

$$\text{若 } \tilde{x}_0 = x_i \in S_i, \quad i = 0, 1, \dots. \quad (5.85)$$

注意, 在这方程的右边, 是按 NSP 的数据定义的. 作为此方程的一种特殊情况, 若 $\tilde{x}_0 = x_0 \in S_0$, 我们得

$$\tilde{J}^*(\tilde{x}_0) = \tilde{J}^*(\tilde{x}_0, 0) = J^*(x_0), \quad \text{若 } \tilde{x}_0 = x_0 \in S_0. \quad (5.86)$$

于是, NSP 的最优代价函数 J^* 可由 SP 的最优代价函数 $\tilde{J}^*$ 得到. 而且, 如果 $\tilde{\pi}^* = \{\tilde{\mu}_0^*, \tilde{\mu}_1^*, \dots\}$ 是 SP 的最优策略, 由下式定义的策略 $\pi^* = \{\mu_0^*, \mu_1^*, \dots\}$

$$\mu_i^*(x_i) = \tilde{\mu}_i^*(x_i), \quad \text{对所有 } x_i \in S_i, \quad i = 0, 1, \dots, \quad (5.87)$$

是 NSP 的一个最优策略. 于是, 通过式(5.87), SP 的最优策略产生了 NSP 的最优策略. 要注意的另一点是, 如果 NSP 满足假设 $D'(P', N')$, 则 SP 满足本章前面介绍的假设 $D(P, N)$.

这些结果表明, 人们能够借助于 SP 来分析 NSP. 当把 § 5.1 和 § 5.4 给出的每一个结果应用于 SP 时, 便产生了相应的 NSP 的结果. 我们将以如下命题提出 NSP 最优性方程的形式.

命题 15 在假设 $D'(P', N')$ 条件下, 下式成立

$$J^*(x_0) = \tilde{J}^*(x_0, 0), \quad x_0 \in S_0,$$

式中对所有 $i = 0, 1, \dots$, 函数 $\tilde{J}^*(\cdot, i)$ 把 S_i 映射到 $[0, \infty)$ ($[0, \infty]$, $[-\infty, 0]$), 它由式(5.85)给出, 满足

$$\tilde{J}^*(x_i, i) = \min_{u_i \in U_i(x_i), w_i} E \{ g_i(x_i, u_i, w_i) + \alpha \tilde{J}^*[f_i(x_i, u_i, w_i), i+1] \},$$

$$x_i \in S_i, \quad i = 0, 1, \dots. \quad (5.88)$$

在假设 D' 条件下, 函数 $\tilde{J}^*(\cdot, i)$, $i = 0, 1, \dots$ 是方程组式(5.88)的唯一有界解. 而且, 在假设 D' 或 P' 条件下, 如果对所有 $x_i \in S_i$ 和 i , $\mu_i^*(x_i) \in U_i(x_i)$, 在式(5.88)中达到极小, 则策略 $\pi^* = \{\mu_0^*, \mu_1^*, \dots\}$ 对 NSP 就是最优的.

证明: 把命题 2、8 和 11 用于 SP, 则此结果可利用定义式(5.84)到式(5.86)得出。

证毕

周期性问题

假定在 NSP 框架内, 存在一个整数 $p \geq 2$ (称为周期), 使得对所有整数 i, j , 且 $|i-j| = \lambda p, \lambda = 1, 2, \dots$, 我们有

$$S_i = S_j, \quad C_i = C_j, \quad D_i = D_j, \quad U_i(\cdot) = U_j(\cdot),$$

$$f_i = f_j, \quad g_i = g_j, \quad P_i(\cdot | x, u) = P_j(\cdot | x, u), \quad (x, u) \in S_i \times C_i.$$

我们假定空间 $S_i, C_i, D_i, i = 0, 1, \dots, p-1$ 都是互不相交的。定义新的状态、控制和扰动空间为

$$S = \bigcup_{i=0}^{p-1} S_i, \quad C = \bigcup_{i=0}^{p-1} C_i, \quad D = \bigcup_{i=0}^{p-1} D_i.$$

等价平稳问题的最优性方程简化成 p 个方程:

$$\tilde{J}^*(x_0, 0) = \min_{u_0 \in U_0(x_0)} E \{g_0(x_0, u_0, w_0) + \alpha \tilde{J}^*[f_0(x_0, u_0, w_0), 1]\},$$

$$\tilde{J}^*(x_1, 1) = \min_{u_1 \in U_1(x_1)} E \{g_1(x_1, u_1, w_1) + \alpha \tilde{J}^*[f_1(x_1, u_1, w_1), 2]\},$$

$\vdots$

$$\begin{aligned} \tilde{J}^*(x_{p-1}, p-1) = & \min_{u_{p-1} \in U_{p-1}(x_{p-1})} E \{g_{p-1}(x_{p-1}, u_{p-1}, w_{p-1}) \\ & + \alpha \tilde{J}^*[f_{p-1}(x_{p-1}, u_{p-1}, w_{p-1}), 0]\}. \end{aligned}$$

只要对所有 $x_i, i = 0, 1, \dots, p-1$, 右边达到极小值, 这些方程可以用来求得(在假设 D' 或 P' 条件下)形式为 $\{\mu_0^*, \dots, \mu_{p-1}^*, \mu_0^*, \dots, \mu_{p-1}^*, \dots\}$ 的周期性策略。

当所涉及的全部空间均为有限时, 可以通过策略迭代算法或线性规划算法, 经有限次算术运算求得最优策略。将算法用到相应的 SP, 可得到这些算法的形式。

最后, 我们给出逐次逼近法的形式, 起始函数为零:

$$\tilde{J}_0(x_i, i) = 0, \quad x_i \in S_i, \quad i = 0, 1, \dots, p-1.$$

$k+1$ 步迭代是由下式给出

$$\tilde{J}_{k+1}(x_i, i) = \min_{u_i \in U_i(x_i)} E \{g_i(x_i, u_i, w_i) + \alpha \tilde{J}_k[f_i(x_i, u_i, w_i), i+1]\},$$

$$i = 0, 1, \dots, p-2,$$

$$\begin{aligned} \tilde{J}_{k+1}(x_{p-1}, p-1) = & \min_{u_{p-1} \in U_{p-1}(x_{p-1})} E \{g_{p-1}(x_{p-1}, u_{p-1}, w_{p-1}) \\ & + \alpha \tilde{J}_k[f_{p-1}(x_{p-1}, u_{p-1}, w_{p-1}), 0]\}. \end{aligned}$$

在假设 D' 和 N' 条件下, (将命题 1 或 12 应用到相应的 SP), 我们有

$$\lim_{k \rightarrow \infty} \tilde{J}_k(x_i, i) = \tilde{J}^*(x_i, i), \quad x_i \in S_i, \quad i = 0, \dots, p-1,$$

同时, 在假设 P' 条件下, 如果以下集合

$$\begin{aligned}
U_k(x_i, \lambda, i) &= \left\{ u_i \in U_i(x_i) \mid E_{w_i} \{ g_i(x_i, u_i, w_i) \right. \\
&\quad \left. + \alpha \tilde{J}_k[f_i(x_i, u_i, w_i), i+1] \} \leq \lambda \right\}, \quad i=0, \dots, p-2, \\
U_k(x_{p-1}, \lambda, p-1) &= \left\{ u_{p-1} \in U_{p-1}(x_{p-1}) \mid E_{w_{p-1}} \{ g_{p-1}(x_{p-1}, u_{p-1}, w_{p-1}) \right. \\
&\quad \left. + \alpha \tilde{J}_k[f_{p-1}(x_{p-1}, u_{p-1}, w_{p-1}), 0] \} \leq \lambda \right\}
\end{aligned}$$

对所有 $x_i \in S_i$, $\lambda \in R$, 以及对大于某个整数 k 的 k (命题 14 应用到 SP), 均为欧氏空间的紧子集, 则同一个方程成立。在此相同的紧性条件下, 保证最优周期性策略存在。

§ 5.6 注 记

具有每阶段有界代价的折扣问题是最简单和性能最好的无限时域问题, 这是由折扣因子引起的收缩特性造成的。很多作者都为此分析作出了贡献, 最著名的有贝尔曼[B 5]和 Blackwell[B 27]。§ 5.2 的映射 F 以及相应的算法在[K 14]中给出, 其中还指出与高斯-赛德尔迭代的联系(也可参看[H 5])。§ 5.2 的线性规划方法是在[D 3]中提出来的。在 § 5.2 和习题 3 给出的误差界限是对[M 5](见[P 13], [P 14]和[B17])已有结果的改进。关于用有限状态马尔科夫链逼近无限状态空间的离散化方法参见[B 18], [F 5], [H 6], [W 8], [W 9]和[W 10]。计算方法研究的综述文章可在[P 16]中找到。带折扣的半马尔科夫决策问题与本章所研究的问题是类似的, 除了前后两种状态之间转换所需时间是随机的, 以及通过折扣因子影响代价之外。这种分析与我们这儿给出的分析很接近(见[R 6])。特别是当每阶段代价有界时, 可以建立如 § 5.3 中情况之一的收缩特性, 而且用于推导类似 § 5.1 和 § 5.2 的结果。自适应集结方面的内容是新的(见[B 20])。我们的方法与其它方法[S 11]的区别在于: 集结状态根据计算的进展随迭代而自适应变化; 这对计算的有效性有显著的影响, 尤其是对含有多个遍历类的问题。

无折扣问题以及每阶段代价无界的折扣问题在[D 9], [B 28]和[S 28]中首先进行了系统的分析。进一步的研究在[B 23]给出。它也可解决有关的可测性问题。在假设 N (见命题 14) 条件下, 逐次逼近法收敛的充分条件在[B 16]和[S 6]中独立地导出, 而参考文献[B16]还给出收敛的充分与必要条件。

虽然本书的主要目的是分析具有可加代价结构的随机最优控制问题, 但我们多次指出 DP 可用于其他类型问题。(如见第一章习题 5、7、9, 以及本章习题 4 和 6)。虽然这些问题的本质差异很大, 但其基本结构都非常类似。我们用描述相应 DP 算法的抽象映射作为起点可掌握这种结构。按此方式, 大多数与 DP 有关的分析或计算方面的基本结果, 都能按一种统一的方式导出。这种分析的细节在[B 16]和[B 23]中给出。

逐次逼近法的结构非常适合于并行或分布式计算, 使得这种方法可由多台处理器按异步方式(实际上不规则)来实现。它容许处理器之间就它们各自的计算结果有任意的通信时延。请看习题 8 和[B 19]。

在问题 I 的模式中, 如有必要, 通过调整控制约束集 $U(x_{k-1})$, 可以考虑对状态 x_k 有形式为 $x_k \in X \subset S$ 的可能约束。这样有

$$x_k = f(x_{k-1}, u_{k-1}, w_{k-1}) \in X, \text{ 对所有 } w_{k-1} \in D, u_{k-1} \in U(x_{k-1}).$$

另一种可能性就是, 通过对每阶段代价函数 g 加上集合 X 的示性函数 $\delta(x|X)$,

$$\delta(x|X) = \begin{cases} 0, & \text{若 } x \in X, \\ +\infty & \text{若 } x \notin X. \end{cases}$$

在假设 P 条件下, 直接考虑状态约束 $x_k \in X$ 。然而, 这种模式要求 g 可以取值 $+\infty$ 。不管如何, 在假设 P 条件下, § 5.4 所证明的所有结果都可以证明, 因为 g 满足

$$0 \leq g(x, u, w) \leq +\infty \quad (x, u, w) \in S \times C \times D,$$

即任何时候 g 容许取值 $+\infty$ 。对于状态约束的分析和处理, 请看参考文献[B 12]和[B 14]或第六章习题 10。

我们已经绕开了许多有关平稳策略的复杂理论问题, 而这些问题在历史上曾对本章所讨论题目的发展起过重要的作用。主要的问题是, 可在多大范围内把我们的注意力限制于平稳策略。这个问题的某些方面现在仍然是悬而未决的。例如, 假定给出一个 $\epsilon > 0$, 问题之一就是, 是否存在一个 ϵ -最优平稳策略, 即一个策略 $\{\mu, \mu, \dots\}$, 使得

$$J_\mu(x) \leq J^*(x) + \epsilon, \text{ 对所有 } x \in S, \text{ 且 } J^*(x) > -\infty,$$

$$J_\mu(x) \leq -\frac{1}{\epsilon}, \text{ 对所有 } x \in S, \text{ 且 } J^*(x) = -\infty.$$

满足如下条件之一, 则答案是肯定的:

1. 假设 P 成立, 而 $\alpha < 1$ (见习题 22)。

2. 假设 N 成立, S 是一个有限集, $\alpha = 1$, 且对所有 $x \in S, J^*(x) > -\infty$ (见习题 25, 或[B 28], [B 29]和[O 3])。

3. 假设 N 成立, S 是一个有限集, $\alpha = 1$, 且问题是确定性的 (见[B 24])。

满足如下条件之一, 则答案是否定的:

4. 假设 P 成立, 且 $\alpha = 1$, (见习题 22)。

5. 假设 N 成立, 且 $\alpha < 1$, (见习题 25, 或[B 24])。

另一个问题是, 当对每个初始状态存在一个最优策略时, 是否存在一个最优平稳策略。在假设 P 条件下, 这个结论是肯定的 (见习题 23)。在假设 N 条件下, 如果对所有 $x \in S, J^*(x) > -\infty, \alpha = 1$, 且扰动空间 D 是可数的, 则这一结论也是肯定的 (但很难证明) [B 29], [D 9], [O 3]。可构造简单的两状态例子, 表明若 $\alpha = 1$, 对某些状态 $x, J^*(x) = -\infty$, 其结论是不成立的 (见习题 24)。然而, 这些例子都依赖于问题中随机元的存在性。如果问题是确定性的, 则可得到更强的结果: 如果无论 $\alpha = 1$, 或 $\alpha < 1$, 每个初始状态上都存在一个最优策略, 且对所有 $x \in S, J^*(x) > -\infty$, 就可找到一个最优平稳策略。这些结果的证明也较困难 [B 24]。

最后我们注意到, 虽然本章的问题要求一个可数的扰动空间, 但仍可以作为分析具有不可数扰动空间问题的起点。做到这一点, 要把这个问题简化成状态空间为概率测度集合的确定性 (即扰动空间是由单个元构成的问题)。这种简化的基本思想展示在习题 18 中, 水平较高的读者可以查询 [B 23], 看如何对非常广泛的一类有限和无限时域问题进行有关简化。

习 题

1. 一个计算机制造商能够处在两种状态。处在状态 1, 他有畅销的好产品; 而处在状态 2, 他的产品滞销。当处在状态 1 时, 他可为他的产品作广告; 在此情况下, 一个阶段报

酬是4个单位,而转移概率是 $p_{11}=0.8$,和 $p_{12}=0.2$ 。如果在状态1,他不作广告,报酬是6个单位,而转移概率是 $p_{11}=p_{12}=0.5$ 。当处在状态2时,他可以作研究,以改进他的产品;在此情况下,一个阶段报酬是-5单位,而转移概率是 $p_{21}=0.7$,且 $p_{22}=0.3$ 。如果在状态2他并不作研究,则报酬是-3个单位,而转移概率是 $p_{21}=0.4$,且 $p_{22}=0.6$ 。把此问题考虑为无限时域折扣问题。

(a) 证明:当折扣因子 α 充分小时,这个计算机商人应该遵循“近视”策略,即处在状态1(或状态2)时,不作广告(或不作研究)。相反,当 α 充分接近1时,他应该遵循“远见”策略,即处在状态1(或状态2)时,作广告(或作研究)。

(b) 当 $\alpha=0.9$ 时,计算最优代价和策略。

2. 一个精力充沛的推销员一个星期每天都工作。他每天只能在A和B两个小城之一工作,他在A城(或B城)工作一天的期望报酬是 r_A (或 r_B),改变工作城市的费用是 c 。假定 $c > r_A > r_B$,且存在一个折扣因子 $\alpha < 1$ 。

(a) 证明 α 充分小时,最优策略是留在他开始留的城市;而当 α 充分接近于1时,最优策略是移到A城(如果开始不是在那里的话),且其后就留在A城。

(b) 对 $c=3$, $r_A=2$, $r_B=1$, 且 $\alpha=0.9$,解这一问题。

(c) 假定只有星期天在A城和B城工作的期望报酬分别变成 R_A 和 R_B ,假设 $R_A < R_B$,讨论最优策略的实质是什么。对于(b)中给出的数据以及 $R_A=1$, $R_B=4.5$,求解这一问题。提示:这一部分需要§5.5周期性问题的理论。

3. 广义误差界限[P14], [D15], [B17]。令 S 是一个集合, $B(S)$ 是 S 上所有有界实值函数的集合;令 $T: B(S) \rightarrow B(S)$ 是一个映射,具有如下两个性质:

- (1) $T(J) \leq T(J')$, 对所有 $J, J' \in B(S)$, 且 $J \leq J'$ 。
- (2) 对每个标量 $r \neq 0$, 及所有 $x \in S$

$$\alpha_1 \leq \frac{[T(J+re)(x) - T(J)(x)]}{r} \leq \alpha_2,$$

其中 α_1, α_2 是两个标量, 且 $0 \leq \alpha_1 \leq \alpha_2 < 1$ 。

(a) 证明 T 是 $B(S)$ 上的一个收缩映射。因此, 对每个 $J \in B(S)$ 有

$$\lim_{k \rightarrow \infty} T^k(J)(x) = J^*(x), \quad x \in S,$$

其中 J^* 是 T 在 $B(S)$ 中的唯一不动点。

(b) 证明对所有 $J \in B(S)$, $x \in S$, 和 $k=1, 2, \dots$,

$$\begin{aligned} T^k(J)(x) + c_k &\leq T^{k+1}(J)(x) + c_{k+1} \leq J^*(x) \\ &\leq T^{k+1}(J)(x) + \bar{c}_{k+1} \leq T^k(J)(x) + \bar{c}_k, \end{aligned}$$

其中对所有 k

$$\begin{aligned} c_k &= \min \left\{ \frac{\alpha_1}{1-\alpha_1} \min_{x \in S} [T^k(J)(x) - T^{k-1}(J)(x)], \right. \\ &\quad \left. \frac{\alpha_2}{1-\alpha_2} \min_{x \in S} [T^k(J)(x) - T^{k-1}(J)(x)] \right\}, \\ \bar{c}_k &= \max \left\{ \frac{\alpha_1}{1-\alpha_1} \max_{x \in S} [T^k(J)(x) - T^{k-1}(J)(x)], \right. \\ &\quad \left. \frac{\alpha_2}{1-\alpha_2} \max_{x \in S} [T^k(J)(x) - T^{k-1}(J)(x)] \right\}, \end{aligned}$$

$$\frac{\alpha_2}{1-\alpha_2} \max_{x \in S} [T^k(J)(x) - T^{k-1}(J)(x)] \}.$$

在 S 由单个元构成的情况下, 这些关系的几何解释示于图 5.4。

(c) 证明由式(5.37)和式(5.38)定义的高斯-赛德尔映射 F 满足




图 5.4 问题 3 误差界限的几何解释

$$\alpha^n \leq \frac{[F(J+re)(x) - F(J)(x)]}{r} \leq \alpha,$$

其中 n 是 S 中元的个数。

(d) 设 J 是一个 n 维向量, 且为方程 $J = T(J)$ 的解。映射 $T: R^n \rightarrow R^n$ 是由下式给出

$$T(J) = g + MJ,$$

其中向量 $g \in R^n$ 和矩阵 M 给定。设 s_i 是 M 的第 i 行的和, 即

$$s_i = \sum_{j=1}^n m_{ij},$$

且设 $\alpha_1 = \min_i s_i$, $\alpha_2 = \max_i s_i$; 证明若 M 的元素 m_{ij} 全非负, 且 $\alpha_2 < 1$, 则(a)和(b)部分的结论成立。

(e) 用高斯-赛德尔方法求解方程组 $J = g + \alpha PT$, 其中, $0 < \alpha < 1$, P 是转移概率矩阵。利用(d)部分构造界限, 它要比(c)部分不等式所给出的界陡。

4. 极小极大问题。对于极小极大问题, 提出类似于 § 5.1 和 § 5.2 的结论与算法。此处代价是

$$J_\pi(x_0) = \lim_{N \rightarrow \infty} \max_{w_k \in W[x_k, \mu_k(x_k)]} \sum_{k=0}^{N-1} \alpha^k g[x_k, \mu_k(x_k), w_k],$$

g 满足假设 D, x_k 是由 $x_{k+1} = f(x_k, \mu_k(x_k), W_k)$ 产生, 而 $w(x, u)$ 是对每个 $(x, u) \in S \times C$, 给定的 D 的非空子集(与第一章习题 5 比较)。

5. 考虑类似于 § 5.1 的问题, 但当处于状态 x_k 时, 存在一个概率 β , 且 $0 < \beta < 1$, 下

一个状态 x_{k+1} 由 $x_{k+1} = f(x_k, u_k, w_k)$ 以及概率 $(1-\beta)$ 决定。系统将以概率 $(1-\beta)$ 转移到一个终态, 并在以后无代价地长久处在这个状态。证明即使 $\alpha = 1$ (无折扣), 该问题也可归入折扣代价问题的框架。

6. 考虑在假设 D 条件下, 类似于问题 I 的一个问题, 但折扣因子 α 依赖于当前的状态 x_k , u_k , 以及 w_k , 即代价函数具有如下形式:

$$J_\pi(x_0) = \lim_{N \rightarrow \infty} E_{\substack{\pi \\ k=0,1,\dots}} \left\{ \sum_{k=0}^{N-1} \alpha_{\pi,k} g[x_k, \mu_k(x_k), w_k] \right\},$$

其中

$$\alpha_{\pi,k} = \alpha[x_0, \mu_0(x_0), w_0] \alpha[x_1, \mu_1(x_1), w_1] \cdots \alpha[x_k, \mu_k(x_k), w_k],$$

且 $\alpha(x, u, w)$ 是一个给定的函数, 满足

$$\begin{aligned} 0 &\leq \min\{\alpha(x, u, w) \mid x \in S, u \in C, w \in D\} \\ &\leq \max\{\alpha(x, u, w) \mid x \in S, u \in C, w \in D\} < 1. \end{aligned}$$

证明此问题具有与 § 5.1 和 § 5.2 直接对应的结果与算法。

7. 令 $\bar{J}: S \rightarrow R$ 是 S 上任意有界函数, 考虑 § 5.2 的逐次逼近法, 且起始函数 $J: S \rightarrow R$ 具有如下形式

$$J(x) = \bar{J}(x) + r, \quad x \in S,$$

其中 r 是某个标量。证明命题 4 的界 $T^k(J)(x) + c_k$ 以及 $T^k(J)(x) + \bar{c}_k$ 对所有 $x \in S$, 不依赖于标量 r 。再证明若 S 是由单个元 $\tilde{x}$ 构成 (即 $S = \{\tilde{x}\}$), 则

$$T(J)(\tilde{x}) + c_1 = T(J)(\tilde{x}) + \bar{c}_1 = J^*(\tilde{x}).$$

8. 分布式异步动态规划 [B19]。逐次逼近法很适合于分布式 (或并行) 计算, 因为相应于状态 i 的迭代

$$J(i) := T(J)(i) \quad (5.89)$$

能以并行于任何其他状态的迭代来完成。考虑 § 5.2 有限状态折扣问题, 且假定对每个状态 i , 式 (5.89) 的迭代是异步地在不同的处理器 i 上执行。即意味着第 i 个处理器在任意时刻执行如下形式的迭代

$$J^i(i) := T(J^i)(i),$$

而且在任意时刻把最后计算的结果传送到另一个处理器 m , 后者然后按下式更新 $J^m(i)$:

$$J^m(i) := J^i(i).$$

假定所有的处理器从不停止计算和传送它们的计算结果到其它处理器。证明在时刻 t 用于每个处理器 i 的最优代价函数的估计 J_t^i , 当 $t \rightarrow \infty$ 时收敛于最优解函数 J^* 。

提示: 设 $\bar{J}$ 和 $\underline{J}$ 是两个函数, 使得 $\underline{J} \leq T(\underline{J})$, 且 $T(\bar{J}) \leq \bar{J}$; 并假定对处理器的所有初始估计 J_0^i 有 $\underline{J} \leq J_0^i \leq \bar{J}$ 。证明在时刻 t , 处理器的估计 J_t^i , 对所有 $t \geq 0$ 满足 $\underline{J} \leq J_t^i \leq \bar{J}$, 而且对充分大的 t 有 $T(\underline{J}) \leq J_t^i \leq T(\bar{J})$ 。

9. 令 $S = [0, \infty)$ 和 $C = U(x) = (0, \infty)$ 分别为状态和控制空间, 令系统方程为

$$x_{k+1} = \left(\frac{2}{\alpha}\right)x_k + u_k, \quad k = 0, 1, \dots,$$

其中 α 是折扣因子, 再令

$$g(x_k, u_k) = x_k + u_k$$

是每阶段代价。证明假设 P 对这个确定性问题是满足的；而且对所有 $x \in S$, $J^*(x) = \infty$ ；但对所有 k , $T^k(J_0)(0) = 0$, [J_0 是零函数, 对所有 $x \in S$, $J_0(x) = 0$]。

10. 设假设 P 成立, 考虑有限状态情况 $S = D = \{1, 2, \dots, n\}$, $\alpha = 1$, $x_{k+1} = w_k$ 。映射 T 表示为

$$T(J)(i) = \min_{u \in U(i)} [g(i, u) + \sum_{j=1}^n p_{ij}(u) J(j)], \quad i = 1, \dots, n,$$

式中 $p_{ij}(u)$ 表示当前状态为 i , 施加控制 u , 下一状态为 j 的转移概率。假定 $p_{ij}(u)$ 和 $g(i, u)$ 对所有 i, j 在 $U(i)$ 上连续, 且 $U(i)$ 对所有 i 是 R^n 的紧子集。证明有 $\lim_{k \rightarrow \infty} T^k(J_0)(i) = J^*(i)$, 其中 $J_0(i) = 0$, $i = 1, 2, \dots, n$ 。

再证明存在一个最优平稳策略。

11. 考虑含如下线性系统的确定性问题

$$x_{k+1} = Ax_k + Bu_k, \quad k = 0, 1, \dots,$$

其中 (A, B) 对是能控的, 且 $x_k \in R^n$, $u_k \in R^m$ 。假定控制无约束, 而每阶段代价 g 满足

$$0 \leq g(x, u), \quad (x, u) \in R^n \times R^m.$$

进一步假定 g 对 x 和 u 连续, 而且当 $\{x_n\}$ 有界, $|u_n| \rightarrow +\infty$ 时, 有 $g(x_n, u_n) \rightarrow +\infty$ 。

(a) 证明对一个折扣因子 $\alpha < 1$, 最优代价对所有 $x \in R^n$ 满足 $0 \leq J^*(x) < +\infty$, 而且存在一个最优平稳策略, 且

$$\lim_{k \rightarrow \infty} T^k(J_0)(x) = J^*(x), \quad x \in R^n.$$

(b) 证明当系统具有 $x_{k+1} = f(x_k, u_k)$ 形式, 且 $f: R^n \times R^m \rightarrow R^n$ 是一个连续函数时, 或许除了 $J^*(x) < +\infty$ 之外, 上式成立。

(c) 假定控制被约束在一个紧集 $U \subset R^m$ ($U(x) \equiv U$), 取代前面: 若 $\{x_n\}$ 有界, 且 $|u_n| \rightarrow \infty$ 时, 有 $g(x_n, u_n) \rightarrow +\infty$ 的假设。证明有相同的结果。

提示: 证明 $T^k(J_0)$ 对每个 k 都是实值连续函数, 再利用命题 14。

12. 在假设 P 条件下, 令 u 对所有 $x \in S$ 使得 $\mu(x) \in U(x)$, 且

$$T_\mu(J^*)(x) \leq T(J^*)(x) + \epsilon, \quad x \in S.$$

证明若 $\alpha < 1$, 则

$$J_\mu(x) \leq J^*(x) + \frac{\epsilon}{1-\alpha}, \quad x \in S.$$

提示: 证明 $T_\mu^k(J^*)(x) \leq J^*(x) + \sum_{i=0}^{k-1} \alpha^i \epsilon$; 另外, 令 $\tilde{J} = J^* + [\epsilon/(-\alpha)]e$, 证明 $T_\mu(\tilde{J}) \leq \tilde{J}$, 再利用推论 9.1。

13. 广义策略迭代算法。本题的目的在于, 对状态空间和控制空间都不必是有限集的情况, 提出一种策略迭代算法。在假设 D 条件下, 设 $\{\mu, \mu, \dots\}$ 是一个容许的平稳策略, 且令 $\tilde{J}_\mu: S \rightarrow R$, 使得

$$\max_{x \in S} |\tilde{J}_\mu(x) - J_\mu(x)| \leq \gamma;$$

令 $J': S \rightarrow R$, 使得

$$\max_{x \in S} |J'(x) - T(\tilde{J}_\mu)(x)| \leq \delta,$$

而且假定

$$\max_{x \in S} |J'(x) - \tilde{J}_\mu(x)| \leq \epsilon;$$

证明对所有 $x \in S$, 下式成立

$$J^*(x) \leq J_\mu(x) \leq J^*(x) + \frac{\delta + \epsilon}{1 - \alpha} + \gamma. \quad (5.90)$$

对固定的 $\gamma, \delta, \epsilon > 0$, 考虑如下策略迭代算法:

1. 由一个容许的平稳策略 $\pi^0 = \{\mu^0, \mu^0, \dots\}$ 开始;
2. 给定 $\{\mu^i, \mu^i, \dots\}$, 求 $\tilde{J}_{\mu^i}: S \rightarrow R$, 使得对所有 $x \in S$, $|\tilde{J}_{\mu^i}(x) - J_{\mu^i}(x)| \leq \gamma \alpha^i$;
3. 求 $\mu^{i+1}: S \rightarrow C$, 且对所有 $x \in S$, $\mu^{i+1}(x) \in U(x)$, 使得

$$T_{\mu^{i+1}}(\tilde{J}_{\mu^i})(x) \leq T(\tilde{J}_{\mu^i})(x) + \delta \alpha^i, \quad x \in S.$$

如果 $\max_{x \in S} |T_{\mu^{i+1}}(\tilde{J}_{\mu^i})(x) - \tilde{J}_{\mu^i}(x)| \leq \epsilon$, 停止; 否则用 μ^{i+1} 替换 μ^i , 且返回步骤2.

证明该算法在有限步(比如说 k 步)迭代后终止, 且

$$J^*(x) \leq J_{\mu^k}(x) \leq J^*(x) + \frac{\alpha^{k-1} \delta + \epsilon}{1 - \alpha} + \gamma \alpha^{k-1}, \quad x \in S.$$

提示: 为证明不等式(5.90), 可用如下事实: 对于任意 $\beta > 0$, 存在一个 k , 使得对所有 $x \in S$, 有

$$|T^{k+1}(\tilde{J}_\mu)(x) - J^*(x)| \leq \beta.$$

然后利用不等式

$$\begin{aligned} |\tilde{J}_\mu(x) - J^*(x)| &\leq |\tilde{J}_\mu(x) - T(\tilde{J}_\mu)(x)| + |T(\tilde{J}_\mu)(x) - T^2(\tilde{J}_\mu)(x)| \\ &\quad + \dots + |T^{k+1}(\tilde{J}_\mu)(x) - J^*(x)| \\ &\leq \max_{x \in S} |\tilde{J}_\mu(x) - T(\tilde{J}_\mu)(x)| (1 + \alpha + \dots + \alpha^k) + \beta \\ &\leq \frac{1}{1 - \alpha} \max_{x \in S} |\tilde{J}_\mu(x) - T(\tilde{J}_\mu)(x)| + \beta, \end{aligned}$$

来证明

$$|\tilde{J}_\mu(x) - J^*(x)| \leq \frac{1}{1 - \alpha} \max_{x \in S} |\tilde{J}_\mu(x) - T(\tilde{J}_\mu)(x)|, \quad x \in S.$$

为证明策略迭代算法在有限步迭代终止, 假设上式不成立, 即对所有 i , 有

$$\max_{x \in S} |T_{\mu^{i+1}}(\tilde{J}_{\mu^i})(x) - \tilde{J}_{\mu^i}(x)| > \epsilon$$

且该算法产生了一个无限策略序列 $\{\pi^i\}$. 首先证明, 对所有 $x \in S$ 及 $i = 0, 1, \dots$, 有

$$T_{\mu^{i+1}}(J_{\mu^i})(x) \leq T(J_{\mu^i})(x) + (\delta + 2\gamma\alpha)\alpha^i \leq J_{\mu^i}(x) + (\delta + 2\gamma\alpha)\alpha^i.$$

利用这个不等式, 证明对所有 $x \in S$, 以及 i, k 有

$$T_{\mu^{i+1}}^k(J_{\mu^i})(x) \leq T(J_{\mu^i})(x) + (\delta + 2\gamma\alpha)\alpha^i \sum_{j=0}^{k-1} \alpha^j,$$

并由此得出结论, 对所有 $x \in S$, 及 $i = 0, 1, \dots$, 有

$$J^*(x) \leq J_{\mu^{i+1}}(x) \leq T(J_{\mu^i})(x) + \lambda \alpha^i,$$

其中

$$\lambda = \frac{\delta + 2\gamma\alpha}{1 - \alpha}.$$

证明对所有 $x \in S$, 及 $i = 1, 2, \dots$, 有

$$J^*(x) \leq J_{\mu^i}(x) \leq T^i(J_{\mu^0})(x) + i\alpha^{i-1}\lambda,$$

并由此得结论

$$\lim_{i \rightarrow \infty} \max_{x \in S} |J_{\mu^i}(x) - J^*(x)| = 0.$$

利用这个等式, 使矛盾成立。

14. 本题的目的在于, 当 S, C, D 均为有限集时, 证明逐次逼近法在有限步迭代之后, 将产生一个最优策略。在假设 D 条件下, 设 $J: S \rightarrow R$ 是一个函数, 对某个 $\epsilon > 0$, 和所有 $x \in S$, 使得

$$|J(x) - J^*(x)| \leq \epsilon.$$

令 $\mu(x)$ 对所有 $x \in S$, 使得 $\mu(x) \in U(x)$, 且

$$\begin{aligned} T_\mu(J)(x) &= E_w \{g[x, \mu(x), w] + \alpha J[f(x, \mu(x), w)]\} \\ &= \min_{u \in U(x)} E_w \{g(x, u, w) + \alpha J[f(x, u, w)]\} = T(J)(x). \end{aligned}$$

(a) 证明对所有 $x \in S$,

$$|T_\mu(J)(x) - J(x)| \leq (1 + \alpha)\epsilon.$$

(b) 利用上面的不等式, 证明对所有 $x \in S$.

$$|T_\mu(J)(x) - J_\mu(x)| \leq \frac{\alpha(1 + \alpha)}{1 - \alpha} \epsilon.$$

(c) 证明对所有 $x \in S$,

$$J^*(x) \leq J_\mu(x) \leq J^*(x) + \frac{2\epsilon}{1 - \alpha}.$$

(d) 假定状态、控制和扰动空间均是有限集, 证明逐次逼近法对每次迭代, 在某个标号之后将产生一个最优策略, 也就是说, 对于任意起始函数 $J: S \rightarrow R$, 存在一个标号 $\bar{k}$, 若 μ^* 使得

$$T_\mu \cdot [T^k(J)] = T^{k+1}(J) \text{ 和 } k \geq \bar{k},$$

则 $\{\mu^*, \mu^*, \dots\}$ 是最优的。

15. 在假设 P 或 N 条件下, 证明若 $\alpha < 1$, 且 $\tilde{J}: S \rightarrow R$ 是一个满足 $\tilde{J} = T(\tilde{J})$ 的有界函数, 则 $\tilde{J} = J^*$ 。

16. 策略迭代与牛顿法[P17]。本题的目的在于, 展示策略迭代与求解非线性方程牛顿法之间的关系。考虑形式为 $F(J) = 0$ 的方程, 其中 $F: R^n \rightarrow R^n$ 。给定一个向量 J_k , 牛顿法是由求解如下线性方程

$$F(J_k) + \frac{\partial F(J_k)}{\partial J} (J_{k+1} - J_k) = 0,$$

确定 J_{k+1} , 其中 $\partial F(J_k)/\partial J$ 是 F 在 J_k 取值的雅可比矩阵。

(a) 考虑 § 5.2 的折扣有限状态问题, 定义

$$F(J) = T(J) - J.$$

证明如果存在唯一策略 μ , 使得

$$T_\mu(J) = T(J),$$

则 F 在 J 的雅可比阵是

$$\frac{\partial F(J)}{\partial J} = \alpha P_\mu - I,$$

其中 I 是 $n \times n$ 单位阵。

(b) 证明当求解 $F(J) = 0$ 时, 策略迭代算法与牛顿法是同一个算法(假定在每一步给出一个唯一的策略)。

17. 考虑求解一个标量序列 $\{u_0, u_1, \dots\}$ 的问题, 对所有 k , 它满足 $u_k \geq 0$, 而 $\sum_{k=0}^{\infty} u_k \leq c$, 并使 $\sum_{k=0}^{\infty} g(u_k)$ 极大, 其中 $c > 0$, 和 对所有 $u \geq 0$, $g(u) > 0$, $g(0) = 0$ 。假定 g 在 $[0, \infty)$ 上单调非减, 证明问题的最优值是 $J^*(c)$, 其中 J^* 是 $[0, \infty)$ 上的一个单调非减函数, 满足 $J^*(0) = 0$, 且

$$J^*(x) = \max_{0 \leq u \leq x} \{g(u) + J^*(x-u)\}, \quad x \in [0, \infty).$$

18. 把一个随机问题转化为一个确定性问题。考虑本章在假设 D 条件下, 集合 S 、 C 、 D 均为有限集的问题。利用 § 5.2 的记法, 考虑被控系统

$$p_{k+1} = p_k P_{\mu_k}, \quad k = 0, 1, \dots,$$

其中 p_k 是在 S 上的概率分布, 看作为一个行向量; P_{μ_k} 是相应于函数 $\mu_k: C \rightarrow S$, 且对所有 $i \in S$, $\mu_k(i) \in U(i)$ 的转移概率矩阵。状态为 p_k , 控制为 μ_k , 再考虑代价泛函

$$\lim_{N \rightarrow \infty} \sum_{k=0}^{N-1} \alpha^k p_k g_{\mu_k}.$$

证明包括该系统和以上代价泛函的确定性问题。它的最优代价和最优策略为本章问题的最优代价和最优策略。

19. 逐次逼近的雅可比方法。考虑 § 5.2 的问题, 以及由任意函数 $J: S \rightarrow R$ 开始, 递推产生 $F(J)$, $F^2(J)$, $\dots$ 的逐次逼近法, 其中 F 是由下式给出的映射

$$F(J)(i) = \min_{u \in U(i)} \frac{g(i, u) + \alpha \sum_{j \in S} p_{ij}(u) J(j)}{1 - \alpha p_{ii}(u)}.$$

证明当 $k \rightarrow \infty$ 时, $F^k(J)(i) \rightarrow J^*(i)$ 。给出一个收敛率的估计, 它至少与原有方法之一不相上下(参看命题 3)。

20. 数据转换[S9]。一个每阶段折扣因子依赖于状态的有限状态问题, 能够转换成状态与折扣因子独立的问题。为看清这一问题。考虑如下一组以 J_i 为变量的方程:

$$J_i = g_i + \sum_{j=1}^n M_{ij} J_j \quad i = 1, \dots, n, \quad (5.91)$$

其中, 假定对所有 i, j 有 $M_{ij} \geq 0$, 且

$$m_i \triangleq \sum_{j=1}^n M_{ij} < 1.$$

(a) 令

$$\alpha = \max_{i=1, \dots, n} \left\{ \frac{m_i - M_{i,i}}{1 - M_{i,i}} \right\}$$

$$\delta_{i,j} = \begin{cases} 1, & \text{若 } i = j, \\ 0, & \text{若 } i \neq j, \end{cases}$$

再对所有 i 和 j 定义

$$\overline{g}_i = \frac{g_i(1-\alpha)}{1-m_i},$$

$$\overline{M}_{i,j} = \delta_{i,j} + \frac{(1-\alpha)(M_{i,j} - \delta_{i,j})}{1-m_i}.$$

证明对所有 i 和 j 有

$$\sum_{j=1}^n \overline{M}_{i,j} = \alpha < 1, \quad \overline{M}_{i,j} \geq 0,$$

而且式(5.91)的一个解 $\{J_i | i = 1, \dots, n\}$ 也是如下方程的一个解

$$J_i = \overline{g}_i + \sum_{j=1}^n \overline{M}_{i,j} J_j, \quad i = 1, \dots, n.$$

(b) 提出该结果的类型, 它用于如式(5.91)的方程, 涉及控制集上求极小, 且将此与 § 5.2 中某个相类似的无限时域问题建立关系。

21. 设假设 P 成立, 并假定 $\pi^* = \{\mu_0^*, \mu_1^*, \dots\} \in \Pi$, 对所有 k 满足 $J^* = T_{\mu_k^*}(J^*)$, 证明 π^* 是最优的, 即 $J_{\pi^*} = J^*$ 。

22. 在假设 P 条件下, 给定 $\epsilon > 0$, 证明存在一个策略 $\pi_\epsilon \in \Pi$, 使得对所有 $x \in S$ 有 $J_{\pi_\epsilon}(x) \leq J^*(x) + \epsilon$; 且对 $\alpha < 1$, 策略 π_ϵ 可被当成平稳的。给出一个例子, 其中 $\alpha = 1$, 并对于每个平稳策略有 $J_\pi(x) = \infty$; 同时对所有 x , $J^*(x) = 0$ 。

提示: 参看命题 8 的证明。

23. 在假设 P 条件下, 证明若存在一个最优策略(一个策略 $\pi^* \in \Pi$, 使得 $J_{\pi^*} = J^*$), 则存在一个最优平稳策略。

24. 利用下面的反例去证明在假设 N 的条件下, 若对某个 $x \in S$, $J^*(x) = -\infty$, 则习题 23 的结论可能不成立。设 $S = D = \{0, 1\}$, $f(x, u, w) = w$, $g(x, u, w) = u$, $U(0) = (-\infty, 0]$, $U(1) = \{0\}$, $p(w=0|x=0, u) = \frac{1}{2}$, 且 $p(w=1|x=1, u) = 1$; 证明 $J^*(0) = -\infty$,

$J^*(1) = 0$, 而且一个容许的非平稳策略 $\{\mu_0^*, \mu_1^*, \dots\}$, 且 $\mu_k^*(0) = -\left(\frac{2}{\alpha}\right)^k$ 是最优的。证明任意容许平稳策略 $\{\mu, \mu, \dots\}$ 满足 $J_\mu(0) = [2/(2-\alpha)]\mu(0)$, $J_\mu(1) = 0$ (见[B29], [D9], 及[O3]有关分析)。

25. 证明: 当 S 是一个有限集, $\alpha = 1$, 且对所有 $x \in S$, $J^*(x) > -\infty$ 时, 习题 22 的结果成立。构造一个反例以表明当 S 是可数集, 且 $\alpha < 1$ (即使对所有 $x \in S$, $J^*(x) > -\infty$) 时, 上述结果是不成立的。

提示: 考虑一个整数 N , 使得对所有 x , N 阶段最优代价 J_N 满足 $J_N(x) \leq J^*(x) + \epsilon$ 。反例参阅[B24]。

26. 带误差界限逐法逼近法的收敛速率。令 P 是一个 $n \times n$ 转换概率矩阵, g 是 R^n 中的

一个向量, e 是 R^n 中的单位向量, 且 $\alpha < 1$ 是折扣因子, 对 $J \in R^n$ 定义

$$T(J) = g + \alpha P J,$$

$$A(J) = J + \frac{e'(T(J) - J)}{n(1 - \alpha)} e,$$

$$F(J) = T(A(J)) = T(J) + \frac{\alpha e'(T(J) - J)}{n(1 - \alpha)} e,$$

并考虑生成 $\{F^k(J)\}$ 的方法 (与命题 4 带误差界限的逐次逼近法类似)。

(a) 证明

$$\begin{aligned} T(F(J)) - F(J) &= \alpha P(F(J) - A(J)) \\ &= \alpha P \left(I - \frac{ee'}{n} \right) (T(J) - J). \end{aligned}$$

(b) 对 $k \geq 1$ 定义

$$r_k = T(F^k(J)) - F^k(J)$$

证明对所有 k , 有

$$r_k = (\alpha P - I)[F^k(J) - J^*],$$

其中 J^* 是 T 的唯一不动点; 进而

$$\begin{aligned} r_k &= \alpha P \left(I - \frac{ee'}{n} \right) r_{k-1} \\ \bar{r}_k &= \alpha^k P \left(I - \frac{ee'}{n} \right) P^{k-1} (T(J) - J). \end{aligned}$$

提示: 证明 $\left(I - \frac{ee'}{n} \right) P \left(I - \frac{ee'}{n} \right) = \left(I - \frac{ee'}{n} \right) P$.

(c) 为简单起见, 假定 P 有一组线性独立的特征向量, 考虑把 $P^{k-1}(T(J) - J)$ 分解为这些特征向量的线性组合。证明 r_k 将以 αP 的次主特征值决定的速率几何地收敛于零。注: 如果 P 不具有线性独立的特征向量, 考虑把 $P^{k-1}(T(J) - J)$ 沿一组相应于 P 的特征值的不变子空间进行分解, 则类似的论证也适用。

第六章 无限时域问题: 应用部分

本章我们将讨论第五章无限时域问题 I 中的各种特殊情况。其中大多数按它们的性质代表了重要的问题类型。也选择其它一些应用问题, 因为它们能够说明第五章理论部分有意义的特征。习题一节接触到各种有关的课题。

本章所讨论的每个问题都满足 § 5.1 和 § 5.4 的假设 D、P 和 N 之一。为严格限制在第五章的框架之内, 我们也假定基本扰动空间是可数的, 虽然在各单独的情况下, 我们并不明显说明这一假定。对于更一般的扰动空间, 大多数结果仍能得到证明, 但需要花费精力以解决技术上的复杂性(见[B23])。

§ 6.1 线性系统与二次代价

考虑这样一种情况: 在问题 I 中系统是线性的, 即

$$x_{k+1} = Ax_k + Bu_k + w_k, \quad k = 0, 1, \dots,$$

其中对所有 k , $x_k \in R^n$, $u_k \in R^m$, 矩阵 A, B 为已知。如在 § 2.1 和 § 3.2 一样, 我们假定随机扰动 w_k 具有零均值和有限二次矩的独立过程。代价函数是二次的, 具有如下形式

$$J_\pi(x_0) = \lim_{N \rightarrow \infty} E_{w_k} \left\{ \sum_{k=0}^{N-1} \alpha^k [x_k' Q x_k + \mu_k(x_k)' R \mu_k(x_k)] \right\},$$

$k = 0, \dots, N-1$

其中 Q 是半正定的 $n \times n$ 对称阵, R 是正定的 $m \times m$ 对称阵。这个问题显然属于假设 P 的框架。

我们的方法就是利用 DP 算法得到函数 $T(J_0)$, $T^2(J_0)$, $\dots$, 以及按点极限函数 $J_\infty = \lim_{k \rightarrow \infty} T^k(J_0)$; 随后将证明 J_∞ 满足 $J_\infty = T(J_\infty)$, 因此由 § 5.4 命题 12 知, $J_\infty = J^*$ 。利用贝尔曼方程及 § 5.4 命题 11, 从 J^* 得到最优策略。

如在 § 2.1 一样, 有

$$\begin{aligned} J_0(x) &= 0, \quad x \in R^n, \\ T(J_0)(x) &= \min_u (x' Q x + u' R u) = x' Q x, \quad x \in R^n, \\ T^2(J_0)(x) &= \min_u E \{ x' Q x + u' R u + \alpha (Ax + Bu \\ &\quad + w)' Q (Ax + Bu + w) \} \\ &= x' K_1 x + \alpha E \{ w' Q w \}, \quad x \in R^n, \end{aligned}$$

$$T^{k+1}(J_0)(x) = x' K_k x + \sum_{m=0}^{k-1} \alpha^{k-m} E \{ w' K_m w \}, \quad x \in R^n, \quad k = 1, 2, \dots,$$

其中 $K_0, K_1, K_2, \dots$ 是由下列递推公式给出

$$K_0 = Q,$$

$$K_{k+1} = A' [\alpha K_k - \alpha^2 K_k B (\alpha B' K_k B + R)^{-1} B' K_k] A + Q, \quad k = 0, 1, \dots.$$

令 $\tilde{R} = R/\alpha$, $\tilde{A} = \sqrt{\alpha} A$, 则上式可写成

$$K_{k+1} = \tilde{A}' [K_k - K_k B (B' K_k B + R)^{-1} B' K_k] \tilde{A} + Q,$$

而且具有 § 2.1 所需要的形式。利用已证明过的结论则有

$$K_k \rightarrow K,$$

如果 $(\tilde{A}, B)$ 和 $(\tilde{A}, C)$ (其中 $Q = C' C$) 分别是能控和能观对。因为 $\tilde{A} = \sqrt{\alpha} A$, 显然 (A, B) 的能控性或 (A, C) 的能观性与 $(\tilde{A}, B)$ 的能控性或 $(\tilde{A}, C)$ 的能观性等价。矩阵 K 是正定的, 它在半正定对称矩阵类的范围内, 是如下方程的唯一解

$$K = A' [\alpha K - \alpha^2 K B (\alpha B' K B + R)^{-1} B' K] A + Q. \quad (6.1)$$

根据前面的分析, 函数 $T^h(J_0)$ 的按点极限由下式给出

$$J_\infty(x) = \lim_{h \rightarrow \infty} T^h(J_0)(x) = x' K x + c, \quad (6.2)$$

其中

$$c = \lim_{h \rightarrow \infty} \sum_{m=0}^{h-1} \alpha^{h-m} E\{w' K_m w\}.$$

这个极限是有确定定义的, 因为 $K_m \rightarrow K$ 。事实上, 可证明下式成立

$$c = \frac{\alpha}{1-\alpha} E\{w' K w\}. \quad (6.3)$$

利用式(6.1)到式(6.3), 可以看出对所有 $x \in S$ 有

$$J_\infty(x) = T(J_\infty)(x) = \min_u [x' Q x + u' R u + \alpha E\{J_\infty(Ax + Bu + w)\}], \quad (6.4)$$

因此由 § 5.4 命题 12 有 $J_\infty = J^*$ 。证明 $J_\infty = T(J_\infty)$ 的另一种方法就是证明 § 5.4 命题 14 的假设是满足的, 即集合

$$U_\lambda(x, \lambda) = \{u | E\{x' Q x + u' R u + \alpha T^h(J_0)(Ax + Bu + w)\} \leq \lambda\}$$

是一个紧集。利用 $T^h(J_0)$ 是一个二次函数, R 为正定的事实, 这是容易验证的。在式(6.4)中求极小即得到最优策略, 它具有 $x^* = \{\mu^*, \mu^*, \dots\}$ 的形式, 其中 μ^* 由下式给出

$$\mu^*(x) = -\alpha (\alpha B' K B + R)^{-1} B' K A x, \quad x \in R^n.$$

这一策略的线性性质和平稳性使它对工程应用具有很大的吸引力。关于本节问题的几种更一般性形式, 包括不完全状态信息情况, 均在习题中进行讨论。一个有趣的事实是, 这个问题能够用策略迭代求解(见习题 5), 虽然如 § 5.4 所讨论的那样, 一般情况下在假设 P 条件下策略迭代是无效的。

§ 6.2 库存控制

对 § 2.2 中每阶段代价带折扣的库存控制问题, 我们考虑它的无限时域形式。库存存量是按如下方程演变

$$x_{k+1} = x_k + u_k - w_k, \quad k = 0, 1, \dots, \quad (6.5)$$

我们还假定逐次的需求 w_k 是独立和有界的, 而且具有恒等的概率分布。为简单起见, 我们假定没有固定代价。对于非零固定代价的情况, 也可以得出类似的分析。最小代函数由下式给出

$$J_{\pi}(x_0) = \lim_{N \rightarrow \infty} E_{w_h} \left\{ \sum_{k=0}^{N-1} \alpha^k [c\mu_k(x_k) + p \max(0, w_k - x_k - \mu_k(x_k)) + h \max(0, x_k + \mu_k(x_k) - w_k)] \right\}.$$

DP 算法是按式计算

$$\begin{aligned} J_0(x) &= 0, \\ T^{k+1}(J_0)(x) &= \min_{0 \leq u \leq w} E \{ cu + p \max(0, w - x - u) \\ &\quad + h \max(0, x + u - w) + \alpha T^k(J_0)(x + u - w) \}. \end{aligned}$$

首先, 让我们证明对所有 $x_0 \in S$ 有

$$J^*(x_0) = \min_x J_x(x_0) < +\infty. \quad (6.6)$$

事实上, 考虑策略 $\tilde{\pi} = \{\tilde{\mu}, \tilde{\mu}, \dots\}$, 其中 $\tilde{\mu}$ 定义为

$$\tilde{\mu}(x) = \begin{cases} 0, & \text{若 } x \geq 0, \\ -x, & \text{若 } x < 0. \end{cases}$$

因为 w_k 是非负有界的, 从而当应用策略 $\tilde{\pi}$ 时, 库存存量满足

$$-w_{k-1} \leq x_k \leq \max[0, x_0], \quad k=1, 2, \dots,$$

而且是有界的。因此 $\tilde{\mu}(x_k)$ 也是有界的。随之当用策略 $\tilde{\pi}$ 时, 所引起的每阶段代价也是有界的, 又因为存在折扣因子, 则有

$$J_{\tilde{\pi}}(x_0) < +\infty, \quad x_0 \in S.$$

因为 $J^* \leq J_{\tilde{\pi}}$, 所以式(6.6)成立。

其次, 当假定 $c < p$ 时, 我们看到 $T^k(J_0)$ 是实值凸函数。事实上有

$$J_0 \leq T(J_0) \leq \dots \leq T^k(J_0) \leq J^*,$$

此即意味着 $T^k(J_0)$ 是实值的。凸性如 § 2.2 证明的那样容易归纳得到。现在考虑集合

$$\begin{aligned} U_k(x, \lambda) &= \{u \geq 0 \mid E\{cu + p \max(0, w - x - u) + h \max(0, x + u - w) \\ &\quad + \alpha T^k(J_0)(x + u - w)\} \leq \lambda\}. \end{aligned} \quad (6.7)$$

这些集合是有界的, 因为当 $u \rightarrow \infty$ 时, 期望值趋于 $+\infty$ 。集合 $U_k(x, \lambda)$ 也是闭的, 因为式(6.7)中的期望值是 u 的一个连续函数[回顾 $T^k(J_0)$ 是实值凸的, 因而是连续的函数]。因此, 我们可以求助于 § 5.4 命题 14 得出

$$J^\infty(x) = \lim_{k \rightarrow \infty} T^k(J_0)(x) = J^*(x), \quad x \in S.$$

由 $T^k(J_0)$ 的凸性可以得出, 极限函数 J^* 也是一个实值凸函数。进而, 我们由 § 5.4 命题 8 得到最优性方程

$$\begin{aligned} J^*(x) &= \min_{u \geq 0} E\{cu + p \max(0, w - x - u) + h \max(0, x + u - w) \\ &\quad + \alpha J^*(x + u - w)\}. \end{aligned}$$

如 § 2.2 那样, 由此方程我们能得到最优平稳策略 $\pi^* = \{\mu^*, \mu^*, \dots\}$, 有

$$\mu^*(x) = \begin{cases} S^* - x, & \text{若 } x \leq S^*, \\ 0, & \text{其它,} \end{cases}$$

其中 S^* 是下式的极小点

$$G^*(y) = cy + L(y) + E\{J^*(y-w)\},$$

且

$$L(y) = pE\{\max(0, w-y)\} + hE\{\max(0, y-w)\}.$$

容易看出, 若 $p > c$, 则有 $\lim_{y \rightarrow -\infty} G^*(y) = +\infty$, 所以这样的极小点存在。而且, 利用 § 5.4 接近末尾所作分析, $G^*(y)$ 的极小点 S^* 可以作为序列 $\{S_k\}$ 的极限点而得到, 这时 S_k 对每个 k 极小化

$$G_k(y) = cy + L(y) + \alpha E\{T^k(J_0)(y-w)\},$$

并利用逐次逼近法得出。

这样一来, 临界水平 S^* 有一个简单的特性, 可以证明 S^* 使表达式 $(1-\alpha)cy + L(y)$ 对 y 极大, 而且本质上能以闭的形式得到(参看第二章习题 25, 及 [H8])。

在有正的固定代价 ($K > 0$) 的情况下, 可以利用相同的论证方法。类似地, 我们证明 J^* 是一个实值、 K -凸的函数。还必须用另一种方法来证明 J^* 也是连续的 (这在直观上是显然的, 留给读者作为练习)。一旦 J^* 的 K -凸性和连续性建立起来, 平稳策略 (s^*, S^*) 的最优性由如下方程得出

$$J^*(x) = \min_{u \geq 0} E\{C(u) + p \max(0, w-x-u) + h \max(0, x+u-w) + \alpha J^*(x+u-w)\},$$

其中 $C(u) = K + cu$, 当 $u > 0$; 且 $C(0) = 0$ 。

§ 6.3 最优停止

考虑一种情况, 当处在每个状态 x 时, 有两种可供选择的行动: 停止, 并付终止代价 $t(x)$; 或付代价 $c(x)$, 按以下系统方程继续过程:

$$x_{k+1} = f_c(x_k, w_k), \quad k = 0, 1, \dots \quad (6.8)$$

目标是寻求一个最优的停止策略, 使得对无限阶段总的期望代价为极小。假定输入扰动 w_k 对所有 k 具有相同的概率分布, 它只依赖于当前的状态 x_k 。

为把这一问题纳入问题 I 的框架, 引入一个附加状态 s (终态); 如在 § 2.4 那样, 完成系统方程式 (6.8) 是按

$$x_{k+1} = s, \quad \text{如果 } u_k = \text{停止, 或 } x_k = s.$$

一旦系统达到终态, 它将无代价地永久停留在这个状态上。

在本节我们假定

$$t(x) \geq 0, \quad c(x) \geq 0, \quad \text{对所有 } x \in S. \quad (6.9)$$

对所有 $x \in S$, $t(x) \leq 0$, 且 $c(x) \leq 0$ 的情况在习题 7 中讨论。事实上, 每当存在一个 $\epsilon > 0$, 使得对所有 $x \in S$ 有 $c(x) \geq \epsilon$, 则所得到的结果也适用于如下情况

$$\min_{x \in S} t(x) > -\infty,$$

即 $t(x)$ 有下界为某标量而不是零。原因是如果假定 $c(x)$ 对所有 $x \in S$ 均大于 $\epsilon > 0$, 任何在一个有限期望阶段数内不停止的策略都会导致无限大的代价, 因而可以不予考虑。这样, 如果

我们对此问题进行变换, 将 $t(x)$ 加一个常数 r , 使得对所有 $x \in S$ 有 $t(x) + r \geq 0$; 这样, 最优代价 $J^*(x)$ 即增加一个 r , 而最优策略则不受影响。

在我们的假设下, 只要扰动空间 D 是可数集, 此问题显然处在问题 I 的框架之内, 而且, 藉助式(6.9), 假设 P 也得以满足。定义 DP 算法的映射 T 取如下形式

$$T(J)(x) = \min[t(x), c(x) + E\{J[f_c(x, w)]\}], \quad x \in S, \quad (6.10)$$

其中 $t(x)$ 就是停止行动的代价; 而 $c(x) + E\{J[f_c(x, w)]\}$ 是继续行动的代价。为了更明确, 我们定义 $T(J)(s) = 0$, 其中 s 是终止状态。然而, 在 s 之后的各种函数值是什么无关重要, 不予明显地考虑。

由 § 5.4 的命题 8, 最优代价函数 J^* 满足

$$J^* = T(J^*).$$

因为控制空间仅有两个元, 由 § 5.4 命题 13 有

$$\lim_{k \rightarrow \infty} T^k(J_0)(x) = J^*(x), \quad x \in S, \quad (6.11)$$

其中 J_0 是零函数(对所有 $x \in S$, $J_0(x) = 0$)。由 § 5.4 的命题 11, 存在一个平稳最优策略, 它由下式给出:

如果 $t(x) < c(x) + E\{J^*[f_c(x, w)]\}$, 停止;

如果 $t(x) \geq c(x) + E\{J^*[f_c(x, w)]\}$, 继续。

令 S^* 表示最优停止集合(可能是空集), 即

$$S^* = \{x \in S \mid t(x) < c(x) + E\{J^*[f_c(x, w)]\}\}.$$

再考虑集合

$$S_k = \{x \in S \mid t(x) < c(x) + E\{T^k(J_0)[f_c(x, w)]\}\},$$

对有限时域, 它为停止问题确定了最优策略。因为有

$$J_0 \leq T(J_0) \leq \dots \leq T^k(J_0) \leq \dots \leq J^*,$$

从而有

$$S_1 \subset \dots \subset S_k \subset \dots \subset S^*,$$

因而 $\bigcup_{k=1}^{\infty} S_k \subset S^*$ 。又, 若 $\tilde{x} \notin \bigcup_{k=1}^{\infty} S_k$, 则有

$$t(\tilde{x}) \geq c(\tilde{x}) + E\{T^k(J_0)[f_c(\tilde{x}, w)]\}, \quad k = 0, 1, \dots,$$

取极限再利用式(6.11)得

$$t(\tilde{x}) \geq c(\tilde{x}) + E\{J^*[f_c(\tilde{x}, w)]\},$$

由此知 $\tilde{x} \notin S^*$ 。所以

$$S^* = \bigcup_{k=1}^{\infty} S_k \quad (6.12)$$

换句话说, 无限时域问题的最优停止集合 S^* 等于所有有限时域停止集合 S_k 的并集。特别是, 当状态空间有限时, 只要时域充分大, 无限时域与有限时域的停止集合是重合的。

假设检验例题: 序列概率比检验

考虑 § 3.5 假设检验问题, 其可能的观察数目为无限的情况。此处, 集合 S 是区间 $[0, 1]$, 且相应于如下充分统计

$$p_k = P(x_k = x^0 | z_0, z_1, \dots, z_k).$$

对于每个 $p \in [0, 1]$, 我们可以规定终止代价

$$t(p) = \min[(1-p)L_0, pL_1],$$

它是与分布 f_0 和 f_1 之间最优选择有关的代价。式(6.10)的映射 T 取如下形式

$$T(J)(p) = \min[(1-p)L_0, pL_1, c + E_z \left\{ J \left[\frac{pf_0(z)}{pf_0(z) + (1-p)f_1(z)} \right] \right\}], \quad (6.13)$$

式中对 z 求数学期望, 它相对于以下概率分布来进行

$$P(z) = pf_0(z) + (1-p)f_1(z), \quad z \in Z.$$

最优代价函数 J^* 满足

$$J^*(p) = \min[(1-p)L_0, pL_1, c + E_z \left\{ J^* \left[\frac{pf_0(z)}{pf_0(z) + (1-p)f_1(z)} \right] \right\}], \quad (6.14)$$

而且是通过如下方程以极限形式得到

$$J^*(p) = \lim_{k \rightarrow \infty} T^k(J_0)(p), \quad p \in [0, 1],$$

其中 J_0 是 $[0, 1]$ 区间上的零函数。

现在考虑函数 $T^k(J_0)$, $k=0, 1, \dots$, 显然有

$$J_0 \leq T(J_0) \leq \dots \leq T^k(J_0) \leq \dots \leq \min[(1-p)L_0, pL_1].$$

而且, 根据 § 3.5 的分析, 我们知道对于所有 k , 函数 $T^k(J_0)$ 在 $[0, 1]$ 区间是凹函数。因此, 点极限函数 J^* 也是 $[0, 1]$ 区间上的凹函数。另外, 式(6.14)意味着

$$J^*(0) = J^*(1) = 0, \text{ 且 } J^*(p) \leq \min[(1-p)L_0, pL_1].$$

由式(6.14)和图 6.1 知[只要 $c < L_0 L_1 / (L_0 + L_1)$], 存在两个标量 $\bar{\alpha}$, $\bar{\beta}$, 且 $0 < \bar{\beta} \leq \bar{\alpha} < 1$, 它们决定了如下形式的最优平稳策略

接受 f_0 若 $p \geq \bar{\alpha}$;
接受 f_1 若 $p \leq \bar{\beta}$;
继续观察 若 $\bar{\beta} < p < \bar{\alpha}$




图 6.1 序列概率比检验的推导

根据上述平稳策略的最优性, 当可能的观察是无限时, § 3.5 描述的序列概率比检验被证明是正确的。

一步前瞻策略

我们已经考虑过一种有效的逐次逼近法, 由零函数 J_0 开始, 逐次计算 $T^N(J_0)$, $N=0, 1, \dots$ 。我们能把 $T^N(J_0)(x_0)$ 看作为一个 N 阶段停止问题在初始状态 x_0 的代价。由此, 若在第 N 阶段还未发生停止, 第 N 段的终端代价为零。

另一个有趣的 N 阶段问题(已经以更一般的形式在 § 2.5 考虑过) 是终端代价为 $t(x_N)$ 的问题(即, 若在第 N 阶段还不终止时, 迫使其停止)。相应的逐次逼近法是对所有 $x \in S, N=0, 1, \dots$ 逐次计算 $T^N(t)(x)$ 。然而, 这一方法一般来说并非有效, 因为对任意 x , 当 $N \rightarrow \infty$ 时, $T^N(t)(x)$ 并不一定收敛于 $J^*(x)$ 。为弄清这一点, 考虑对所有 x , 连续代价 $c(x)$ 为零, 而终止代价 $t(x)$ 是由 $\epsilon > 0$ 定界的下有界函数的情况。此时, 对所有 x 有 $T^N(t)(x) \geq \epsilon$; 同时对所有 x , $J^*(x) = 0$, 因为无代价一直继续的策略是最优的。然而, 这样的情况也可能发生: 如果问题中最优策略最终以概率 1 终止, 则上述反常现象不会发生, 且 $T^N(t)$ 将收敛到 J^* 。保证这一点的一种方法([R6])就是对某个 $\epsilon > 0$, 假定有

$$c(x) \geq \epsilon, \text{ 对所有 } x \in S, \quad (6.15)$$

在此情况下, 正如前面讨论的那样, 我们也可以放松对 t 的正性假设为下有界。对于不同的一组假设, 请看下一节末的例题 4。

命题 1 在本节问题中, 假定式(6.15)成立, 且 $t(x)$ 对 $x \in S$ 上有界, 则对所有 $x_0 \in S$, 及 $N=0, 1, \dots$ 有

$$0 \leq T^N(t)(x_0) - J^*(x_0) \leq \frac{(\bar{t} - \epsilon)t(x_0)}{(N+1)\epsilon}, \quad (6.16)$$

其中 ϵ 是式(6.15)的下界, $\bar{t}$ 由下式给出

$$\bar{t} = \max[\epsilon, \max_{x \in S} t(x)].$$

证明: 设 π^* 是一个最优策略, 又设 π_N 是对于 $k=0, 1, \dots, N-1$ 选取与 π^* 相同动作的策略, 且在此之前还未停止。那么, 若 k_s 是 π^* 停止的一个随机时刻, 而 J_{π_N} 是相应于利用 π_N 的代价, 对于所有 $x_0 \in S$ 有

$$\begin{aligned} T^*(x_0) &= J^*(x_0) = E\{C | k_s \leq N, \pi^*\} P(k_s \leq N) \\ &\quad + E\{C | k_s > N, \pi^*\} P(k_s > N), \\ T^N(t)(x_0) &\leq J_{\pi_N}(x_0) = E\{C | k_s \leq N, \pi_N\} P(k_s \leq N) \\ &\quad + E\{C | k_s > N, \pi_N\} P(k_s > N), \end{aligned}$$

其中 C 表示所引起的总代价, 而期望随初始状态 x_0 而定。由以上关系式得

$$\begin{aligned} T^N(t)(x_0) - J^*(x_0) &\leq [E\{C | k_s > N, \pi_N\} \\ &\quad - E\{C | k_s > N, \pi^*\}] P(k_s > N) \\ &\leq (\bar{t} - \epsilon) P(k_s > N) \end{aligned} \quad (6.17)$$

为得到 $P(k_s > N)$ 的一个界, 注意到

$$t(x_0) \geq J^*(x_0) \geq (N+1)\epsilon P(k_s > N),$$

所以

$$P(k_s > N) \leq \frac{t(x_0)}{(N+1)\epsilon}. \quad (6.18)$$

由式(6.17)和式(6.18), 我们得到式(6.16)的右边。通过重复应用映射 T 于关系式 $t \geq J^*$ 的两边得到左边。证毕

该意, 关系式(6.16)不仅保证了由终止代价 t 开始的逐次逼近法的有效性, 而且提供了一个收敛速率的估计和可预计的误差界限。

现在, 考虑 § 2.4 的向前一步的停止集合

$$\tilde{S}_1 = \{x \in S \mid t(x) \leq c(x) + E\{t[f_c(x, w)]\}\}, \quad (6.19)$$

并假定 $\tilde{S}_1$ 在如下意义下是吸收的

$$f_c(x, w) \in \tilde{S}_1, \text{ 对所有 } x \in \tilde{S}_1, w \in D. \quad (6.20)$$

那么, 如在 § 2.4 一样, 得出一步前瞻策略:

$$\text{停止, 当且仅当 } x \in \tilde{S}_1$$

是最优的。我们现在给出一些例子。

资产出售

考虑 § 2.4 和 § 2.5 资产出售的例子, 其中利率 r 为零, 房子未售出时每周期的维修费 $c > 0$, 而且以往的出价能够在未来任何时刻被接受。我们有如下最优方程:

$$J^*(x) = \max[x, -c + E\{J^*(\max[x, w])\}].$$

在此情况下, 我们考虑对总期望报酬求极大, 继续代价严格为负, 而终止报酬 x 是正的。因此不满足假设式(6.9)。然而, 如果我们假定 x 在一个有界区间 $[0, M]$ 取值, 其中 M 是可能出价值的一个上界, 我们的分析仍然是可用的[参看式(6.9)后面的讨论]。考虑向前一步的停止集合式(6.19), 它由下式给出

$$\tilde{S}_1 = \{x \mid x \geq -c + E\{\max[x, w]\}\}.$$

经过类似于 § 2.4 所给出的计算之后, 可以看出

$$\tilde{S}_1 = \{x \mid x \geq \bar{\alpha}\},$$

其中 $\bar{\alpha}$ 是一个标量, 满足

$$\bar{\alpha} = P(\bar{\alpha})\bar{\alpha} + \int_{\bar{\alpha}}^{\infty} w dP(w) - c.$$

显然, $\tilde{S}_1$ 在式(6.20)的意义下是吸收的, 因而接受大于或等于 $\bar{\alpha}$ 的首次出价的一步前瞻策略是最优的。

推理的盗贼

这个例子我们在 § 2.4 末考虑过, 已证明对于任意时域长度, 一步前瞻策略是最优的。最优性方程为

$$\begin{aligned} J^*(x) &= \max[x, (1-p)E\{J^*(x+w)\}] \\ &= \max[x, c(x) + E\{J^*(x+w)\}], \end{aligned}$$

其中

$$c(x) = -pE\{J^*(x+w)\}.$$

我们可以把 $c(x)$ 看作相应于盗贼被捕可能性的严格负继续代价函数。所以, 由终止代价起始的逐次逼近法是有效的, 方程(6.20)成立。且容易看出: 有限时域的最优策略即盗贼累计的收入达到或超过 $(1-p)\bar{w}/p$ 的而罢休的策略, 对于无限时域问题也是最优的。

§ 6.4 首次通过问题^[原注]

在上一节的停止问题中, 每一阶段只有两种可能的行动: 停止或继续。现在我们考虑一般性的问题, 其中控制者不能停止这个系统, 但能影响终止的概率, 和由一个状态到下一个状态的转移概率。我们要把这一问题的两种不同形式加以区分。在第一种形式中, 我们假定在所有策略下不可避免地以概率 1 终止。在第二种形式中, 我们假定在某些策略下最后终止是肯定的, 且假定代价结构使得存在一种力图终止的刺激。人们可以粗略地把控制目标描述为力图以最小代价来终止, 而且在这种意义下本节的问题可看作为 § 1.3 中最短路径问题的一种随机推广。

除非另有规定, 本节都假定系统是一个有限状态马尔科夫链, 且状态空间是

$$\hat{S} = \{0, 1, \dots, n\}.$$

控制空间 C 也假定是有限的。与控制 u 相应的转移概率记为

$$p_{ij}(u) = P\{x_{k+1} = j | x_k = i, u_k = u\}.$$

状态 0 在下述意义下是一个终止状态

$$p_{00}(u) = 1, u \in U(0)$$

当控制 u 施加于系统时, 在状态 $i = 1, \dots, n$ 的每阶段代价记为 $g(i, u)$, 而且处在终止状态时无代价, 即对所有的 u , $g(0, u) = 0$ 。

在所有策略下终止不可避免

此处我们假定存在一个正整数 m , 使得对每个容许策略 $\pi = \{\mu_0, \mu_1, \dots\}$, 下式成立

$$P(x_m = 0 | x_0 = i, \pi) > 0, i = 1, 2, \dots, n. \quad (6.21)$$

也就是说, 由每个初始状态开始, 在每一个策略下, 存在一个正的概率到达终止状态。稍加思考后读者将确信, 这等价于假定对每个策略, 终止将以概率 1 发生。实际上, 对所有平稳策略 π , 假定式(6.21)成立已足够了, 请参看习题 12 和 13。

在此假设下, 能够证明无论在假设 P 或假设 N 条件下, 许多重要结果是不可利用的。事实上, 也没有必要假定假设 P 或 N 成立 (即没有必要规定每阶段代价 g 全非负或全非正)。主要理由是定义 DP 算法的映射 T , 对所有函数 $J: S \rightarrow R$, $J(0) = 0$, 是一个 m 阶段的收缩映射, 其中 m 是式(6.21)的正整数 (见 § 5.3)。

命题 2 存在一个标量 $\rho < 1$ 使得对所有 $J, J': S \rightarrow R$, 且 $J(0) = J'(0) = 0$, 有

$$\begin{aligned} \max_{i=0,1,\dots,n} |T^m(J)(i) - T^m(J')(i)| \\ \leq \rho \max_{i=0,1,\dots,n} |J(i) - J'(i)|, \end{aligned} \quad (6.22)$$

其中

$$T(J)(i) = \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u) J(j) \right], i = 1, 2, \dots, n,$$

$$T(J)(0) = 0.$$

证明: 令 $\pi_m = \{\mu_0, \mu_1, \dots, \mu_{m-1}\}$, 使得

原注: 本节要求熟悉有限状态马尔科夫链的基本概念, 综述及其参考文献在附录 D 中给出。

$$T^m(J') = (T_{\mu_0}, T_{\mu_1}, \dots, T_{\mu_{m-1}})(J').$$

从如下不等式减去上式

$$T^m(J) \leq (T_{\mu_0}, T_{\mu_1}, \dots, T_{\mu_{m-1}})(J),$$

则对每个 i 得

$$\begin{aligned} T^m(J)(i) - T^m(J')(i) &\leq (T_{\mu_0} T_{\mu_1} \dots T_{\mu_{m-1}})(J)(i) \\ &\quad - (T_{\mu_0} T_{\mu_1} \dots T_{\mu_{m-1}})(J')(i). \end{aligned} \quad (6.23)$$

右边两项是相应于初始状态 i , 策略 π_m , 以及终端代价分别为 $J(x_m)$ 和 $J'(x_m)$ 的 m 阶段代价。因此式(6.23)右边等于

$$\sum_{j=1}^n P(x_m = j | x_0 = i, \pi_m) [J(j) - J'(j)], \quad (6.24)$$

而且对所有 i 得到

$$T^m(J)(i) - T^m(J')(i) \leq \sum_{j=1}^n P(x_m = j | x_0 = i, \pi_m) \max_s |J(s) - J'(s)|.$$

把 J 和 J' 的作用颠倒过来, 对某个策略 π'_m , 类似地可以得到

$$T^m(J')(i) - T^m(J)(i) \leq \sum_{j=1}^n P(x_m = j | \hat{x}_0 = i, \pi'_m) \max_s |J(s) - J'(s)|.$$

由式(6.21)有

$$\rho = \max_{\pi} \max_i \sum_{j=1}^n P(x_m = j | x_0 = i, \pi) < 1. \quad (6.25)$$

最后三个关系式证明了式(6.22)。

证毕

用于此证明中的论证结果也证明了如下推论。

推论 2.1 令 $\pi = \{\mu_0, \mu_1, \dots\}$ 为一个容许策略, 则对所有的 $J, J': S \rightarrow R$, 且 $J(0) = J'(0) = 0$ 有

$$\begin{aligned} \max_{i=0,1,\dots,n} |(T_{\mu_0} T_{\mu_1} \dots T_{\mu_{m-1}})(J)(i) - (T_{\mu_0} T_{\mu_1} \dots T_{\mu_{m-1}})(J')(i)| \\ \leq \rho \max_{i=0,1,\dots,n} |J(i) - J'(i)|, \end{aligned}$$

其中 ρ 由式(6.25)给出。

建立命题 2 和推论 2.1 的 m 阶段收缩特性之后, 我们可以说明许多重要的分析和计算结果。下面的命题保证由任意函数 $J: S \rightarrow R$, $J(0) = 0$ 起始的逐次逼近法收敛到最优代价函数 J^* ; 且 J^* 和 J_μ 也可分别作为方程 $J = T(J)$ 和 $J = T_\mu(J)$ 的唯一解而求得。

命题 3 对于每个 $J: S \rightarrow R$, 且 $J(0) = 0$,

$$J^*(x) = \lim_{k \rightarrow \infty} T^k(J)(x), \quad x \in S,$$

和对每个平稳策略,

$$J_\mu(x) = \lim_{k \rightarrow \infty} T_\mu^k(J)(x), \quad x \in S.$$

而且, J^* 和 J_μ 分别是方程 $J = T(J)$ 和 $J = T_\mu(J)$ 在函数类 $J: S \rightarrow R, J(0) = 0$ 之内的唯一解。

另外, 对于 $i = 1, \dots, n$, 若 $\mu^*(i)$ 使如下方程右边达到极小

$$J^*(i) = \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u) J^*(j) \right], \quad i = 1, \dots, n,$$

则 $\pi^* = \{\mu^*, \mu^*, \dots\}$ 是一个最优平稳策略。

命题 3 的证明可以通过类似于 § 5.1 的论证而得到。利用策略迭代法或线性规划去计算最优平稳策略也是可能的(见 § 5.2)。这些算法的推导和证明再次留给读者作为练习。

例题 1

平均终止时间极小化。这一情况即

$$g(i, u) = 1, \quad i = 1, \dots, n, \quad u \in U(i),$$

是相应于目标为按平均尽可能快把终止的一个问题, 同时相应的最优代价函数 $J^*(i)$ 是由状态 i 起始的最小平均终止时间。由命题 3, 我们看出这些时间就是如下方程的唯一解

$$J^*(i) = \min_{u \in U(i)} \left[1 + \sum_{j=1}^n p_{ij}(u) J^*(j) \right], \quad i = 1, \dots, n.$$

在特殊情况下, 每个状态仅有一个控制, 则 $J^*(i)$ 表示由 i 到 0 的平均首次通过时间(见附录 D)。把这些时间记为 t_i , 它是如下方程的唯一解

$$t_i = 1 + \sum_{j=1}^n p_{ij} t_j, \quad i = 1, \dots, n,$$

这是马尔科夫链理论熟知的结果。

下面的例子表示一种病态, 表明对控制空间的有限假设不能轻易放松。

例题 2

敲诈者二难推论[W11]。考虑这样一个问题, 其中存在两个状态, 终态 0 和另一个状态 $x=1$ 。在状态 1, 我们可以在 $(0, 1]$ 中选择一个控制 u , 然后以概率 u^2 无代价地转移到状态 0, 以概率 $1-u^2$ 和代价 $-u$ 保留在状态 1。

我们可以把 u 看作敲诈者提出的要求, 状态 1 为受害者屈从的状况; 状态 0 则为受害者拒绝敲诈者要求的状况。这个问题可以看作敲诈者抬高要价和使受害者屈从之间进行平衡, 力图使其总的收益为最大的问题。

如果从 $(0, 1]$ 区间的一个有限子集中选择控制, 这个问题就纳入本节的框架, 且对每个容许策略, 满足假设式(6.21)。最优代价则应是有限的, 而且还存在一个最优平稳策略。然而, 若设有有限性限制, 则由状态 1 起始的最优代价是 $-\infty$, 就不存在一个最优平稳策略。为弄清这一点, 首先注意这个问题满足假设 N。定义 DP 算法的映射 T 由下式给出

$$\begin{aligned} T(J)(0) &= 0, \\ T(J)(1) &= \min_{u \in (0, 1]} [-u + (1-u^2)J(1)]. \end{aligned}$$

对于任意平稳策略 $\{\mu, \mu, \dots\}$, 且 $\mu(1) = u$, 则有

$$J_\mu(1) = -u + (1-u^2)J_\mu(1),$$

由此得

$$J_\mu(1) = -\frac{1}{u}.$$

因此, $\min_\mu J_\mu(1) = -\infty$, 且 $J^*(1) = -\infty$, 但不存在一个最优平稳策略, 还要注意, 如果约束集合是 $u \in [0, 1]$ (即 $u=0$ 是一个容许的控制), 虽违反条件式(6.21), 情况不发生变化。

某些策略下终止可避免：最短回路路径

这儿我们提出一些假设，当把注意力集中在以概率 1 导致终止的策略上，保证不会有损失。那么，基于命题 2 收缩特性推导出的理论正好可起作用。

一个平稳策略 π 称为是正常的，如果存在一个整数 m ，使得

$$P(x_m = 0 | x_0 = i, \pi) > 0, \text{ 对所有 } i = 1, 2, \dots, n. \quad (6.26)$$

我们假定至少存在一个最优正常策略。在这些环境下，假设 N 成立的情况可以简化为已经讨论过的情況[对所有 i 和 π ，式(6.21)成立]；参看习题 13(b)。因此，我们只限于讨论假设 P 成立的情况[对所有 $i = 1, \dots, n$ 和 $u \in U(i)$ ， $g(i, u) \geq 0$]。注意，若至少存在一个正常策略，且

$$g(i, u) > 0, \quad i = 1, \dots, n, \quad u \in U(i), \quad (6.27)$$

那么，必存在一个最优正常策略，因为在式(6.27)条件下，每个非正常的平稳策略对某个初始状态导致无限代价，因而不可能是最优的。

设 P_μ 表示转移概率矩阵，即

$$P_\mu = \begin{bmatrix} 1 & 0 & \dots & 0 \\ p_{10}[\mu(1)] & p_{11}[\mu(1)] & \dots & p_{1n}[\mu(1)] \\ \dots & \dots & \dots & \dots \\ p_{n0}[\mu(n)] & p_{n1}[\mu(n)] & \dots & p_{nn}[\mu(n)] \end{bmatrix} \quad (6.28)$$

P_μ 的第一行是 $(1, 0, \dots, 0)$ ，因为 $x = 0$ 是一个吸收态。下面的推论是由命题 3 将 i 点的约束集限制为 $\{\mu(i)\}$ 而得到的。

推论 3.1 如果 $\pi = \{\mu, \mu, \dots\}$ 是一个正常策略，则

$$J_\mu = \{J_\mu(0), J_\mu(1), \dots, J_\mu(n)\}$$

满足 $J_\mu = T_\mu(J_\mu)$ ，或等效地为

$$J_\mu = g_\mu + P_\mu J_\mu, \quad (6.29)$$

其中 P_μ 是矩阵式(6.28)，而 g_μ 是向量

$$g_\mu = \begin{bmatrix} g[0, \mu(0)] \\ g[1, \mu(1)] \\ \dots \\ g[n, \mu(n)] \end{bmatrix}.$$

而且， J_μ 为满足 $J = T_\mu(J)$ ， $J(0) = 0$ ，的唯一实值 J 。另外，对每个 $J(0) = 0$ 的实值 J 有

$$\lim_{k \rightarrow \infty} T_\mu^k(J)(i) = J_\mu(i), \quad i = 0, 1, \dots, n. \quad (6.30)$$

因为假设 P 成立，由 § 5.4 命题 10 有：一个平稳策略 $\{\mu^*, \mu^*, \dots\}$ 是最优的，当且仅当 $\mu^*(x)$ 在贝尔曼方程中达到最小，即

$$T_{\mu^*}(J^*) = T(J^*). \quad (6.31)$$

下面的命题提出了另一种充分与必要条件。

命题 4 设 $\pi^* = \{\mu^*, \mu^*, \dots\}$ 是一个平稳策略，且对所有 i ， $J_{\mu^*}(i) < \infty$ 。为使 π^* 最优，其充分与必要条件是

$$T_{\mu^*}(J_{\mu^*}) = T(J_{\mu^*}), \quad (6.32)$$

或等效地

$$g[i, \mu^*(i)] + \sum_{j=0}^n p_{ij}[\mu^*(i)] J_{\mu^*}(j) \\ = \min_{u \in U(i)} \left[g(i, u) + \sum_{j=0}^n p_{ij}(u) J_{\mu^*}(j) \right], \quad i = 0, 1, \dots, n.$$

证明: 式(6.32)的必要性是由式(6.31)得出。反过来, 对于任意最优正常策略 $\pi = \{\bar{\mu}, \bar{\mu}, \dots\}$, 利用式(6.30)(之所以可用是因为 J_{μ^*} 假定为实值), 条件 $J_{\mu^*} = T(J_{\mu^*})$ 即意味着

$$J_{\mu^*} \leq J_{\bar{\mu}}(J_{\mu^*}) \leq T_{\bar{\mu}}^2(J_{\mu^*}) \leq \dots \leq \lim_{k \rightarrow \infty} T_{\bar{\mu}}^k(J_{\mu^*}) = J_{\bar{\mu}} = J^*.$$

因此 π^* 是最优的。

证毕

另一个结果如下:

命题 5 最优代价函数 J^* 是唯一的实值函数 J , $J(0) = 0$, $J(i) \geq 0$, $i = 1, \dots, n$; 且满足方程 $J = T(J)$ 。

证明: 设 $J: S \rightarrow R$ 是一个实值函数, $J(0) = 0$, $J(i) \geq 0$, 使得 $J = T(J)$ 。由 § 5.4 的命题 9, 有 $J \geq J^*$, 于是剩下的只是证明相反的不等式。令 $\{\mu^*, \mu^*, \dots\}$ 是一个最优正常策略, 则有

$$J = T(J) \leq T_{\mu^*}(J) \leq \dots \leq T_{\mu^*}^k(J) \leq \dots.$$

利用式(6.30), 则得 $J \leq J_{\mu^*}$ 。因为 μ^* 是最优的, 则得 $J \leq J^*$ 。

证毕

这一结果可用来证明关于逐次逼近法有效性的命题 12(a) 的下述强化形式。

推论 5.1 如果 J 是实值函数, $J(0) = 0$, $J(i) \geq 0$, $i = 1, \dots, n$, 使得或者

$$J(i) \leq J^*(i), \quad i = 0, 1, \dots, n,$$

或者

$$T(J)(i) \leq J(i), \quad i = 0, 1, \dots, n,$$

则

$$\lim_{k \rightarrow \infty} T^k(J) = J^*(i), \quad i = 0, 1, \dots, n.$$

证明: 在第一假设条件下, 这个结果是由第五章命题 12(a) 得到。在第二假设条件下, 容易看出极限 $J_{\infty}(i) = \lim_{k \rightarrow \infty} T^k(J)(i)$ 存在, 且满足 $J_{\infty} = T(J_{\infty})$ (利用控制空间的有限性, 并参照第五章命题 13 的证明)。这一结果现在由命题 5 得出。

证毕

在我们现有的假设条件下, 对首次通过问题, 证明策略迭代算法的有效性是可能的。确实, 令 $\pi = \{\mu, \mu, \dots\}$ 是一个平稳策略, 且对所有 i , $J_{\mu}(i) < \infty$, 再令 $\bar{\mu}$ 使得 $\bar{\mu}(i) \in U(i)$, $i = 0, 1, \dots, n$, 以及

$$T_{\bar{\mu}}(J_{\mu}) = T(J_{\mu}),$$

则 $T_{\bar{\mu}}(J_{\mu}) \leq T_{\mu}(J_{\mu}) = J_{\mu}$, 于是由 § 5.4 的推论 9.1(a), 得 $J_{\bar{\mu}} \leq J_{\mu}$ 。若有 $J_{\bar{\mu}} = J_{\mu}$, 则根据关系式

$$J_{\bar{\mu}} = T_{\bar{\mu}}(J_{\bar{\mu}}) \leq T_{\bar{\mu}}(J_{\mu}) = T(J_{\mu}) \leq T_{\mu}(J_{\mu}) = J_{\mu},$$

能够得到 $T(J_{\mu}) = J_{\mu}$; 再由命题 4, $\pi = \{\mu, \mu, \dots\}$ 是最优的。因而, 或者 $\pi = \{\mu, \mu, \dots\}$ 是最优的, 或者 $\pi = \{\bar{\mu}, \bar{\mu}, \dots\}$ 是一个严格较好的策略。因此可得出: 假定从一个平稳策略

开始, 该平稳策略对所有初始状态产生有限的代价, 用策略迭代法, 我们可以在有限步迭代得到一个最优正常策略。

例题 3

最短路径问题。考虑一个有向图, 和从所有结点 $i = 1, 2, \dots, n$ 到一个特定的结点 0 寻求一个最短路径的问题。我们假定, 每个连线的长度 a_{ij} 是严格正的, 而且从每个结点 $i \neq 0$, 到结点 0 存在一条路径。为方便起见, 如果 (i, j) 没有连线, 我们写成 $a_{ij} = \infty$ 。稍加思考后读者就会相信我们面临的是一个首次通过问题。其中结点即为状态, 由一个结点向外的连线即为在相应状态的控制变量, 每阶段代价即连线长度。而且, 还存在一个最优正常策略。如果用 $J^*(i)$ 表示由结点 i 到结点 0 的最小距离, 贝尔曼方程即为

$$J^*(i) = \min_j [a_{ij} + J^*(j)], \quad i = 1, 2, \dots, n,$$

$$J^*(0) = 0.$$

由命题 5 知, 这些最小距离是贝尔曼方程的唯一解。还有, 这些距离也能通过策略迭代, 或从任意非负初始距离 $J(i)$ 开始, $J(0) = 0$ 的逐次逼近法(推论 5.1)求得。

现在如果把长度为正性的假设放松为非负[对所有 $i, j, a_{ij} \geq 0$], 考虑将会发生什么情况。可以证明, 最短路径是贝尔曼方程的解, 但这些距离未必是唯一解, 未必或者等于相应首次通过问题的最优代价。作为一个例子, 考虑图 6.2 所示网络, 连线长度 $a_{10} = 1, a_{12} = 0, a_{21} = 0$ 。最短距离是 $J(1) = J(2) = 1$, 满足贝尔曼方程且 $J(0) = 0$ 。然而, 与首次通过问题相应的最优代价是 $J^*(0) = J^*(1) = J^*(2) = 0$, 根据 § 5.4 的理论推断, 这也是贝尔曼方程的解。这里发生的问题是: 最优策略是以零代价从结点 1 移到结点 2, 再从结点 2 返回到结点 1。这个策略并非是正常的, 也不相应于从结点 1 和 2 到结点 0 的一组路径。结果命题 5 不成立。而且, 正常策略是从结点 1 移到结点 0, 从结点 2 移到结点 1, 它满足条件式 (6.32), 但不是最优的。另外, 由此策略起始的策略迭代, 和由最短距离 $J(1) = J(2) = 1, J(0) = 0$ 开始的逐次逼近, 都不会改进结果。




图 6.2 包含一个零长度循环的最短路径问题。最短距离是 $J(1) = J(2) = 1$ 且与 $J(0) = 0$ 一起满足贝尔曼方程; 然而, 与首次通过问题相应的最优代价是 $J^*(0) = J^*(1) = J^*(2) = 0$ 。

只要我们假定不含结点 0 的每个有向循环至少包括一个正长度的连线, 才可容许有零长度。因此, 可以看出, 每个最优策略是正常的; 而且由命题 5, 最短距离就是贝尔曼方程的唯一解。

例题 4

最优停止 假定在每个状态 i , 存在一个特定的控制 u^s , 它肯定把系统驱动到终态, 即

$$p_{i0}(u^s) = 1, \quad i = 1, \dots, n.$$

那么, 我们得到一个比上一节状态空间为有限集时较特殊的停止问题; 但也是更一般的问题, 它除了终止状态之外, 每个状态有不正一个可利用的控制变量。注意到这里存在至少一个正常策略, 它在每个状态停止。我们假定对所有 i 和 u , $g(i, u) \geq 0$, 且存在至少一个最优正常策略[比如, 若式 (6.27) 成立, 这将是正确的]。那么, 推论 3.1, 命题 4 和命题 5 的结果就适用。

令 $t(i)$ 表示在状态 i 的终止代价,

$$t(i) = g(i, u^s), \quad i = 1, \dots, n,$$

而 $\tilde{U}(i)$ 就是在状态 i 的容许控制集合而不停止:

$$\tilde{U}(i) = \{u \in U(i) \mid u \neq u^s\}, \quad i = 1, \dots, n,$$

贝尔曼方程取如下形式

$$J^*(i) = T(J^*)(i) = \min \left[t(i), \min_{u \in \tilde{U}(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u) J^*(j) \right] \right], \quad (6.33)$$

$$J^*(0) = T(J^*)(0) = 0. \quad (6.34)$$

由推论 5.1 知, 由零函数起始的逐次逼近法收敛到 J^* 。另一方面, 由式 (6.33) 和式 (6.34) 可以看出, 对所有 i , 终止代价函数 t 满足 $T(t)(i) \leq t(i)$ 。由推论 5.1 得知, 由 t 起始的逐次逼近法收敛到最优代价, 即

$$\lim_{k \rightarrow \infty} T^k(t)(i) = J^*(i), \quad i = 0, 1, \dots, n.$$

这个事实与命题 1 纯停止问题的结论是类似的。

现在考虑向前一步的停止集合:

$$\bar{S}_1 = \{i \mid t(i) \leq T(t)(i), \quad i = 0, 1, \dots, n\},$$

并且假定在如下意义下是吸收的, 即对所有 $u \neq u^s$,

$$p_{ij}(u) = 0, \quad \text{若 } i \in \bar{S}_1, \quad j \notin \bar{S}_1$$

那么可以看出, 与上一节类似, 存在一个最优的一步前瞻策略, 当且仅当目前的状态处在 $\bar{S}$ 中它才停止。

§ 6.5 随机调度和多臂投赌机问题

在本节的问题中, 存在 n 个项目(或活动), 在任意一个时间周期, 只可开展一个项目。每个项目 i 在时刻 k 由状态 x_k^i 来表征。若在时刻 k 进行项目 i , 可以收到一个期望报酬 $\alpha^k \cdot R^i(x_k^i)$, 其中 $\alpha \in (0, 1)$ 是一个折扣因子; 状态 x_k^i 按如下方程演变:

$$x_{k+1}^i = f^i(x_k^i, w_k^i), \quad \text{若在时刻 } k \text{ 进行项目 } i, \quad (6.35)$$

其中 w_k^i 是一个随机扰动, 概率分布依赖于 x_k^i , 但不依赖于以前的扰动。所有闲置项目的状态均不受影响, 即

$$x_{k+1}^i = x_k^i, \quad \text{若在 } k \text{ 时刻项目 } i \text{ 是闲置的。} \quad (6.36)$$

我们假定为完全状态信息, 而且报酬函数 $R^i(\cdot)$ 是一致地上有界和下有界的, 于是问题满足第五章假设 D 的条件。

我们还假定, 在任意时刻 k , 存在从所有项目中永远撤出的选择。在此情况下收到的报酬是 $\alpha^k M$, 且将来不再得到另外的报酬。撤出的报酬 M 是给定的, 对问题提供了参量化, 这一点将被证明是非常有用的。注意, 对于充分小的 M , 撤出将永远不是最优的, 因此容许对撤出不作为一个实际选择的问题进行建模。

这个问题的关键特征表现在以下三个基本假设中的项目独立性:

1. 闲置项目的状态维持不变;
2. 收到的报酬仅依赖于项目当前所处的状态;
3. 在一个时刻只进行一个项目。

由这些假设所蕴含的丰富结构有可能产生功能很强的方法。结果，最优策略具有指标规则的形式，即对每个项目 i ，存在一个函数 $m^i(x^i)$ ，使得 k 时刻的最优策略是：

$$\text{若 } M > \max_i \{m^i(x_k^i)\}, \text{ 撤出;} \quad (6.37a)$$

$$\text{若 } m^i(x_k^i) = \max_i \{m^i(x_k^i)\} \geq M, \text{ 进行项目 } i. \quad (6.37b)$$

于是 $m^i(x_k^i)$ 可以看作进行第 i 个项目的利益指标，而 M 则表示在时刻 k 撤出所获利益。最优策略就是最大可得利益的选择过程。

本节的问题传统上称为多臂投赌机问题。项目调度和在投币机上选择投币的序列存在相似性。投币机有很多臂，它们相应于不同但未知的支付的概率分布。在每次投赌时，所选择的臂的分布是易于识别的。于是，要在支付期望高的臂上投币与发掘其它臂获赢潜力之间进行折衷。把项目状态与臂的支付分布联系起来，我们看出基本特征 1 至 3 都出现在多臂投赌机问题中。

一个项目的指标

设 $J(x, M)$ 表示当初始状态为 $x = (x^1, \dots, x^n)$ 和撤出报酬为 M 时能获得的最优报酬。由 § 5.1 我们知道，对每个 M ， $J(0, M)$ 是如下贝尔曼方程的唯一有界解：

$$J(x, M) = \max [M, \max_i L^i(x, M, J)], \text{ 对所有 } x, \quad (6.38)$$

其中 L^i 定义为

$$L^i(x, M, J) = R^i(x^i) + \alpha E_{w^i} \{J[x^1, \dots, x^{i-1}, f^i(x^i, w^i), x^{i+1}, \dots, x^n, M]\}. \quad (6.39)$$

下一个命题给出 J 的某些有用的特性。

命题 6 设 $B = \max_i \max_{x^i} |R^i(x^i)|$ ，对于固定的 x ，最优报酬函数 $J(x, M)$ 作为 M 的函数具有如下性质：

- (a) $J(x, M)$ 是凸的，且单调非减的；
- (b) $J(x, M)$ ，对于 $M \leq -B/(1-\alpha)$ 为常值；
- (c) $J(x, M) = M$ ，对所有 $M \geq B/(1-\alpha)$ 。

证明：考虑逐次逼近法，由如下函数起始

$$J_0(x, M) = \max[0, M].$$

产生以下的逐次迭代

$$J_{k+1}(x, M) = \max[M, \max_i L^i(x, M, J_k)], \quad k = 0, 1, \dots, \quad (6.40)$$

而由 § 5.1 命题 1 知

$$\lim_{k \rightarrow \infty} J_k(x, M) = J(x, M), \text{ 对所有 } x, M. \quad (6.41)$$

我们归纳证明 $J_k(x, M)$ 具有此命题所列 (a) 到 (c) 的性质，当 $k \rightarrow \infty$ 时，我们通过取极限建立 J 的相同性质。显然， $J_0(x, M)$ 满足 (a) 到 (c) 性质。假定 $J_k(x, M)$ 满足 (a) 到 (c)，则由式 (6.39) 和式 (6.40) 得出 $J_{k+1}(x, M)$ 是 M 的凸单调非减函数。这是因为，求期望和求极大运算保留了这些性质。验证 (b) 和 (c) 是很容易的，留给读者作为练习。证毕

现在考虑仅有一个项目，比方说 i 能进行的问题。这就是停止问题，除了存在折扣因子外与 § 6.3 的问题是一样的。对此问题的最优报酬函数记为 $J^i(x^i, M)$ ，而且具有命题 6 中

指出的性质。对固定的 x^i ，把 $J^i(x^i, M)$ 看作 M 的函数的一个典型形式示于图 6.3。显然，存在 $J^i(x^i, M) = M$ 时 M 的最小值 $m^i(x^i)$ ，即

$$m^i(x^i) = \min\{M | J^i(x^i, M) = M\}, \text{ 对所有 } x^i. \quad (6.42)$$

函数 $m^i(x^i)$ 称为项目 i 的指标函数(或简称指标)，它对每个状态给出了一个无差阈值，即 $m^i(x^i)$ 是一个撤出报酬，对此报酬当处在状态 x^i 时，撤出与继续进行该项目是无差别的。




图 6.3 对于固定 x^i ，第 i 个项目报酬函数的形式，以及指标 $m^i(x^i)$ 的定义

我们的目的在于对由式(6.42)定义的指标函数，证明指标规划式(6.37)的最优性。

项目逐项撤出策略

首先考虑具有单个项目，比方说项目 i 的问题，和一个固定的撤出报酬 M 。那么，由指标的定义式(6.42)，最优策略就是

$$\text{若 } m^i(x^i) < M, \text{ 撤出项目 } i; \quad (6.43a)$$

$$\text{若 } m^i(x^i) \geq M, \text{ 项目 } i \text{ 继续进行。} \quad (6.43b)$$

换句话说，这个项目继续进行到其状态落到撤出集合

$$S^i = \{x^i | m^i(x^i) < M\} \quad (6.44)$$

的时刻。在该时刻，项目永远撤出。

现在考虑对固定撤出报酬 M 的多项目问题。假定在某个时刻我们处在状态 $x = (x^1, \dots, x^n)$ ，我们先回答两个问题：

1. 当仍有一个项目 i 在状态 x^i ，使得 $m^i(x^i) > M$ ，(从所有项目中)撤出是否有意义？答案是否定的。当 $m^i(x^i) > M$ 时，撤出不可能是最优的。因为如果我们使项目 i 单独进行到其状态落入式(6.44)撤出集合 S^i 再撤出，我们将得到更高的期望报酬。[这是根据指标的定义式(6.42)，以及对于单个项目问题最优策略式(6.43)的本质而得出的。]

2. 状态处在式(6.44)撤出集合 S^i 的项目 i 继续进行是否有意义？直观上这个答案是否定的；一个已经达到撤出而毫无吸引力的项目，如果仅仅因为其它项目(按这里假定是独立的)的可利用性而变得有吸引力，似乎是不可能的。

因此, 我们便猜想存在一种项目逐项撤出(PPR)策略, 它仿佛把撤出项目当作唯一可利用的项目, 永久性地予以撤出。于是, 在每个时刻, 当状态为 $x = (x^1, \dots, x^n)$ 时, 一个 PPR 策略是

若 $x^i \in S^i$, 永久撤出项目 i ; (6.45a)

若对某个 j , $x^j \notin S^j$, 进行项目 j 。 (6.45b)

其中 S^i 就是式(6.44)第 i 个项目的撤出集合。注意, 一个 PPR 策略决定有关项目的撤出, 但并不在还未撤出的项目中指定要进行工作的项目。

下面的命题证实了我们的猜想, 证明很长但很简单。

命题 7 存在一个最优的 PPR 策略。

证明: 根据式(6.38), 式(6.39)和式(6.45), PPR 策略的存在性等价于对所有 i 有

$$M > L^i(x, M, J), \text{ 对所有 } x, \text{ 且 } x^i \in S^i, \quad (6.46a)$$

$$M \leq L^i(x, M, J), \text{ 对所有 } x, \text{ 且 } x^i \notin S^i. \quad (6.46b)$$

其中 L^i 是由下式给出

$$L^i(x, M, J) = R^i(x^i) + \alpha E_{w^i} \{J[x^1, \dots, x^{i-1}, f^i(x^i, w^i), x^{i+1}, \dots, x^n, M]\}. \quad (6.47)$$

而 $J(x, M)$ 是相应于 x 和 M 的最优报酬函数。

对所有 x^i , 第 i 个单项目最优报酬函数显然满足

$$J^i(x^i, M) \leq J(x^1, \dots, x^{i-1}, x^i, x^{i+1}, \dots, x^n, M). \quad (6.48)$$

因为选择非 i 的其它项目进行工作并不减小最优报酬。而且, 由撤销集合 S^i 的定义式(6.44),

$$x^i \notin S^i, \text{ 若 } M \leq R^i(x^i) + \alpha E_{w^i} \{J^i[f^i(x^i, w^i), M]\}. \quad (6.49)$$

利用式(6.47)到式(6.49), 我们得式(6.46b)。

对于 $i = 1$ 证明式(6.46a)是充分的。记:

$\underline{x} = (x^2, \dots, x^n)$: 非项目 1 的所有其它项目的状态;

$\underline{J}(\underline{x}, M)$: 项目 1 永远撤出后, 问题的最优报酬函数;

$\underline{J}(x^1, \underline{x}, M)$: 包括所有项目和相应于状态 $x = (x^1, \underline{x})$ 问题的最优报酬函数。

对于所有 $x = (x^1, \underline{x})$, 我们将证明如下不等式:

$$\underline{J}(\underline{x}, M) \leq \underline{J}(x^1, \underline{x}, M) \leq \underline{J}(\underline{x}, M) + [\underline{J}^1(x^1, M) - M]. \quad (6.50)$$

[也就是说, 这在直观上表示了显然的事实: 处在状态 $(x^1, \underline{x})$, 如果作为撤出回报, 人们获得了从项目 1 能得到的超过撤出报酬 M 的最大报酬, 人们则乐于永久撤出项目 1。]我们已说明, 对 $i = 1$, 为证明式(6.46a), 只要证明式(6.50)就足够了。事实上, 当 $x^1 \in S^1$ 时, 则 $\underline{J}^1(x^1, M) = M$, 于是由式(6.50)得 $\underline{J}(x^1, \underline{x}, M) = \underline{J}(\underline{x}, M)$, 此式当 $i = 1$ 时即与式(6.46a)等价。

现在我们转到式(6.50)的证明。其左边是显然的。为证明右边, 我们用归纳法进行逐次逼近递推。

$$\begin{aligned} J_{k+1}(x^1, \underline{x}) &= \max[M, R^1(x^1) + \alpha E\{J_k[f^1(x^1, w^1), \underline{x}]\}, \\ &\quad \max_{i \neq 1}\{R^i(x^i) + \alpha E\{J_k[x^1, F^i(x, w^i)]\}\}, \end{aligned} \quad (6.51a)$$

$$\underline{J}_{k+1}(\underline{x}) = \max[M, \max_{i \neq 1}\{R^i(x^i) + \alpha E\{\underline{J}_k[F^i(\underline{x}, w^i)]\}\}], \quad (6.51b)$$

$$\underline{J}_{k+1}^1(x^1) = \max[M, R^1(x^1) + \alpha E\{J_k[f^1(x^1, w^1)]\}], \quad (6.51c)$$

其中, 对所有 $i \neq 1$, 和 $\underline{x} = (x^2, \dots, x^n)$,

$$F^i(\underline{x}, w^1) = (x^2, \dots, x^{i-1}, f^i(x^1, w^1), x^{i+1}, \dots, x^n). \quad (6.52)$$

对于递推公式(6.51)的初始条件是

$$J_0(x^1, \underline{x}) = M, \text{ 对所有 } (x^1, \underline{x}), \quad (6.53a)$$

$$J_0(\underline{x}) = M, \quad \text{对所有 } \underline{x}, \quad (6.53b)$$

$$J_0^1(x^1) = M, \quad \text{对所有 } x^1. \quad (6.53c)$$

我们知道, $J_k^1(x^1, \underline{x}) \rightarrow J(x^1, \underline{x}, M)$, $J_k(\underline{x}) \rightarrow J(\underline{x}, M)$, 及 $J_k^1(x^1) \rightarrow J^1(x^1, M)$; 所以为证明式(6.50), 证明对所有 k 及 $\underline{x} = (x^1, \underline{x})$ 有

$$J_k(x^1, \underline{x}) \leq J_k(\underline{x}) + [J_k^1(x^1) - M] \quad (6.54)$$

就足够了。根据定义式(6.53), 我们看出对于 $k=0$, 式(6.54)成立。假定对于某个 k 成立, 我们将证明对 $k+1$ 也成立。由式(6.51a)及归纳假设式(6.54), 我们有

$$J_{k+1}(x^1, \underline{x}) \leq \max[M, R^1(x^1) + \alpha E\{J_k(\underline{x}) + J_k^1[f^1(x^1, w^1)] - M\}, \\ \max_{i \neq 1}\{R^i(\underline{x}^i) + \alpha E\{J_k[F^i(\underline{x}, w^1)] + J_k^1(x^1) - M\}\}].$$

利用 $J_k(\underline{x}) \geq M$ 和 $J_k^1(x^1) \geq 1$ 的事实[见式(6.51)], 以及前面的方程, 可以看出

$$J_{k+1}(x^1, \underline{x}) \leq \max[\beta_1, \beta_2],$$

其中

$$\beta_1 = \max[M, R^1(x^1) + \alpha E\{J_k^1[f^1(x^1, w^1)]\}] + \alpha[J_k(\underline{x}) - M],$$

$$\beta_2 = \max[M, \max_{i \neq 1}\{R^i(\underline{x}^i) + \alpha E\{J_k[F^i(\underline{x}, w^1)]\}\}] + \alpha[J_k^1(x^1) - M].$$

利用式(6.51b), 式(6.51c), 和前面的方程, 可以看出

$$J_{k+1}(x^1, \underline{x}) \leq \max[J_{k+1}^1(x^1) + J_k(\underline{x}) - M, J_{k+1}(\underline{x}) + J_k^1(x^1) - M]. \quad (6.55)$$

由式(6.51)和式(6.53)可以看出, 对所有 k , x^1 和 $\underline{x}$, $J_k^1(x^1) \leq J_{k+1}^1(x^1)$, 以及 $J_k(\underline{x}) \leq J_{k+1}(\underline{x})$; 于是, 由式(6.55)得, 对于 $k+1$, 式(6.54)成立。归纳证明完成。证毕

最优报酬函数的形式

有了关于最优 PPR 策略存在性的知识, 我们可把多项目问题最优报酬函数与单项目问题的最优报酬函数之间的关系建立起来[参看方程式(6.56), 可得此结果]。这对于证明最优规则的最优性提供了有利条件。首先我们得到 $J(x, M)$ 关于 M 偏导数的表达式。

引理 对于固定的 x , 令 K_M 表示当撤出报酬为 M 时, 在最优策略下的撤出时刻。那么, 对于所有 M , $\partial J(x, M)/\partial M$ 存在, 且有

$$\frac{\partial J(x, M)}{\partial M} = E\{\alpha^{K_M} | x_0 = x\}.$$

证明: x 和 M 固定, 令 π^* 为一个最优策略, K_M 是在 π^* 下的撤出时刻。如果 π^* 用于具有撤出报酬为 $M + \epsilon$ 的问题, 可得:

$E\{\text{撤出以前的报酬}\} + (M + \epsilon)E\{\alpha^{K_M}\} = J(x, M) + \epsilon E\{\alpha^{K_M}\}$ 。当撤出报酬为 $M + \epsilon$ 时, 最优报酬 $J(x, M + \epsilon)$ 不小于上式, 于是

$$J(x, M + \epsilon) \geq J(x, M) + \epsilon E\{\alpha^{K_M}\},$$

类似地可有

$$J(x, M - \epsilon) \geq J(x, M) - \epsilon E\{a^{K_M}\}.$$

又因为 $\epsilon > 0$, 可有两个关系式

$$\frac{J(x, M) - J(x, M - \epsilon)}{\epsilon} \leq E\{a^{K_M}\} \leq \frac{J(x, M + \epsilon) - J(x, M)}{\epsilon},$$

使 $\epsilon \rightarrow 0$ 则得所证结果。

证毕

注意, $J(x, \cdot)$ 关于 M 的凸性(命题 6)意味着, 导数 $\partial J(x, M)/\partial M$ 关于勒贝格测度几乎处处存在[12]。而能够证明, $\partial J(x, M)/\partial M$ 对所有 M 存在, 对此情况最优策略是唯一的。

对于一个给定的 M , 初始状态 x 和最优策略, 令 T_i 是项目 i 为唯一可利用项目时, 项目 i 的撤出时间, 且令 T 是多项目问题的撤出时间。 T_i 和 T 均取值非负或 $+\infty$ 。一个最优 PPR 策略的存在性意味着必有

$$T = \sum_{i=1}^n T_i,$$

另外, $T_i, i = 1, \dots, n$ 是独立的随机变量。因此,

$$E\{a^T\} = E\{a^{\sum_{i=1}^n T_i}\} = \prod_{i=1}^n E\{a^{T_i}\}.$$

利用引理则得

$$\frac{\partial J(x, M)}{\partial M} = \prod_{i=1}^n \frac{\partial J^i(x^i, M)}{\partial M}. \quad (6.56)$$

对于证明指标规则的最优性, 表达式 (6.56) 是充分的。然而有趣的是证明如何利用式 (6.56) 来得到最优报酬函数的表达式。由 M 到某个常数 $C \geq M$ 积分得

$$J(x, M) = J(x, C) - \int_M^C \prod_{i=1}^n \frac{\partial J^i(x^i, m)}{\partial m} dm.$$

对于 $C \geq B/(1-\alpha)$, 由命题 6(c) 知 $J(x, C) = C$, 于是上式变成

$$J(x, M) = C - \int_M^C \prod_{i=1}^n \frac{\partial J^i(x^i, m)}{\partial m} dm, \text{ 对所有 } x, C \geq B/(1-\alpha).$$

这就是以单项目最优报酬函数的形式表示多项目问题的最优报酬函数。

指标规则的最优性

现在, 已作好证明我们重要结果的准备。

命题 8 指标规则式 (6.37) 是一个最优平稳策略。

证明: 固定 $x = (x^1, \dots, x^n)$, 令 i 使得

$$m^i(x^i) = m(x) \triangleq \max_j \{m^j(x^j)\}.$$

如果 $m(x) < M$, 指标规则式 (6.37 a) 在状态 x 的最优性, 从最优 PPR 策略的存在性求得。

如果 $m(x) \geq M$, 我们首先注意到

$$J^i(x^i, M) = R^i(x^i) + \alpha E\{J^i[f^i(x^i, w^i), M]\},$$

然后利用这一等式和式 (6.56) 写成

$$\begin{aligned}
\frac{\partial J(x, M)}{\partial M} &= \frac{\partial J^i(x^i, M)}{\partial M} \cdot \prod_{j \neq i} \frac{\partial J^j(x^j, M)}{\partial M} \\
&= \alpha \frac{\partial}{\partial M} E \left\{ J^i[f^i(x^i, w^i), M] \cdot \prod_{j \neq i} \frac{\partial J^j(x^j, M)}{\partial M} \right\} \\
&= \alpha E \left\{ \frac{\partial}{\partial M} J^i[f^i(x^i, w^i), M] \cdot \prod_{j \neq i} \frac{\partial J^j(x^j, M)}{\partial M} \right\} \\
&= \alpha E \left\{ \frac{\partial}{\partial M} J[x^1, \dots, x^{i-1}, f^i(x^i, w^i), x^{i+1}, \dots, x^n, M] \right\} \\
&= \alpha \frac{\partial}{\partial M} E \{ J[x^1, \dots, x^{i-1}, f^i(x^i, w^i), x^{i+1}, \dots, x^n, M] \},
\end{aligned}$$

最后有

$$\frac{\partial J(x, M)}{\partial M} = \frac{\partial}{\partial M} L^i(x, M, J),$$

式中

$$L^i(x, M, J) = R^i(x^i) + \alpha E \{ J[x^1, \dots, x^{i-1}, f^i(x^i, w^i), x^{i+1}, \dots, x^n, M] \}.$$

(微分与求期望的变换对几乎所有的 M 可证明是正确的, 见[B 13].) 按最优 PPR 策略的存在性, 我们还有

$$J[x, m(x)] = L^i[x, m(x), J].$$

因此, 当 x 固定时, 看作为 M 函数的凸函数 $J(x, M)$ 和 $L^i(x, M, J)$, 对于 $M = m(x)$ 是相等的, 而且对几乎所有 $M \leq m(x)$ 具有相同的导数。从而对所有 $M \leq m(x)$ 有

$$J(x, M) = L^i(x, M, J).$$

这就意味着对所有 x , $m(x) \geq M$, 指标规则式(6.37 b)是最优的。

证毕

蜕化和进化的情况

显然, 指标规划式(6.37)的最优性使问题大为简化, 因为多项目问题的优化已简化为 n 个相互独立的单项目优化问题。然而, 求解这些单项目问题的每一个都可能是复杂的。在某些环境条件下, 情况会简化。

假定对所有 i , x^i 和以正概率发生的 w^i , 我们有

$$m^i(x^i) \leq m^i[f^i(x^i, w^i)], \quad (6.57)$$

或有

$$m^i(x^i) \geq m^i[f^i(x^i, w^i)]. \quad (6.58)$$

在式(6.57)[或式(6.58)]条件下, 进行项目变得更加有(或不)利。我们分别称其为进化或蜕化的情况。

在进化情况, 最优策略的本质是明显的: 或在第一个周期撤出, 或者选择第一个周期具有指标最大的项目, 并在以后的周期里继续从事该项目。

在蜕化情况, 最优策略形式不太明显。但实际上变成较为简单。为了解真相, 注意到式(6.58)意味着如在状态 i 撤出是最优的, 则在各状态 $f^i(x^i, w^i)$ 也是最优的。因此, 对所有 x^i , 使得 $M = m^i(x^i)$ 有: 对所有 w^i ,

$$J^i(x^i, M) = M, \quad J^i[f^i(x^i, w^i), M] = M,$$

由贝尔曼方程

$$J^i(x^i, M) = \max[M, R^i(x^i) + \alpha E\{J^i[f^i(x^i, w^i), M]\}],$$

可得

$$m^i(x^i) = R^i(x^i) + \alpha m^i(x^i),$$

或

$$m^i(x^i) = \frac{R^i(x^i)}{1 - \alpha}. \quad (6.59)$$

在蜕化情况下的最优策略现在由式(6.59)成为显然的:

若 $M > \max_i \frac{R^i(x^i)}{1 - \alpha}$, 撤销; 否则按最大一步报酬 $R^i(x^i)$ 从事项目 i 。

例题

探宝问题。考虑包含 n 个地点的搜索问题。每个地点 i 可能有期望价值为 v_i 的财宝。在地点 i , 一次搜索代价为 c_i , 且以概率 β_i 发现财宝(假定有财宝的话)。令 P_i 是地点 i 存在财宝的概率。我们把 P_i 作为相应于搜索地点 i 的项目状态, 则相应的一步报酬为

$$R^i(P_i) = \beta_i P_i v_i - c_i \quad (6.60)$$

如果在搜索地点 i 时并未发现财宝, 概率 P_i 降为

$$P_i^* = \frac{P_i(1 - \beta_i)}{P_i(1 - \beta_i) + 1 - P_i},$$

利用贝叶斯规则容易验证上式。如果搜索找到了财宝, 概率 P_i 降为零。因为财宝已从该地点拿走。基于此以及 $R^i(P_i)$ 是 P_i 递增函数的事实[参看式(6.60)], 容易证明蜕化条件式(6.58)成立。因此, 对表达式(6.60)为最大的地点进行搜索是一个最优的指标规则。

§ 6.6 最优博弈策略

一个赌徒按如下方式进入赌博: 赌徒可在任何时刻 k 下一个不超过他当前赌本 x_k [定义是他的初始赌本加上到此时刻的赢得, 或减去到此时刻的亏损] 的任意赌注 $u_k \geq 0$ 。他以概率 p 赢回与他的赌注一样多的钱, 以概率 $1 - p$ 输掉他的赌注。于是, 赌徒的赌本按如下方程演变

$$x_{k+1} = x_k + w_k u_k, \quad k = 0, 1, \dots, \quad (6.61)$$

式中 $w_k = 1$ 的概率为 p , $w_k = -1$ 的概率为 $(1 - p)$ 。几种赌博, 如在轮盘赌中赌红黑点都符合这种描述。

赌徒以初始赌本 x_0 进入赌局, 他的目标是把他的赌本增加到 X 的水平。他继续赌博, 直至或达到他的目标, 或者输掉他全部初始赌本, 此时, 他将离开赌博。这个问题就是确定最优策略, 使其达到目标的概率为最大。按所谓博弈策略, 我们意指一种规则, 它规定在时刻 k 当赌徒的赌本为 x_k (x_k 满足 $0 < x_k < X$) 时, 赌注应该是多少。

这个问题可纳入问题 I 的框架, 此处我们用求极大代替求极小。为方便起见, 我们假定赌本是正则化的, 于是 $X = 1$ 。状态空间就是集合 $[0, 1] \cup \{s\}$; 其中 s 是终态, 系统肯定从状态 0 和 1, 分别以相应的报酬 0 和 1 移动到此状态。当 $x_k \neq 0, x_k \neq 1$ 时, 系统按方程(6.61)演变。控制约束集规定为

$$0 \leq u_k \leq x_k, \quad 0 \leq u_k \leq 1 - x_k.$$

当 $x_k \neq 0$, $x_k \neq 1$ 时, 每阶段报酬为零。在这些环境下, 到达目标的概率等于总的期望报酬。假设 N 成立, 因为我们的问题等价于每阶段代价非正, 使总的期望代价为最小的问题。

定义 DP 算法的映射 T 取如下形式

$$T(J)(x) = \max_{\substack{0 \leq u \leq x \\ 0 \leq v \leq 1-x}} [pJ(x+u) + (1-p)J(x-u)], \quad x \in (0, 1),$$

$$T(J)(0) = 0, \quad T(J)(1) = 1. \quad (6.62)$$

对任意函数 $J: [0, 1] \rightarrow [0, +\infty]$ 。实际上, 对于这个问题, 可集中注意 J 在区间 $[0, 1]$ 取值, $J(0) = 0$, $J(1) = 1$ 。

现在考虑

$$0 < p < \frac{1}{2}$$

情况, 即赌博对赌徒是不公平的。 $\frac{1}{2} \leq p < 1$ 情况的离散描述形式在习题 15 中考虑。当 $0 < p < \frac{1}{2}$

时, 在直觉上显然是, 如果赌徒遵从一种非常保守的策略, 每次下很小的赌注, 他肯定全部输掉他的赌本。例如, 若赌徒采用每次赌 $\frac{1}{n}$ 的策略, 可以证明 (见习题 15 或 [A 9, p. 182]),

由一个初始赌本 i/n 开始, $0 < i < n$, 达到 1 单位赌本的概率由下式给出

$$\left[\left(\frac{1-p}{p} \right)^i - 1 \right] \left[\left(\frac{1-p}{p} \right)^n - 1 \right]^{-1}.$$

如果 $0 < p < \frac{1}{2}$, n 趋于无限大, i/n 趋于一个常量, 则上式给出的概率趋于零。由此看出,

一直下小赌注是最坏的策略。

由前面的讨论知, 促使人们考虑下大赌注的策略。特别是所谓大胆策略, 按此策略赌徒在每个时刻 k 下了他全部的赌本 x_k , 或者足以达到他的目标的赌注, 无论哪一种都是最起码的。换句话说, 大胆策略是一个平稳策略 $\{\mu^*, \mu^*, \dots\}$, 且 μ^* 由下式给出

$$\mu^*(x) = \begin{cases} x, & \text{若 } 0 < x \leq \frac{1}{2}, \\ 1-x, & \text{若 } \frac{1}{2} \leq x < 1. \end{cases}$$

我们将证明大胆策略实际上是一种最优策略。为达到这一点, 只要对每个初始赌本 $x \in [0, 1]$, 证明相应于大胆策略 $\{\mu^*, \mu^*, \dots\}$ 的报酬函数 $J_{\mu^*}(x)$ 的值满足如下充分条件 (参看 § 5.4 命题 10) 就足够了

$$J(J_{\mu^*}) = J_{\mu^*},$$

或等价地

$$J_{\mu^*}(0) = 0, \quad J_{\mu^*}(1) = 1$$

$$J_{\mu^*}(x) \geq pJ_{\mu^*}(x+u) + (1-p)J_{\mu^*}(x-u),$$

对所有 $x \in (0, 1)$, $u \in [0, x] \cap [0, 1-x]$. (6.63)

利用大胆策略的定义, 以及如下事实

$$J_{\mu^*} = T_{\mu^*}(J_{\mu^*}),$$

我们得到函数 J_{μ^*} 必须满足

$$J_{\mu^*}(0) = 0, \quad J_{\mu^*}(1) = 1, \quad (6.64)$$

$$J_{\mu^*}(x) = \begin{cases} pJ_{\mu^*}(2x), & \text{若 } 0 < x \leq \frac{1}{2}, \\ p + (1-p)J_{\mu^*}(2x-1), & \text{若 } \frac{1}{2} \leq x < 1. \end{cases} \quad (6.65)$$

我们证明下面的引理, 以表明 J_{μ^*} 是由这些关系式唯一确定的。

引理 对每个 p , $0 < p \leq \frac{1}{2}$, 在 $[0, 1]$ 区间, 仅存在唯一有界函数, 满足式 (6.64) 和式 (6.65), 即函数 J_{μ^*} 。而且, J_{μ^*} 在 $[0, 1]$ 间是连续且严格的递增函数。

证明: 假定存在两个有界函数 $J_1: [0, 1] \rightarrow R$, 和 $J_2: [0, 1] \rightarrow R$, 使得 $J_i(0) = 0$, $J_i(1) = 1$, $i = 1, 2$; 以及

$$J_i(x) = \begin{cases} pJ_i(2x), & \text{若 } 0 < x \leq \frac{1}{2}, \\ p + (1-p)J_i(2x-1), & \text{若 } \frac{1}{2} \leq x < 1, \end{cases} \quad i = 1, 2,$$

则有

$$J_1(2x) - J_2(2x) = \frac{J_1(x) - J_2(x)}{p}, \quad \text{若 } 0 \leq x \leq \frac{1}{2}, \quad (6.66)$$

$$J_1(2x-1) - J_2(2x-1) = \frac{J_1(x) - J_2(x)}{1-p}, \quad \text{若 } \frac{1}{2} \leq x \leq 1, \quad (6.67)$$

令 z 是任意实数, 且 $0 \leq z \leq 1$, 定义

$$\begin{aligned} z_1 &= \begin{cases} 2z, & \text{若 } 0 \leq z \leq \frac{1}{2}, \\ 2z-1, & \text{若 } \frac{1}{2} < z \leq 1, \end{cases} \\ &\vdots \\ z_k &= \begin{cases} 2z_{k-1}, & \text{若 } 0 \leq z_{k-1} \leq \frac{1}{2}, \\ 2z_{k-1}-1, & \text{若 } \frac{1}{2} < z_{k-1} \leq 1, \end{cases} \end{aligned}$$

对 $k = 1, 2, \dots$ 。那么, 由式 (6.66) 和式 (6.67) 可得 (利用 $p \leq \frac{1}{2}$)

$$|J_1(z_k) - J_2(z_k)| \geq \frac{|J_1(z) - J_2(z)|}{(1-p)^k}, \quad k = 1, 2, \dots.$$

因为 $J_1(z_k) - J_2(z_k)$ 是有界的, 从而有 $J_1(z) - J_2(z) = 0$; 对其它情况, 不等式右边将趋于 $+\infty$ 。因为 $z \in [0, 1]$ 是任意的, 我们得 $J_1 = J_2$ 。因此 J_{μ^*} 是满足式 (6.64) 和式 (6.65) 在 $[0, 1]$ 区间上的唯一有界函数。

为证明 J_{μ^*} 是严格递增和连续的, 考虑映射 T_{μ^*} , 它对函数 $J: [0, 1] \rightarrow [0, 1]$ 进行运算, 而且定义为

$$J_{\mu^*}(J)(x) = \begin{cases} pJ(2x) + (1-p)J(0), & \text{若 } 0 < x \leq \frac{1}{2}, \\ pJ(1) + (1-p)J(2x-1), & \text{若 } \frac{1}{2} \leq x < 1, \end{cases}$$

$$T_{\mu^*}(J)(0) = 0, T_{\mu^*}(J)(1) = 1. \quad (6.68)$$

考虑函数 $J_0, T_{\mu^*}(J_0), \dots, T_{\mu^*}^k(J_0), \dots$, 其中 J_0 是零函数(对所有 $x \in [0, 1]$, $J_0(x) = 0$)。

我们有

$$J_{\mu^*}(x) = \lim_{k \rightarrow \infty} T_{\mu^*}^k(J_0)(x), x \in [0, 1]. \quad (6.69)$$

而且, 函数 $T_{\mu^*}^k(J_0)$ 能被证明在 $[0, 1]$ 区间上是单调非递减的; 因而由式(6.69), J_{μ^*} 也是单调非递减的。

现在考虑对 $n = 0, 1, \dots$ 的集合

$$S_n = \{x \in [0, 1] | x = k 2^{-n}, k = \text{非负整数}\},$$

容易验证

$$T_{\mu^*}^m(J_0)(x) = T_{\mu^*}^n(J_0)(x), x \in S_{n-1}, m \geq n \geq 1.$$

根据上式和式(6.69),

$$J_{\mu^*}(x) = T_{\mu^*}^n(J_0)(x), x \in S_{n-1}, n \geq 1. \quad (6.70)$$

利用归纳法及式(6.68)和式(6.70)可以验证的事实是: 对于任意非负整数 k, n , 且 $0 \leq k 2^{-n} < (k+1) 2^{-n} \leq 1$, 有

$$p^n \leq J_{\mu^*}[(k+1) 2^{-n}] - J_{\mu^*}(k 2^{-n}) \leq (1-p)^n. \quad (6.71)$$

因为 $[0, 1]$ 中的任意实数, 可以用形如 $k 2^{-n}$ 的数由上或由下任意逼近, 而且 J_{μ^*} 已被证明是单调非递减的, 由式(6.71)立即得出 J_{μ^*} 是连续且严格递增的。证毕

现在我们有条件证明如下命题。

命题 9 大胆策略是一个最优的平稳博弈策略。

证明: 我们将证明充分条件

$$J_{\mu^*}(x) \geq p J_{\mu^*}(x+u) + (1-p) J_{\mu^*}(x-u), x \in [0, 1], u \in [0, x] \cap [0, 1-x]. \quad (6.72)$$

根据上述引理建立的 J_{μ^*} 的连续性, 只要对所有 $x \in [0, 1]$ 以及 $u \in [0, x] \cap [0, 1-x]$ 建立式(6.72)就足够了, x 和 u 属于并集 $\bigcup_{n=0}^{\infty} S_n$, S_n 定义为

$$S_n = \{x \in [0, 1] | x = k 2^{-n}, k = \text{非负整数}\}.$$

我们利用归纳法。利用 $J_{\mu^*}(0) = 0$, $J_{\mu^*}(\frac{1}{2}) = p$, 以及 $J_{\mu^*}(1) = 1$ 的事实, 我们可证明对 S_0

和 S_1 中的所有 x 和 u , 式(6.72)成立。假定对所有 $x, u \in S_n$ 和 $n \geq 1$ 式(6.72)成立, 我们将证明对所有 $x, u \in S_{n+1}$, 式(6.72)也成立。

对于任意 $x, u \in S_{n+1}$, $u \in [0, x] \cap [0, 1-x]$, 存在四种可能性:

$$1. x+u \leq \frac{1}{2},$$

$$2. x-u \geq \frac{1}{2},$$

$$3. x-u \leq x \leq \frac{1}{2} \leq x+u,$$

$$4. x-u \leq \frac{1}{2} \leq x \leq x+u.$$

我们将对上述每一种情况证明式(6.72)。

情况 1. 如果 $x, u \in S_{n+1}$, 则 $2x \in S_n$, 和 $2u \in S_n$, 那么根据归纳假设

$$J_{\mu^*}(2x) - pJ_{\mu^*}(2x+2u) - (1-p)J_{\mu^*}(2x-2u) \geq 0. \quad (6.73)$$

如果 $x+u \leq \frac{1}{2}$, 则由式(6.65),

$$\begin{aligned} J_{\mu^*}(x) - pJ_{\mu^*}(x+u) - (1-p)J_{\mu^*}(x-u) \\ = p[J_{\mu^*}(2x) - pJ_{\mu^*}(2x+2u) - (1-p)J_{\mu^*}(2x-2u)], \end{aligned}$$

再利用式(6.73), 则已证明了情况 1 所要求的关系式(6.72)。

情况 2. 如果 $x, u \in S_{n+1}$, 则 $(2x-1) \in S_n$, $2u \in S_n$, 根据归纳假设

$$J_{\mu^*}(2x-1) - pJ_{\mu^*}(2x+2u-1) - (1-p)J_{\mu^*}(2x-2u-1) \geq 0.$$

如果 $x-u \geq \frac{1}{2}$, 则由式(6.65),

$$\begin{aligned} J_{\mu^*}(x) - pJ_{\mu^*}(x+u) - (1-p)J_{\mu^*}(x-u) \\ = p + (1-p)J_{\mu^*}(2x-1) - p[p + (1-p)J_{\mu^*}(2x+2u-1)] \\ - (1-p)[p + (1-p)J_{\mu^*}(2x-2u-1)] \\ = (1-p)[J_{\mu^*}(2x-1) - pJ_{\mu^*}(2x+2u-1) \\ - (1-p)J_{\mu^*}(2x-2u-1)] \geq 0, \end{aligned}$$

由上式可得式(6.72)。

情况 3. 利用式(6.65)有

$$\begin{aligned} J_{\mu^*}(x) - pJ_{\mu^*}(x+u) - (1-p)J_{\mu^*}(x-u) \\ = pJ_{\mu^*}(2x) - p[p + (1-p)J_{\mu^*}(2x+2u-1)] - p(1-p)J_{\mu^*}(2x-2u) \\ = p[J_{\mu^*}(2x) - p - (1-p)J_{\mu^*}(2x+2u-1) - (1-p)J_{\mu^*}(2x-2u)]. \end{aligned}$$

现在必有 $x \geq \frac{1}{4}$, 否则 $u < \frac{1}{4}$, $x+u < \frac{1}{2}$ 。因此 $2x \geq \frac{1}{2}$, 而等式序列可继续如下

$$\begin{aligned} J_{\mu^*}(x) - pJ_{\mu^*}(x+u) - (1-p)J_{\mu^*}(x-u) \\ = p[p + (1-p)J_{\mu^*}(4x-1) - p - (1-p)J_{\mu^*}(2x+2u-1) \\ - (1-p)J_{\mu^*}(2x-2u)] \\ = p(1-p)[J_{\mu^*}(4x-1) - J_{\mu^*}(2x+2u-1) - J_{\mu^*}(2x-2u)] \\ = (1-p)\left[J_{\mu^*}\left(2x - \frac{1}{2}\right) - pJ_{\mu^*}(2x+2u-1) - pJ_{\mu^*}(2x-2u)\right]. \end{aligned}$$

因为 $p \leq (1-p)$, 最后一个表达式大于或等于下列二式

$$(1-p)\left[J_{\mu^*}\left(2x - \frac{1}{2}\right) - pJ_{\mu^*}(2x+2u-1) - (1-p)J_{\mu^*}(2x-2u)\right],$$

和

$$(1-p)\left[J_{\mu^*}\left(2x-\frac{1}{2}\right)-(1-p)J_{\mu^*}(2x+2u-1)-pJ_{\mu^*}(2x-2u)\right].$$

现在, 对 $x, u \in S_{n+1}$, 及 $n \geq 1$, 若 $\left(2u - \frac{1}{2}\right) \in [0, 1]$, 则有 $\left(2x - \frac{1}{2}\right) \in S_n$, $\left(2u - \frac{1}{2}\right) \in S_n$,

若 $\left(\frac{1}{2} - 2u\right) \in [0, 1]$ 则有 $\left(\frac{1}{2} - 2u\right) \in S_n$. 根据归纳假设, 上述第一个或第二个表达式是非

负的, 它取决于 $2x + 2u - 1 \geq 2x - \frac{1}{2}$ 或 $2x - 2u \geq 2x - \frac{1}{2}$ 是否成立 (即 $u \geq \frac{1}{4}$ 或 $u \leq \frac{1}{4}$).

因此证明了式(6.72)。

情况 4. 这个证明与情况 3 的证明相类似. 利用式(6.65), 我们有

$$\begin{aligned} & J_{\mu^*}(x) - pJ_{\mu^*}(x+u) - (1-p)J_{\mu^*}(x-u) \\ &= p + (1-p)J_{\mu^*}(2x-1) - p[p + (1-p)J_{\mu^*}(2x+2u-1)] \\ & \quad - (1-p)pJ_{\mu^*}(2x-2u) \\ &= p(1-p) + (1-p)[J_{\mu^*}(2x-1) - pJ_{\mu^*}(2x+2u-1) - pJ_{\mu^*}(2x-2u)]. \end{aligned}$$

必定有 $x \leq \frac{3}{4}$, 否则 $u < \frac{1}{4}$, $x-u > \frac{1}{2}$. 因此, $0 \leq 2x-1 \leq \frac{1}{2} \leq 2x - \frac{1}{2} \leq 1$, 利用式

(6.65)有

$$(1-p)J_{\mu^*}(2x-1) = (1-p)pJ_{\mu^*}(4x-2) = p\left[J_{\mu^*}\left(2x-\frac{1}{2}\right)-p\right].$$

利用上述关系式得

$$\begin{aligned} & J_{\mu^*}(x) - pJ_{\mu^*}(x+u) - (1-p)J_{\mu^*}(x-u) \\ &= p(1-p) + p\left[J_{\mu^*}\left(2x-\frac{1}{2}\right)-p\right] - p(1-p)J_{\mu^*}(2x+2u-1) \\ & \quad - p(1-p)J_{\mu^*}(2x-2u) \\ &= p\left[(1-2p) + J_{\mu^*}\left(2x-\frac{1}{2}\right) - (1-p)J_{\mu^*}(2x+2u-1) \right. \\ & \quad \left. - (1-p)J_{\mu^*}(2x-2u)\right]. \end{aligned}$$

这些关系式等于如下二式

$$\begin{aligned} & p\left[(1-2p)[1-J_{\mu^*}(2x+2u-1)] + J_{\mu^*}\left(2x-\frac{1}{2}\right) \right. \\ & \quad \left. - pJ_{\mu^*}(2x+2u-1) - (1-p)J_{\mu^*}(2x-2u)\right], \end{aligned}$$

和

$$\begin{aligned} & p\left[(1-2p)[1-J_{\mu^*}(2x-2u)] + J_{\mu^*}\left(2x-\frac{1}{2}\right) \right. \\ & \quad \left. - (1-p)J_{\mu^*}(2x+2u-1) - pJ_{\mu^*}(2x-2u)\right]. \end{aligned}$$

因为 $0 \leq J_{\mu^*}(2x+2u-1) \leq 1$ 和 $0 \leq J_{\mu^*}(2x-2u) \leq 1$, 这些表达式大于或等于如下二式

$$p\left[J_{\mu^*}\left(2x - \frac{1}{2}\right) - pJ_{\mu^*}(2x + 2u - 1) - (1-p)J_{\mu^*}(2x - 2u)\right],$$

和

$$p\left[J_{\mu^*}\left(2x - \frac{1}{2}\right) - (1-p)J_{\mu^*}(2x + 2u - 1) - pJ_{\mu^*}(2x - 2u)\right].$$

得出类似情况 3 的结果。

证毕

注意大胆策略并非唯一的最优平稳博弈策略。为表征所有平稳策略, 参看[D 9, p.90]。大胆策略为最优策略的几种其它的博弈情况在参考文献[D 9, 第五和第六章]中已有描述。

§ 6.7 连续时间马尔科夫链及其一致化:

在排队系统中的应用^[原注]

截至目前我们所研究的问题中, 每阶段代价并不依赖于由一个状态转移到下一个状态所需的时间。这样的问题具有自然的离散时间表示。另一方面, 还存在这样的情况: 控制是在离散时间施加的, 但代价定义为时间的积分。而且两次转移之间的时间是变化的; 可能是随机的, 也可能依赖于当前的状态。例如, 在排队系统中, 状态转移相应于顾客的到来或离去, 而相应的转移时间是随机的。在本节我们将证明, 对于重要的一类连续时间优化模型, 与转移时间有关的问题可按如下方式得出, 即这些模型可以在至今已讨论的离散时间框架内进行分析。

我们将限于讨论有限或可数状态的马尔科夫链模型所描述的系统。此处状态转移和控制选择都发生在离散时间, 但从一次转移到下一次的时间是随机的。特别的, 我们假定:

1. 若系统处在状态 i , 加上控制 u , 下一个状态为 j 的概率为 $p_{ij}(u)$;
2. 转移到状态 i 与转移到下一个状态之间的时间间隔 τ 以参数 $\nu_i(u)$ 指数分布, τ 的概率密度函数是

$$p(\tau) = \nu_i(u) e^{-\nu_i(u)\tau}, \quad \tau \geq 0.$$

而且, τ 与以前转移时间, 状态和控制无关。参数 $\nu_i(u)$ 在如下意义下是一致有界的, 即对某个 ν 有

$$\nu_i(u) \leq \nu, \quad \text{对所有 } i, u.$$

在任意时刻 t 的状态和控制分别记为 $x(t)$ 和 $u(t)$, 而且在两次转移之间保持为常量。代价是由下式给出

$$E\left\{\int_0^\infty e^{-\beta t} g[x(t), u(t)] dt\right\}, \quad (6.74)$$

其中 g 是一个给定的函数, 而 $\beta > 0$ 是给定的一个标量折扣参数。参数 $\nu_i(u)$ 称为与状态 i 和控制 u 相应的转移率。可以验证, 相应的平均转移时间是

$$E\{\tau\} = \int_0^\infty \tau \nu_i(u) e^{-\nu_i(u)\tau} d\tau = \frac{1}{\nu_i(u)},$$

所以 $\nu_i(u)$ 可以解释为单位时间的平均转移次数。

首先我们考虑对所有状态和控制转移率相同的情况, 即

原注: 本节要求熟悉泊松过程和连续时间马尔科夫链的基本概念 (如见[R8])。

$$v_i(u) = v, \quad \text{对所有 } i, u.$$

然后我们证明, 如何通过一种所谓一致化的过程可把依赖于状态和控制的转移率模型简化为这一情况。

假定对所有 i 和 u , $v_i(u) = v$, 且记

t_k : 第 k 次转移发生的时间(为方便起见, $t_0 = 0$);

$\tau_k = t_k - t_{k-1}$: 第 k 个转移时间间隔;

$x_k = x(t_k)$: 第 k 次转移后的状态[对于 $t_k \leq t < t_{k+1}$, $x(t) = x_k$];

$u_k = u(t_k)$: 第 k 次转移的控制[对 $t_k \leq t < t_{k+1}$, $u(t) = u_k$].

稍为一想, 读者应确信, 这个问题本质上与转移时间固定的情况是一样的。直观的原因是控制不通过转移时间间隔影响代价。更具体地说, 相应于序列 $\{(x_k, u_k) | k=0, 1, \dots\}$ 的代价式(6.74)表示为

$$\begin{aligned} & \sum_{k=0}^{\infty} E \left\{ \int_{t_k}^{t_{k+1}} e^{-\beta t} g[x(t), u(t)] dt \right\} \\ &= \sum_{k=0}^{\infty} E \left\{ \int_{t_k}^{t_{k+1}} e^{-\beta t} dt \right\} E \{ g(x_k, u_k) \}. \end{aligned} \quad (6.75)$$

如果 $\beta > 0$, 则有(利用转移时间间隔的独立性)

$$E \left\{ \int_{t_k}^{t_{k+1}} e^{-\beta t} dt \right\} = \frac{E \{ e^{-\beta t_k} \} (1 - E \{ e^{-\beta \tau_{k+1}} \})}{\beta} = \frac{\alpha^k (1 - \alpha)}{\beta}, \quad (6.76)$$

式中

$$\alpha = E \{ e^{-\beta \tau} \} = \int_0^{\infty} e^{-\beta \tau} v e^{-v \tau} d\tau = \frac{v}{\beta + v}.$$

如果 $\beta = 0$, 则

$$E \left\{ \int_{t_k}^{t_{k+1}} dt \right\} = E \{ \tau_{k+1} \} = \frac{1}{v}.$$

由式(6.75)和式(6.76)以及 $(1 - \alpha)/\beta = 1/(\beta + v)$ 的事实, 从而知该问题的代价可表示为

$$\frac{1}{\beta + v} \sum_{k=0}^{\infty} \alpha^k E \{ g(x_k, u_k) \}, \quad \text{若 } \beta > 0,$$

和

$$\frac{1}{v} \sum_{k=0}^{\infty} E \{ g(x_k, u_k) \}, \quad \text{若 } \beta = 0.$$

可以看出, 事实上我们面临一个总期望代价求极小的普通离散时间问题。如果 $\beta > 0$, 则 $\alpha < 1$, 并为折扣问题。若 $\beta = 0$, 则为无折扣问题。转移时间随机性的影响只是简单地适当加大了每阶段代价。

总结起来, 一个连续时间马尔科夫链问题, 具有代价

$$E \left\{ \int_0^{\infty} e^{-\beta t} g[x(t), u(t)] dt \right\},$$

和独立于状态和控制的转移率 v , 等价于一个离散时间马尔科夫链问题具有折扣因子。

$$\alpha = \frac{v}{\beta + v}, \quad (6.77)$$

且每阶段代价给定为

$$\tilde{g}(i, u) = -\frac{1}{\beta + \nu} g(i, u). \quad (6.78)$$

特别地, 贝尔曼方程取如下形式

$$J(i) = \frac{1}{\beta + \nu} \min_{u \in U(i)} [g(i, u) + \nu \sum_j p_{ij}(u) J_j]. \quad (6.79)$$

例题 1

一个特制品制造商以批量方式处理订货。我们假定订货是按照泊松过程到达, 单位时间的到达率是 λ ; 对每个订货, 不供应订货时每单位时间有一个正代价 c 。处理订货的安排代价为 K 。每当新的订货到达, 制造商必须决定处理当前这批订货, 还是等到下次订货。

在此例中, 两次转移之间的时间为指数分布, 具有独立于状态和控制的参数 λ , 如图 6.4 所示。假定有一个正的折扣参数 β , 则有效的折扣因子是 $\alpha = \lambda/(\beta + \lambda)$ [参见式 (6.77)], 当 i 个订货未供应时, 转移的平均代价为 $(ci)/(\beta + \lambda)$ [参见式 (6.78)], 而处理订货的转移代价是 K 。(注意, 假定一旦处理订货的决定作出之后, 立即招致安排代价 K ; 于是 K 在下次转移之前的时间间隔内, 不打折扣。)我们面临一个带折扣问题, 每阶段代价为正, 但无界。假设 P 成立(见 § 5.4), 且贝尔曼方程取如下形式:

$$J(i) = \min \left[K + \alpha J(1), -\frac{ci}{\beta + \lambda} + 2J(i+1) \right], \quad i = 1, 2, \dots$$

[注意, 最优代价 $J(i)$ 不可能超过订货到达时刻供应每个订货策略的代价 $K/(1 - \alpha)$ 。因此, 由第五章习题 15, 我们看出最优代价函数 J 是贝尔曼方程的唯一有界解。]由基本原理推理, 我们看出 $J(i)$ 是 i 的一个单调非递减函数。所以由贝尔曼方程知, 存在一个阈值 i^* , 使得当且仅当数目 i 等于或超过 i^* 时, 处理订货才为最优。当不存在折扣时 ($\beta = 0$), 这一结果还有一种形式, 见第七章习题 11。





图 6.4 例题 1 连续时间马尔科夫链转移图。与第一控制(不供应订货)相应的转移用实线表示; 而与第二控制(供应订货)相应的转移用虚线表示

非一致转移率

现在我们断言, 对转移率 $\nu_i(u)$ 依赖于状态和控制的更一般情况, 可利用从一个状态到其本身的虚拟转移的技巧, 转化为前面一致转移率的情况。粗略地说, 只要明白有时一个转移后状态也许保持不变, 按平均而言慢转移可以加快。为理解如何会成立, 令 ν 为一个新的转移率, 且对所有 i 和 u 有 $\nu_i(u) \leq \nu$ [见式 (6.75)], 定义新的转移概率

$$\tilde{p}_{ij}(u) = \begin{cases} \frac{\nu_i(u)}{\nu} p_{ij}(u), & \text{若 } i \neq j, \\ 1 - \frac{\nu_i(u)}{\nu}, & \text{若 } i = j. \end{cases}$$

我们把这一过程称为原问题的一致化形式(见图 6.5)。现在我们断言, 以转移率 $\nu_i(u)$ 离开状态 i 的原过程, 统计上等于以快得多的转移率 ν 离开状态 i , 但又以概率 $(1 - \nu_i(u))/\nu$ 返回到状态 i 的新过程。等价地说, 实际转移(即转移到不同的状态)具有概率 $\nu_i(u)/\nu < 1$ 。按照统计上的等价性, 我们指的是, 对任意给定的策略 π , 初始状态 x_0 , 时间 t 和状态 i ,



连续时间链的转移率和概率

一致化形式的转移概率

图 6.5 通过利用虚拟的自转移, 把一个连续时间马尔科夫链转化为它的一致化形式。一致化形式具有一个一致转移率 ν , 它是原问题所有转移率 $\nu_i(u)$ 的一个上界, 且转移概率为 $\tilde{p}_{ij}(u) = (\nu_i(u)/\nu)p_{ij}(u)$, $i \neq j$; 且 $\tilde{p}_{ii}(u) = 1 - \nu_i(u)/\nu$ 。

对于原过程及其一致化形式, 概率 $P\{x(t) = i | \pi, x_0\}$ 是相同的。在习题 22 中, 对有限状态的情况, 我们给出了有关这一事实的证明(还可参看 [L 4]、[S 14] 和 [R 8] 的进一步讨论)。下面我们将用排队理论的例子来说明这一思想。

总结起来, 我们能够把一个具有转移率 $\nu_i(u)$, 转移概率 $p_{ij}(u)$, 以及代价函数

$$E\left\{\int_0^\infty e^{-\beta t} g[x(t), u(t)] dt\right\}$$

的连续时间马尔科夫链问题, 转化为一个离散时间马尔科夫链问题, 具有折扣因子

$$\alpha = \frac{\nu}{\beta + \nu}, \quad (6.80)$$

其中 ν 是一个一致转移率, 适当选择使得

$$\nu_i(u) \leq \nu, \text{ 对所有 } i, u. \quad (6.81)$$

转移概率为

$$\tilde{p}_{ij}(u) = \begin{cases} \frac{\nu_i(u)}{\nu} p_{ij}(u), & \text{若 } i \neq j, \\ 1 - \frac{\nu_i(u)}{\nu}, & \text{若 } i = j. \end{cases} \quad (6.82)$$

而每阶段代价是:

$$\tilde{g}(i, u) = \frac{1}{\beta + v} g(i, u), \text{ 对所有 } i, u. \quad (6.83)$$

特别地, 贝尔曼方程取如下形式

$$J(i) = \frac{1}{\beta + v} \min_{u \in U(i)} [g(i, u) + [v - v_i(u)]J(i) + v_i(u) \sum_j p_{ij}(u)J(j)]. \quad (6.84)$$

排队问题的应用

例题 2

具有受控服务率的 $M/M/1$ 排队问题。考虑一个单服务的排队系统, 其中顾客到达是按到达率 λ 的泊松分布。一个顾客的服务时间是按指数分布, 具有参数 μ (称为服务率)。顾客的服务时间相互是独立的, 而且独立于顾客相互到达的时间。服务率 μ 可以在一个区间 $[0, \bar{\mu}]$ 的闭子集 M 中选择, 并可在顾客离开这个系统的时刻发生变化。对服务率 μ , 存在单位时间代价 $q(\mu)$, 当系统中有 i 个顾客时 (在队列中等待或正在被服务), 有单位时间的等待代价 $c(i)$ 。想法是: 选择一个更快的服务率 (预计耗费更多服务代价), 应该能减小顾客的等待代价。粗略地说, 这个问题就是选择一个服务率, 使得服务代价与顾客等待代价最优地折衷。

我们假设如下:

1. 对于某个 $\mu \in M$, 有 $\mu > \lambda$ 。(也就是说, 提供的服务率快到足以跟上到达率, 据此保持队列长度有界。)

2. 等待代价函数 c 是非负的, 单调非递减的, 而且按如下意义是“凸的”:

$$c(i+2) - c(i+1) \geq c(i+1) - c(i), \quad i = 0, 1, \dots$$

3. 服务率代价函数 q 非负, 且在 $[0, \bar{\mu}]$ 区间连续, 而且 $q(0) = 0$ 。




图 6.6 对于例题 2, 当服务率为 μ 时的连续时间马尔科夫链及一致化形式。一致化形式的转移率是 $v = \lambda + \bar{\mu}$

这个问题适合本节所讨论问题的框架。状态即为系统中的顾客数,控制就是顾客离去后选择一个服务率。马尔科夫链,以及转移概率和转移率示于图 6.6,其中也表示了相应的一致化形式,选择

$$\nu = \lambda + \bar{\mu}.$$

有效的折扣因子为

$$\alpha = \frac{\nu}{\beta + \nu},$$

每阶段代价为

$$\frac{1}{\beta + \nu} [c(i) + q(\mu)].$$

贝尔曼方程取如下形式[见式(6.84)]

$$\begin{aligned} J(0) &= \frac{1}{\beta + \nu} [c(0) + (\nu - \lambda)J(0) + \lambda J(1)], \\ J(i) &= \frac{1}{\beta + \nu} \min_{\mu \in M} [c(i) + q(\mu) + \mu J(i-1) \\ &\quad + (\nu - \lambda - \mu)J(i) + \lambda J(i+1)], \quad i = 1, 2, \dots. \end{aligned} \quad (6.85)$$

最优策略就是在状态 i 时,采用使右边表达式为极小的服务率。于是,在状态 i 时采用如下服务率是最优的

$$\mu^*(i) = \arg \min_{\mu \in M} \{q(\mu) - \mu \Delta(i)\}, \quad (6.86)$$

其中 $\Delta(i)$ 就是最优代价微分:

$$\Delta(i) = J(i) - J(i-1), \quad i = 1, 2, \dots.$$

[当不只一个服务率 μ 使式(6.86)达到极小时,为方便起见,我们选择最小的。]我们马上将证明 $\Delta(i)$ 是单调非减的。那么由式(6.86)得出(参看图 6.7),最优服务率 $\mu^*(i)$ 是单调非减的,于是当队列长度增大时,用较快的服务率是最优的。

为证明 $\Delta(i)$ 是单调非减的,我们利用逐次逼近法产生函数的序列,起始函数是

$$J_0(i) = 0, \quad i = 0, 1, \dots,$$

而且对 $k = 0, 1, \dots$ [见式(6.85)],

$$\begin{aligned} J_{k+1}(0) &= \frac{1}{\beta + \nu} [c(0) + (\nu - \lambda)J_k(0) + \lambda J_k(1)], \\ J_{k+1}(i) &= \frac{1}{\beta + \nu} \min_{\mu \in M} [c(i) + q(\mu) + \mu J_k(i-1) \\ &\quad + (\nu - \lambda - \mu)J_k(i) + \lambda J_k(i+1)], \quad i = 1, 2, \dots. \end{aligned} \quad (6.87)$$

对于 $k = 0, 1, \dots$, 以及 $i = 1, 2, \dots$, 令

$$\Delta_k(i) = J_k(i) - J_k(i-1).$$

为使这一记法完善,定义 $J_k(-1) = J_k(0)$, 且 $\Delta_k(0) = 0$ 。由 § 5.4 的理论(见命题 14, 且参照第五章习题 10), 当 $k \rightarrow \infty$ 时有 $J_k(i) \rightarrow J(i)$ 。从而有

$$\lim_{k \rightarrow \infty} \Delta_k(i) = \Delta(i), \quad i = 1, 2, \dots.$$

因此,对于每个 k 只要证明 $\Delta_k(i)$ 是单调非减的就足够了。为此我们利用归纳法。对于 $k = 0$, 这一论断无疑是正确的。假定 $\Delta_k(i)$ 是单调非减的,我们证明对于 $\Delta_{k+1}(i)$ 这一结论同

样是正确的。令

$$\mu^h(0) = 0,$$

$$\mu^h(i) = \arg \min_{\mu \in M} \{g(\mu) - \mu \Delta_h(i)\}, i = 1, 2, \dots.$$

由式(6.87), 对所有 $i = 0, 1, \dots$, 有

$$\begin{aligned} \Delta_{h+1}(i+1) &= J_{h+1}(i+1) - J_{h+1}(i) \\ &\geq \frac{1}{\beta + \nu} [c(i+1) + q[\mu^h(i+1)] + \mu^h(i+1)J_h(i) \\ &\quad + [\nu - \lambda - \mu^h(i+1)]J_h(i+1) \\ &\quad + \lambda J_h(i+2) - c(i) - q[\mu^h(i+1)] - \mu^h(i+1)J_h(i-1) \\ &\quad - [\nu - \lambda - \mu^h(i+1)]J_h(i) - \lambda J_h(i+1)] \\ &= \frac{1}{\beta + \nu} [c(i+1) - c(i) + \lambda \Delta_h(i+2) + (\nu - \lambda) \Delta_h(i+1) \\ &\quad - \mu^h(i+1)[\Delta_h(i+1) - \Delta_h(i)]]. \end{aligned} \quad (6.88)$$

类似地, 对于 $i = 1, 2, \dots$, 得

$$\begin{aligned} \Delta_{h+1}(i) &\leq \frac{1}{\beta + \nu} [c(i) - c(i-1) + \lambda \Delta_h(i+1) + (\nu - \lambda) \Delta_h(i) \\ &\quad - \mu^h(i-1)[\Delta_h(i) - \Delta_h(i-1)]]. \end{aligned}$$

前两个不等式相减, 对于 $i = 1, 2, \dots$, 得

$$\begin{aligned} &(\beta + \nu)[\Delta_{h+1}(i+1) - \Delta_{h+1}(i)] \\ &\geq [c(i+1) - c(i)] - [c(i) - c(i-1)] + \lambda[\Delta_h(i+2) - \Delta_h(i+1)] \\ &\quad + [\nu - \lambda - \mu^h(i+1)][\Delta_h(i+1) - \Delta_h(i)] \\ &\quad + \mu^h(i-1)[\Delta_h(i) - \Delta_h(i-1)]. \end{aligned}$$

利用 $c(i)$ 的凸性假设和 $\nu - \lambda - \mu^h(i+1) = \bar{\mu} - \mu^h(i+1) \geq 0$ 的事实, 以及归纳假设, 可以看出上式右边每一项都是非负的。所以对 $i = 1, 2, \dots$, $\Delta_{h+1}(i+1) \geq \Delta_{h+1}(i)$ 。由式(6.88)




图 6.7 例题 2 中, 在状态 i 和 $i+1$ 确定最优服务率。最优代价微分 $\Delta(i)$ 是按 i 单调非减的。结果, 当系统变得更加拥挤 (i 增大) 时, 最优服务率 $\mu^*(i)$ 趋向于增大。

也容易证明 $\Delta_{k+1}(1) \geq 0 = \Delta_{k+1}(0)$, 则完成了归纳证明。

总结起来, 最优服务率 $\mu^*(i)$ 由式(6.86)给出, 而且当系统变得更加拥挤(i 增大)时, 服务率趋向于变得更快。

例题 3

具有受控到达率的 $M/M/1$ 排队问题。考虑与上例题相同的排队系统, 所不同的是服务率 μ 固定, 但到达率 λ 可以控制。我们假定 λ 从区间 $[0, \bar{\lambda}]$ 的一个闭子集 A 中选取, 每单位时间有一个连续代价 $q(\lambda)$ 。例 2 中所有其它假设仍有效。这是一个流量控制问题。调节到达过程的代价最优地与顾客等待代价进行折衷。

这个问题非常类似于例题 2 中的问题。我们选择一致转移率

$$v = \bar{\lambda} + \mu,$$

并且构造一个马尔科夫链的一致化形式。贝尔曼方程取如下形式

$$J(0) = \frac{1}{\beta + v} \min_{\lambda \in A} [c(0) + q(\lambda) + (v - \lambda)J(0) + \lambda J(1)],$$

$$J(i) = \frac{1}{\beta + v} \min_{\lambda \in A} [c(i) + q(\lambda) + \mu J(i-1) + (v - \lambda - \mu)J(i) + \lambda J(i+1)].$$

最优策略是在状态 i 时采用到达率

$$\lambda^*(i) = \arg \min_{\lambda \in A} \{q(\lambda) + \lambda \Delta(i+1)\}, \quad (6.89)$$

其中 $\Delta(i)$ 和以前一样是最优代价微分

$$\Delta(i) = J(i) - J(i-1), \quad i = 1, 2, \dots.$$

如在例题 2 中一样, 我们能够证明 $\Delta(i)$ 是单调非减的, 于是由式(6.89)我们可以看出, 当系统变得更拥挤时(i 增大), 最优到达率趋向于减小。

例题 4

优先权分配与 μc 规则。考虑 n 个队列共用一个服务者的问题。在每个队列 i 有一个顾客和每单位时间正的代价 c_i ; 队列 i 中一个顾客的服务时间按指数分布, 具有参数 μ_i , 而且所有顾客的服务时间是独立的。假定我们由给定的各队列中的顾客数开始, 其后再没有顾客到达, 而对这些顾客服务的最优顺序是什么呢? 此处的代价是

$$E \left\{ \int_0^\infty e^{-\beta t} \sum_{i=1}^n c_i x_i(t) dt \right\},$$

其中 $x_i(t)$ 是时刻 t 在第 i 个队列中的顾客数, β 是正的折扣参数。

首先, 我们根据一致转移率


$$\mu = \max_i \{\mu_i\}$$

构造这个连续马尔科夫链问题的一致化形式。其结构示于图 6.8, 折扣因子是


$$\alpha = \frac{\mu}{\beta + \mu}, \quad (6.90)$$

相应的代价是

$$\frac{1}{\beta + \mu} \sum_{k=0}^\infty \alpha^k E \left\{ \sum_{i=1}^n c_i x_i^k \right\}, \quad (6.91)$$



当提供服务时第 i 个队列的转移率和转移概率



一致化形式的转移概率

图 6.8 例题 4 中, 当提供服务时第 i 个队列的连续时间马尔科夫链及一致化形式

其中 x_k^i 是在第 i 个队列中第 k 次转移(实际的或虚拟的)之后的顾客数。

现在我们以更便于分析的方式写出代价函数。其思想是把一个使等待代价极小的问题, 通过顾客服务, 转化为一个使等待代价节约为极大的问题。对于 $m=0, 1, \dots$, 定义

$$i_k = \begin{cases} i, & \text{如果第 } k \text{ 次转移相应于一个顾客从队列 } i \text{ 中离去;} \\ 0, & \text{如果第 } k \text{ 次转移是虚拟的。} \end{cases}$$

再记

$$c_{i0} = 0,$$

x_0^i : 队列 i 的初始顾客数。

那么, 代价式(6.91)也可以写成

$$\begin{aligned} & \frac{1}{\beta + \mu} \left[\sum_{i=1}^n c_i x_0^i + \sum_{k=1}^{\infty} \alpha^k E \left\{ \sum_{i=1}^n c_i x_0^i - \sum_{m=0}^{k-1} c_{i_m} \right\} \right] \\ &= \frac{1}{\beta + \mu} \left[\sum_{k=0}^{\infty} \alpha^k \left(\sum_{i=1}^n c_i x_0^i \right) - E \left\{ \sum_{m=0}^{\infty} \sum_{k=m+1}^{\infty} \alpha^k c_{i_m} \right\} \right] \\ &= \frac{1}{(\beta + \mu)(1 - \alpha)} \sum_{i=1}^n c_i x_0^i - \frac{\alpha}{(\beta + \mu)(1 - \alpha)} \sum_{k=0}^{\infty} \alpha^k E \{ c_{i_k} \} \\ &= \frac{1}{\beta} \sum_{i=1}^n c_i x_0^i - \frac{\alpha}{\beta} \sum_{k=0}^{\infty} \alpha^k E \{ c_{i_k} \}. \end{aligned}$$

因此, 对式(6.91)代价求极小, 我们可等效地对下式求极大

$$\sum_{k=0}^{\infty} \alpha^k E \{ c_{i_k} \}, \quad (6.92)$$

其中 c_{i_k} 可以看作是第 k 次转移所得到的等待代价率的节约。刚才建立的问题等价性表达了直观上显然的观念: 对顾客服务我们就节约了相应的队列中等待的代价。

现在我们认识到式(6.92)的问题是一个多臂赌博问题。 n 个队列可看作为相互独立的项目。在每个时刻,一个非空队列,比如说队列*i*被选择服务。因为顾客以概率 μ_i/μ 离去,而一个虚拟转移,使状态不发生变化的概率为 $1-\mu_i/\mu$,相应的期望报酬是

$$\frac{\mu_i}{\mu} c_i. \quad (6.93)$$

显然,这个问题属于§6.5末所讨论的蜕化情况。因此,每一个顾客离去之后,最优策略就是对每阶段具有最大期望报酬的队列进行服务(即从事具有最大指标的项目,见§6.5末)。等价地[见式(6.93)],对 $\mu_i c_i$ 为最大的非空队列*i*进行服务是最优的。这一策略即所谓 μc 规则。它在优先权分配问题的其它几种方程建立中(见[B2],[H3]及[H4]),起着重要的作用。我们可把 $\mu_i c_i$ 看作为等待代价率 c_i 与对一个顾客服务所需平均时间 $1/\mu_i$ 的比值,据此在代价率中节省了 c_i 。所以, μc 规则就是在每单位平均服务时间中,对等待代价节省为最大的队列进行服务。

例题 5

双服务站排队系统中,路径选择的策略。考虑图 6.9 所示由两个队列组成的系统,顾客以到达率 λ 按泊松过程到达,而且被引到两个队列之一。服务时间是独立的,且按指数分布;第一个队列中的参数是 μ_1 ,第二个队列中的参数是 μ_2 。代价是

$$E\left\{\int_0^\infty e^{-\beta t} [c_1 x_1(t) + c_2 x_2(t)] dt\right\},$$

其中 β , c_1 和 c_2 是给定的正标量,而 $x_1(t)$ 和 $x_2(t)$ 分别表示 t 时刻队列 1 和队列 2 中的顾客数。

如以前一样,我们构造该问题的一致化形成,具有一致转移率为

$$\nu = \lambda + \mu_1 + \mu_2,$$

转移概率示于图 6.10。我们把在队列 1 和队列 2 中的顾客对 (i, j) 的集合作为状态空间。贝尔曼方程取如下形式

$$\begin{aligned} J(i, j) = & \frac{1}{\beta + \nu} [c_1 i + c_2 j + \mu_1 J[(i-1)^+, j] + \mu_2 J[i, (j-1)^+]] \\ & + \frac{\lambda}{\beta + \nu} \min[J(i+1, j), J(i, j+1)], \end{aligned} \quad (6.94)$$

其中对任意 x , 记

$$(x)^+ = \max[0, x].$$

由此方程,我们看出一个最优策略是:

当且仅当到达时刻的状态 (i, j) 属于 S_1 , 把到来的顾客引到队列 1, (6.95)

其中, S_1 是一个状态集合;对此状态,把新的顾客引到队列 1, 其造成的结果至少与把顾客引到队列 2 有同样优惠的余留代价,

$$S_1 = \{(i, j) | J(i+1, j) \leq J(i, j+1)\}. \quad (6.96)$$

这一最优策略可以通过进一步分析而更好地表征。直观上人们期望,把顾客送到在某种意义上“不拥挤”的队列,就能达到最优路径选择。因此,自然会猜想:如果当状态为 (i, j) 时,






图 6.9 例题 5 的排队系统。这个问题就是把每个到达的顾客引到队列 1 或队列 2, 以使总的平均折扣等待代价为极小。

引到第1队列是最优的, 当第1队列较不拥挤, 即状态为 $(i-m, j)$, 且 $m \geq 1$ 时, 同样做法也必定是最优的。这等价于说, 引到第一队列为最优的状态集合 S_1 , 可以用一个单调非减



当顾客被引到队列1时的转移率



一致化形式的转移概率

图 6.10 例题 5 中, 当顾客被引到第 1 队列时的连续时间马尔科夫链和一致化形式。状态即为在两个队列中的顾客数对。

的阈函数 F , 按

$$S_1 = \{(i, j) | i = F(j)\} \quad (6.97)$$

来表征(见图 6.11)。因此, 称相应的最优策略为一个阈策略。

我们将通过证明变分

$$\Delta_1(i, j) = J(i+1, j) - J(i, j+1),$$

$$\Delta_2(i, j) = J(i, j+1) - J(i+1, j)$$

分别对固定的 j 是 i 的, 和对固定的 i 是 j 的单调非减函数, 来表明最优阈策略的存在性。对于所有的 $k=0, 1, \dots$, 这只要证明函数

$$\Delta_k^+(i, j) = J_k(i+1, j) - J_k(i, j+1) \quad (6.98)$$

对每个固定的 j 是 i 的单调非减函数就够了。其中 J_k 是从零函数起始, 按逐次逼近法产生




图 6.11 用一个阈函数表征的典型的阈策略

的, 即 $J_{k+1}(i, j) = T(J_k)(i, j)$, 式中 T 定义了贝尔曼方程式(6.94)的 DP 映射, 且 $J_0 = 0$ 。因为当 $k \rightarrow \infty$ 时, 对所有 i, j 有 $J_k(i, j) \rightarrow J(i, j)$ (§ 5.4 的命题 13), 所以这是正确的。为证明 $\Delta_1^k(i, j)$ 具有所要求的特性, 首先证明 $J_k(i, j)$ 对固定的 j (或 i) 是 i 的 (或 j 的) 单调非减函数是有用的。主要是利用归纳法, 或利用事实从基本原理推断, 去证明 $J_k(i, j)$ 具有 K 阶段最优代价的解释。接下来, 我们利用式(6.94)和式(6.98)写出

$$\begin{aligned} (\beta + \nu) \Delta_1^{k+1}(i, j) = & c_1 - c_2 \\ & + \mu_1 [J_k(i, j) - J_k[(i-1)^+, j+1]] \\ & + \mu_2 [J_k[i+1, (j-1)^+] - J_k(i, j)] \\ & + \lambda [\min[J_k(j+2, j), J_k(i+1, j+1)] \\ & - \min[J_k(i+1, j+1), J_k(i, j+2)]]]. \end{aligned} \quad (6.99)$$

现在我们用归纳法论证, 对所有 (i, j) , 有 $\Delta_1^0(i, j) = 0$ 。我们假定对固定的 j , $\Delta_1^k(i, j)$ 是 i 的单调非减函数, 并证明 $\Delta_1^{k+1}(i, j)$ 同样如此。这可以通过证明式(6.99)右边的每一项对固定的 j 是 i 的单调非减函数来验证。事实上, 第一项是常值; 第二和第三项容易看出是 i 的单调非减函数, 只要对 $i, j > 0$ 的情况利用归纳假设, 以及对 $i = 0$ 或 $j = 0$ 情况, 利用前面已证明的 $J_k(i, j)$ 是 i 的单调非减函数这一事实即可。式(6.99)右边最末一项可以写成

$$\begin{aligned} & \lambda [J_k(i+1, j+1) + \min[J_k(i+2, j) - J_k(i+1, j+1), 0] \\ & - J_k(i+1, j+1) - \min[0, J_k(i, j+2) - J_k(i+1, j+1)]] \\ & = \lambda [\min[0, J_k(i+2, j) - J_k(i+1, j+1)] \\ & + \max[0, J_k(i+1, j+1) - J_k(i, j+2)]] \\ & = \lambda [\min[0, \Delta_1^k(i+1, j)] + \max[0, \Delta_1^k(i, j+1)]]]. \end{aligned}$$

因为根据归纳假设, $\Delta_1^k(i+1, j)$ 和 $\Delta_1^k(i, j+1)$ 是 i 的单调非减函数, 所以上式也是 i 的单调非减函数。因此, 式(6.99)右边的每一项都是 i 的单调非减函数。这就完成了归纳证明。于是, 最优阈策略的存在性已建立。

还存在一些有关本例题路径选择问题的推广形式, 允许用类似的分析方法, 而且对此存在阈值型最优策略。比如, 假定有另一个泊松到达过程, 在队列 1 和 2 中的到达率分别是 λ_1 和 λ_2 , 则可几乎逐字重复利用我们的分析方法, 来证明存在最优阈策略。当另有服务容量 μ 时, 可以获得更重要的推广, 在顾客到达, 或对队列 1 或 2 中的一个顾客服务完成的转移时刻, 可以切换到 μ 。因此可用以前的类似证明方法证明: 当且仅当 $(i, j) \in S_1$; 并且当仅当 $(i+1, j+1) \in S_1$, S_1 由式(6.96)给定, 并由式(6.97)的阈函数所表征, 把附加容量切换到队列 2, 则引导到队列 1 是最优的。为证明这结果和更进一步扩充, 参考[H1], 该文献把此主题的以前几个结果推广和统一起来。

§ 6.8 注 记

首次通过问题在[E1]中首先作了描述。我们的表述从几个来源包括[D4], [K14] 和 [P1], 加深了这些结果。

多臂投赌机问题的指标规则解来源于[G1]和[G2], 这里给出的证明归功于 Tsitsiklis [T9], 对早期证明的重要改进是由 Whittle 做出的[W11]。参考文献[V3]分析了投赌机问题的推广。参考文献[K10]和[K13], 对这一课题作了许多其它的工作。

赌博问题及其求解取自[D9]。在[B25]中,证明了该问题最优报酬函数 J^* 的一个令人惊异的特性:导数为零,几乎处处可微,且在 0 到 1 范围内取值,是严格递增的。

利用一致化形式把包含连续时间马尔科夫链的随机控制问题,转化为离散时间问题的思想,是由[L4]而得到广泛的注意。排队系统的控制已得到广泛的研究。关于到达率或服务率控制的其它材料(参看 § 6.7 例题 2 和 3),请看[C4], [R4], [S15], [S22], [S25] 和 [S26]。关于优先权分配和路径选择(参看 § 6.7 例题 4 和 5)的更多的内容,请分别参看[B2], [B3], [C4], [H3], 和[E3], [H1], [L3]。

习 题

1. 确定性线性二次问题。考虑一个确定性二次问题,有系统

$$x_{k+1} = Ax_k + Bu_k,$$

和代价泛函

$$J_\pi(x_0) = \sum_{k=0}^{\infty} x_k' Q x_k + \mu_k(x_k)' R \mu_k(x_k).$$

假定 R 是正定对称的, Q 有 $C' C$ 的形式, 且 (A, B) 和 (A, C) 分别是能控和能观的。利用 § 2.1 和 § 6.1 的理论证明, 平稳策略 $\pi^* = \{\mu^*, \mu^*, \dots\}$, 且,

$$\mu^*(x) = -(B'KB + R)^{-1}B'KAx$$

是最优的, 其中 K 是如下代数黎卡提方程(见 § 2.1)的唯一半正定对称解:

$$K = A'[K - KB(B'KB + R)^{-1}B'K]A + Q.$$

对于周期确定性系统和周期性二次代价泛函(参见 § 5.5 和习题 3), 在适当的能控性假设下, 提出一个类似的结果。

2. 具有非平稳扰动的线性二次问题。考虑 § 6.1 的线性二次问题, 唯一的不同点是扰动 w_k 具有零均值, 但其协方差阵是非平稳的, 且对 k 一致有界。证明最优控制律保持不变。

3. 周期性线性二次问题。考虑线性系统

$$x_{k+1} = A_k x_k + B_k u_k + w_k, \quad k=0, 1, \dots,$$

以及二次代价泛函

$$J_\pi(x_0) = \lim_{N \rightarrow \infty} E \sum_{k=0, 1, \dots, N-1} \alpha^k [x_k' Q_k x_k + \mu_k(x_k)' R_k \mu_k(x_k)],$$

其中矩阵具有适当的维数, Q_k 和 R_k 对所有 k 分别是半正定和正定的, 且 $0 < \alpha < 1$ 。假定系统和代价泛函是周期性的, 具有周期 p (参见 § 5.5), 控制无约束, 且扰动是独立的, 具有零均值和有限协方差阵。进一步假定如下(能控性)条件是有效的。

给定任意初始状态 $\bar{x}_0$, 存在有限控制序列 $\{\bar{u}_0, \bar{u}_1, \dots, \bar{u}_r\}$, 使得 $\bar{x}_{r+1} = 0$, 其中 $\bar{x}_{k+1}$ 是由下式产生

$$\bar{x}_{k+1} = A_k \bar{x}_k + B_k \bar{u}_k, \quad k=0, 1, \dots, r.$$

证明存在一个最优周期性策略 π^* , 形式为:

$$\pi^* = \{\mu_0^*, \mu_1^*, \dots, \mu_{p-1}^*, \mu_0^*, \mu_1^*, \dots, \mu_{p-1}^*, \dots\},$$

其中 $\mu_0^*, \dots, \mu_{p-1}^*$ 由下式给出

$$\mu_i^*(x) = -\alpha(\alpha B_i' K_{i+1} B_i + R_i)^{-1} B_i' K_{i+1} A_i x,$$

$$i = 0, \dots, p-2,$$

$$\mu_{p-1}^*(x) = -\alpha(\alpha B_{p-1}' K_0 B_{p-1} + R_{p-1})^{-1} B_{p-1}' K_0 A_{p-1} x,$$

而矩阵 $K_0, K_1, \dots, K_{p-1}$ 满足如下联立代数黎卡提方程组

$$K_i = A_i' [\alpha K_{i+1} - \alpha^2 K_{i+1} B_i (\alpha B_i' K_{i+1} B_i + R_i)^{-1} B_i' K_{i+1}] A_i + Q_i,$$

$$i = 0, 1, \dots, p-2,$$

$$K_{p-1} = A_{p-1}' [\alpha K_0 - \alpha^2 K_0 B_{p-1} (\alpha B_{p-1}' K_0 B_{p-1} + R_{p-1})^{-1} B_{p-1}' K_0] A_{p-1} + Q_{p-1}.$$

4. 具有不完全状态信息的折扣线性二次问题。考虑 § 6.1 的线性二次问题，差别是控制器不再具有完全状态信息，而取得如下形式的量测进行存取：

$$z_k = Cx_k + v_k, \quad k = 0, 1, \dots.$$

如在 § 3.2 一样，扰动 v_k 是一个独立过程，具有恒等统计量，零均值，有限协方差阵。假定对每个容许策略 π ，矩阵

$$E\{[x_k - E\{x_k | I_k\}][x_k - E\{x_k | I_k\}]' | \pi\}$$

对 k 是一致有界的，其中 I_k 就是在 § 3.2 定义的信息向量。证明最优策略是 $\pi^* = \{\mu^*, \mu^*, \dots\}$ ，其中 μ^* 是由下式给出

$$\mu^*(I_k) = -\alpha(\alpha B'KB + R)^{-1} B'KA E\{x_k | I_k\},$$

$$\text{对所有 } I_k, \quad k = 0, 1, \dots.$$

若 w_k 和 v_k 是非平稳的，具有零均值和对 k 一致有界的协方差阵。再证明上述结论也是正确的。提示：结合 § 3.2 和 § 6.1 的理论。

5. 折扣线性二次问题的策略迭代【K9】。考虑 § 6.1 的问题，且令 L_0 是一个 $m \times n$ 矩阵，使得 $(A + BL_0)$ 阵是稳定的。(a) 证明相应于平稳策略 $\{\mu_0, \mu_0, \dots\}$ ，其中 $\mu_0(x) = L_0(x)$ 的代价具有如下形式

$$J_{\mu_0}(x) = x' K_0 x + \text{常量},$$

其中 K_0 是一个半正定矩阵，满足(线性)方程

$$K_0 = \alpha(A + BL_0)' K_0 (A + BL_0) + Q + L_0' R L_0.$$

(b) 令 $\mu_1(x)$ 在如下表达式中对每个 x 达到极小值

$$\min_u \{u' R u + (Ax + Bu)' K_0 (Ax + Bu)\}.$$

证明对所有 x ,

$$J_{\mu_1}(x) = x' K_1 x + \text{常量} \leq J_{\mu_0}(x),$$

其中 K_1 是某个半正定矩阵。

(c) 证明在 (a) 和 (b) 中描述的策略迭代过程产生一个序列 $\{K_k\}$ ，使得

$$K_k \rightarrow K,$$

其中 K 是该问题的最优代价矩阵。

6. 周期性库存控制问题。在 § 6.2 的库存控制问题中，考虑需求 w_k 的统计量，价格 c_k ，以及存货和缺货代价均为以 p 为周期的周期性情况。证明存在一个最优周期性策略，形式如 $\pi^* = \{\mu_0^*, \dots, \mu_{p-1}^*, \mu_0^*, \dots, \mu_{p-1}^*, \dots\}$,

$$\mu_i^*(x) = \begin{cases} S_i^* - x, & \text{若 } x \leq S_i^*, \\ 0, & \text{其它,} \end{cases} \quad i = 0, 1, \dots, p-1,$$

其中 $S_0^*, \dots, S_{j-1}^*$ 是适当的标量。

7. 考虑在如下假设条件下, § 6.3 的停止问题:

对所有 $x \in S$, $t(x) \leq 0$, $c(x) \leq 0$.

再考虑由下式定义的映射 T :

$$T(J)(x) = \min [t(x), c(x) + \min_w \{J[f_c(x, w)]\}].$$

(a) 证明最优代价函数 J^* 满足

$$J^* = T(J)^*, \quad J^* = \lim_{k \rightarrow \infty} T^k(J_0),$$

其中 J_0 是零函数。

(b) 设对所有 $i \in S$, $S = \{1, 2, \dots\}$, $f_c(i, w) = i + 1$; 且 $c(i) = 0$, 对所有 $i \in S$, $w \in D$, 以及 $t(i) = -1 + (1/i)$ 。证明对所有 i , $J^*(i) = -1$, 而且该问题不存在一个最优策略 (即使控制空间是有限集)。

8. 令 $z_0, z_1, \dots$ 是一个独立等分布, 且取值于有限集 Z 的随机变量序列。我们知道 z_k 的概率分布是 n 个分布 $f_1, f_2, \dots, f_n$ 中的一个, 我们正试图确定哪一个分布是正确的。在每个时刻 k , 观察 $z_1, \dots, z_k$ 之后我们或停止观察, 接受 n 个分布中的一个为正确; 或者以代价 $c > 0$ 取另一次观察。在给定 f_i 为正确的情况下, 接受 f_i 的代价是 L_{ij} , $i, j = 1, \dots, n$ 。我们假定对 $i \neq j$, $L_{ij} > 0$, $L_{ii} = 0$, $i = 1, \dots, n$ 。 $f_1, \dots, f_n$ 的一个先验分布记为

$$P_0 = \{p_0^1, p_0^2, \dots, p_0^n\}, \quad p_0^i \geq 0, \quad \sum_{i=1}^n p_0^i = 1.$$

证明最优代价 $J^*(P_0)$ 是 P_0 的凹函数。表征最优接受区域, 且证明如何按逐次逼近法以极限形式得到这些区域。

9. 证明属于第一章基本问题框架内的 N 阶段有限时域问题, 可看作为一个 (平稳的) 首次通过问题 (不必具有有限状态, 控制和扰动空间), 对此问题满足类似于 § 6.4 的假设。再证明, 对此问题式 (6.22) 的收缩条件成立。

提示: 如果 $S_0, S_1, \dots, S_N$ 是阶段 $0, 1, \dots, N$ 的状态空间, 定义一个新的状态空间 S , 按 $S = \{(x, k) | x \in S_k, k = 0, 1, \dots, N\} \cup \{T\}$, 其中 T 是终止 (吸收) 态。类似于 § 5.5 中的结构, 系统从 $\{(x, N) | x \in S_N\}$ 中的每一个状态, 肯定被驱动到这个终止态。

10. 无限时间可达性 [B9], [B12]。考虑本章问题的一个平稳系统:

$$x_{k+1} = f(x_k, u_k, w_k), \quad k = 0, 1, \dots,$$

其中扰动空间 D 是一个任意 (不必是可数的) 集合。扰动 w_k 可取值于 D 的一个子集 $W(x_k, u_k)$, 它可能依赖于 x_k 和 u_k 。这可处理以下的问题: 给定状态空间 S 的一个非空子集 X , 在什么条件下存在一个容许策略 $\{\mu_0, \mu_1, \dots\}$, 且对所有 $x_k \in S$ 和 $k = 0, 1, \dots$, $\mu_k(x_k) \in U(x_k)$, 使得 (闭环) 系统的状态

$$x_{k+1} = f[x_k, \mu_k(x_k), w_k] \quad (6.100)$$

对所有 k 和所有容许值 $w_k \in W[x_k, \mu_k(x_k)]$ 属于集合 X , 即

$$x_k \in X, \quad \text{对所有 } w_k \in W[x_k, \mu_k(x_k)], \quad k = 0, 1, \dots? \quad (6.101)$$

如果存在一个容许策略 $\{\mu_0, \mu_1, \dots\}$, 和某个初始状态 $x_0 \in X$, 满足关系式 (6.100) 和式 (6.101), 则集合 X 说成是无限可达的; 如果存在一个容许策略 $\{\mu_0, \mu_1, \dots\}$, 使得对所有初始

状态 $x_0 \in X$ 满足关系式(6.100)和式(6.101), 称其为是强可达的。

考虑函数 R , 把状态空间 S 的任意子集 Z 映射到 S 的一个子集 $R(Z)$, $R(Z)$ 定义为:

$$R(Z) = \{x \mid \text{存在 } u \in U(x), \text{ 且对所有 } w \in W(x, u) \text{ 有 } f(x, u, w) \in Z\} \cap Z.$$

(a) 证明, 当且仅当 $R(X) = X$, X 是强可达的。

给定 X , 考虑集合 X^* 定义如下: $x_0 \in X^*$, 当且仅当 $x_0 \in X$, 且存在一个容许策略 $\{\mu_0, \mu_1, \dots\}$, 使得当 x_0 取为系统初始状态时满足式(6.100)和式(6.101)。

(b) 证明集合 X 是无限可达的, 当且仅当其包含一个非空强可达集。而且在 X^* 为非空它就是强可达的意义上, 最大的这种集合是 X^* ; 且如果 $\tilde{X} \subset X$ 是另一个强可达集, 则 $\tilde{X} \subset X^*$ 。

(c) 证明若 X 是无限可达的, 存在一个容许的平稳策略 $\{\mu, \mu, \dots\}$, 使得若初始状态 x_0 属于 X^* , 则保证闭环系统 $x_{k+1} = f[x_k, \mu(x_k), w_k]$ 其后的所有状态属于 X^* 。

(d) 给定 X , 考虑集合 $R(X), \dots, R^k(X), \dots$, 其中 $R^k(X)$ 表示 k 次应用映射 R 于 X 之后得到的集合。证明

$$X^* \subset \bigcap_{k=1}^{\infty} R^k(X).$$

(e) 给定 X , 对每个 $x \in X$ 和 $k=1, 2, \dots$, 考虑集合

$$U_k(x) = \{u \mid f(x, u, w) \in R^k(x), \text{ 对所有 } w \in W(x, u)\}.$$

证明如果存在一个指标 $\bar{k}$, 使得对所有 $x \in X$ 和 $k \geq \bar{k}$, 集合 $U_k(x)$ 是欧氏空间的一个紧子集, 则 $X^* = \bigcap_{k=1}^{\infty} R^k(X)$ 。

11. 线性系统的无限时间可达性。考虑线性平稳系统

$$x_{k+1} = Ax_k + Bu_k + Gw_k,$$

式中 $x_k \in R^n$, $u_k \in R^m$, 和 $w_k \in R^r$, 矩阵 A, B 和 G 是已知的, 且具有适当维数。矩阵 A 假定是可逆的。控制 u_k 和扰动 w_k 分别限于在椭球 $U = \{u \mid u' Ru \leq 1\}$ 和 $W = \{w \mid w' Qw \leq 1\}$ 取值, 其中 R 和 Q 是适当维数的正定对称矩阵。证明为了使椭球 $X = \{x \mid x' Kx \leq 1\}$ 是强可达的(习题 10 的术语), 其中 K 是一个正定对称阵, 则其充分条件是对某正定矩阵 M 和对某标量 $\beta \in (0, 1)$, 有

$$K = A' \left[(1 - \beta) K^{-1} - \frac{1 - \beta}{\beta} GQ^{-1}G' + BR^{-1}B' \right]^{-1} A + M, \quad (6.102)$$

$$K^{-1} - \frac{1}{\beta} GQ^{-1}G', \text{ 正定。} \quad (6.103)$$

再证明若满足式(6.102)和式(6.103), 平稳策略 $\{\mu^*, \mu^*, \dots\}$, 式中

$$\mu^*(x) = -(R + B'FB)^{-1} B' F A x = Lx,$$

$$F = \left[(1 - \beta) K^{-1} - \frac{1 - \beta}{\beta} GQ^{-1}G' \right]^{-1},$$

实现对椭球 $X = \{x \mid x' Kx \leq 1\}$ 的可达性。而且, 矩阵 $(A + BL)$ 是一个稳定阵。(寻求满足式(6.102)和式(6.103)的矩阵 K 的计算方法和证明, 参看[B9]和[B12])。

12. 在 § 6.4 首次通过问题中, 假定存在 $m > 0$, 使得

$$P(x_m = 0 \mid x_0 = i, \pi) > 0 \quad (6.104)$$

对所有 $i = 1, \dots, n$, 和平稳策略 π 。证明这一关系式对所有非平稳策略 π 也成立。

提示：用反证法。假定存在一个非平稳策略 $\pi = \{\mu_0, \mu_1, \dots\}$ 和初始状态 i ，使得式(6.104)对任意 m 不成立。对于 $k=1, 2, \dots$ ，定义

$$S_k(i) = \{j \mid P(x_k = j \mid x_0 = i, \pi) > 0\}.$$

令 S_∞ 表示一个状态集合，该状态属于无限多个集合 $S_k(i)$ ；对于每个 $j \in S_\infty$ ，令 μ^j 使得 $\mu_k = \mu^j$ 与 $j \in S_k(i)$ 对无限多个整数 k 同时成立。考虑任意平稳策略 μ ，使得对 $j \in S_\infty$ ， $\mu(j) = \mu^j(j)$ 。证明对于 $\pi = \{\mu, \mu, \dots\}$ ，式(6.104)不成立。

13. 考虑 § 6.4 的首次通过问题。

(a) 假定对某平稳策略 π ，存在 $m > 0$ 和 $\varepsilon > 0$ ，使得对所有 i ，

$$P(x_m = 0 \mid x_0 = i, \pi) \geq \varepsilon,$$

用归纳法证明对所有 k ，

$$P(x_{km} = 0 \mid x_0 = i, \pi) \geq 1 - (1 - \varepsilon)^k,$$

因而当 $k \rightarrow \infty$ 时， $P(x_k = 0 \mid x_0 = i, \pi) \rightarrow 1$ 。

(b) 在假设 N 条件下，证明或对某个初始状态最优代价为 $-\infty$ ；或者在每个策略下，系统最终以概率 1 进入一个无代价状态的集合，而且以后不再离开这一集合。

(c) 在假设 P 条件下，证明若对每个初始状态，存在一个在式(6.26)意义下为正常的最优非平稳策略，则就存在一个最优平稳正常的策略。

14. 一个赌徒在无限时域参与逐次投硬币的赌博。每次正面(H)朝上他赢得 1 美元；而每连续两个背面(T)朝上，输掉 $m > 0$ 美元(于是，序列 TTTT 输掉 $3m$ 美元)。这个赌徒每次或投一个正常的硬币，或者投一个双正面硬币进行哄骗。在后一种情况下，他投硬币前将以概率 $p > 0$ 被抓住，于是赌博结束，这个赌徒就保持迄今为止的赢利。这个赌徒希望他所期望的赢利最大。

(a) 证明 m 有一个临界值 $\bar{m}$ ，当 m 低于它时，全投正常硬币是最优的。

(b) 假定 $m > \bar{m}$ ，试论证若最末一次投反面，则试图哄骗是最优的；其它情况投正常硬币。

提示：这是一个首次通过问题。然而，§ 6.4 的假设并不完全满足。

15. 有利赌局的赌博策略。一个赌徒玩如 § 6.6 中的赌博，但赢的概率 p 满足 $\frac{1}{2} \leq p < 1$ 。他的目标是达到一个最终赌本 n ，其中 n 是一个正整数，且 $n \geq 2$ 。他的初始赌本是一个正整数 i ，且 $0 < i < n$ ；且他在第 k 次的赌注只能取整数 u_k ，满足 $0 \leq u_k \leq x_k$ ， $0 \leq u_k \leq n - x_k$ ，其中 x_k 是他在 k 时刻的赌本。证明一直下一个单位赌注的策略是最优的[也就是说，对所有整数 x ，且 $0 < x < n$ ， $\mu^*(x) = 1$ 是最优的]。

提示：利用命题 3 证明：

$$J_{\mu^*}(i) = \left[\left(\frac{1-p}{p} \right)^i - 1 \right] \left[\left(\frac{1-p}{p} \right)^n - 1 \right]^{-1}, \quad 0 \leq i \leq n, \quad \frac{1}{2} < p < 1,$$

$$J_{\mu^*}(i) = \frac{i}{n}, \quad 0 \leq i \leq n, \quad p = \frac{1}{2}.$$

(或参看[A9, p.182]的证明)。然后利用 § 5.4 命题 10 的充分条件。

16. 计算机分配。在橄榄球比赛中，四分卫在一次进攻中可在奔跑和传球之间进行选择。由奔跑所进的码数按泊松分布，具有参数 λ_r 。而传球以概率 p 不能传出，它以概率 q 被拦截，因而完成传球的概率是 $1 - p - q$ 。当传球完成时，一个传球所进的码数也按泊松分布，具有参数 λ_p 。我们假定在一次进攻中所进码数是整数，距目标为 x 码开始的一次进攻，底线得

分的概率等于所进码数大于或等于 x 的概率。我们还假定在每一次进攻中码数不会丢失,而且没有罚球。在四分位失误或发生截球时,球落入对方手中。把这个问题描述成一个首次通过问题,且利用逐次逼近法和策略迭代去计算当 $\lambda_r = 3$, $\lambda_p = 10$, $p = 0.4$ 和 $q = 0.05$ 时,使任何一次进攻中底线得分概率为最大的四分卫选择策略。

17. 网球的最优发球[N4]。一个网球运动员有快发球和慢发球两种方式,分别记为 F 和 S 。 F (或 S)落入界内的概率是 p_F (或 p_S)。假定发球落在界内,赢得一分的概率是 q_F (或 q_S)。我们假定 $p_F < p_S$, 且 $q_F > q_S$ 。问题是比赛中在可能得分的情况下,寻求所用的发球策略,使得比赛中赢球的概率为最大。

(a) 把这个问题表述为具有 36 个状态(加上吸收态)的首次通过问题,写出贝尔曼方程。

(b) 解析证明若 $(p_F q_F)/(p_S q_S) > 1$, 两次发球用 F ; 而当 $(p_F q_F)/(p_S q_S) < 1 + p_F - p_S$ 时,两次发球用 S ;其它情况下第一次发球用 F ,第二次发球用 S 是最优的(不管比分多少)。

(3) 最优计算机分配: 假定 $q_F = 0.6$, $q_S = 0.4$, 且 $p_S = 0.95$; 将以最优发球赢得比赛的发球概率画成(增量 0.05) P_F 的函数。

18. 赋税问题[V3]。这个问题类似于多臂投赌机问题。唯一的差别是: 如果我们在周期 k 从事项目 i , 我们对每一个其它项目 j , 赋税 $\alpha^k C^j(x^i)$ [总的为 $\alpha^k \sum_{j \neq i} C^j(x^i)$], 而不是赚得报酬 $\alpha^k R^i(x^i)$ 。目标就是寻求一个项目选择策略, 使总赋税为最小。证明这个问题可以转化为一个投赌问题, 每个项目 i 的报酬函数等于

$$R^i(x^i) = C^i(x^i) - \alpha E\{C^i[f^i(x^i, w^i)]\}.$$

19. 重新起终问题[K4]。这个问题的目的是证明, 在多臂投赌问题中的一个项目的指标, 可以通过求解一个有关的无限时域折扣代价问题来计算。下面我们考虑单个项目问题, 它具有报酬函数 $R(x)$, 固定的初始状态 x_0 , 并对这个状态计算指标 $m(x_0)$ 的值。考虑这个问题 k 时刻在状态 x_k 有两种选择: (1) 继续, 它带来报酬 $\alpha^k R(x_k)$, 而且把这个项目移到状态 $x_{k+1} = f(x_k, w)$; 或者(2)重新起始这个项目, 即把状态移到 x_0 , 带来报酬 $\alpha^k R(x_0)$, 再把项目移到状态 $x_{k+1} = f(x_0, w)$ 。证明该问题的最优报酬函数与具有 $M = m(x_0)$ 的投赌问题有相同的最优报酬函数, 所以从 x_0 起始时两个问题的最优报酬均等于 $m(x_0)$ 。

提示: 这两个问题的贝尔曼方程均取如下形式

$$J(x) = \max[R(x_0) + \alpha E\{J[f(x_0, w)]\}, R(x) + \alpha E\{J[f(x, w)]\}.$$

20. 项目指标的另一个特性。在多臂投赌机问题中, 固定一个项目和一个初态 x_0 , 令 $m(x_0)$ 为在此状态下的指标值。考虑具有撤出报酬等于 $m(x_0)$ 的单项目问题。对于任意平稳策略 $\{\mu, \mu, \dots\}$, 令 K_μ 为这个问题的相应的(随机)撤出时间, 证明

$$m(x_0) = \max_{\mu} \frac{E\{K_\mu \text{ 以前的折扣报酬}\}}{1 - E\{\alpha^{K_\mu}\}},$$

且当 μ 为最优撤出策略时, 达到最大值。

21. 在具有单个顾客类的开放排队网络中, 确定瓶颈连接[S8]。考虑具有 n 个队列的网络, 在队列 i 中的一个顾客服务完成后以概率 p_{ij} 被引到队列 j , 而以概率 $1 - \sum_j p_{ij}$ 退出这个网络。对每个队列 i 记:

r_i : 外部顾客到达率;

$\frac{1}{\mu_i}$: 平均顾客服务时间;

λ_i : 顾客离开率,

a_i : 总的顾客到达率(外部到达率加上以相应概率加权的上游队列离开率)。

则有

$$a_i = r_i + \sum_{j=1}^n x_j p_{ji}, \text{ 对所有 } i,$$

而且我们假定到达率 a_i 超过服务率 μ_i 的任何部分都丢失; 于是在队列 i 的离开率满足

$$\lambda_i = \min[\mu_i, a_i] = \min\left[\mu_i, r_i + \sum_{j=1}^n \lambda_j p_{ji}\right].$$

假定对至少一个 i , 有 $r_i > 0$; 对每个 $r_{i_1} > 0$ 的 i_1 队列, 存在一个队列 i , $1 - \sum_j p_{ji} > 0$, 而且序列 $i_1, i_2, \dots, i_k, i$ 使得 $p_{i_1 i_2} > 0, \dots, p_{i_k i} > 0$. 证明满足上面方程的离开率 λ_i 是唯一的, 而且可以由逐次逼近法或策略迭代求得。

提示: 这不是一个马尔科夫决策问题, 因为对于某个 i , 可能有 $\sum_j p_{ji} > 1$. 然而, 它可以根据 m 阶段收缩映射来进行分析, 这类似于首次通过问题(参考命题2)。

22. 一致化有效性的证明。完成如下论证的细节, 对有限个状态 $i = 1, \dots, n$ 的情况证明一致化形式的有效性。我们固定一个策略, 为记法上的简化, 我们并不证明转移率对控制的依赖情况。令 $p(t)$ 是一个行向量, 其元为

$$p_i(t) = P\{x(t) = i | x_0\}, \quad i = 1, \dots, n.$$

则有

$$dp(t)/dt = p(t)A,$$

其中 $p(0)$ 是一个行向量, 若 $x_0 = i$, 则其第 i 个元素为 1, 而其余的元素为零; 矩阵 A 具有元素

$$a_{ij} = \begin{cases} v_i p_{ij}, & \text{若 } i \neq j, \\ -v_i, & \text{若 } i = j. \end{cases}$$

由此得

$$p(t) = p(0)e^{At},$$

其中

$$e^{At} = \sum_{k=0}^{\infty} \frac{(At)^k}{k!}.$$

考虑一致化形式的转移概率矩阵 B

$$B = I + \frac{A}{v},$$

其中 $v \geq v_i$, $i = 1, \dots, n$. 再考虑如下方程

$$\begin{aligned} e^{At} &= e^{-vt} e^{Bvt} \\ &= e^{-vt} \sum_{k=0}^{\infty} \frac{(Bvt)^k}{k!}. \end{aligned}$$

利用这些关系式写出

$$p(t) = p(0) \sum_{k=0}^{\infty} \Gamma(k, t) B^k,$$

式中

$$\Gamma(k, t) = \frac{(pt)^k}{k!} e^{-pt}$$

= Prob{在一致化马尔科夫链中 0 与 t 之间发生 k 次转移}。

验证对 $i = 1, \dots, n$ 有

$$p_i(t) = \text{Prob}\{x(t) = i, \text{ 在一致化马尔科夫链中}\}.$$

23. 考虑具有可变服务率的 $M/M/1$ 排队问题 (§ 6.7 例题 2)。假定容许没有到达 ($\lambda = 0$)，且人们或以服务率 μ 服务于顾客，或者拒绝服务 ($M = \{0, \mu\}$)。令顾客等待的代价率和服务代价率分别为 $c(i) = c_i$ 和 $q(\mu)$ 。证明最优策略为一直服务于可服务的顾客，如果

$$\frac{q(\mu)}{\mu} \leq \frac{c}{\beta},$$

而其它情况下一直是拒绝服务。

24. 考虑一台机器，它可能损坏，也可以修理。在其处于运行的一个单位时间内，它产生一个 -1 单位负代价(利益)，而且以概率 0.1 可能损坏。当其损坏时，我们必须以耗费 u 去修理，使它在一个单位时间运行的概率是 u ，且代价是 cu^2 。对于具有折扣因子 $\alpha > 1$ 的无限时域问题，确定最优修理耗费。(这个问题可用解析求解。)

25. 证明 § 6.2 具有零固定代价库存问题的临界水平 S^* ，使 $(1-\alpha)cy + L(y)$ 对 y 为极大。

提示：证明代价可表示为

$$J_\pi(x_0) = E\left\{\sum_{k=0}^{\infty} \alpha^k [(1-\alpha)cy_k + L(y_k)] + \frac{c\alpha}{1-\alpha} E\{w\} - cx_0\right\},$$

其中 $y_k = x_k + \mu_k(x_k)$ 。

第七章 每阶段平均代价的极小化

前两章的结果可用于总期望代价至少对某些初始状态为有限的问题。我们看到,对于几类类型的问题,或通过折扣因子,或通过系统最终要进入或逼近的无代价吸收态,是可能做到这一点的。另一方面,在许多情况下,对每一个策略和初始状态,总期望代价

$$\lim_{N \rightarrow \infty} E \left\{ \sum_{k=0}^{N-1} g[x_k, \mu_k(x_k), w_k] \right\} \quad (7.1)$$

是无限的,但极限

$$\lim_{N \rightarrow \infty} \frac{1}{N} E \left\{ \sum_{k=0}^{N-1} g[x_k, \mu_k(x_k), w_k] \right\} \quad (7.2)$$

存在且有限。表达式(7.2)可看作为每阶段平均代价,而且是最优化一个合理有意义的判据。除了对式(7.2)每阶段平均代价求极小代替式(7.1)总期望求极小之外,本章将处理类似于第五章的问题。而且,在前三节,我们将限于有限状态空间,控制空间和扰动空间的情况。因此,一开始就换用更适合于有限状态系统的记法。

令 $S = \{1, \dots, n\}$ 表示状态空间,正如 § 5.2 所讨论的那样,对每个状态 $i \in S$, 和有限控制空间 C 中的控制 u , 相应地有一个转移概率 $p_{ij}(u)$, $j = 1, \dots, n$ 的集合。系统处在状态 i 和施加控制 u 的每一个时刻,我们引出一个期望代价,记为 $g(i, u)$, 而且系统以概率 $p_{ij}(u)$ 转移到状态 j 。目标是,对所有容许策略 $\pi = \{\mu_0, \mu_1, \dots\}$, $\mu_k: S \rightarrow C$, $\mu_k(i) \in U(i)$, 对所有 $i \in S$, 使得每阶段平均代价^[原注]

$$J_\pi(x_0) = \lim_{N \rightarrow \infty} \frac{1}{N} E \left\{ \sum_{k=0}^{N-1} g[x_k, \mu_k(x_k)] \right\}, \quad (7.3)$$

对任意给定的初始状态 $x_0 \in S$ 为极小。

平均代价的表达式

现在我们初步讨论一下这个问题,以促进在下一节得到某些结果。给定任意平稳策略 $\pi = \{\mu, \mu, \dots\}$, 用 P_π 表示转移概率矩阵,其元素为 $p_{ij}[\mu(i)]$:

$$P_\pi = \begin{bmatrix} p_{11}[\mu(1)] & \cdots & p_{1n}[\mu(1)] \\ \vdots & \ddots & \vdots \\ p_{n1}[\mu(n)] & \cdots & p_{nn}[\mu(n)] \end{bmatrix}. \quad (7.4)$$

矩阵 P_π 可以用来表示相应于一个平稳策略 $\pi = \{\mu, \mu, \dots\}$ 的 m 步转移概率。我们有

$$p_{ij}[\mu(i)] = P(x_{k+1} = j | x_k = i, \pi),$$

原注: 当不知式(7.3)中的极限存在时,我们定义平均代价为

$$J_\pi(x_0) = \limsup_{N \rightarrow \infty} \frac{1}{N} E \left\{ \sum_{k=0}^{N-1} g[x_k, \mu_k(x_k)] \right\}.$$

然而,我们将证明,式(7.3)的极限至少对那些感兴趣的策略 π 存在,这将成为我们以后分析的一部分。

最基本的是证明如下关系式(见附录D)

$$[P_\mu^m]_{ij} = P(x_{k+m} = j | x_k = i, \pi),$$

其中 $[P_\mu^m]_{ij}$ 为矩阵 P_μ^m (即 P_μ 的 m 次方)的第 i 行、第 j 列的元素。

这些概率可以用来表示式(7.3)的代价 $J_\pi(x_0)$ 。如前述一样,对平稳策略 $\pi = \{\mu, \mu, \dots\}$,我们采用记法

$$J_\pi(i) = J_\mu(i), \quad i = 1, \dots, n.$$

记

$$J_\mu = \begin{bmatrix} J_\mu(1) \\ J_\mu(2) \\ \vdots \\ J_\mu(n) \end{bmatrix}, \quad g_\mu = \begin{bmatrix} g[1, \mu(1)] \\ g[2, \mu(2)] \\ \vdots \\ g[n, \mu(n)] \end{bmatrix}. \quad (7.5)$$

利用这些记法,可以看出

$$J_\mu = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=0}^{N-1} P_\mu^k g_\mu. \quad (7.6)$$

下面的结果将证明 J_μ 是适当定义的。这是转移概率矩阵的一个标准结果,其证明在本章的附录(命题 A7.1)中给出。

引理 1 对于任意 $n \times n$ 随机矩阵 P , 即其元素为 p_{ij} 的矩阵, 满足

$$p_{ij} \geq 0, \quad i, j = 1, \dots, n, \quad \sum_{j=1}^n p_{ij} = 1, \quad i = 1, \dots, n,$$

则有

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=0}^{N-1} P^k = P^*, \quad (7.7)$$

其中 P^* 是一个随机矩阵, 具有如下性质:

- (a) $P^* = PP^* = P^*P = P^*P^*$;
- (b) $(I - P + P^*)$ 为可逆阵, 其中 I 为 $n \times n$ 单位阵。

利用引理 1 写出

$$P_\mu^* = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=0}^{N-1} P_\mu^k, \quad (7.8)$$

而且从式(7.6)有

$$J_\mu = P_\mu^* g_\mu \quad (7.9)$$

于是, 对每个容许的平稳策略, 相应的每阶段平均代价是有定义的, 且方便地用式(7.9)表示。这一方程有一个自然的解释。利用式(7.8), 我们看出: P_μ^* 的第 (i, j) 个元素就是当初始状态为 i , 系统到达状态 j 的时间的长期部分。所以, 式(7.9)说明 $J_\mu(i)$ 是在状态 j 所引起的代价 $g[j, \mu(j)]$ 对所有 j 之和, 并由初始状态 i 到达状态 j 的时间部分所加权。

平均代价对初始状态的依赖

关于式(7.2)每阶段平均代价需要记住的一个重要事实是: 它主要表示在长期中所引起的代价。在初始阶段(比方说头 k 个阶段)引起的代价并不起作用, 因为它们对每阶段平均代

价的贡献当 $N \rightarrow \infty$ 时趋于零, 即

$$\lim_{N \rightarrow \infty} \frac{1}{N} E \left\{ \sum_{k=0}^K g[x_k, \mu_k(x_k)] \right\} = 0. \quad (7.10)$$

现在考虑一个平稳策略 $\{\mu, \mu, \dots\}$, 以及两个状态 i 和 j , 使得在 μ 作用下, 系统由 i 开始以概率 1 最终到达 j 。那么, 直观上显然的是: 无论从 i 或 j 起始, 其每阶段平均代价不可能有差别, 因为由 i 到 j 过程中所引起的代价, 实质上对每阶段平均代价并没有什么贡献 [见式 (7.10)]。更准确地说, 令 $K_{ij}(\mu)$ 是在策略 μ 下由 i 到 j 的首次通过时间; 即在策略 μ 下由 $x_0 = i$ 起始, 对 $x_k = j$ (见附录 D) 的第一个标号 k 。那么, 相应于初始条件 $x_0 = i$ 的每阶段平均代价可以表示为

$$J_\mu(j) = \lim_{N \rightarrow \infty} \frac{1}{N} E \left\{ \sum_{k=0}^{K_{ij}(\mu)-1} g[x_k, \mu(x_k)] \right\} + \lim_{N \rightarrow \infty} E \left\{ \frac{1}{N} \sum_{k=K_{ij}(\mu)}^N g[x_k, \mu(x_k)] \right\}.$$

如果 $E\{K_{ij}(\mu)\} < \infty$ (它等价于假设系统由 i 起始, 以概率 1 最终到达 j ; 见附录 D), 那么容易看出, 第一个极限是零, 而第二个极限等于 $J_\mu(j)$ 。因此对所有 i, j , 且 $E\{K_{ij}(\mu)\} < \infty$, 有

$$J_\mu(i) = J_\mu(j),$$

前面的论证提出, 最优代价

$$J^*(i) = \min_x J_\pi(i), \quad i = 1, \dots, n$$

在正常环境下也应独立于初始状态。为看清楚这一点, 假定对两个状态 i 和 j , 存在一个平稳策略 $\{\mu, \mu, \dots\}$, 使得 $E\{K_{ij}(\mu)\} < \infty$; 那么就不可能有

$$J^*(j) < J^*(i),$$

因为, 当从 i 起始时, 我们可采用策略 $\{\mu, \mu, \dots\}$, 直到首次到达 j 的时刻, 然后转换到由 j 起始的最优策略; 由此得到从 i 起始等于 $J^*(j)$ 的每阶段平均代价。事实上, 我们在命题 4 中将证明有

$$J^*(i) = J^*(j), \quad \text{对所有 } i, j = 1, \dots, n,$$

它是在更弱的假设条件下得出的, 即对每一对状态 i 和 j , 存在一个平稳策略 (依赖于 i 和 j), 按此策略, 由状态 i 起始以正概率到达 j 。

于是我们得出结论: 对于大多数感兴趣的问题, 每阶段最优平均代价与初始状态无关。由此, 我们将此看作为正常情况, 而且在本章的主要部分单独地专门讨论。在本章的附录中, 我们对更一般的情况给出分析。

贝尔曼方程的类似方程

下面我们将试图为平均代价问题推测贝尔曼方程的正常形式。考虑一个平稳策略 $\{\mu, \mu, \dots\}$, 以及相应于初始状态 x_0 的 N 阶段代价:

$$J_\mu^N(x_0) = E \left\{ \sum_{k=0}^{N-1} g[x_k, \mu(x_k)] \right\}.$$

我们已经看出 [见式 (7.6)], $\lim_{N \rightarrow \infty} (1/N) J_\mu^N(i) = J_\mu(i)$, 所以得

$$J_\mu^N(i) = N J_\mu(i) + \epsilon_N(i), \quad (7.11)$$

式中 $\epsilon_N(i)$ 使 $\lim_{N \rightarrow \infty} [\epsilon_N(i)/N] = 0$, 用 J_μ^N 和 ϵ_N 表示具有分量 $J_\mu^N(i)$ 和 $\epsilon_N(i)$, $i = 1, \dots, n$, 的向量, 我们把此关系写成

$$J_{\mu}^N = NJ_{\mu} + \epsilon_N.$$

把此方程代入 N 阶段代价通常的递推形式

$$J_{\mu}^{N+1} = g_{\mu} + P_{\mu} J_{\mu}^N,$$

得到

$$(N+1)J_{\mu} + \epsilon_{N+1} = g_{\mu} + NP_{\mu}J_{\mu} + P_{\mu}\epsilon_N. \quad (7.12)$$

除以 N , 并当 $N \rightarrow \infty$ 时取极限, 则可看出

$$J_{\mu} = P_{\mu}J_{\mu}. \quad (7.13)$$

注意, 不管 $J_{\mu}(i)$ 是否与初始状态 i 有关, 这一关系式[也可以由式(7.9)和引理 1(a) 得到]成立。而且, 由式(7.12)和式(7.13)有

$$J_{\mu} + \epsilon_{N+1} = g_{\mu} + P_{\mu}\epsilon_N, \quad N = 1, 2, \dots. \quad (7.14)$$

如果 $N \rightarrow \infty$ 时 $\epsilon_N(i)$ 趋于一个极限, 即

$$\lim_{N \rightarrow \infty} \epsilon_N(i) = h_{\mu}(i), \quad i = 1, 2, \dots, n, \quad (7.15)$$

对于某个 $h_{\mu}(i)$, $i = 1, \dots, n$, 则由式(7.14)得

$$J_{\mu} + h_{\mu} = g_{\mu} + P_{\mu}h_{\mu},$$

这就导出了由 J_{μ} 满足的泛函方程的正常形式[即类似于第五章 $J_{\mu} = J_{\mu}(j_{\mu})$], 由式(7.11)和式(7.15), 注意到当 $J_{\mu}(i)$ 与初始状态 i 无关时, 对任意 i 和 j 有

$$h_{\mu}(i) + h_{\mu}(j) = \lim_{N \rightarrow \infty} [J_{\mu}^N(i) - J_{\mu}^N(j)].$$

于是, 我们可以把 $h_{\mu}(i) - h_{\mu}(j)$ 看作为一个长期微分代价, 表示由状态 i 而不是状态 j 起始的总代价的长期差值(而不是每阶段平均)。

在通常情况下, $\epsilon_N(i)$ 如式(7.15)那样收敛于一个极限是不成立的, 主要是因为 $\epsilon_N(i)$ 可能有一个周期性分量(见下面的例题)。然而, 利用式(7.11) ϵ_N 的定义和引理 1(见习题 5), 可以证明

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^N \epsilon_k = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^N \epsilon_{k+1} = (I - P_{\mu} + P_{\mu}^*)^{-1} (I - P_{\mu}^*) g_{\mu} \triangleq h_{\mu}, \quad (7.16)$$

其中 P_{μ}^* 是由式(7.8)给出。对 $N = 1, 2, \dots$, 加上式(7.14)得

$$J_{\mu} + \frac{1}{N} \sum_{k=1}^N \epsilon_{k+1} = g_{\mu} + P_{\mu} \left(\frac{1}{N} \sum_{k=1}^N \epsilon_k \right).$$

于是, 利用式(7.16)我们看出, 不管式(7.15)的极限是否存在, 方程

$$J_{\mu} + h_{\mu} = g_{\mu} + P_{\mu}h_{\mu}$$

总成立。由式(7.11)和式(7.16)我们看出, 对于任意两个状态 i 和 j , 且 $J_{\mu}(i) = J_{\mu}(j)$,

$$h_{\mu}(i) - h_{\mu}(j) = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^N [J_{\mu}^k(i) - J_{\mu}^k(j)].$$

所以, 当 $J_{\mu}(i)$ 独立于初始状态 i 时, 我们再一次可以把 h_{μ} 看作为一个微分代价向量。

例题

假定存在两个状态, 且每阶段代价向量为

$$g_{\mu} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}.$$

情况 1: 令转移概率矩阵为

$$P_{\mu} = \begin{bmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} \end{bmatrix},$$

那么, 由式(7.8)和式(7.9)容易看出

$$P_{\mu}^* = \begin{bmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} \end{bmatrix}, \quad J_{\mu} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

N 阶段代价向量 J_{μ}^N 可以由如下递推公式计算

$$J_{\mu}^{N+1} = g_{\mu} + P_{\mu} J_{\mu}^N, \quad J_{\mu}^0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

利用归纳法可以验证

$$J_{\mu}^N = N J_{\mu} + \epsilon_N, \quad N = 1, 2, \dots,$$

其中

$$\epsilon_N = \begin{bmatrix} -1 \\ 1 \end{bmatrix}.$$

代价 $J_{\mu}^N(1)$ 和 $J_{\mu}^N(2)$ 示于图 7.1。在此情况下, ϵ_N 收敛于一个微分代价向量

$$h_{\mu} = \begin{bmatrix} -1 \\ 1 \end{bmatrix},$$

而且可很容易验证关系式 $J_{\mu} + h_{\mu} = g_{\mu} + P_{\mu} h_{\mu}$.

情况 2: 令转移概率矩阵是

$$P_{\mu} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix},$$

我们再次由式(7.8)和式(7.9)看出

$$P_{\mu}^* = \begin{bmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} \end{bmatrix}, \quad J_{\mu} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

利用归纳法可以验证

$$J_{\mu}^N = N J_{\mu} + \epsilon_N, \quad N = 1, 2, \dots,$$

其中

$$\epsilon_N = \begin{cases} \begin{bmatrix} 0 \\ 0 \end{bmatrix}, & \text{若 } N \text{ 是偶数,} \\ \begin{bmatrix} -1 \\ 1 \end{bmatrix}, & \text{若 } N \text{ 是奇数.} \end{cases}$$

代价 $J_{\mu}^N(1)$ 和 $J_{\mu}^N(2)$ 示于图 7.2。在此情况下, ϵ_N 并不收敛, 而反映了马尔科夫链的周期行




图 7.1 微分代价作为有限时域差分极限的图解说明。




图 7.2 当有限时域代价差值不收敛于一个极限时, 微分代价的图解说明。

为。然而, ϵ_N 在式(7.16)的意义下收敛于一个微分代价向量

$$h_\mu = \begin{bmatrix} -\frac{1}{2} \\ \frac{1}{2} \end{bmatrix},$$

满足方程 $J_\mu + h_\mu = g_\mu + P_\mu h_\mu$.

受 J_μ 的泛函方程的启发, 自然会猜想: 当最优平均代价与初始状态无关时, 平均代价问题的贝尔曼最优性方程取如下形式

$$\lambda + h(i) = \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u) h(j) \right], \quad i = 1, \dots, n, \quad (7.17)$$

其中对所有 i , $\lambda = J^*(i)$, 且 $h(i)$, $i = 1, \dots, n$ 为某些标量。如前面讨论的那样, 具有一个微分代价的解释。而且, 通过在式(7.17)中求极小, 得到一个最优平稳策略应该是可能的。下一节我们将演示这一事实。§ 7.2 和 § 7.3 处理计算方法, 而 § 7.4 讨论无限状态情况, 尤其是线性二次型问题的平均代价形式。

本章的主体部分无例外针对最优代价对所有初始状态都是相等的情况。如前面讨论的那样, 这正是实际中正常出现的情况。然而, 对不同初始状态最优代价可不同的更一般的情况, 其分析是确实令人感兴趣的, 因为它对较简单情况, 提供了深入的剖析和证明方法, 而由其方法是难以得到的。这一分析主要是对水平较高的读者, 列于本章的附录。

§ 7.1 最优性条件

首先我们引入在第五和第六章广泛应用的映射 T 和 T_μ 。因此, 按如下方程, T 把一个 n 维向量 h 映射到另一个 n 维向量 $T(h)$,

$$T(h)(i) = \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u) h(j) \right], \quad i = 1, \dots, n. \quad (7.18)$$

对于任意平稳策略 $\{\mu, \mu, \dots\}$, 相应的映射 T_μ 是由下式给出

$$T_\mu(h)(i) = g[i, \mu(i)] + \sum_{j=1}^n p_{ij}[\mu(i)] h(j), \quad i = 1, \dots, n. \quad (7.19)$$

记 M 为所有容许控制函数 μ 的集合, 我们可把这些映射以更紧凑的形式写成

$$T(h) = \min_{\mu \in M} [g_\mu + P_\mu h], \quad (7.20)$$

$$T_\mu(h) = g_\mu + P_\mu h, \quad \text{对所有 } \mu \in M, \quad (7.21)$$

其中 g_μ 和 P_μ 是由式(7.4)和式(7.5)给出。式(7.20)的求极小是指对每个状态分别进行的。

这些映射具有基本的单调性质:

$$h \leq h' \Rightarrow T(h) \leq T(h'),$$

$$h \leq h' \Rightarrow T_\mu(h) \leq T_\mu(h'), \quad \mu \in M,$$

如前面所说, 其中不等式假定为对每个状态单独成立。下面我们将应用 n 维单位向量

$$e = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}.$$

注意, 若 r 是一个标量, 则

$$T(h+re) = T(h) = re, \quad (7.22a)$$

$$T_\mu(h+re) = T_\mu(h) + re, \quad \mu \in M. \quad (7.22b)$$

第一个结果对各个初始状态其最优代价相等的情况引入了贝尔曼方程的类似方程。命题将证明该方程的所有解与最优代价和相应的微分代价相一致。然而, 它并不能保证方程有解。为此要求进一步的假设条件, 下面给出此条件。

命题 1 如果一个标量 λ 和一个 n 维向量 h 满足

$$\lambda + h(i) = \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u) h(j) \right], \quad i = 1, \dots, n, \quad (7.23)$$

或等价地

$$\lambda e + h = T(h), \quad (7.24)$$

则 λ 为对所有 i 代价 $J_\pi(i)$ 的最优值:

$$\lambda = \min_{\pi} J_\pi(i) = J^*(i), \quad i = 1, 2, \dots, n. \quad (7.25)$$

而且, 若 $\mu^*(i)$ 在式(7.23)中对每个 i 达到极小, 平稳策略 $\{\mu^*, \mu^*, \dots\}$ 就是最优的; 即对所有 $i, J_{\mu^*}(i) = J^*(i) = \lambda$ 。

证明: 令 $\pi = \{\mu_0, \mu_1, \dots\}$ 为任意的容许策略, $N > 0$ 是一个整数, 由式(7.23)有

$$\lambda e + h \leq T_{\mu_{N-1}}(h).$$

根据单调性质, 若 $T_{\mu_{N-2}}$ 作用于两边, 这个不等式维持不变。因此, 利用式(7.22)和式(7.23)得

$$2\lambda e + h \leq \lambda e + T_{\mu_{N-2}}(h) \leq (T_{\mu_{N-2}} T_{\mu_{N-1}})(h).$$

以此方式继续下去, 我们最终得

$$N\lambda e + h \leq (T_{\mu_0} T_{\mu_1} \dots T_{\mu_{N-1}})(h). \quad (7.26)$$

如果每个 $\mu_k, k = 0, 1, \dots, N-1$ 在式(7.23)中达到极小, 则等式成立。我们有

$$(T_{\mu_0} T_{\mu_1} \dots T_{\mu_{N-1}})(h)(i) = E \left\{ h(x_N) + \sum_{k=0}^{N-1} g[x_k, \mu_k(x_k)] \mid x_0 = i, \pi \right\}.$$

利用式(7.26)中的等式, 得

$$\lambda + \frac{1}{N} h(i) \leq \frac{1}{N} E \{ h(x_N) \mid x_0 = i, \pi \} + \frac{1}{N} E \left\{ \sum_{k=0}^{N-1} g[x_k, \mu_k(x_k)] \mid x_0 = i, \pi \right\},$$

而且当 $N \rightarrow \infty$ 时取极限, 有

$$\lambda \leq J_\pi(i), \quad i = 1, \dots, n.$$

若 $\mu_k(i), k = 0, 1, \dots$, 在式(7.23)中达到极小值, 等式成立。

证毕

注意, 即使状态空间和控制空间是无限的, 只要函数 h 是有界的, 而且对每个 i , 式(7.23)中的极小值能达到, 仍能完成证明。又, 命题 1 的反命题也是成立的; 即如果 $J^*(i) = \lambda, i = 1, \dots, n$, 对某个标量 λ 成立, 则 λ 连同向量 h 满足最优性方程式(7.23)。然而, 这一结论的证明需要本章附录中导出的方法(见命题 A7.3 和 A7.4)。

现在给定一个平稳策略 $\pi = \{\mu, \mu, \dots\}$, 如在前两章一样, 我们可以考虑一个问题, 其中

约束集合 $U(i)$ 由集合 $\tilde{U}(i) = \{\mu(i)\}$ 代替; 即 $\tilde{U}(i)$ 含单一的元素——控制 $\mu(i)$ 。因为对此问题仅有一个容许策略, 即策略 $\{\mu, \mu, \dots\}$, 应用命题 1 产生了如下推论。

推论 1.1 令 $\pi = \{\mu, \mu, \dots\}$ 为一个平稳策略, 如果对所有 $i \in S$, 一个标量 λ_μ 和一个 n 维向量 h_μ , 满足

$$\lambda_\mu + h_\mu(i) = g[i, \mu(i)] + \sum_{j=1}^n p_{ij}[\mu(i)] h_\mu(j),$$

或等价地

$$\lambda_\mu e + h_\mu = T_\mu(h_\mu),$$

则

$$\lambda_\mu = J_\mu(i), \quad i = 1, 2, \dots, n.$$

现在我们转到寻求满足贝尔曼方程式(7.23)的 λ 和 h 保证存在的条件。与此同时, 我们将建立与第五章折扣代价问题的联系。

考虑折扣代价

$$\lim_{N \rightarrow \infty} E \left\{ \sum_{k=0}^{N-1} \alpha^k g[x_k, \mu_k(x_k)] \right\}, \quad 0 < \alpha < 1.$$

令 $J_\alpha(i)$ 为相应初始状态 i 的代价的最优值, § 5.1 的命题 2 证明, J_α 为如下最优性方程的唯一解

$$J_\alpha(i) = \min_{u \in U(i)} \left[g(i, u) + \alpha \sum_{j=1}^n p_{ij}(u) J_\alpha(j) \right], \quad i = 1, \dots, n. \quad (7.27)$$

令 s 是 S 中的任一个状态, 定义

$$h_\alpha(i) = J_\alpha(i) - J_\alpha(s), \quad i = 1, \dots, n, \quad (7.28)$$

利用式(7.27)从式(7.28)中消去 $J_\alpha(i)$ 得

$$\begin{aligned} h_\alpha(i) + J_\alpha(s) &= \min_{u \in U(i)} \left[g(i, u) + \alpha \sum_{j=1}^n p_{ij}(u) [h_\alpha(j) + J_\alpha(s)] \right] \\ &= \alpha J_\alpha(s) + \min_{u \in U(i)} \left[g(i, u) + \alpha \sum_{j=1}^n p_{ij}(u) h_\alpha(j) \right], \end{aligned}$$

由此得

$$(1 - \alpha) J_\alpha(s) + h_\alpha(i) = \min_{u \in U(i)} \left[g(i, u) + \alpha \sum_{j=1}^n p_{ij}(u) h_\alpha(j) \right]. \quad (7.29)$$

这一方程看起来与最优性方程式(7.23)很类似。特别地, 如果对某个序列 $\{\alpha_m\}$, 且 $0 < \alpha_m < 1$, $\alpha_m \rightarrow 1$, 我们有

$$\lim_{m \rightarrow \infty} (1 - \alpha_m) J_{\alpha_m}(s) = \lambda, \quad (7.30)$$

$$\lim_{m \rightarrow \infty} h_{\alpha_m}(i) = h(i), \quad i = 1, \dots, n, \quad (7.31)$$

(即上述极限存在), 则由式(7.29)得

$$\lambda + h(i) = \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u) h(j) \right], \quad i = 1, \dots, n.$$

且条件式(7.23)满足。下面的命题说明,存在序列 $\{\alpha_m\}$,使得式(7.30)和式(7.31)的极限存在的一个充分条件是:差值 $[J_\alpha(i) - J_\alpha(s)]$ 对 α 是一致有界的。

命题 2 假定存在一个常值 L , 使得对某个状态 $s \in S$ 有

$$|J_\alpha(i) - J_\alpha(s)| \leq L, \text{ 对所有 } i \in S, \alpha \in (0, 1). \quad (7.32)$$

则对某个序列 $\{\alpha_m\}$, $\alpha_m \in (0, 1)$ 及 $\alpha_m \rightarrow 1$, 对所有 i 有

$$\begin{aligned} h(i) &= \lim_{m \rightarrow \infty} [J_{\alpha_m}(i) - J_{\alpha_m}(s)], \\ \lim_{m \rightarrow \infty} (1 - \alpha_m) J_{\alpha_m}(i) &= \lambda, \end{aligned}$$

而 λ 和 h 满足最优性方程式(7.23)。

证明: 令 $\{\alpha_k\}$ 是任意序列, 使得 $\alpha_k \rightarrow 1$ 。由式(7.32), 序列 $\{J_{\alpha_k}(i) - J_{\alpha_k}(s)\}$ 是有界的。因此, 存在 $\{\alpha_k\}$ 的一个子序列, 比如说 $\{\alpha_m\}$, 使得对每个 i , $\{J_{\alpha_m}(i) - J_{\alpha_m}(s)\}$ 收敛于一个极限 $h(i)$ 。如果 B 是一个常值, 使得对所有 i 和 $u \in U(i)$ 有 $|g(i, u)| \leq B$, 则

$$|J_{\alpha_m}(s)| \leq B(1 - \alpha_m)^{-1}.$$

因此, 序列 $\{(1 - \alpha_m) |J_{\alpha_m}(s)|\}$ 是有界的。于是存在 $\{\alpha_m\}$ 的一个子序列, 比方说 $\{\alpha_{m'}\}$, 使

$$(1 - \alpha_{m'}) J_{\alpha_{m'}}(s) \rightarrow \lambda.$$

得由式(7.29)有

$$(1 - \alpha_{m'}) J_{\alpha_{m'}}(s) + h_{\alpha_{m'}}(i) = \min_{u \in U(i)} \left[g(i, u) + \alpha_{m'} \sum_{j=1}^n p_{ij}(u) h_{\alpha_{m'}}(j) \right].$$

取极限, 而且交换求极限和求极小的次序(利用 $U(i)$ 的有限性), 即得式(7.23)。证毕

回顾一下, 如果每两个状态彼此互通, 马尔科夫链称为是不可约的。这就等价于存在包括所有状态的单个遍历类, 并意味着任意两个状态之间的首次通过时间是有限的(见附录 D)。下面的命题提出对所有初始状态最优代价相同的最简单(也是限制最多的)条件。

命题 3 假定每个平稳策略产生一个不可约马尔科夫链, 则存在一个标量 λ 和一个向量 h , 使得对所有 $i \in S$ 有

$$\lambda + h(i) = \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u) h(j) \right],$$

且(由命题 1)

$$\lambda = J^*(i), \quad i = 1, \dots, n,$$

而且当 $\mu^*(i)$ 对每个 i 达到上述最小值时, 平稳策略 $\{\mu^*, \mu^*, \dots\}$ 是最优的。

证明: 对任意 $\alpha \in (0, 1)$, 令 $\{\mu_\alpha, \mu_\alpha, \dots\}$ 为使相应折扣代价为最小的一个策略。如果 B 使得所有 $i \in S$ 和 $u \in U(i)$, $|g(i, u)| \leq B$, 则对每个 $i \in S$ 和 $s \in S$ 有

$$\begin{aligned} J_\alpha(i) &= E \left\{ \sum_{k=0}^{K_{i,s}(\mu_\alpha)-1} \alpha^k g[x_k, \mu_\alpha(x_k)] + \sum_{k=K_{i,s}(\mu_\alpha)}^{\infty} \alpha^k g[x_k, \mu_\alpha(x_k)] \mid x_0 = i \right\} \\ &\leq B E\{K_{i,s}(\mu_\alpha)\} + J_\alpha(s), \end{aligned}$$

其中 $K_{i,s}(\mu_\alpha)$ 就是在 μ_α 策略下由 i 到 s 的首次通过时间。这一假设意味着 $E\{K_{i,s}(\mu_\alpha)\}$ 对 i , s 和 μ_α 是一致有界的。因而差值 $J_\alpha(i) - J_\alpha(s)$ 对 i, s 和 α 也是一致有界的, 且命题 2 的假设得以满足。这一结论就由命题 1 和 2 得出。证毕

命题 3 可以在更弱的假设下证明。强化的形式在本章附录中给予证明。

命题 4 假定下列条之一成立:

(a) 每一个平稳策略产生具有单一遍历类的马尔科夫链;

(b) 对每两个状态 i 和 j , 存在一个平稳策略 π , 使得对某个 k 有

$$P(x_k = j | x_0 = i, \pi) > 0.$$

则命题 3 的结论成立。

证明: 见本章附录。在条件(a)下, 单独的证明也能从下面的命题 8 得到。

所列条件可能是保证最优每阶段平均代价独立于初始状态的最弱的条件。当然很明显, 某种可接受条件必须由相应于平稳策略, 或者至少相应于最优平稳策略的转移概率矩阵来满足。因为若存在两个状态, 无论我们采用什么样的策略, 其中没有一个能由另外一个达到, 则只有在很偶然的情况下每个状态的最优策略彼此才是相同的。一个极端的例子就是, 状态被迫处在相同的位置, 而不管所加控制(即每个状态是吸收的)。那么, 对每个状态 i 的最优每阶段平均代价为 $\min_{u \in U(i)} g(i, u)$, 而这一代价对不同的状态可能不同。

对于任意平稳策略 $\{\mu, \mu, \dots\}$, 我们可考虑在状态 i 仅有控制 $\mu(i)$ 可用的问题。那么, 我们可得到命题 4 的如下推论。这个推论的证明可以通过对命题 3 的证明稍加修改而得到。

推论 4.1 令 $\pi = \{\mu, \mu, \dots\}$ 是一个平稳策略, 产生一个具有单一遍历类的马尔科夫链, 那么存在一个常数 λ_μ 和一个向量 h_μ , 使得

$$J_\mu(i) = \lambda_\mu, \quad i = 1, \dots, n, \quad (7.33)$$

以及

$$\lambda_\mu + h_\mu(i) = g[i, \mu(i)] + \sum_{j=1}^n p_{ij}[\mu(i)] h_\mu(j), \quad i = 1, \dots, n. \quad (7.34)$$

方程(7.34)表示一组 n 个线性方程, 具有 $(n+1)$ 个未知数: 标量 $\lambda_\mu, h_\mu(1), h_\mu(2), \dots, h_\mu(n)$ 。我们可以通过使

$$h_\mu(s) = 0, \quad (7.35)$$

式中 s 为状态中的任一个, 在上述方程组增加一个附加方程。若 $\{\lambda_\mu, h_\mu(1), \dots, h_\mu(n)\}$ 是式(7.34)的一个解, 则 $\{\lambda_\mu, h_\mu(1) + r, \dots, h_\mu(n) + r\}$, r 为任意标量, 也是式(7.34)的一个解, 由此就丧失了自由度。在所述的条件下, 推论 4.1 肯定了方程组式(7.34)和(7.35)至少有一个解。现在我们证明这个解是唯一的。

命题 5 对于具有单一遍历类马尔科夫链所产生的每一个平均稳略 $\pi = \{\mu, \mu, \dots\}$, 方程组式(7.34)和(7.35)具有唯一解。

证明: 令 $\{\lambda, h(1), \dots, h(n)\}$ 和 $\{\lambda', h'(1), \dots, h'(n)\}$ 是两个解, 根据推论 1.1 有 $\lambda = \lambda' = \lambda_\mu$ 。因此, 由式(7.34), 对每个 $m \geq 1$ 得

$$h - h' = P_\mu(h - h') = P_\mu^m(h - h'),$$

或等价地

$$h(i) - h'(i) = \sum_{j=1}^n p_{ij}^m(\mu) [h(j) - h'(j)], \quad i = 1, \dots, n.$$

首先假定式(7.35)中的状态 s 属于这个遍历类, 则对某个 $m_i \geq 1$ 和 $\epsilon > 0$ 得

$$p_{ii}^{m_i}(\mu) \geq \epsilon > 0,$$

而且由式(7.35)有 $h(s) - h'(s) = 0$ 。因此

$$\begin{aligned}
|h(i) - h'(i)| &\leq \sum_{j=1}^n p_{ij}^m(\mu) |h(j) - h'(j)| \\
&= \sum_{j \neq i} p_{ij}^m(\mu) |h(j) - h'(j)| \\
&\leq (1 - \epsilon) \max_j |h(j) - h'(j)|.
\end{aligned}$$

于是我们得:

$$\max_j |h(j) - h'(j)| \leq (1 - \epsilon) \max_j |h(j) - h'(j)|,$$

而且对所有 j 有 $h(j) = h'(j)$.

现在考虑式(7.35)中的状态 s 并不属于这个遍历类的情况。我们在这个遍历类选择另一个状态 $\bar{s}$, 而且定义

$$\bar{h}(i) = h(i) - h(\bar{s}), \quad \bar{h}'(i) = h'(i) - h'(\bar{s}).$$

那么, $\{\pi, \bar{h}(1), \dots, \bar{h}(n)\}$ 和 $\{\lambda', \bar{h}'(1), \dots, \bar{h}'(n)\}$ 都是式(7.34)的解, 且 $h_\mu(\bar{s}) = 0$ 。根据前面的论证, 则有 $\bar{h} = \bar{h}'$, 此即意味着 $h = h'$ 。证毕

现在我们用一个例题来结束这一节。

机器更换问题。考虑一台机器, 它可以处在 n 个状态 $S = \{1, 2, \dots, n\}$ 中的任一个状态。这儿的含义是, 状态 i 优于状态 $i+1$, 而状态 1 相应于机器处在完好状态。当机器处在状态 i 时, 每单位时间的运行代价记为 g_i , 且假定

$$0 \leq g_1 \leq g_2 \leq \dots \leq g_n. \quad (7.36)$$

在运行的时间段内, 转移概率满足

$$\begin{aligned}
p_{ij} &= 0, & \text{若 } j < i, \\
p_{ij} &< 1, & i = 1, \dots, n-1.
\end{aligned}$$

即机器在使用中不可能返回到更好的状况。我们还假定对任意非减函数 J 有

$$i \leq i' \Rightarrow \sum_{j=1}^n p_{ij} J(j) \leq \sum_{j=1}^n p_{i'j} J(j). \quad (7.37)$$

在每个周期开始, 机器的状态是确定的。必须做出一个决策: 是否以代价 $R > 0$ 用一台新机器更换这台机器, 即处在状态 1 或继续运行。于是, 存在两种可能的控制: 更换和不更换。这个问题就是寻求一种策略, 使每阶段平均代价为极小。

注意, 命题 3 和 4 的假设对此问题并不满足。比如, 考虑一种平稳策略, 除了最坏状态 n 之外, 在每个状态都更换机器(一种不合理但却合法的选择)。相应的马尔科夫链具有两个遍历类 $\{1, 2, \dots, n-1\}$ 和 $\{n\}$ 。还可以看出, 在没有进一步假设的情况下, 不能保证命题 4 的条件(b)得以满足。然而, 我们能够利用命题 2 去论证。

考虑具有一个折扣因子 $\alpha < 1$ 的相应的折扣问题。则对所有 i 有

$$J_\alpha(i) = \min \left[R + g_i + \alpha \sum_{j=1}^n p_{ij} J_\alpha(j), g_i + \alpha \sum_{j=1}^n p_{ij} J_\alpha(j) \right].$$

从而有

$$J_\alpha(i) - J_\alpha(1) = \min \left[R, (g_i - g_1) + \alpha \sum_{j=1}^n (p_{1j} - p_{ij}) J_\alpha(j) \right] \leq R.$$

利用式(7.36)和式(7.37)容易证明: 对所有 $\alpha \in (0, 1)$ 有

$$0 \leq J_\alpha(i) - J_\alpha(1), \quad i = 1, 2, \dots, n.$$

而且, $J_\alpha(i) - J_\alpha(1)$ 对 i 是非递减的。因此由命题 2, 存在一个标量 λ 和一个非递减函数 h , 使得

$$\lambda + h(i) = \min \left[R + g_1 + \sum_{j=1}^n p_{1j} h(j), g_1 + \sum_{j=1}^n p_{ij} h(j) \right], \quad i = 1, 2, \dots, n,$$

而且选择极小行动的策略是平均代价最优的。令

$$i^* = \max \left\{ i \mid g_i + \sum_{j=1}^n p_{ij} h(j) \leq R + g_1 + \sum_{j=1}^n p_{1j} h(j) \right\},$$

则当目前的状态大于 i^* 时更换, 否则不更换的策略是最优的。

§ 7.2 逐次逼近、误差界限和线性规划解

对于平均代价问题, 逐次逼近法的一种自然形式是简单地逐次产生由零函数 $J_0 \equiv 0$ 起始的 N 阶段最优代价 $J_0, T(J_0), \dots, T^k(J_0), \dots$ 。通过集中讨论单个平稳策略 $\{\mu, \mu, \dots\}$ 及考虑迭代

$$J_\mu^0 = 0, \quad J_\mu^{k+1} = T_\mu(J_\mu^k) = g_\mu + P_\mu J_\mu^k, \quad (7.38)$$

我们可得到有关这一方法的本质和适当实现的某些见解。显然, J_μ^k 是相应于 μ 的 k 阶段代价向量, 如在本章引言中讨论的那样, 有

$$J_\mu^k = kJ_\mu + \epsilon_k, \quad (7.39)$$

其中 J_μ 为对 μ 的平均代价向量, 而 ϵ_k 是一个向量, 在如下意义下收敛到某个 h_μ :

$$h_\mu = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^N \epsilon_k \quad (7.40)$$

(而且在很多情况下, 意即 $\lim_{k \rightarrow \infty} \epsilon_k = h_\mu$)。

而且, 我们有

$$J_\mu + h_\mu = T_\mu(h_\mu), \quad (7.41)$$

且差值 $h_\mu(i) - h_\mu(j)$ 具有长期微分代价的含义。

我们可通过递推产生 $J_\mu^k, k = 0, 1, \dots$, 并取极限 $\lim_{k \rightarrow \infty} (1/k) J_\mu^k$ 来确定 J_μ 。但这有两个缺点。首先, J_μ^k 在典型情况下要发散到 $+\infty$ 或 $-\infty$, 所以, 直接数值计算 $\lim_{k \rightarrow \infty} (1/k) J_\mu^k$ 是不切实际的。其次, 它并不能给我们提供相应的微分代价向量 h_μ 。我们通过递推产生 J_μ^k , 而不是收敛于 h_μ 的序列 $\{h^k\}$, 从而避开了这两个困难。然后可按式(7.41)得到平均代价向量 J_μ 。实际上, 我们并不真正需要式(7.40)的 h_μ ; 对每一个分量, 任何向量 h_μ , 只要从式(7.40)中的一个减去同一常量, 就足以由式(7.41)来确定 J_μ 。为消去这一自由度, 我们要求对某个固定的状态 s 使

$$h_\mu^k(s) = 0. \quad (7.42)$$

有了这一点, 考虑迭代

$$h^{k+1} = T_\mu(h^k) - T_\mu(h^k)(s)e, \quad (7.43)$$

其中对所有 i ,

$$T_{\mu}(h^k)(i) = g[i, \mu(i)] + \sum_{j=1}^n p_{ij}[\mu(i)]h^k(j), \quad (7.44)$$

$e = [1, 1, \dots, 1]'$ 是单位向量。一个重要的结果是, 如果序列 $\{h^k\}$ 收敛, 比如说收敛到 h_{μ} , 则必有[见式(7.43)]

$$T_{\mu}(h_{\mu})(s)e + h_{\mu} = T_{\mu}(h_{\mu}).$$

由推论 1.1, 此即意味着 $T_{\mu}(h_{\mu})(s)$ 就是相应于 μ 的平均代价, 而 h_{μ} 就是与之有关的微分代价向量。

再考虑由下式给出的迭代式(7.43)的多重策略形式

$$h^{k+1} = T(h^k) - T(h^k)(s)e, \quad (7.45)$$

其中对所有 i ,

$$T(h^k)(i) = \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u)h^k(j) \right]. \quad (7.46)$$

如果这一迭代收敛到某个向量 h , 则必有

$$T(h)(s)e + h = T(h).$$

由命题 1, 此即意味着 $T(h)(s)$ 是平均代价的最优值, 而 h 是相应的微分代价向量。

下面的命题提出了一些条件, 在此条件下式(7.45)的收敛得以保证。作为理解这一命题假设的一种辅助手段, 我们首先注意, 这一收敛只有当最优平均代价与初始状态无关时才有希望。因此, 至少命题 2, 3 或 4 中一个的假设条件对收敛是需要的。这样一来, 就需要比命题中给出的更强的假设。水平较高的读者通过考虑迭代式(7.43)即可理解其中的原因。利用式(7.44), 能够写成

$$h^{k+1} = (I - ee')g_{\mu} + \tilde{P}_{\mu}h^k, \quad (7.47)$$

其中

$$\tilde{P}_{\mu} = (I - ee')P_{\mu}$$

而 e_s 是第 s 个座标向量, 即除了第 i 个分量为 1, 其余分量为零的向量。因此, 迭代式(7.43)的收敛性取决于 $\tilde{P}_{\mu}$ 的所有特征值是否严格处在单位圆内。利用 $P_{\mu}e = e$ 和 $e'e = 1$ 的事实, 有

$$\begin{aligned} \tilde{P}_{\mu}^2 &= (P_{\mu} - ee'e)(P_{\mu} - ee'e) = P_{\mu}^2 - P_{\mu}ee'e - ee'eP_{\mu}^2 + ee'eP_{\mu}ee'eP_{\mu} \\ &= P_{\mu}^2 - ee'eP_{\mu}^2 = P_{\mu}\tilde{P}_{\mu}, \end{aligned}$$

从而对所有 $k > 1$, 有

$$\tilde{P}_{\mu}^k = P_{\mu}^{k-1}\tilde{P}_{\mu}. \quad (7.48)$$

利用这一方程可以证明, 除了 $\tilde{P}_{\mu}$ 有一个零特征值取代 P_{μ} 的单个特征值 1 之外, $\tilde{P}_{\mu}$ 和 P_{μ} 具有相同的特征值。因此, 为使式(7.43)收敛, P_{μ} 的所有特征值, 除了单个的特征值 1 之外, 都应严格处在单位圆内。这一条件当 P_{μ} 具有多个遍历类时遭到破坏, 在此情况下, 1 是多重特征值; 而且当 P_{μ} 具有一个周期性结构和某些非 1 特征值处在单位圆上时, 该条件也受到破坏。

命题 6 假定存在一个正整数 m , 对每一组控制函数 $\mu_0, \mu_1, \dots, \mu_m$, 且 $\mu_k(i) \in U(i)$, $i = 1, \dots, n$, $k = 0, \dots, m$, 存在一个 $\epsilon > 0$ 和一个状态 x , 使得

$$[P_{\mu_m} P_{\mu_{m-1}} \cdots P_{\mu_1}]_{ix} \geq \epsilon, \quad i = 1, \cdots, n, \quad (7.49)$$

$$[P_{\mu_{m-1}} P_{\mu_{m-2}} \cdots P_{\mu_0}]_{ix} \geq \epsilon, \quad i = 1, \cdots, n, \quad (7.50)$$

其中 $[\cdot]_{ix}$ 表示相应矩阵的第 i 行第 x 列元素。固定一个状态 $s \in S$, 考虑算法

$$h^{k+1}(i) = T(h^k)(i) - T(h^k)(s), \quad i = 1, \cdots, n, \quad (7.51)$$

其中 $h^0(i)$ 是任意标量, 而映射 T 由式(7.46)给出。那么, 极限

$$h(i) = \lim_{k \rightarrow \infty} h^k(i), \quad i = 1, 2, \cdots, n \quad (7.52)$$

存在, 且有

$$\lambda = J^*(i), \quad i = 1, \cdots, n, \quad (7.53)$$

以及

$$\lambda + h(i) = T(h)(i), \quad i = 1, \cdots, n, \quad (7.54)$$

其中 $\lambda = T(h)(s)$ 。

证明: 记

$$q^k(i) = h^{k+1}(i) - h^k(i), \quad i = 1, 2, \cdots, n. \quad (7.55)$$

我们将证明, 对所有 i 和 $k \geq m$ 有

$$\max_i q^k(i) - \min_i q^k(i) \leq (1 - \epsilon) [\max_i q^{k-m}(i) - \min_i q^{k-m}(i)], \quad (7.56)$$

其中 m 和 ϵ 如假设所述。然后对某个 $B > 0$ 和所有 k , 由式(7.56)得

$$\max_i q^k(i) - \min_i q^k(i) \leq B(1 - \epsilon)^{k/m}.$$

因为, $q^k(s) = 0$, 从而对所有 i ,

$$|h^{k+1}(i) - h^k(i)| = |q^k(i)| \leq \max_j q^k(j) - \min_j q^k(j) \leq B(1 - \epsilon)^{k/m}.$$

所以对每个 $r > 1$ 和 i 有

$$\begin{aligned} |h^{k+r}(i) - h^k(i)| &\leq B(1 - \epsilon)^{k/m} \sum_{t=0}^{r-1} (1 - \epsilon)^{t/m} \\ &= \frac{B(1 - \epsilon)^{k/m} [1 - (1 - \epsilon)^{r/m}]}{1 - (1 - \epsilon)^{1/m}}, \end{aligned} \quad (7.57)$$

从而知 $\{h^k(i)\}$ 是一个柯西序列, 而且收敛到一个极限 $h(i)$ 。那么由式(7.51)看出

$$T(h)(s) + h(i) = T(h)(i), \quad i = 1, \cdots, n,$$

所以由命题 1, 对所有 i , 得 $\lambda = T(h)(s) = J^*(i)$ 。

为证明式(7.56), 我们用 $\mu_k(i)$ 表示一个控制, 它在下式

$$T(h^k)(i) = \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u) h^k(j) \right]$$

中, 对每个 k 和 i 达到极小。记

$$w_k = T(h^k)(s),$$

则有

$$h^{k+1} = g_{\mu_k} + P_{\mu_k} h^k - w_k e \leq g_{\mu_{k-1}} + P_{\mu_{k-1}} h^k - w_k e,$$

$$h^k = g_{\mu_{k-1}} + P_{\mu_{k-1}} h^{k-1} - w_{k-1} e \leq g_{\mu_k} + P_{\mu_k} h^{k-1} - w_{k-1} e,$$

其中 $e = [1, 1, \cdots, 1]'$ 是单位向量。由此关系式, 利用定义 $q^k = h^{k+1} - h^k$ 得:

$$P_{\mu_k} q^{k-1} + (w_{k-1} - w_k) e \leq q^k \leq P_{\mu_{k-1}} q^{k-1} + (w_{k-1} - w_k) e.$$

因为这一关系式对每个 $k \geq 1$ 成立, 通过迭代得:

$$\begin{aligned} P_{\mu_k} \cdots P_{\mu_{k-m+1}} q^{k-m} + (w_{k-m} - w_k) e &\leq q^k \\ &\leq P_{\mu_{k-1}} \cdots P_{\mu_{k-m}} q^{k-m} + (w_{k-m} - w_k) e. \end{aligned} \quad (7.58)$$

首先, 我们假定如在式(7.49)和式(7.50)中一样, 相应于 $\mu_{k-m}, \dots, \mu_k$ 的特定状态 x , 就是在迭代式(7.51)中的固定状态 s , 即

$$[P_{\mu_k} \cdots P_{\mu_{k-m+1}}]_{is} \geq \epsilon, \quad i = 1, \dots, n, \quad (7.59)$$

$$[P_{\mu_{k-1}} \cdots P_{\mu_{k-m}}]_{is} \geq \epsilon, \quad i = 1, \dots, n. \quad (7.60)$$

那么, 式(7.58)的右边得:

$$q^k(i) \leq \sum_{j=1}^n [P_{\mu_{k-1}} \cdots P_{\mu_{k-m}}]_{ij} q^{k-m}(j) + w_{k-m} - w_k.$$

利用式(7.60)和 $q^{k-m}(s) = 0$ 的事实, 我们由上式得

$$q^k(i) \leq (1 - \epsilon) \max_j q^{k-m}(j) + w_{k-m} - w_k, \quad i = 1, \dots, n.$$

所以,

$$\max_j q^k(j) \leq (1 - \epsilon) \max_j q^{k-m}(j) + w_{k-m} - w_k. \quad (7.61)$$

类似地, 由式(7.58)的左边得

$$\min_j q^k(j) \geq (1 - \epsilon) \min_j q^{k-m}(j) + w_{k-m} - w_k, \quad (7.62)$$

把式(7.61)和式(7.62)结合起来, 即得所要求的关系式(7.56)。

如在式(7.49)和式(7.50)一样, 当相应于 $\mu_{k-m}, \dots, \mu_k$ 的特定状态 x 并不等于 s 时, 我们定义一个有关的迭代过程

$$\tilde{h}^{k+1}(i) = T(\tilde{h}^k)(i) - T(\tilde{h}^k)(x), \quad i = 1, \dots, n, \quad (7.63)$$

$$\tilde{h}^0(i) = h^0(i), \quad i = 1, \dots, n.$$

那么, 与前面一样有

$$\max_i \tilde{q}^k(i) - \min_i \tilde{q}^k(i) \leq (1 - \epsilon) [\max_i \tilde{q}^{k-m}(i) - \min_i \tilde{q}^{k-m}(i)], \quad (7.64)$$

其中

$$\tilde{q}^k = \tilde{h}^{k+1} - \tilde{h}^k.$$

利用式(7.51)和式(7.63)容易证明, 对所有 i 和 k 有

$$h^k(i) = \tilde{h}^k(i) + T(\tilde{h}^{k-1})(x) - T(\tilde{h}^{k-1})(s).$$

因此, h^k 和 q^k 的分量都分别与 $\tilde{h}^k$ 和 $\tilde{q}^k$ 的分量差一个常值。从而有

$$\max_i q^k(i) - \min_i q^k(i) = \max_i \tilde{q}^k(i) - \min_i \tilde{q}^k(i),$$

且由式(7.64)得到所要求的结果式(7.56)。证毕

注意到, 作为这一证明的一个附带结果, 我们得到收敛率的一个估计。当 $r \rightarrow \infty$ 时, 在式(7.57)中取极限, 得

$$\max_i |h^k(i) - h(i)| \leq \frac{B(1 - \epsilon)^{k/m}}{1 - (1 - \epsilon)^{1/m}}, \quad k = 0, 1, \dots,$$

于是, 收敛率至少与收敛比值 $(1 - \epsilon)^{1/m}$ 成线性关系。考虑式(7.47)中矩阵 $\tilde{P}_\mu$ 特征值的结构, 可以获得更陡的收敛率。

误差界限

如对折扣问题一样, 逐次逼近法通过计算单调误差界限可得到加强。

命题 7 对于算法式(7.51), 在命题 6 的假设下, 对每个 k 下式成立:

$$c_k \leq c_{k+1} \leq \lambda \leq \bar{c}_{k+1} \leq \bar{c}_k, \quad (7.65)$$

其中 $\lambda = J^*(i)$, 对 $i = 1, \dots, n$, 且

$$c_k = \min_i [T(h^k)(i) - h^k(i)],$$

$$\bar{c}_k = \max_i [T(h^k)(i) - h^k(i)].$$

证明: 令 $\mu_k(i)$ 在下式

$$T(h^k)(i) = \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u) h^k(j) \right]$$

中, 对每个 k 和 i 达到极小值。利用式(7.51)有

$$T(h^k)(i) = g[i, \mu_k(i)] + \sum_{j=1}^n p_{ij}[\mu_k(i)] T(h^{k-1})(j) - T(h^{k-1})(s),$$

$$h^k(i) \leq g[i, \mu_k(i)] + \sum_{j=1}^n p_{ij}[\mu_k(i)] h^{k-1}(j) - T(h^{k-1})(s).$$

由此得

$$T(h^k)(i) - h^k(i) \geq \sum_{j=1}^n p_{ij}[\mu_k(i)] [T(h^{k-1})(j) - h^{k-1}(j)].$$

且接着有

$$\min_i [T(h^k)(i) - h^k(i)] \geq \min_i [T(h^{k-1})(i) - h^{k-1}(i)]$$

或等价地有

$$c_{k-1} \leq c_k.$$

类似的方法证明

$$\bar{c}_k \leq \bar{c}_{k-1}.$$

由命题 6, 对所有 i , 有 $h^k(i) \rightarrow h(i)$, 和 $T(h)(i) - h(i) = \lambda$, 所以 $c_k \rightarrow \lambda$. 因为 $\{c_k\}$ 也是非递减的, 必对所有 k 有 $c_k \leq \lambda$. 类似地, 对所有 k 有 $\bar{c}_k \geq \lambda$.

现在我们通过一个例题来演示一下逐次逼近算法和误差界限式(7.65)。

例题

考虑 § 6.2 例题的无折扣情况。我们有

$$S = \{1, 2\}, \quad C = \{u^1, u^2\},$$

$$P(u^1) = \begin{bmatrix} p_{11}(u^1) & p_{12}(u^1) \\ p_{21}(u^1) & p_{22}(u^1) \end{bmatrix} = \begin{bmatrix} \frac{3}{4} & \frac{1}{4} \\ \frac{3}{4} & \frac{1}{4} \end{bmatrix},$$

$$P(u^2) = \begin{bmatrix} p_{11}(u^2) & p_{12}(u^2) \\ p_{21}(u^2) & p_{22}(u^2) \end{bmatrix} = \begin{bmatrix} \frac{1}{4} & \frac{3}{4} \\ \frac{1}{4} & \frac{3}{4} \end{bmatrix},$$

和

$$g(1, u^1) = 2, \quad g(1, u^2) = 0.5, \quad g(2, u^1) = 1, \quad g(2, u^2) = 3.$$

令 $s = 1$ 是参考状态, 算法式(7.51)取如下形式

$$T(h^k)(i) = \min \left\{ g(i, u^1) + \sum_{j=1}^2 p_{ij}(u^1) h^k(j), g(i, u^2) + \sum_{j=1}^2 p_{ij}(u^2) h^k(j) \right\}, \quad i = 1, 2,$$

$$h^{k+1}(1) = 0,$$

$$h^{k+1}(2) = T(h^k)(2) - T(h^k)(1).$$

由 $h^0(1) = h^0(2) = 0$, 起始的计算结果示于表 7.1。

表 7.1

k	$h^k(1)$	$h^k(2)$	c_k	$\bar{c}_k$
0	0.00000	0.00000		
1	0.00000	0.50000	0.62500	0.87500
2	0.00000	0.25000	0.68750	0.81250
3	0.00000	0.37500	0.71875	0.78125
4	0.00000	0.31250	0.73438	0.76563
5	0.00000	0.34375	0.74219	0.75781
6	0.00000	0.32813	0.74609	0.75391
7	0.00000	0.33594	0.74805	0.75195
8	0.00000	0.33203	0.74902	0.75098
9	0.00000	0.33398	0.74951	0.75049
10	0.00000	0.33301	0.74976	0.75024
11	0.00000	0.33350	0.74988	0.75012
12	0.00000	0.33325	0.74994	0.75006
13	0.00000	0.33337	0.74997	0.75003
14	0.00000	0.33331	0.74998	0.75002
15	0.00000	0.33334	0.74999	0.75001
16	0.00000	0.33333	0.75000	0.75000

逐次逼近法的其它形式

前面我们已提到, 在命题 6 中给出的逐次逼近法收敛的条件, 比在命题 3 和 4 中给出的独立于初始状态的最优平均代价的条件强。事实上, 本章引言中给出的例题表明, 当把它应用于具有单一策略和相应转移矩阵

$$P_\mu = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}.$$

的问题时, 逐次逼近法并不收敛。矩阵 P_μ 是不可约的, 但这里的困难在于, 有关的马尔科夫链具有周期特征。我们可把这问题进行修正, 它不影响最优代价和最优策略, 且把逐次逼近法用于修正后的问题, 以此来避开困难。

设 τ 是任一标量, 且

$$0 < \tau < 1,$$

我们考虑相应于平稳策略 $\{\mu, \mu, \dots\}$ 的每个转移矩阵 P_μ 由下式

$$\tilde{P}_\mu = \tau P_\mu + (1-\tau)I, \quad (7.66)$$

来代替这样一个问题, 其中 I 是单位阵。注意, $\tilde{P}_\mu$ 是具有如下特性的一个转移概率矩阵: 在每个状态, 自转移至少以概率 $(1-\tau)$ 发生。这就破坏了 P_μ 可能具有的任何周期特征。从另一角度看, 注意到 $\tilde{P}_\mu$ 的特征值是 $\tau\lambda_k + (1-\tau)$, 其中 λ_k 是 P_μ 的特征值。所以, P_μ 所有处在单位圆上 $\lambda_k \neq 1$ 的特征值, 被映射到严格处在单位圆内 $\tilde{P}_\mu$ 的特征值。方程

$$J_\mu + h_\mu = g_\mu + P_\mu h_\mu$$

也可写成

$$J_\mu + \tilde{h}_\mu = g_\mu + \tilde{P}_\mu \tilde{h}_\mu,$$

且

$$\tilde{h}_\mu = \frac{h_\mu}{\tau}.$$

由推论 1.1 得出, 如果对每个 μ , $J_\mu(i)$ 与 i 无关, 则等式对修正的问题也是正确的。而且, 对于原问题和修正问题, 所有平稳策略的代价以及最优代价都是相等的。

现在考虑对修正问题的逐次逼近法。直接计算表明它取如下形式

$$\begin{aligned} h^{k+1}(i) &= (1-\tau)h^k(i) + \min_{u \in U(i)} \left[g(i, u) + \tau \sum_{j=1}^n p_{ij}(u) h^k(j) \right] \\ &\quad - \min_{s \in U(s)} \left[g(s, u) + \tau \sum_{j=1}^n p_{sj}(u) h^k(j) \right], \end{aligned} \quad (7.67)$$

式中 s 就是某个固定的状态, 且 $h^0(s) = 0$ 。注意到这一迭代方法与原形式一样易于计算。然且, 它的收敛条件比命题 6 所要求的较弱。

命题 8 假定每个平稳策略产生一个具有单一遍历类的马尔科夫链, 则对 $0 < \tau < 1$, 由迭代公式(7.67)产生的序列 $\{h^k(i)\}$ 满足

$$\begin{aligned} \lim_{k \rightarrow \infty} h^k(i) &= \frac{h(i)}{\tau}, \\ \lim_{k \rightarrow \infty} \min_{u \in U(i)} \left[g(s, u) + \tau \sum_{j=1}^n p_{sj}(u) h^k(j) \right] &= \lambda, \end{aligned} \quad (7.68)$$

其中 λ 和 h 是最优平均代价和微分代价, 满足

$$\lambda + h(i) = \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u) h(j) \right], \quad i = 1, \dots, n.$$

证明: 证明包括验证涉及式(7.66)转移概率矩阵 $\tilde{P}_\mu$ 的修正问题满足命题 6 的条件。

令 $m > nn_M$, 其中 n 是状态个数, n_M 是不同平稳策略的个数。考虑一个控制函数 $\mu_0, \mu_1, \dots, \mu_m$ 的集合, 那么在子集 $\mu_1, \dots, \mu_{m-1}$ 中至少有一个 $\mu \in M$ 重复 n 次。令 x 是属于相应于 μ 的马尔科夫链遍历类的一个状态, 则对某 ϵ , 条件

$$[\tilde{P}_{\mu_m} \cdots \tilde{P}]_{ix} \geq \epsilon, \quad i = 1, \dots, n,$$

$$[\tilde{P}_{\mu_{m-1}} \cdots \tilde{P}_{\mu_0}]_{ix} \geq \epsilon, \quad i = 1, \dots, n,$$

是满足的, 因为根据式(7.66), 在某个阶段存在由 i 到 x 的一个正概率, 则在任意后来的阶

段也存在到达它的一个正概率。

证毕

注意, 因为修正的逐次逼近法除了把原有方法应用于修正问题之外, 没有别的东西。所以命题 7 的误差界限将以适当的修正形式来使用。

误差界限与线性规划

可能比命题 7 所指出的更一般的方式, 将最优代价进行由上和由下定界。如果 h 是任意的 n 维向量, 且 μ 使得

$$T_{\mu}(h) = T(h),$$

我们将证明, 对所有 i ,

$$\min_j [T(h)(j) - h(j)] \leq J^*(i) \leq J_{\mu}(i) \leq \max_j [T(h)(j) - h(j)]. \quad (7.69)$$

不管 $J^*(i)$ 是否独立于初始状态 i , 这些界限成立。

确实, 令

$$\delta(i) = T(h)(i) - h(i), \quad i = 1, \dots, n,$$

且令 δ 为具有坐标 $\delta(i)$ 的一个向量。因为 $T_{\mu}(h) = T(h)$, 则有

$$T_{\mu}(h) = \delta + h, \quad T_{\mu}^2(h) = T_{\mu}(h) + P_{\mu}\delta = \delta + P_{\mu}\delta + h,$$

以同样方式继续下去得

$$T_{\mu}^N(h) = \sum_{k=0}^{N-1} P_{\mu}^k \delta + h, \quad N = 1, 2, \dots.$$

从而有

$$J_{\mu} = \lim_{N \rightarrow \infty} \frac{1}{N} T_{\mu}^N(h) = P_{\mu}^* \delta,$$

其中

$$P_{\mu}^* = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=0}^{N-1} P_{\mu}^k.$$

因此, $J_{\mu}(i) \leq \max_j \delta(j)$, 证明了式(7.69)的右边。

同样, 令 $\pi = \{\mu_0, \mu_1, \dots\}$ 为任意策略, 则有

$$T_{\mu_N}(h) \geq \delta + h,$$

且把 $T_{\mu_{N-1}}$ 作用于这个不等式的两边, 得

$$\begin{aligned} (T_{\mu_{N-1}} T_{\mu_N})(h) &\geq P_{\mu_{N-1}} \delta + T_{\mu_{N-1}}(h) \\ &\geq P_{\mu_{N-1}} \delta + \delta + h \\ &\geq 2[\min_j \delta(j)]e + h. \end{aligned}$$

以这种方式继续下去, 对所有 i 有

$$\frac{1}{N+1} (T_{\mu_0} \cdots T_{\mu_N})(h)(i) \geq \min_j \delta(j) + \frac{h(i)}{N+1},$$

而且当 $N \rightarrow \infty$ 时取极限得:

$$J_{\pi}(i) \geq \min_j \delta(j).$$

因为 π 是任意的, 则得式(7.69)的左边。

由误差界限式(7.69), 得不等式

$$\begin{aligned} \max_h \min_j [T(h)(j) - h(j)] &\leq J^*(i) \\ &\leq \min_h \max_j [T(h)(j) - h(j)], \quad i = 1, \dots, n. \end{aligned} \quad (7.70)$$

如果一个标量 λ 和一个向量 h 满足 $\lambda e + h = T(h)$ (见命题 1), 则 h 到达式(7.70)所表示的极值, 而且对所有 i , 有 $J^*(i) = \lambda$ 。换句话说, 在此环境下, h 求解如下问题:

$$\max_h \min_j [T(h)(j) - h(j)].$$

作一问题认为等价于如下问题

$$\begin{aligned} \max \quad &\lambda \\ \text{s.t.} \quad &\lambda \leq T(h)(i) - h(i), \quad i = 1, \dots, n. \end{aligned}$$

从而得出, λ 和 $h(i)$, $i = 1, \dots, n$ 求解如下线性规划问题

$$\begin{aligned} \max \quad &\lambda \\ \text{s.t.} \quad &\lambda + h(i) \leq g(i, u) + \sum_{j=1}^n p_{ij}(u)h(j), \quad i = 1, \dots, n, \quad u \in U(i), \end{aligned}$$

遗憾的是, 当状态和(或)控制的个数非常多时, 这个规划问题的求解变得非常困难。

§ 7.3 策略迭代

对于平均代价问题的策略迭代算法, 类似于前两章所描述的方法。给定一个平稳策略, 人们利用一个求极小的过程得到一个改进的策略, 直到不可能再进一步改进为止。本节通篇假定, 在算法进行过程中所遇到的每一个平稳策略, 都产生具有单一遍历类的马尔科夫链。

在策略迭代算法的第 k 步, 有一个平稳策略 $\{\mu^k, \mu^k, \dots\}$, 我们要确定相应的平均代价 λ^k 和微分代价 h^k , 满足

$$\lambda^k + h^k(i) = g[i, \mu^k(i)] + \sum_{j=1}^n p_{ij}[\mu^k(i)]h^k(j), \quad i = 1, \dots, n, \quad (7.71)$$

或等价地

$$\lambda^k e + h^k = T_{\mu^k}(h^k) = g_{\mu^k} + P_{\mu^k} h^k,$$

其中 $e = [1, 1, \dots, 1]'$ 是单位向量。注意到通过求解线性方程组式(7.71)与正则化方程 $h^k(s) = 0$, 其中 s 是任意状态(见命题 5)的唯一解, 可确定 λ^k 和 h^k 。这个方程组可以直接求解, 也可以利用逐次逼近和自适应集结(见 § 5.2 和 [B20])迭代求解。接下去我们就要寻求一个平稳策略 $\pi^{k+1} = \{\mu^{k+1}, \mu^{k+1}, \dots\}$, 使得

$$\begin{aligned} &g[i, \mu^{k+1}(i)] + \sum_{j=1}^n p_{ij}[\mu^{k+1}(i)]h^k(j) \\ &= \min_{u \in U(i)} \left[g(i, u) + \sum_{j=1}^n p_{ij}(u)h^k(j) \right], \quad i = 1, \dots, n, \end{aligned} \quad (7.72)$$

或等价地,

$$T_{\mu^{k+1}}(h^k) = T(h^k).$$

这里有一个限定：若 $\mu^k(i)$ 在式(7.72)中达到极小值，我们选择 $\mu^{k+1}(i) = \mu^k(i)$ ，即使除了 $\mu^k(i)$ 之外还有达到极小值的其它控制。如果 $\mu^{k+1} = \mu^k$ ，则算法终结；否则，用 μ^{k+1} 代替 μ^k 重复这一过程。

该算法的有效性在如下命题建立。

命题 9 上述策略迭代算法以最优平稳策略在有限步内终结。

把证明命题 9 所需要的主要论断叙述成引理，简单方便。

引理 2 令 $\{\mu, \mu, \dots\}$ 为一个平稳策略，又令 λ 和 h 为满足

$$\lambda e + h = T_\mu(h), \quad (7.73)$$

和正则化条件

$$P_\mu^* h = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=0}^{N-1} P_\mu^k h = 0 \quad (7.74)$$

的相应平稳代价和微分代价。令 $\{\bar{\mu}, \bar{\mu}, \dots\}$ 为通过上述策略迭代步骤由 μ 得到的策略，且令 $\bar{\lambda}$ 和 $\bar{h}$ 为满足

$$\bar{\lambda} e + \bar{h} = T_{\bar{\mu}}(\bar{h}), \quad (7.75)$$

及

$$P_{\bar{\mu}}^* \bar{h} = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^{N-1} P_{\bar{\mu}}^k \bar{h} = 0 \quad (7.76)$$

相应的平均代价和微分代价。那么，若 $\bar{\mu} \neq \mu$ ，则对所有 $i = 1, \dots, n$ ，必有：(1) $\bar{\lambda} < \lambda$ ，或 (2) $\bar{\lambda} = \lambda$ ；且 $\bar{h}(i) \leq h(i)$ ，其中对至少一个状态 i 是严格不等的。

注意，一旦建立了引理 2，可以很容易证明策略迭代算法在有限步终结。其理由是，由式(7.73)和式(7.74)，相应于 μ 的向量 h 根据命题 5 是唯一的；因此，引理 2 的结论保证了在算法进行的过程中，一个策略不会出现一次以上。因为平稳策略的个数是有限的，算法必定有限地终结。如果算法在第 k 步以 $\mu^{k+1} = \mu^k$ 终结，则由式(7.71)和式(7.72)看出

$$\lambda^k e + h^k = T(h^k),$$

由命题 1，此即意味着 $\{\mu^k, \mu^k, \dots\}$ 是一个最优平稳策略。于是，为证明命题 9 所遗留的问题就是去证明引理 2。

引理 2 的证明：为简化记法，令

$$P = P_\mu, \quad \bar{P} = P_{\bar{\mu}}, \quad P^* = P_\mu^*, \quad \bar{P}^* = P_{\bar{\mu}}^*,$$

$$g = g_\mu, \quad \bar{g} = g_{\bar{\mu}}.$$

定义向量 δ 为

$$\delta = \lambda e + h - \bar{g} - \bar{P}h. \quad (7.77)$$

根据假设有， $T_{\bar{\mu}}(h) = T(h) \leq T_\mu(h) = \lambda e + h$ ，或等价地

$$\bar{g} + \bar{P}h \leq g + Ph = \lambda e + h, \quad (7.78)$$

由此得

$$\delta(i) \geq 0, \quad i = 1, \dots, n. \quad (7.79)$$

再定义

$$\Delta = h - \bar{h}, \quad (7.80)$$

把式(7.77)与方程 $\bar{\lambda} e + \bar{h} = \bar{g} + \bar{P}\bar{h}$ ，结合起来得

$$\delta = (\lambda - \bar{\lambda})e + \Delta - \bar{P}\Delta.$$

对此关系式乘以 $\bar{P}^k$, 而且由 0 加到 $N-1$ 得

$$\sum_{k=0}^{N-1} \bar{P}^k \delta = N(\lambda - \bar{\lambda})e + \Delta - \bar{P}^N \Delta. \quad (7.81)$$

用 N 除, 并且当 $N \rightarrow \infty$ 取极限得

$$\bar{P}^* \delta = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=0}^{N-1} \bar{P}^k \delta = (\lambda - \bar{\lambda})e. \quad (7.82)$$

根据 $\delta \geq 0$ 的事实[见式(7.79)], 看出

$$\lambda \geq \bar{\lambda}.$$

如果 $\lambda > \bar{\lambda}$, 则已完成; 所以假定 $\lambda = \bar{\lambda}$. 如果 i 属于(或不属于)相应于 $\bar{P}^*$ 的马尔科夫链的单一遍历类, 则称状态 i 为 $\bar{P}$ -循环(P -瞬变)的. 由式(7.82), $\bar{P}^* \delta = 0$, 且因为 $\delta \geq 0$, 以及 $\bar{P}^*$ 中的正元素为相应于 $\bar{P}$ -循环态的那些列, 我们得:

$$\delta(i) = 0, \quad \text{对所有 } \bar{P}\text{-循环的 } i. \quad (7.83)$$

由算法的结构得出, 若 i 是 $\bar{P}$ -循环的, 则 P 和 $\bar{P}$ 的第 i 行是相等的[因为对所有 i , $\delta(i) = 0$, $\bar{\mu}(i) = \mu(i)$]. 因为 P 和 $\bar{P}$ 均具有一个单一遍历类, 从而知道对 P 和 $\bar{P}$, 遍历类是相同的. 由正则化条件式(7.74)和式(7.76), 则对所有为 $\bar{P}$ -循环的 i , 得 $h(i) = \bar{h}(i)$. 等价地

$$\Delta(i) = 0, \quad \text{对所有为 } \bar{P}\text{-循环的 } i. \quad (7.84)$$

由式(7.81)得

$$\lim_{N \rightarrow \infty} \bar{P}^N \Delta = \Delta - \lim_{N \rightarrow \infty} \sum_{k=0}^{N-1} \bar{P}^k \delta \leq \Delta - \delta.$$

根据式(7.84), 相应于 $\bar{P}$ -瞬变态的 $\bar{P}^N \Delta$ 坐标趋于零. 因此有

$$\delta(i) \leq \Delta(i), \quad \text{对所有 } \bar{P}\text{-瞬变的 } i. \quad (7.85)$$

由式(7.79)和式(7.83)到式(7.85), 现在我们看出或 $\delta = 0$, 在此情况下 $\mu = \bar{\mu}$; 或者 $\Delta \geq 0$, 而且至少对一个 $\bar{P}$ -瞬变态 i 有严格不等式 $\Delta(i) > 0$. 证毕

现在我们通过上一节的例题来演示策略迭代算法.

例题(继续)

令

$$\mu^0(1) = u^1, \quad \mu^0(2) = u^2.$$

我们取 $s = 1$ 作为参考态, 且从如下方程组

$$\begin{aligned} \lambda_{\mu^0} + h_{\mu^0}(1) &= g(1, u^1) + p_{11}(u^1)h_{\mu^0}(1) + p_{12}(u^1)h_{\mu^0}(2), \\ \lambda_{\mu^0} + h_{\mu^0}(2) &= g(2, u^2) + p_{21}(u^2)h_{\mu^0}(1) + p_{22}(u^2)h_{\mu^0}(2), \\ h_{\mu^0}(1) &= 0, \end{aligned}$$

求得 λ_{μ^0} , $h_{\mu^0}(1)$ 和 $h_{\mu^0}(2)$. 代入该问题的数据,

$$\lambda_{\mu^0} = 2 + \frac{1}{4}h_{\mu^0}(2), \quad \lambda_{\mu^0} + h_{\mu^0}(2) = 3 + \frac{3}{4}h_{\mu^0}(2),$$

由此得

$$\lambda_{\mu^0} = 2.5, \quad h_{\mu^0}(1) = 0, \quad h_{\mu^0}(2) = 2.$$

现在, 按式(7.72)给出的极小化公式求 $\mu^1(1)$ 和 $\mu^1(2)$. 确定:

$$\begin{aligned}
& \min[g(1, u^1) + p_{11}(u^1)h_{\mu^0}(1) + p_{12}(u^1)h_{\mu^0}(2), \\
& \quad g(1, u^2) + p_{11}(u^2)h_{\mu^0}(1) + p_{12}(u^2)h_{\mu^0}(2)] \\
& = \min\left[2 + \frac{1}{4} \times 2, 0.5 + \frac{3}{4} \times 2\right] = \min[2.5, 2], \\
& \min[g(2, u^1) + p_{21}(u^1)h_{\mu^0}(1) + p_{22}(u^1)h_{\mu^0}(2), \\
& \quad g(2, u^2) + p_{21}(u^2)h_{\mu^0}(1) + p_{22}(u^2)h_{\mu^0}(2)] \\
& = \min\left[1 + \frac{1}{4} \times 2, 3 + \frac{3}{4} \times 2\right] = \min[1.5, 4.5].
\end{aligned}$$

极小化产生

$$\mu^1(1) = u^2, \quad \mu^1(2) = u^1.$$

由如下方程组

$$\begin{aligned}
\lambda_{\mu^1} + h_{\mu^1}(1) &= g(1, u^2) + p_{11}(u^2)h_{\mu^1}(1) + p_{12}(u^2)h_{\mu^1}(2), \\
\lambda_{\mu^1} + h_{\mu^1}(2) &= g(2, u^1) + p_{21}(u^1)h_{\mu^1}(1) + p_{22}(u^1)h_{\mu^1}(2), \\
h_{\mu^1}(1) &= 0,
\end{aligned}$$

求得 λ_{μ^1} , $h_{\mu^1}(1)$ 和 $h_{\mu^1}(2)$ 。代入该问题的数据得:

$$\lambda_{\mu^1} = 0.75, \quad h_{\mu^1}(1) = 0, \quad h_{\mu^1}(2) = \frac{1}{3}.$$

通过以下方程

$$\begin{aligned}
& \min[g(1, u^1) + p_{11}(u^1)h_{\mu^1}(1) + p_{12}(u^1)h_{\mu^1}(2), \\
& \quad g(1, u^2) + p_{11}(u^2)h_{\mu^1}(1) + p_{12}(u^2)h_{\mu^1}(2)] \\
& = \min\left[2 + \frac{1}{4} \times \frac{1}{3}, 0.5 + \frac{3}{4} \times \frac{1}{3}\right] = \min[2.08, 0.75], \\
& \min[g(2, u^1) + p_{21}(u^1)h_{\mu^1}(1) + p_{22}(u^1)h_{\mu^1}(2), \\
& \quad g(2, u^2) + p_{21}(u^2)h_{\mu^1}(1) + p_{22}(u^2)h_{\mu^1}(2)] \\
& = \min\left[1 + \frac{1}{4} \times \frac{1}{3}, 3 + \frac{3}{4} \times \frac{1}{3}\right] = \min[1.08, 3.25],
\end{aligned}$$

确定最小值, 可求得 $\mu^2(1)$ 和 $\mu^2(2)$ 。极小化产生

$$\mu^2(1) = \mu^1(1) = u^2, \quad \mu^2(2) = \mu^1(2) = u^1.$$

因此以上策略最优的, 每阶段最优平均代价是 $\lambda_{\mu^1} = 0.75$ 。

§ 7.4 无限状态空间: 具有二次代价泛函的线性系统

前几节一直假定状态空间是有限的, 因而基本系统就是一个受控有限状态马尔科夫链。一旦人们把状态空间的有限性假设去掉, 在前三节提出的许多结果都不再成立。例如, 对于有限状态系统, 人们可以把注意力集中在平稳策略上, 但当状态空间是无限时, 这就不再正确了。下面的例题[R6]表明, 对于一个可数的状态空间, 最优策略也许是非平稳的。

例题

令状态空间为 $S = \{1, 2, 3, \dots\}$, 且存在两个控制活动 $C = \{u^1, u^2\}$ 。在 u^1 和 u^2 作用下的转移概率规定为

$$p_{i(i+1)}(u^1) = p_{ii}(u^2) = 1.$$

每阶段代价为

$$g(i, u^1) = 1, \quad g(i, u^2) = \frac{1}{i}, \quad i = 1, 2, 3, \dots.$$

换句话说, 在状态 i , 可以以 1 单位的代价移动到状态 $i+1$, 或以代价 $1/i$ 停留在状态 i 不动。

对任意平稳策略 $\pi = \{\mu, \mu, \dots\}$, 而不是 $\mu(i) = u^1$ (对所有 i), 令 $n(\pi)$ 为最小整数, 对此有 $\mu[n(\pi)] = u^2$ 。

那么, 相应的每段平均代价满足

$$J_\pi(i) = \frac{1}{n(\pi)} > 0, \quad i \leq n(\pi).$$

对于所有 i , $\mu(i) = u^1$ 的策略, 有 $J_\pi(i) = 1$, 对所有 i 。因为每阶段最优代价不可能小于零, 显然有

$$\min_x J_x(i) = 0, \quad i = 1, 2, \dots.$$

然而, 最优代价不可能由任意平稳策略达到, 所以平稳策略不是最优的。另一方面, 考虑非平稳策略 π^* , 它进入状态 i 时, 连续 i 次选择 u^2 , 然后选择 u^1 。若起始状态为 i , 则引起的代价序列为

$$\underbrace{\frac{1}{i}, \frac{1}{i}, \dots, \frac{1}{i}}_{i \text{ 次}}, 1, \underbrace{\frac{1}{i+1}, \frac{1}{i+1}, \dots, \frac{1}{i+1}}_{i+1 \text{ 次}}, 1, \frac{1}{i+2}, \frac{1}{i+2}, \dots.$$

相应于此策略的平均代价是

$$J_{\pi^*}(i) = \lim_{m \rightarrow \infty} \frac{2m}{\sum_{k=1}^m (i+k)} = 0, \quad i = 1, 2, 3, \dots.$$

因此, 非平稳策略 π^* 是最优的, 如前面证明的一样, 没有平稳最优策略的。

一般情况下, 对无限状态空间平均代价问题的分析是困难的。然而, 某些特殊情况可圆满地作分析。这些情况之一就是在第二、三和六章中讨论过的线性二次问题的平均代价形式。

考虑 § 6.1 线性二次问题的无折扣情况 ($\alpha = 1$), 包括系统

$$x_{k+1} = Ax_k + Bu_k + w_k, \quad k = 0, 1, \dots, \quad (7.86)$$

和一个代价泛函

$$J_\pi(x_0) = \lim_{N \rightarrow \infty} \frac{1}{N} E_{w_k} \left\{ \sum_{k=0}^{N-1} [x_k' Q x_k + \mu_k(x_k)' R \mu_k(x_k)] \right\}. \quad (7.87)$$

我们的假设与 § 6.1 相同, 即 w_k 是一个独立过程, 具有零均值和有限二次矩。我们还假定 (A, B) 对是能控的, (A, C) 对是能观的, 其中 $Q = C' C$ 。在这些假设条件下, § 2.1 已证明, 黎卡提方程

$$K_0 = 0, \quad (7.88)$$

$$K_{k+1} = A' [K_k - K_k B (B' K_k B + R)^{-1} B' K_k] A + Q, \quad (7.89)$$

以极限形式产生矩阵 K ,

$$K = \lim_{k \rightarrow \infty} K_k, \quad (7.90)$$

它是如下方程

$$K = A' [K - KB(B'KB + R)^{-1}B'K]A + Q \quad (7.91)$$

在半正定对称矩阵类中的唯一解。

N 阶段代价

$$\frac{1}{N} E_{w_k} \left\{ \sum_{k=0}^{N-1} (x_k' Q x_k + u_k' R u_k) \right\} \quad (7.92)$$

的最优值已在前面导出, 而且等于

$$\frac{1}{N} \left[x_0' K_N x_0 + \sum_{k=0}^{N-1} E\{w_k' K_k w_k\} \right].$$

利用式(7.90)和如下事实

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=0}^{N-1} E\{w_k' K_k w_k\} = E\{w' K w\},$$

当 $N \rightarrow \infty$ 时, 最优有限时域代价趋于

$$\lambda = E\{w' K w\}. \quad (7.93)$$

另外, 在初始时段的 N 阶段最优策略趋于平稳策略

$$\mu^*(x) = -(B'KB + R)^{-1}B'K A x. \quad (7.94)$$

而且, 一个简单的计算表明, 由 λ , K 和 $\mu^*(x)$ 的定义, 有

$$\lambda + x' K x = \min_u E\{x' Q x + u' R u + (Ax + Bu + w)' K (Ax + Bu + w)\},$$

而且如式(7.94)所给出, 方程右边在 $u^* = \mu^*(x)$ 达到极小。

重复本章命题 1 的证明得:

$$\lambda \leq \frac{1}{N} E\{x_N' K x_N | x_0, \pi\} - \frac{1}{N} x_0' K x_0 + \frac{1}{N} E\left\{ \sum_{k=0}^{N-1} (x_k' Q x_k + u_k' R u_k) | x_0, \pi \right\},$$

而且当 $\pi = \{\mu^*, \mu^*, \dots\}$ 时以等式成立。因此, 若 π 使得 $E\{x_N' K x_N | x_0, \pi\}$ 对 N 一致有界, 则当 $N \rightarrow \infty$ 时, 对上式取极限有

$$\lambda \leq J_\pi(x), \quad x \in R^n,$$

且当 $\pi = \{\mu^*, \mu^*, \dots\}$ 时成为等式。因此, 由式(7.94)给出的线性平稳策略对所有策略 π , 且 $E\{x_N' K x_N | x_0, \pi\}$ 对 N 一致有界时, 是最优的。

§ 7.5 注 记

平均代价问题在[H15]中曾进行描述和分析。有几位作者已对此问题作出了贡献([B34, R6, S7, V4, V6]), 最著名的是 Blackwell([B26])。

§ 7.1 所获的结果, 由[R6]而来。这方法可推广到状态空间为无限的情况。命题 4(b)的结果在[B4]中给出证明。在[W6]中给出了 § 7.2 的逐次逼近法。命题 7 的误差界限由 Odoni([O1])导出。在[S10], [S12]和[S13]中, 对逐次逼近法进行了透彻的分析。误差界限式(7.69)由 Varaiya([V2])导出, 他由此构造了逐次逼近法的一种微分形式。Varaiya 方法的离散

时间形式在[P12]中给出。Platzman([P10])指出这种方法与早期工作([S10])之间的关系,而且证明了比这里给出的条件([P11])更弱情况下的收敛性。

策略迭代算法可推广到对每个初始状态每阶段最优平均代价不同的问题(见[B26],[V4]和[D4])。自适应集结与 § 5.2 类似,迭代地完成策略迭代算法的策略评价[B20]。

诸如 § 2.2 中一类库存控制问题的无限时域方面的分析,可参看 [I3], [H13], [H14]和[V7]。[K15]在无限状态空间范围内考虑了更一般的平均代价问题。

习题 3 也曾称为妓女二难推论,取自[R6],它考虑了包含连续时间马尔科夫链的半马尔科夫决策问题。

习 题

1. 确定性有限状态系统的最优控制。考虑一个平稳确定性控制系统

$$x_{k+1} = f(x_k, u_k), \quad k=0, 1, \dots,$$

其中状态 x_k 属于一个有限状态空间 $S = \{1, 2, \dots, n\}$, 而且控制 u_k 被约束在一个有限控制空间 C 的子集 $U(x_k)$ 之内。如果给定任意两个状态 $i, j \in S$, 存在一个容许控制序列, 使得在至多 $(n-1)$ 步范围内把系统的状态由状态 i 驱动到状态 j , 我们说系统是完全能控的。对于一个完全能控的系统和一个给定的初始状态 $x_0 = i$, 考虑寻求一个容许控制序列 $\{u_0, u_1, \dots\}$ 的问题, 使下式达到极小

$$J_\pi(i) = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=0}^{N-1} g(x_k, u_k),$$

其中 $g: S \times C \rightarrow R$ 给定。证明对每个初始状态最优代价是相同的。再证明存在一个最优控制序列, 它在某个时间标号之后是周期性的。

2. 考虑已在 § 3.2 中考虑过的这类平稳库存控制问题, 区别在于存货 x_k 只能取由 0 到某个整数 M 中的整数值。订货 u_k 取整数值, 且 $0 \leq u_k \leq M - x_k$, 而随机需求 w_k 仅能取非负整数值, 且 $P(w_k = 0) > 0$, 和 $P(w_k = 1) > 0$ 。不满足需求即为损失。于是存货按方程 $x_{k+1} = \max(0, x_k + u_k - w_k)$ 演变。这个问题是寻求一个库存策略, 使得每阶段平均代价为极小。证明存在一个最优平稳策略, 而且最优代价独立于初始存货 x_0 。

3. 考虑一个对顾客提供某种服务的生意人(B)。B 在每个时间周期的开始以概率 p_i 接到一个 i 类型顾客请求, 其中 $i = 1, 2, \dots, n$, 顾客提供总额 M_i 的钱。我们假定 $\sum_{i=1}^n p_i \leq 1$ 。B 可能拒绝这个出价, 在此情况下顾客离去, 而 B 在此周期保持空闲。或者 B 可以接受出价, 在此情况下, B 与该顾客在一起, 消磨按马尔科夫过程所决定的某些时间, 过程的转移概率是 β_{ik} 。对 $k = 1, 2, \dots$,

β_{ik} = 给定 i 类顾客与 B 在一起呆了 $(k-1)$ 个周期情况下, 顾客将在 k 个周期后离去的概率。

此问题就是确定接受—拒绝策略, 使下式为最大

$$\lim_{N \rightarrow \infty} \frac{1}{N} \{N \text{ 个周期的期望报酬}\}.$$

考虑两种情况:

1. $\beta_{ik} = \beta_i \in (0, 1)$, 对所有 k ,

2. 对每个 i , 存在 $\bar{k}_i$ 使得 $\beta_{i, \bar{k}_i} = 1$ 。

(a) 把这生意人问题建立为一个平均代价马尔科夫决策问题, 而且证明最优值与初始状态无关。

(b) 证明当且仅当

$$\lambda^* T_i \leq M_i,$$

存在一个标量 λ^* , 和接受一个 i 类型顾客出价的最优策略, 式中 T_i 是与 i 类型顾客所消磨的期望时间, 由下式给出

$$T_i = \beta_{i,1} + \sum_{k=2}^{\infty} k \beta_{i,k-1} (1 - \beta_{i,k-2}) \cdots (1 - \beta_{i,0}).$$

4. 线性二次问题的策略迭代。此问题的目的在于证明策略迭代算法适用于线性二次问题(即使状态空间或控制空间都不是有限的)。在通常的能控性, 能观性和(半)正定假设条件下, 考虑 § 7.4 中的问题。令 L_0 是一个 $m \times n$ 矩阵, 使得矩阵 $(A + BL_0)$ 是稳定的。

(a) 证明相应于平稳策略 $\{\mu_0, \mu_0, \dots\}$, 式中 $\mu_0(x) = L_0 x$ 的每阶段平均代价具有如下形式

$$J_{\mu_0} = E\{w' K_0 w\},$$

其中 K_0 是一个半正定矩阵, 满足如下(线性)方程

$$K_0 = (A + BL_0)' K_0 (A + BL_0) + Q + L_0' R L_0.$$

(b) 令 $\mu_1(x) = L_1 x = (R + B' K_0 B)^{-1} B' K_0 A x$ 为如下表达式中

$$\min_u \{u' R u + (Ax + Bu)' K_0 (Ax + Bu)\},$$

对每个 x 达到极小值的控制函数, 证明

$$J_{\mu_1} = E\{w' K_1 w\} \leq J_{\mu_0},$$

其中 K_1 是某个半正定矩阵。

(c) 考虑在(a)和(b)中描述的(策略迭代)过程, 由此得到一个半正定矩阵序列 $\{K_k\}$ 。证明

$$K_k \rightarrow K,$$

式中 K 就是该问题的最优代价矩阵。

5. 证明方程(7.16)。证明梗概: 由定义式(7.11)有

$$\epsilon_N = \sum_{k=0}^{N-1} P_{\mu}^k g_{\mu} - N J_{\mu},$$

乘上 P_{μ}^* 得 $P_{\mu}^* \epsilon_N = 0$, 从而有 $(I - P_{\mu} + P_{\mu}^*) \epsilon_N = (1 - P_{\mu}) \epsilon_N = g_{\mu} - P_{\mu}^N g_{\mu}$ 。将此关系式由 1 加到 N , 则得式(7.16)。

6. 考虑一个确定性系统, 具有两个状态 0 和 1。一旦进入状态 0, 系统将无代价地永久保持在那里。在状态 1, 则有选择, 或无代价呆在那里, 或以单位代价移到状态 0。证明每个策略都是平均代价最优的, 但只有将系统保持在当前所处的状态是 Blackwell 最优的(见本章附录)。

7. 证明对所有策略(不仅是平稳策略) Blackwell 最优策略是最优的。

提示: 利用事实如下: 如果 $\{c_n\}$ 是一个非负有界序列, 则

$$\begin{aligned}\liminf_{N \rightarrow \infty} \frac{1}{N} \sum_{n=1}^N c_n &\leq \liminf_{\beta \uparrow 1} (1-\beta) \sum_{n=1}^{\infty} \beta^{n-1} c_n \\ &\leq \limsup_{\beta \uparrow 1} (1-\beta) \sum_{n=1}^{\infty} \beta^{n-1} c_n \leq \limsup_{N \rightarrow \infty} \frac{1}{N} \sum_{n=1}^N c_n.\end{aligned}$$

这一事实就是如下 Tauber 定理的推论。这一定理可在如下文献找到: D.V. Widder, The Laplace Transform, Princeton University Press, Princeton, N. J., 1941, pages 181-182.

如果 $K(\cdot)$ 在 $[0, \infty)$ 上是非递减的, 且

$$f(x) = \int_0^{\infty} e^{-xt} dK(t), \quad x > 0$$

是收敛的, 则

$$\liminf_{t \rightarrow \infty} \frac{K(t)}{t} \leq \liminf_{x \downarrow 0} xf(x) \leq \limsup_{x \downarrow 0} xf(x) \leq \limsup_{t \rightarrow \infty} \frac{K(t)}{t}.$$

8. 简化为折扣问题。对于 § 7.1 和 § 7.3 的问题, 假定存在一个状态 s , 使得对某个 $\beta > 0$, 和对所有状态 i 和控制 u , 有 $p_{is}(u) \geq \beta$ 。考虑 $(1-\beta)$ 折扣问题, 具有相同的状态空间和控制空间, 和转移概率

$$\bar{p}_{ij}(u) = \begin{cases} (1-\beta)^{-1} p_{ij}(u), & \text{若 } j \neq s, \\ (1-\beta)^{-1} [p_{ij}(u) - \beta], & \text{若 } j = s. \end{cases}$$

证明 $\beta \bar{J}(s)$ 和 $\bar{J}(i)$ 分别是最优平均代价和微分代价, 其中 $\bar{J}$ 是 $(1-\beta)$ 折扣问题的最优代价函数。

9. 求解计算机制造商问题(第五章习题 1)的平均代价形式($\alpha=1$), 并验证命题 2(c) 的结果成立。

10. 连续时间马尔科夫链。考虑 § 6.7 中讨论的这类连续时间马尔科夫链控制问题。对此情况, 代价为

$$\lim_{T \rightarrow \infty} E \left\{ \frac{1}{T} \int_0^T g[x(t), u(t)] dt \right\}.$$

利用类似于 § 6.7 的论证方法, 证明:

(a) 存在一个等价的离散时间马尔科夫链问题, 具有平均代价

$$\lim_{N \rightarrow \infty} \frac{1}{N} E \left\{ \sum_{k=0}^{N-1} \frac{g(x_k, u_k)}{\nu} \right\},$$

其中 ν 是所有转移率 $\nu_i(u)$ 的一个上界。

(b) 此问题的贝尔曼方程取如下形式

$$\lambda + h(i) = \frac{1}{\nu} \min_{u \in U(i)} \left[g(i, u) + [\nu - \nu_i(u)] h(i) + \nu_i(u) \sum_j \bar{p}_{ij}(u) h(j) \right].$$

11. 考虑 § 6.7 例题 1 的制造商问题, 对此情况, $\beta=0$, 代价是

$$\lim_{T \rightarrow \infty} \frac{1}{T} E \left\{ \int_0^T g[x(t), u(t)] dt \right\}.$$

(a) 证明贝尔曼方程取如下形式

$$\lambda + h(i) = \min \left[K + h(1), \frac{ci}{\lambda} + h(i+1) \right].$$

(b) 证明存在一个阈值 i^* , 当且仅当 i 等于或超过 i^* 时才使得处理订货是最优的。

提示: 利用命题 2。

附录: 存在性结果和证明

在此附录中, 我们对本章正文中的某些结果(引理 1 和命题 4) 提供证明。在此过程中, 我们将要展示最优平稳策略的存在性。这一结果的证明是基于平均代价问题与其折扣形式之间的关系。在命题 2 和 3 的证明中我们已应用了这一关系, 在此情况下最优平均代价与初始状态无关。我们现在考虑一般的情况。本附录通篇考虑有限状态马尔科夫链情况, 且使用本章引言中建立的记号。

对于任意平稳策略 $\{\mu, \mu, \dots\}$, 相应的 α 折扣代价以向量形式给出

$$J_{\alpha, \mu} = \sum_{k=0}^{\infty} \alpha^k P_{\mu}^k g_{\mu} = (I - \alpha P_{\mu})^{-1} g_{\mu}, \quad \alpha \in (0, 1). \quad (A7.1)$$

下面的命题对 $(I - \alpha P_{\mu})^{-1}$ 提出一种表达式, 而且同时证明了引理 1。

命题 A7.1 对于任意随机矩阵 P 和 $\alpha \in (0, 1)$, 成立

$$(I - \alpha P)^{-1} = (1 - \alpha)^{-1} P^* + H + O(|1 - \alpha|), \quad (A7.2)$$

其中 $O(|1 - \alpha|)$ 是一个依赖于 α 的矩阵, 使得

$$\lim_{\alpha \rightarrow 1} O(|1 - \alpha|) = 0, \quad (A7.3)$$

而矩阵 P^* 和 H 由下式给出

$$P^* = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=0}^{N-1} P^k, \quad (A7.4)$$

$$H = (I - P + P^*)^{-1} - P^*. \quad (A7.5)$$

[式(A7.4)的极限和式(A7.5)中逆的存在性将作为证明的一部分。]而且, P^* 和 H 满足如下方程:

$$P^* = PP^* = P^*P = P^*P^*, \quad (A7.6)$$

$$P^*H = 0, \quad (A7.7)$$

$$P^* + H = I + PH. \quad (A7.8)$$

证明: 由通常的矩阵求逆公式知, $(1 - \alpha P)^{-1}$ 可以表示为一个矩阵, 其元素或为零, 或者分母和分子均为 α 的多项式且无公因子的分式。每个非零元的分母多项式不可能有多重根 1, 因为不然的话, 矩阵 $(1 - \alpha)(I - \alpha P)^{-1}$ 就有某个元素当 $\alpha \rightarrow 1$ 时趋于无限大, 而这根据折扣代价的解释式(A7.1)和 $|J_{\alpha, \mu}(j)| \leq (1 - \alpha)^{-1} \max_i |g_{\mu}(i)|$ 的事实是不可能的。因此, $(I - \alpha P)^{-1}$ 在 $\alpha = 1$ 的邻域有一个展开式, 形如式(A7.2)和式(A7.3), 且有等式关系

$$P^* = \lim_{\alpha \rightarrow 1} (1 - \alpha)(I - \alpha P)^{-1}, \quad (A7.9)$$

$$H = \lim_{\alpha \rightarrow 1} [(I - \alpha P)^{-1} - (1 - \alpha)^{-1} P^*]. \quad (A7.10)$$

现在我们按次序证明方程(A7.6), (A7.5), (A7.7)和(A7.8), 最后证明式(A7.4)。我们有

$$(I - \alpha P)(I - \alpha P)^{-1} = I, \quad (A7.11)$$

和

$$\alpha(I - \alpha P)(I - \alpha P)^{-1} = \alpha I. \quad (A7.12)$$

两个方程相减并将项重新排列得

$$\alpha P(1 - \alpha)(I - \alpha P)^{-1} = (1 - \alpha)(I - \alpha P)^{-1} + (\alpha - 1)I.$$

当 $\alpha \rightarrow 1$ 时取极限, 再利用定义式(A7.9), 得

$$PP^* = P^*.$$

又, 通过在式(A7.11)和式(A7.12)中颠倒 $(I - \alpha P)$ 和 $(I - \alpha P)^{-1}$ 的次序, 类似可得 $P^*P = P^*$ 。

由 $PP^* = P^*$, 我们还得到 $(I - \alpha P)P^* = (1 - \alpha)P^*$, 或 $P^* = (1 - \alpha)(I - \alpha P)^{-1}P^*$, 当 $\alpha \rightarrow 1$ 时取极限有 $P^* = P^*P^*$ 。于是式(A7.6)得证。

利用式(A7.6)有 $(P - P^*)^2 = P^2 - P^*$, 类似地有

$$(P - P^*)^k = P^k - P^*, \quad k > 0.$$

因此,

$$\begin{aligned} (I - \alpha P)^{-1} - (1 - \alpha)^{-1}P^* &= \sum_{k=0}^{\infty} \alpha^k (P^k - P^*) \\ &= I - P^* + \sum_{k=1}^{\infty} \alpha^k (P - P^*)^k \\ &= [I - \alpha(P - P^*)]^{-1} - P^*, \end{aligned}$$

当 $\alpha \rightarrow 1$ 时取极限, 再利用式(A7.10), 得式(A7.5)。

由式(A7.5)得

$$(I - P + P^*)H = I - (I - P + P^*)P^*,$$

或利用式(A7.6),

$$H - PH + P^*H = I - P^*. \quad (A7.13)$$

用 P^* 乘以这个关系式, 再利用式(A7.6)得 $P^*H = 0$, 此即式(A7.7)。方程(A7.8)则由式(A7.13)而得。

用 P^* 乘以式(A7.8), 再利用式(A7.6)得

$$P^* + P^k H = P^k + P^{k+1} H, \quad k = 0, 1, \dots.$$

对 $k = 0, \dots, N-1$, 将此式相加, 有

$$NP^* + H = \sum_{k=0}^{N-1} P^k + P^N H.$$

除以 N , 且当 $N \rightarrow \infty$ 时取极限, 得式(A7.4)。

证毕

由表达式(A7.1)和命题 A7.1, 我们得到如下 α 折扣代价和相应于平稳策略的平均代价之间的关系。

命题 A7.2 对于任意平稳策略 $\{\mu, \mu, \dots\}$, 及 $\alpha \in (0, 1)$, 下式成立:

$$J_{\alpha, \mu} = (1 - \alpha)^{-1} J_{\mu} + h_{\mu} + 0(|1 - \alpha|), \quad (A7.14)$$

其中

$$J_{\mu} = P_{\mu}^* g_{\mu} = \left(\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=0}^{N-1} P_{\mu}^k \right) g_{\mu}$$

是相应于 μ 的平均代价向量, 而 h_{μ} 是微分代价向量, 满足

$$J_{\mu} + h_{\mu} = g_{\mu} + P_{\mu} h_{\mu}.$$

证明: 此证明是根据式(A7.1)和命题 A7.1, 以及恒等关系式 $P = P_{\mu^*}, P_{\mu^*}^* = P_{\mu^*}^*$, 和 $h_{\mu^*} = Hg_{\mu^*}$. 证毕

由 §5.1 知道, 对于每个 $\alpha \in (0, 1)$, α 折扣问题存在一个最优平稳策略。如果它对所有 α 折扣问题同时为最优, 其中 α 在区间 $(\bar{\alpha}, 1)$ 中, 而 $\bar{\alpha} \in (0, 1)$ 是某个标量, 我们称这个平稳策略 $\{\mu, \mu, \dots\}$ 为 Blackwell 最优的。这个概念和以下分析最先在 [B26] 中介绍。由命题 A7.2 知, 一个 Blackwell 最优策略, 在所有平稳策略类中对平均代价问题是最优的。为弄清楚这一点, 注意到若 $\{\mu^*, \mu^*, \dots\}$ 为 Blackwell 最优的, 则对所有平稳策略 $\{\mu, \mu, \dots\}$ 和区间 $(\bar{\alpha}, 1)$ 的 α 有 $J_{\alpha, \mu^*} \leq J_{\alpha, \mu}$ 。等效地, 利用式(A7.14),

$$\begin{aligned} & (1-\alpha)^{-1}J_{\mu^*}^* + h_{\mu^*}^* + 0(|1-\alpha|) \\ & \leq (1-\alpha)^{-1}J_{\mu} + h_{\mu} + 0(|1-\alpha|), \quad \alpha \in (\bar{\alpha}, 1), \end{aligned}$$

或

$$J_{\mu^*} \leq J_{\mu} + (1-\alpha)(h_{\mu} - h_{\mu^*}) + (1-\alpha)0(|1-\alpha|), \quad \alpha \in (\bar{\alpha}, 1).$$

当 $\alpha \rightarrow 1$ 取极限得 $J_{\mu^*} \leq J_{\mu}$ 。反之并不成立, 即一个最优平稳平均代价策略可能不是 Blackwell 最优的 (见习题 6)。还要指出, 我们可以证明更强的结果, 即一个 Blackwell 最优的策略, 在所有的策略类 (不仅是平稳的, 见习题 7) 中也是平均代价最优的。

下面的命题非常重要, 且为命题 4 的证明提供了基础。

命题 A7.3 存在一个 Blackwell 最优策略。

证明: 由式(A7.1)知, 对每个 μ 和状态 i , $J_{\alpha, \mu}(i)$ 为 α 的一个有理函数。因此, 对任意两个策略 μ 和 μ' , $J_{\alpha, \mu}(i)$ 和 $J_{\alpha, \mu'}(i)$ 的图形在区间 $(0, 1)$ 或者重合, 或者仅相交有限次。因为仅存在有限个策略, 我们可以得出结论: 对于状态 i , 存在一个策略 μ^i 和一个标量 $\bar{\alpha}_i \in (0, 1)$, 使得当初始状态为 i 时, 对于 $\alpha \in (\bar{\alpha}_i, 1)$, μ^i 对 α 折扣问题为最优。考虑对每个 i , 由 $\mu^*(i) = \mu^i(i)$ 定义的平稳策略, 可以看出, 对所有 α , 且 $\max_i \bar{\alpha}_i < \alpha < 1$, $\{\mu^*, \mu^*, \dots\}$ 为 α 折扣问题的一个最优平稳策略, 因此, $\{\mu^*, \mu^*, \dots\}$ 是 Blackwell 最优的。证毕

下面的命题提出了 Blackwell 最优策略的一个特征:

命题 A7.4 如果 $\{\mu^*, \mu^*, \dots\}$ 是 Blackwell 最优的, 则对所有平稳策略 $\{\mu, \mu, \dots\}$ 有

$$J_{\mu^*} = P_{\mu^*} J_{\mu^*} \leq P_{\mu} J_{\mu^*}. \quad (A7.15)$$

而且, 对所有 μ 使得 $P_{\mu^*} J_{\mu^*} = P_{\mu} J_{\mu^*}$, 则有

$$J_{\mu^*} + h_{\mu^*} = g_{\mu^*} + P_{\mu^*} h_{\mu^*} \leq g_{\mu} + P_{\mu} h_{\mu^*}, \quad (A7.16)$$

其中 h_{μ^*} 就是相应于 μ^* 的一个微分代价向量 (见命题 A7.2)。

证明: 因为对区间 $(\bar{\alpha}, 1)$ 中的所有 α , $\{\mu^*, \mu^*, \dots\}$ 为 α 折扣问题最优的, 对每个 μ 必有

$$J_{\alpha, \mu^*} = g_{\mu^*} + \alpha P_{\mu^*} J_{\alpha, \mu^*} \leq g_{\mu} + P_{\mu} J_{\alpha, \mu^*}. \quad (A7.17)$$

由命题 A7.2 知, 对所有 $\alpha \in (\bar{\alpha}, 1)$ 有

$$J_{\alpha, \mu^*} = (1-\alpha)^{-1}J_{\mu^*} + h_{\mu^*} + 0(|1-\alpha|).$$

把这一表达式代入式(A7.17), 而且当 $\alpha \rightarrow 1$ 时取极限, 我们就得到所要求的关系式。证毕

注意到如果相应于一个 Blackwell 最优策略 $\{\mu^*, \mu^*, \dots\}$ 的平均代价 $J_{\mu^*}(i)$ 与初始状态 i 无关 [即对所有 $i, J_{\mu^*}(i) = \lambda$], 那么, 对于每个 μ , 向量 $P_{\mu} J_{\mu^*}$ 的每个元素等于 λ 。由式

(A7.16), 则得

$$\lambda c + h_{\mu^*} = T(h_{\mu^*}) = \min_{\mu} [g_{\mu} + P_{\mu} h_{\mu^*}],$$

这就是命题 1 的充分条件。因此, 为证明命题 4, 只要证明其假设 保证 Blackwell 最优策略获得与初始状态无关的平均代价就足够了。这就是以下证明的基础。

命题 4 的证明

如果一个平稳策略 $\{\mu, \mu, \dots\}$ 产生一个马尔科夫链, 它具有一个单一遍历类, 相应的平均代价 $J_{\mu}(i)$ 则与初始状态 i 无关。(这已在命题 8 中证明, 而且也可以将命题 3 的证明推广而证得。)因此, 在命题的假设 (a) 下, 一个 Blackwell 最优策略获得与初始状态无关的平均代价, 且此结果由前面讨论所得出。

假定假设 (b) 成立, 即每一对状态在某个平稳策略下互通。考虑一个 Blackwell 最优策略 $\{\mu^*, \mu^*, \dots\}$, 如果它产生一个与初始状态无关的平均代价, 则如前, 已完成了证明。假定相反, 即集合 M 和 $\bar{M}$ 是非空的, 这里

$$M = \{i | J_{\mu^*}(i) = \max_j J_{\mu^*}(j)\},$$

而 $\bar{M}$ 是 M 的补集。现在的想法是, 与 $\bar{M}$ 中状态进行互通, 应该有可能减小 相应于 M 中状态的平均代价, 这样就有矛盾。取任意状态 $i \in M$ 和 $j \in \bar{M}$, 和一个平稳策略 $\{\mu, \mu, \dots\}$, 使得对某个 k , $P(x_k = j | x_0 = i, \mu) > 0$ 。那么, 必存在状态 $m \in M$ 和 $\bar{m} \in \bar{M}$, 使得在策略 μ 下存在一个由 m 到 $\bar{m}$ 的正转移概率, 即 $[P_{\mu}]_{m\bar{m}} = P(x_{k+1} = \bar{m} | x_k = m, \mu) > 0$ 。容易看出, $P_{\mu} J_{\mu^*}$ 的第 m 个分量严格地小于 $\max_i J_{\mu^*}(i)$, 后者等于 J_{μ^*} 的第 m 个分量。这与必要条件式 (A7.15) 相矛盾。

证毕

附录 A

数学综述

本节及以后各附录的目的是提供本书常用的一些数学和概率的定义、概念、关系及结果。关于详细的推导可参阅各附录中给出的参考文献。

A.1 集合

如果 x 是集合 S 的一个元, 写成 $x \in S$; 如果 x 不是 S 的元写成 $x \notin S$ 。集合 S 可用括号内列出它的元来确定。例如 $S = \{x_1, x_2, \dots, x_n\}$ 是指集合 S 由元 $x_1, \dots, x_n$ 组成, 集合 S 也可以一般形式来确定。

$$S = \{x | x \text{ 满足 } P\}$$

表示为满足性质 P 的元的集合。例如

$$S = \{x | x: \text{实数}, 0 \leq x \leq 1\}$$

表示所有满足 $0 \leq x \leq 1$ 的元的集合。

两个集合 S 和 T 的并由 $S \cup T$ 表示, S 和 T 的交由 $S \cap T$ 表示。集合序列 $S_1, S_2, \dots, S_k, \dots$ 的并和交分别用 $\bigcup_{k=1}^{\infty} S_k$ 和 $\bigcap_{k=1}^{\infty} S_k$ 表示。如果 S 是 T 的子集(即 S 的每一个元也是 T 的一个元), 写成 $S \subset T$ 或 $T \supset S$ 。

有限和可数集合

如果 S 由有限个元组成, 集合 S 称为有限的。如果 S 的各元与非负整数存在一种联系, 使 S 的一对不同元对应于两个不同整数, 则集合称为可数。因此, 根据定义, 有限集合也是可数的, 但相反不成立。非有限的可数集合可列出它的元来表示 $x_0, x_1, x_2, \dots$ (即 $S = \{x_0, x_1, x_2, \dots\}$)。如果 $A = \{a_0, a_1, \dots\}$ 是可数集合, $S_{a_0}, S_{a_1}, \dots$ 各是可数集合, 则 $\bigcup_{k=1}^{\infty} S_{a_k}$ (或 $\bigcup_{a \in A} S_a$) 也是可数集合。

实数集合

如果 a 和 b 是实数或 $+\infty, -\infty$, 用 $[a, b]$ 表示满足 $a \leq x \leq b$, 元 x 的集合(包括 $x = +\infty$ 或 $x = -\infty$ 的可能性)。圆括号代替方括号表示定义中严格的不等式。因此, $(a, b], [a, b)$ 和 (a, b) 分别表示满足 $0 < x \leq b, a \leq x < b$ 和 $a < x < b$ 元 x 的集合。

如果 S 是上有界的实数集合, 则存在一个最小的实数 y , 使得对所有 $x \in S$, 有 $x \leq y$, 则这个数称作最小上界或上确界。表示为 $\sup\{x | x \in S\}$ 或 $\max\{x | x \in S\}$ (这与通常数学上使用符号有些不一致, 这里用 $\max$ 代替 $\sup$ 说明上确界由 S 的某些元所达到)。同样, 对所有 $x \in S$, 最大实数 z 使 $z \leq x$, 称作 S 的最大下界或下确界, 由 $\inf\{x | x \in S\}$ 或 $\min\{x | x \in S\}$ 表示。如果 S 是上无界的, 写成 $\sup\{x | x \in S\} = +\infty$; 如果 S 是下无界的, 写成 $\inf\{x | x \in S\} = -\infty$; 如果 S 是空集, 则按规定写成 $\inf\{x | x \in S\} = +\infty$ 以及 $\sup\{x | x \in S\} = -\infty$ 。

4.2 欧氏空间

所有 n 元组 $x = (x_1, \dots, x_n)$, $x_1, \dots, x_n$ 为实数构成了 n 维欧氏空间, 用 R^n 表示。 R^n 的元看成是 n 维向量。或在不会混淆情况下简称为向量。一维欧氏空间 R^1 由所有实数组成, 表示为 R^1 。在 R^n 中向量可以由它的相应分量加起来。向量乘上一个标量可通过向量各元素乘以该标量来实现。两个向量 $x = (x_1, \dots, x_n)$ 和 $y = (y_1, \dots, y_n)$ 的内积(或标量积)由 $x' y$ 表示, 并等于 $\sum_{i=1}^n x_i y_i$ 。一个向量 $x = (x_1, \dots, x_n) \in R^n$ 的范数由 $\|x\|$ 表示, 并等于 $(x' x)^{\frac{1}{2}} = (\sum_{i=1}^n x_i^2)^{\frac{1}{2}}$ 。

如存在非全为零的标量 $\lambda_1, \lambda_2, \dots, \lambda_k$, 使 $\sum_{i=1}^k \lambda_i a_i = 0$, 则称向量集合 $a_1, a_2, \dots, a_k$ 为线性相关; 如果这种标量集合不存在, 这些向量称为线性独立。

4.3 矩阵

一个 $m \times n$ 的矩阵是一个数的矩形阵列; 该数称为元素, 以 m 个行和 n 个列排列。矩阵 A 中第 i 行和第 j 列的元素由下标 ij 表示, 如 a_{ij} 。在这种情况下, 我们写成 $A = [a_{ij}]$ 。元素 $a_{ij} = 0$, $i \neq j$ 和 $a_{ii} = 1$, $i = 1, \dots, n$ 的方阵称为单位阵。两个 $m \times n$ 的矩阵之和写成 $A + B$, 其矩阵的元素是 A 和 B 矩阵相应元素之和。一个矩阵 A 和一个标量 λ 之积写成 λA , 或 $A\lambda$ 。由 A 中各元素乘上 λ 得到。一个 $m \times n$ 矩阵 A 和一个 $n \times p$ 矩阵 B 的乘积 AB 为一个 $m \times p$ 的矩阵 C , 其元素为 $C_{ij} = \sum_{k=1}^n a_{ik} b_{kj}$ 。如果 b 是 $n \times 1$ 矩阵(即 n 维列向量), A 是一个 $m \times n$ 矩阵, 则 Ab 是一个 m 维(列)向量。

一个 $m \times n$ 矩阵 A 的转置是 $n \times m$ 矩阵 A' , 其元素 $a'_{ij} = a_{ji}$ 。如果 $A' = A$, 则 A 阵为对称。一个 $n \times n$ 方阵是非奇异的, 如果存在一个称为 A 逆的 $n \times n$ 矩阵, 表示为 A^{-1} , 使 $A^{-1}A = I = AA^{-1}$, I 是 $n \times n$ 的单位阵。当且仅当构成行的 n 个向量为线性独立; 或等效地, 构成列的 n 个向量为线性独立时, 方阵 A 才是非奇异的。

分块矩阵

通过矩阵画分割线, 将矩阵分成 n 个子矩阵, 这常常是方便的。例如矩阵:

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \end{bmatrix}$$

可以划分为

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix},$$

式中

$$\begin{aligned} A_{11} &= [a_{11} \ a_{12}], & A_{12} &= [a_{13} \ a_{14}], \\ A_{21} &= \begin{bmatrix} a_{21} & a_{22} \\ a_{31} & a_{32} \end{bmatrix}, & A_{22} &= \begin{bmatrix} a_{23} & a_{24} \\ a_{33} & a_{34} \end{bmatrix}. \end{aligned}$$

对一个分块矩阵 $A = [B : C]$, 我们可互换标记为 $[B, C]$ 或 $[BC]$, 分块矩阵 A 的转置是

$$A' = \begin{bmatrix} A'_{11} & A'_{21} \\ A'_{12} & A'_{22} \end{bmatrix}.$$

分块矩阵同非分块矩阵一样可以相乘, 如果在分块中所涉及的维数相匹配。因此, 如

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}, \quad B = \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix},$$

如果子矩阵的维数可以形成前述的乘积 $A_{ij}B_{jk}$, $i, j, k = 1, 2$ 。则

$$AB = \begin{bmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{bmatrix}.$$

矩阵的秩

矩阵 A 的秩等于线性独立行向量的最大数目。也等于线性独立列向量的最大数目。一个 $m \times n$ 的矩阵 A 称为满秩, 如果 A 的秩等于 m 和 n 的最小值。一个方阵当且仅当为可逆时(即非奇异)才是满秩。

正定和半正定矩阵

一个 $n \times n$ 对称方阵 A 称为半正定, 如果对所有 $x \in R^n$, 有 $x'Ax \geq 0$ 。如果对所有非零 $x \in R^n$, 有 $x'Ax > 0$, 就称为正定。矩阵 A 称为负半定(负定), 如果 $(-A)$ 是半正定(正定)。

一个正(负)定矩阵是可逆的, 且其逆也是正(负)定的。相反, 一个可逆半正(负)定矩阵是正(负)定的。如果 A 和 B 是 $n \times n$ 半正定(正定)矩阵, 则对所有 $\lambda > 0$ 和 $\mu > 0$ 矩阵 $\lambda A + \mu B$ 也是半正定(正定)的。如果 A 是 $n \times n$ 半正定矩阵, C 是 $m \times n$ 矩阵, 则矩阵 CAC' 正定。

一个 $n \times n$ 正定矩阵 A 可以写成 CC' , C 是可逆方阵。如果 A 是半正定且它的秩是 m , 则可以写成 CC' , C 是 $n \times m$ 满秩矩阵。

矩阵求逆公式

下面表示不同矩阵求逆的公式, 通常十分有用。令 A 和 B 为可逆方阵, C 为适当维数的矩阵, 则以下的逆存在,

$$(A + CBC')^{-1} = A^{-1} - A^{-1}C(B^{-1} + C'A^{-1}C)^{-1}C'A^{-1}.$$

此方程式可用右乘 $(A + CBC')$ 来证明, 它表明乘积为单位矩阵。

考虑一个分块矩阵 M , 形式为

$$M = \begin{bmatrix} A & B \\ C & D \end{bmatrix}.$$

假定所有的逆存在, 我们有:

$$M^{-1} = \left[\begin{array}{c|c} Q & -QBD^{-1} \\ \hline -D^{-1}CQ & D^{-1} + D^{-1}CQBD^{-1} \end{array} \right],$$

式中

$$Q = (A - BD^{-1}C)^{-1}.$$

其证明可以将 M 乘上 M^{-1} 的表达式来得到, 并判断其乘积为单位矩阵。

A.4 R^n 中的拓扑概念

序列的收敛

R^n 中一个向量序列 $x_0, x_1, \dots, x_k, \dots$, 表示为 $\{x_k\}$, 当 $k \rightarrow \infty$ 时, 如 $\|x_k - x\| \rightarrow 0$, 则称

为收敛于一个极限向量 x (即, 如果给定 $\epsilon > 0$, 存在一个 N , 使得对所有 $k \geq N$, 有 $\|x_k - x\| < \epsilon$)。如果 $\{x_n\}$ 收敛于 x , 用们写成 $x_k \rightarrow x$, 或 $\lim_{k \rightarrow \infty} x_k = x$ 。可以容易地证明, 如果 $x_k \rightarrow x$, $y_k \rightarrow y$, 我们有 $Ax_k + By_k \rightarrow Ax + By$, A, B 为适当维数的矩阵。

如果存在一个收敛于 x 的 $\{x_k\}$ 的子序列, 即如果存在一个非负整数的无限子集 K , 使 $\{x_k\}_{k \in K}$ 收敛于 x , 则 x 称为序列 $\{x_k\}$ 的极限点。

一个单调非减(非增)实数序列 $\{r_k\}$, 即对所有 k , 满足 $r_k \leq r_{k+1}$ ($r_k \geq r_{k+1}$), 必定或者收敛于一个实数或者上无界的(下无界的)。在这种情况下我们写成 $\lim_{k \rightarrow \infty} r_k = +\infty$ ($-\infty$)。给定任何实数有界序列 $\{r_k\}$, 我们可考虑序列 $\{s_k\}$, 式中 $s_k = \sup\{r_i | i \geq k\}$ 。因为这个序列单调非增并有界, 它必有一个极限, 称之为 $\{r_k\}$ 上极限, 表示为 $\limsup_{k \rightarrow \infty} r_k$ 。同样, 我们定义 $\{r_k\}$ 的下极限, 表示为 $\liminf_{k \rightarrow \infty} r_k$ 。如果 $\{r_k\}$ 是上无界的, 我们写成 $\limsup_{k \rightarrow \infty} r_k = +\infty$; 如果是下无界的, 写成 $\liminf_{k \rightarrow \infty} r_k = -\infty$ 。如果对所有 k , $r_k \in [-\infty, \infty]$, 我们也用这种标记。

开、闭和紧集合

如果对每一向量 $x \in S$, 可以找到一个 $\epsilon > 0$, 使得 $\{z | \|z - x\| < \epsilon\} \subset S$, 则称 R^n 的子集 S 为开集。当且仅当 S 在 R^n 中的补是开集时, 集合 S 为闭集。等效地说, 当且仅当元在 S 中的每一个收敛序列 $\{x_k\}$ 收敛于也属于 S 的一个点时, S 为闭集。当且仅当 S 既是闭集又有界时, 则称 S 为紧集(即它是闭集, 且对某个 $M > 0$, 对所有 $x \in S$, 我们有 $\|x\| \leq M$)。当且仅当元在 S 的每一个序列 $\{x_k\}$ 至少有一个属于 S 的极限点时, S 才是紧集合。另一重要事实是, 如果 $S_0, S_1, \dots, S_k, \dots$ 是一个在 R^n 中非空紧集的序列, 使对所有 k , $S_k \supset S_{k+1}$, 则交 $\bigcap_k S_k$ 是一个非空紧集。

连续函数

一个函数 f 将一个集合 S_1 映射到另一个集合 S_2 表示为 $f: S_1 \rightarrow S_2$ 。如果 $x_k \rightarrow x$ 时, $f(x_k) \rightarrow f(x)$, 函数 $f: R^n \rightarrow R^m$ 就称为是连续的。等效地, 如果给定 $x \in R^n$, 和 $\epsilon > 0$, 存在一个 $\delta > 0$, 使 $\|y - x\| < \delta$, 有 $\|f(y) - f(x)\| < \epsilon$, 则函数 f 是连续的。对任何两个标量 a_1, a_2 和任何两个函数 $f_1, f_2: R^n \rightarrow R^m$, 则函数

$$(a_1 f_1 + a_2 f_2)(\cdot) = a_1 f_1(\cdot) + a_2 f_2(\cdot)$$

是连续的。如果 S_1, S_2, S_3 为任何集合, $f_1: S_1 \rightarrow S_2$, $f_2: S_2 \rightarrow S_3$ 为函数, 函数 $f_1 \cdot f_2: S_1 \rightarrow S_3$, 它定义为 $(f_2 \cdot f_1)(x) = f_2[f_1(x)]$ 称为 f_1 和 f_2 的复合函数。如果 $f_1: R^n \rightarrow R^m$ 和 $f_2: R^m \rightarrow R^p$ 是连续的, 则 $f_2 \cdot f_1$ 也是连续的。

4.5 凸集和函数

如果对每一个 $x_1, x_2 \in C$ 和每一个标量 α , $0 \leq \alpha \leq 1$, 我们有 $\alpha x_1 + (1 - \alpha)x_2 \in C$, 则 R^n 的子集 C 是凸的。也就是说, 如果连接 C 中二点的线段属于 C , 则 C 是凸的。一个定义在 R^n 中一个凸子集 C 上的函数 $f: C \rightarrow R$, 如果对某一个 $x_1, x_2 \in C$ 和每一个标量 α , $0 \leq \alpha \leq 1$, 有

$$f[\alpha x_1 + (1 - \alpha)x_2] \leq \alpha f(x_1) + (1 - \alpha)f(x_2),$$

则函数是凸的。

如果 $(-f)$ 是凸的, 函数 f 称为是凹的。如果 $f: C \rightarrow R$ 是凸的, 则对于每一个标量 λ , 集合 $\Gamma_\lambda = \{x | x \in C, f(x) \leq \lambda\}$ 也都为凸的。一个重要性质是 R^n 中的实值凸函数通常是一个连续函数。

如果 $f_1, f_2, \dots, f_m$ 是关于 R^n 中的一个凸子集 C 的凸函数, $a_1, a_2, \dots, a_m$ 为非负标量, 则函数 $a_1 f_1 + \dots + a_m f_m$ 也是关于 C 的凸函数。如果 $f: R^n \rightarrow R$ 是凸的, A 是 $m \times n$ 矩阵, b 是 R^m 中向量, 则由 $g(x) = f(Ax + b)$ 所定义的函数 $g: R^n \rightarrow R$ 也是凸的。如果函数 $f: R^n \rightarrow R$ 是凸的, 假定对每一个 $x \in R^n$, 期望值适当定义并有限, 则函数 $g(x) = E_w\{f(x+w)\}$ 是一个凸函数。式中 w 是 R^n 中一个随机变量。

对可微的函数 $f: R^n \rightarrow R$, 存在另一些凸性的特征。这样, 如 $\nabla f(x)$ 表示 f 在 x 的梯度, 即为列向量

$$\nabla f(x) = \left[\frac{\partial f(x)}{\partial x^1}, \dots, \frac{\partial f(x)}{\partial x^n} \right]',$$

当且仅当

$$f(y) \geq f(x) + \nabla f(x)'(y-x), \text{ 对所有 } x, y \in R^n,$$

函数 f 是凸的。

如果 $\nabla^2 f(x)$ 表示 f 对 x 的海森矩阵, 即

$$\nabla^2 f(x) = \left[\frac{\partial^2 f(x)}{\partial x^i \partial x^j} \right],$$

其元素为 f 对 x 的二次导数。则当且仅当, 对每一个 $x \in R^n$, $\nabla^2 f(x)$ 为一个半正定矩阵时, f 是凸的。

本附录详细的材料, 见参考文献[H10], [S27], [R2], [R9]和[R10]。

附录 B

关于优化理论

给定定义在集合 S 的一个实值函数 $f: S \rightarrow R$ 和一个子集 $x \subset S$, 所谓最优化问题

$$\min f(x) \quad (B \cdot 1)$$

约束: $x \in X$,

是寻找一个元 $x^* \in X$ (称作极小的元或最优解) 使得

$$f(x^*) \leq f(x) \quad \text{对所有 } x \in X.$$

这样一个元不一定存在。例如标量函数 $f(x) = x$ 和 $f(x) = e^x$ 对实数集没有极小元。第一个函数当 x 趋于 $-\infty$ 时, 无界地递减至 $-\infty$; 而第二函数当 x 趋于 $-\infty$ 时, 向零递减, 但一直取正值。当 x 在 X , 即实数集上变化时, 给定 $f(x)$ 取值的范围:

$$\{f(x) | x \in X\}$$

有两种可能性:

1) 集合 $\{f(x) | x \in X\}$ 是下无界的 (即含有任意小实数), 这种情况下, 写作:

$$\min\{f(x) | x \in X\} = -\infty \text{ 或}$$

$$\min_{x \in X} f(x) = -\infty.$$

2) 集合 $\{f(x) | x \in X\}$ 是下有界的, 即存在一个标量 M , 对所有 $x \in X$ 使 $M \leq f(x)$ 。 $\{f(x) | x \in X\}$ 的最大下界也由下式表示:

$$\min\{f(x) | x \in X\} \text{ 或 } \min_{x \in X} f(x).$$

不论哪一种情况, 我们称 $\min_{x \in X} f(x)$ 为问题式 (B·1) 的最优值。

极大化问题形式为:

$$\max f(x)$$

约束: $x \in X$,

可以转换成极小化问题

$$\min -f(x)$$

约束: $x \in X$ 。

在这个意义上两个问题有相同的最优解, 且一个问题的最优值等于另一问题负的最优解。极大化问题的最优值由 $\max_{x \in X} f(x)$ 来表示。

最优解的存在性

证明在问题式 (B·1) 中至少存在一个极小元常引起人们的注意。当 X 是一个有限集合时, 这样一个元显然是存在的。当 X 不是有限时, 如果 $f: R^n \rightarrow R$ 是一个连续函数, 且 X 是 R^n 的一个紧子集, 则保证问题式 (B·1) 极小点的存在性。这就是 Weierstrass 定理。根据有关的结果, 如果 $f: R^n \rightarrow R$ 是一个连续函数, $X = R^n$, 且当 $\|x\| \rightarrow +\infty$ 时, $f(x) \rightarrow +\infty$, 则保证极小点的存在性。

最优的充要条件

当 f 在 R^n 上可微且 X 是 R^n 的一个凸子集(可能 $X = R^n$)时, 这种充要条件是存在的。因此, 如果 x^* 是问题式(B·1)中极小点, $f: R^n \rightarrow R$ 是 R^n 上连续可微函数, X 为凸, 我们有:

$$\nabla f(x^*)'(x - x^*) \geq 0, \text{ 对所有 } x \in X. \quad (B \cdot 2)$$

式中 $\nabla f(x^*)$ 表示 f 在 x^* 的梯度。当 $X = R^n$ (即极小化无约束)时, 必要条件式(B·2)等效于熟悉的条件

$$\nabla f(x^*) = 0. \quad (B \cdot 3)$$

另外, 当 f 二次连续可微, 且 $X = R^n$ 时, 一个附加的必要条件是海森矩阵 $\nabla^2 f(x^*)$ 在 x^* 是半正定。一个重要的事实是: 如果 $f: R^n \rightarrow R$ 是一个凸函数, 且 X 为凸, 则式(B·2)是点 x^* 的最优性的必要和充分条件。

二次形极小化问题

令 $f: R^n \rightarrow R$ 为一个二次形式:

$$f(x) = \frac{1}{2} x' Q x + b' x.$$

式中 Q 是一个 $n \times n$ 对称矩阵, $b \in R^n$ 。如果 Q 是一个正定阵, 则 f 是一个凸函数。它的梯度由下式给定:

$$\nabla f(x) = Q \cdot x + b.$$

由式(B·3), 当且仅当

$$\nabla f(x^*) = Q x^* + b = 0,$$

点 x^* 是一个极小点。由此得

$$x^* = -Q^{-1}b.$$

详细推导, 见参考文献[A 3],[L 9],[L 10]和[Z 1]。

附 录 C

关于概率论

本附录有选择地列出我们要用到的某些基本的概率概念。其主要目的使读者能熟悉我们要采用的某些术语。这并不意味已包括一切。关于详细的处理,特别是有关随机变量的运算,条件概率,贝页斯规则等等,读者应参阅文献[A 9], [F2], [P 6]和[P 7]。关于测度理论的概率论处理方法可看 R·B·Ash 的著作:实分析和概率(Real Analysis and Probability)

概率空间

一个概率空间由以下组成:

a) 一个集合 Ω 。

b) Ω 的子集的一个集类 $\mathcal{F}$, 叫做事件。它包括 Ω , 并有以下性质:

1) 如 A 是一事件, 则补 $\bar{A} = \{\omega \in \Omega | \omega \notin A\}$ 也是一个事件(Ω 的补是空集, 并认作一个事件)。

2) 如 A_1 和 A_2 是事件, 则 $A_1 \cap A_2$, $A_1 \cup A_2$ 也是事件。

3) 如果 $A_1, A_2, \dots, A_k, \dots$ 为事件, 则 $\bigcup_{k=1}^{\infty} A_k$ 和 $\bigcap_{k=1}^{\infty} A_k$ 也是事件。

c) 一个函数给各事件分配一个实数 $P(A)$, 称为事件 A 的概率, 满足

1) 对每一事件 A , $P(A) \geq 0$ 。

2) $P(\Omega) = 1$ 。

3) 对每对不相交事件 A_1, A_2 , $P(A_1 \cup A_2) = P(A_1) + P(A_2)$ 。

4) 对互不相交事件 $A_1, A_2, \dots, A_k, \dots$ 的每一序列,

$$P\left(\bigcup_{k=1}^{\infty} A_k\right) = \sum_{k=1}^{\infty} P(A_k)。$$

函数 P 称为概率测度。

有限和可数概率空间的约定

在本书中经常碰到集合 Ω 为可数(可能有限)集合这种概率空间的情况。我们指定 Ω 为有限或可数, 蕴涵地假定事件的相伴集类是 Ω 所有子集的集类(包括 Ω 和空集)。在这些条件下, 所有事件的概率是由 Ω 的元(即由 Ω 中单个元所组成的事件)的概率所确定。因此, 如果 Ω 是一个有限集合 $\Omega = \{\omega_1, \omega_2, \dots, \omega_n\}$, 概率空间由概率 $p_1, p_2, \dots, p_n$ 确定, 这里 p_i 表示由 ω_i 组成的事件的概率。类似地, 如果 $\Omega = \{\omega_1, \omega_2, \dots, \omega_k, \dots\}$, 则概率空间就由相应的概率 $p_1, p_2, \dots, p_k, \dots$ 所确定。无论哪种情况, 我们把 $(p_1, p_2, \dots, p_n)$ 或 $(p_1, p_2, \dots, p_k, \dots)$ 称作一个关于 Ω 的概率分布。

随机变量

给定一个概率空间 $(\Omega, \mathcal{F}, P)$, 在概率空间上的随机变量是一个函数 $x: \Omega \rightarrow R$, 使得对

每一个标量 λ , 集合

$$\{\omega \in \Omega | x(\omega) \leq \lambda\}$$

是一个事件(即属于集类 $\mathcal{F}$)。

一个 n 维随机向量 $x = (x_1, \dots, x_n)$ 是各定义在同一概率空间的随机向量 $x_1, x_2, \dots, x_n$ 的 n 元组。

一个随机变量 x 的分布函数 $F: R \rightarrow R$ 由下式定义:

$$F(z) = P(\{\omega \in \Omega | x(\omega) \leq z\}).$$

即 $F(z)$ 等于随机变量取值小于或等于 z 的概率。

一个随机向量 $x(x_1, x_2, \dots, x_n)$ 的分布函数 $F: R^n \rightarrow R$ 由下式定义:

$$F(z_1, z_2, \dots, z_n) = P(\{\omega \in \Omega | x_1(\omega) \leq z_1, x_2(\omega) \leq z_2, \dots, x_n(\omega) \leq z_n\}).$$

给定一个随机向量 $x = (x_1, \dots, x_n)$ 的分布函数, 各随机变量 x_i 的(边缘)分布函数由下式得到:

$$F_i(z_i) = \lim_{z_j \rightarrow \infty, j \neq i} F(z_1, z_2, \dots, z_n).$$

如果对所有标量 $z_1, \dots, z_n$,

$$F(z_1, \dots, z_n) = F_1(z_1)F_2(z_2) \cdots F_n(z_n),$$

则随机变量 $x_1, \dots, x_n$ 称作是独立的。

具有分布函数 F 的一个随机变量 x , 其期望值定义为:

$$E\{x\} = \int_{-\infty}^{\infty} z dF(z),$$

如果该积分已经定义。

一个随机向量 $x = (x_1, \dots, x_n)$ 的期望值为向量 $E(x) = (E(x_1), E(x_2), \dots, E(x_n))$ 。

具有期望值 $E\{x\} = (\bar{x}_1, \dots, \bar{x}_n)$ 的一个随机向量 $x = (x_1, \dots, x_n)$, 假定期望值适当定义, 则其方差阵定义为 $n \times n$ 对称半正定矩阵:

$$Q_x = \begin{bmatrix} E\{(x_1 - \bar{x}_1)^2\} & \cdots & E\{(x_1 - \bar{x}_1)(x_n - \bar{x}_n)\} \\ \vdots & & \\ E\{(x_n - \bar{x}_n)(x_1 - \bar{x}_1)\} & \cdots & E\{(x_n - \bar{x}_n)^2\} \end{bmatrix},$$

两个随机变量 x 和 y , 如果

$$E\{(x - E\{x\})(y - E\{y\})'\} = 0,$$

式中 $(x - E\{x\})$ 看作一个列向量, $(y - E\{y\})'$ 看作行向量, 则此两随机变量是不相关的。

如果对每一个 $z_1, \dots, z_n$, f 为分段连续, 并且

$$F(z_1, \dots, z_n) = \int_{-\infty}^{z_1} \int_{-\infty}^{z_2} \cdots \int_{-\infty}^{z_n} f(y_1, \dots, y_n) dy_1 \cdots dy_n,$$

则随机向量 $x = (x_1, \dots, x_n)$ 称为由分段连续密度函数 $f: R^n \rightarrow R$ 所表征。

条件概率

我们将把讨论的问题限定在所构成的概率空间 Ω 是可数(可能是有限的), 以及事件的集合为所有 Ω 子集的集类的情况。

给定两个随机变量 A 和 B , 我们定义给定 A 的情况下 B 的条件概率为:

$$P(B|A) = \begin{cases} \frac{P(A \cap B)}{P(A)}, & \text{若 } P(A) > 0, \\ 0, & \text{若 } P(A) = 0. \end{cases}$$

如果 $B_1, B_2, \dots$ 是互斥和穷举事件的一个可数(可能有限)集类(即集合 B_i 为不相交, 且它们的集为 Ω), A 是一个事件, 则我们有:

$$P(A) = \sum_i P(A \cap B_i).$$

从前面二个关系, 看出:

$$P(A) = \sum_i P(B_i)P(A|B_i).$$

从这些表达式我们得到, 对每一个 k , 假定 $P(A) > 0$,

$$P(B_k|A) = \frac{P(A \cap B_k)}{P(A)} = \frac{P(B_k)P(A|B_k)}{\sum_i P(B_i)P(A|B_i)}.$$

现在考虑分别在 R^n 和 R^m 取值的(可数)概率空间上二个随机向量[即, 对所有 $\omega \in \Omega$, $x(\omega) \in R^n$, $y(\omega) \in R^m$], 分别给定 R^n 和 R^m 的二个子集 X 和 Y , 我们记

$$P(X|Y) = P(\{\omega | x(\omega) \in X\} | \{\omega | y(\omega) \in Y\}).$$

对每一个固定的向量 $w \in R^m$, 我们定义给定 w 时 x 的条件分布函数为:

$$F(z|w) = P(\{\omega | x(\omega) \leq z\} | \{\omega | y(\omega) = w\}).$$

给定 w 时, x 的条件期望为

$$E\{x|w\} = \int_{R^n} z dF(z|w),$$

假定积分是适当定义的。注意到 $E\{x|w\}$ 是一个将 w 映射到 R^n 的函数。

最后, 我们推导随机向量贝页斯规则。如果 $\omega_1, \omega_2, \dots$ 是 Ω 的元, 表记:

$$z_i = x(\omega_i), w_i = y(\omega_i), i = 1, 2, \dots$$

又, 对任意 $z \in R^n$, $w \in R^m$, 让我们表记:

$$P(z) = P(\{\omega | x(\omega) = z\}), P(w) = P(\{\omega | y(\omega) = w\})$$

如果 $z \neq z_i, i = 1, 2, \dots$, 有 $P(z) = 0$; 如果 $w \neq w_i, i = 1, 2, \dots$, $P(w) = 0$, 又表记:

$$P(z|w) = P(\{\omega | x(\omega) = z\} | \{\omega | y(\omega) = w\})$$

如 $P(w) > 0$, 则得贝页斯规则:

$$P(z_i|w) = \frac{P(z_i)P(w|z_i)}{\sum_i P(z_i)P(w|z_i)}, i = 1, 2, \dots,$$

$$P(z|w) = 0, \quad \text{如果 } z \neq z_i, i = 1, 2, \dots.$$

式中

$$P(w|z) = P(\{\omega | y(\omega) = w\} | \{\omega | x(\omega) = z\}).$$

附录 D

关于有限状态马尔科夫链

一个 $n \times n$ 方阵 $[p_{ij}]$ 称为随机矩阵, 如果所有元素都是非负的, 即 $p_{ij} \geq 0$, $i, j = 1, \dots, n$, 它的每一行元素之和为 1, 即对所有 $i = 1, \dots, n$, $\sum_{j=1}^n p_{ij} = 1$.

平稳有限状态马尔科夫链

假定给定一个随机的 $n \times n$ 矩阵 P 以及称为状态空间的一个有限集合 $S = \{1, \dots, n\}$. S 的元称为状态. (S, P) 对就是一个平稳有限状态马尔科夫链. 我们把 (S, P) 与一个过程联系起来. 依据此过程, 按某个初始概率分布:

$$p_0 = (p_0^1, p_0^2, \dots, p_0^n),$$

选择一个初始状态 $x_0 \in S$, 结果, 按照如下由 P 指定的概率分布, 形成了从状态 x_0 到状态 $x_1 \in S$ 的一个转移. 每当初始状态为 i , 新状态为 j 的概率将等于 p_{ij} , 即

$$P(x_1 = j | x_0 = i) = p_{ij}, \quad i, j = 1, \dots, n.$$

类似地, 按照

$$P(x_{k+1} = j | x_k = i) = p_{ij}, \quad i, j = 1, \dots, n, \quad (D \cdot 1)$$

逐次的转移产生状态 $x_2, x_3, \dots$.

给定初始状态 x_0 为 i , 在第 k 次转移后状态 x_k 为 j 的概率表示为

$$p_{ij}^k = P(x_k = j | x_0 = i), \quad i, j = 1, \dots, n. \quad (D \cdot 2)$$

容易看出, 这些概率等于矩阵 p^k (p 的 k 次幂) 的元素, 意即 p_{ij}^k 为 P^k 第 i 行第 j 列元素:

$$P^k = [p_{ij}^k]. \quad (D \cdot 3)$$

给定状态 x_0 (看作 R^n 中一个列向量) 的初始概率分布 p_0 , 在 k 次转移之后, 状态 x_k 的概率分布

$$p_k = (p_k^1, p_k^2, \dots, p_k^n)$$

(也看成一行向量) 给定为:

$$p_k = p_0 P^k, \quad k = 1, 2, \dots. \quad (D \cdot 4)$$

一旦我们写出:

$$p_k^j = \sum_{i=1}^n P(x_k = j | x_0 = i) p_0^i = \sum_{i=1}^n p_{ij}^k p_0^i.$$

式 $(D \cdot 4)$ 这个关系式立即可从式 $(D \cdot 2)$ 和式 $(D \cdot 3)$ 获得.

马尔科夫链状态的分类

给定一个平稳有限状态马尔科夫链 (S, P) , 如果存在两个正整数 k_1 和 k_2 , 使 $p_{ii}^{k_1} > 0$ 和 $p_{jj}^{k_2} > 0$, 我们说此两状态互通. 换句话说, 状态 i 和 j 是互通的, 如果一个状态可以按正的概率从另一状态达到.

令 $\tilde{S} \subset S$ 为一个状态的子集使:

1) 所有在 $\tilde{S}$ 中的状态互通。

2) 如果 $i \in \tilde{S}$, 和 $j \notin \tilde{S}$, 则对所有 k , $p_{ij}^k = 0$ 。

如果 S 本身组成一个遍历类(即所有状态彼此互通), 则马尔科夫链是不可约的。有可能存在几个遍历类。证明至少必定存在一个遍历类也是可能的。不属于任何遍历类的状态称为瞬态。瞬态由下式表征:

$$\lim_{k \rightarrow \infty} p_{ii}^k = 0, \text{ 当且仅当 } i \text{ 为瞬态时。}$$

换句话说, 如果过程开始于一个瞬态, 在 k 次转移之后回到同一状态的概率, 当 k 趋向无限大时, 减少到零。

这定义说明, 一旦进入一个遍历类, 则对每一个随后的转移, 过程保持在遍历类内。因此, 如果过程在一个遍历类内开始, 它就驻留在此类内。如果它在一个瞬态开始, 几个转移之后, 它必然地(概率为 1)进入一个遍历类并往后保留在该遍历类内。

极限概率

任何随机矩阵的一个重要性质是: 存在由下式定义的矩阵 P^*

$$P^* = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=0}^{N-1} P^k.$$

[意即 $(1/N) \sum_{k=0}^{N-1} P^k$ 的元素序列收敛于相应的 P^* 元素]。 P^* 的元素 p_{ij}^* 满足

$$p_{ij}^* \geq 0, \quad \sum_{j=1}^n p_{ij}^* = 1, \quad i=1, \dots, n.$$

即 P^* 是一个随机矩阵。这个论据的证明在第七章的附录命题 A 7.1 中给出。

如果 $\tilde{S} \subset S$ 是一个遍历类, $i, j \in \tilde{S}$, 则可以证明, 对所有 $k \in \tilde{S}$,

$$p_{ik}^* = p_{jk}^* > 0,$$

所以, 如一个马尔科夫链是不可约的, 矩阵 P^* 有相同的行。又, 如果 j 是一个瞬态, 我们有:

$$p_{ij}^* = 0, \text{ 对所有 } i \in S.$$

所以相应于瞬态的矩阵 P^* 的列均恒为零。

首次通过时间

让我们用 q_{ij}^k 表示给定初始状态为 i , 在准确地 $k \geq 1$ 次转移之后, 第 1 次状态为 j 的概率, 即

$$q_{ij}^k = P(x_k = j, x_m \neq j, 1 \leq m < k | x_0 = i).$$

又, 对固定的 i 和 j , 表记:

$$K_{ij} = \min\{k \geq 1 | x_k = j, x_0 = i\}.$$

则 K_{ij} 称为从 i 到 j 首次通过时间。它可以看成是一个随机变量。对每一个 $k=1, 2, \dots$, 我们有

$$P(K_{ij} = k) = q_{ij}^k,$$

且写成:

$$P(K_{ij} = \infty) = P(x_k \neq j, k=1, 2, \dots | x_0 = i) = 1 - \sum_{k=1}^{\infty} q_{ij}^k.$$

当然, $\sum_{k=1}^{\infty} q_{ij}^k < 1$ 是有可能的。例如, 如果从 i 不能到达 j , 就会发生这种情况。在这种情况下, 对所有 $k=1, 2, \dots, q_{ij}^k = 0$ 。从 i 到 j 平均首次通过时间是 K_{ij} 的期望值:

$$E\{K_{ij}\} = \begin{cases} \sum_{k=1}^{\infty} k q_{ij}^k, & \text{若 } \sum_{k=1}^{\infty} q_{ij}^k = 1, \\ \infty, & \text{若 } \sum_{k=1}^{\infty} q_{ij}^k < 1. \end{cases}$$

可以证明, 如果 i 和 j 属于同一遍历类, 则

$$E\{K_{ij}\} < \infty.$$

如果 i 和 j 属于两个不同的遍历类, 则 $E\{K_{ij}\} = E\{K_{ji}\} = \infty$ 。如果 i 属于一个遍历类, j 是瞬时的, 则我们有 $E\{K_{ij}\} = \infty$ 。关于详细的说明, 见[A 9],[C 2],[K 6]和[R 8]。

参 考 文 献

- [A 1] Anderson, B. D. O., and Moore, J. B., *Optimal Filtering*. Prentice-Hall, Englewood Cliffs, N. J., 1979.
- [A 2] Aoki, M., *Optimization of Stochastic Systems—Topics in Discrete-Time Systems*, Academic Press, New York, 1967.
- [A 3] Aoki, M., *Introduction to Optimization Techniques*. Macmillan, New York, 1971.
- [A 4] Aoki, M., and Li, M. T., Optimal discrete-time control systems with cost for observation, *IEEE Trans. Automatic Control* **AC-14** (1969), 165–175.
- [A 5] Arrow, K. J., *Aspects of the Theory of Risk Bearing*. Yrjö Jahnsson Lecture Series, Helsinki, Finland, 1965.
- [A 6] Arrow, K. M., Blackwell, D., and Girshick, M. A., Bayes and minimax solutions of sequential design problems, *Econometrica* **17** (1949), 213–244.
- [A 7] Arrow, K. J., Harris, T., and Marschack, J., Optimal inventory policy, *Econometrica* **19** (1951), 250–272.
- [A 8] Arrow, K. H., Karlin, S., and Scarf, H., *Studies in the Mathematical Theory of Inventory and Production*. Stanford University Press, Stanford, California, 1958.
- [A 9] Ash, R. B., *Basic Probability Theory*. Wiley, New York, 1970.
- [A 10] Ash, R. B., and Gardner, M. F., *Topics in Stochastic Processes*. Academic Press, New York, 1975.
- [A 11] Åström, K. J., *Introduction to Stochastic Control Theory*. Academic Press, New York, 1970.
- [A 12] Åström, K. J., Theory and applications of adaptive control—a survey, *Automatica*, **19** (1983), 471–486.
- [A 13] Åström, K. J., and Wittenmark, B. *Computer Controlled Systems*, Prentice-Hall, Englewood Cliffs, N. J., 1984.
- [A 14] Åström, K. J., and Wittenmark, B., On self-tuning regulators, *Automatica* **9** (1973), 185–199.
- [A 15] Atkinson, R. C., Bower, G. H., and Crothers, E. J., *An Introduction to Mathematical Learning Theory*. Wiley, New York, 1965.
- [B 1] Bar-Shalom, Y., and Tse, E., Dual effect, certainty equivalence, and separation in stochastic control, *IEEE Trans. Automatic Control* **AC-19** (1974), 494–500.
- [B 2] Baras, J. S., Dorsey, A. J., and Makowski, A. M., Two compet-

- ing queues with linear costs; The μ c-rule is often optimal, Report SRR 83-1, Department of Electrical Engineering, University of Maryland, 1983.
- [B 3] Baras, J. S., and Dorsey, A.J., Stochastic control of two partially observed competing queues, *IEEE Trans. Aut. Control* **AC-26** (1981), 1106-1117.
 - [B 4] Bather, J., Optimal decision procedures for finite Markov chains, *Advances in Appl. Probability* **5** (1973), 328-339, 521-540, 541-553.
 - [B 5] Bellman, R., *Dynamic Programming*. Princeton University Press, Princeton, N. J., 1957.
 - [B 6] Bellman, R., and Dreyfus, S., *Applied Dynamic Programming*, Princeton University Press, Princeton, N. J., 1962.
 - [B 7] Bensoussan, A., and Lions, J. L., *Applications des Inequations Variationnelles en Controle Stochastique*. Dunod, Paris, 1978.
 - [B 8] Bertsekas, D. P., On the separation theorem for linear systems, quadratic criteria, and correlated noise, unpubl. rep., Electronic Systems Lab., MIT, Cambridge, Mass., September 1970 .
 - [B 9] Bertsekas, D. P., Control of uncertain systems with a set-membership description of the uncertainty." Ph. D. Dissertation, MIT, Cambridge, Mass., 1971.
 - [B 10] Bertsekas, D. P., Stochastic optimization problems with nondifferentiable cost functionals with an application in stochastic programming, *Proc. IEEE Decision and Control Conf.*, New Orleans, La., December 1972.
 - [B 11] Bertsekas, D. P., On the solution of some minimax problems, *Proc. IEEE Decision and Control Conf.*, New Orleans, La., December 1972.
 - [B 12] Bertsekas, D. P., Infinite time reachability of state space regions by using feedback control, *IEEE Trans. Automatic Control* **AC-17** (1972), 604-613.
 - [B 13] Bertsekas, D. P., Stochastic optimization problems with nondifferentiable cost functionals, *J. Optimization Theory Appl.* **12** (1973), 218-231.
 - [B 14] Bertsekas, D. P., Linear convex stochastic control problems over an infinite time horizon, *IEEE Trans. Automatic Control* **AC-18** (1973), 314-315.
 - [B 15] Bertsekas, D. P., Necessary and sufficient conditions for existence of an optimal portfolio, *J. Econom. Theory* **8** (1974), 235-247.
 - [B 16] Bertsekas, D. P., Monotone mappings with application in dynamic

- programming, *SIAM J. Control and Optimization* **15** (1977), 438-464.
- [B 17] Bertsekas, D. P., On error bounds for successive approximation methods, *IEEE Trans. Automatic Control* **AC-21** (1976), 394-396.
- [B 18] Bertsekas, D. P., Convergence of discretization procedures in dynamic programming, *IEEE Trans. Automatic Control* **AC-20** (1975), 415-419.
- [B 19] Bertsekas, D. P., Distributed dynamic programming, *IEEE Trans. Automatic Control* **AC-27** (1982), 610-616.
- [B 20] Bertsekas, D. P., and Castanon, D., Dynamic Aggregation Methods for Discounted Markovian Decision Problems, Proc. of 25th IEEE Conference on Decision and Control, Athens, Greece, Dec. 1986; *IEEE Trans. on Aut. Control* (to appear).
- [B 21] Bertsekas, D. P., and Rhodes, I. B., On the minimax reachability of target sets and target tubes, *Automatica* **7** (1971), 233-247.
- [B 22] Bertsekas, D. P. and Rhodes, I. B., Sufficiently informative functions and the minimax feedback control of uncertain dynamic systems, *IEEE Trans. Automatic Control* **AC-18** (1973), 117-124.
- [B 23] Bertsekas, D. P., and Shreve, S. E., *Stochastic Optimal Control: The Discrete Time Case*. Academic Press, New York, 1978.
- [B 24] Bertsekas, D. P., and Shreve, S. E., Existence of optimal stationary policies in deterministic optimal control, *J. Math. Anal. and Appl.* **69** (1979), 607-620.
- [B 25] Billingsley, P., The singular function of bold play, *American Scientist* **71** (1983), 392-397.
- [B 26] Blackwell, D., Discrete dynamic programming, *Ann. Math. Statist.* **33** (1962), 719-726.
- [B 27] Blackwell, D., Discounted dynamic programming. *Ann. Math. Statist.* **36** (1965), 226-235.
- [B 28] Blackwell, D., Positive dynamic programming, *Proc. 5th Berkeley Symp. Math., Statist., and Probability* **1** (1965), 415-418.
- [B 29] Blackwell, D., On stationary policies, *J. Roy. Statist. Soc. Ser. A*, **133** (1970), 33-38.
- [B 30] Blackwell, D., and Girshick, M. A., *Theory of Games and Statistical Decisions*. Wiley, New York, 1954.
- [B 31] Blake, I. F., and Thomas, J. B., On a class of processes arising in linear estimation theory, *IEEE Trans. Information Theory* **IT-14** (1968), 12-16.
- [B 32] Borkar, V., and Varaiya, P.P., Identification and adaptive control of Markov chains. *SIAM J. on Control and Optimization* **20** (1982),

- [B 33] Borkar, V., and Varaiya, P. P., Adaptive control of Markov chains, I: Finite parameter set, *IEEE Trans. Aut. Control* **AC-24** (1979), 953-958.
- [B 34] Brown, B. W., On the iterative method of dynamic programming on a finite space discrete Markov process, *Ann. Math. Statist.* **36** (1965), 1279-1286.
- [C 1] Chernoff, H., *Sequential Analysis and Optimal Design*. Regional Conference Series in Applied Mathematics, SIAM, Philadelphia, Pa., 1972.
- [C 2] Chung, K. L., *Markov Chains with Stationary Transition Probabilities*. Springer-Verlag, Berlin and New York, 1960.
- [C 3] Cooper, C. A., and Nahi, N. E., An optimal stochastic control problem with observation cost, *Proc. Joint Automatic Control Conf.*, Atlanta, Ga., June 1970.
- [C 4] Courcoubetis, C., and Varaiya, P. P., The service process with least thinking time maximizes resource utilization, *IEEE Trans. Aut. Control* **AC-29** (1984), 1005-1008.
- [C 5] Crabill, T. B., Gross, D., and Magazine, M. J., A classified bibliography of research on optimal design and control of queues, *Operations Res.* **25** (1977), 219-232.
- [D 1] DeGroot, M. H., *Optimal Statistical Decisions*. McGraw-Hill, New York, 1970.
- [D 2] Denardo, E. V., Contraction mappings in the theory underlying dynamic programming, *SIAM Rev.* **9** (1967), 165-177.
- [D 3] D'Epenoux, F., Sur un probleme de production et de stockage dans l'aleatoire, *Rev. Francaise Automat. Informat. Recherche Operationnelle* **14** (1960) (English Transl: *Management Sci.* **10** (1963), 98-108).
- [D 4] Derman, C., *Finite State Markovian Decision Processes*. Academic Press, New York, 1970.
- [D 5] Deshpande, J. G., Upadhyay, T. N., and Lainiotis, D. G., Adaptive control of linear control systems, *Automatica* **9** (1973), 107-115.
- [D 6] Dial, R., and others. A computational analysis of alternative algorithms and labeling techniques for finding shortest path trees, *Networks* **9** (1979), 215-248.
- [D 7] Doshi, B., and Shreve, S., Strong consistency of a modified maximum likelihood estimator for controlled Markov chains, *J. of*

Applied Probability **17** (1980), 726-734.

- [D 8] Dreyfus, S. E., *Dynamic Programming and the Calculus of Variations*. Academic Press, New York, 1965.
- [D 9] Dubins, L., and Savage, L. M., *How to Gamble If You Must*. McGraw-Hill, New York, 1965.
- [D 10] Dynkin, E. B., Controlled random sequences, *Theor. Probability Appl.* **10** (1965), 1-14.
- [D 11] Dynkin, E. B., and Juskevici, A. A., *Controlled Markov Processes*. Springer-Verlag, New York, 1979.
- [E 1] Eaton, J. H., and Zadeh, L. A., Optimal pursuit strategies in discrete state probabilistic systems, *Trans. ASME Ser. D, J. Basic Eng.* **84** (1962), 23-29.
- [E 2] Eckles, J. E., Optimum maintenance with incomplete information, *Operations Res.* **16** (1968), 1058-1067.
- [E 3] Ephremides, A., Varaiya, P. P., and Walrand, J. C., A simple dynamic routing problem, *IEEE Trans. Aut. Control* **AC-25** (1980), 690-693.
- [F 1] Federgruen, A., Schweitzer, P. J., and Tijms, H. C., Denumerable undiscounted semi-Markov decision processes with unbounded rewards, *Math. of Operations Res.* **8** (1983), 298-313.
- [F 2] Feller, W., *An Introduction to Probability Theory and Its Applications*, 3rd ed. Wiley, New York, 1968.
- [F 3] Fleming, W., and Rishel, R., *Optimal Deterministic and Stochastic Control*, Springer-Verlag, New York, 1975.
- [F 4] Forney, G. D., The Viterbi algorithm, *Proc. IEEE* **61** (1973), 268-278.
- [F 5] Fox, B. L., Finite state approximations to denumerable state dynamic programs, *J. Math. Anal. Appl.* **34** (1971), 665-670.
- [G 1] Gittins, J. C., Bandit processes and dynamic allocation indices, *J. Roy. Statist. Soc., B*, **41** (1979), 148-164.
- [G 2] Gittins, J. C., and Jones, D. M., A dynamic allocation index for the sequential design of experiments, in *Progress in Statistics* (J. Gani, ed.), North-Holland, Amsterdam, 1974, pp. 241-266.
- [G 3] Goodwin, G. C., and Sin, K. S. S., *Adaptive Filtering, Prediction, and Control*, Prentice-Hall, Englewood Cliffs, N. J., 1984.
- [G 4] Groen, G. J., and Atkinson, R. C., Models for optimizing the learning process, *Psychol. Bull.* **66** (1966), 309-320.
- [G 5] Gunckel, T. L., and Franklin, G. R., A general solution for linear sampled-data control, *Trans. ASME Ser. D, J. Basic Engrg.* **85**

- (1963), 197-201.
- [H 1] Hajek, B., Optimal control of two interacting service stations, *IEEE Trans. Aut. Control* **29** (1984), 491-499.
 - [H 2] Hajek, B., and van Loon, T., Decentralized dynamic control of a multiaccess broadcast channel, *IEEE Trans. Aut. Control* **AC-27** (1982), 559-569.
 - [H 3] Harrison, J. M., A priority queue with discounted linear costs, *Operations Res.* **23** (1975), 260-269.
 - [H 4] Harrisen, J. M., Dynamic scheduling of a multiclass queue: Discount optimality, *Operations Res.* **23** (1975), 270-282.
 - [H 5] Hastings, N. A. J., Some notes on dynamic programming and replacement, *Operational Res. Quart.* **19** (1968), 453-464.
 - [H 6] Haurie, A., and L'Ecuyer, P., Approximation and bounds in discrete event dynamic programming, *IEEE Trans. Aut. Control* **AC-31** (1986), 227-235.
 - [H 7] Hendrikx, M., Van Nunen, J., and Wessels, J., On iterative optimization of structured Markov decision-processes, *Math. Oper. u. Statist.* **15** (1984), 439-459.
 - [H 8] Heyman, D. P., and Sobel, M. J., *Stochastic Models in Operations Research*, McGraw-Hill, New York, Vol. I, 1982, Vol. II, 1984.
 - [H 9] Hinderer, K., *Foundations of Non-Stationary Dynamic Programming with Discrete Time Parameter*. Springer-Verlag, New York, 1970.
 - [H 10] Hoffman, K., and Kunze, R., *Linear Algebra*. Prentice-Hall, Englewood Cliffs, N. J., 1961.
 - [H 11] Holt, C. C., Modigliani, F., and Simon, H. A., A linear decision rule for production and employment scheduling, *Management Sci.* **2** (1955), 1-30.
 - [H 12] Hordijk, A., and Tijms, H., The method of successive approximations and Markovian decision problems, *Operations Res.* **22** (1974), 519-521.
 - [H 13] Hordijk, A., and Tijms, H. C., Convergence results and approximations for optimal (s,S) policies, *Management Sci.* **20** (1974), 1432-1438.
 - [H 14] Hordijk, A., and Tijms, H. C., On a conjecture of Iglehart, *Management Sci.* **21** (1975), 1342-1345.
 - [H 15] Howard, R., *Dynamic Programming and Markov Processes*. MIT Press, Cambridge, Mass., 1960.
 - [H 16] Howard, R., *Dynamic Probabilistic Systems*, Vols. I and II. Wiley, New York, 1971.

- [I 1] *IEEE Trans. Aut. Control*, special issue on Linear-Quadratic Gaussian Problem, **AC-16** (1971).
- [I 2] Iglehart, D. L., Optimality of (S, s) policies in the infinite horizon dynamic inventory problem, *Management Sci.* **9** (1963), 259-267.
- [I 3] Iglehart, D. L., Dynamic programming and stationary analysis of inventory problems, in Scarf, H., Gilford, D., and Shelly, M. (eds.), *Multistage Inventory Models and Techniques*. Stanford University Press, Stanford, Calif., 1963.
- [J 1] Jacobson, D. H., Optimal stochastic linear systems with exponential performance criteria and their relation to deterministic differential games, *IEEE Trans. Aut. Control* **AC-18** (1973), 124-131.
- [J 2] Jacobson, D. H., A general result in stochastic optimal control of nonlinear discrete-time systems with quadratic performance criteria, *J. Math. Anal. Appl.* **47** (1974), 153-161.
- [J 3] Jazwinski, A. H., *Stochastic Processes and Filtering Theory*. Academic Press, New York, 1970.
- [J 4] Jewell, W., Markov renewal programming I and II, *Operations Res.* **11** (1963), 938-971.
- [J 5] Joseph, P. D., and Tou, J. T., On linear control theory, *AIEE Trans.* **80** (II) (1961), 193-196.
- [K 1] Kalman, R. E., A new approach to linear filtering and prediction problems, *Trans. ASME Ser. D. J. Basic Engrg.* **82** (1960), 35-45.
- [K 2] Kalman, R. E., and Koepcke, R. W., Optimal synthesis of linear sampling control systems using generalized performance indexes, *Trans. ASME* **80** (1958), 1920-1926.
- [K 3] Karush, W., and Dear, E. E., Optimal stimulus presentation strategy for a stimulus sampling model of learning, *J. Mathematical Psychology* **3** (1966), 15-47.
- [K 4] Katehakis, M., and Veinott, A. F., *The Multi-Armed Bandit Problem: Decomposition and Computation*, T. R. 41, Department of Operations Research, Stanford University, Stanford, Calif., July 1985.
- [K 5] Kaufmann, A., and Cruon, R., *Dynamic Programming*. Academic Press, New York, 1967.
- [K 6] Kemeny, J. G., and Snell, J. L., *Finite Markov Chains*. Van Nostrand-Reinhold, New York, 1960.
- [K 7] Kimemia, J., Gershwin, S. B., and Bertsekas, D.P., Computation of production control policies by a dynamic programming technique,

- in *Analysis and Optimization of Systems* (A. Bensoussan and J. L. Lions, eds.), Springer-Verlag, New York, 1982, pp. 243-269.
- [K 8] Kimemia, J., Hierarchical control of production in flexible manufacturing systems, Ph.D. thesis, MIT, Department of Electrical Engineering and Computer Science, April 1982.
 - [K 9] Kleinman, D. L., On an iterative technique for Riccati equation computations, *IEEE Trans. Aut. Control*, **AC-13** (1968), 114-115.
 - [K 10] Kumar, P. R., A survey of some results in stochastic adaptive control, *SIAM J. Control Optimization* **23** (1985), 329-380.
 - [K 11] Kumar, P. R., Optimal adaptive control of linear-quadratic-Gaussian systems, *SIAM J. Control Optimization* **21** (1983), 163-178.
 - [K 12] Kumar, P. R., and Lin, W., Optimal adaptive controllers for unknown Markov chains, *IEEE Trans. Aut. Control* **AC-27** (1982), 765-774.
 - [K 13] Kumar, P. R., and Varaiya, P. P., *Stochastic Systems: Estimation, Identification, and Adaptive Control*. Prentice-Hall, Englewood Cliffs, N. J., 1986.
 - [K 14] Kushner, H. J., *Introduction to Stochastic Control*. Holt, Rinehart and Winston, New York, 1971.
 - [K 15] Kushner, H. J., Optimality conditions for the average cost per unit time problem with a diffusion model, *SIAM J. Control Optimization* **16** (1978), 330-346.
 - [L 1] Lasserre, J. B., A mixed forward-backward dynamic programming method using parallel computation, *J. Optimization Theory Appl.* **45** (1985), 165-168.
 - [L 2] Levy, D., *The Chess Computer Handbook*. B. T. Batsford Ltd., London, 1984.
 - [L 3] Lin, W., and Kumar, P. R., Optimal control of a queueing system with two heterogeneous servers, *IEEE Trans. Aut. Control* **AC-29** (1984), 696-703.
 - [L 4] Lippman, S., Applying a new device in the optimization of exponential queueing systems, *Operations Res.* **23** (1975), 687-710.
 - [L 5] Liusternik, L., and Sobolev, V., *Elements of Functional Analysis*. Ungar, New York, 1961.
 - [L 6] Ljung, L., On positive real transfer functions and the convergence of some recursions, *IEEE Trans. Aut. Control* **AC-22** (1977), 539-551.
 - [L 7] Ljung, L., *System Identification: Theory for the User*. Prentice-Hall, Englewood Cliffs, N. J., 1986.

- [L 8] Ljung, L., and Soderstrom, T., *Theory and Practice of Recursive Identification*, MIT Press, Cambridge, Mass., 1983.
- [L 9] Luenberger, D. G., *Optimization by Vector Space Methods*, Wiley, New York, 1969.
- [L 10] Luenberger, D. G., *Linear and Nonlinear Programming*, Addison-Wesley, Reading, Mass., 1984.
- [M 1] Malinvaud, E., First order certainty equivalence, *Econometrica* **37** (1969), 706-718.
- [M 2] Mandl, P., Estimation and control in Markov chains, *Advances in Applied Probability* **6** (1974), 40-60.
- [M 3] Manne, A., Linear programming and sequential decisions, *Management Sci.* **6** (1960), 259-267.
- [M 4] Markovitz, H., *Portfolio Selection*, Wiley, New York, 1959.
- [M 5] McQueen, J., A modified dynamic programming method for Markovian decision problems, *J. Math. Anal. Appl.* **14**(1966), 38-43.
- [M 6] Meditch, J. S. *Stochastic Optimal Linear Estimation and Control*, McGraw-Hill, New York, 1969.
- [M 7] Mendel, J. M., *Discrete Techniques of Parameter Estimation-The Equation Error Formulation*, Dekker, New York, 1973.
- [M 8] Morton, T. E., On the asymptotic convergence rate of cost differences for Markovian decision processes, *Operations Res.* **19**(1971), 244-248.
- [M 9] Morton, T.E., and Wecker, W., Discounting, ergodicity and convergence for Markov decision processes, *Management Sci.* **23** (1977), 890-900.
- [M10] Mossin, J., Optimal multi-period portfolio policies, *J. Business* **41** (1968), 215-229.
- [N 1] Nahi, N., *Estimation Theory and Applications*, Wiley, New York, 1969.
- [N 2] Nemhauser, G. L., *Introduction to Dynamic Programming*, Wiley, New York, 1966.
- [N 3] Newborn, M., *Computer Chess*, Academic Press, New York, 1975.
- [N 4] Norman, J. M., Dynamic programming in tennis-When to use a fast serve, *J. Opl. Res. Soc.* **36**(1985), 75-77.
- [O 1] Odoni, A. R., On finding the maximal gain for Markov decision processes, *Operations Res.* **17** (1969), 857-860.
- [O 2] Omura, J. K., On the Viterbi decoding algorithm, *IEEE Trans. Information Theory* **17-15** (1969), 117-179.
- [O 3] Ornstein, D., On the existence of stationary optimal strategies,

- Proc. Amer. Math. Soc.* **20** (1969), 563-569.
- [O 4] Ortega, J. M., and Rheinboldt, W. C., *Iterative Solution of Non-linear Equations in Several Variables*. Academic Press, New York, 1970.
 - [P 1] Pallu de la Barriere, R., *Optimal Control Theory*. Saunders, Philadelphia, 1967.
 - [P 2] Papadimitriou, C. H., and Steiglitz, K., *Combinatorial Optimization: Algorithms and Complexity*. Prentice-Hall, Englewood Cliffs, N. J., 1982.
 - [P 3] Papadimitriou, C. H., and Tsitsiklis, J. N., The complexity of Markov decision processes, *Math. of Operations Research* (to appear).
 - [P 4] Pape, V., Implementation and efficiency of Moore algorithms for the shortest path problem, *Math. Progr.* **7** (1974), 212-222.
 - [P 5] Papoulis, A., *Signal Analysis*. McGraw-Hill, New York, 1977.
 - [P 6] Papoulis, A., *Probability, Random Variables and Stochastic Processes*. McGraw-Hill, New York, 1965.
 - [P 7] Parzen, E., *Modern Probability Theory and Its Applications*. Wiley, New York, 1960.
 - [P 8] Pattipati, K. R., and Kleinman, D. L., Priority assignment using dynamic programming for a class of queueing systems, *IEEE Trans. Aut. Control* **AC-26** (1981), 1095-1106.
 - [P 9] Pearl, J., *Heuristics*. Addison-Wesley, Reading, Mass, 1984.
 - [P 10] Platzman, L., Comments on "Optimal and suboptimal stationary controls for Markov chains," *IEEE Trans. Aut. Control* **AC-24** (1979), 375.
 - [P 11] Platzman, L., Improved conditions for convergence in undiscounted Markov renewal programming, *Operations Res.* **25** (1977), 529-533.
 - [P 12] Popyak, J. L., Brown, R. L., and White, C. C., Discrete versions of an algorithm due to Varaiya, *IEEE Trans. Aut. Control* **AC-24** (1979), 503-504.
 - [P 13] Porteus, E., Bounds and transformations for finite Markov decision chains, *Operations Res.* **23** (1975), 761-784.
 - [P 14] Porteus, E., Some bounds for discounted sequential decision processes, *Management Sci.* **18** (1971), 7-11.
 - [P 15] Porteus, E., Overview of iterative methods for discounted finite Markov and semi-Markov decision chains, in *Rec. Developments in Markov Decision Processes*, R. Hartley, L. C. Thomas, and D. J. White (eds.), Academic Press, London, 1980.
 - [P 16] Puterman, M. L. (ed.), *Dynamic Programming and Its Applications*,

Academic Press, New York, 1978.

- [P 17] Puterman, M. L., and Brumelle, S. L., The analytic theory of policy iteration, in *Dynamic Programming and Its Applications*, M. L. Puterman (ed.), Academic Press, New York, 1978.
- [P 18] Puterman, M. L., and Shin, M. C., Action elimination procedures for modified policy iteration algorithms, *Operations Res.* **30** (1982), 301-308.
- [P 19] Puterman, M. L., and Shin, M. C., Modified policy iteration algorithms for discounted Markov decision problems, *Management Sci.* **24** (1978), 1127-1137.
- [R 1] Rivest, R. L., Network control by Bayesian broadcast, MIT, LCS Report, August 1985.
- [R 2] Rockafellar, R. T., *Convex Analysis*. Princeton University Press, Princeton, N. J., 1970.
- [R 3] Rockafellar, R. T., and Wets, R., Stochastic convex programming: Basic duality, *Pacific J. Math.* **62** (1976), 173-195.
- [R 4] Rosberg, Z., Varaiya, P. P., and Walrand, J. C., Optimal control of service in tandem queues, *IEEE Trans. Aut. Control* **AC-27** (1982), 600-609.
- [R 5] Ross, S. M., Arbitrary state Markovian decision processes, *Ann. Math. Statist.* **39** (1968), 2118-2122.
- [R 6] Ross, S. M., *Applied Probability Models with Optimization Applications*. Holden-Day, San Francisco, 1970.
- [R 7] Ross, S. M., *Introduction to Stochastic Dynamic Programming*. Academic Press, New York, 1983.
- [R 8] Ross, S. M., *Stochastic Processes*. Wiley, New York, 1983.
- [R 9] Royden, H. L., *Real Analysis*. Macmillan, New York, 1968.
- [R 10] Rudin, E., *Principles of Mathematical Analysis*. McGraw-Hill, New York, 1964.
- [S 1] Saridis, G. N., *Self-Organizing Control of Stochastic Systems*. Dekker, New York, 1977.
- [S 2] Saridis, G. N., and Dao, T. K., A learning approach to the parameter-adaptive self-organizing control problem, *Automatica* **8** (1972), 589-597.
- [S 3] Sawaragi, Y., and Yoshikawa, T., Discrete-time Markovian decision processes with incomplete state observation, *Ann. Math. Statist.* **41** (1970), 78-86.
- [S 4] Scarf, H., The optimality of (s, S) policies for the dynamic inventory problem, *Proceedings of the 1st Stanford Symposium on Mat-*

hematical Methods in the Social Sciences. Stanford University Press, Stanford, Calif., 1960.

- [S 5] Schal, M., On the optimality of (s, S) policies in dynamic inventory models with finite horizon, *SIAM J. Appl. Math.* **30** (1976), 528-537.
- [S 6] Schal, M., Conditions for optimality in dynamic programming and for the limit of n -stage optimal policies to be optimal, *Z. Wahrscheinlichkeitstheorie und Verw. Gebiete* **32** (1975), 179-196.
- [S 7] Schweitzer, P. J., Perturbation theory and finite Markov chains, *J. Appl. Prob.* **5** (1968), 401-413.
- [S 8] Schweitzer, P. J., Bottleneck determination in networks of queues, Graduate School of Management Working Paper No. 8107, University of Rochester, Rochester, N. Y., February 1981.
- [S 9] Schweitzer, P. J., Data transformations for Markov renewal programming, talk at National ORSA Meeting, Atlantic City, N.Y., November 1972.
- [S 10] Schweitzer, P. J., Iterative solution of the functional equations of undiscounted Markov renewal programming, *J. Math. Anal. Appl.* **34** (1971), 495-501.
- [S 11] Schweitzer, P. J., Puterman, M. L., and Kindle, K. W., Iterative aggregation-disaggregation procedures for solving discounted semi-Markovian reward processes, *Operations Research* **33** (1985), 589-605.
- [S 12] Schweitzer, P. J., and Federgruen, A., The asymptotic behavior of value iteration in Markov decision problems, *Math. Operations Res.* **2** (1977), 360-381.
- [S 13] Schweitzer, P. J., and Federgruen, A., The functional equations of undiscounted Markov renewal programming, *Math. Operations Res.* **3** (1978), 308-321.
- [S 14] Serfozo, R., An equivalence between discrete and continuous time Markov decision processes, *Operations Res.* **27** (1979), 616-620.
- [S 15] Serfozo, R., Optimal control of random walks, birth and death processes, and queues, *Adv. Appl. Prob.* **13** (1981), 61-83.
- [S 16] Shannon, C., Programming a digital computer for playing chess, *Phil. Mag.* **41** (1950), 356-375.
- [S 17] Shapley, L. S., Stochastic games, *Proc. Nat. Acad. Sci. U. S. A.* **39** (1953).
- [S 18] Sharpe, W., *Portfolio Theory and Capital Markets*. McGraw-Hill, New York, 1970.

- [S19] Simon, H. A., Dynamic programming under uncertainty with a quadratic criterion function, *Econometrica* **24** (1956), 74-81.
- [S20] Smallwood, R. D., The analysis of economic teaching strategies for a simple learning model, *J. Math. Psychology* **8** (1971), 285-301.
- [S21] Smallwood, R. D., and Sondik, E.J., The optimal control of partially observable Markov processes over a finite horizon. *Operations Res.* **11** (1973), 1071-1088.
- [S22] Sobel, M. J., The optimality of full-service policies, *Operations Res.* **30** (1982), 636-649.
- [S23] Sondik, E. J., The optimal control of partially observable Markov processes. Ph. D. Dissertation. Department of Engineering-Economic Systems. Stanford University, Stanford, Calif., June 1971.
- [S24] Stein, G., and Saridis, G. N., A parameter adaptive control technique, *Automatica* **5** (1969), 731-739.
- [S25] Stidham, S., and Prabhu, N. U., Optimal control of queuing systems, in *Mathematical Methods in Queuing Theory* (Lecture Notes in Economics and Math. Syst., Vol, 98), A. B. Clarke(Ed.). Springer-Verlag, New York, 1974. pp. 263-294.
- [S26] Stidham, S.S., Optimal control of admission to a queueing system, *IEEE Trans. Aut. Control* **AC-30** (1985), 705-713.
- [S27] Strang, G., *Linear Algebra and Its Applications*. Academic Press, New York, 1976.
- [S28] Strauch, R., Negative dynamic programming. *Ann. Math. Statist.* **37** (1966), 871-890.
- [S29] Striebel, C. T., Sufficient statistics in the optimal control of stochastic systems, *J. Math. Anal. Appl.* **12** (1965), 576-592.
- [S30] Striebel, C. T., *Optimal Control of Discrete Time Stochastic Systems*. Springer-Verlag, New York, 1975.
- [S31] Sussman, R., Optimal control of systems with stochastic disturbances, Electronics Research Lab., University of California, Berkeley, Rep. No. 63-20. November 1963.
- [S32] Sworder, D. D., Bayes' controllers with memory for a linear system with jump parameters. *IEEE Trans. Auto. Control* **AC-17** (1972), 119-121.
- [T1] Thau, F. E., and Witsenhausen, H. S., A comparison of closed-loop and open-loop optimum systems, *IEEE Trans. Auto. Control* **AC-11** (1966), 619-621.
- [T2] Theil, H., Econometric models and welfare maximization, *Weltw-*

- irtsch. Arch.* **72**(1954), 60-83.
- [T 3] Tse, E., and Athans, M., Adaptive stochastic control for a class of linear systems, *IEEE Trans. Auto. Control* **AC-17** (1972), 38-52.
 - [T 4] Tse, E., and Bar-Shalom, Y., An actively adaptive control for linear systems with random parameters via the dual control approach, *IEEE Trans. Auto. Control* **AC-18** (1973), 109-117.
 - [T 5] Tse, E., Bar-shalom, Y., and Meier, L., III, Wide-sense adaptive dual control for noolinear stochastic systems, *IEEE Trans. Auto. Control* **AC-18** (1973), 98-108.
 - [T 6] Tsitsiklis, J. N., Convexity and characterization of optimal policies in a dynamic routing problem, *J. Optimization Theory Appl.* **44** (1984), 105-136.
 - [T 7] Tsitsiklis, J. N., Periodic review inventory systems with continuous demand and discrete order sizes, *Management Sci.* **30** (1984), 1250-1254.
 - [T 8] Tsitsiklis, J. N., *Analysis of a Multiaccess Control Scheme*, Lab. for Info. and Decision Systems Report LIDS-P-1534, MIT. Feb. 1986.
 - [T 9] Tsitsiklis, J. N., A lemma on the multiarmed bandit problem, *IEEE Trans. Aut. Control* **AC-31** (1986), 576-577.
 - [V 1] Vajda, S., Stochastic programming, Chapter 14 in Abadie, J. (ed.), *Integer and Nonlinear Programming*, North-Holland, Amsterdam, 1970.
 - [V 2] Varaiya, P. P., Optimal and suboptimal stationary controls of Markov chains, *IEEE Trans. Aut. Control* **AC-23** (1978), 388-394.
 - [V 3] Varaiya, P. P., Walrand, J. C., and Buyukkoc, C., Extensions of the multiarmed bandit problem: The discounted case, *IEEE Trans. Auto. Control* **AC-30** (1985), 426-439.
 - [V 4] Veinott, A. F., Jr., On finding optimal policies in discrete dynamic programming with no discounting, *Ann. Math. Statist.* **37** (1966), 1284-1294.
 - [V 5] Veinott, A. F., Jr., The status of mathematical inventory theory, *Management Sci.* **12** (1966), 745-777.
 - [V 6] Veinott, A. F., Jr., Discrete dynamic programming with sensitive discount optimality criteria, *Ann. Math. Statist.* **40** (1969), 1635-1660.
 - [V 7] Veinnot, A. F., Jr., The optimal inventory policy for batch ordering, *Operations Res.* **13** (1965), 424-432.
 - [V 8] Veinott, A. F., Jr., and Wagner, H. M., Computing optimal (s,

- S) policies, *Management Sci.* **11** (1965), 525-552.
- [V 9] Vershik, A. M., Some characteristic properties of Gaussian stochastic processes, *Theory Probability Appl.* **9** (1964), 353-357.
- [W 1] Wald, A., *Sequential Analysis*. Wiley, New York, 1947.
- [W 2] Walkup, D., and Wets, R., Stochastic programs with recourse, *SIAM J. Appl. Math.* **15** (1967), 1299-1314.
- [W 3] Weiss, G., and Pinedo, M., Scheduling tasks with exponential service times on nonidentical processors to minimize various cost functions, *J. Appl. Prob.* **17** (1980), 187-202.
- [W 4] White, C. C., and Harrington, D.P., Application of Jensen's inequality to adaptive suboptimal design, *J. Optimization Theory Appl.* **32** (1980), 89-99.
- [W 5] White, C. C., and Schlussel, K., Suboptimal design for large scale, multimodule systems, *Operations Res.* **29** (1981), 865-875.
- [W 6] White, D. J., Dynamic programming. Markov chains, and the method of successive approximations, *J. Math. Anal. Appl.* **6** (1963), 373-376.
- [W 7] White, D.J., *Dynamic Programming*. Holden-Day, San Francisco, 1969.
- [W 8] White, D. J., Finite state approximations for denumerable state infinite horizon discounted Markov decision processes: The method of successive approximations, in *Recent Developments in Markov Decision Processes*, Hartley, R., Thomas, L. C., and White, D. J. (eds.), Academic Press, New York, 1980, pp.57-72.
- [W 9] Whitt, W., Approximations of dynamic programs I, *Math. Oper. Res.* **3** (1978), 231-243.
- [W 10] Whitt, W., Approximations of dynamic programs II, *Math. Oper. Res.* **4** (1979), 179-185.
- [W 11] Whittle, P., *Optimization over Time*, Wiley, New York, Vol. 1. 1982, Vol. 2, 1983.
- [W 12] Whittle, P., *Prediction and Regulation by Linear Least-Square Methods*. English Universities Press, London, 1963.
- [W 13] Witsenhausen, H. S., Minimax control of uncertain systems, Ph. D. Dissertation, Department of Electrical Engineering, MIT, Cambridge, Mass., May 1966.
- [W 14] Witsenhausen, H. S., Inequalities for the performance of suboptimal uncertain systems, *Automatica* **5** (1969), 507-512.
- [W 15] Witsenhausen, H. S., On performance bounds for uncertain systems, *SIAM J. Control* **8** (1970), 55-89.

- [W16] Witsenhausen, H. S., Separation of estimation and control for discrete-time systems, *Proc. IEEE* **59** (1971), 1557-1566.
- [Z1] Zwill, W. I., *Nonlinear Programming: A Unified Approach*, Prentice-Hall, Englewood Cliffs, N. J., 1969.

Images have been losslessly embedded. Information about the original file can be found in PDF attachments. Some stats (more in the PDF attachments):

```
{
  "filename": "MTAwNzAzMjEuemlw",
  "filename_decoded": "10070321.zip",
  "filesize": 24620308,
  "md5": "4f17ee1ca405ff54a9e235892937f8e1",
  "header_md5": "7a2aa4f0435f4a38f024529475f3ecdb",
  "sha1": "c5c58b03271235e3642259a1919e4e178d628cee",
  "sha256": "5fae3ec0d749892cfd6f88592695f18b2e54154050a3a159dbb21b451d68d63",
  "crc32": 1316806698,
  "zip_password": "",
  "uncompressed_size": 24983905,
  "pdg_dir_name": "\u2562\u00bb\u2560\u00bc\u2563\u00b5\u2557\u00ab\u255a\u2566\u2562\u00bf\u2568\u2558\u2551\u2550\u2566\u00b5\u2557\u00b7\u2500\u00fa\u2568\u2550_10070321",
  "pdg_main_pages_found": 287,
  "pdg_main_pages_max": 287,
  "total_pages": 295,
  "total_pixels": 2073878016,
  "pdf_generation_missing_pages": false
}
```